

PARTIAL PS !!

Curs 1 Introducere în teoria probabilităților

$$* P(A) = \frac{|A|}{|U|}$$

* $P(A) \approx \frac{k}{n}$ r.m. cureau în care ev. de interes s-a produs
 r.m. experimente

$$* P(C_n A) = 1 - P(A)$$

$$* P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

$$* P(A_1 \cup A_2 \cup A_3) = P(A_1) + P(A_2) + P(A_3) - P(A_1 \cap A_2) - P(A_2 \cap A_3) - P(A_1 \cap A_3) - P(A_1 \cap A_2 \cap A_3).$$

$$* P(A|B) = P(A) - P(A \cap B)$$

Curs 2 Probabilități conditionate. Formula lui Bayes

$$* P(E_2|E_1) = \frac{P(E_1 \cap E_2)}{P(E_1)}$$

$$P(E_2|E_1) = P_{E_1}(E_2)$$

* $P(E_1 \cap E_2) = P(E_2|E_1) \cdot P(E_1)$ sau $P(E_1 \cap E_2) = P(E_1) \cdot P(E_2)$,
dacă evenimentele sunt independente

$$P(H_k|A) = \frac{P(H_k)P(A|H_k)}{\sum_{i=1}^m P(H_i) \cdot P(A|H_i)}$$

Formula
lui Bayes

Curs 3 Variabile aleatorii discrete

$$X = (\begin{matrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{matrix}) \quad \sum_{i=1}^n p_i = 1.$$

N/N

Distribuția de probabilitate:

$$p_x : D \rightarrow [0,1] \quad p_x(x_k) = P(X=x_k)$$

Probabilitatea ca variabila aleatoare X să ia valori mai mici sau egale cu x :

funcție $F_X : \mathbb{R} \rightarrow [0,1]$

$$F_X(x) = P(X \leq x) \quad F_X(x) = \sum_{\{x_i \leq x\}} p_i$$

$$F_X(x) = \begin{cases} 0, & x < x_1 \\ p_1, & x_1 \leq x < x_2 \\ p_1 + p_2, & x_2 \leq x < x_3 \\ \vdots \\ p_1 + p_2 + \dots + p_k, & x_k \leq x < x_{k+1} \\ \vdots \\ 1, & x \geq x_m \end{cases}$$

PROPRIETĂȚI

$$\begin{cases} \lim_{x \rightarrow -\infty} F_X(x) = 0 \\ \lim_{x \rightarrow \infty} F_X(x) = 1. \\ a < b \Rightarrow F_X(a) < F_X(b). \end{cases}$$

Media $M(X) = \sum_{i=1}^n x_i p_i$

Dispersia $\sigma^2(X) = \sum_{i=1}^n (x_i - m)^2 p_i = M(x^2) - [M(x)]^2$

Curs 4 Vectori aleatori discrete

		<u>y</u>		
			<u>x₁</u>	<u>x₂</u>
			p ₁₁	p ₁₂
			p ₂₁	p ₂₂
<u>x</u>				
		x _i	p _{i1}	p _{i2}
		x _m	p _{m1}	p _{m2}

$\sim 2 \sim$

$$* P_{X,Y}(x_i, y_j) = P((X, Y) = (x_i, y_j)) = P(X = x_i, Y = y_j)$$

$$* \sum_{i=1}^m \sum_{j=1}^n p_{ij} = 1.$$

Functia de repartitie

$$F_{(X,Y)}(x, y) = P(X \leq x, Y \leq y)$$

$$F_{(X,Y)}(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p(x_i, y_j).$$

OBS. $P(X = x_i) = \text{suma elem. de pe linia } i$

$$\Rightarrow p_i^* = \sum_{j=1}^m p_{ij}$$

$P(Y = y_j) = \text{suma elem. de pe coloane } j$.

Distributii de probabilitate ale var. aleatoarei X si Y :

$$X = \left(\begin{matrix} x_i \\ p_{i*} \end{matrix} \right) \quad i \in \{1, m\} \quad Y = \left(\begin{matrix} y_j \\ p_{*j} \end{matrix} \right) \quad j \in \{1, n\}$$

Variabile aleatoare conditionate

$$P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{p_{*j}} = \boxed{\frac{p_{ij}}{\sum_{i=1}^m p_{ij}}}$$

$$(X | Y = y_j) = \left(\begin{matrix} x_1 & x_2 & \dots & x_i & \dots & x_m \\ p(x_1 | y_j) & p(x_2 | y_j) & \dots & p(x_i | y_j) & \dots & p(x_m | y_j) \end{matrix} \right)$$

$$(Y | X = x_i) = \left(\begin{matrix} y_1 & y_2 & \dots & y_j & \dots & y_m \\ p(y_1 | x_i) & p(y_2 | x_i) & \dots & p(y_j | x_i) & \dots & p(y_m | x_i) \end{matrix} \right)$$

~3~

Cursul 5 Distribuții clasică de probabilitate

Distribuția Bernoulli Se aruncă o monedă $X \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$ $M(X) = p$
 $B = 0$ $q = 1 - p$ $\sigma^2(X) = p(1-p)$.
 $S = 1$
 $X \sim \text{Bernoulli}(p)$ p - prob. succeseului

Distribuția Binomială Se aruncă o monedă n ori. $X \begin{pmatrix} k \\ C_n^k p^k (1-p)^{n-k} \end{pmatrix}$ $M(X) = np$
 $X \sim \text{Bin}(n, p)$ $k = 0, 1, \dots, n$ $\sigma^2(X) = npq$.
 $1 - p = q$

Distribuția Geometrică Se aruncă o monedă de un nr. infinit de ori. $X \begin{pmatrix} k \\ (1-p)^{k-1} \cdot p \end{pmatrix}$ $M(X) = \frac{1}{p}$
 $X \sim \text{Geom}(p)$ $k \in \mathbb{N}^*$ $\sigma^2(X) = \frac{1}{p^2}$.
 $1 - p = q$

Distribuția Hipergeometrică Se aruncă m monede din N monede $X \begin{pmatrix} k \\ C_N^k \cdot C_m^{m-k} \end{pmatrix}$ $M(X) = mp$
 $a = \text{monedă } A$ $\sigma^2(X) = \frac{N-m}{N-1} \cdot mpq$
 $b = \text{monedă } S$.
 $X \sim \text{Hypergeom}(N, m, p = \frac{a}{N})$ $1 - p = q$

Distribuția Poisson Se produc X evenimente rare - cu interval de timp fixat. $X \begin{pmatrix} k \\ e^{-\lambda} \cdot \lambda^k \end{pmatrix}$ $M(X) = \lambda$
 $X \sim \text{Pois}(\lambda)$ $k = 0, \dots, m, \dots$ $\sigma^2(X) = \lambda$

~ ~

Curs 6 Variații aleatoare continue

Densitate de prob. (p.d.f.)

$f: \mathbb{R} \rightarrow \mathbb{R}$ cu prop.: $f(x) \geq 0$

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$

Variația aleatoare continuă - m.a pt. căm distribuția de probab. este definită de o densitate de probab.


* Ce putem face cu p.d.f?

* Ne interesează $P(X \in I)$.

$$I = [a, b], (a, b), (a, b], [a, b), (-\infty, b], (\infty, b), (a, +\infty), [a, +\infty)$$

$$P(X \in I) = \int_I f_X(x) dx$$

Interpretare geometrică



$$\int_I f_X(x) dx = \text{Aria de sub } G_f.$$

obs. $P(X = a) = P(X \in [a, a]) = \int_a^a f_X(x) dx = 0.$

Funția de cumpărătire


$$F_X: \mathbb{R} \rightarrow [0, 1]$$

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f(x) dx.$$

$\approx 5 \approx$

\dots

\dots



$$\text{OBS. } P(X \in I) = \int_a^b f(x) dx = \int_{-\infty}^b f(x) dx - \int_{-\infty}^a f(x) dx = F(b) - F(a)$$

EXEMPLU $f(x) = \begin{cases} 0, & x < 0 \\ \frac{1}{2}e^{-\frac{x}{2}}, & x \geq 0 \end{cases}$

$$F(x) = \int_{-\infty}^x f(x) dx = \begin{cases} \int_{-\infty}^0 0 dx = 0 & x < 0 \\ \int_{-\infty}^0 0 dx + \int_0^x \frac{1}{2}e^{-\frac{x}{2}} dx = 1 - e^{-\frac{x}{2}} & x \geq 0. \end{cases}$$

V.a. cont. are den. de prob.:

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases}$$

se numeste m.a | uniform
distribută pe $[a, b]$)
 $X \sim \text{Unif}[a, b]$

Unit

Functia de supartitie

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & x \in [a, b] \\ 1, & x \geq b. \end{cases}$$

V.a. cont. are den. de prob.:

$$f(x) = \begin{cases} 0, & x < 0 \\ \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x \geq 0. \end{cases}$$

$\theta > 0$, se numeste m.a cu
distributie exponentiala de param. θ
 $X \sim \text{Exp}(\theta)$

Exp

Functia de supartitie

$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\frac{x}{\theta}}, & x \geq 0. \end{cases}$$

$\sim \text{Exp}$

Media și dispersia n.r.a. cont.

$$M(X) = \int_{-\infty}^{+\infty} x f(x) dx.$$

Teorema lui LOTUS.

$g: \mathbb{R} \rightarrow \mathbb{R}$ funcț. cont. sau cu nr. finit de pt. de discontinuitate de specie I $\Rightarrow Y = g(X)$ este o r.v.a.

Dacă $\int_{-\infty}^{\infty} |g(x)| f(x) dx < \infty$ atunci $Y = g(X)$ are medie:

$$M(g(X)) = \int_{-\infty}^{\infty} g(x) f(x) dx.$$

LOTUS = law of the unconscious statistician.

Dispersia

$$D^2(X) = \sigma^2(X) = M((X-m)^2) \text{ unde } m = M(X)$$

$$\Rightarrow \sigma^2(X) = \int_{-\infty}^{+\infty} (x-m)^2 f(x) dx. = M(X^2) - (M(X))^2.$$

$\sim \neq \sim$

CONCLUZII

(V.a. discrete)

Δx - probătă

$$X \left(\frac{x_i}{p_i} \right) \sum_{i=1}^n p_i = 1.$$

$$P(X=x_i) = P(X=x_i) = p_i$$

$$P(X=x_i) = p_i$$

$$F_X(x) = P(X \leq x)$$

$$F_X(x) = \sum_{i: x_i < x} p_i$$

$$M(X) = \sum_{i=1}^n x_i p_i$$

$$\sigma^2(X) = \sum_{i=1}^n (x_i - m)^2 p_i$$

Mult. de rezolvări

Reprezentare

interval din \mathbb{R}

$$f(x) \geq 0 \quad x \in \mathbb{R}$$

$$\int_{-\infty}^{\infty} f(x) dx = 1.$$

Calcul prob.

$$P(X \in I) = \int_I f(x) dx.$$

Functia de
repartitie

$$F_X(x) = \int_{-\infty}^x f(x) dx.$$

$$P(X \in I) = \int_a^b f(x) dx = \\ = F_X(b) - F_X(a).$$

Media

$$M(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

Dispersia

$$\sigma^2(X) = \int_{-\infty}^{+\infty} (x - m)^2 f(x) dx.$$

$$\sigma^2(X) = M(X^2) - [M(X)]^2.$$


(V.a. continue)

Curs 7 Distribuții continue clasice: uniformă, exponentială, normală

I. Distribuția uniformă

Unif $[a, b]$

- parametrii: a, b
- dom. de valori: $[a, b]$.
- not.: $\text{Unif } [a, b]$ sau uniform $[a, b]$
- den. de prob.: $f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases}$
- funcție de repartitie: $F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b \end{cases}$



- model: valorile din domeniu au probabilitate egală de apariție

II. Distribuția exponentială

Exp (θ)

- parametrii: θ
- dom. de valori: $[0, +\infty)$
- not.: $\text{Exp} (\theta)$
- den. de prob.: $f(x) = \begin{cases} 0, & x < 0 \\ \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x \geq 0 \end{cases}$
- funcția de repartitie: $F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\frac{x}{\theta}}, & x \geq 0. \end{cases}$
- $M(x) = \theta$; $\Gamma^2(x) = \theta^2$.

~g~

→ model: timpul de așteptare pt. un proces continuu.

→ lipsa de memorie: prob. de a aștepta încă t minute nu este afectată de acuza că a fi așteptat deja s minute față de eveniment

$$P(X > s+t | X > s) = P(X > t).$$

III. Distribuția normală = Distribuție Gaussiana $N(m, \sigma^2)$

DEF. → o variabilă aleatoare continuă, X , cu o dens. de probab. $f(x) = \frac{1}{\sqrt{2\pi}} \exp \frac{-(x-m)^2}{2\sigma^2}$, $x \in \mathbb{R}$ se numește N.a normală distribuție.

→ parametrii: m, σ^2

→ dom. de valori: $(-\infty, +\infty)$

→ mot.: $N(m, \sigma^2)$ sau $N(m, \sigma^2)$.

→ dens. de probab.: $f(x) = \frac{1}{\sqrt{2\pi}} \exp \frac{-(x-m)^2}{2\sigma^2}$, $x \in \mathbb{R}$.

→ funcția de repartitie: sau o formula (real. se pot doli folosind tabele sau software matematic: primul în \mathbb{R})

$$\rightarrow M(X) = m, \sigma^2(X) = \sigma^2.$$

→ model: măsurarea erorilor, rezultate, media big data.

IV. Distribuția normală standard $Z \sim N(0,1)$

→ parametrii: $m = 0, \sigma^2 = 1$.

→ dens. de probab.: $\varphi(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$, $t \in \mathbb{R}$

→ P este pară.

→ graficul se numește clopotul lui Gauss.

→ mot.: $N(0,1)$

→ fct. de repartitie: $\Phi(x) = P(Z \leq x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt.$

$$\rightarrow M(Z) = 0, \sigma^2(Z) = 1$$

$\sim 1/\sqrt{N}$

Cuantile unei variabile aleatoare

Mediană → mediană unei v.r. a X este real. și pt. că

$P(X \leq x) = P(X \geq x) = 0,5$. Adică x este real. și pt. că

$$F(x) = 0,5.$$

λ -cuantila → unicul nr. real x_2 ; $\lambda \in (0,1)$

$$\rightarrow F(x_2) = P(X \leq x_2) = \lambda$$

PROP.

- Între cantilele $x_{1-\alpha}$ și x_α ale unei v.r. $Z \sim N(0,1)$ are loc :

$$x_{1-\alpha} = -x_\alpha \quad \alpha \in (0,1)$$

- Fie $X \sim N(\mu, \sigma^2)$. Atunci, $Z = \frac{X-\mu}{\sigma}$ are prop. că $Z \sim N(0,1)$.

Curs 3 Simularea variabilelor aleatoare

↪ presupune a genera independențial, conform unui algoritm, un sir de nr. y_1, y_2, \dots, y_n care să aibă proprietățile unei valori de observație după variabilei.

ex: generatorul $u = \text{rand}()$;

A- eveniment

$$P(A) = 0,65$$

$$B = \text{CA} \quad P(B) = 0,35$$

dacă $u < 0,65 \Rightarrow$ A- a predeus evenimentul $U < 0,65$.
 $\Rightarrow P(U < 0,65) = P(U \in [0; 0,65]) = 0,65$.

dacă $u \in (0,65; 1] \Rightarrow$ A- a predeus evenimentul $U \in (0,65; 1]$
 $\Rightarrow P(U \in (0,65; 1]) = 1 - 0,65 = 0,35$.

~11~

PROF. Dacă $U \sim \text{Unif}(0,1)$ și a uniform distribuții pe $[0,1]$, iar n este nr. întreg, $n > 1$, atunci $X = [nU]$,

o v.a. discrete care are distribuție uniformă pe mult.
 $\{0, 1, 2, \dots, n-1\}$ adică $X = \left(\begin{array}{cccc} 0 & 1 & \dots & n-1 \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{array} \right)$.

* algoritm

Funcție SaluDiscretU(n)

$u = \text{rand}();$

$kR = \text{int}(n * u);$

return $k;$

end.

* algoritm ce extrage un nr. la întâmpinare din mult. de nr.

Intregi $\{m, m+1, \dots, n\}$ $m < n$.

$N = n - m + 1$ elem.

$$X = \left(\begin{array}{cccc} \frac{m}{n-m+1} & \frac{m+1}{n-m+1} & \dots & \frac{n}{n-m+1} \end{array} \right)$$

Funcție randint(m, n)

$u = \text{rand}();$

$k = \text{int}((n - m + 1) * u);$

return $k + m;$

end.

* generaarea unei permutări aleatoare

fie X o v.a. discrete cu val. ordonate $x_0 < x_1 < \dots < x_{n-1}$

$$X = \left(\begin{array}{cccc} x_0 & x_1 & \dots & x_{n-1} \\ p_0 & p_1 & \dots & p_{n-1} \end{array} \right) \sum_{k=0}^{n-1} p_k = 1.$$

~ / ~

Simulația n.a discrete cu o distribuție uniformă

Este X o n.a discrete cu val. ordonate, $x_0 < x_1 < \dots < x_m$,

$$X = \begin{pmatrix} x_0 & x_1 & \dots & x_{m-1} \\ p_0 & p_1 & \dots & p_{m-1} \end{pmatrix} \quad \sum_{k=0}^{m-1} p_k = 1$$

Function SimDiscret(X, p, m)

```

R = 0;
F = P0;
u = urand();
while (u > F)
{
    k = k + 1;
    F = F + pk;
}
return Xk;
end.

```

Simulația distribuției Bernoulli

$$X = \begin{pmatrix} 1 & 0 \\ p & 1-p \end{pmatrix}$$

- dacă $U \leq p \Rightarrow$ 1-a probabilitate (U ≤ p)
- $P(U \leq p) = P(0 \leq U \leq p) = p - 0 = p.$
- dacă $U > p \Rightarrow$ alegere codificată de 0.

```

Function Bernoulli(p);
u = urand();
if (u < p)
    return 1;
else
    return 0;
end.

```

Simularea distributiei binomiale

$$X \sim \text{Bin}(n, p) \quad X = \begin{pmatrix} 0 & 1 & \dots & k & \dots & n \\ P_{n,0} & P_{n,1} & \dots & P_{n,k} & \dots & P_{n,n} \end{pmatrix}$$

Function Bin(n, p)

$$k = 0;$$

$$c = p / (1 - p);$$

$$p_n = (1 - p)^n;$$

$$F = p_n;$$

$$u = \text{rand();}$$

while ($u > F$)

$$\{ p_n = (c * (n - k)) / (k + 1) * p_n;$$

$$F = F + p_n;$$

$$k = k + 1;$$

}

return k;

end.

Simularea distributiei geometrice

$$X \sim \text{Geom}(p) \quad X = \left(\frac{k}{p(1-p)^{k-1}} \right) \quad k \in \mathbb{N} \setminus \{0\}$$

Function Geom1(p)

$$kR = 0;$$

do {

$$u = \text{rand();}$$

$$kR = k + 1;$$

} while ($u > p$);

return kR;

end.

$\sim 14 \text{ N}$

PROP. Dacă $p \in (0,1)$ și $U \sim \text{Unif}[0,1]$, atunci r.a.:

$$X = \left\lceil \frac{\ln(1-U)}{\ln(1-p)} \right\rceil + 1 \quad \text{are distribuția geom.}$$

de parametru p .

Funcție Geom z(p)

$u = \text{rand}();$

return $\lceil \log(1-u) / \log(1-p) \rceil + 1;$
end.

Metoda inversă:

→ se aplică pt. variabilele ce au fct. de supratitie inversabilă.

$X - r.a. cont$

dens. de prob. f_X .

fct. de supratitie $F_X: \mathbb{R} \rightarrow \mathbb{R}$.

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f(x) dx$$

PROP.:

* fct. cont.

* nedescrescătoare

$x_1 < x_2 \Rightarrow F_X(x_1) \geq F_X(x_2)$

* $\lim_{x \rightarrow -\infty} F_X(x) = 0$

* $\lim_{x \rightarrow \infty} F_X(x) = 1$.

Simulare r.a. continue

Fct. de supratitie F_U a unei r.a., $U \sim \text{Unif}[0,1]$

$$F_U(x) = \begin{cases} 0, & x < 0 \\ x, & x \in [0,1] \\ 1, & x \geq 1. \end{cases}$$

F_X - strict. $\Rightarrow \Rightarrow$ inversabilă
 $\forall u \in (0,1), F_X^{-1}(u) \in \mathbb{R}$.

Funcție Metoda Inv.($)$

$u = \text{rand}();$

$x = F_X^{-1}(u);$

return $x;$
end.

Simularea distribuției exponentiale cu parametru θ .

fct. de suprație $F_X(x) = \begin{cases} 0 & x < 0 \\ 1 - e^{-\frac{x}{\theta}} & x \geq 0 \end{cases}$

$$P(X \geq 0) = 1 - P(X < 0) = 1 - 0 = 1.$$

Funcția Simulare Exp(theta)

$u = \text{rand();}$

$x = -\theta * \log(1-u);$

return x;

end.

$$1 - e^{-\frac{x}{\theta}} = u$$

$$\Rightarrow x = -\theta \ln(1-u)$$

$\sim 16 N$