1. Introducere

1.1. Generalităţi despre sistem, model, simulare

Noţiunea de simulare este interpretată în n moduri de m indivizi, în funcţie de natura problemei de rezolvat, de obiectivul urmărit şi de cunoştinţele deţinute. Datorită sensurilor diferite ale cuvântului (capacitate de reproducere, reprezentare, imitare) este dificil să se precizeze o semnificaţie general valabilă a termenului simulare pentru toate domeniile în care este întâlnit. O definiţie acoperitoare ar fi următoarea:

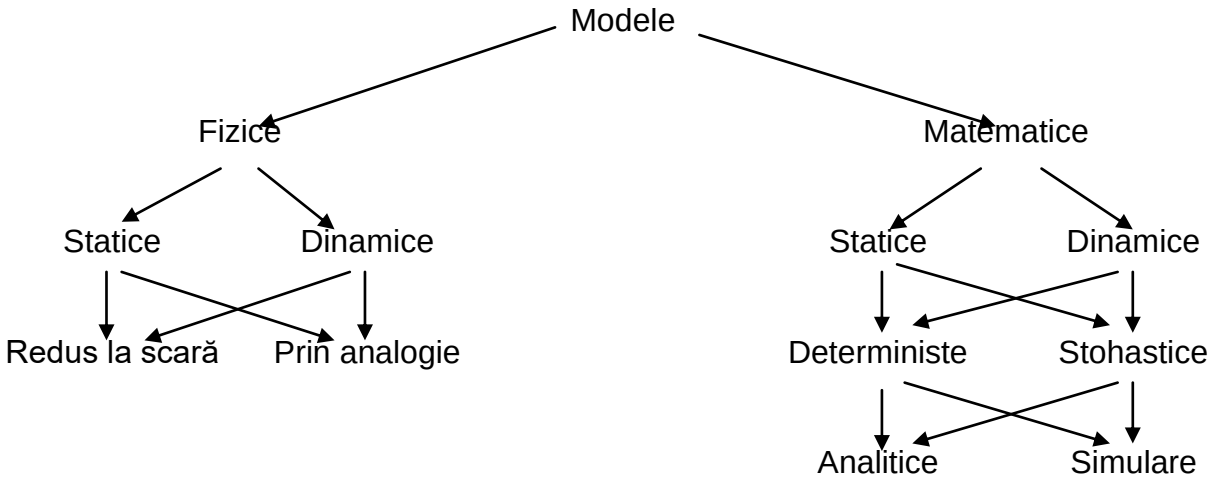
Simularea este o tehnică de realizare a experienţelor cu ajutorul calculatorului care implică utilizarea unor modele matematice sau logice ce descriu comportarea unui sistem real pe durata unui interval de timp.

Tehnicile de simulare se utilizează în acele cazuri în care găsirea unei soluţii analitice este imposibilă, iar experimentarea nemijlocită pe sistemul real, este dintr-un motiv sau altul neoperaţională. Deci în cele ce urmează, simularea va fi înţeleasă ca o imitare a comportării sistemului studiat, reprezentat prin modelul său. Astfel, devine posibilă obţinerea unor adevărate instantanee privind comportarea sistemului în diferite momente şi în condiţii diverse. Trebuie subliniat de la început că, în general, simularea nu oferă soluţia optimă pentru problema de decizie, ci doar tabloul rezultatelor ce s-ar obţine în timp şi spaţiu, ca urmare a folosirii variantelor utilizate.

Conceptele care stau la baza tehnicilor de simulare sunt:

Sistem:	o mulţime de componente care interacţionează pe de o parte între ele, iar pe de altă parte interacţionează cu mediul înconjurător.
Entitate:	reprezintă o abstractizarea unei componente reale a unui sistem. Astfel sistemul poate fi privit ca o reuniune de entităţi, fiecare fiind caracterizată printr-un set de atribute care o descriu şi o definesc funcţional.
Model:	descriere abstractă logico-matematică a unui sistem. Acesta aproximează un sistem pe baza unor observări şi măsurători, abaterile faţă de realitate depinzând de stadiul de cunoaştere a sistemului.

Prin urmare, modelul se formează pe baza unui proces de abstractizare a situaţiei reale. Din acest motiv, un model nu se poate identifica, sau substitui sistemului pe care îl descrie. Mai mult, una din condiţiile oricărui model este că el nu e identic cu sistemul pe care îl reprezintă. Astfel, pentru un sistem pot exista o multitudine de modele, fiecare model fiind potrivit scopului care se urmăreşte în studierea sistemului. Modelele se pot clasifica în:



Modele fizice:	apar ca nişte sisteme reale care reproduc la scară redusă sistemul studiat.
Modele matematice:	în care dependenţa variabilelor de ieşire de variabilele de intrare şi în general modul de desfăşurare a activităţilor în sistem sunt descrise printr-un set de ecuaţii sau algoritmi de calcul.
Modele statice:	sunt acelea în care nu se ia în considerare în mod explicit variabila timp. În cadrul acestei categorii de cele mai multe ori soluţiile pot fi obţinute în mod static.
Modele dinamice:	sunt modelele în care timpul este explicit luat în considerare.
Modele deterministe:	sunt acelea în care relaţiile dintre entităţi sunt fixe. Acest aspect dă posibilitatea cunoaşterii şi determinării cu precizie a situaţiei viitoare cunoscând situaţia curentă
Modele stohastice:	sunt acelea în care cel puţin o variabilă de intrare sau un

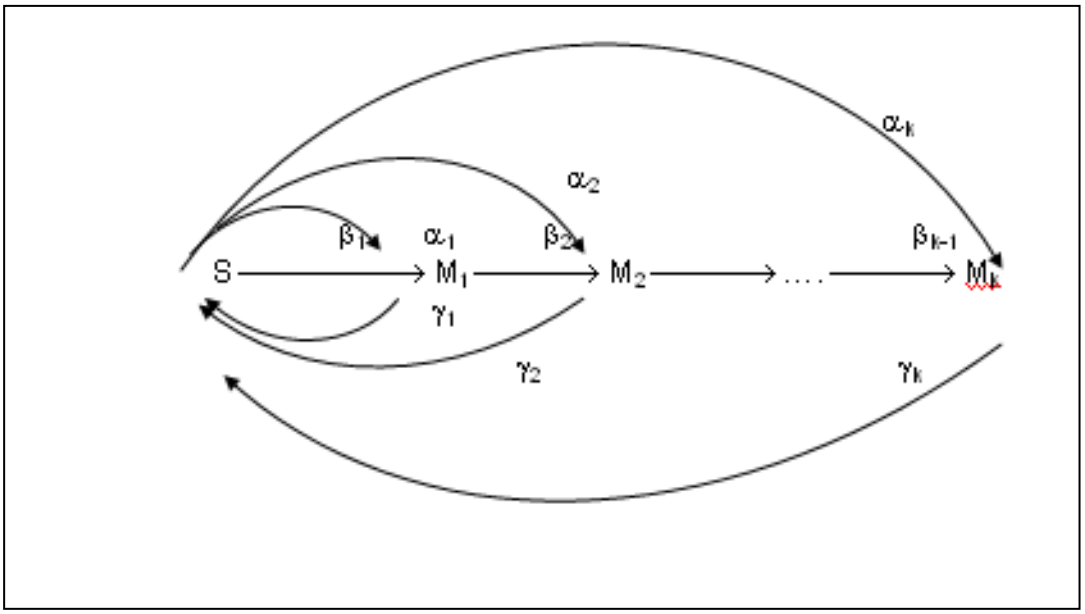
	atribut al unei entităţi este o mărime a cărei variaţie este aleatoare. În acest caz o situaţie viitoare nu se poate prevedea decât în mod probabilistic. Se cunoaşte setul de valori pe care-l poate lua un parametru în viitor, dar nu se poate prevedea cu certitudine valoarea pe care o va lua.
Modele analitice:	sunt acelea în care valorile mărimilor care ne interesează se obţin în urma rezolvării unui sistem de ecuaţii.
Modele de simulare:	sunt modelele în caresistemul de ecuaţii nu se poate rezolva analitic, sau modelele în care dependenţa între entităţi este precizată printr-un algoritm. În primul caz se aplică o tehnică numerică de rezolvare, în cel de al doilea se recurge la o metodă cu caracter experimental, care constă din precizarea unui set de condiţii iniţiale, din urmărirea modelului pe o perioadă de timp modificând parametrii de intrare şi atributele acestora urmată de culegerea datelor de ieşire şi analizarea lor.

Modelare: ⇨ este operaţia de construire a modelului în cadrul căreia se face trecerea de la fenomenul real la modelul fizic sau matematic prin neglijarea unor elemente şi aspecte – uneori esenţiale ale sistemului real – în vederea obţinerii unor informaţii despre sistem.

Modelul ca reprezentare satisfăcătoare a unui sistem este rezultatul unor iteraţii în care se parcurge de fiecare dată ciclul

sistem ⇨ model ⇨ validare ⇨ sistem

reprezentat schematic în următoarea figură:



unde:

S- sistemul modelat;

β_k- informaţiile obţinute de la modelul k pentru construirea modelului k+1;

γ_k – rezultatele obţinute de la modelul k care se compară cu sistemul real:

α_k - informaţiile obţinute direct de la sistem, utilizate în construirea modelului M_k.

Dacă γ_k dă un răspuns satisfăcător privind calitatea reprezentării realizate de model, procesul de construire a modelului se opreşte, iar modelul M_k poate fi acceptat pentru utilizări ulterioare ca reprezentare a sistemului S.

Simulare

Din definiţia sistemului, se observă că acesta asigură transformarea unui grup de intrări (care reprezintă mărimi primite din exterior) într-un grup de ieşiri care aparţine de asemenea mediului exterior. De asemenea s-a afirmat că setul de valori numerice care caracterizează o entitate a sistemului poartă denumirea de atribute. Rezultă imediat că starea unei entităţi este definită de totalitatea valorilor numerice pe care le au la un moment dat atributele entităţilor respective, iar starea sistemului va fi definită de ansamblul tuturor stărilor entităţilor care alcătuiesc sistemul. Trecerea unui sistem dintr-o stare în alta va apare ca urmare a schimbării valorilor atributelor entităţilor sistemului şi a modificării ca urmare a relaţiilor de interdependenţă. Se face observaţia că relaţiile de interdependenţă au un caracter static dacă nu se modifică în timp, chiar ca urmare a

modificării entităţilor între care apar, şi un caracter dinamic în caz contrar. Se consideră că numai legăturile dinamice sunt cele care definesc activităţile care se produc în sistem. (se poate pune semnul de identitate între activităţile din sistem şi modificarea relaţiilor de interdependenţă).

În acest context, simularea va reprezenta procesul de modificare a atributelor antităţilor sistemului, ceea ce va declanşa apariţia activităţilor în cadrul sistemului şi deci evoluţia acestuia în timp. Dacă modificarea atributelor se va face la intervale discrete de timp, modelul va fi discret, iar dacă are loc continuu în timp modelul va fi de tip continuu.

1.2. Etape în realizarea şi studiul unui model

Utilizarea tehnicilor de modelare şi simulare necesită o muncă laborioasă. Pentru a simplifica şi ordona această muncă sunt necesare de parcurs următoarele etape:

a) formularea problemei

Se definesc cât mai detaliat obiectivele modelării conform scopului urmărit. Se specifică care sunt entităţile principale şi relaţiile de interdependenţă dintre ele.

b) colecţionarea şi prelucrarea datelor

Pe baza măsurătorilor efectuate pe sistemul real se vor obţine valorile numerice pentru mărimile de intrare, de ieşire şi pentru atributele entităţilor. De asemenea se vor determina legile de variaţie a acestora.

c) formularea modelului

Nu există proceduri general acceptate de construirea modelelor. În general se utilizează pentru modele dinamice şi statice de tip matematic grafuri, reţele cu şiruri de aşteptare, reţele Petri, reţele de evaluare.

d) transpunerea modelului în formă program

Constă în alegerea limbajului în care se va descrie modelul. Acestea pot fi convenţionale (Pascal, Fortran, ş.a.m.d.) rămânând în sarcina programatorului rezolvarea problemelor specifice legate de tehnica simulării (prelucrări statistice, gestionarea timpului şi asigurarea sincronizării activităţilor etc.), aspecte care au făcut ca utilizarea acestora să fie în general limitată la clasa modelelor definite prin ecuaţii, sisteme de ecuaţii diferenţiale sau nu.

A doua categorie o definesc limbajele orientate pe blocuri de tip (GPSS, CSMP, etc.) în cadrul cărora activităţile şi entităţile sistemului au un corespondent direct

în elementele limbajului. În funcţie de tipul sistemului studiat aceste limbaje sunt orientate pe sisteme continue şi respectiv discrete.

e) validarea modelului

Constă în determinarea diferenţelor dintre valorile furnizate de model şi valorile din sistemul real, şi stabilirea pe această bază a acceptabilităţii sau a refuzului modelului. Validarea nu poate fi întotdeauna efectuată în cazul în care nu există un sistem real, acesta fiind de abia în stare de proiectare.

f) planificarea experimentelor de simulare

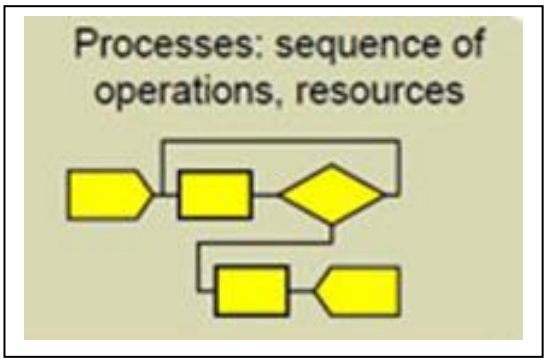
Constă în executarea programului care defineşte modelul şi în verificarea calităţii generatoarelor utilizate astfel ca rezultatele să nu fie afectate de erori întâmplătoare.

Analiza rezultatelor care se obţin depind de natura modelului, iar în cazul modelării stohastice de tip simulare se va face apel la metode ce aparţin statisticii matematice.

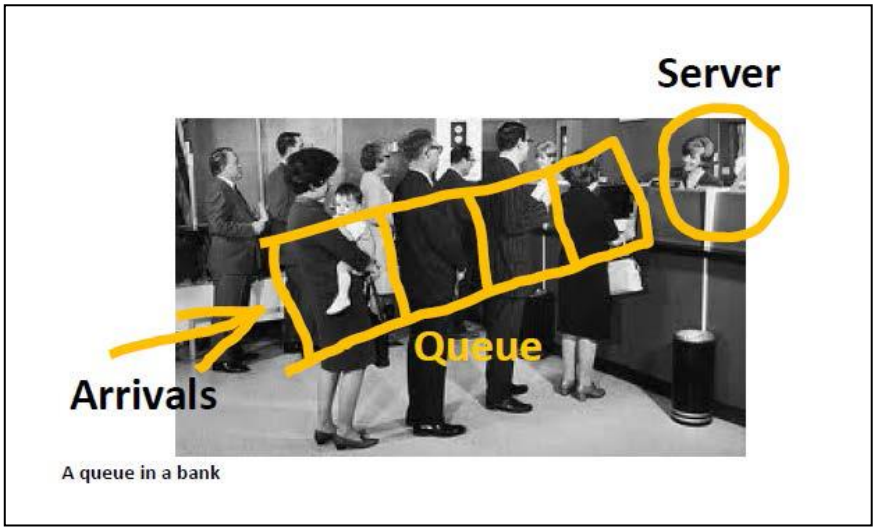
2. Modelarea bazată pe evenimente.

În contextul acestei tehnici **Sistemul modelat este descris de o secvență de evenimente interconectate care se desfășoară la momente discrete de timp**.

Grafic acest mod de reprezentare apare ca o diagramă de activități interconectate între ele (vezi fig următoare)



Un exememplu îl poate reprezenta sistemul plăți la un ghișeu în care evenimentele (activitățile) care definesc sistemul sunt :sosirea celor care solicită efectuare unei plăți, așteptarea într-un șir la ghișeul unde urmează să fie efectuată plata, efectauare plății urmată de părăsirea sistemului după ce această plată a fost efectuată. Reprezentarea grafică a acestui sistem este dată în figura următoare



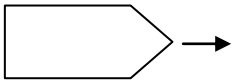
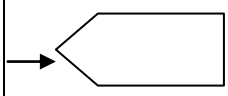
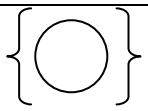
În cazul general un astfel de model în care sistemul este reprezentat prin activitățile care au loc în sistem și succesiunea acestora în timp este defint de ceea ce poart-denumirea de șir de așteptare

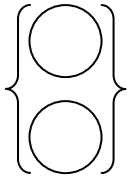
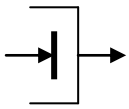
Utilizarea teoriei şirurilor de aşteptare în modelarea sistemelor

În cele ce urmează vom încerca să prezentăm principiile care stau la baza construirii modelelor de simulare reprezentabile prin șiruri de așteptare. Exemplificările le vom face din considerente de urmărire mai simplă a procesului de construire a modelelor din domeniul traficului rutier. Aceste principii vor fi dezvoltate gradat în cadrul mai multor exemple.

Grafuri al activităţilor.

Este un graf in care nodurile reprezintă activităţi din sistemul real iar arcele tranziţia între activităţi.Nodurile utilizate sunt:

Reprezentare grafică	Activitatea care se modelează
	**Definește activitatea de tip sosire clienți** Are drept corespondent in sistemul real sursa clienţilor. La bloc se ataşează o procedură care specifică : - cum sosesc clien!ii (rtimp mediu de sosire, lege de distribuţie) - caracteristicile particulare care individualizează un client
	**Definește activitatea de tip plecare clienți** Are drept corespondent în sistemul real echipamentul prin intermediul căruia clienţii părăsesc sistemul . La bloc se ataşează o procedură care specifică : - cum plecă clienți
	**Definește activitatea de tip servire clienți** Are drept corespondent in sistemul real resursa formată din una,

	două sau mai multe echipamente de servire (resursa poate fi multiplă), la care se cere accesul. Practic este utiliztă pentru reprezentarea oricărei activităţi de orice natură care poate apare în lumea reală. La bloc se ataşează o procedură care specifică : - timpul de ocupare a resursei (timp mediu de servire, lege de distribuţie) - caracteristicile particulare care individualizează un client după ce acesta a părăsit resursa. Efectuarea serviciului cerut poate modifica caracteristicile clientului
	**Definește activitatea de tip așteptare clienți** Are drept corespondent in sistemul real şirul de aşteptare care se formează în faţa resursei la care s- cerut accesul. La bloc se ataşează o procedură care specifică : - Disciplina de planificare a clienţilor în şir (modul în care aceştia se ordonează pentru a ocupa resursa) caracteristicile particulare care individualizează un client
	**Definește activitatea de alocare a unei resurse** Are drept corespondent în sistemul real echipamentul prin intermediul căruia este solicitată o cantitate de resursă dintr-un depozit care dispune de o anumită cantitate. Are ataşată o procedură prin intermediul căreia este specificată ce cantitate este solicitată.
	**Definește activitatea de eliberare a unei resurse** Are drept corespondent în sistemul real echipamentul prin intermediul căruia este eliberată o cantitate de resursă. Aceasta este trimisă spre un depozit care dispune de o cantitate, de unde poate fi reutilizată. Are ataşată o procedură prin intermediul căreia este specificată ce cantitate este returnată
	**Reprezintă un depozit în care este prezentă o cantitate variabilă de resursă care este disponibilă**. Are drept corespondent în sistemele reale resurse alocbile n cantităţi discrete (de exemplu memorii de diferite capacitati , magistrale, rezervoare s.a.m.d)

→	**Reprezintă modul de interconectare a activităţilor din sistem**. Specifică succesiunea în timp a modului în care aceste activităţi se desfăşoară

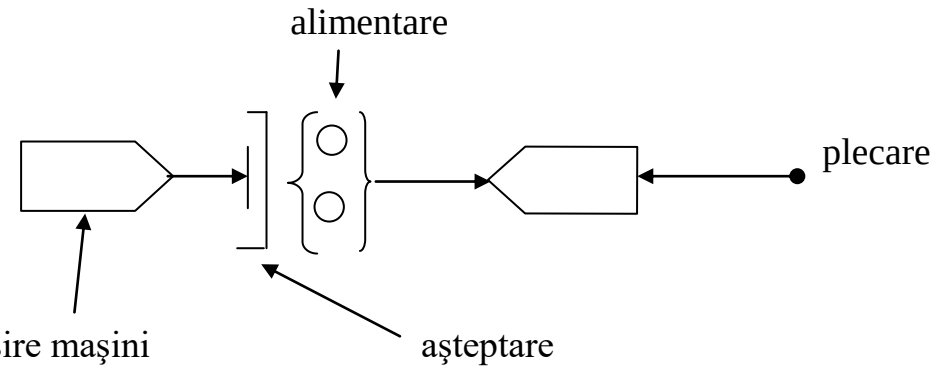
Studiu de caz 1

Pe o şosea există o staţie de benzină care dispune de un număr de 2 pompe. Maşinile care solicită alimentarea cu combustibil sosesc la intervale de 240 u.t. exponenţial distribuite, solicitând un interval de 96 unităţi de timp normal distribuite cu media de 32 u.t. (unităţi de timp) pentru alimentare (inclusiv plata combustibilului). Se cere construirea unui model care să simuleze activităţile care apar în cadrul procesului de alimentare cu combustibil. O unitate de timp este egală cu 5 secunde.

Activităţile care au loc în sistem sunt:

- sosire maşini;
- aşteptare;
- alimentare cu combustibil;
- plecare.

Cele 4 tipuri de activităţi conduc la următoarea reprezentare:



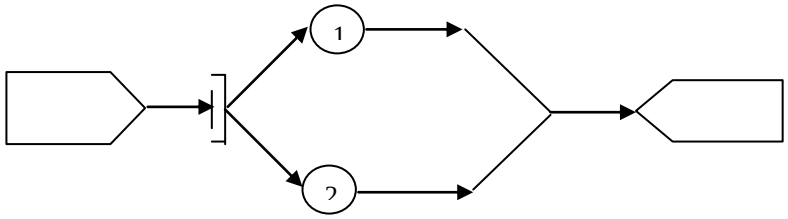
Informaţiile care se pot obţine prin simularea activităţilor din prezentul model se referă la:

- timpul mediu de aşteptare pentru alimentare;
- lungimea medie maximă a cozii care se formează la cele 2 pompe;
- gradul de încărcare a celor 2 pompe;

- capacitatea de trecere (câte maşini sunt alimentate în unitatea de timp);
- timpul mediu de răspuns (cât timp este necesar din momentul sosirii până când alimentarea cu combustibil s-a terminat şi maşina pleacă).

Varianta 1

Modelul anterior poate fi detaliat sub forma:

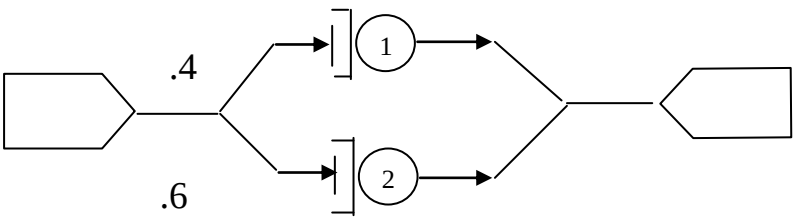


În acest cele două pompe de benzină apar ca unităţi individuale şi nu ca grup. În această situaţie, devine posibilă obţinerea gradului de încărcare a fiecărei pompe în parte (în cazul anterior acest grad de utilizare era global), cu observaţia că în acest caz devine necesară stabilirea unui mod de ocupare a celor două pompe. Se pot stabili diferite criterii de ocupare, de exemplu:

- pompele se ocupă în ordinea 1, 2 (pompa 1 având deci prioritate maximă)
- se ocupă pompa care s-a utilizat cel mai puţin, caz în care apare o echilibrare a utilizării celor 2 pompe.

Varianta 2

Modelul de bază poate fi detaliat sub forma:



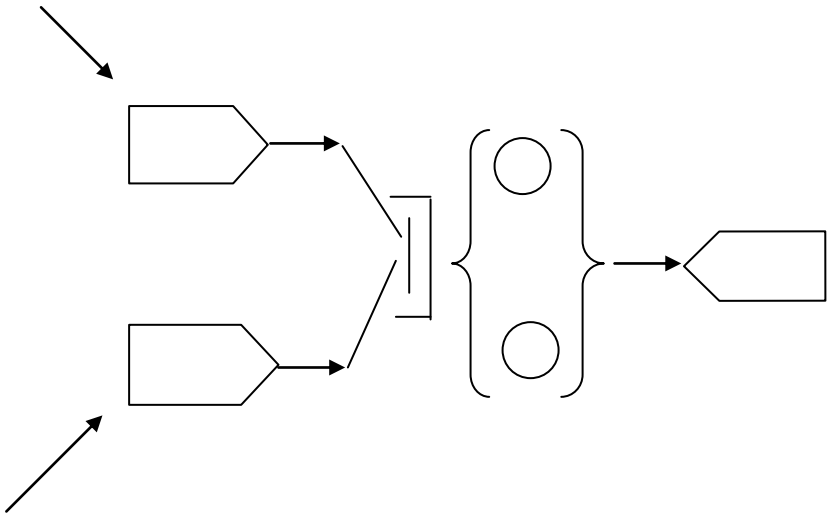
caz în care sunt prezente două şiruri de aşteptare, ocupare unei pompe depinzând de cât de repede avansează maşinile din şirul în cauză. Este evident că

în acest caz se pune problema unei opţiuni a şoferului relativă la şirul pe care îl alege. Această opţiune apare procentual şi pentru cazul nostru 40% din cei care sosesc optează pentru pompa 1 iar restul de 60% pentru pompa 2. Informaţiile care se obţin sunt similare celor oferite de modelul de bază cu observaţia că apare o detaliere la nivelul şirului de aşteptare.

Varianta 3

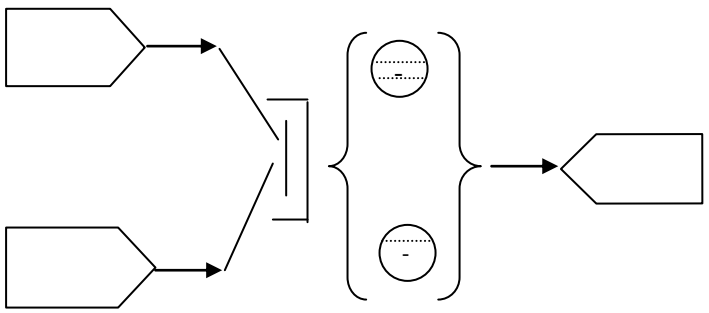
Modelul de bază poate fi detaliat sub forma:

sosire autoturisme



sosire mijloace de transport în comun

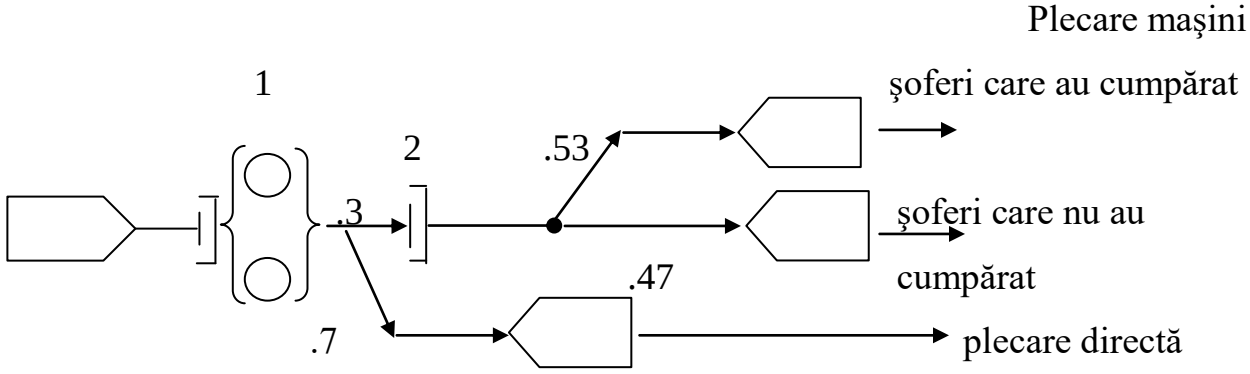
În această situaţie apare clară prezenţa a două clase de maşini care apar la intervale diferite de timp la staţia de alimentare. Ambele clase utilizează acelaşi şir de aşteptare şi aceleaşi pompe. Indicii de performanţă sunt similari cu cei ai modelului de bază. O variantă care poate apare se referă la posibilitatea ca fiecare clasă să aibă nevoie de alţi timpi de alimentare. De exemplu clasa autoturisme are nevoie de 93 u.t. normal distribuiţi cu dispersia 35 u.t iar clasa mijloace de transport în comun are nevoie de 190 u.t. uniform distribuiţi cu dispersia 70 u.t. Modelul va apare în următoarea formă:



În această situaţie gradul de utilizare a celor două pompe va avea două componente corespunzătoare celor două clase de clienţi existente (suma lor va da gradul de utilizare global al celor două pompe de alimentare).

Varianta 4

Să presupunem că după alimentare 30% don şoferii maşinilor se opresc deoarece intenţionează să cumpere 1 sau mai multe produse din magazinul existent lângă staţia de alimentare. Timpul de staţionare are o distribuţie exponenţială cu media de 23 u.t. Dintre aceştia numai 53% cumpără, restul plecând fără să facă nici o achiziţie. Modelul de bază poate fi completat:

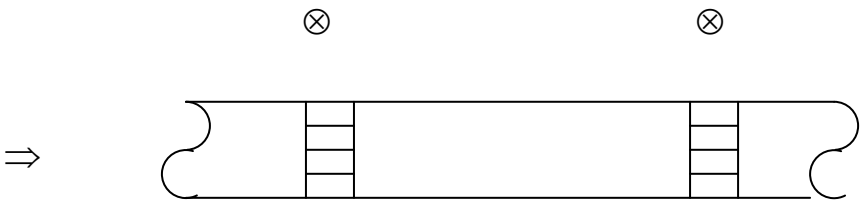


În acest caz apare evidentă necesitatea de a bloca un interval de timp (23 u.t.) maşinile într-un şir de aşteptare. deci în astfel de situaţii realitatea fenomenului modelat impune ataşarea la şirul de aşteptare a unui timp de execuţie similar celui existent într-o staţie.

Informaţiile suplimentare faţă de modelul de bază se referă la indicii de performanţă aferenţi şirului de aşteptare 2, indici care dau posibilitatea dimensionării parcării în care staţionează vehiculele în cauză.

Studiu de caz 2

Să presupunem că se doreşte modelarea traficului pe un tronson stradal cu sens unic delimitat de 2 treceri de pietoni la ambele capete ca în figura de mai jos:



A

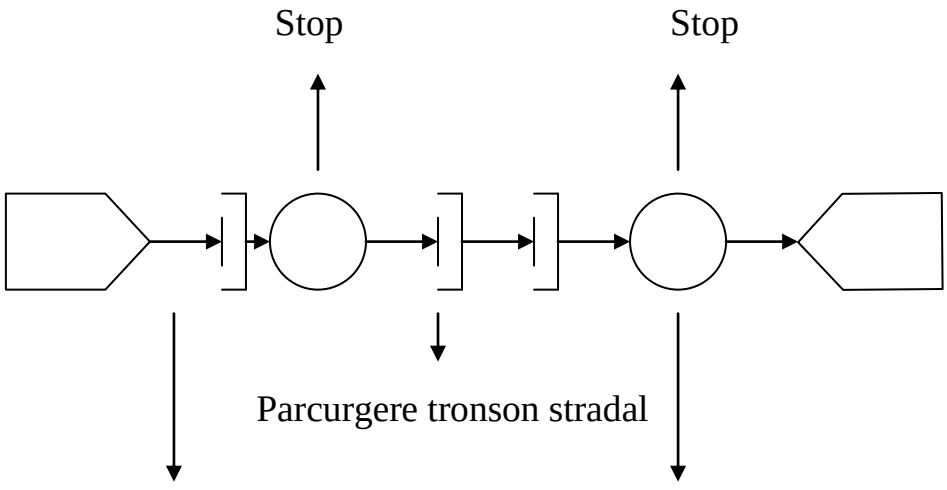
Măsurătorile care s-au efectuat în punctul A arată că maşinile sosesc la intervale de 250 u.t. exponenţial distribuite şi că semafoarele trec de pe verde pe roşu la intervale de 300 u.t. O unitate de de timp este egală cu 1 secundă.

Informaţiile pe care dorim să le obţinem prin simulare se referă la caracteristicile procesului de aşteptare a maşinilor în faţa semafoarelor şi la încărcarea tronsonului stradal în cauză.

Modelul în acest caz ia în considerare următoarele activităţi:

- sosire maşini;
- aşteptare în faţa stopului la ambele capete;
- schimbarea culorii stopului;
- parcurgerea tronsonului stradal şi plecare maşini

care conduc la următorul model:



Se observă că stopul propriu-zis s-a modelat printr-o staţie de servire. Aceasta se blochează la intervale de 300 u.t. simulând trecerea pe verde a stopului pentru pietoni, moment în care se formează o coadă de aşteptare cu maşini în faţa lui. Stopul rămne blocat de asemenea 300 u.t. moment în care maşinile în aşteptare pot intra pe tronsonul stradal. Informaţiile care se obţin prin simulare se referă la dinamica numărului de maşini în şirurile din faţa stopurilor. Dacă aceste şiruri de aşteptare nu au asociat un timp, în schimb şirul de aşteptare care modelează parcurgerea tronsonului stradal are asociat un timp, care corespunde celui necesar parcurgerii străzii (măsurătorile efectuate arată că timpul necesar străbaterii spaţiului dintre cele două marcaje de pietoni este uniform distribuit cu media de 200 u.t. şi dispersia de 40 u.t.). Se poate calcula care este capacitatea de trecere a tronsonului stradal ca şi timpii maxim şi minim de staţionare în faţa dopurilor. Pentru acest model este de reţinut modul de reprezentare a străzii şi stopurilor şi discuţia referitoare la timp relativă la şirurile de aşteptare utilizate.

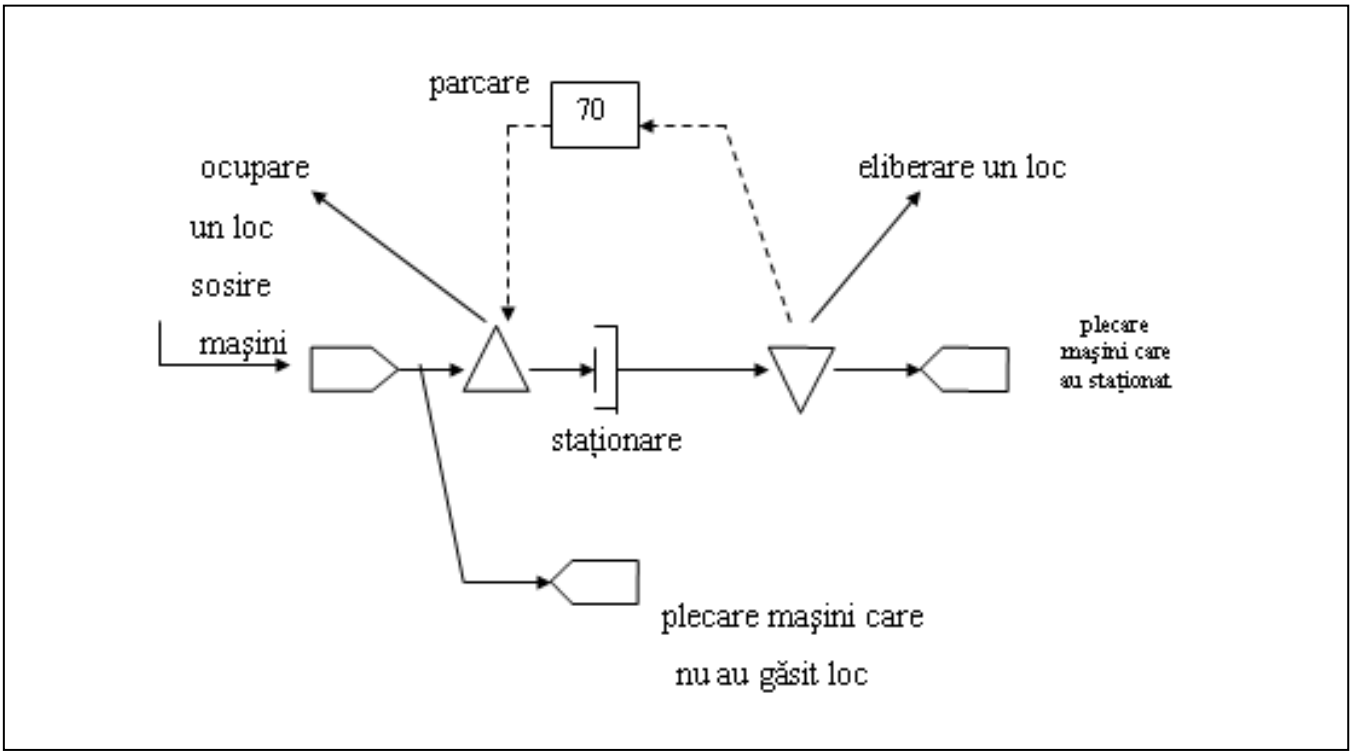
Studiu de caz 3

Considerăm o parcare cu un număr de 70 de locuri. Maşinile care solicită intrarea în parcare apar la 240 u.t. exponenţial distribuite şi staţionează un interval de 1000 u.t. normal distribuite cu media de 300 u.t. O unitate de timp este eglă cu 1 s. Se urmăreşte carpin modelare să se determine gradul de încărcare a parcării pe un interval de 8 ore şi numărul de maşini care negăsind un loc pleacă.

Activităţile carese iau în considerare sunt:

- sosire maşini;
- ocupare loc;
- staţionare;
- eliberare loc;
- plecare.

Modelul care ia în considerare aceste activităţi prezintă următorul aspect:



Maşinile care sosesc solicită un loc liber, în cazul în care acesta există staţionează după care eliberează locul şi pleacă. Dacă nu există un loc liber maşinile pleacă mai departe. Se observă modul în care s-a reprezentat procesul de ocupare /eliberare parcare prin utilizarea unui alocator de resurse ca şi modul de definire a staţionării în parcare prin folosirea unui şir de aşteptare care are asociat un timp. Informaţiile care se obţin se referă la evoluţia numărului de locuri din parcare, a gradului de încărcare a acesteia ca şi a numărului de maşini care renunţă deoarece nu mai există un loc disponibil.

3. Elemente de bază în modelarea sistemelor cu şiruri de aşteptare

3.1. Definiţia unui sistem cu şir de aşteptare

A. Un sistem în cadrul căruia se execută un anumit serviciu se numeşte **sistem de servire.**

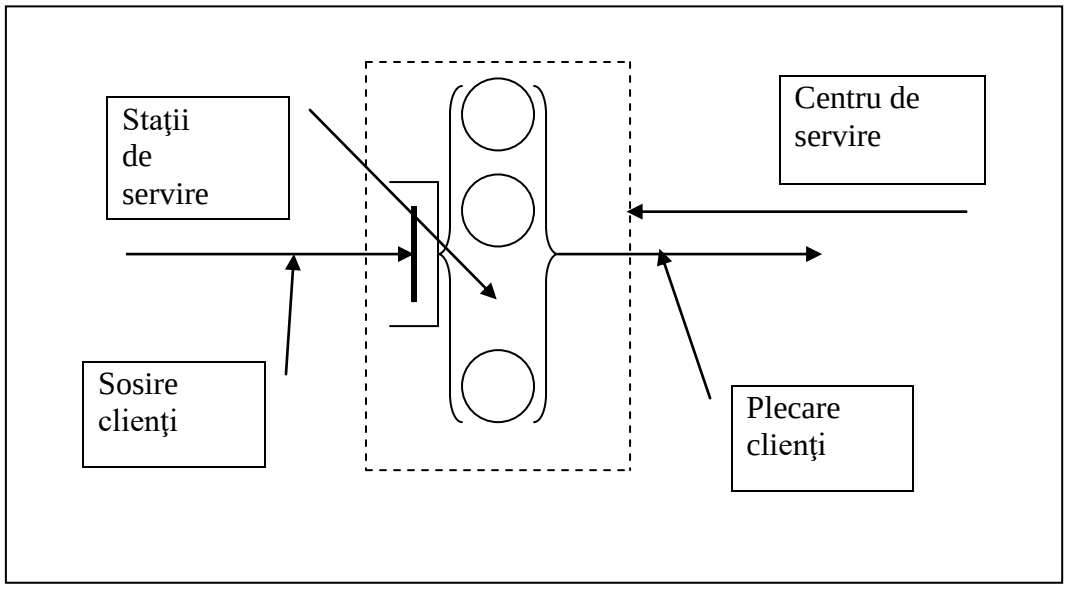
B. Obiectivul asupra căruia se execută serviciul respectiv poartă denumirea de **clienţi .** Un client emite o cerere de servire.

C. Staţia de servire este o instalaţie (într-un sens foarte larg) care poate servi un singur client la un moment dat. Dacă serviciul se execută în etape de către mai multe staţii, atunci succesiunea acestora formează o **linie de servire**. Mai multe staţii sau linii de servire care por servi mai mulţi clienţi simultan formează un canal de servire.

D. Presupunem că o secvenţă de clienţi soseşte la o linie de servire. Dacă clientul care a sosit găseşte staţia de servire ocupată, va fi pus în situaţia să aştepte. Unităţile care aşteaptă să fie servite formează un **şir de aşteptare**. Criteriul prin care este stabilită ordinea servirii unităţilor aflate în sistem se numeşte **disciplina şirului de aşteptare**.

E. Când staţia se eliberează, un client este selectat din şirul de aşteptare conform disciplinei de servire. Cererea de servire prezentată de client este în continuare executată şi după completarea serviciului clientul părăseşte sistemul de servire.

Un sistem de servire are următoarea reprezentare:

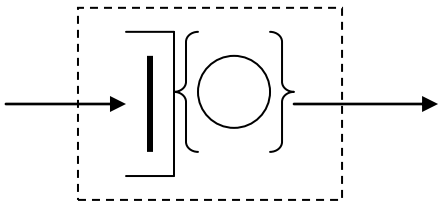


Teoria aşteptării pune la dispoziţie un aparat matematic care dă posibilitatea descrierii stării prezente a unui sistem cu şiruri de aşteptare şi de a formula concluzii cu caracter probabilistic asupra comportării sale viitoare.

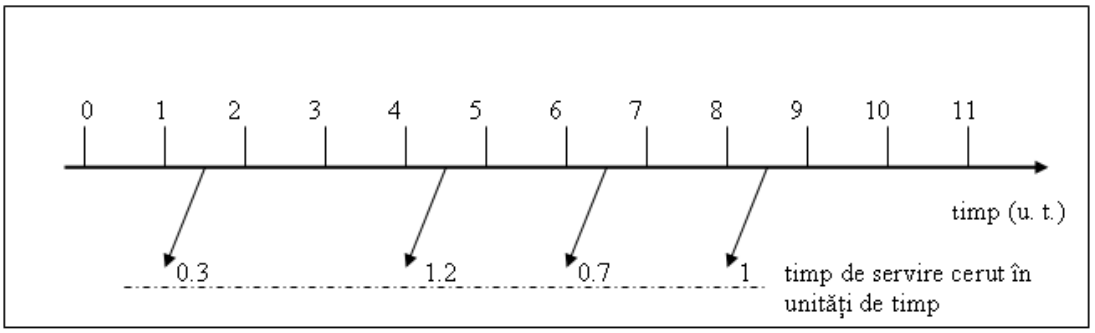
3.2. Indici de performanţă pentru un sistem cu şir de aşteptare

Indicii de performanţă definesc parametrii ce caracterizează funcţionarea de ansamblu a sistemului studiat. Pentru înţelegerea acestora definirea se va face plecând de la un exemplu.

Considerăm că la intrarea unui centru de servire de forma



sosesc într-un interval de 10 unităţi de timp un număr de 4 clienţi la momentele specificate în graficul de mai jos. Pentru fiecare client se specifică şi timpul de servire solicitat a fi efectuat în staţia de servire.



Mărimile care caracterizează procesul de sosire/servire sunt următoarele:

(a) ***frecvenţa de sosire***

Defineşte numărul de clienţi care sosesc la intrarea centrului în unitatea de timp. Parametrul se notează cu λ. Pentru exemplul dat avem:

$$\lambda = \frac{4}{10} = 0.4 \text{ cereri/u.t.}$$

(b) timpul mediu de servire

Defineşte cât solicită în medie o cerere pentru a fi servită. În acelaşi timp parametrul reprezintă şi timpul mediu de execuţie a staţiei centrului de servire. Mărimea se notează cu $\bar{s}$.

Pentru exemplul dat avem:

$$\bar{s} = \frac{0.3 + 1.2 + 0.7 + 1}{4} = \frac{3.2}{4} = 0.8 \text{ u.t.}$$

(c) frecvenţa de servire

Reprezintă numărul de cereri care pot fi servite de staţia centrului în unitatea de timp. Mărimea se notează cu μ.

Este egală cu:

$$\mu = \frac{1}{\bar{s}} \qquad \mu = \frac{1 \text{ unitate de timp}}{\text{timp mediu de servire/cerere}}$$

Pentru exemplul dat avem $\mu = \frac{1}{0.8} = 1.25$ cereri/u.t.

(d) gradul de utilizare

Reprezintă din timpul total de funcţionare în care centrul de servire (staţia sau staţiile) sunt ocupate. Parametrul se notează cu ρ. Pentru exemplul dat avem:

$\rho = \frac{0.3 + 1.2 + 0.7 + 1}{10} = 0.32$ cu interpretarea: din timpul de funcţionare 32% staţia este ocupată.

Se pot face următoarele observaţii:

- ρ se mai poate scrie sub forma: $\rho = \frac{3.2}{10} = \frac{\frac{3.2}{4}}{\frac{10}{4}} = \frac{\bar{s}}{\frac{1}{\lambda}} = \frac{\lambda}{\mu}$

Prin urmare $\rho = \frac{\lambda}{\mu}$

- gradul de utilizare $\rho \le 1$. Pentru $\rho = 1$ clienţii sosesc mai repede decât pot fi serviţi.

- pentru un sistem de servire cu m staţii

$\rho = \min\left\{\frac{\lambda}{m\mu}, 1\right\}$

(e) capacitatea de trecere

Parametrul defineşte numărul mediu de clienţi serviţi în unitatea de timp. Se notează cu τ şi este echivalentă cu frecvenţa sosirilor dacă λ este mai mică decât maximul frecvenţei de servire μ, în caz contrar capacitatea de trecere se saturează la valoarea μ. Pentru un centru de servire cu m staţii capacitatea de trecere este

$\tau = \min\{\lambda, m\mu\}$

(f) timpul de aşteptare şi timpul de răspuns

Reprezintă timpul pe care îl petrece un client în şirul de aşteptare până în momentul în care poate fi servit. Parametrul se notează cu w_j. Timpul de răspuns

este definit ca fiind timpul total petrecut de un client în sistem. Se notează cu T_j şi este egal cu $T_j = w_j + s_j$

(g) lungimea şirului de aşteptare, numărul total de clienţi din sistem.

Se notează cu Q(t) şi reprezintă numărul de clienţi care se găsesc în şir la momentul t. Numărul total de clienţi care se găsesc în centrul de servire la momentul t se notează cu N(t). Pentru un centru cu m staţii de servire

$$Q(t) = \max\{0, N(t)-m\}$$

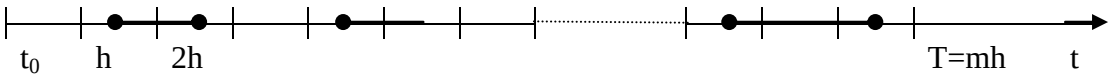
3.3. Distribuţia numărului de clienţi care apar la intrarea unui centru de servire

Să considerăm un sistem la intrarea căruia cererile sosesc întâmplător. Ne propunem să determinăm distribuţia de probabilitatea variabilei aleatoare

număr de clienţi care sosesc într-un interval de timp de lungime T.

Notăm cu $P (n (t_0, T) = k)$ probabilitatea să înregistrăm k sosiri în sistem în intervalul de timp (t_0, t_0+T), $(t_0 \geq 0)$.

Pentru a calcula această distribuţie împărţim intervalul T în m subintervale, fiecare din acestea având lungimea $h = \frac{T}{m}$



Vom presupune că:

(a) $P (n (t_0, T) = k)$ nu depinde de t_0 (ci numai de k şi de lungimea T a intervalului de timp) şi nici de numărul intrărilor înregistrate în intervalele anterioare momentului t_0. În acest caz vom putea scrie

$$P (n (t_0, T) = k) = P (n (T) = k)$$

Proprietatea ne asigură că sosirile sunt statistic independente (sosirea unui client nu este condiţionată de sosirea altuia).

(b) Probabilitatea ca să sosească două sau mai multe unităţi într-un interval de timp foarte mic este neglijabilă faţă de lungimea intervalului, sau altfel spus este practic imposibil să înregistrăm două sau mai multe sosiri simultane. Notăm cu P (n (h) > 1) = o (h) unde prin o (h) am notat o funcţie de h cu proprietatea

$$\lim_{h\to 0} \frac{o(h)}{h} = 0$$

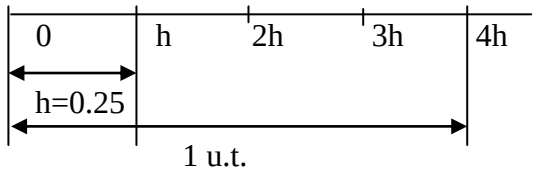
(c) Dacă notăm cu λ frecvenţa medie a unei sosiri a clienţilor (nr. de clienţi în unitatea de timp) atunci probabilitatea înregistrării unei singure sosiri în intervalul t, t+h este

P (n (h) = 1) = λ h

Obs.

$$\text{probabilitatea} = \frac{\text{nr. de cereri aparute}}{\text{nr. total posibil de cereri care pot apare}}$$

$$P(n(h)=1) = \frac{\lambda}{\frac{1}{h}} = \lambda h \qquad \text{numeric } \frac{1}{h} \text{ apare din considerentul}$$



$$\text{Pot apare } \frac{1}{h} = \frac{1}{0.25} = 4 \text{ cereri}$$

Proprietatea ne spune că pentru intervale foarte mici de timp probabilitatea este proporţională cu lungimea intervalului.

(d) Ca urmare probabilitatea de a avea cel puţin o sosire a unui client într-un interval de lungime h este

P (n (h) ≥ 1) = P (n (h) = 1) + P (n (h) > 1) = λh + o (h)

iar probabilitatea de a nu avea nici o sosire într-un interval de lungime h este

P (n (h) = 0) = 1 - P (n (h) = 1) = 1 – (λh + o (h))

Teoremă

În condiţiile a, b, c pentru orice $t \geq 0$ distribuţia variabilei aleatore

n (T) – număr de sosiri în intervalul T – este o distribuţie Poisson de parametru λT

$$P(n(T) = k) = \frac{(\lambda T)^k}{k!} e^{-\lambda T}$$

Demonstraţie

Se poate considera sosirea unei cereri ca un "succes al unui experiment Bernoulli, iar modul în care sosesc cererile pe perioada $T = m \cdot h$ ca o secvenţă de m experimente Bernoulli.

Cu aceste considerente probabilitatea ca să apară exact k clienţi în k subintervale şi să nu apară în m - k subintervale poate fi definită ca fiind o distribuţie binomială

$$P(n(T) = k) = C_m^k (\lambda h + o(h))^k (1 - \lambda h - o(h))^{m-k}$$

Pentru a vedea cum se ajunge la aceasta relaţie vom proceda in următorii paşi succesivi:

1. Şansa ca să avem o sosire in intervalul *h* este λh
2. Şansa ca să avem *k* sosiri in *k* subintervale este
   λh si λh si …… λh de *k* ori deci avem $(\lambda h)^k$
3. Şansa ca să nu avem sosiri intr-un interval *h* este $1 - \lambda h$
4. Şansa ca să nu avem sosiri in restul de *m-k* subintervale este
   $(1 - \lambda h)$ si $(1 - \lambda h)$ si $(1 - \lambda h)$ si ……..$(1 - \lambda h)$ si deci avem $(1 - \lambda h)^{m-k}$
5. Şansa ca să avem sosiri in *k* subintervale si in restul de *m-k* să nu avem sosiri va fi data de $(\lambda h)^k$ si $(1 - \lambda h)^{m-k}$ si deci vom avea $(\lambda h)^k (1 - \lambda h)^{m-k}$
6. Deoarece cele *k* sosiri se pot distribui in C_m^k moduri in cele *m* subintervale vom avea:

$(\lambda h+o(h))^k(1-\lambda h-o(h))^{m-k}$ sau $(\lambda h+o(h))^k(1-\lambda h-o(h))^{m-k}$ sau

$(\lambda h+o(h))^k(1-\lambda h-o(h))^{m-k}$ de C_m^k deci in final vom obţine:

7. $P(n(T)=k)=C_m^k(\lambda h+o(h))^k(1-\lambda h-o(h))^{m-k}$
8. Deoarece şansa de a avea doua sau mai multe sosiri in intervalul h este foarte mica *o(h)=0* si ca rezultat vom obţinem relaţia finala:
9. $P(n(T)=k)=C_m^k(\lambda h)^k(1-\lambda h)^{m-k}$

Pentru a găsi probabilitatea ca n(T) clienţi să sosească în intervalul T vom trece la limită pentru $h \to 0$ şi $m \to \infty$ menţinându-l însă pe $T = h \cdot m$ constant

$$P(n(T)=k)=\lim_{\substack{h\to 0\\ m\to\infty}} C_m^k(\lambda h)^k(1-\lambda h)^{m-k}=\lim_{\substack{h\to 0\\ m\to\infty}} \frac{m!}{k!(m-k)!}\cdot\frac{(\lambda h)^k(1-\lambda h)^m}{(1-\lambda h)^k}$$

$$\lim_{\substack{h\to 0\\ m\to\infty}}(1-\lambda h)^m=\lim_{\substack{h\to 0\\ m\to\infty}}(1-\lambda h)^{\frac{T}{h}\cdot\frac{\lambda}{\lambda}}=\lim_{h\to 0}(1-\lambda h)^{\frac{1}{\lambda h}\cdot\lambda T}=e^{-\lambda T}$$

$$P(n(T)=k)=\frac{e^{-\lambda T}}{k!}\lim_{\substack{m\to 0\\ h\to\infty}}\frac{m!}{(m-k)!}\cdot\frac{(\lambda h)^k}{(1-\lambda h)^k}$$

$$P(n(T)=k)=\frac{e^{-\lambda T}}{k!}\lim_{m\to\infty} m(m-1)(m-2)...(m-k+1)\frac{\left(\frac{\lambda T}{m}\right)^k}{\left(1-\frac{\lambda T}{m}\right)^k}$$

$$P(n(T)=k)=\frac{e^{-\lambda T}(\lambda T)^k}{k!}\lim_{m\to\infty}\frac{m^k+...}{m^k+...}$$

$$P(n(T)=k)=\frac{e^{-\lambda T}(\lambda T)^k}{k!}$$

Observaţii

(1) Variabila aleatoare n (T) are o distribuţie Poisson cu media şi varianta egale cu λT

(2) Observaţia (1) implică faptul că variabila aleatoare $X = \frac{n(T)}{T}$ are valoarea medie $E\left\{\frac{n(T)}{T}\right\} = \lambda$ iar

varianta $\mathrm{Var}\left\{\frac{n(T)}{T}\right\} = \frac{1}{T^2}\mathrm{Var}\{n(T)\} = \frac{\lambda T}{T^2} = \frac{\lambda}{T}$

Pentru $T \to \infty$ media tinde către λ iar varianta către 0 ceea ce justifică numele de frecvenţă de sosire pentru parametrul λ.

3.4. Distribuţia intervalului de timp între două sosiri

Dacă sosirile constituie un proces Poisson cu parametrul λT, atunci intervalele de timp între două intrări consecutive sunt variabile aleatoare independente care urmează o lege exponenţială cu parametrul λ..

Notăm cu X intervalul de la o origine de timp arbitrar aleasă până la prima sosire. Dacă ne raportăm la desenul anterior putem avea



Ne propunem să găsim distribuţia de probabilitate a variabilei aleatoare interval de timp până la prima sosire.

Dacă notăm cu P (n (x) = 0) probabilitatea ca nici un client să nu sosească în intervalul (t_0, t_0+x), n(x) reprezentând numărul de clienţi sosiţi într-un interval de timp de lungime x atunci

$P(X \geq x) = P(n(x) = 0)$

dar din P (n (T) = k) $\Rightarrow$ $P(n(x) = 0) = e^{-\lambda x}$

Prin urmare funcţia de distribuţie a variabilei aleatoare X dată de P (X < x) = F (x) = 1 – P (X ≥ x) = 1 – $e^{-\lambda x}$ pentru x ≥ 0

ca urmare densitatea de probabilitate

f (x) = F'(x) = λ $e^{-\lambda x}$

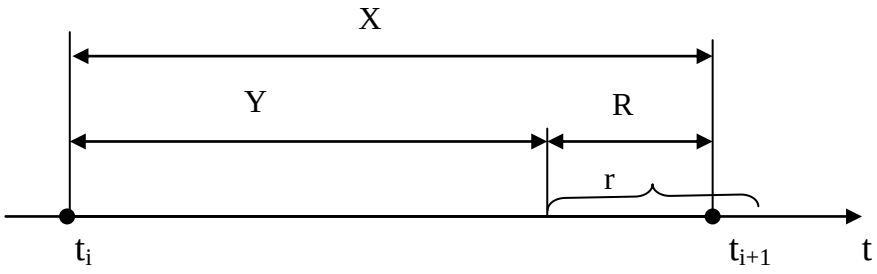
Astfel pentru un proces de sosire Poisson intervalul X între o origine arbitrar aleasă şi momentul primei sosiri este exponenţial distribuit cu media $\frac{1}{\lambda}$. Dacă se va alege ca origine momentul sosirii unui alt client, atunci X va reprezenta intervalul între două sosiri.

În concluzie un proces Poisson are intervalele între două sosiri succesive exponenţial distribuite cu media $\frac{1}{\lambda}$.

3.5. Lipsa de memorie a unui proces Poisson

Un proces Poisson este lipsit de memorie deoarece în calculul probabilităţii timpului rămas înainte de următoarea sosire, nu se ia în considerare când a avut loc ultima sosire.

Notăm cu t_i momentul în care a sosit clientul numărul I şi presupunem că au trecut Y unităţi de timp înaintea momentului t_{i+1} la care urmează să sosească clientul i+1. Grafic avem



Ne propunem să calculăm probabilitatea ca clientul i+1 să sosească într-un interval r unităţi de timp.

Deci se cere calculul probabilităţii

P (R ≤ r | X ≥ Y) unde R = X – Y reprezintă timpul rămas până la următoarea sosire.

Ştim că $P(A \cap B) = P(A) \cdot P(B \mid A)$ de unde $P(B \mid A) = \frac{P(A \cap B}{P(A)}$

deci

$$P(R \le r \mid X \ge Y) = \frac{P(X \ge Y \cap R \le r)}{P(X \ge Y)} = \frac{P(Y \le X \le Y + r}{P(X \ge Y)} =$$

$$= \frac{P(X \le Y + r) - P(X < Y)}{1 - P(X < Y)} = \frac{1 - e^{\lambda(Y+r)} - 1 + e^{-\lambda Y}}{1 - (1 - e^{-\lambda Y})} =$$

$$= \frac{e^{-\lambda Y} - e^{-\lambda(Y+r)}}{e^{-\lambda Y}} = 1 - e^{-\lambda r}.$$

În concluzie timpul rămas până la proxima sosire nu depinde de timpul scurs până în momentul prezent, de la ultima sosire.

3.6 Simularea sistemelor reprezentabile prin șiruri de așteptare

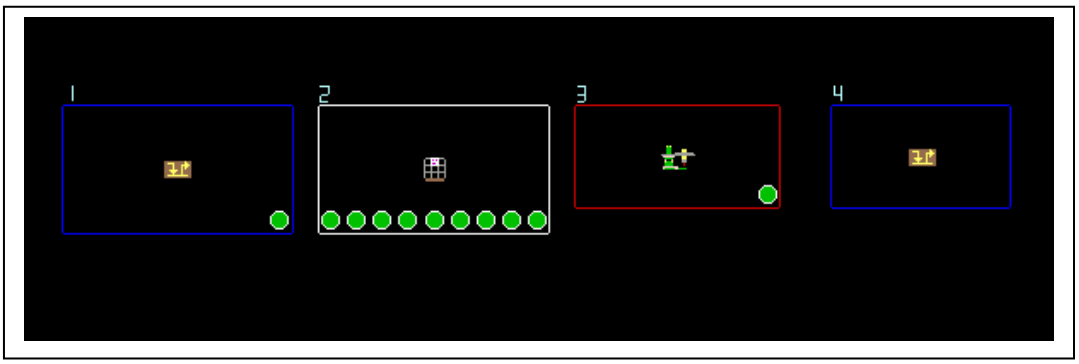
Pentru a putea realiza operația de simulare aunui sistem reprezentabil prin activitățile care se desfășoară la nivelul acestuia sunt necesare două componente.

Prima componentă se referă la reprezentarea sistemului printr-un graf de activități interconectate în timp. Fiecare activitate este descrisă printr-un set de atribute prin intermediul cărora aceasta este particularizată în contextul sistemului în care este prezentă.

A doua componentă se referă la definirea clienților (cererilor) care solicită efectuarea activităților prezente în sistem , activități care sunt descrise de graful activităților care au loc în acesta. Dacă graful activităților reprezintă elementul static al modelului, cererile definesc un element mobil care trece dintr-o activitate în alta. De exemplu în contextul unui sistem care reprezintă procesul de servire la un bancomat activitățile sunt sosire clienți, așteptare, operare bancomat și plecare, în timp ce elementul mobil este definic de persoana care solicită efectuarea unei operații bancare la bancomatul în cauză. Ca și în cazul primei componente clientul

(cererea) este particularizată de un set de atribute care o definesc și o particularizează îcontextul multitudinii de cerei care fac apel la sistemul în cauză.

O imagine a celor două componente prezente în modelul de simulare a sistemul servire a unei cerei la un bancomt este prezentată în figura următoare.



In figurăs e observă prezența celor 4 activități sosire clienți (blocul 1) așteptare (blocul 2) , operare la bancomat (blocul 3) plecare (blocul 4). Peste structura de activități reprezentată de cele 4 blocuri ale grafului activităților se suprapune fluxul de cereri de accesare a unei operații bancare, flux reprezentat grafic de elemntul mobil care se deplasează în graf reprezentat prin cercuri.

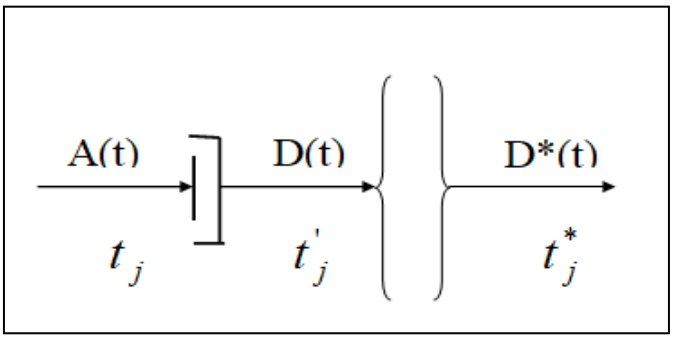
ANEXA

Formula lui Little

Arată că lungimea medie a şirului de aşteptare $\overline{Q}$ care se formează într-un centru de servire este egală cu produsul dintre frecvenţa medie a sosirilor cererilor λ la intrarea centrului şi timpul mediu de aşteptare în şir, notat cu $\overline{W}$.

$$\overline{Q} = \lambda \overline{W}$$

Considerăm un centru de servire în care apare un fenomen de aşteptare de forma:



unde:

t_j - momentele sosirii j = 0,1,2,…

t_j'- momentul primirii serviciului j = 0,1,2,…

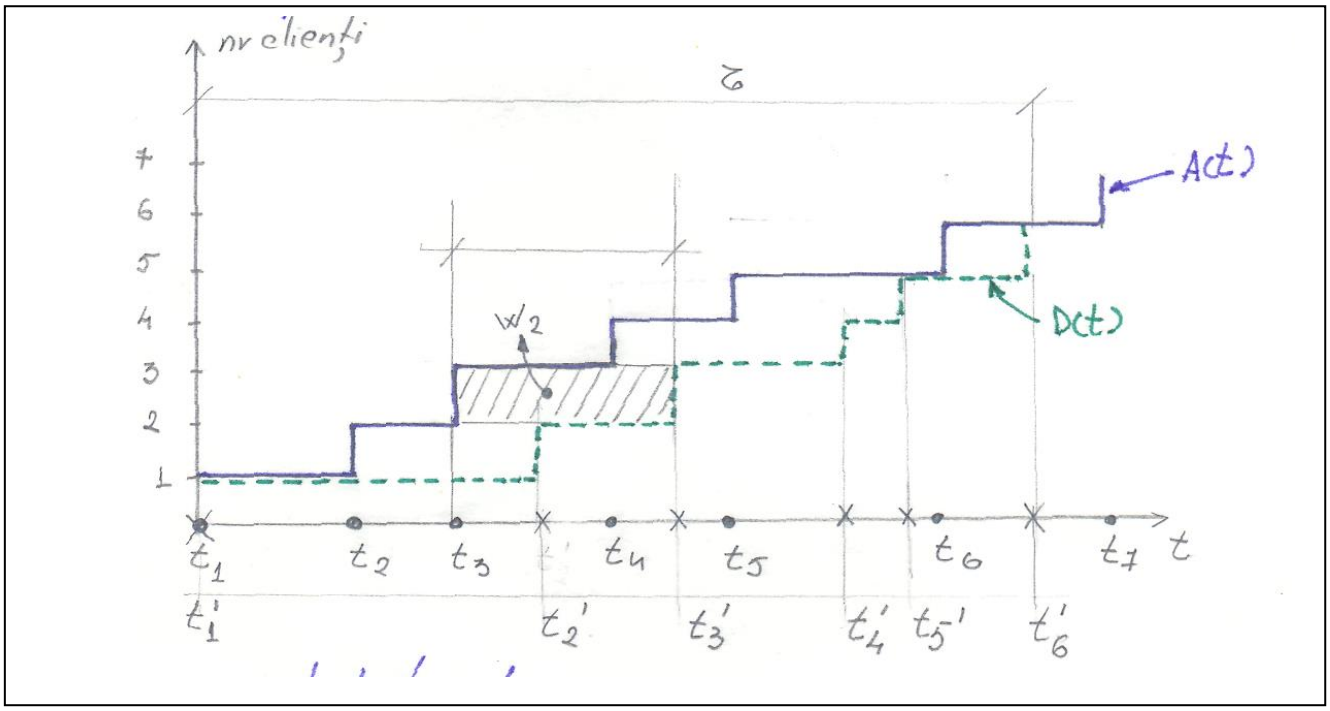
t_j* - momentul părăsirii centrului j = 0,1,2,…

- *A(t)* reprezintă numărul cumulat de clienţi sosiţi în sistem până la momentul *t*;

- *D(t)* reprezintă numărul cumulat de clienţi care au intrat în serviciu până la momentul *t*;

- *D*(t)* reprezintă pentru fiecare t numărul cumulat de clienţi care au părăsit sistemul până la momentul *t*.

- disciplina de planificare a şirului este primul venit primul servit (FIFO).



Pentru orice moment de timp t avem că:

- $Q(t) = A(t) - D(t)$ reprezintă lungimea şirului de aşteptare.
- În cazul disciplinei FIFO diferenţa dintre $t_j' = t_j$ **defineşte timpul cât clientul j aşteaptă în sistem** şi este egală cu distanţa pe orizontală între curbele $A(t)$ şi $D(t)$ şi punctele de coordonate j şi respectiv j-1.
- **Aceeaşi distanţă** pe orizontală este egală cu aria cuprinsă între $A(t)$ şi $D(t)$ de la j-1 la j (înălţimea pe ordonată fiind 1).
- Notăm cu w_j timpul de aşteptare pentru clientul j.
- Alegem două puncte pe axa timpului O şi τ pentru care avem îndeplinită condiţia:

$$A(0) = D(0) \text{ şi } A(\tau) = D(\tau)$$

condiţia însemnând că există o staţie disponibilă la t=0 şi t=τ (deci că A(t), D(t) se intersectează cu efectul că șirul de așteptare dispare).

- Cu aceste presupuneri putem defini:
  - $n(\tau) = A(\tau) - A(0)$ numărul de clienţi sosiţi în intervalul [0, τ]
  - $\lambda(\tau) = \frac{n(\tau)}{\tau}$ frecvenţa medie a sosirilor în intervalul [0, τ]

- Ca urmare timpul mediu de aşteptare pentru intervalul [0, τ] notat cu $\overline{\mathrm{W}}(\tau)$ se va obţine ca suma fâşiilor de înălţime unitară ce se pot forma între *A(t)* şi *D(t)* în intervalul respectiv, raportată la numărul de clienţi sosiţi în acelaşi interval de timp

  $\overline{W}(\tau)=\sum_{j=1}^{n(\tau)} W_j / n(\tau)$ unde W_j este timpul de aşteptare a clientului j.

- Pe de altă parte deoarece *Q(t) = A(t) – D(t)* reprezintă lungimea şirului de aşteptare la momentul t, se poate exprima lungimea medie a şirului de aşteptare pe intervalul [0, τ] notată cu $\overline{\mathrm{Q}}(\tau)$ astfel:

$$\overline{Q}(\tau)=\frac{\int_0^{\tau} Q(t)\,dt}{\tau}$$

- Deoarece fiecare fâşie are o înălţime unitară, suma lungimii fâşiilor este egală cu suma ariilor fâşiilor:

$$\sum_{j=1}^{n(\tau)} W_j = \int_0^{\tau} Q(t)\,dt \text{ şi ca urmare rezultă că}$$

$$\Rightarrow \overline{Q}(\tau)=\frac{\sum_{j=1}^{n(\tau)} W_j}{\tau} \qquad \overline{Q}(\tau)=\frac{\overline{W}(\tau)\cdot n(\tau)}{\tau}=\overline{W}(\tau)\cdot\lambda(\tau)$$

- Dacă se notează cu

  $\lambda=\lim_{\tau\to\infty}\lambda(\tau)$; $\overline{\mathrm{W}}=\lim_{\tau\to\infty}\overline{W}(\tau)$ $\overline{\mathrm{Q}}=\lim_{\tau\to\infty}\overline{Q}(\tau)$ se va obţine

$$\overline{Q}=\lambda\overline{W}$$

Observaţii

1) Dacă τ este suficient de lung se poate face abstracţie de faptul că şirul în acest interval poate dispărea de multe ori (se poate face abstracţie de condiţia *A(0)=D(0)* şi *A(τ)=D(τ)*. De asemenea se poate arăta că indiferent de disciplina de planificare a şirului, timpul de aşteptare va fi egal cu aria cuprinsă între cele două curbe.
2) Dacă se include şi timpul de servire se poate arăta similar că vom avea:

$$\overline{N}=\lambda\overline{T}$$

indiferent de disciplina de servire unde:

$\overline{N}$ este numărul mediu de clienţi din centrul de servire;

$\overline{T}$ este timpul mediu de răspuns (timpul de aşteptare plus timpul de serviciu).

4. Concepte fundamentale de statistică în modelare şi simulare

Statistica este un domeniu al matematicii care se ocupa cu modul în care se colectează datele și cu analiza acestora.

4.1.Populaţie. Eşantion.

Acurateţea unui model depinde în mare măsură de culegerea, respectiv definirea datelor care urmează a fi utilizate pentru a caracteriza atributele entităţilor ce caracterizează sistemul modelat.

In ambele cazuri se face apel la o cantitate mare de date, aspect care ridică probleme legate de prelucrarea lor datorită resurselor de calcul limitate. Din aceste considerente se operează asupra unui set de date (restrâns) extras din cele primare disponibile. Ca urmare a acestei modalităţi de lucru se ridică doua probleme:

1. Cum se extrage setul de date care se va utiliza în cazul tehnicilor de modelare respectiv simulare
2. In ce măsura acesta este reprezentativ pentru datele primare din care a provenit.

Se defineşte :

- *Populaţia statistică* ca fiind mulţimea completă a tuturor datelor posibile ce caracterizează un fenomen sau proces.
- *Eşantion* dintr-o populaţie statistică reprezintă mulţimea datelor la care are acces utilizatorul. Un eşantion se spune că este reprezentativ, dacă dă o idee suficient de completă despre populaţia în cauză. Dacă nu există nici o informaţie apriorică despre

populaţie, singurul mod de a asigura reprezentativitatea este de a efectua o eşantionare aleatoare. Aceasta se realizează printr-un procedeu de randomizare. Presupunem că dorim să extragem 100 date dintr-o populaţie de 10000. Primul pas constă în a număra datele de la 0 la 9999. Utilizând o tabelă de numere aleatoare uniform repartizate de la 0 la 9999 vom putea selecta cele 100 date care ne interesează în mod aleatoriu.

Datorită caracterului aleatoriu al eşantionului, rezultă că orice informaţie care se face asupra unei populaţii pe baza analizei unui eşantion are, de asemenea, un caracter aleatoriu (statistic).

- Fiecare element din cadrul eşantionului (și deci din cadrul populaţiei din care a provenit acesta) este caracterizat de un set de atribute (un element din eşantionul ce provine din setul de informaţii dintr-o centrala de telefonie mobilă va avea ca atribute : durata convorbirii, ora de început / sfârşit convorbire, data convorbirii etc.). Valorile atributelor au un caracter aleatoriu indiferent de natura acestora (numerice, alfanumerice, booleene etc.) aspect care ne permite să discutăm în general despre aceste ca reprezentând *variabile aleatoare*.
- O *variabila aleatoare* este o mărime care în cadrul unui experiment (in cazul nostru un atribut a unui element din eşantion) ia valori diferite.

  Notăm cu **X** variabila aleatoare (de exemplu durata convorbire telefonica) și cu $\mathbf{x_1, x_2, \dots, x_n}$ valorile pe care le poate lua această variabila aleatoare. Valorile luate de X pot fi :

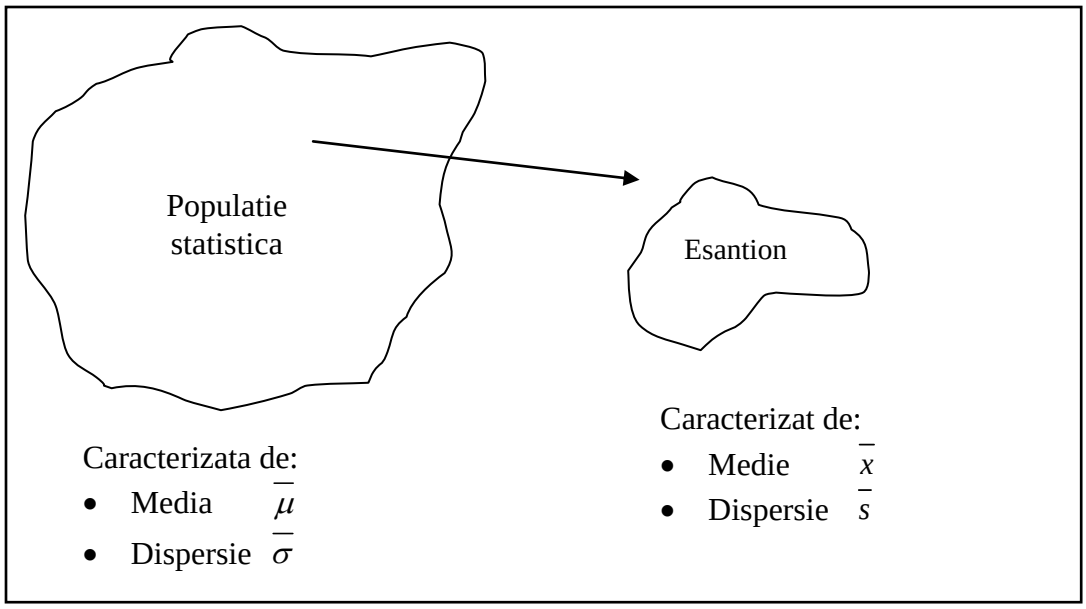
  - *discrete* daca iau valori distincte, de exemplu [2, 9, 4, 11]

- *continue* daca iau valori intr-un interval, de exemplu [1, 20]

Aceste tipuri de valori au un caracter aleatoriu, deoarece nu pot fi prevăzute cu certitudine. Ca urmare avem doua tipuri de variabile:

Variabile aleatoare discrete – dacă se ia numai o valoare distinctă

Variabile aleatoare continue – dacă se ia o valoare într-un interval



Important

Din punct de vedere statistic caracterizarea informaţiilor se poate face astfel:

1. **Static,** de o valoare medie și o dispersie a valorilor în jurul valorii medii. Astfel *populaţia* este definită de medie, notată cu μ și de dispersie notată cu σ, iar eşantionul este definit de medie notată cu $\overline{x}$ barat și de *dispersie* notată cu $\overline{s}$ barat. Atât $\overline{x}$ cât și $\overline{s}$ aproximează valoare medie și dispersia populaţiei.

2. **Dinamic** se specifică cum se modifica valorile datelor din populaţie și eşantion astfel încât să fie obţinute valorile medii și dispersia calculată. Modul în care se modifica valorile este definit de ceea ce poartă numele de *funcţie de distribuţie*.
3. Cele specificate mai sus se aplica valorilor atributelor ce caracterizează o dată, atât din eşantion cât și evident din populaţia statistică.

4.2. Reprezentarea statistică a datelor

Discuţia care urmează se referă la datele prezente în cadrul unui eşantion (de fapt singurele informaţii la care avem în mod real accesul). Pentru a ilustra conceptele pe care le vom discuta vom pleca de la un exemplu. Astfel în 1798 Henry Cavendish a estimat densitatea pământului utilizând o balanţă de torsiune pentru care a obţinut următoarele valori definite în tabelul de mai jos:

5.5	5.29	5.75
5.57	5.34	5.29
5.42	5.26	5.1
5.61	5.44	5.86
5.53	5.46	5.58
5.47	5.55	5.27
5.88	5.34	5.85
5.62	5.3	5.65
5.63	5.36	5.39
4.07	5.79	Notă Apa =1g/c^3 Granit =2.7 g/ c^3

Esantion

Aceste date reprezintă un eşantion din mulţimea datelor care se pot obţine printr-un număr oricât de mare de măsurători. Putem afirma ca densitatea pământului este o mărime care se modifică de la un experiment la altul și în consecință reprezintă o variabila aleatoare pe care o notăm cu ***X***. În contextul acestor măsurători, în număr de n=29 , o valoare o vom nota cu x_i (i = 1, 29).

4.2.1 Frecvenţa Relativă

Frecvenţa

Pentru a ajunge la conceptul de *frecvenţa relativă* vom introduce iniţial noţiunea de *frecvenţa*. Aceasta reprezintă numărul de valori care se găsesc intr-un interval dat. Pentru a calcula frecvenţa de apariţie în cadrul unui interval se procedează la sortarea datelor în ordine crescătoare a parametrului aflat în discuţie. Pentru cazul nostru vom obţine următorul tabel:

Densitatea în ordine crescătoare

1	4.07	8	5.3	15	5.46	22	5.61
2	4.88	9	5.34	16	5.47	23	5.62
3	5.10	10	5.34	17	5.5	24	5.63
4	5.26	11	5.36	18	5.53	25	5.65
5	5.27	12	5.39	19	5.55	26	5.75
6	5.29	13	5.42	20	5.57	27	5.79
7	5.29	14	5.44	21	5.58	28	5.85
						29	5.86

Valoarea acceptată a densităţii pământului este 5.50 g/c^3

Fier: 7.85 g/ c^3

Nichel:8.90 g/ c^3

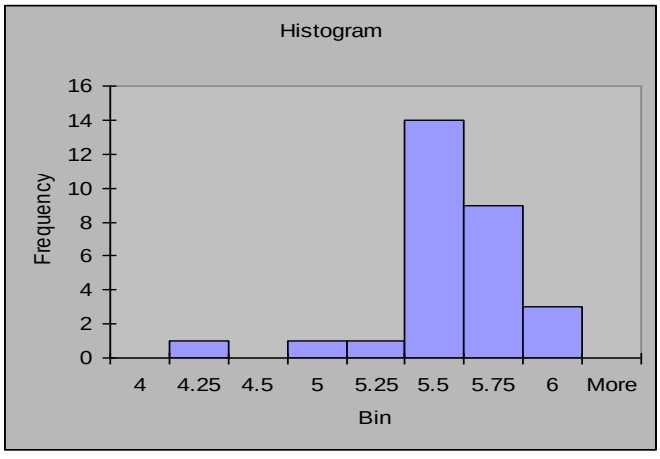
Vom considera un interval de 0.25 și vom considera un număr de 9 intervale care plecă de la valoare minima (4.07) din tabelul de mai sus și vom număra câte valori sunt prezente în fiecare interval. Găsim următoarea situaţie

Histograma

Densitate	Frecvenţa
< 4	0
4 - 4.2	1
4.2 - 4.5	0
4.5 - 5	1
5 - 5.25	1
5.25 - 5.5	14
5.5 - 5.75	9
5.75 - 6	3
> 6	0
Total	29

Frecvența = 14 pentru densitatea pământului valori între 5.25 și 5.5

Trasând histograma pentru datele din tabelul anterior se va obţine:



Frecvenţa relativă

Frecvenţa obţinută depinde de numărul total de observaţii. Se poate elimina aceasta dependență. Pentru aceasta se procedează la împărţirea numărului de valori aflate în fiecare interval la numărul total de valori.

Astfel n_x / n

defineşte frecvenţa valorilor eşantionului aflate în cadrul unui interval dat, frecvenţă care poartă numele de frecvenţă relativă. Pentru exemplul dat vom obţine:

Densitate	Frecvenţa	Frecvenţa Relativă
< 4	0	0
4 - 4.2	1	0.034483
4.2 - 4.5	0	0
4.5 - 5	1	0.034483
5 - 5.25	1	0.034483
5.25 - 5.5	14	0.482759
5.5 - 5.75	9	0.310345
5.75 - 6	3	0.103448
> 6	0	0
Total	29	1

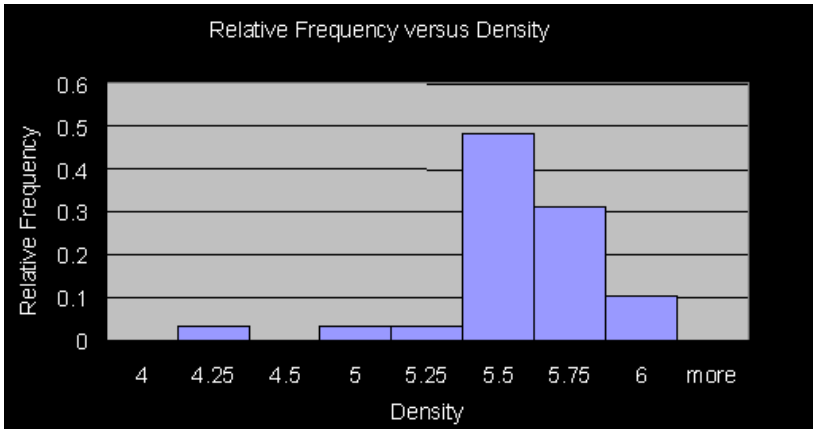
Revenind la un concept fundamental din statistica matematica care spune ca:

Dacă un experiment este repetat de *n* ori (n foarte mare) și evenimentul A este observat de *b* ori *Probabilitatea* de apariţie a evenimentului A este

$$P(A)=b/n$$

Se observă imediat că Probabilitatea= frecvenţa relativă

Trasând histograma acestui tip de frecvenţă se obţine:



În această etapă se face următoarea observaţie:

Este mai importantă aria dreptunghiurilor decât înălţimea acestora (mai ales dacă clasele sunt diferite), deoarece ochiul uman reacţionează la arii şi nu la dimensiuni.

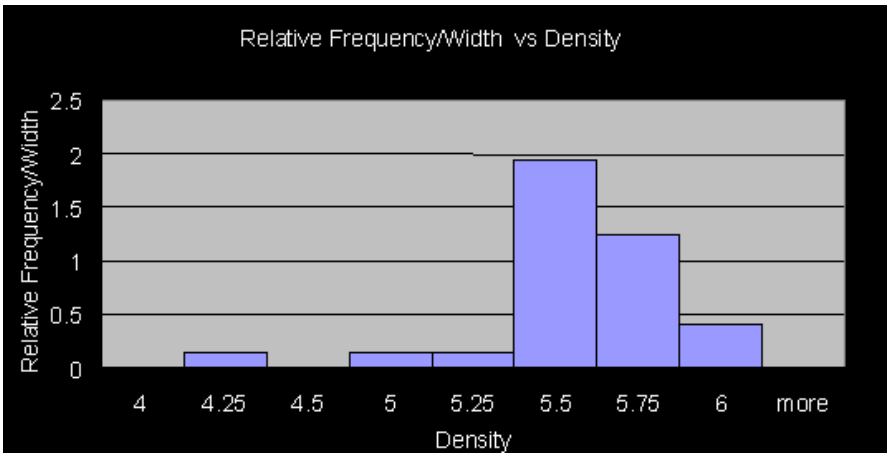
Se intenţionează ca aria dreptunghiurilor să definească frecvenţa relativă. În acest context, se procedează la împărţirea frecventei relative la lăţimea clasei, obţinând astfel ca aria să reprezinte frecvenţa relativă. Pentru exemplul dat vom avea:

Densitate	Frecvenţa	Frecvenţa Relativa = Probabilitate	Frecvenţa Relativa/Lăţimea clasei	Aria care definește frecvența relativă
< 4	0	0	0	0
4 - 4.2	1	0.03448	0.137931	0.03448275
4.2 - 4.5	0	0	0	0
4.5 - 5	1	0.03448	0.137931	0.03448275
5 - 5.25	1	0.03448	0.137931	0.03448275
5.25 - 5.5	14	0.48275	1.931034	0.482
5.5 - 5.75	9	0.31034	1.241379	0.31034475
5.75 - 6	3	0.10344	0.413793	0.02586
> 6	0	0	0	0
Total	29	1	4	

Pentru densitatea pământului valori între 5.25 și 5.5 avem :

- Frecvenţa Relativă / Lăţimea clasei =1.93
- Aria care definește frecvența relativă=1.93x0.25 = 0.482

Pentru acest caz, histograma care se obţine este de forma



4.2.2 Funcţia de distribuţie

Aşa cum am specificat este important să caracterizăm și modul în care se modifică valorile eşantionului. Cu alte cuvinte, ne interesează dinamica acestora, modul în care aceste valori apar în succesiune una după alta. Pentru a obţine această dinamică se parcurg următorii paşi, primul fiind construirea a ceea ce poartă denumirea de frecvenţe cumulate.

- ***Frecvenţe cumulate***

Acestea se construiesc adunând frecventele relative care sunt mai mici decât limita superioara a clasei, cu alte cuvinte vom calcula

$$\sum n_k \leq \text{limita superioară a clasei k}$$

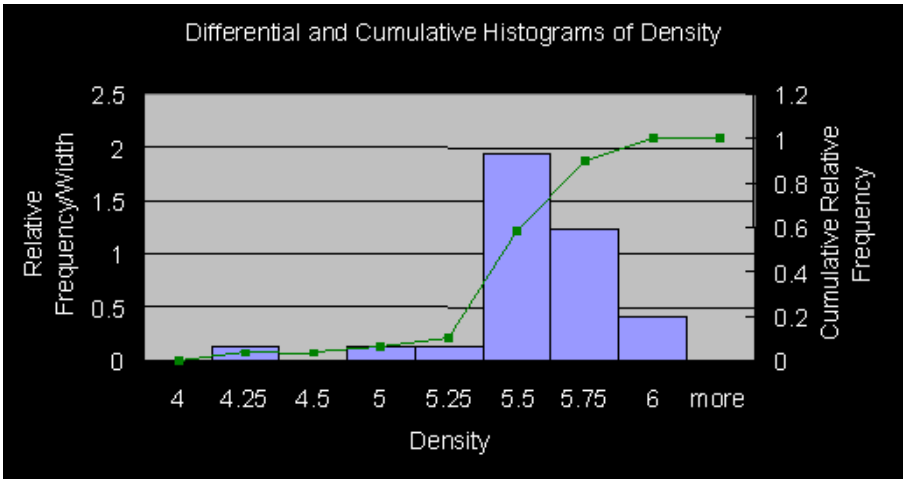
unde:

- k reprezintă clasa
- n_k definește frecvența relativă a clasei k (aria)

Pentru exemplul studiat vom obţine:

Clasa k	Densitate	Frecvenţa	Frecvenţa Relativa	Frecvenţa Relativa/ Lăţimea clasei	Aria care definește frecvența relativă n_k	Frecvente relative Cumulate
1	4	0	0	0	0	0
2	4.25	1	0.03448	0.13793	0.03448275	0.03448
3	4.5	0	0	0	0	0.03448
4	5	1	0.03448	0.13793	0.03448275	0.06896
5	5.25	1	0.03448	0.13793	0.03448275	0.10344
6	5.5	14	0.48275	1.93103	0.482	0.58620
7	5.75	9	0.31034	1.24137	0.31034475	0.89655
8	6	3	0.10344	0.41379	0.02586	1
	Mai mari	0	0	0	0	1
	Total	29	1	4		

Histograma care se obţine în acest caz, în care s-a reprezentat prin interpolare frecvențele cumulate, este de forma:



Din histograma se observa două proprietăţi remarcabile și anume:

- Pe ordonată avem probabilităţi astfel încât pentru o valoare a densităţii pământului mai mică decât o anumită valoare putem afla şansa de a fi posibilă. Astfel

  f(X < x) =Probabilitatea (densitatea < 5.5) = 0.677

Motiv, pentru care funcţia obţinută mai sus poartă numele de *densitate de probabilitate* în cazul variabilelor continue și *distribuţie de probabilitate* in cazul variabilelor discrete.

- Un alt aspect care este remarcabil se refera la faptul că putem determina probabilitatea ca o valoare a densităţii pământului să se afle între anumite limite, însumând ariile prezente intre aceste limite. De exemplu:

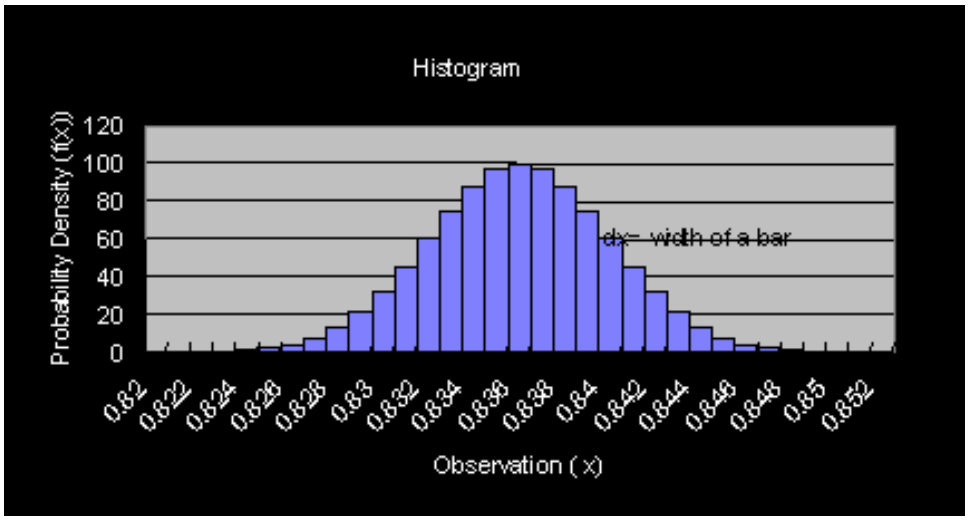
$F(x_1 < X < x_2)$ = Probabilitatea (5.2 < densitatea < 5.5) = 0.05 + 0.91 = 0.916

- ***Funcţia de distribuţie . Densitate de probabilitate.***

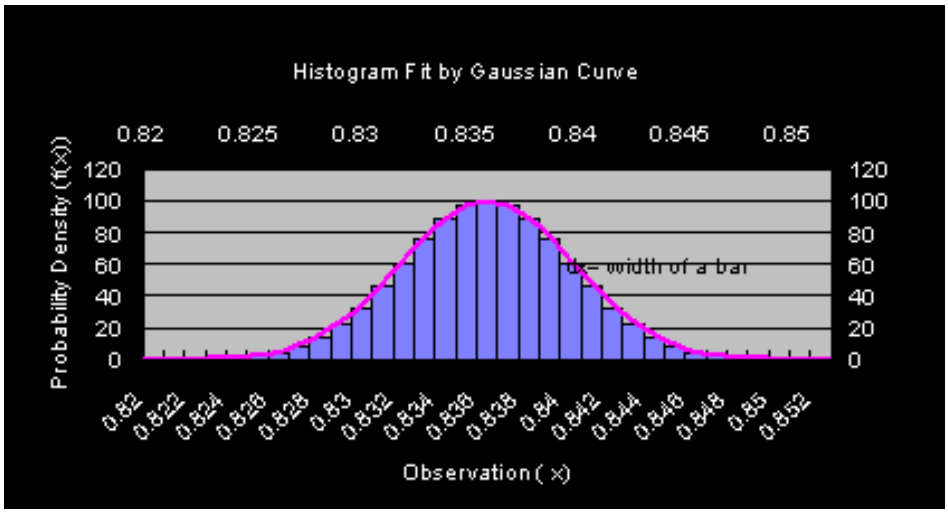
Se observă că atunci când valorile eşantionului sunt foarte mari, la limită identice cu valorile populaţiei din care provine, se obţine funcția care reprezintă modul în care se modifică dinamic valorile populaţiei. Cu alte cuvinte, obţinem funcția care descrie modul în care variază valorile în cauza. Pentru aceasta, facem următoarele observaţii și procedăm după cum urmează:

- Aria fiecărui dreptunghi este egala cu frecvenţa relativa
- Se utilizează un număr mare de observaţii
- Reducem lăţimea dreptunghiului pana la o valoare foarte mica pe care o notăm cu *dx*
- și consideram ca înălţimea dreptunghiului reprezintă o valoare a unei funcții pe care o notăm cu *f(x)*
- Atunci aria dreptunghiului este *f(x)dx*

Histograma distribuţiei de probabilitate (variabila discretă)



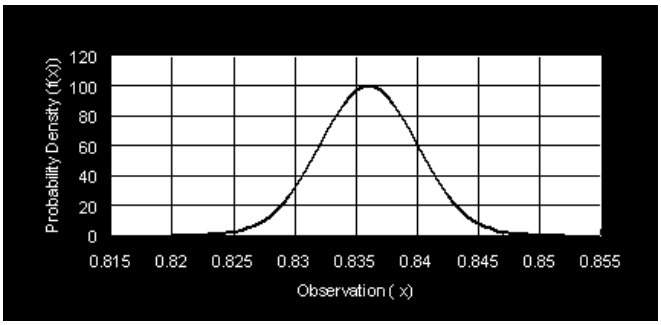
Funcţia densităţii de probabilitate (variabilă continuă)



S-a calculat teoretic și s-a verificat experimental că distribuţia valorilor unei variabile aleatoare ce reprezintă o dată numerica dintr-o populaţie, indiferent dacă aceasta defineşte un atribut a unei date cât și data în sine, urmează o lege de distribuţie de forma specificată în figura de mai sus. Funcţia poartă numele de *distribuţie Gaussiană* și se exprimă prin relaţia

$$f(x) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} \right)$$

În care *f(x)* este probabilitatea de a observa o valoare a lui *x*, intru-un interval dat. Grafic această funcţie prezintă următorul aspect



Există câteva observaţii care pot fi făcute referitoare la axa x și anume:

Aria de la μ- σ la μ+ σ este 0.6826
Aria de la μ- 2σ la μ+ 2σ este 0.9544
Aria de la μ-3 σ la μ+ 3σ este 0.9974
Aria totala de sub curbă este =1.0000

4.2.3 Media și Dispersia datelor

Aşa cum am specificat există un set de indici care caracterizează global datele din populaţie / eşantion. Acestea sunt:

- Valoarea medie a datelor
- Mediana
- Dispersia datelor

Valoarea Medie

Exprimă nivelul atins de o variabilă numerică când ea este uniform repartizată pe unităţile care compun o populaţie determinată. De obicei (se utilizează o distanță Euclidiană, dar se poate utiliza de exemplu și o distanță Manhattan), valoarea medie se referă la media aritmetică definită de relaţia :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Media eşantionului reprezintă o aproximaţie a mediei μ a populaţiei din care provine

Mediana

Este valoarea situată la mijlocul eşantionului care are valori aranjate în ordine de mărime crescătoare sau descrescătoare. Ca urmare, mediana împarte eşantionul în două grupe egale ca număr. în jur de 50% din valorile ordonate ale densităţii sunt prezente sub mediana

Cazuri :

1) Pentru un eşantion cu un număr impar de valori (2k+1), mediana este valoarea de rangul k+1.

Ex : mediana seriei : 4 7 12 26 32 38 59

|

2) Pentru un eşantion cu un număr par de valori (2k), mediana se găseşte între valorile de rangul k și k+1, și în general se convine să fie reprezentată de media aritmetică a celor două valori.

Ex : mediana seriei : 4 7 12 26 32 38

|_ _|

|

(12+26) / 2

Dispersia datelor

Caracterizează variaţia ce predomină în eşantionul a cărui medie este cunoscută. Pentru o serie de valori individuale abaterea (dispersia datelor) este definită de expresia

$$s^2 = \frac{1}{n}\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2$$

Se procedează la ridicarea la pătrat, datorită faptului ca o serie de valori pot fi negative, respectiv mai mici decât valoarea medie, ceea ce face

ca diferenţa dintre o valoare particulară și medie să fie negativa, aspect care fără ridicarea la pătrat influențează valoarea adevărată a abaterii. Din acest considerent se recurge la calculul pătratului acestei abateri. Parametrul care se obţine poartă numele de *varianță*.

Pentru a obţine valoarea corectă a abaterii se extrage radicalul fiind astfel obţinută *dispersia*, altfel numită *deviaţia standard*. Aceasta este definită de expresia

$$\bar{s} = \frac{1}{n}\sqrt{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}$$

Pentru a ilustra conceptul de abatere și modul în care acesta se calculează se prezintă următorul exemplu:

Numărul valorii i	Valori variabilă aleatoare X	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	35	-18.67	348.44
2	47	-6.67	44.44
3	48	-5.67	32.11
4	50	-3.67	13.44
5	51	-2.67	7.11
6	53	-0.67	0.44
7	54	0.33	0.11
8	70	16.33	266.78
9	75	21.33	455.11
Media variabilei aleatoare X notată cu $\bar{x}$ este	67	0	1168.00
Deviaţia standard notată cu $\bar{\sigma}$ este			12.08

Parametrii globali care caracterizează variabila aleatoare

Densitatea pământului (X)

Media	$\overline{x}$ =5.42	Deviaţia standard	$\overline{\sigma}$ =0.3388
Minimum	4.07	Maximum	5.86
Mediana	5.46	Lege de distribuție normală a valorilor	

Exemplu

Presupunem că dintr-o populaţie uniform distribuită în (0,100) extragem un număr de 4 eşantioane pentru care calculăm valoarea medie.

Nr. Eşantion	Eşantion Variabila aleatoare măsurată este X	Val. medie $\overline{x}$	Mediana
1	X_1 { 22, 92, 35, 63 }	53	49
2	X_2 { 97, 13, 34, 3, 77 }	45	34
3	X_3 { 45, 55, 37, 76, 83 }	59	55
4	X_4 { 15, 57, 44, 68 }	46	51

Întrebarea care se pune este următoarea:

Care este valoarea mediei care caracterizează populația din care provin cele 4 eșantioane , deoarece fiecare eșantion a furnizat o altă valoare medie. Pentru a avea o imagine cât mai corectă asupra valorii medii a populației se procedează astfel:

- Se extrag mai multe eșantioane. Operația este valabilă atât în cazul în care se efectuează măsurători pe un sistem real sau când se efectuează experimente de simulare cu un model. În această ultimă situație întotdeauna se vor efectua mai multe experimente de simulare.

- Se calculează valoare medie a mediilor variabilei aleatoare care definește un parametru al modelului. Se calculează de asemenea dispersia mediilor astfel obținute.
- Deoarece valorile obținute din măsurători au o distribuție normală, putem determina un interval în care se află valoarea adevărată a parametrului analizat cu un grad de certitudine dat.

  Pentru exemplul dat vom avea:

  - pentru valoarea medie

  $$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \quad \bar{x} = \frac{53+45+59+46}{4} = 50.75$$

  - pentru dispersie

  $$\bar{s} = \frac{1}{n-1}\sqrt{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}$$

  $$\bar{s} = \frac{1}{3}\sqrt{(53-50.75)^2 + (45-50.75)^2 + (59-50.75)^2 + (46-50.75)^2}$$

  $$\bar{s} = \frac{1}{3}\sqrt{(-2.25)^2 + (-5.75)^2 + (8.25)^2 + (4.75)^2}$$

  $$\bar{s} = \frac{1}{3}\sqrt{128.3375}$$

  $$\bar{s} = \frac{11.3283}{3} = 3.77$$

  Deoarece cunoaștem că legea de distribuție a valorilor medii obținute din măsurători pentru un același parametru este normal distribuită putem afirma că valoarea medie a parametrului care aparține populației este:

  $$\mu \in \left[\bar{x} \pm \bar{s}\right]$$
  $$\mu \in \left[50.75 - 3.77, 50.75 + 3.77\right]$$

Valoare medie a parametrului care aparține populației este calculată astfel

- Aria de la μ- σ la μ+ σ este 0.6826 deci

  $\bar{\mu} \in \left[\bar{x} - \bar{s}, \bar{x} + \bar{s}\right] = \left[50.75 - 3.77, \quad 50.75 + 3.77\right] = \left[46.98, \quad 53.52\right]$

  cu o probabilitate de 0.68
- Aria de la μ- 2σ la μ+ 2σ este 0.9544

  $\bar{\mu} \in \left[\bar{x} - \bar{s}, \bar{x} + \bar{s}\right] = \left[50.75 - 7.54, \quad 50.75 + 7.54\right] = \left[43.21 \quad 58.29\right]$

  Cu o probabilitate de 0.95

Concluzii

1) Întotdeauna se operează pe un eşantion de date, deoarece cantitatea primară de date este mult prea vastă pentru a putea fi prelucrată.
2) Eşantionul este caracterizat de un set de parametrii globali și de o lege de variaţie a datelor. Ambii se raportează la întreaga populaţie, fiind utilizaţi pentru caracterizarea acesteia.
3) Funcţia densităţii de probabilitate și distribuţia de probabilitate sunt ambele ilustrate de histograme.

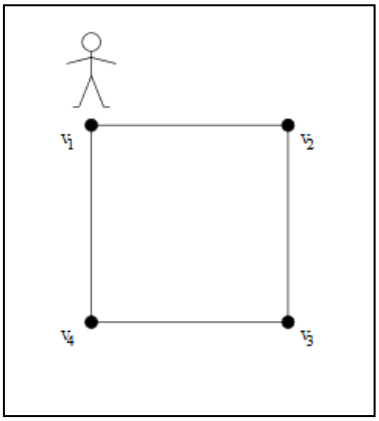
5. Modele Markov.

5.1 Principii.

Vom pleca de la un exemplu simplu pentru a specifica ce este un model Markov. Acesta reprezintă sisteme, în care starea viitoare în care se poate afla sistemul este determinată de starea curentă a acestuia. Aceste sisteme au fost studiate pentru prima dată de matematicianul rus Andrei Markov și din acest considerent denumirea procesului care descrie dinamica sistemului în timp poartă numele de **proces Markov** iar modelul care poate descrie o astfel de evoluție, **lanț Markov** sau **model Markov**.

Exemplu 1. Pieton aleator.

Considerăm un "*pieton aleator*" într-un oraș mic, care are numai 4 străzi și 4 colțuri de stradă v_1, v_2, v_3, v_4 aranjate ca în figura următoare:



La momentul 0 , pietonul stă în colțul de stradă v_1,. La momentul 0 aruncă o monedă în aer și după cum cade, cap sau stemă se deplasează la v_2 sau v_4. Alegerea de deplasare la următorul colț de stradă este *în sens orar dacă este cap* și *trigonometric dacă este stemă*. Această procedură este utilizată pentru toate momentele de timp $n = 0, 1, 2, 3,$ ….

Notăm cu X_n o variabilă care să definească colțul de stradă unde este prezent pietonul la momentul de timp n. În acest context mulțimea (X_0, X_1, X_2, …..) va defini un proces aleator care ia valori din mulțimea {1, 2, 3, 4}.

Deoarece pietonul începe să se deplaseze la momentul de timp 0 fiind prezent în v_1, vom avea

$$P(X_0 = 1) = 1 \tag{1}$$

La următorul moment de timp pietonul se va putea deplasa la v_2 sau v_4 cu probabilitatea ½ fiecare astfel că

$$P(X_0 = 2) = \frac{1}{2} \text{ și } P(X_0 = 4) = \frac{1}{2} \tag{2}$$

Să luăm în considerare un alt aspect. Presupunem că la momentul de timp n , pietonul este la v_2.

Putem scrie că

$$P(X_{n+1} = v_1 \mid X_n = v_2) = \frac{1}{2} \tag{3}$$

$$P(X_{n+1} = v_3 \mid X_n = v_2) = \frac{1}{2} \tag{4}$$

Datorită mecanismului de alegere a sensului de deplasare pe care pietonul l-a adoptat, se poate lua în considerare întregul istoric al deplasării în oraș de forma

$$P(X_{n+1} = v_1 \mid X_0 = i_0, X_1 = i_1, ..., X_{n-1} = i_{n-1}, X_n = v_2) = \frac{1}{2} \tag{5}$$

și

$$P(X_{n+1} = v_3 \mid X_0 = i_0, X_1 = i_1, ..., X_{n-1} = i_{n-1}, X_n = v_2) = \frac{1}{2} \tag{6}$$

pentru orice alegere din $i_0, i_1, \ldots\ldots i_{n-1}$.

Această afirmație este corectă, deoarece o aruncare a monedei în pasul $n+1$ este independentă de toate cele n aruncări anterioare $X_0, X_1, X_2, \ldots..,$, X_n. Acest fenomen este cunoscut sub denumirea de *lipsă de memorie* sau *proprietate Markov* iar sistemul în care apare acest fenomen este cunoscut sub denumirea de *sistem cu proprietate Markov*.

- Acesta proprietate spune că distribuția de valori pentru X_{n+1} dată de istoricul valorilor din stările trecute $X_0, X_1, X_2, \ldots, , X_n$ depinde numai de valoarea obținută în starea X_n . Cu alte cuvinte pentru a fi posibil de **prevăzut** ce se va întâmpla "*mâine*" (timpul $n+1$) este necesar să cunoaștem ce se întâmplă "*azi*" (timpul n) iar "*trecutul – istoricul*" (timpul $0, 1, \ldots, n-1$) nu ne furnizează nici o informație utilă.
- Altă proprietate interesantă a unui proces aleatoriu este aceea că distribuția de valori pentru X_{n+1} depinde numai de valorile din starea precedentă X_n fiind aceeași pentru toate momentele de timp n , (aceasta deoarece mecanismul prin care pietonul ia decizii în fiecare moment de timp n este același). Această proprietate este cunoscută ca omogenitate a unui proces Markov sau pe scurt *omogenitate*.

Definiție

Fie P o matrice de dimensiune (k x k) cu elemente $\{P_{i,j} : i, j = 1, \ldots, k\}$. *Un proces aleator* $(X_0, X_1, \ldots)$ *cu stări finite din spațiul* $S=\{s_1, s_2, \ldots s_k\}$ *se spune că este un* ***lanț Markov omogen cu matricea de tranziție*** *P, dacă pentru toți n, toți* $i,j \in \{1, 2, \ldots, k\}$ *si toți* $i_0, \ldots, i_{n-1} \in \{1,2,..k\}$ *avem*

$$\begin{aligned} & P\left(X_{n+1} = s_j \mid X_0 = s_0, X_1 = s_1, \ldots, X_{n-1} = s_{n-1}, X_n = s_n\right) \\ & = P\left(X_{n+1} = s_j \mid X_n = s_i\right) \\ & = P_{i,j}. \end{aligned} \tag{7}$$

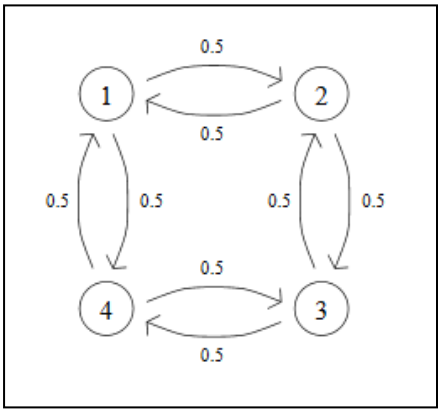
Elementele matricei de tranziție poartă numele de ***probabilități de tranziție***. Probabilitatea de tranziție P_{ij} este probabilitatea ca să fim în starea s_j "*mâine*" atunci când suntem în starea s_i "*azi*".

Termenul omogen se referă la faptul că indiferent de starea în care se găsește sistemul se utilizează aceeași procedură trecere dintr-o stare în alta. Atunci când se vorbește despre *lanț Markov* proprietatea de *omogen* este implicită și se omite.

De exemplu pentru un "*pieton aleator"* acesta poate fi definit de un lanț Markov unde spațiul stărilor este {1, . . .,4} și matricea de tranziție

$$\begin{bmatrix} 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \end{bmatrix} \tag{8}$$

O modalitate curentă de reprezentare a unui lanț Markov este grafică prin intermediul unui **graf de tranziție**. Un graf de tranziție (matricea probabilităților de tranziție) constă din noduri care definesc stările unui lanț Markov, iar arcele dintre noduri vor reprezenta probabilitățile de tranziție. Pentru exemplul dat definit prin matricea (8) vom avea următoarea reprezentare



Fiecare matrice de tranziție satisface următoarele condiții

$$P_{i,j} \geq 0 \text{ pentru toți } i, j \in \{1,\ldots.k\}, \tag{9}$$

$$\sum_{j=1}^{k} P_{i,j} = 1 \text{ pentru toți } i \in \{1,\ldots.k\} \tag{10}$$

Proprietatea (9) specifică faptul că toate probabilitățile de tranziție sunt pozitive ia proprietatea (10) că suma lor este întotdeauna 1.

Să luăm în considerarea o altă caracteristică importantă a unui lanț Markov care poartă denumirea de **distribuție inițială.** Aceasta specifică starea inițială a unui lanț Markov, fiind reprezentată de un vector $\mu^{(0)}$ dat de

$$\mu^{(0)} = \left(\mu_1^{(0)}, \mu_2^{(0)}, ..., \mu_k^{(0)}\right)$$
$$= \left(P\left(X_0 = s_1\right), P\left(X_0 = s_2\right), ...P\left(X_0 = s_k\right)\right)$$

Deoarece $\mu^{(0)}$ reprezintă o distribuție de probabilitate vom avea

$$\mu^{(n)} = \mu^{(0)} \times P^n \tag{11}$$

Pentru exemplul dat al "*pieton aleator*" vom avea

$$\mu^{(0)} = (1, 0, 0, 0) \tag{12}$$

Similar vectorul linie $\mu_1^{(n)}, \mu_2^{(n)}, ..., \mu_k^{(n)}$ va defini distribuția unui lanț Markov la momentele de timp 1,2,…,n astfel încât

$$\mu^{(n)} = \left(\mu_1^{(n)}, \mu_2^{(n)}, ..., \mu_k^{(n)}\right)$$
$$= \left(P\left(X_n = s_1\right), P\left(X_n = s_2\right), ...P\left(X_n = s_k\right)\right)$$

Pentru "*pieton aleator" din exemplul ,* ecuațiile (3) și (4) specifică faptul că

$$\mu^{(1)} = (0, 0.5, 0, 0.5)$$

Revenind la exemplul dat se observă că cunoscând distribuția inițială $\mu^{(0)}$ și matricea de tranziție P se pot calcula toate distribuțiile $\mu^{(1)}, \mu^{(2)}, ...$ a unui lanț Markov. Această observație face ca calculul distribuției să se reducă la o simplă multiplicare de matrice. Convenim să scriem P^n pentru a specifica putere a *n* a acestei matrice

Teoremă 1

Pentru un lanț Markov $(X_0, X_1, ...)$ cu spațiul de stări $\{s_1, ..., s_k\}$, distribuția inițială $\mu^{(0)}$ și matricea de tranziție P, vom avea pentru orice *n* distribuția $\mu^{(n)}$ la momentul de timp n care satisface relația

$$\mu^{(n)} = \mu^{(0)} \times P^n \tag{13}$$

Demonstrație

Considerăm primul caz în care n-1. Vom obține pentru j=1,..,k că

$$\mu_j^{(1)} = \quad P\left(X_1 = s_j\right) = \sum_{i=1}^{k} P\left(X_0 = s_i, X_1 = s_j\right)$$
$$= \sum_{i=1}^{k} P\left(X_0 = s_i\right) P\left(X_1 = s_j \mid X_0 = s_i\right)$$
$$= \sum_{i=1}^{k} \mu_i^{(0)} P_{i,j} = \left(\mu^{(0)} P\right)_j$$

Unde $\left(\mu^{(0)} P\right)_j$ reprezintă cel de al *j* element din vectorul linie $\mu^{(0)} P$.

Deci $\mu^{(1)} = \mu^{(0)} P$

Pentru a demonstra ecuația (13) se va utiliza inducția. Considerăm momentul de timp *n=m*. Pentru momentul de timp ulterior *n=m+1* se va obține

$$\mu_j^{(m+1)} = \quad P\left(X_{m+1} = s_j\right) = \sum_{i=1}^{k} P\left(X_m = s_i, X_{m+1} = s_j\right)$$
$$= \sum_{i=1}^{k} P\left(X_m = s_i\right) P\left(Xm+_1 = s_j \mid X_m = s_i\right)$$
$$= \sum_{i=1}^{k} \mu_i^{(m)} P_{i,j} = \left(\mu^{(m)} P\right)_j$$

Astfel încât $\mu^{(m+1)} = \mu^{(m)} P$. Dar $\mu^{(m)} = \mu^{(0)} P^m$ și prin recurență obținem $\mu^{(m+1)} = \mu^{(m)} P = \mu^{(0)} P^m P = \mu^{(0)} P^{m+1}$

Exemplu 2: Predicție vreme

Se afirmă că cel mai simplu mod de a prevedea vremea de mâine este acela de a ști cum este vremea azi. Să presupunem că această afirmație este corectă aspect care face ca modelul firesc pentru predicția vremii este de tip lanț Markov. Pentru simplificare să presupunem că luăm numai trei tipuri de vreme: Înnorat, Plouă și Soare. În acest caz spațiul avem

- stărilor este *S = { s1 = „Înorat”, s2 = „Plouă” și s3 = „Soare”}*

- Matricea de tranziție
- Care în cazul general este de forma

$$A=\begin{bmatrix} a_{11} & a_{12} & .... & a_{1j} & .... & a_{1N} \\ a_{21} & a_{22} & .... & a_{2j} & ..... & a_{2N} \\ . & . & . & . & . & . \\ a_{i1} & a_{i2} & .... & a_{ij} & .... & a_{iN} \\ . & . & . & . & . & . \\ a_{N1} & a_{N2} & .... & a_{Nj} & .... & a_{NN} \end{bmatrix} \text{ unde}$$

$$a_{ij}=P\left(q_t=j \mid q_{t-1}=i\right) \quad 1\le i,j\le N$$

cu: $a_{ij}>0 \quad \forall i,j$

$$\sum_{j=1}^{N} a_{ij}=1 \quad \forall i$$

Pentru cazul particular din exemplu avem

$$[A]=\begin{array}{c} \begin{matrix} \text{Înnorat} & \text{Plouă} & \text{Soare} \end{matrix} \\ \begin{bmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{bmatrix} \end{array} \begin{matrix} \text{Înorat} \\ \text{Plouă} \\ \text{Soare} \end{matrix}$$

unde

$$a_{13}=P\left(q_t=\text{Soare} \mid q_{t-1}=\text{Înnorat}\right)=0.3$$
$$a_{32}=P\left(q_t=\text{Plouă} \mid q_{t-1}=\text{Soare}\right)=0.1$$

Se cere

Calculați care este probabilitatea de a avea *SSSPPSÎS* dacă astăzi este *S*.

Starea inițială este dată de $\pi = P(S) = 1$

Rezolvare

Probabilitatea de a avea evenimentul A care sa succeadă după evenimentul B este

$$P(A,B)=P(A \mid B)P(B)$$

Modelul Markov care surprinde aceasta succesiune in care cu $q_{k,k=\overline{1,n}}$ s-a notat probabilitatea de a avea un eveniment de tip *{Î,P,S}* la momentele de timp 1,2,….n. Cu

$$\begin{aligned} &P\left(q_{1,}q_{2,}.....q_n\right) \\ &\quad =P\left(q_{n,} \mid q_{1,}q_{2,}.....q_{n-1,}\right)P\left(q_{1,}q_{2,}.....q_{n-1,}\right) \\ &\quad =P\left(q_n \mid q_{n-1}\right)P\left(q_{1,}q_{2,}.....q_{n-1}\right) \\ &\quad =P\left(q_n \mid q_{n-1}\right)P\left(q_{n-1} \mid q_{n-2}\right)P\left(q_{1,}q_{2,}.....q_{n-2}\right) \\ &\quad =P\left(q_n \mid q_{n-1}\right)P\left(q_{n-1} \mid q_{n-2,}\right).....P\left(q_2 \mid q_1\right)P\left(q_1\right) \end{aligned}$$

Pentru secvența O = (SSSPPSÎS)

$$
\begin{aligned}
&P(O \mid \text{model}) \\
&= P(S,S,S,P,P,S,\hat{I},S \mid \text{model}) \\
&= P(S)P(S \mid S)P(S \mid S)P(P \mid S)P(P \mid P)P(S \mid P)P(\hat{I} \mid S)P(S \mid \hat{I}) \\
&= \pi a_{33} a_{33} a_{31} a_{11} a_{13} a_{32} a_{23} \\
&= (1)(0.8)(0.8)(0.1)(0.4)(0.3)(0.1)(0.2) = 1.536 \times 10^{-4}
\end{aligned}
$$

5.2 Modele Markov. Descriere formală a unui model Markov.

Sunt utilizate pentru descrierea unui sistem prin intermediul unui graf în care:

- nodurile reprezintă stări în care este prezent sistemul;
- arcele sunt utilizate pentru descrierea modului în care sistemul tranzitează dintr-o stare în alta;
- etichetele arcelor reprezintă şansa (probabilitatea) ca sistemul să treacă dintr-o stare în altă stare.

5.2.1 Reprezentarea matematică a unui sistem printr-un model Markov

Matematic, descrierea unui sistem prin intermediul unui graf poate fi formalizată după cum urmează:

1. Stările în care este prezent un sistem pot reprezenta valorile unei variabile aleatoare. Dacă notăm cu X această variabilă care reprezintă sistemul, aceasta are un caracter aleatoriu (stohastic / probabilistic), deoarece trecerea dintr-o stare în altă stare se face funcţie de şansa de a tranzita dintr-o stare prezentă într-o altă stare. Deoarece acest proces se desfăşoară în timp, variabila, care desemnează sistemul are un caracter dinamic şi denumirea matematică utilizată este de *funcţie aleatoare sau proces stohastic*.

2. Se notează cu $X(t,\omega)$ funcţia care defineşte sistemul unde:
   - mărimea ω defineşte o stare în care poate fi prezent sistemul
   - Ω va reprezenta mulţimea tuturor stărilor în care este prezent sistemul modelat
   - $\omega \in \Omega$, va exprima caracterul aleator (apartenenţa unei stării curente la o mulţime de stări posibile) iar mărimea t dependenţa de timp.

3. Proprietăţile pe care le are un proces stohastic - denumit proces Markov (sau lanţ Markov datorită succesiunii în timp a evenimentelor) sunt:

a) este de forma:

$$\{X_t ; t = 0,1,2,...\}$$

parametrul t parcurgând o mulţime discretă de valori de timp

b) poate fi prezent în una din stările

$\{ S_0, S_1, S_2, \ldots S_j \ldots \}$

Valorile posibile ale variabilei aleatoare X_i care aparţin unei mulțimi numărabile S poartă denumirea de <u>*spaţiul stărilor*</u> a lanțului Markov

c) probabilitatea ca sistemul să fie prezent în starea S_j la momentul t_{k+1} depinde numai de starea în care se află la momentul t_k pentru orice secvenţă de momente $t_1<t_2<...<t_k<t_{k+1}<...$ Proprietatea enunţată se poate scrie:

$$P(X_{t+1} = j | X_0 = a, X_1 = b, ..., X_t = i) = P(X_{t+1} = j | X_t = i)$$

Cu alte cuvinte un <u>*proces Markov este un proces stohastic în care cunoaşterea dezvoltării ulterioare este determinată de stadiul prezent.*</u> Deci, probabilitatea oricărei stări viitoare, dată de stările trecute şi de starea prezentă este independentă de stările trecute şi depinde numai de starea prezentă în care se găseşte procesul. Altfel spus starea prezentă în care se găseşte sistemul condiţionează starea viitoare în care acesta se va afla.

5.2.3 Mărimi caracteristice ale unui lanţ Markov

Sistemul din lumea reală reprezentat printr-un model Markov este definit de un graf care formal este descris prin :

- probabilităţi de tranziţie
- matricea probabilităţilor de tranziţie

a) <u>Probabilităţi de tranziţie</u>

Definesc şansa ca sistemul să evolueze dintr-o stare prezentă într-o altă stare. Şansa de a trece din starea *i* existentă la momentul *t* în starea *j* la momentul următor de timp *t+1* matematic apare de forma:

$$P(X_{t+1}=j/X_t=i)$$

şi este notată cu $q_{ij}(t)$.

b) <u>Matricea probabilităţilor de tranziţie</u>

Considerăm ca sistemul se găseşte în starea *i* la momentul de timp *t* cu şansa (probabilitatea) $p_i(t)$, $i = 1,2,...j, ...N$. Sistemul va evolua în momentul de timp următor *t+1* în starea j cu probabilitatea $p_j(t+1)$.

Pentru fiecare stare i există o probabilitate de tranziţie $q_{ij}(t)$ pe care sistemul o va lua ca să tranziteze din această stare în starea *j*. Deci putem scrie:

$$p_j(t+1)=\sum_{i=1}^{N} p_i(t)\,q_{ij}(t) \quad \mathrm{j}=1,2,...\mathrm{N}$$

unde

$$\mathrm{p_j(t+1)=P(X_{t+1}=j)}$$

sau în reprezentare matricială

$$[\mathrm{p(t+1)}]=[\mathrm{p(t)}]\cdot[\mathrm{Q(t)}] \qquad (1)$$

unde:

- [p(t+1)] este o matrice *N* dimensională linie având elementele $p_j(t)$; j=1,2,…N

- [Q(t)] este o matrice *N x N* având elementele $q_{ij}(t)$, a cărei denumire este de <u>*matricea probabilităţilor de tranziţie*</u> la momentul t.

Exemplu

Să considerăm o maşină care efectuează o revizie tehnică într-un atelier de întreţinere auto. Autoturismul. în intervalul de timp corespunzător reviziei se poate găsi în unul din punctele de lucru:

M – atelier mecanic

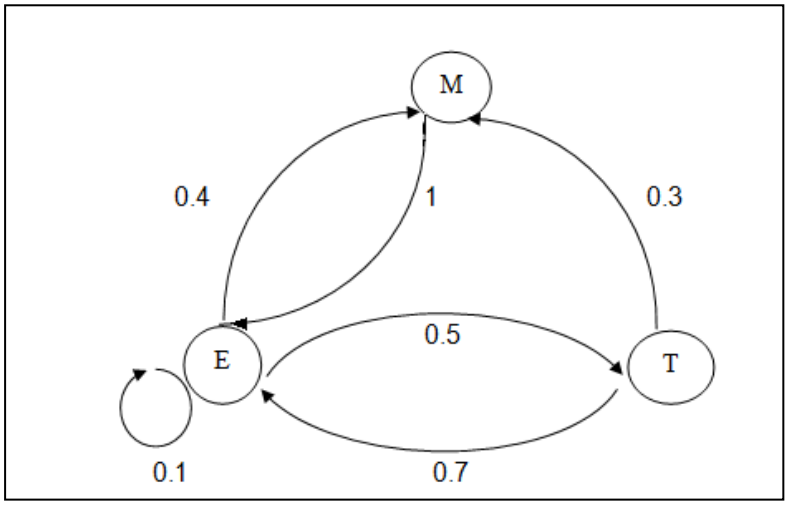
E – verificare instalaţie electrică

T – testare caracteristici frână

Ca urmare a acestei configuraţii de stări, variabila aleatoare X cu semnificaţie – unde este prezent autoturismul poate fi scrisă:

X = {M, E, T}

Din măsurătorile efectuate în atelier apar modalităţile în care autoturismul tranzitează între aceste stări – deci probabilităţile de tranziţie de forma



În cazul dat putem scrie:

$p_e(t+1) = 0.1\ p_e(t) + 0.7 p_t(t) + p_m(t)$

$p_t(t+1) = 0.5\ p_e(t)$

$p_m(t+1) = 0.3\ p_t(t) + 0.4\ p_e(t)$

prima ecuaţie din sistemul de mai sus defineşte şansa de a trece în starea *e* şi este dată de şansa de a fi în:

- E şi a rămâne în E cu probabilitatea de 0.1 SAU
- T şi a trece în E cu probabilitatea de 0.7 SAU
- M şi a trece în E cu probabilitatea de 01

matricial avem

$$[p_e(t+1)\,p_t(t+1)\,p_m(t+1)] = [p_e(t)\,p_t(t)\,p_m(t)] \cdot \begin{bmatrix} 0.1 & 0.5 & 0.4 \\ 0.7 & 0 & 0.3 \\ 1 & 0 & 0 \end{bmatrix}$$

5.3 Tipuri de lanţuri Markov. Reprezentare. Caracteristici

5.3.1. Tipuri de lanţuri Markov

Se definesc funcţie de forma pe care o prezintă matricea probabilităţilor de tranziţie. Astfel vom avea:

a) *Un lanţ Markov staţionar (omogen)* dacă matricea Q este aceeaşi pentru orice interval de timp. Se obţine deci pentru cazul în care $q_{ij}(t)$ sunt independente de t, caz în care (1) se va scrie

$$[p(t+1)] = [p(t)] \cdot [Q] \qquad (2)$$

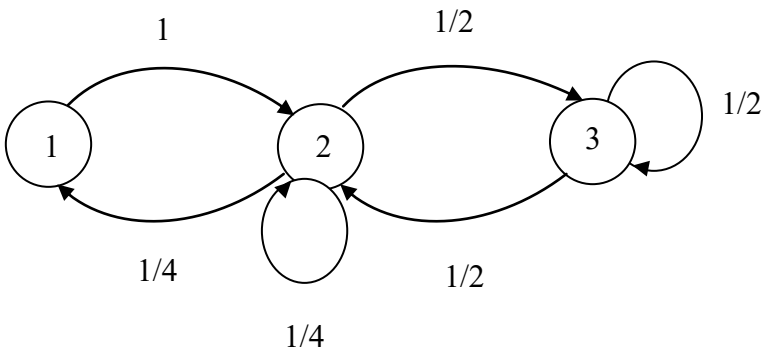
b) *Un lanţ Markov nestaţionar* apare dacă matricea Q diferă de la o etapă la alta. Se obţine deci în cazul în care q_{ij} este dependent de t, situaţie în care lanţul este definit de ecuaţia (1)

5.3.2. Modalităţi de reprezentare

(a) Considerăm un *lanţ Markov staţionar* cu 3 stări, având următoarea matrice a probabilităţilor de tranziţie:

$$[Q] = \begin{bmatrix} 0 & 1 & 0 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}$$

diagrama stărilor de tranziţie este în acest caz de forma:



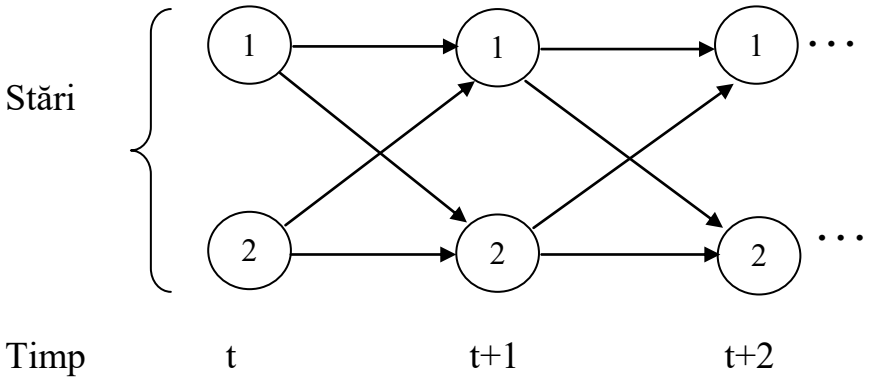
aplicând ecuaţia (2) obţinem

$[p_1(t+1), p_2(t+1), p_3(t+1)] = [p_1(t), p_2(t), p_3(t)] \cdot [Q]$

(b) Considerăm un *lanţ Markov nestaţionar*, cu două stări având următoarea matrice a probabilităţilor de tranziţie

$$[Q(t)] = \begin{bmatrix} q_{11}(t) & q_{12}(t) \\ q_{21}(t) & q_{22}(t) \end{bmatrix}$$

diagrama stărilor de tranziţie este de forma:



Aplicând ecuaţia (1) obţinem:

$$[p_1(t+1), p_2(t+1)] = [p_1(t), p_2(t)] \cdot [Q(t)]$$

c) În funcţie de structura matricei [Q] vom avea:

I. dacă sistemul nu mai revine niciodată în starea i, atunci *i este o stare cu revenire nulă.*

II. Un lanț Markov se spune *că este ireductibil* dacă este posibil să trecem dintr-o stare în orice altă stare a clasei.

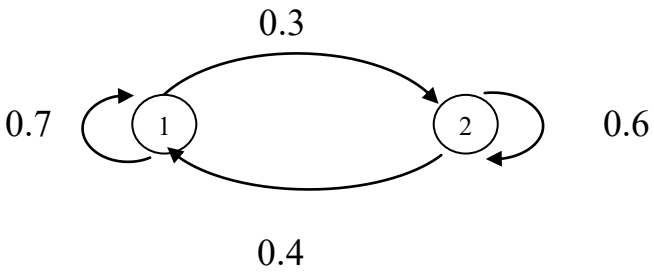
III. dacă sistemul revine în starea i după un număr oarecare de tranziţii, atunci *i este o stare cu revenire pozitivă.* Acestea conduc la:

- *stări periodice*, dacă se revine la starea în cauză după aceleaşi număr de tranziţii;
- *stări aperiodice*, dacă se revine la starea în cauză după un număr oarecare de tranziţii;
- *stări absorbante*, dacă ea nu va mai fi părăsită dacă procesul a intrat în ea.

Exemple

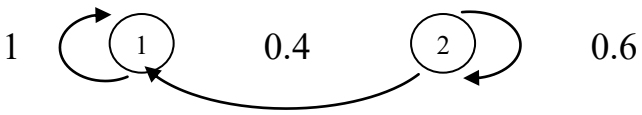
1) Lanţ Markov aperiodic

$$[Q]=\begin{bmatrix}0.7 & 0.3\\ 0.4 & 0.6\end{bmatrix}$$



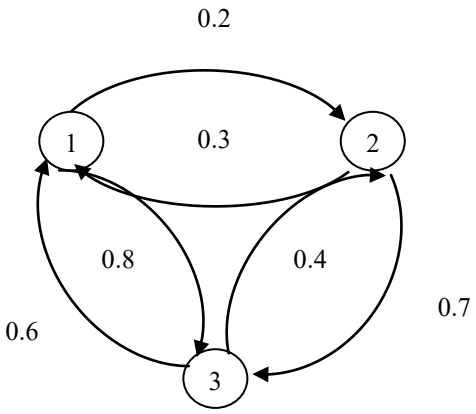
2) Lanţ Markov cu o stare absorbantă

$$[Q]=\begin{bmatrix}1 & 0\\ 0.4 & 0.6\end{bmatrix}$$



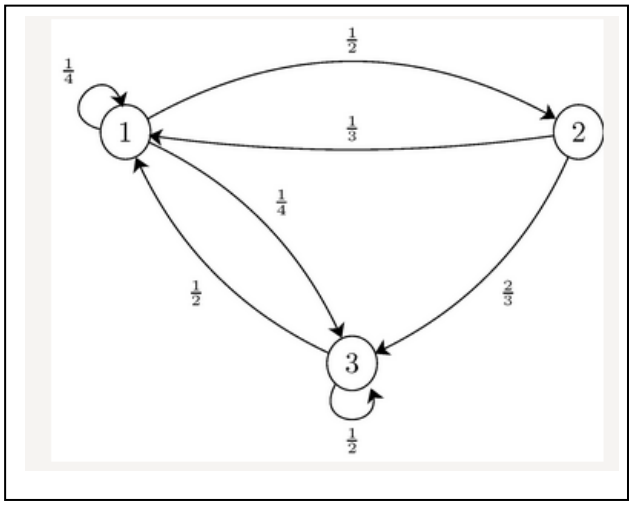
3) Lanţ Markov periodic

$$[Q]=\begin{bmatrix}0 & 0.2 & 0.8\\ 0.3 & 0 & 0.7\\ 0.6 & 0.4 & 0\end{bmatrix}$$



Exemplu

Considerăm lanțul Markov din figura următoare



$$P = \begin{bmatrix} \frac{1}{4} & \frac{1}{2} & \frac{1}{4} \\ \frac{1}{3} & 0 & \frac{2}{3} \\ \frac{1}{2} & 0 & \frac{1}{2} \end{bmatrix}.$$

Se cere:

a. $P(X_4 = 3|X_3 = 2)$.

b. $P(X_3 = 1|X_2 = 1)$.

c. Dacă se cunoaște că $P(X_0 = 1) = 1/3$, determinați $P(X_0 = 1, X_1 = 2)$.

d. Dacă se cunoaște că $P(X_0 = 1) = 1/3$, determinați $P(X_0 = 1, X_1 = 2, X_3 = 3)$.

Rezolvare

a. Prin definiție avem $P(X_4 = 3|X_3 = 2) = p_{23} = 2/3$

b. Prin definiție avem $P(X_3 = 1|X_2 = 1) = p_{11} = 1/4$

c. Se poate scrie că

$$P(X_0 = 1, X_1 = 2) = P(X_0 = 1) \cdot P(X_1 = 2|X_0 = 1)$$
$$= 1/3 \cdot p_{12}$$
$$= 1/3 \cdot 1/2 = 1/6.$$

d. Se poate scrie că

$P(X_0 = 1, X_1 = 2, X_3 = 3) =$

$= P(X_0 = 1) \cdot P(X_1 = 2|X_0 = 1) \cdot P(X_2 = 3|X_1 = 2, X_0 = 1)$

$= P(X_0 = 1) \cdot P(X_1 = 2|X_0 = 1) \cdot P(X_2 = 3|X_1 = 2)$

(datorită proprietății unui lanț Markov)

$= 1/3 \cdot p_{12} \cdot p_{23}$

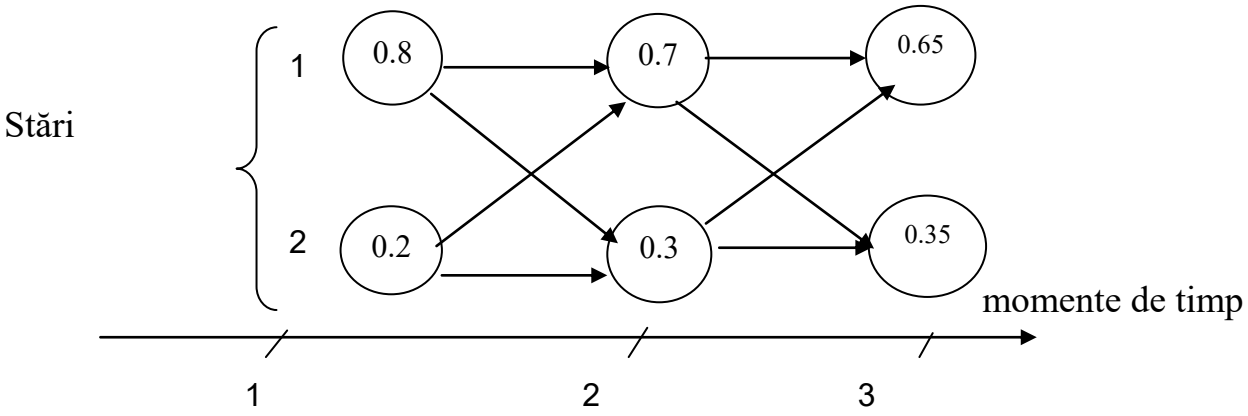
$= 1/3 \cdot 1/2 \cdot 2/3$

$=1/9$

5.3.2 Aproximarea matricei probabilităţilor de tranziţie

În practică nu se dispune decât cu totul întâmplător de valorile elementelor matricei probabilităţilor de tranziţie dintr-o stare în alta. În marea majoritate a cazurilor se dispune numai de valorile probabilităţilor de stare (şansa ca sistemul să fie prezent într-o stare la un moment dat) la diferite intervale de timp.

Procedura de construire se bazează pe explorarea unei secvenţe de ecuaţii. De exemplu, presupunem că pentru un sistem care poate fi prezent în două stări cunoaştem valorile matricei [p(t)] la momentele de timp t=1, 2 şi 3.



Utilizând $[p(t+1)] = [p(t)][Q]$

rezultă sistemul de ecuaţii:

$$\begin{cases} 0.7 = 0.8q_{11} + 0.2q_{21} \\ 0.3 = 0.8q_{12} + 0.2q_{22} \\ 0.65 = 0.7q_{11} + 0.3q_{21} \\ 0.35 = 0.7q_{12} + 0.3q_{21} \end{cases}$$ prin rezolvarea sistemului rezultă:

$$[Q] = \begin{bmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{bmatrix}$$

Prin generalizarea celor de mai sus se pot spune următoarele:

- dacă un sistem are *m* stări posibile, trebuie cunoscute matricele [p(t)] pentru *m+1* stări posibile, rezultând un sistem de *m* ecuaţii cu *m* necunoscute.

- în cazul în care se dispune de mai mult de *m+1* matrice [p(t)] fie de exemplu *m+n* procedura de lucru este următoarea

a) se scriu şi se rezolvă separat cele n-1 sisteme de ecuaţii liniare cu m necunoscute

b) pentru fiecare element al matricei [p(t)] se obţin câte n-1 valori şi se face media acestora.

c) cu ajutorul valorilor astfel obţinute se construieşte matricea provizorie $[Q]_p$.

d) se calculează pentru fiecare rând al matricei

$$\alpha_i = \sum_{j=1}^{m} q_{ij} \quad (i = 1, m)$$

e) dacă $\alpha_i = 1$ oricare i, înseamnă că s-a obţinut matricea definitivă [Q]. Dacă nu se calculează pentru fiecare rând

$$q_{ij} = \frac{q_{ij}^p}{\alpha_i} \quad i = \overline{1, m} \quad j = \overline{1, m}$$

obţinându-se matricea [Q] a probabilităţilor de tranziţie ce se va utiliza pentru simularea procesului în continuare.

5.4 Exemple de utilizare a matricei a probabilităţilor de tranziţie

Exemplul I

Un utilaj este caracterizat prin două stări:

- o stare în care nu sunt necesare intervenţii
- o stare în care sunt necesare intervenţii

În conformitate cu această caracterizare utilajul se găseşte în starea

$$[p(1)] = [1 \quad 0]$$

După un an de exploatare se constată că 10% din componente au nevoie de reparaţii

$$[p(2)] = [0.9 \quad 0.1]$$

După 2 ani de exploatare se constată că 18% din componente au nevoie de reparaţii

$$[p(3)] = [0.82 \quad 0.18]$$

Se cere. să se determine în ce an vor fi necesare intervenţii la 40% din componente

Etape de calcul

- se calculează matricea probabilităţilor de tranziţie

$$\begin{cases} 0.9 = q_{11} \cdot 1 + 0 \cdot q_{21} \\ 0.1 = q_{12} \cdot 1 + 0 \cdot q_{22} \\ 0.82 = 0.9 \cdot q_{11} + 0.1 \cdot q_{21} \\ 0.18 = 0.9 \cdot q_{21} + 0.1 \cdot q_{22} \end{cases} \Rightarrow [Q] = \begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}$$

- utilizând:

$$[p(t+1)] = [p(t)][Q]$$

se ajunge la momentul t = 4, 5, 6, 7, 8 să avem:

$$[p(t)] = [0{,}6048 \quad 0{,}3952]$$

Deci la trecerea a 8 ani 39,52% din componentele sistemului vor solicita intervenţii.

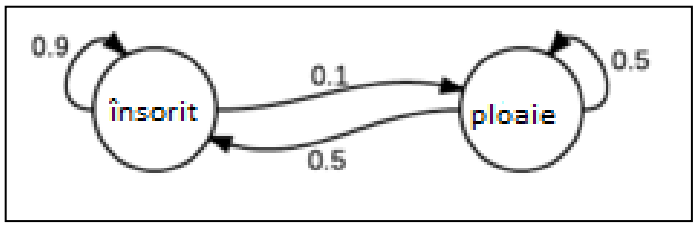
Exemplul II

Model predicție vreme

Ne propunem să construim un model de tip vreme. Luăm în considerare două stări "zi cu ploaie" respectiv "ziua este însorită". Probabilitățile asociate condițiilor de vreme dau vremea din precedenta zi și sunt reprezentate de următoarea matrice a probabilităților de tranziție.

$$P = \begin{matrix} \text{însorit} & \text{ploaie} \\ \begin{bmatrix} 0.9 & 0.1 \\ 0.5 & 0.5 \end{bmatrix} & \begin{matrix} \text{însorit} \\ \text{ploaie} \end{matrix} \end{matrix}$$

Matricea P definește modelul vreme în care o zi însorita are șansa de 90% de a fi urmată de o altă zi însorită, și o zi cu ploaie are șansa de 50% de a fi urmată de o altă zi cu ploaie. Graful corespunzător prezintă aspectul



$(P)_{ij}$ reprezintă probabilitatea ca fiind dată o zi de tip i să fie urmată de o zi de tip j.

Predicția vremii

Cunoaștem că vremea în ziua 0 este însorită. Condiția inițială va fi reprezentată de un vector în care poziția corespunzătoare zilei de tip însorit este 100% intrarea corespunzătoare zilei de tip în care plouă este 0%. Acesta apare de forma

$$\mathbf{x}^{(0)} = \begin{bmatrix} 1 & 0 \end{bmatrix}$$

Vremea după o zi poate fi prezisă ca fiind:

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} P = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} 0.9 & 0.1 \\ 0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} 0.9 & 0.1 \end{bmatrix}$$

Se observă că există o șansă de 90% ca ziua următoare să fie însorită.

Vremea celei de a doua zi poate fi prezisă de următoarea manieră:

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} P = \mathbf{x}^{(0)} P^2 = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} 0.9 & 0.1 \\ 0.5 & 0.5 \end{bmatrix}^2 = \begin{bmatrix} 0.86 & 0.14 \end{bmatrix}$$

sau

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} P = \begin{bmatrix} 0.9 & 0.1 \end{bmatrix} \begin{bmatrix} 0.9 & 0.1 \\ 0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} 0.86 & 0.14 \end{bmatrix}$$

Pentru a prezice vremea pentru ziua n putem proceda de următoarea manieră:

$$\mathbf{x}^{(n)} = \mathbf{x}^{(n-1)} P$$
$$\mathbf{x}^{(n)} = \mathbf{x}^{(0)} P^n$$

5.5. Distribuţia staţionară de probabilitate a unui lanţ Markov.

In practică, în majoritatea cazurilor probabilitatea ca sistemul să se afle într-o stare sau alta nu se modifică la momente de timp succesive. Cu alte cuvinte, comportarea sistemului este staţionară, cu excepţia momentelor de la începutul sau sfârşitul perioadei analizate (moment în care comportarea are un regim tranzitoriu). Eliminând perioadele tranzitorii caracteristice începutului, respectiv terminării funcţionalităţii sistemului, putem considera că probabilitatea ca sistemul să fie prezent într-o stare sau alta este independentă de timp. Matematic determinarea matricei probabilităţilor ca un sistem să fie prezent într-o stare poate fi formalizată astfel:

Considerăm un lanţ Markov aperiodic ireductibil. Ne propunem să studiem stabilitatea acestui proces. Studiul impune determinarea distribuţiei de probabilitate spre care converge sistemul după un număr mare de tranziţii.

Altfel spus urmărim să determinăm care este probabilitatea ca sistemul să se găsească (indiferent de starea iniţială) după un timp îndelungat într-o anumită stare.

Dacă notăm cu $[\pi]$ distribuţia căutată, atunci ea apare ca un rezultat al aplicării limitei :

$$\lim_{t\to\infty}[p(t)]=[\pi]$$

Definiție

Un sistem pentru care există limitele probabilităților stărilor pentru *t* tinzând către infinit se numește *sistem ergodic*, iar procesul stocastic respectiv se numește proces ergodic.

Aplicând această limită ecuaţiei $[p(t+1)]=[p(t)]\cdot[Q]$ obţinem:

$$[\pi]=[\pi]\cdot[Q] \qquad (3)$$

Distribuţia de probabilitate [π] care satisface ecuaţia (3) poartă numele de *distribuţie staţionară de probabilitate*. Este evident că în acest caz

$$\sum_{i=1}^{N} \pi_i = 1 \tag{4}$$

ecuaţie care reprezintă condiţia de normalizare.

Ecuaţia (4) se mai poate scrie sub forma:

$$[\pi][1]^T = 1 \tag{5}$$

unde $[1]^T$ este transpusa matricei linie N dimensională cu toate elementele egale cu unitatea.

Pentru a putea concatena

$$\begin{cases} [\pi] = [\pi][Q] \\ \sum_{i=1}^{N} \pi_i = 1 \end{cases}$$

înmulţim (5) cu [1] şi obţinem

$$[\pi][E] = [1] \tag{6}$$

în care [E] este o matrice *N x N* dimensională cu toate elementele egale cu unitatea.

Adunăm (3) cu (6) şi obţinem:

$$[\pi]([Q] + [E] - [I]) = [1]$$

în care [I] este o matrice *N x N* dimensională cu toate elementele de pe diagonala principală 1 restul fiind 0 (numită matricea unitate sau identică – ea este matricea care înmulţită cu orice altă matrice o lasă neschimbată).

Ca urmare vectorul distribuţiei staţionare este

$$[\pi] = [1]([Q] + [E] - [I])^{-1} \tag{7}$$

Exemple

A. Găsiţi distribuţia staţionară de probabilitate a următorului lanţ Markov

$$[Q]=\begin{bmatrix} 0 & 1 & 0 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}$$

Rezolvare

Se pleacă de la relaţia

$$[\pi]([Q]+[E]-[I])=[1]$$

a) $$[Q]+[E]-[I]=\begin{bmatrix} 0 & 1 & 0 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}+\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}-\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$[Q]+[E]-[I]=\begin{bmatrix} 0 & 2 & 1 \\ \frac{5}{4} & \frac{1}{4} & \frac{3}{2} \\ 1 & \frac{3}{2} & \frac{1}{2} \end{bmatrix}$$

$$[\pi_1 \quad \pi_2 \quad \pi_3]\begin{bmatrix} 0 & 2 & 1 \\ \frac{5}{4} & \frac{1}{4} & \frac{3}{2} \\ 1 & \frac{3}{2} & \frac{1}{2} \end{bmatrix}=[1\ 1\ 1]$$

De unde apare sistemul de ecuaţii:

$$\begin{cases} \frac{5}{4}\pi_2+\pi_3=1 \\ 2\pi_1+\frac{\pi_2}{4}+\frac{3}{2}\pi_3=1 \\ \pi_1+\frac{3}{2}\pi_2+\frac{1}{2}\pi_3=1 \end{cases} \quad \text{rezultă} \quad \pi_1=\frac{1}{9} \quad \pi 2=\frac{4}{9} \quad \pi 3=\frac{4}{9}$$

B. Considerăm un lanț Markov cu trei stări, S={1, 2, 3}, care are următoarea matrice a probabilităților de tranziție

$$P = \begin{bmatrix} \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{3} & 0 & \frac{2}{3} \\ \frac{1}{2} & \frac{1}{2} & 0 \end{bmatrix}.$$

Se cere:

a) Desenați diagrama stărilor de tranziție pentru acest lanț.

b) Dacă cunoaștem că $P(X_1 = 1) = P(X_1 = 2) = 1/4$, determinați $P(X_1 = 3, X_2 = 2, X_3 = 1)$

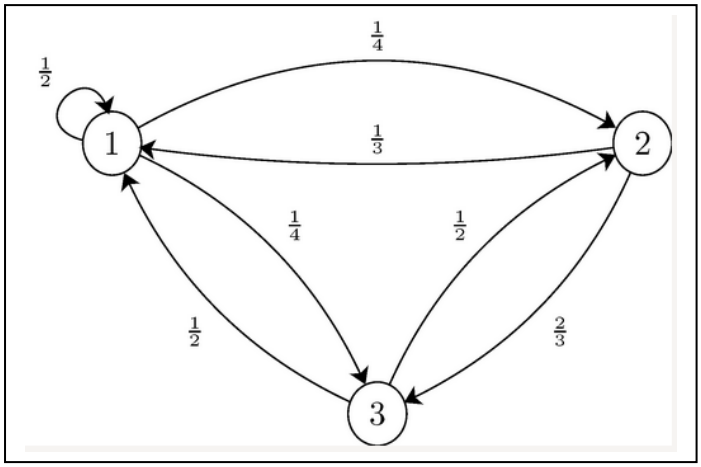
c) Acest lanț Markov este ireductibil?

d) Este aperiodic?

e) Găsiți distribuția de probabilitate pentru acest lanț Markov

Soluție

a. Diagrama stărilor de tranziție este



b. Inițial avem

$$P(X_1 = 3) = 1 - P(X_1 = 1) - P(X_1 = 2) = 1 - 1/4 - 1/4 = 1/2$$

Se poate scrie că

$$P(X_1 = 3, X_2 = 2, X_3 = 1) = P(X_1 = 3) \cdot p_{32} \cdot p_{21}$$
$$= 1/2 \cdot 1/2 \cdot 1/3$$
$$= 1/12$$

c. Lanțul este ireductibil deoarece se poate face trecerea dintr-o stare în altă stare într-un număr finit de pași.

d. Lanțul este aperiodic deoarece există cel puțin o tranziție de la o stare la aceiași stare. De exemplu avem $p_{11} > 0$.

e. Pentru a găsi distribuția staționară de probabilitate este necesar să rezolvăm sistemul

$$\pi_1 = 1/2 \cdot \pi_1 + 1/3 \cdot \pi_2 + 1/2 \cdot \pi_3,$$

$$\pi_2 = 1/4 \cdot \pi_1 + 1/2 \cdot \pi_3,$$

$$\pi_3 = 1/4 \cdot \pi_1 + 2/3 \cdot \pi_2,$$

$$\pi_1 + \pi_2 + \pi_3 = 1.$$

Se obține

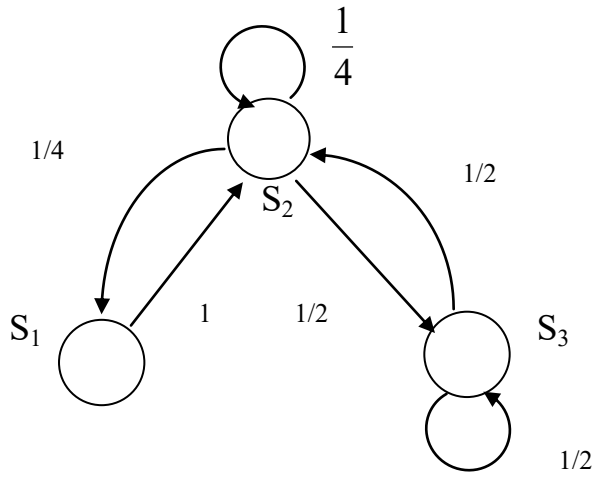
$$\pi_1 \cong 0.475,\ \pi_2 \cong 0.257,\ \pi_3 \cong 0.286$$

5.6. Indici de performanţă

Discuţia se va face în contextul exemplului **A** anterior unde

$$[\pi] = \begin{bmatrix} \frac{1}{9} & \frac{4}{9} & \frac{4}{9} \end{bmatrix} \quad [Q] = \begin{bmatrix} 0 & 1 & 0 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}$$

În acest caz diagrama de tranziţii este de forma



Timpul de tranziţie dîntr-o stare în alta este de 50 u.t. (unităţi de timp) – mărime măsurabilă pe sistemul real. Am determinat anterior următoarele valori pentru şansa ca sistemul să fie prezent în una din stările S_1, S_2 şi S_3 . Aceste sunt pentru :

$$S_1 \text{ este } p_1 = \frac{1}{9};\ S_2 \text{ este } p_2 = \frac{4}{9};\ S_3 \text{ este } p_3 = \frac{4}{9}$$

1) *p_i poate fi interpretată* ca fiind:

- *procentul* din timpul în care sistemul se găseşte în starea S_i. Dacă sistemul se analizează pentru 1000 u.t. de exemplu sistemul se găseşte în S_1 este de 1000 x $\frac{1}{9}$ u.t.

- *gradul de utilizare* a echipamentului corespunzător stării care îl modelează. De exemplu dacă S_2 reprezintă starea procesor ocupat $\rho_2 = \frac{4}{9}$

2) *Valoarea medie a timpului petrecut în starea Si* se notează cu t_i şi se calculează astfel:

- La fiecare moment discret de timp (în cazul nostru acestea sunt cuante de 50 u.t.) sistemul are probabilitatea p_i de a rămâne în starea *i* şi ca urmare distribuţia de probabilitate a intervalelor de timp petrecute în starea S_i este:

Dacă sistemul stă în starea i o unitate de timp

$P(t_i=1) = (1-p_i)$ interpretată ca fiind *sistemul NU pleacă din starea i*

Dacă sistemul stă în starea i 2 unităţi de timp

$P(t_i=2) = p_i\,(1-p_i)$

-
-

Dacă sistemul este în starea *i* n unităţi de timp

$P(t_i=n) = p_i^{n-1}(1-p_i)$

Ca urmare valoarea medie

$$\overline{t_i} = \sum_{n=1}^{\infty} n.P(t_i = n)$$

$$\overline{t_i} = \sum_{n=1}^{\infty} n(1-p_i)p_i^{n-1} = (1-p_i)\left[1 + 2p_i + 3p_i^2 + \ldots\right]$$

$$\overline{t_i} = \frac{1-p_i}{(1-p_i)^2} \quad \Rightarrow \overline{t_i} = \frac{1}{1-p_i}$$

Pentru exemplul dat timpul petrecut în starea 3 în cadrul unui interval de 50 u.t. este

$$\overline{t_3} = \frac{50}{1-\frac{4}{9}} = \frac{450}{5} = 90 \text{ u.t.}$$

3) *Valoarea medie a timpului de revenire în starea i* se notează cu $\overline{t_{ri}}$ şi se calculează astfel

$$p_i = \frac{\text{timpul mediu petrecut in Si}}{\text{timpul mediu petrecut în Si} + \text{timp revenire in Si}}$$

(din definiţia probabilităţii)

$$p_i = \frac{\frac{1}{1-p_i}}{\frac{1}{1-p_i} + \bar{t}_{ri}} \; ; \; p_i\left(\bar{t}_{ri} + \frac{1}{1-p_i}\right) = \frac{1}{1-p_i}$$

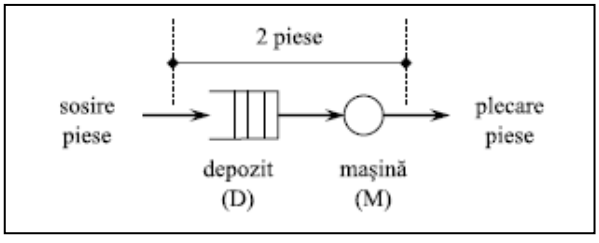
$$p_i \bar{t}_{ri} = \frac{1}{1-p_i} - \frac{p_i}{1-p_i} \Rightarrow \bar{t}_{ri} = \frac{1}{p_i}$$

Pentru exemplul dat $\bar{t}_{r3} = \frac{50\text{u.t.}}{\frac{4}{9}} = \frac{450}{4} = 112 \text{ u.t}$

deci sistemul revine în starea 3 în medie după 112 u.t.

Exemplu

Fie un sistem de fabricaţie compus dîntr-o maşină M şi un depozit D ca în figura de mai jos, capacitatea sistemului (maşină - depozit) fiind limitată la două piese:



Dacă există loc liber în depozit, piesele intră în depozitul D după o distribuţie exponenţială cu frecvența λ . Ori de câte ori maşina M este liberă şi exista o piesă în depozit, aceasta este preluată imediat pe maşină. Maşina M prelucrează piesele după o distribuţie exponenţială cu frecvența μ.

Se cere:

1. Să se construiască lanţul Markov asociat modelului.
2. Considerând $\lambda = 2$ [s^{-1}] şi $\mu = 1$ [s^{-1}], să se determine analitic (în ipoteza că sistemul funcţionează în regim permanent):
   i. probabilitatea cu care sistemul se poate afla în fiecare din stările accesibile;
   ii. gradul de utilizare a maşinii;
   iii. frecvenţa reală de sosire a pieselor în depozit şi frecvenţa reală de prelucrare a pieselor pe maşina M;
   iv. numărul mediu de piese ce se pot afla în depozitul D sau se prelucrează de către maşina M;
   v. timpul mediu petrecu de o piesă în sistem.

Rezolvare

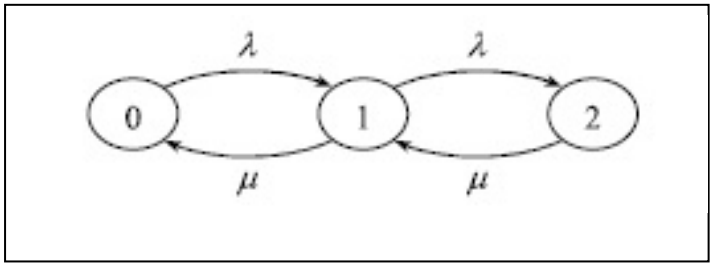
i. Concret, sistemul de fabricaţie se poate afla în una dintre următoarele trei stări:

„0" — nici o piesă în sistem,

„1" — o singură piesă în sistem (in curs de prelucrare) şi

„2" — două piese în sistem (una în curs de prelucrare şi una în depozit).

Tranziţiile din „0" în „1" şi din „1" în „2" au loc cu frecvența λ (frecvența de sosire a clienţilor în sistem), iar tranziţiile din „2" în „1" şi din „1" în „0" au loc cu frecvența μ (frecvența de servire). Lanţul Markov corespunzător este prezentat în figura următoare:



Matricea frecvența de tranziție corespunzătoare lanțului Markov este

$$Q = \begin{bmatrix} -\lambda & \lambda & 0 \\ \mu & -(\lambda+\mu) & \lambda \\ 0 & \mu & -\mu \end{bmatrix}.$$

Vectorul distribuției staționare de probabilitate, $\pi = [\pi_0, \pi_1, \pi_2]$, se determină din condițiile

$$[\pi]([Q]+[E]-[I])=[1]$$

$\pi_0 + \pi_1 + \pi_2 = 1,$

Pentru valorile numerice precizate în enunţ rezultă $\pi_0 = 4/7$, $\pi_1 = 2/7$ şi $\pi_2 = 1/7$ •

ii. Deoarece maşina este utilizată atunci când există cel puţin o piesă (un client) în sistem, gradul de utilizarea maşinii este $\pi_1 + \pi_2 = 1 — \pi_0 = 3/7$.

iii. În sistem pot sosi piese numai atunci când sistemul se află într-o stare diferită de „2". astfel că frecvenţa reală de sosire a pieselor în depozit (frecvența efectivă de sosire a clienţilor) este dată de

$$\lambda(1-\pi_2) = 6/7\ [s^{-1}].$$

Frecvenţa reală de prelucrare a pieselor pe maşina M (frecvența de plecare a clienţilor), fiind dată de $\mu(1-\pi_0) = 6/7\ [s^{-1}]$, este egală cu frecvenţa reală de sosire a pieselor.

iv. Numărul mediu de piese aflate în sistem (în depozitul D sau în curs de prelucrare de către mașina M), notat M[X], se poate calcula, de asemenea pe baza probabilităților staționare de stare, sub forma $M[X] = \pi_1 + 2\pi_2 = 4/7$.

v. Timpul mediu petrecut de o piesă în sistem, notat M[S], reprezintă raportul dintre numărul mediu de piese din sistem și frecvența reală de sosire a pieselor în sistem

$$M[S] = \frac{M[X]}{\lambda(1-\pi_2)} = \frac{2}{3}$$

6. Modele matematice.
Modelarea și simularea dinamicii sistemelor.

6.1 Model matematic

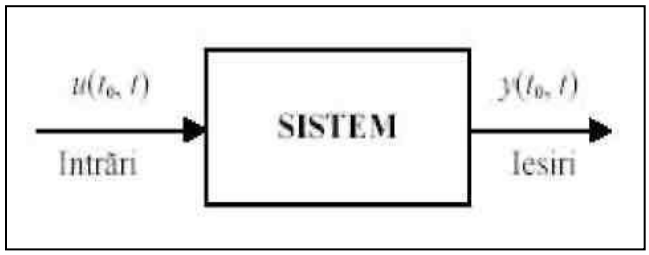
Un **model matematic** este un sistem de relații matematice / ecuații diferențiale, care descrie comportamentul (relațiile care sunt prezente între componentele unui sistem real) într-o măsură rezonabilă.

Într-un model matematic se disting:

- *variabile independente* care sunt puse în corespondentă cu intrările sistemului real, în general manipulabile. Alte variabile sunt dependente de primele și sunt puse în legătură cu ieșirile sistemului modelat.
- Modelele matematice mai cuprind și un număr de parametri. *Parametrii* fac particular un model, îl pun în acord cu realitatea unui sistem fizic. Variabilele și parametrii unui model pot fi uneori în relație directă cu cantități fizice si/sau fizico-chimice din sistemul real.

Prin **simulare** se înțelege operația de rezolvare în condiții precizate a sistemului de relații / ecuații care constituie modelul matematic al dinamicii unui sistem real sau pe cale de a deveni real. Simularea se conduce cu referire la și prin comparare permanentă cu sistemul simulat, real sau virtual, sau cu sisteme similare. Prin urmare, este necesară o acțiune constantă de interpretare a produsului calculelor de simulare din partea celui care elaborează sau utilizează modelul cu care se face simularea.

În figura alăturată este reprezentat un sistem abstract care are particularitatea că nu este afectat de perturbații, sau perturbațiile pot fi ignorate.



Se disting:

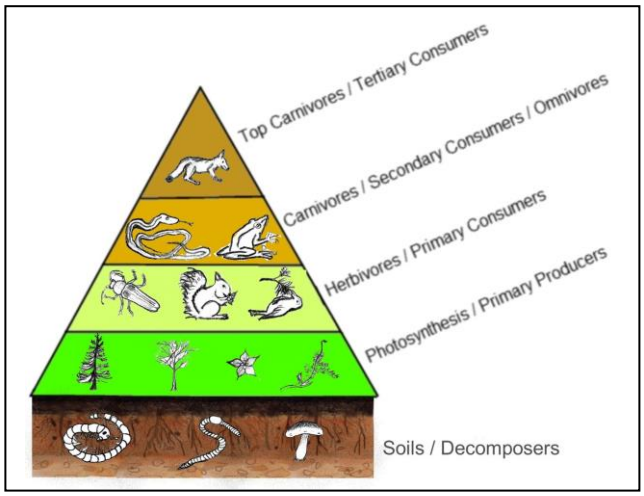
- vectorul intrărilor $u(t_0, t)$ si
- vectorul ieșirilor $y(t_0, t)$.
- momentul t_0 poate fi convențional o origine a timpului, momentul de început al aplicării intrărilor care sunt funcții de timp mai simple sau mai complicate. Ulterior momentului inițial t_0 se observă ieșirile. Acestea depind desigur de intrările aplicate dar și de starea sistemului la momentul inițial t_0.
- ieșirile sistemului, numite și răspunsul lui la intrări pot fi diferite dacă intrările aplicate sunt repetat aceleași dar starea sistemului este diferită de la caz la caz în momentul de început al aplicării acelor intrări. Se poate spune că, de fapt, intrările acționează asupra stării sistemului, iar ieșirile observate sunt produse de modificările în starea sistemului.

Starea sistemului este descrisă uzual de un număr de variabile de stare, finit sau infinit. Variabilele de stare sunt funcții de timp și conțin informația minimală necesară la un moment ***t,*** altfel oarecare, pentru a determina comportarea sistemului în momentele următoare, cu sau fără intrări. Informația privind starea unui sistem este grupată de obicei într-un vector ***x(t),*** așa-numitul vector de stare. Vectorul ***x(t)*** nu este unic. Orice transformare liniară nedegenerată a spațiului componentelor acestui vector produce un vector de stare care conține nealterată informația necesară definirii stării sistemului.

Cu unele modificări în notații, dacă starea sistemului în momentul inițial t_0 este descrisă de vectorul $x(t_0)$ și dacă se aplică sistemului intrările $u(t_0,t)$ evoluția sistemului după t_0 este observată prin intermediul ieșirilor $y(t_0,t)$. Relațiile care cuprind dependenta răspunsului unui sistem de starea lui curentă și de intrările aplicate și care dau șansa calculului explicit al răspunsului se constituie în modelul matematic al acelui sistem.

8.2 Modelul Lotka-Volterra

Acest model a fost propus independent de Alfred Lotka in 1925 și Vito Volterra în 1926 având scopul de a descrie dinamica populațiilor prezente în natură și modul în care acestea interacționează atât între ele cât și mediul în care sunt prezente. Modelul s-a orientat pe descrierea relației care apare între o populație pradă care interacționează într-un areal dat cu o populație de tip prădător. Astfel de relații se întâlnesc în natură la toate nivelele unui Eco sistem.



Studiul unor astfel de interacțiuni s-a extins și în acest moment modele de tip pradă prădător sunt utilizate in toate domeniile socio economice ca de exemplu

- Modele care descriu relația dinamică dintre salariile reale și ocuparea forței de muncă
- Managementul riscului investițiilor
- Analiza fluctuațiilor și ciclurilor economice (modele - Goodwin)
- Impactul investițiilor în cercetare și dezvoltare (C & D) și produsul intern brut (PIB)
- studiul relației dintre consumul de energie și PIB.

8.2.1 Modelul pradă-prădător de bază

În studiul dinamicii unei singure populații se iau în considerare factori de tip „*creștere naturală*” și capacitatea de “*sustenabilitat*e” a mediului în care este prezentă populația respectivă. Sustenabilitatea se referă în acest caz la factorii (cantitate de hrană, modul în care se interacționează cu mediul în care este prezentă populația). Un caz special al dinamicii unei populații se referă la modul în care exact două specii , una dintre ele de tip prădător iar cea de a doua de tip pradă interacționează. Astfel de cazuri sunt numeroase în natură, de exemplu

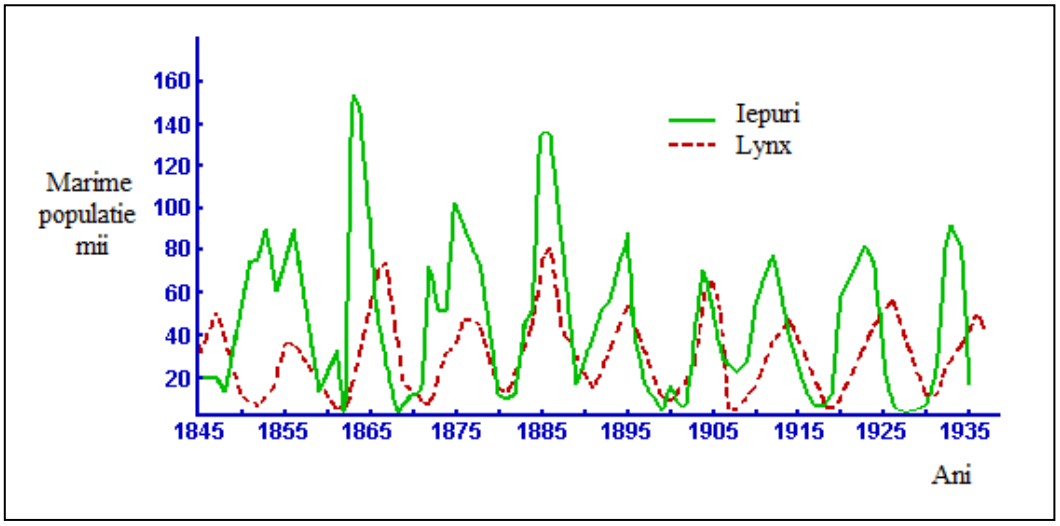
- Păsări și insecte,
- Lei și gazele,
- Panda și arbori eucalipți
- Lilieci și insecte.

Pentru a putea construi un model matematic simplu al unei astfel de relații de tip pradă / prădător vom face o serie de presupuneri care sunt nerealiste în majoritatea cazurilor în natură. Mai concret aceste presupuneri se referă la

- Specia prădător este total dependentă de o singură specie pradă, aceasta reprezentând singura sursă de hrană
- Specia pradă dispune de cantități nelimitate de hrană
- Specia pradă nu este amenințată de alte specii prădător

Deși o astfel de interacțiune poate fi considerată restrictivă ea se întâlnește în natură, exemplul clasic fiind cel al interacțiunii dintre râsul canadian și iepurele de zăpadă. Înregistrările au fost realizate pe un interval de 100 de ani de Hudson Bay Company, fiind prezentate în graficul de mai jos. Caracteristica dominantă prezentă în grafic este dată de oscilațiile în mărimea celor două populații cât și

modul în care acestea se corelează între ele.



Ecuațiile Lotka-Volterra, de asemenea cunoscute ca ecuații prădător-pradă, reprezintă o pereche de ecuații diferențiale neliniare utilizate pentru descrierea dinamicii sistemelor biologice în care are loc interacțiunea a două specii de tip prădător respective pradă.. Schimbările care au loc în timp în această populație sunt descrise de ecuațiile

$$\frac{dx}{dt} = \alpha x - \beta xy$$
$$\frac{dy}{dt} = \delta xy - \gamma y$$
$$\alpha,\ \beta,\ \gamma,\ \delta$$

Unde

- x este numărul de animale pradă (de exemplu iepuri)
- y este numărul de animale prădător (de exemplu vulpi)
- $\frac{dx}{dt}$ si $\frac{dy}{dt}$ reprezintă ratele (frecvențele) de creștere a celor două populații

- $\alpha, \beta, \gamma, \delta$ sunt parametrii reali care descriu interacțiunea dintre cele două specii, unde
    - α (frecvența de creștere populației de tip pradă),
    - β (frecvența cu care prădătorii distrug prada),
    - γ (frecvența de deces a prădătorilor) și
    - δ (frecvența cu care prădătorii cresc consumând prada),

În concluzie

- Variabila *x (t)* reprezintă o populație de pradă la momentul *t* care crește exponențial în absența prădătorilor [corespunzător termenului $\alpha\, x\,(t)$.
- Variabila *y (t)* reprezintă o populație prădătoare la momentul *t*, cu prada ca sursă exclusivă de hrană.

Modelul Lotka-Volterra funcționează în contextul unui set de presupuneri , nu neapărat prezente în natură, relative la mediul înconjurător și la modul de evoluție a populațiilor pradă prădător

1. Populația pradă găsește hrană tot timpul în cantități suficiente
2. Necesarul de hrană a populației prădător depinde în totalitate de mărimea populației pradă
3. Frecvența de modificare a populației este proporțională cu mărimea sa
4. În timpul procesului de interacțiune mediul înconjurător nu se schimbă în favoarea unei specii iar adaptarea genetică este nulă
5. Prădătorii au un apetit limitat
6. Presupunem un teritoriu restrâns ca biotop, ceea ce limitează în mod evident populația de tip pradă

Pradă

Ecuația pentru specia pradă este de forma

$$\frac{dx}{dt} = \alpha x - \beta xy$$

Se presupune că

Prada are hrană nelimitată și se reproduce exponențial, reproducerea exponențială este reprezentată în ecuație de termenul αx. În absența prădătorilor populația ***x*** va crește exponențial cu mărimea sa, creștere care este dată de

$$\frac{dx}{dt} = \alpha x$$

Coeficientul α **a fost numit de Volterra coeficient de auto creștere**. În această formă **relația definește legea de creștere a lui Malthus a populației**, soluția ecuației fiind

$$x(t) = x_0 e^{\alpha t}$$

Frecvența cu care această populație este diminuată de către prădători este proporțională cu frecvența cu care aceste două specii se întâlnesc, fiind reprezentată de βxy. Dacă ***x*** sau ***y*** sunt 0 nu există nici o diminuare a populației pradă de către prădător.

Deci ecuația exprimă modul de modificare a populației pradă care este dată de propria creștere minus cantitatea cu care este diminuată de specia prădător.

Prădător

Ecuația pentru specia prădător este dată de

$$\frac{dy}{dt} = \delta xy - \gamma y$$

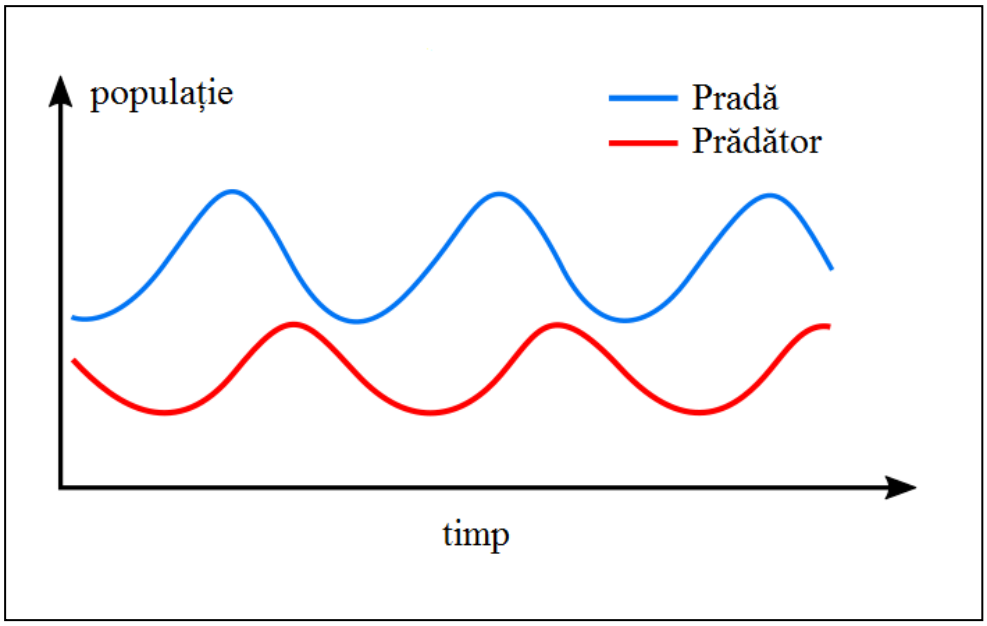
În ecuație δxy reprezintă modul în care crește populația prădător. Constanta δ este

utilizată pentru definirea frecvenței cu care această populație consumă elemente din specia pradă. În absența prăzii, populația ***y*** se va diminua progresiv cu mărimea sa până la extincție, diminuarea este dată în acest caz de

$$\frac{dy}{dt} = -\gamma y,\ y > 0$$

În ecuație γy reprezintă frecvența cu care se diminuează (scade) populația prădător datorită deceselor sau migrației.

Deci ecuația exprimă modul de variație (vezi figura de următoare) a mărimii populației de prădător funcție numai de frecvența cu care consumă elemente din populația pradă, minus frecvența intrinsecă de deces.



Dinamica sistemului

În sistemul modelat , prădătorii prosperă atâta timp cât au hrană în cantități mari și vor intra în declin atunci când aceasta se diminuează cantitativ. Populația prădător va crește din nou atunci când populația pradă va crește din nou. Aceasta dinamică

continuă în contextul unor cicluri succesive de creștere și declin.

- **Echilibrul populației**

  Apare atunci când din punct de vedere cantitativ populația nu se schimbă. Din punct de vedere matematic echilibrul apare atunci când ambele derivate sunt egale cu 0

$$x(\alpha - \beta y) = 0$$
$$-y(\gamma - \delta x) = 0$$

  Rezolvând sistemul se obțin două soluții

$$\{y = 0, x = 0\} \text{ si } \left\{y = \frac{\alpha}{\beta}, x = \frac{\gamma}{\delta}\right\}$$

  Deci avem un număr de două puncte de echilibru

  - Prima corespunde cazului extincției celor două specii. Dacă ambele specii sunt 0 , vor fi astfel un timp infinit.
  - Cea de a doua soluție reprezintă puncte fixe în care cele două populații se pot susține reciproc (co-existență) de asemenea un timp nedefinit. Nivelul populației în care acest echilibru este atins depinde de valorile parametrilor α, β, γ si δ

- **Soluție**

  Ecuația prezintă o soluție definită printr-o funcție periodică care poate fi vizualizată dar care nu are o însă o reprezentare analitică. Prima ecuație este omogenă în ***x*** iar cea de a doua în ***y***. Ca urmare parametrii $\frac{\beta}{\alpha}$ si $\frac{\delta}{\gamma}$ nu intervin în dinamica variației speciilor pradă / prădător , singurul termen rămas fiind $\frac{\alpha}{\gamma}$. Numai acesta va modifica natura soluției

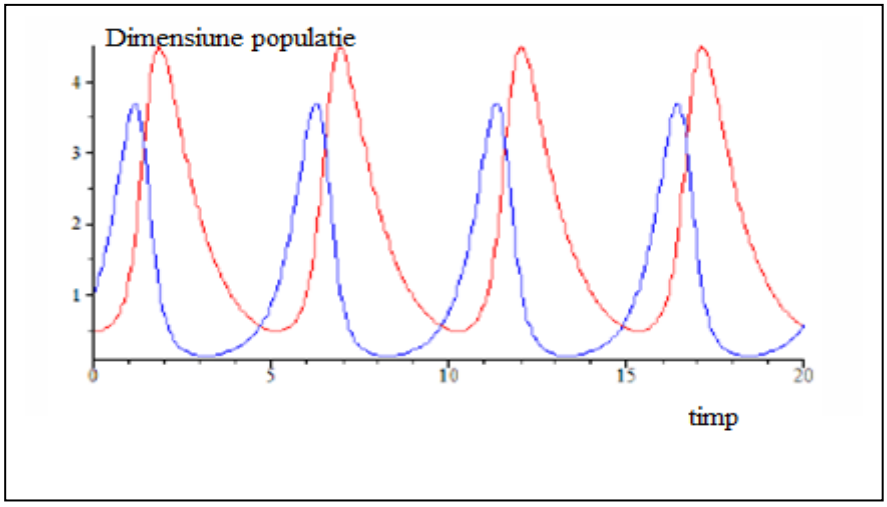
Exemple

1. Pentru $\alpha = 0.2, \beta = 1.1, \gamma = 1$ si $\delta = 0.9$ se va obține următorul model

$$\frac{dx}{dt} = 2x - 1.1xy$$
$$\frac{dy}{dt} = 0.9xy - y$$

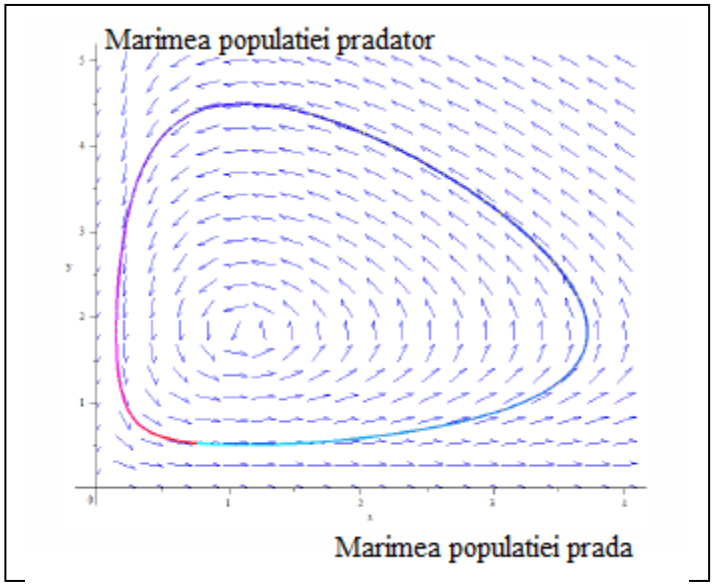
și dacă alegem că inițial populația prădător este jumătate din mărimea populației pradă , ceea ce se traduce prin condițiile inițiale *x(0) = 1* și *y(0) = 0.5* vom avea

- Evoluția dinamicii celor două populații se poate vizualiza în graficul următor în care populația pradă este trasată în albastru iar cea prădător în culoare roșie.



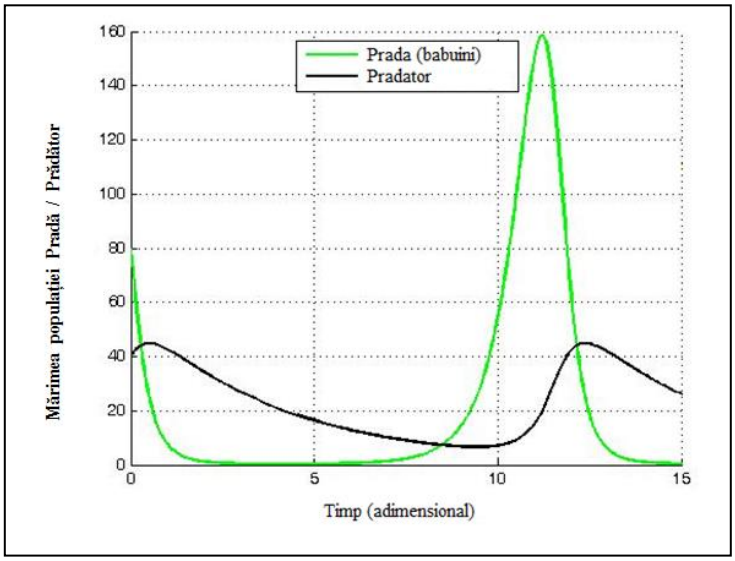
- Punctul de echilibru apare la P(10/9, 20/11)
- O altă modalitate de reprezentare a dinamicii celor două populații este dată de o *reprezentare parametrică* cunoscută sub denumirea de spațiul fazelor în

care timpul nu mai apare, dar în care pe axe se reprezintă mărimea populației pradă respectiv prădător în fiecare moment de timp

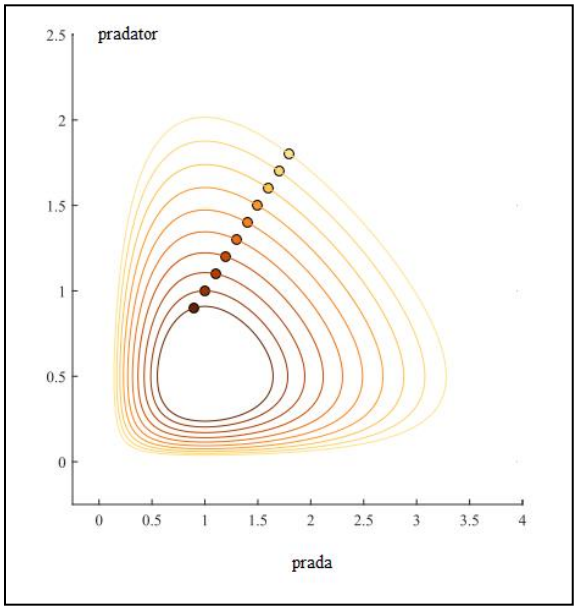


2. Presupunem că avem două specii de animale, babuini (pradă) și gheparzi (prădător) unde $\alpha = 2/3, \beta = 4/3, \gamma = 1$ si $\delta = 1$. Dacă inițial avem 40 de gheparzi și 80 de babuini (x(0) = 80 și y(0) = 40) este posibilă reprezentarea interacțiunii dintre aceste două specii de forma

- Evoluția dinamicii celor două populații se poate vizualiza în graficul următor



– Un alt mod de reprezentare este cel parametric , fără reprezentarea timpului (spațiul fazelor) în care pe axe se reprezintă mărimea populațiilor de tip pradă respectiv prădător. Presupunem că ***x, y*** cuantifică dimensiune populației în mii. Cercurile reprezintă condițiile inițiale care pleacă de la ***x = y = 0.9*** la ***1.8*** cu un pas de 0.1



6.2.2 Modelul pradă-prădător extins

Modelul Lotka-Volterra este nerealistic deoarece ia în considerare numai interacțiunea dintre două populații în care mărimea acestora dictează dinamica acestora. De exemplu atunci când populația pradă crește, este încurajată creșterea populației prădător, iar când aceasta scade, asistăm la un declin a populației prădător. Depinzând de natura sistemului modelat astfel de situații conduc la cicluri haotice care se desfășoară într-o plajă de valori aproximativ constantă fără să existe perspectiva atingerii unei stări de echilibru între cele două populații.

Aceste aspecte au condus la definirea unui model pradă / prădător în care sunt prinse condiții externe ca de exemplu competiția în interiorul populației între indivizi de aceeași natură, influența factorului uman respectiv influența mediului exterior.

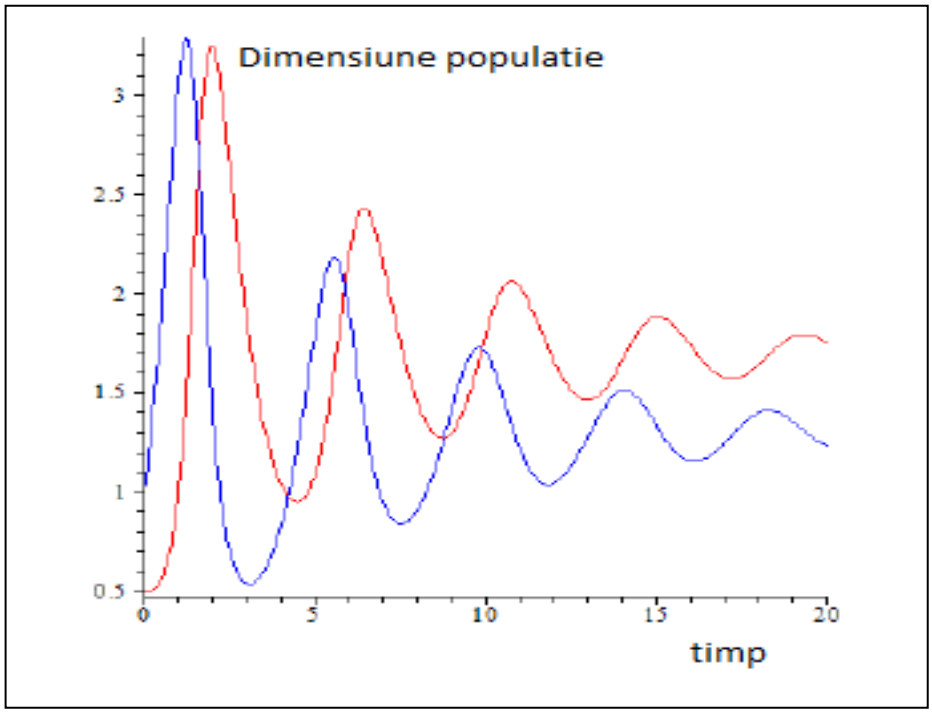
Toate aceste condiții externe pot favoriza sau nu dinamica unei populații în sens pozitiv sau negativ. Modelul în aceste circumstanțe prezintă aspectul

$$\frac{dx}{dt} = \alpha x - \lambda x^2 - \beta xy$$
$$\frac{dy}{dt} = \delta xy - ky^2 - \gamma y$$
$$\alpha,\ \beta,\ \gamma,\ \delta,\ \lambda,\ k$$

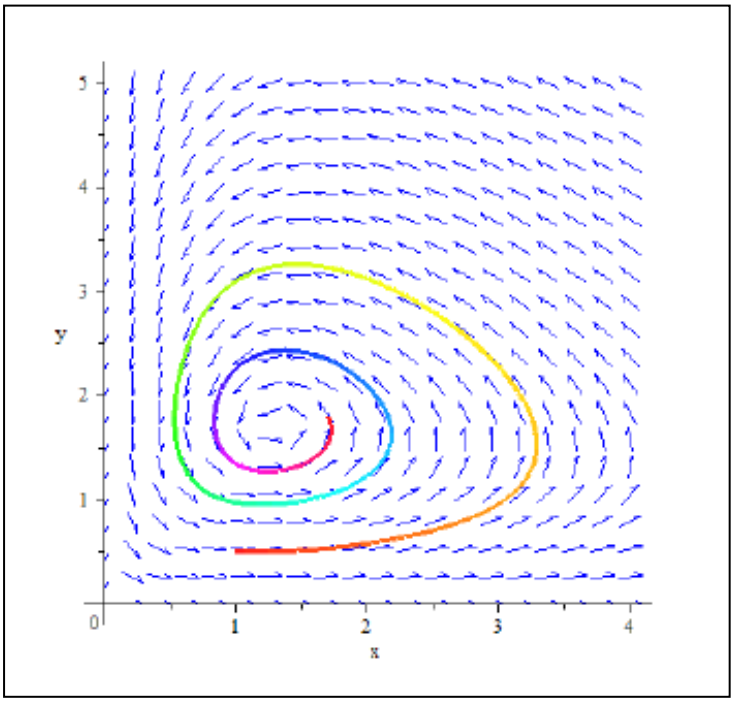
În contextul modelului λ, k contorizează mediul care afectează dinamica populației. Luând în considerare modelul **(1)** pentru aceleași condiții inițiale ***x(0) = 1*** și ***y(0) = 0.5*** în care influența mediului este definită de $\lambda = 0.1$ si $k = 0.1$ vom obține

$$\frac{dx}{dt} = 2x - 0.1x^2 - 1.1xy$$
$$\frac{dy}{dt} = 0.9xy - 0.1y^2 - y$$

În acest caz variația prăzii și a prădătorului nu mai este periodică după cum se poate vedea din figura de mai jos



Punctul de echilibru (1.3, 1.7) apare atunci când timpul crește ca în figura următoare în care se poate vizualiza traiectoria dimensiunii populației pentru ***x*** respectiv ***y***.



6.3 Metode numerice de rezolvare a ecuațiilor diferențiale

Pentru o ecuație diferențială de tipul

$$y' = f(x,y), \qquad y(x_0)=y_0 \tag{8.1}$$

există două tipuri distincte de metode numerice cu ajutorul cărora obținem aproximația numerică a soluției ecuației precedente. Pentru o discretizare a lui *x de* tipul:

$$x_0,$$
$$x_1 = x_0 + h,$$
$$x_2 = x_1 + h = x_0 + 2h,$$
$$x_3 = x_2 + h = x_1 + 2h = x_0 + 3h,$$

etc.,

ambele tipuri de metode numerice determină valorile lui ***y*** pentru precedentele valori ale lui ***x***, anume:

$$y\,(x_1) = y_1,$$
$$y\,(x_2) = y_2,$$
$$y\,(x_3) = y_3,$$
etc.,

însă *diferă calitativ prin tipul polinomului care interpolează funcția y.* Astfel, cunoscută fiind valoarea funcției ***y*** de la punctul inițial x_0 până la un punct oarecare x_n și fiind necesară aflarea funcției în punctul x_{n+1}, ecuația (8.1) se rescrie de obicei sub forma

$$\begin{aligned} y_{n+1} &= y_n + h \bullet F(x) \\ y_{n+1} &\approx y_n + h\left(\beta_n \bullet f_n + \beta_{n-1} \bullet f_{n-1} + \beta_{n-2} \bullet f_{n-2} \ldots\ldots\right) \end{aligned} \qquad (8.2)$$

determinarea lui y_{n+1} depinzând acum de construirea unui polinom de interpolare ***F(x),*** ce coincide cu *f* atât în x_n, cât și într-un număr de puncte anterioare lui x_n, anume x_{n-1}, x_{n-2}, etc., unde β_n, β_n**-1**, β_n**-2**, etc., sunt coeficienți numerici a căror valoare depinde de ordinul polinomului de interpolare. Există două metode de aproximare

1. Deoarece polinomul de interpolare folosit în calcul integralei este determinat folosind informații cu privire la soluția ecuației în puncte precedente lui x_n aceste metode sunt denumite în mod curent ***metode multi-pas*** **sau** ***metode cu memorie***.

   Particularitatea acestor metode numerice este aceea că polinomul de interpolare *F* este determinat folosind *și* punctul x_{n+1}, nu doar punctul x_n și

cele precedente, valoarea aproximativă a lui y_{n+1} fiind

$$y_{n+1} \approx y_n + h\left(\beta_{n+1} \bullet f_{n+1} + \beta_n \bullet f_n + \beta_{n-1} \bullet f_{n-1} + \beta_{n-2} \bullet f_{n-2} \ldots\ldots\right) \qquad (8.3)$$

Aceste metode sunt așadar implicite, valoarea numerice a lui y_{n+1} fiind obținută după rezolvarea unei ecuații al cărei grad de neliniaritate depinde de dependența funcțională a lui *f* de *y*.

2. Cea de-a doua mare categorie de metode folosite pentru determinarea numerică a soluțiilor ecuației (8.1) este reprezentată de așa-numitele ***metode unipas***, în cadrul cărora polinomul de interpolare *F(x)* care aproximează pe *f(x)* este determinat fără a folosi puncte anterioare lui x_n. Valoarea aproximativă a lui y_{n+1} este dată de:

$$y_{n+1} \approx y_n + h \bullet f\left(x_n + \frac{h}{2}, y_n + \frac{h}{2} \bullet f\left(x_n, y_n\right)\right) \qquad (8.4)$$

După cum se observă cu ușurință schema de calcul este una explicită, partea dreaptă a ecuației precedente fiind calculată exclusiv pe baza valorii funcției *y* în punctul x_n.

Remarcă

Ecuațiile diferențiale de ordin superior pot fi reduse la sisteme de ecuații diferențiale de ordinul 1.

Considerând ecuația diferențială

$$\frac{d^n y}{dt^n} = -\frac{a_0}{a_n} y - \frac{a_1}{a_n} y' - \ldots - \frac{a_{n-1}}{a_n} y^{(n-1)} + f(t)$$

si introducând variabilele:

$$y = x_1,\ y' = x_2,\ y'' = x_3, \ldots,\ y^{(n-1)}(x) = x_n$$

rezulta că:

$$y' = x_1' = x_2,\ y'' = x_2' = x_3, \ldots,\ y^{(n-1)} = x_{n-1}' = x_n$$

$$\begin{cases} x_1' = x_2 \\ x_2' = x_3 \\ x_3' = x_4 \\ \vdots \\ x_{n-1}' = x_n \\ x_n' = -\frac{a_0}{a_n} x_1 - \frac{a_1}{a_n} x_2 - \ldots - \frac{a_{n-1}}{a_n} x_n + f(t). \end{cases}$$

8.3.1 Metode multipas

Metodele multipas oferă o imagine extrem de intuitivă asupra modului în care putem construi soluții aproximative pentru o ecuație diferențială dată. Să presupunem, de pildă, că pentru ecuația (8.1) am putut construi o soluție aproximativă până la un punct x_n și că am păstrat,de asemenea, toate informațiile aferente punctului x_{n-1}. Știind, așadar, punctele (x_n, f_n) și (x_{n-1}, f_{n-1}) putem construi fără probleme un polinom de interpolare pentru f (în cel mai simplu caz o dreaptă)

care ia forma

$$F(x)=\frac{x-x_n}{x_{n-1}-x_n}f_{n-1}+\frac{x-x_{n-1}}{x_n-x_{n-1}}f_n \tag{8.5}$$

Cu el putem determina imediat soluția aproximativă a ecuației diferențiale în punctul x_{n+1}, calculând o integrală extrem de simplă, *de forma*

$$\begin{aligned} y_{n+1} &\approx y_n+\int_{x_n}^{x_{n+1}} dxF(x), \\ y_{n+1} &\approx y_n+\int_{x_n}^{x_{n+1}} dx\left(\frac{x-x_n}{x_{n-1}-x_n}f_{n-1}+\frac{x-x_{n-1}}{x_n-x_{n-1}}f_n\right), \\ y_{n+1} &\approx y_n+h\left(\frac{3}{2}f_n-\frac{1}{2}f_{n-1}\right) \end{aligned} \tag{8.6}$$

Pentru a spori acuratețea rezultatului anterior, putem crește ordinul polinomului de interpolare (în calculul precedent, doar o dreaptă), prin adăugarea punctului (x_{n-2}, f_{n-2}). Noul polinom de interpolare (acum de ordinul doi) este dat de

$$F(x)=\frac{x-x_n}{x_{n-2}-x_n}\bullet\frac{x-x_{n-1}}{x_{n-2}-x_{n-1}}\bullet f_{n-2}+\frac{x-x_n}{x_{n-1}-x_n}\bullet\frac{x-x_{n-2}}{x_{n-1}-x_{n-2}}\bullet f_{n-1}+\frac{x-x_{n-2}}{x_n-x_{n-2}}\bullet\frac{x-x_{n-1}}{x_n-x_{n-1}}f_n$$

Iar noua soluție aproximativă este dată de

$$\begin{aligned} y(x_0+h) &= y(x_0)+h\bullet f(x_0,y_0), \\ y(x_0+2h) &= y(x_0+h)+h\bullet f(x_0+h,y_0(x+h)), \\ y(x_0+3h) &= y(x_0+2h)+h\bullet f(x_0+2h,y_0(x+2h)), \\ &\cdots\cdots\cdots\cdots \\ y(x_0+Nh) &= y(x_0+(N-1)h)+h\bullet f(x_0+(N-1)h,y_0(x+(N-1)h)) \end{aligned}$$

Calculul polinomului de interpolare al lui *f* este relativ ușor atunci când sunt două sau trei puncte, însă devine din ce în ce mai complicat odată cu creșterea numărului de puncte.

8.3.2 Metode unipas

Metodele prezentate în paragraful precedent se bazează pe determinarea soluției numerice folosind un polinom de interpolare global cu ajutorul căruia determinăm soluția unei ecuații diferențiale la x_n utilizând informațiile de la x_{n-1}, x_{n-2}, x_{n-3}, etc.

În cele ce urmează vom prezenta metoda Euler și metodele Runge-Kutta folosite pentru majoritatea problemelor.

1. Metoda Euler

Cea mai simplă dintre metodele folosite pentru rezolvarea numerică a unei ecuații diferențiale ordinare este metoda Euler, sau a liniilor poligonale. Ideea din spatele metodei este extrem de simpla: soluția ecuației diferențiale este aproximată de o linie polinomială formată din tangentele la soluția locală a ecuației. Metoda a fost introdusă de Leonhard Euler în volumul *Institutionum calculi integralis* (publicat în perioada 1768-1770). Astfel, dată fiind ecuația diferențială

$$y' = f(x, y) \qquad y(x_0) = y_0 \tag{8.7}$$

soluția este construită astfel :

Daca se notează $\boldsymbol{x_0+h = x_1}$, atunci punctul de coordonate $\boldsymbol{(x_1, y_1)}$ situat pe tangenta considerata reprezintă o aproximație a punctului de coordonate $\boldsymbol{(x_1 , y(x_1))}$ situat pe curba ce reprezintă soluția ecuației diferențiale. Este evident faptul ca eroarea metodei este cu atât mai redusa cu cat valoarea pasului diviziunii considerate **- *h*** este mai mic Se poate construi astfel un proces iterativ de forma:

$$y_{m+1} = y_m + h \bullet f(x_m, y_m) \qquad m = 0,1,2,3,...$$
$$cu \qquad (8.8)$$
$$h = x_{m+1} - x_m$$

a cărui reprezentare grafica se prezintă în figura alăturata**.**

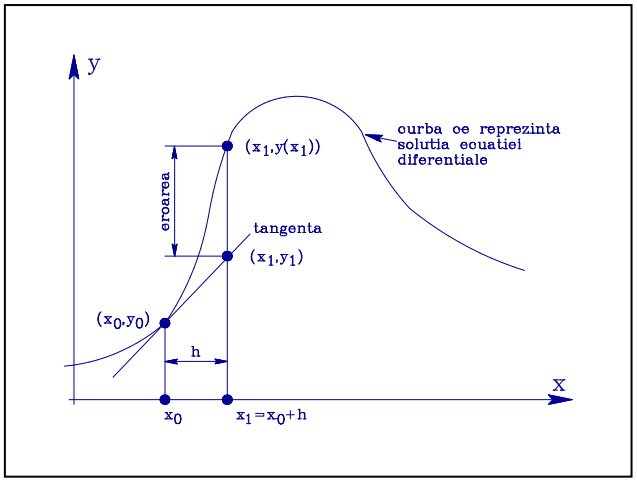


Fig. 8.1 În metoda Euler se aproximează soluția exactă cu o linie poligonală.

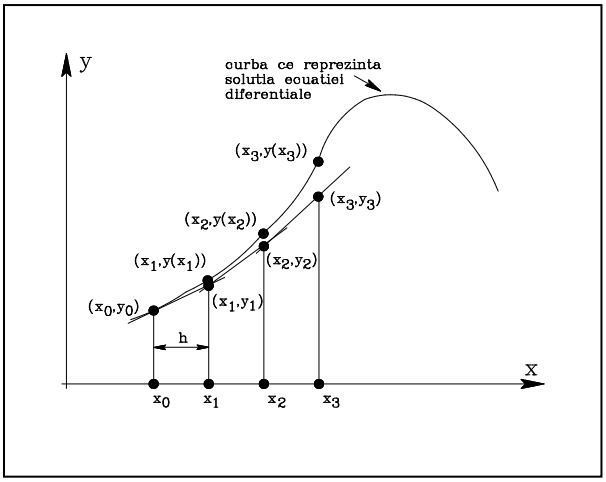


Fig. 8.2 Aproximarea soluției ecuației diferențiale

Efortul computațional al metodei Euler este minim, dar precizia este de asemenea minimă.

Exemplu

Considerând ecuația diferențiala:

$$y' = 2\,x\,y$$

si condiția inițiala ***y(1)=1***, sa se obțină o aproximație pentru a găsi valoarea lui ***y*** în punctul de abscisa ***x = 1.5***, utilizând un pas h cu valorile 0.1, 0.05 și 0.01, apoi să se calculeze și erorile relative raportate la valoarea exacta, cu patru zecimale.

Tab. 1 Valorile obținute pentru h = 0.10

x_n	y_n	Exact	Eroare	Eroare %
1.00	1.0000	1.0000	0.0000	0.00
1.10	1.2000	1.2337	0.0337	2.73
1.20	1.4640	1.5527	0.0887	5.71

1.30	1.8154	1.9937	0.1784	8.95
1.40	2.2874	2.6117	0.3244	12.42
1.50	2.9278	3.4904	0.5625	16.12

Tab. 2 Valorile obținute pentru h = 0.05

x_n	**y_n**	**Exact**	**Eroare**	**Eroare %**
1.00	1.0000	1.0000	0.0000	1.00
1.10	1.2155	1.2337	0.0182	1.10
1.20	1.5044	1.5527	0.0483	1.20
1.30	1.8955	1.9937	0.0982	1.30
1.40	2.4311	2.6117	0.1806	1.40
1.50	3.1733	3.4904	0.3171	1.50

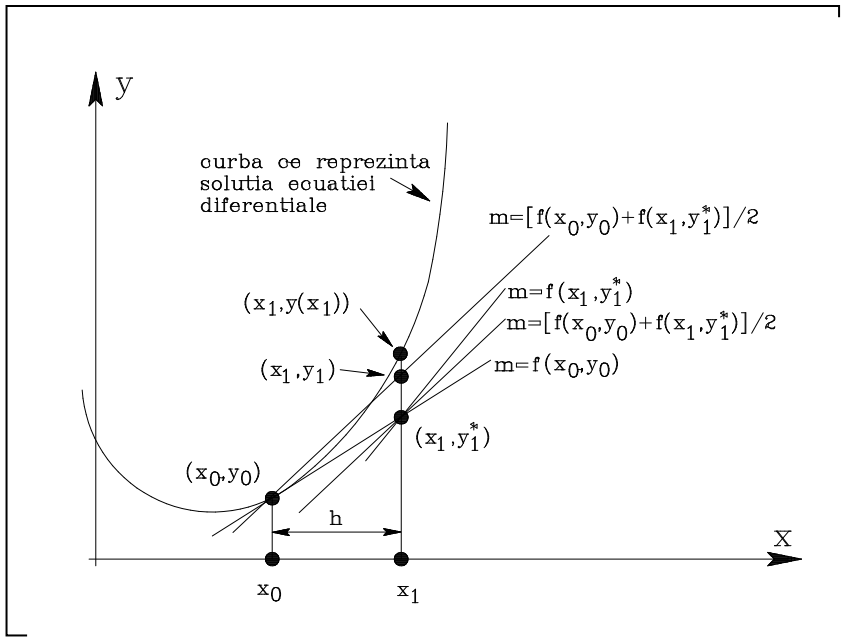
Tab. 3 Valorile obținute pentru h = 0.01

x_n	y_n	Exact	Eroare	Eroare %
1.00	1.0000	1.0000	0.0000	0.00
1.10	1.2298	1.2337	0.0039	0.31
1.20	1.5423	1.5527	0.0104	0.67
1.30	1.9723	1.9937	0.0214	1.07
1.40	2.5719	2.6117	0.0398	1.52
1.50	3.4197	3.4904	0.0707	2.03

2. Metoda Euler-Heun

Aceasta metoda este cunoscuta și sub denumirea de *metoda Euler îmbunătățita*, situația fiind prezentata în figura de mai jos pentru primul pas de integrare. Procesul iterativ pentru soluționarea numerica este descris de relația următoare:

$$y_{n+1} = y_n + h\,\frac{f\left(x_n, y_n\right) + f\left(x_{n+1}, y^*_{n+1}\right)}{2}, \qquad (8.9)$$
$$y^*_{n+1} = y_n + h\,f\left(x_n, y_n\right).$$



Analizând figura se poate constata că valoarea lui y_1 este mai apropiata de soluție decât valoarea obținuta pentru y_1^*, ceea ce poate încadra aceasta metoda în clasa metodelor predicator-corector. Intr-adevăr, aceasta situație se poate interpreta în felul următor:

Pasul predictor: $$y_1^* = y_0 + h\, f\left(x_0,\, y_0\right) \tag{8.10}$$

Pasul corector:

$$y_1 = y_0 + h\,\frac{f\left(x_0,\, y_0\right) + f\left(x_1,\, y_1^*\right)}{2} \tag{8.11}$$

In continuare, cu referire la ecuația diferențiala considerata anterior, se prezintă rezultatele obținute prin aplicarea acestei metode pentru diferiți pași de integrare și programul folosit pentru soluționarea numerica.

Tab. 4 Valorile obținute pentru h = 0.10

x_n	y_n	Exact	Eroare	Eroare %
1.00	1.0000	1.0000	0.0000	0.00
1.10	1.2320	1.2337	0.0017	0.14
1.20	1.5479	1.5527	0.0048	0.31
1.30	1.9832	1.9937	0.0106	0.53
1.40	2.5908	2.6117	0.0209	0.80
1.50	3.4509	3.4904	0.0394	1.13

Tab. 5 Valorile obținute pentru h = 0.05

x_n	y_n	Exact	Eroare	Eroare %
1.00	1.0000	1.0000	0.0000	0.00
1.10	1.2332	1.2337	0.0004	0.04
1.20	1.5514	1.5527	0.0013	0.08
1.30	1.9909	1.9937	0.0029	0.14
1.40	2.6060	2.6117	0.0057	0.22
1.50	3.4795	3.4904	0.0108	0.31

Tab. 6 Valorile obținute pentru h = 0.01

x_n	y_n	Exact	Eroare	Eroare %
1.00	1.0000	1.0000	0.0000	0.00
1.10	1.2337	1.2337	0.0000	0.00
1.20	1.5527	1.5527	0.0000	0.00
1.30	1.9936	1.9937	0.0001	0.005
1.40	2.6115	2.6117	0.0002	0.010
1.50	3.4899	3.4904	0.0005	0.025

8.3. Metode multipas. Metoda dezvoltării în serie Taylor

Aceasta metoda nu prezintă o largă aplicabilitate deoarece, în principal, rezultatele sunt comparabile cu cele obținute prin aplicarea metodei Euler-Heun în condițiile unor calcule mai laborioase.

Așa cum se știe, dezvoltarea unei funcții $y(x)$ în jurul unui punct $x = a$ are expresia:

$$y(x) = y(a) + y'(a)\frac{(x-a)}{1!} + y''(a)\frac{(x-a)^2}{2!} + \ldots \quad (8.12)$$

Pentru a apropia expresia de mai sus de problema curenta, daca se considera cazul în care $\boldsymbol{a = x_n}$ **și** $\boldsymbol{x = x_n + h}$, se obține:

$$y(x_n + h) = y(x_n) + y'(x_n)\,h + y''(x_n)\frac{h^2}{2} + \ldots \quad (8.13)$$

Daca se presupune că funcția *y(x)* este soluția ecuației diferențiale $y' = f(x, y)$

Oprind numai doi termeni din se poate scrie:

$$\begin{array}{c} y(x_n + h) \cong y(x_n) + y'(x_n)\,h \\ \Updownarrow \\ y(x_n + h) \cong y(x_n) + f(x_n, y(x_n))\,h \end{array} \quad (8.13)$$

Se observa faptul că daca în ecuația de mai sus se înlocuiește $y(x_n+h)$ cu y_{n+1} și $y(x_n)$ cu y_n se obține formula ce caracterizează metoda Euler:

$$y_{n+1} = y_n + h\,f(x_n, y_n)$$

Oprind trei termeni și făcând înlocuirile ante menționate se obține următoarea formula:

$$y_{n+1} = y_n + y_n'\,h + y_n''\,h^2 \quad (8.14)$$

Metoda poate fi considerata drept cheia de bolta a majorității metodelor de rezolvare numerica a ecuațiilor diferențiale.

Metode Runge-Kutta

Aceasta clasa de metode reprezintă una dintre cele mai folosite în abordarea numerica a ecuațiilor diferențiale, îmbinând numărul relativ redus de operații elementare cu acuratețea rezultatelor.

Fiind dată ecuația diferențială

$$y' = f(x, y) \qquad y(x_0) = y_0, \tag{8.15}$$

Metoda Runge-Kutta de ordinul II consta în găsirea constantelor a, b astfel încât expresia

$$y_{n+1} = y_n + a\ k_1 + b\ k_2 \tag{8.16}$$

cu

$$\begin{aligned} k_1 &= h\ f\left(x_n, y_n\right), \\ k_2 &= h\ f\left(x_n + \alpha\ h, y_n + \beta\ k_1\right) \end{aligned} \tag{8.17}$$

să se apropie de dezvoltarea în serie Taylor pentru cat mai mulți termeni posibili. Meritul principal al acestei clase de metode rezida deci în aceea că se apropie de acuratețea unei dezvoltări în serie Taylor fără însă a fi nevoie sa se calculeze și derivatele de ordin superior.

Se fac următoarele observații:

a) Daca:

$$a + b = 1,\ b\ \alpha = \frac{1}{2}, b\ \beta = \frac{1}{2} \tag{8.18}$$

atunci relația anterioara reprezintă dezvoltarea în serie Taylor, oprind primii trei termeni, a funcției considerate.

b) Dacă:

$$a = \frac{1}{2}, b = \frac{1}{2},\ \alpha = 1,\ b = 1 \tag{8.19}$$

atunci relația anterioara se reduce la expresia metodei Euler-Heun.

c) Se poate constata că metoda Euler este de fapt o procedura Runge-Kutta de ordinul I.

Folosind aceleași considerații se determina astfel algoritmul de calcul și în cazul metodei Runge-Kutta de ordinul IV (se opresc primii patru termeni din dezvoltarea în serie Taylor):

$$\begin{aligned} y_{n+1} &= y_n + \frac{1}{6}\left(k_1 + 2k_2 + 2k_3 + k_4 \right), \\ k_1 &= h f\left(x_n, y_n \right), \\ k_2 &= h\ f\left(x_n + \frac{1}{2}\ h,\ y_n + \frac{1}{2}\ k_1 \right), \\ k_3 &= h\ f\left(x_n + \frac{1}{2}\ h,\ y_n + \frac{1}{2}\ k_2 \right), \end{aligned} \tag{8.20}$$

care este forma standard de scriere a unei metode Runge-Kutta.

În continuare se prezintă rezultatele numerice obținute în cazul aplicării acestei metode pentru rezolvarea ecuației diferențiale considerate anterior

Tab. 4 Valorile obținute pentru h = 0.10

x_n	y_n	Exact	Eroare	Eroare %
1.00	1.0000	1.0000	0.0000	0.00
1.10	1.2337	1.2337	0.0000	0.00
1.20	1.5527	1.5527	0.0000	0.00
1.30	1.9937	1.9937	0.0000	0.00
1.40	2.6117	2.6117	0.0000	0.00
1.50	3.4903429	3.4904	0.0000571	0.0016

Tab. 5 Valorile obținute pentru h = 0.05

x_n	y_n	Exact	Eroare	Eroare %
1.00	1.0000	1.0000	0.0000	0.00
1.10	1.2337	1.2337	0.0000	0.00
1.20	1.5527	1.5527	0.0000	0.00
1.30	1.9937	1.9937	0.0000	0.00
1.40	2.6117	2.6117	0.0000	0.00
1.50	3.4903	3.4904	0.0001	0.0028

Tab. 6 Valorile obținute pentru h = 0.01

x_n	y_n	Exact	Eroare	Eroare %
1.00	1.0000	1.0000	0.0000	0.00
1.10	1.2337	1.2337	0.0000	0.00
1.20	1.5527	1.5527	0.0000	0.00
1.30	1.9937	1.9937	0.0000	0.00
1.40	2.6117	2.6117	0.0000	0.00
1.50	3.4903429	3.4904	0.0000571	0.0016

7.Modelarea bazată pe agenţi

7.1 Modele comportamentale în epidemiologie.

Un model matematic descrie comportarea unui sistem din lumea reală prin ecuații diferențiale în majoritatea cazurilor în care coeficienții sunt valori constante reprezentând interacțiunea dintre sistem și mediul înconjurător și respectiv interacțiunea dintre componentele sistemului

Un model comportamental este un model matematic în care coeficienții ecuațiilor diferențiale care descriu sistemul din lumea reală sunt mărimi variabile care se modifică în timp.

Modelul Kermack-McKendrick

Un model clasic de tip comportamental este utilizat pentru a înțelege modul în care evoluează o epidemie în contextul unei populații date. Populația în cel mai simplu caz este văzută ca fiind format din

- persoane susceptibile de a fi infectate (notate cu ***S*** - Susceptible)
- persoane care au fost infectate de virusul patogen (notate cu ***I*** – Infected)
- persoane care sau vindecat sau care sunt imune (notate cu ***R*** – Recovered)

Din aceste considerente, modelele matematice care încearcă să analizeze modul de evoluție a unei epidemii sunt cunoscte sub denumirea de modele comportamentale de tip ***SIR*** (**S**usceptible, **I**nfected. **R**ecovered/removed/immune)

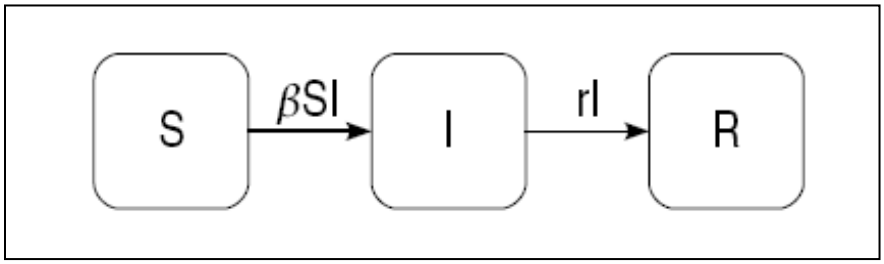
Modelul Kermack-McKendrick

Modelul Kermack-McKendrick este un model matematic de bază de tip *SIR* care încearcă să explice dinamica numărului de persoane infectate cu o boală contagioasă într-o comunitate închisă. S-a utilizat pentru analiza epidemiei de

ciumă (Londra 1665-1666, Bombay 1906) și holeră (Londra 1865). Modelul este construit plecând de la următoarele presupuneri

- mărimea populației este fixă
- nu există nașteri
- decesul apare din cauza epidemiei sau din cauze natural
- perioada de incubație a agentului infecțios este instantanee, iar durata de îmbolnăvire este aceeași pentru orice persoană
- se consideră că populația este omogenă – nu se ține cont de vârstă, structură socială și localizare în spațiul geografic în care se manifestă boala.

Bazat pe aceste presupuneri graful modelului prezintă aspectul



În graf nodurile reprezintă stări de tip (**S**usceptible, **I**nfected. **R**ecovered /removed / immune iar arcele tranziții între acestea.

Graful poate fi translatat într-un model definit de un sistem de trei ecuații diferențiale care sunt de forma

$$\frac{dS}{dt} = -\beta SI$$
$$\frac{dI}{dt} = \beta SI - \gamma I$$
$$\frac{dR}{dt} = \gamma I$$

Unde

- t este timpul
- $S(t)$ – numărul de persoane care pot fi infectate
- $I(t)$ numărul de persoane infectate
- $R(t)$ numărul de persoane care s-au recuperat sau au dezvoltat imunitate la infecție
- **β este frecvența (rata) de infecției**
- **γ este frecvența (rata) de recuperare (însănătoșire)**

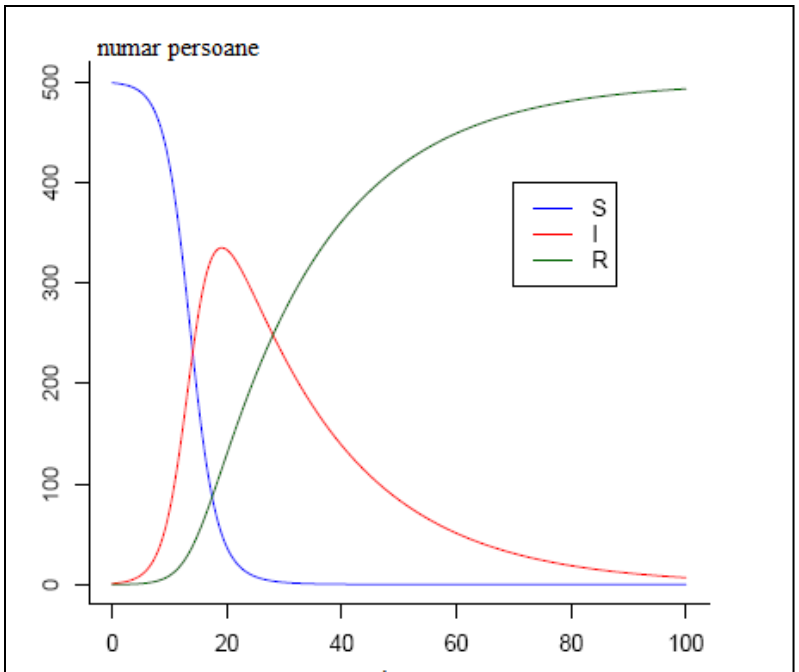
O valoare importantă care determină dinamica celor trei parametrii din sistemul de ecuație poartă denumire de **prag epidemiologic** (mărime care este considerată cel mai important factor în epidemiologie) și este definită de

$$R_0 = \frac{\beta S}{\gamma}$$

Când

- $R_0 < 1$ fiecare persoană care contractează boala va infecta mai puțin de o persoană înainte de a deceda sau se va însănătoși . În acest context $\frac{dI}{dt} < 0$, aspect care va conduce la stingerea epidemiei.
- $R_0 > 1$ fiecare persoană care a contractat boala va infecta mai mult de o persoană astfel că epidemia se va răspândi, aspect relevat de faptul că $\frac{dI}{dt} > 0$

Un exemplu al dinamicii celor trei parametri S, I, R este prezentat în figura de mai jos.



Deoarece complexitatea sistemelor descrise prin modelele comportamentale este greu de surprins matematic ca și de a defini modul în care se modifică în timp coeficienții acestor ecuații s-a încercat o altă abordare de descriere a unui sistem în care ansamblul ecuații diferențiale, coeficienți care se modifică în timp să fie înlocuit de descriere acestuia prin intermediul relațiilor care apar între aceste componente (relații între componentele sistemului, relații între componentele sistemului și mediul înconjurător)

Mare deficiență a modelelor comportamentale (descrise prin ecuații diferențiale) rezidă din faptul că descriu numai parțial complexitatea sistemului din lumea reală. Această deficiență se datorează absenței reprezentări mediului geografic în care este prezent sistemul modelat. Atașarea reprezentări mediului geografic (spațial) a condus la dezvoltarea unei noi tehnici de modelare cunoscută sub denumirea de Agent-Based Modelling (ABM).

Agent-Based Modelling (ABM). Modelarea bazată pe agenți este utilizată atunci când se reprezintă un sistem prin intermediul relațiilor care apar între entitățile care definesc comportarea acestuia. Sistemul din punctul de vedere conceptual, apare de forma

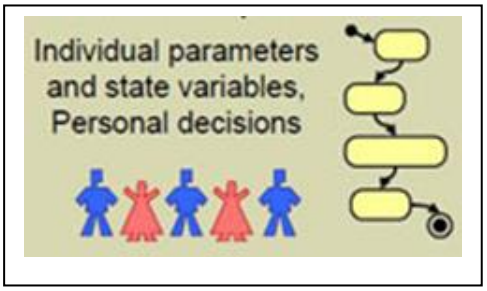


Figura 7.1 Descrie vizual modelul de tip ABM (The Big Book of Simulation Modeling, 2013)

Structura tipică a unui ABM este dată în figura următoare

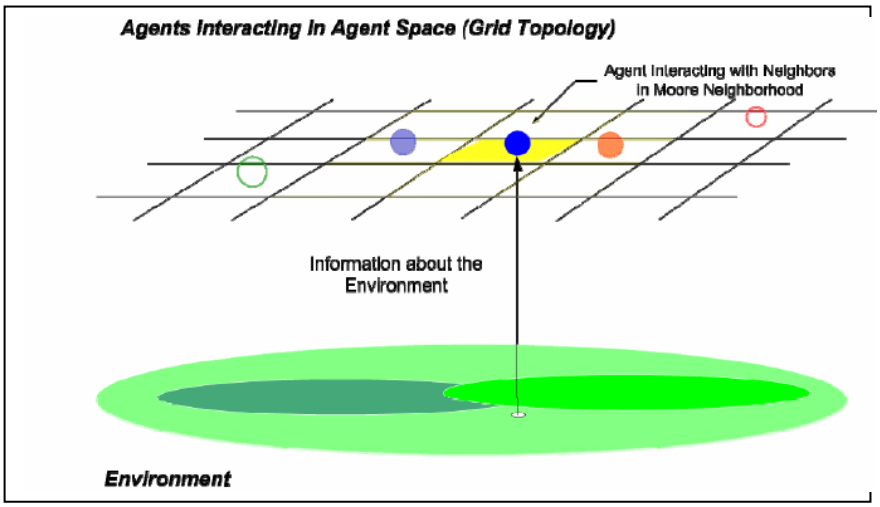


Figura 7.2 Elementele generale ale unui sistem de tip ABM

În cele ce urmează se vor prezenta conceptele de tip agent, modelare bazată pe agenți și se vor exemplifica aceste concepte prin mai multe exemple.

7.2. Arhitecturi de Agenţi Inteligenţi

7.2.1 Agenți utilizați în ABM. Concepte.

Definiție

Un Agent este o entitate care funcționează continuu si autonom intr-un mediu in care au loc alte acțiuni si in care sunt prezenți si alți agenți [1].

Se folosesc trei concepte cheie pentru a defini un agent:

- poziţionarea în raport cu mediul,
- autonomia şi
- flexibilitatea.

Poziţionarea**,** în acest context, înseamnă că agentul primeşte informații de la mediul în care este prezent și că poate executa acţiuni care schimbă acest mediu într-un anumit fel.

Autonomia este înțeleasă ca absenţa intervenţiei umane sau a altor agenţi, deci un agent îşi poate controla complet propriile acţiuni şi starea sa internă. Uneori autonomia este înţeleasă. într-un sens mai strict, ca şi capacitatea pe care o are agentul de a învăţa din propria sa experienţă.

Flexibilitatea presupune. în esenţă, că agentul percepe mediul şi răspunde la timp la schimbările ce apar în el, fiind capabil să exercite un comportament orientat către un anumit scop şi să iniţieze acţiuni care îl apropie de aceste scopuri, şi social, deci agentul este capabil să interacţioneze cu alţi agenţi. Structura tipică a unui agent este prezentată în figura următoare

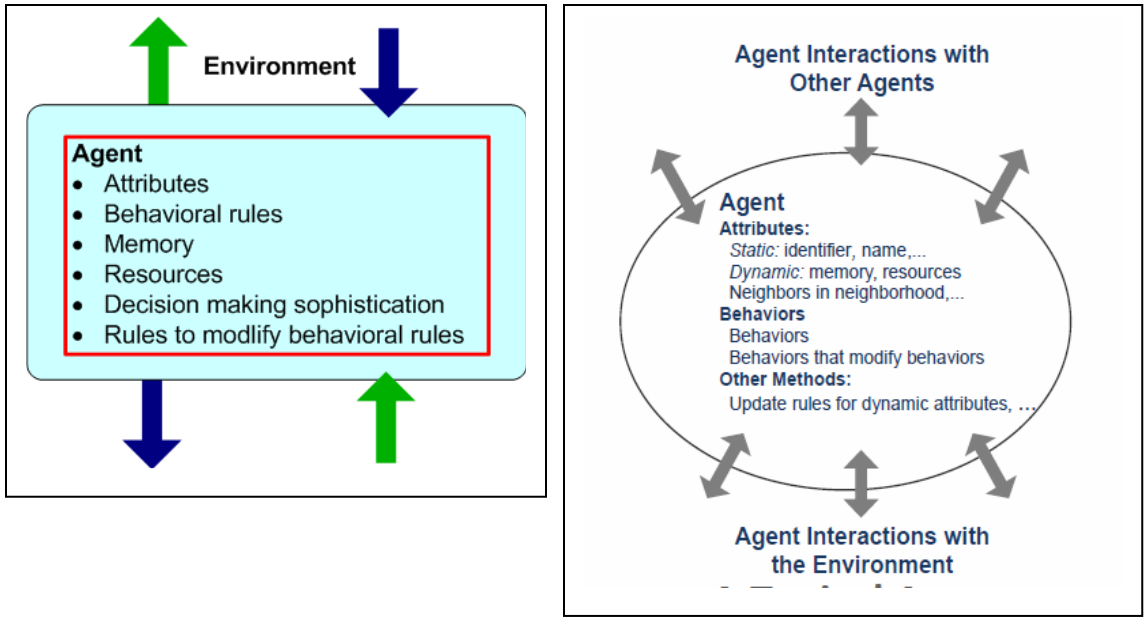


Figura 7.3 Structura unui agent

Un agent tipic utilizat în ABM are un număr de trei componente:

1. **Atribute** care descriu și particularizează agentul (nume, resurse de care dispune etc.)
2. **Reguli** de interacțiune cu alți agenți.
3. **Agentul acționează într-un context** (spațiu real sau virtual), aspect care impune definirea regulilor după care se desfășoară această interacțiune.

7.2.2 Modelul abstract al unui agent inteligent

Din punct de vedere formal un agent inteligent care acționează într-un mediu dat este definit de

- Mediul ***S*** în care acționează agentul este definit prin intermediul stărilor pe care acesta le prezintă. Din punct de vedere formal acesta este definit de o mulțime de stări de forma

$$S = \{s_1,\ s_2,\ .....\}$$

  La orice moment mediul este prezent în una din aceste stări.

- Agentul poate realiza un set de acțiuni Din punct de vedere formal acțiunile ***A*** pe care un agent le poate realiza apar de forma

$$A = \{a_1,\ a_2,\ .....\}$$

Cu aceste precizări un agent standard poate fi considerat ca fiind o funcție care mapează secvenţe de stări ale mediului la acţiuni. Formal un astfel de agent apare de forma

$$\text{actiune} : S^* \Rightarrow A$$

Putem să reprezentăm interacţiunea agentului cu mediul ca şi un **istoric**. Acest istoric este reprezentat de o secvenţă de stări ale mediului – acelea pe care agentul le-a întâlnit până în momentul respectiv. Un istoric ***h*** este o secvenţă

$$h: s_0 \xrightarrow{a_0} s_1 \xrightarrow{a_1} \ldots \xrightarrow{a_{u-1}} s_u \xrightarrow{a_u} \ldots;$$

unde

- s_0 este starea inițială a mediului (starea în care se află mediul în momentul în care agentul își începe execuția),
- a_u fiind ce-a de-a *u*-a acțiune efectuată de agent,
- iar s_u fiind cea de-a *u*-a stare a mediului (starea rezultată în urma execuției acțiunii a_{u-1} în starea s_{u-1}).

Comportamentul unui agent standard poate fi

- ***determinist*** dacă acesta dintr-o stare a mediului în care este prezent poate trece în altă stare existentă a mediului întotdeauna aceeași , indiferent de momentul de timp. Se consideră în acest caz că *mediul este determinist* iar comportamentul agentului poate fi prezis cu acuratețe.
- ***nedeterminist*,** dacă dintr-o stare în care este prezent poate trece în una din stările de mediu prezente într-o submulțime care rezultă în urma executării acțiunii întreprinse de agent Se consideră în acest caz că *mediul este nedeterminist* iar comportamentul agentului este probabilistic

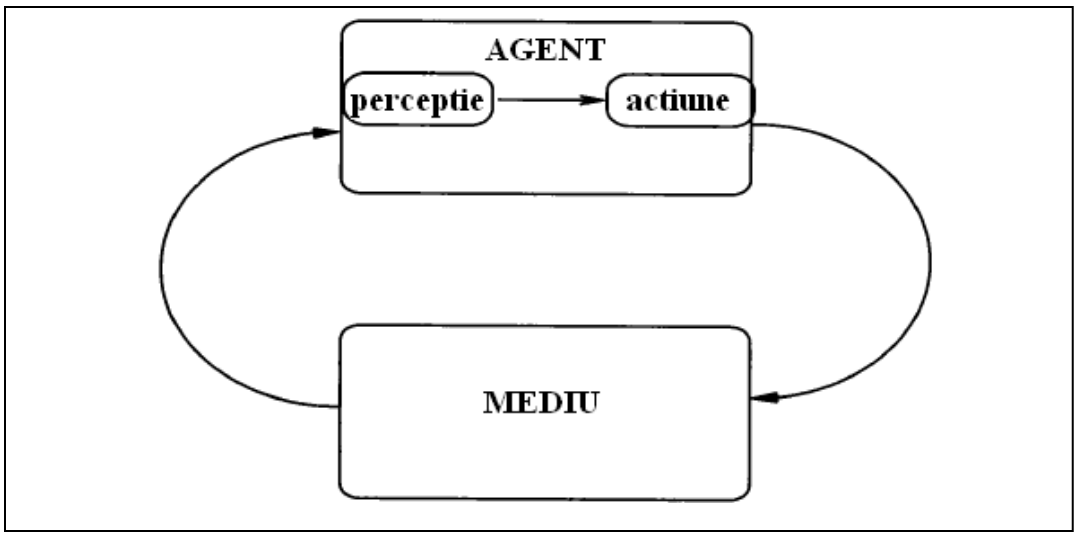
Se observă că **modelul *abstract*** al unui agent presupune două aspecte: arhitectura (partea de construcție) agentului și proiectarea (design-ul) funcției de decizie a agentului.

Analiza celor două subsisteme ale unui *agent*, conduce la următoarele concluzii:

- *proiectarea* (*design*-ul) agentului se referă la datele și structurile de control ce vor fi prezente în descrierea agentului;

- *arhitectura* agentului se referă la *partea internă* – structurile de date, operaţiile care vor trebui aplicate acestor structuri, precum şi controlul fluxului între structurile de date.

Funcţia de decizie a agentului trebuie separată în două subsisteme: subsistemul *percepţie* şi subsistemul *acţiune*



Structura comportamentală a unui Agent

Funcţia percepţie:

- se referă la abilitatea agentului de a-şi observa (percepe) mediul;
- rezultatul (output-ul) funcţiei *percepţie* este un *semnal* (percepţie) – o secvenţă perceptuală primită la intrare;
- dacă P este o mulţime nevidă de percepţii despre mediu , atunci funcţia *percepţie* va fi: $perceptie : S \to P$, funcţie ce asignează stărilor mediului percepţii.

Funcţia acţiune:

- se referă la procesul de aplicare al deciziilor;
- dacă P este o mulţime nevidă de percepţii despre mediu, funcţia *acţiune* va fi: $actiune: P^* \rightarrow A$, funcţie ce asignează secvenţelor de percepţii (semnale) acţiuni.

Spre exemplu pentru un agent hardware (din lumea fizică) senzorii care percep mediul ar putea fi: o cameră video sau un senzor infra-roşu situate pe agentul în mişcare.

În continuare se vor prezenta trei tipuri de arhitecturi abstracte de agenţi inteligenţi:

- agenţi total reactivi,
- agenţi de tip percepţie,
- agenţi cu stări.

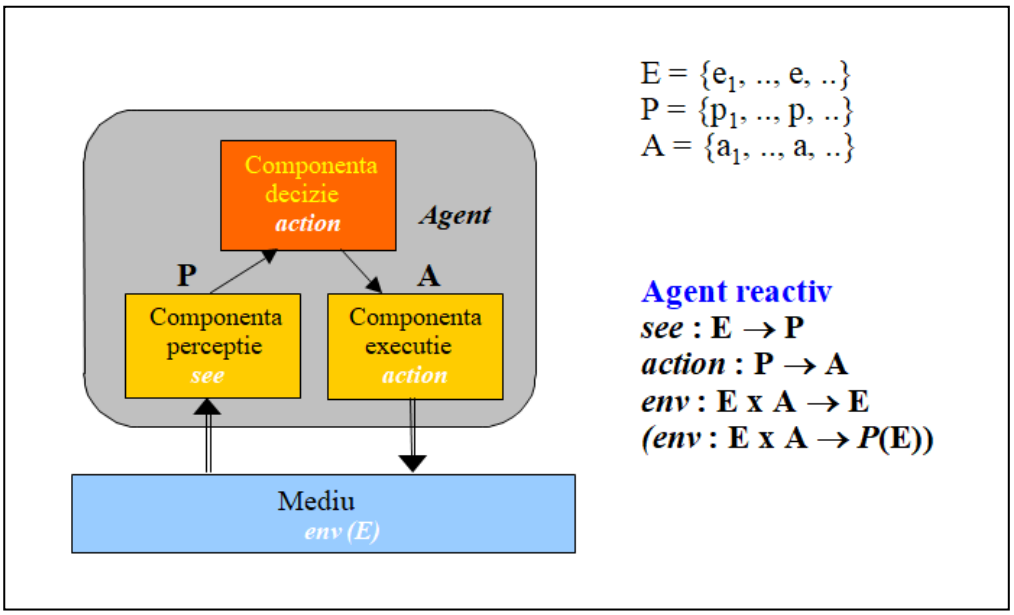
I. Agenţi total reactivi

Anumite categorii de agenţi decid ce acţiune să aleagă la un moment dat, fără a ţine cont de *istoric*-ul lor. Luarea unei decizii se bazează doar pe prezent, nu are nici o legătură cu acţiunile trecute ale agentului. Un astfel de agent se numeşte ***agent total reactiv***, datorită faptului că reacţionează *direct* la mediu ([2]).

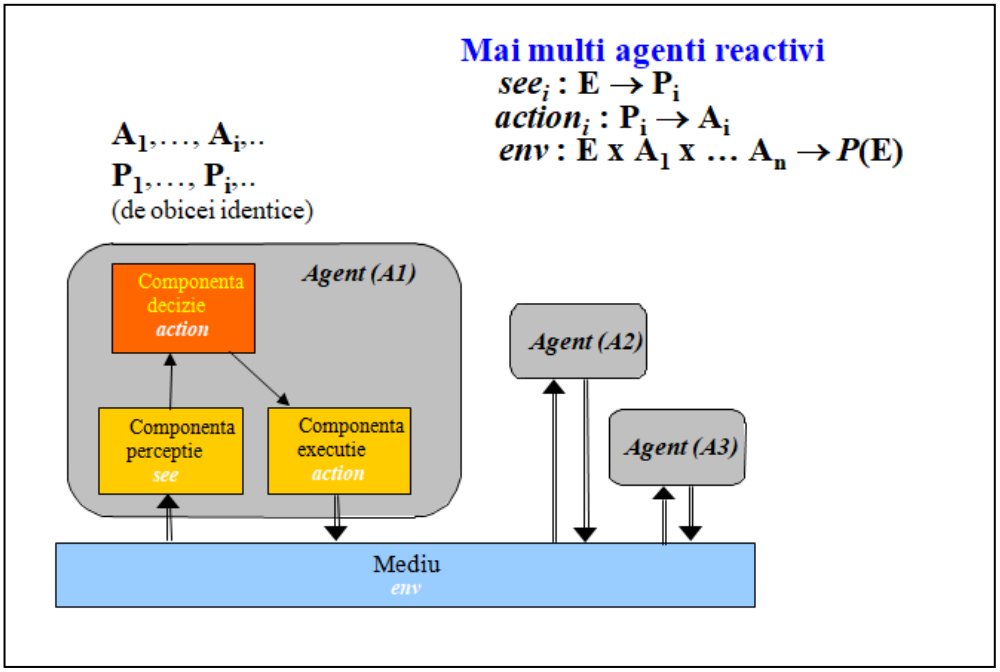
Comportamentul unui agent total reactiv

Formal, comportamentul unui agent total reactiv poate fi reprezentat sub forma unei funcţii : ***acţiune : S→ A***.

Rezultă din această reprezentare că pentru fiecare agent total reactiv, există un agent standard echivalent; reciproca nu este, în general, valabilă.



Model agent total reactiv



Exemplu de agent total reactiv

Un exemplu de agent total reactiv este un termostat ce dispune de un senzor pentru a detecta temperatura camerei. Mediul termostatului poate fi în una din următoarele două stări: prea frig sau temperatură corectă. Acţiunile disponibile fiind doar două, corespunzătoare celor două stări ale mediului:

$$agent(s) = \begin{cases} caldura\ PORNITA \\ caldura\ OPRITA \end{cases}$$

Agentul poate la orice moment să reacţioneze imediat, decizia despre acţiunea pe care o va efectua fiind *independentă* de acţiunile sale anterioare.

II. Agenţi cu stări (cognitivi).

Agenţii cu stări au o structură de date internă care este folosită pentru a păstra informaţii despre starea mediului şi istoricul acțiunilor pe care le-a efectuat. Istoricul va influența acțiunea pe care o ia agentul în momentul curent. Vom nota cu ***I*** mulţimea tuturor stărilor interne ale unui agent.

Funcţia de percepţie pentru un agent cu stări este neschimbată:

$$perceptie : S \to P,$$

funcţie ce asignează stărilor mediului percepţii.

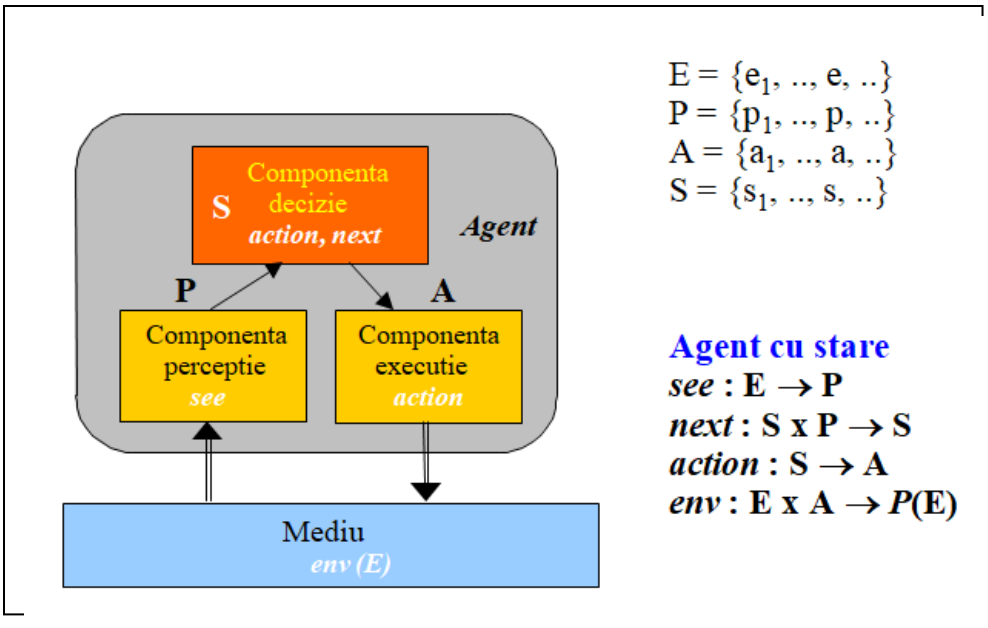
Funcţia de selecţie a acţiunii va fi definită astfel:

$$actiune : I \to A$$

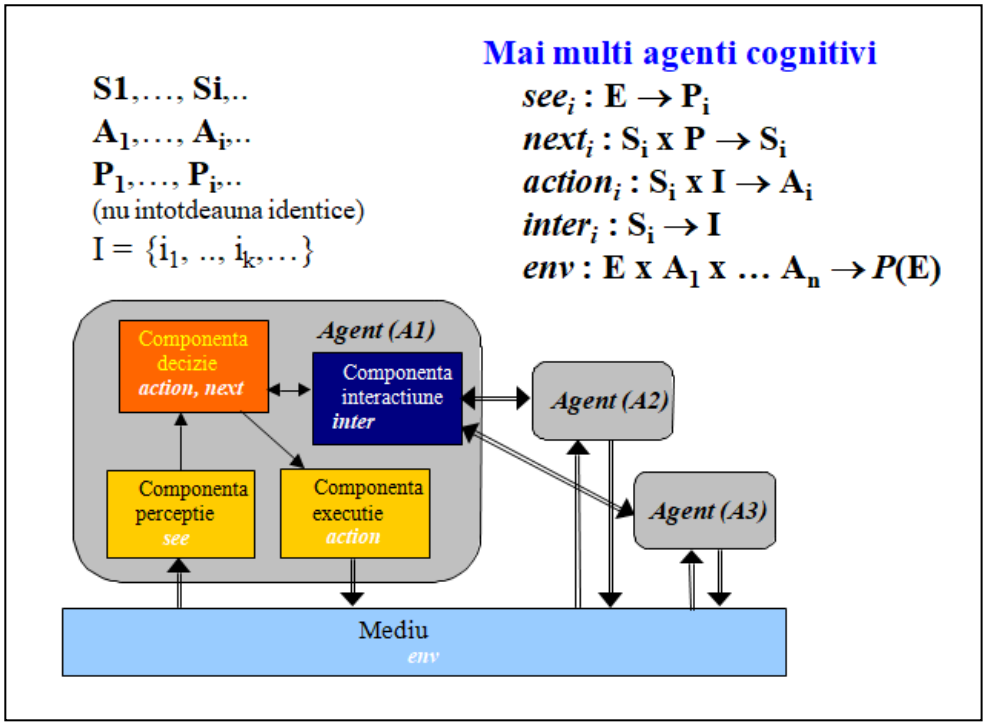
şi asignează acţiuni stărilor interne ale agentului.

Va fi introdusă şi o funcţie adiţională, **funcţia următor**, care asignează *stări interne* unor perechi (*stare internă*, *percepţie*)

$$urmator : IxP \to I$$



Structura comportamentală a unui Agent cognitiv care menţine stările



Comportamentul unui agent bazat pe stări (cognitiv)

Comportamentul unui agent cu stări poate fi rezumat astfel:

- agentul porneşte cu o stare internă iniţială i_0 şi observă starea mediului s;
- generează percepţia *percepţie(s)*;
- starea internă a agentului va fi actualizată conform funcţiei *următor*, devenind *următor*(i_0 , *percepţie*(s));
- acţiunea selectată de agent, corespunzătoare stării sale interne va fi *acţiune(următor*(i_0 , *percepţie*(s)));
- acţiunea va fi executată, după care agentul reia ciclul.

7.3 Modelarea bazată pe agenți

Definiție

Modelarea bazată pe agenți - agent-based model (ABM) – Reprezintă o tehnică de modelare în care sistemul este reprezentat printr-o colecție de agenți care interacționează între ei pe de o parte și cu mediul în care este prezent sistemul modelat pe de altă parte.

Scopul acestei tehnici este acela de a reprezenta un sistem prin intermediul relațiilor care apar între entitățile care definesc comportarea acestuia. Din acest punct de vedere MBA este o tehnică care se poate aplica pentru descrierea și modelarea structurilor sociale, economice și nu în ultimul rând a evenimentelor de orice natură în care relațiile care se stabilesc între componentele sistemului sunt cele care determină comportarea acestuia (manifestări sportive, dezastre naturale etc.)

Cum se construiește un model de tip ABM

Datorită faptului că sunt modelate relații care definesc sistemul supus procesului de modelare și simulare aspect delicat din punct de vedere al definirii acestora se impune ca construirea modelului să fie precedată de o analiză atentă a sistemului în cauză. Este util să se precizeze exact contextul în care se construiește un model de tip ABM. În acest sens este util să se răspundă la o serie de întrebări specifice înainte de a dezvolta un model pe bază de agenți. Răspunsurile la aceste întrebări vor ajuta la definirea domeniului de aplicare şi a nivelului de detaliere necesar de atins. Acestea implică definirea resurselor necesare pentru finalizarea cu succes a modelului, precum la identificarea blocajelor susceptibile care pot apare.

Tabel 1 Întrebări la care trebuie să se răspundă înainte de dezvoltarea unui model de tip ABM

Scopul modelului și ce se dorește a fi obținut printr-o modelare bazată pe agenți: Care este sistemul specific care urmează a fi modelat? La ce probleme specifice trebuie să răspundă modelul? Care sunt informațiile necesare pentru obținerea răspunsurilor dorite a fi obținute prin modelare? De ce un model de tip ABM este cea mai potrivită abordare? Ce aduce în plus față de alte tipuri de tehnici de modelare o reprezentare a sistemului printr-o abordare de tip ABM?
Ce reprezintă agenții în sistemul modelat: Ce relații se vor modela prin intermediul agenților? Care sunt entitățile a căror comportare se va studia? Ce rezultate urmează să fie obținute prin utilizarea agenților? Care sunt datele de intrare necesare pentru a descrie comportarea unui agent?
Stabilirea structurii unui agent: Ce atribute statice are agentul? Ce atribute dinamice are agentul? Dintre aceste atribute dinamice care se actualizează de agent și care de modelul în ansamblu? Care sunt atributele prin intermediul cărora agentul interacționează cu mediul în care acționează? Poate fi luată în considerare mobilitatea agentului în spațiul în care este prezent?
Comportarea agentului: Comportarea agentului este dictată de relațiile pe care le modelează. Care dintre acestea sunt de interes? Ce decizii trebuie să ia agentul și care sunt informațiile necesare pentru luarea acestora? Ce comportări ale agentului se vor lua în considerare? Ce acțiuni poate întreprinde agentul? Cum se reprezintă comportarea agentului? Prin reguli de tip If-then? Printr-o comportare probabilistică? Prin modele regresionale sau rețele neuronale?
Interacțiunea dintre agenți: Cum interacționează un agent cu un alt agent? Cum interacționează agentul cu mediul în care acționează? Cât de generale sau particulare sunt interacțiunile agentului?
Rezultate obținute prin simulare de tip ABM: Cum se proiectează setul de experimente astfel încât să fie surprinsă comportarea de ansamblu a sistemului modelat? Ce date și parametrii se vor urmări în procesul de simulare? Cum se validează modelul, în special comportarea agenților și mecanismele de interacțiune a agenților?

Dezvoltarea unui model de tip ABM presupune parcurgerea unei serii de etape. Acestea sunt prezentate în figura 7.3.

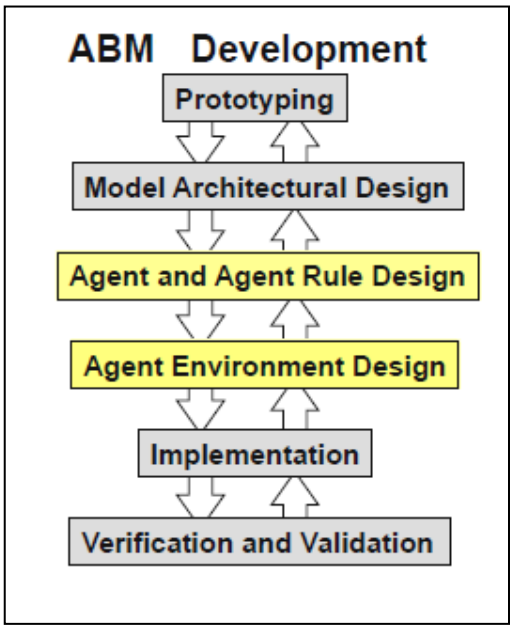


Figura 7.3 Etape în construirea unui model bazat pe agenți - ABM

Datorită dificultăților ridicate de descrierea unui sistem prin intermediul relațiilor care apar între entitățile care îl definesc s-a încercat definirea unor aspecte care trebuie obligatoriu atinse și rezolvate în modelarea bazată pe agenți [3]. Acestea se referă la:

- Rezolvarea conflictelor: Problema apare atunci când doi sau mai mulți agenți urmează să execute o activitate la același moment de timp. Stabilirea unui mecanism de rezolvare a acestor situații este obligatorie. Mecanismul va trebui să țină cont de implicațiile pe care generează execuția unei activități cerute de un agent în fața alteia solicitate de un alt agent la același moment de timp.
- Interacțiunea cu mediul: Problema apare atunci când mediul este descris prin mai multe layere, caz în care trebuie stabilită o strategie de mișcare a agentului în cadrul acestui spațiu complex.
- Strategii de interacțiune: Strategiile pot avea un caracter dinamic. În cazul în care se definesc noi reguli sau se modifică acestea în timpul interacțiunii agenților este necesară separarea clară a procesul de activare a regulilor de mecanismul de creare de noi reguli.
- Învățare: Se referă la posibilitatea ca un agent să învețe și să își modifice comportamentul funcție de experiența obținută din interacțiunea cu mediu și din

interacțiunea cu alți agenți. acest aspect poate sau nu sa fie prezent într-un model de tip ABM

7.3 Exemple

Vom exemplifica conceptele care se utilizează într-o modelare bazată pe agenți prin modelarea a două sisteme:

- Jocul vieţii (game of Life)
- Etnocentrism

I. Jocul vieţii (game of life)

Jocul Life este un automat celular inventat de matematicianul John Conway în 1970. Conway a fost interesat de o problemă prezentată în 1940 de matematicianul John von Neumann, care a încercat să găsească un dispozitiv ipotetic care putea să se reproducă. Neumann a găsit un model matematic pentru această maşină care avea nişte reguli foarte complicate de aceea Conway a încercat să simplifice idea lui John von Neumann şi a reuşit să creeze Game of Life combinând teoria dispozitivului care se autoreproduce cu altă teorie matematică.

Jocul Life nu este chiar un joc el neavând jucători şi nu există pierdere sau câştig asta însemnând că el depinde doar de stare sa iniţială de acolo evoluând după anumite reguli. De aceea Life este atât de interesant pentru că nu se poate găsi un tipar cu care să vezi ce se va întâmpla în viitor,singura modalitate este aplicarea regulilor care-l formează.

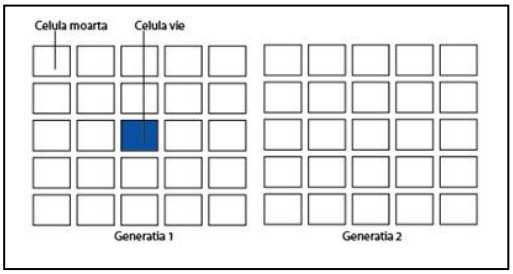
Game of Life se desfăşoară pe o suprafaţă pătrată împărţită în celule, asemănător cu o tablă de şah, suprafaţa pătrată se presupune a fi infinită în toate direcţiile. Fiecare celulă poate să fie moartă sau vie, adică goală sau ocupată de o entitate, şi este înconjurată de alte opt celule care îi pot influenţa starea sa , adică poate să se

nască o nouă entitate sau să moară dacă ea există. Starea fiecărei celule se schimbă simultan datorită regulilor jocului.

John Conway a lucrat la ele timp de câţiva ani până a ajuns să le definească pentru că de fiecare dată când era scrisă o regulă acest joc nu mai era în echilibru, deci entităţile ori mureau ori se înmulţeau prea repede. Următoarele patru reguli fac jocul imprevizibil şi de fiecare dată aduce ceva nou.

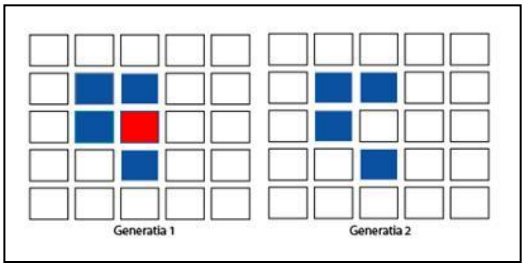
Regulile jocului

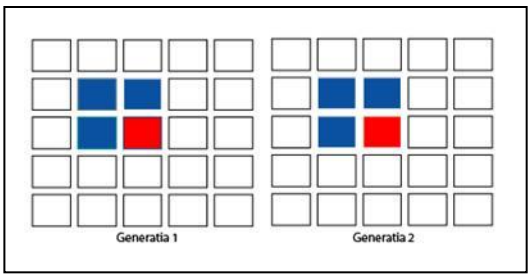
1. Dacă o celulă este vie, dar nu are nici un vecin viu, sau doar un singur vecin viu atunci ea va muri de singurătate în generaţia următoare.



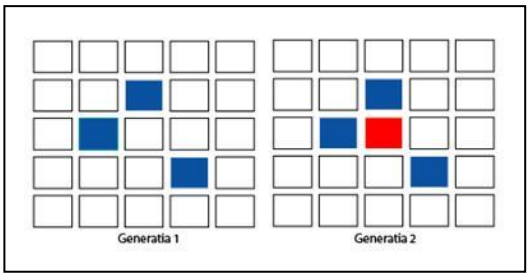
2. Dacă o celulă este vie, dar are cel puțin patru vecini vii, atunci ea va muri sufocată în generaţia următoare.

3. Dacă o celulă este în viaţă şi are doi sau trei vecini atunci ea va trăi, neschimbată, şi în generaţia următoare.

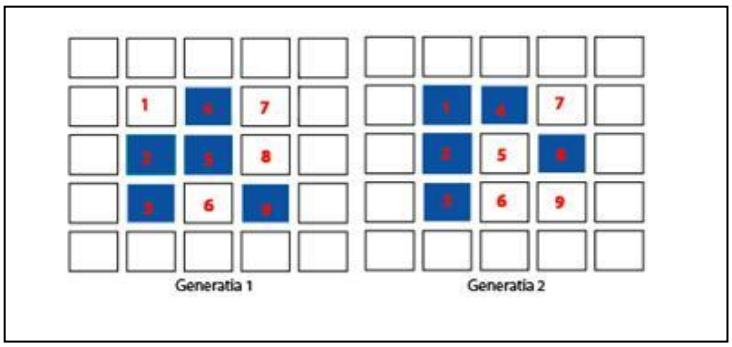




4. Orice celulă moartă va învia în generaţia următoare dacă are exact trei vecini vii în generaţia curentă.



5. Jocul se opreşte într-o stare care se repetă la infinit sau în care toți agenții (entităţiile) mor.
6. Regulile se aplică simultan la fiecare celulă ca în exemplu de mai jos.



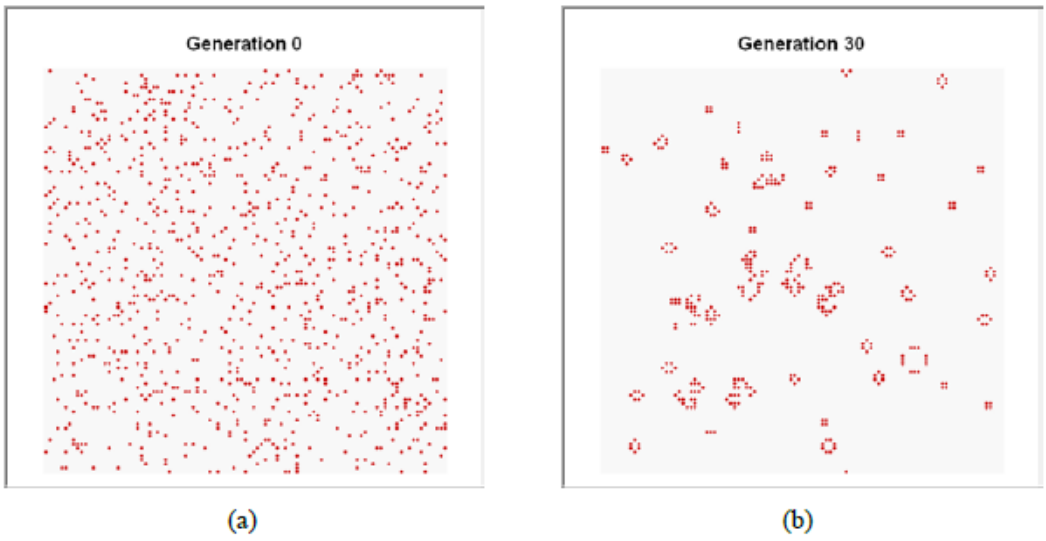
Din cauza existenţei a exact trei vecini în viaţă în jurul celulelor 1 şi 8 , având ca vecini vii celulele 2,4 şi 5 respectiv 4,5 şi 9 în jurul lui 8, se aplică regula patru iar celule moarte 1 şi 8 învie. Celulele 2,3 şi 4 rămân neschimbate datorită reguli 2, având fiecare celulă doi sau trei vecini în viaţă pe 3,4 şi 5 respectiv 2 şi 5. Entităţile 5 şi 9 mor din cauza regulilor 1 şi 2 , celula 9 moare de singurătate, având un singur vecin viu iar celula 5 moare pentru este sufocată de celulele 2,3,4 şi 9.

Dacă interpretăm *Life* ca un agent-based model vom putea considera că fiecare celulă este un agent. Agentul utilizat este de tip reactiv unde

- regulile jocului definesc comportarea agentului

- starea celulei (*On* sau *Off*) reprezintă cele două stări în care este prezentă o celulă
- starea tuturor agenților luați împreună la un moment dat de timp din durata simulării definește starea modelului (sistemului)
- mediul în care acționează *Life* este definit de grila (matricea) în care agenții acționează. Funcția mediul este minimă fiind utilizată numai pentru determinarea vecinilor unui agent (în număr de 8)

Figura următoare surprinde două momente din desfășurarea acestui joc.



Simulare Life (a) distribuția inițială a agenților în mediul în care sunt prezenți. Toți agenții sunt în starea On

(b) distribuția agenților după 30 cicluri de evoluție

Observații

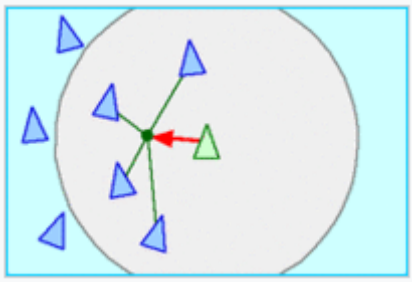
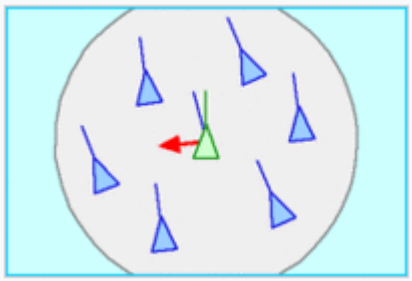
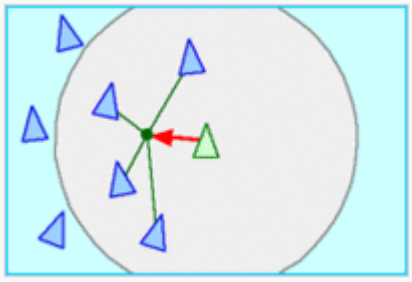
- regulile din Life sunt simple și utilizează numai informații locale. Prin local vom înțelege că starea unui agent este bazată numai pe starea agenților din imediata vecinătate
- evoluția în Life este dictată de configurația inițială (agenți cu stări On sau Off generate aleator) de la care se pleacă.

- Ideea este că avem un sistem simplu compus din reguli simple, care începe într-o stare aleatoare și că evoluția sa care depinde de o stare inițială reflectă posibilitatea de a genera lumi virtual infinite
- Conway a descoperit anumite forme de viaţă pe care el le numea „R-pentomino” care nu puteau să se stabilizeze.
- Cei mai mulţi algoritmi sunt asemănători , se pleacă de la o matrice, în care fiecare celulă este 0 iar unde există o entitate se notează cu 1, se parcurge matricea şi unde se întâlneşte 1 i se verifică cei opt vecini şi se aplică regula.
- Modificări la acest algoritm au venit pentru eficienţă, nu se mai parcurge toată matricea ci doar unde se presupune că ar putea să existe o celulă vie şi unde s-ar putea să apară.
- Un nou tip de algoritm , mult mai eficient decât restul care rezolvă şi problema infinităţii este *HashLife*. Acest algoritm foloseşte funcţii hash care reţin sub modelele care apar în matrice. În general aceste sub modele tind să se repete, de aceea ele sunt reținute in aceeași locaţie. Ca urmare, astfel când este aplicată o regulă, se aplică pe toate aceste modele nu ca în algoritmul anterior , unde fiecare model în parte este tratat particular, astfel viteza creşte semnificativ. Singurul dezavantaj este că HashLife ocupă foarte multă memorie.

II. Modelarea comportării stolurilor de păsări

Modelul a fost propus Craig Reynolds în 1986 cu scopul modelării și simulării comportamentului zborului stolurilor de păsări. Termenul de "boid" corespunde la abrevierea "bird-oid object", care corespunde la păsări ca și obiect. Modelul în care sunt încorporate reguli simple de comportament dă posibilitatea explicării comportamentului emergent (*Teoria evoluției emergente = teorie*

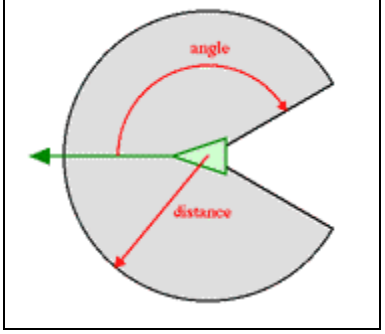
idealistă și metafizică cu privire la procesul dezvoltării, potrivit căreia apariția noilor calități este absolut spontană și imprevizibilă) al mulțimilor de păsări în cazul dat. Regulile care sunt utilizate în contextul acestui model relative la modul de comportare a unui element (pasăre) din mulțimea de elemente de același tip sunt

Regulă		
coeziune		Fiecare tinde să se deplaseze spre mijlocul roiului din care face parte
separare		Evitarea coliziunilor cu vecinii
aliniere		Potrivirea vitezei cu aceea a vecinilor

Fiecare element din mulțime are acces la totalitatea elementelor din mediul în care este prezent. Accesul este limitat la un moment dat numai la un număr mic de elemente din imediata vecinătate. Vecinătatea este caracterizată de o *distanță* (măsurată din centrul boid-ului) și de un unghi , (măsurat de la boid în direcția de zbor). Elementele boid prezente în afara acestei vecinătăți sunt ignorate. Vecinătatea poate fi considerată un model al percepției limitate a unui element

boid, dar de asemenea ca fiind zona în care comportamentul unui boid este influențat de comportamentul elementelor vecine.

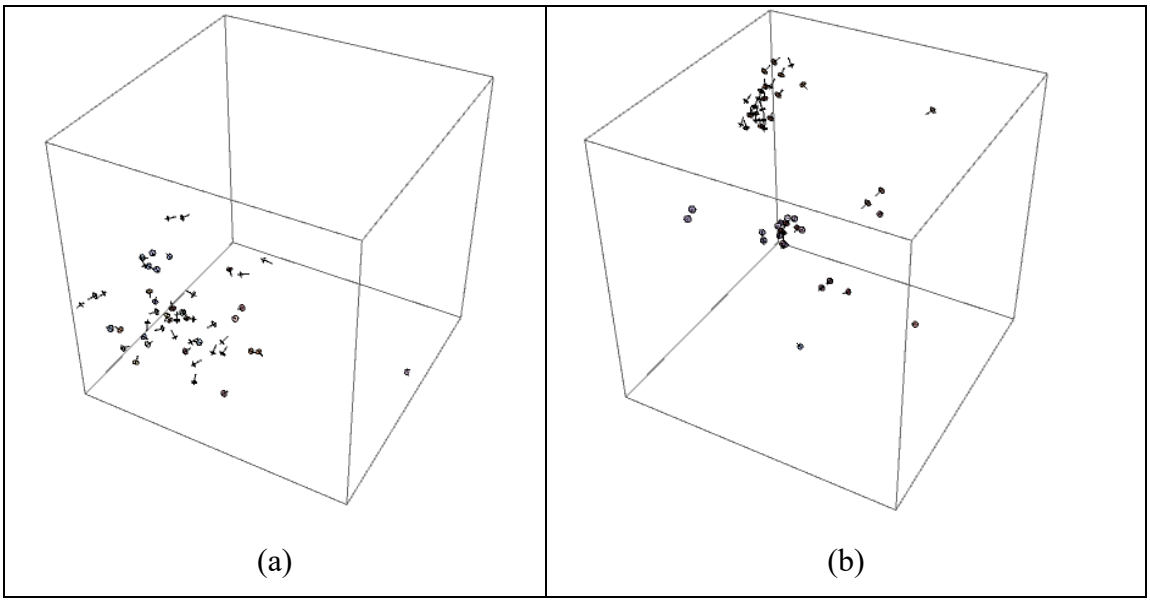
Vecinătate boid



Dacă interpretăm *Boid* ca un agent-based model vom putea considera că fiecare boid este un agent. Agentul utilizat este de tip reactiv unde

- Cele 3 reguli la care se adaugă modul de definire a vecinătății definesc comportarea agentului
- mediul în care acționează *Boid* este definit de o matrice (de dimensiune 2D sau 3D – dacă se modelează deplasarea în trei dimensiuni) în care agenții acționează. Inițial, se generează un număr aleatoriu de elemente de tip boid care se vor amplasa în celulele matricei. În urma acestei generări se va defini poziția inițială de plecare. Aceasta se va actualiza în fiecare pas conform regulilor specificate. În urma actualizării se vor modifica pozițiile elementelor boid din matricea care definește mediul. În contextul acestui mediu se pot defini obstacole (prin blocarea unor elemente din matricea care reprezintă mediul) care să fie evitate de mulțimea de elemente boid.
- starea tuturor agenților luați împreună la un moment dat de timp din durata simulării definește starea modelului (sistemului).

Figura următoare surprinde două momente din desfășurarea simulării comportamentului.



Simulare *Boid* (a) distribuția inițială aleatoare a agenților în mediul în care sunt prezenți.
(b) distribuția agenților după 500 cicluri de evoluție

Agent based epidemic model

Considerăm un model comportamental de tip SEIR (Susceptible Exposed Infectious Recovered). Inițial problema ridicată de un model SEIR (dinamica unei epidemii)a fost rezolvată utilizând ecuații diferențiale. Aceste tratează problema în caz general fără să țină cont de:

- spațiul în care apare epidemia,
- de modul în care acesta influențează răspândirea acesteia (comunicarea între persoane este dependentă de amplasarea acestora într-un spațiu dat)
- de particularitățile individuale ale unei persoane din spațiul respectiv.

Cu alte cuvinte în prezent nu cunoaștem cum ecuațiile diferențiale globale care pot descrie comportamentul unei anumite epidemii care se desfășoară într-un spațiu dat și într-un context dat. Acesta este motivul

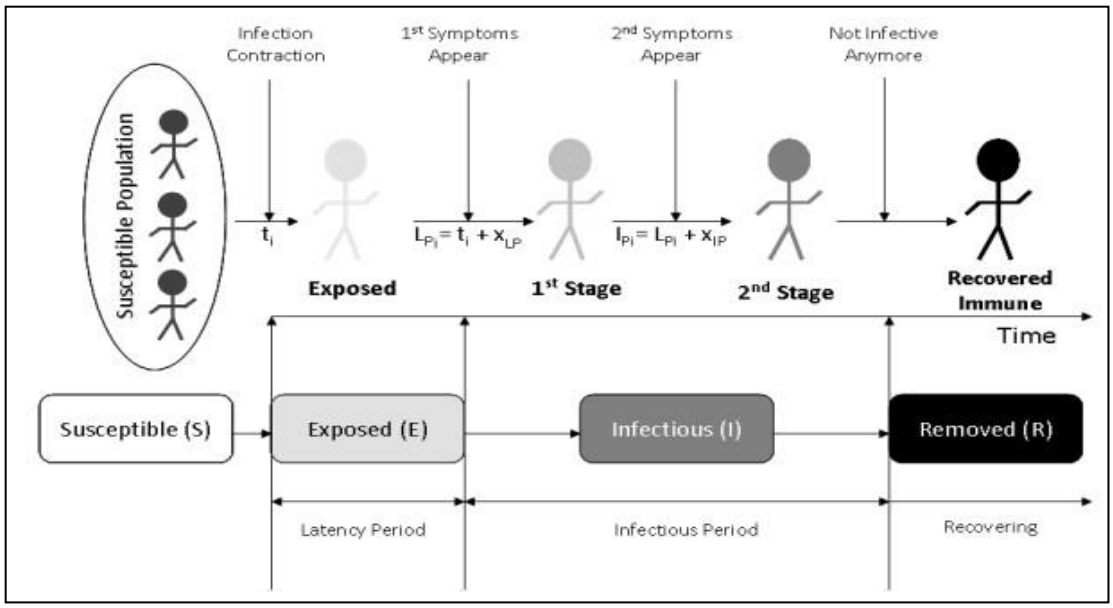
pentru care în prezent sunt utilizate modele cu agenți inteligenți cu stări (cognitivi)

Vom considera în continuare un caz ipotetic al unei epidemii care prezintă următoarele caracteristici:

- Considerăm o populație de 10,000 persoane care domiciliază într-o arie de 10 x 10 km. Aceste persoane apar în zonă uniform.
- O persoană își cunoaște vecinii pe o zonă de 1 km față de punctul în care locuiește. Nu cunoaște persoanele care sunt în afara acestei.
- Inițial 10 persoane sunt infectate aleatoriu. Restul persoanele sunt susceptibile de a fi infectate, ne existând persoane imune la agentul epidemic.
- Dacă o persoană infectată ia contact cu o altă persoană susceptibilă de a fi infectată probabilitatea de transmisie a bolii este de 0,1.
- Dacă o persoană a fost infectată, boala este într-o *fază latentă* cu o durată de 3 până la 6 zile. În această perioadă (pe care o vom numi *exposed*) nu infecta alte persoane cu care intră în contact.
- Durata bolii după faza latentă fază pe care o vom numi *fază de infecție*) este uniform distribuită între 7 și 15 zile
- În timpul fazei de infecție o persoană poate contacta maxim până la 5 persoane pe zi.
- Când o persoană se recuperează devine imună. Imunitatea este câștigată o perioadă limitată de timp, care se întinde pe o perioadă de 30 până la 70 de zile.

Stările specificate anterior pot fi văzute în diagrama de stări care urmează. Notațiile utilizate sunt L_{Pi} : faza latentă, l_{Pi} : faza de infectare, t_i : prima zi în care persoana este expusă la virus pentru prima dată, X_{LP} : numărul de zile pentru o

persoană care boala în care aceasta este activă, X_{IP} : numărul de zile, pentru o persoană care și-a câștigat imunitatea la terminarea boli este imună.

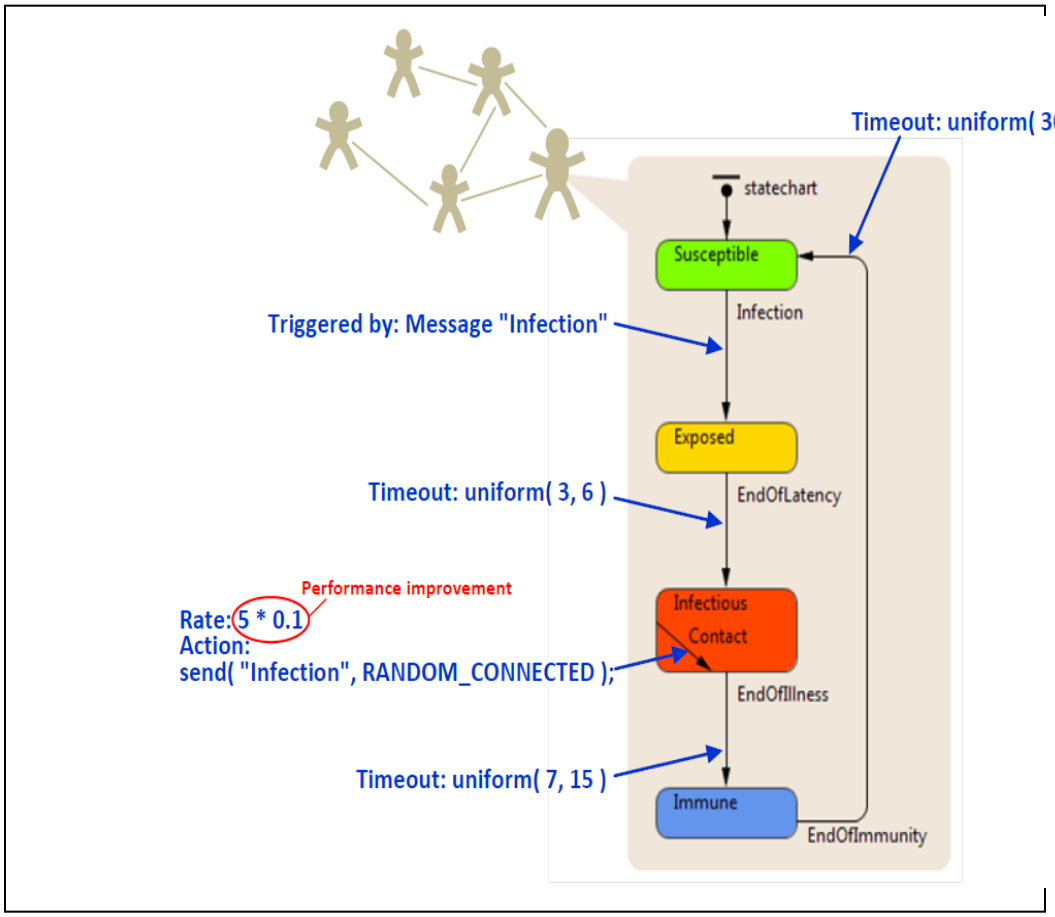


Modelul care se utilizează în cazurile în care sunt studiate sisteme în care apar relații și schimburi de informații între componentele sistemul pe de o parte și între acestea și mediul înconjurător este cel de tip *agent cu stări (cognitiv)*.

Comportamentul agentului

Dacă interpretăm *SIER* ca un model de tip *agent cu stări* , vom putea considera că fiecare persoană este un agent. Agentul utilizat este de tip agent cu stări unde

- Comportamentul agentului este descris de o diagramă de stare. O astfel de diagramă (diagrama este construită în contextul platformei de modelare AnyLogic) este prezentată în figura următoare



Cele 4 stări prezente în diagramă corespund celor patru faze de evoluție a bolii.

1. Inițial persoana este în starea **Susceptibil** , stare în care rămâne până când este infectată. Infectarea poate avea loc numai în timpul contactului cu o altă persoană (de tip vecin) . Acest contact, este modelat prin intermediul unui mesaj care este trimis de la un agent la altul.
2. Tranziția din starea **Susceptibil** în starea **Expus** se face în momentul primirii mesajului prin intermediul căruia se modelează transmiterea virusului.
3. "**Infecție**" . O dată ce o persoană este infectat se trece la calcularea duratei de incubație a maladiei. Acest aspect presupune calcularea valorii pentru **EndOfLatency**, mărime care specifică momentul în care boala devine activă și terminarea perioadei de incubație. Agentul trece în starea **Expus** –

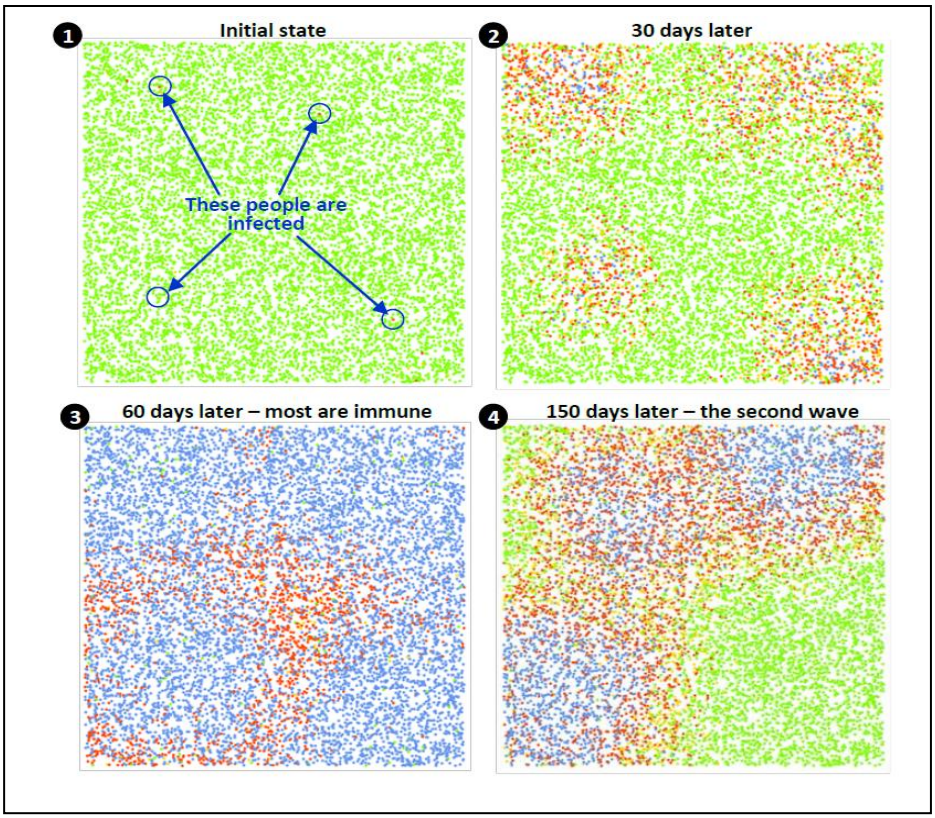
corespunzătoare fazei în care boala este activă. Timpul petrecut în această fază este de [3, 6] zile. Valoarea, se obține generând o valoare uniform distribuită în intervalul specificat.

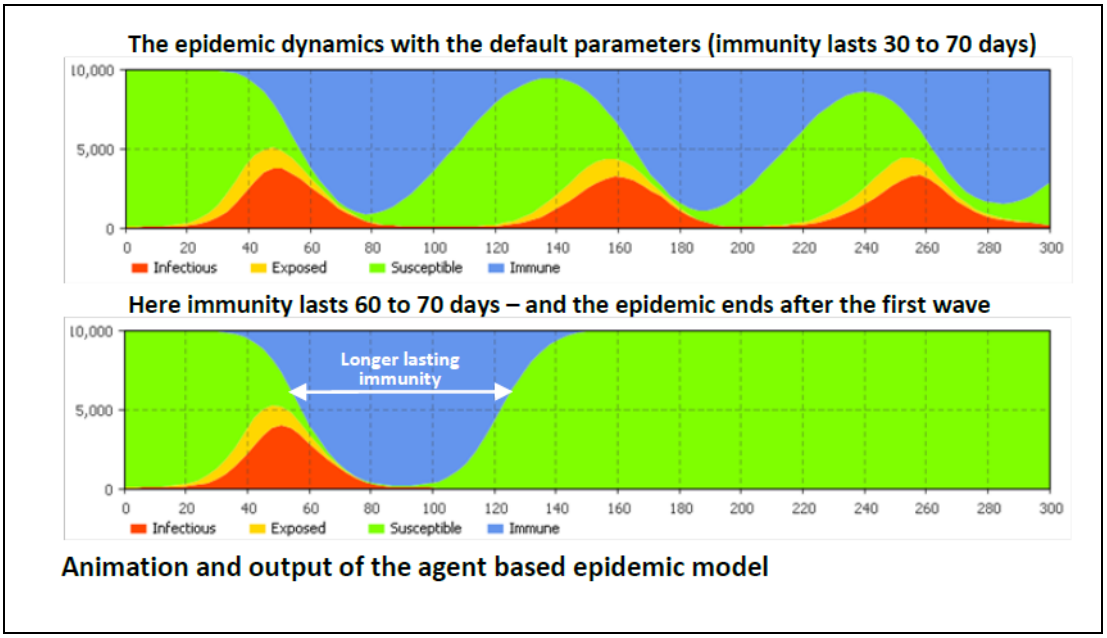
4. Atunci când persoana este în faza **Infecție** poate lua periodic contact cu alte persoane din aria vecină definită. Acest aspect este modelat printr-o tranziție internă a fazei **Infecție** care este activată ciclic cu o frecvență specifică fiecărui agent (persoană) în parte. În momentul când se activează acest tranziție (o numim **Contact**) se trimite un mesaj de tip **Infecție** spre un alt agent. Mesajul conține si o informație de tip șansă de a infecta agentul care primește mesajul. Pentru cazul dat această șansă este de 0,1 %.

Definirea mediului (ariei în care se desfășoară epidemia)

- Spațiul în care se desfășoară epidemia (10 km x 10 km) se poate defini ca o matrice de dimensiune de 1000 x 1000 considerând că un element al matricei va defini un spațiu de 100 metri x 100 metri.
- Se populează spațiul cu un număr de 10,000 de persoane.
- Se infectează aleatoriu 10 persoane prin trimiterea de mesaje de tip **Infecție la începutul simulării.**
- Se lansează operația de simulare pentru o perioadă dată.

O dinamică a modului în care evoluează epidemia este dată în figura de mai jos





Bibliografie

[1] Shoham, Yoav; Leyton-Brown, Kevin (2008). Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations. Cambridge University Press

[2] Sindiy, O., DeLaurentis D., Stein W., "An Agent-based Dynamic Model for Analysis of Distributed Space Exploration Architectures," The Journal of the Astronautical Sciences (JAS), Vol. 57, No. 3, 2011.
[3] North, M. J. and C. M. Macal. 2011. “Product Design Patterns for Agent-Based Modeling.” In Proceedings of the 2011 Winter Simulation Conference, edited by S. Jain, R. R. Creasey, J. Himmelspach, K.P. White, and M. Fu. Piscataway, New Jersey: Institute of Electrical and Electronics Engineers, Inc.

8. Modele corelaționale (regresionale) – Modele cauză / Efect.

În multe situații, sistemul care definește un fenomen din lumea reală (de exemplu fenomene meteo, tehnice – caracteristici funcționale ale unor aparate electronice, medicale – propagarea unei epidemii, sociale – promovarea unui produs, fenomene de tip imigraționiste etc.) este reprezentat de un set de entități a căror mod de interacțiune între ele și cu lumea înconjurătoare nu este posibil de a fi definit. Cu alte cuvinte, nu este posibil de reprezentat sistemul analizat prin ecuații și de asemenea nu este posibil să avem o desfășurare clară a succesiunii activităților care au loc. În aceste cazuri singura posibilitate care rămâne, este aceea ca sistemul asociat fenomenului să fie descris de un set de date, care în foarte multe cazuri are un caracter strict numeric. Tehnica utilizată în astfel de cazuri poartă denumirea de *Analiză corelațională*. *Modelele care apar prin aplicarea acestei tehnici sunt cunoscute sub denumirea de modele corelaționale (regresionale) sau modele de tip cauză / efect.*

Exemplu

Considerăm un set de date de volum ***n***. Fiecare element din setul de date poate fi caracterizat de un ansamblu de atribute. De exemplu (tabel 8.1), în setul de date relativ la performanţele sistemelor de calcul aceste atribute sunt: memoria principala, memorie cache, etc. În cele ce urmează convenim să denumim setul de atribute ca reprezentând variabile. Acestea vor caracterizează sistemul respectiv și va corespunde unei situații în care se găsește sistemul în cauză.

	Cycle time (ns)	Main memory (Kb)		Cache	Channels		Performance
	MYCT	MMI	MMA	CACH	CHMIN	CHMAX	PRP
1	125	256	6000	256	16	128	198
2	29	8000	3200	32	8	32	269
...							
208	480	512	8000	32	0	0	67
209	480	1000	4000	0	0	0	45

MMIN: minimum main memory în kilobytes (integer)
MMAX: maximum main memory în kilobytes (integer)
CACH: cache memory în kilobytes (integer)
CHMIN: minimum channels în units (integer)
CHMAX: maximum channels în units (integer)
PRP: published relative performance (integer)

În astfel de situații MODELUL care va defini sistemul va fi dat de un model matematic – în cazul general o funcție - care va rezulta din setul de măsurători avute la dispoziție.

Analiza unui set de date cu această structură care să conducă la obținerea unui model, se poate efectua din următoarele puncte de vedere:

1. ***din punctul de vedere a unei singure variabile*** **a cărei valoare este influențată de restul variabilelor din setul de date. D**e exemplu, aceasta poate fi un atribut de forma: memoria principala ce caracterizează un sistem de calcul a cărei mărime este condiționată de restul atributelor din setul de măsurători.
2. ***fie din punctul de vedere al ansamblului de atribute*** ce caracterizează un sistem, caz în care modelul surprinde relațiile care apar între variabilele ce caracterizează sistemul în ansamblu. De exemplu relații de intercondiționare între memoria principala, memorie cache, etc.,

Analiza corelaţionala permite obținerea unor modele analitice ce definesc sistemul care a generat setul de date.

Pentru setul de date prezent în tabelul 8.1 modelul (clasificatorul) care poate fi obţinut este de forma:

PRP = -55.9 + 0.0489 MYCT + 0.0153 MMIN + 0.0056 MMAX
+ 0.6410 CACH - 0.2700 CHMIN + 1.480 CHMAX

Este de remarcat faptul că devine posibila caracterizarea globala a setului de date ca și obținerea de informații relative la un element necunoscut, care nu face parte din set, dar are aceeași structura cu datele din acesta.

Mai exact cunoscând :

MYCT, MMIN, MMAX, CACH, CHMIN, CHMAX

Se poate determina **PRP**

Pentru construirea unui model al acestor variabile se parcurg două etape de analiză :

(A) Analiza regresională, care se ocupă cu descrierea și *cercetarea legăturilor (dependenţei)* care există intre variabilele ce caracterizează elementele setului analizat. Rezultatul este un model matematic al fenomenului în cauză,

(B) Calculul coeficientului de corelaţie, care se ocupă cu *determinarea gradului de dependenţă* care există intre variabilele amintite mai sus. Acest coeficient va specifica acuratețea modelului construit

Analiza regresională

Construieşte un model al dependenţei dintre variabile. Aceasta legătură dintre variabile şi, deci, implicit dintre fenomenele care au avut ca efect apariţia unor anumite valori pentru variabilele în cauză, se descrie printr-o ecuație analitică care poartă numele de *funcţie de regresie.*

Datorită faptului ca fenomenele au cauze multiple, în mod normal la cercetarea legăturii dintre ele nu se cunosc toţi factorii. Prin urmare, va trebui să ţinem seama ca ecuaţia regresiei se construiește în anumite condiții simplificate.

Dacă notăm

$x_1, x_2, \dots x_m, y$ *setul de variabile ce caracterizează un element al eşantionului în care*

$\{ x_i \}_{i=1}^{n}$ *caracterizează fenomenul cauză, iar*

y fenomenul efect,

modelul dependenţei dintre cauză şi efect,

deci funcţia regresională este de forma :

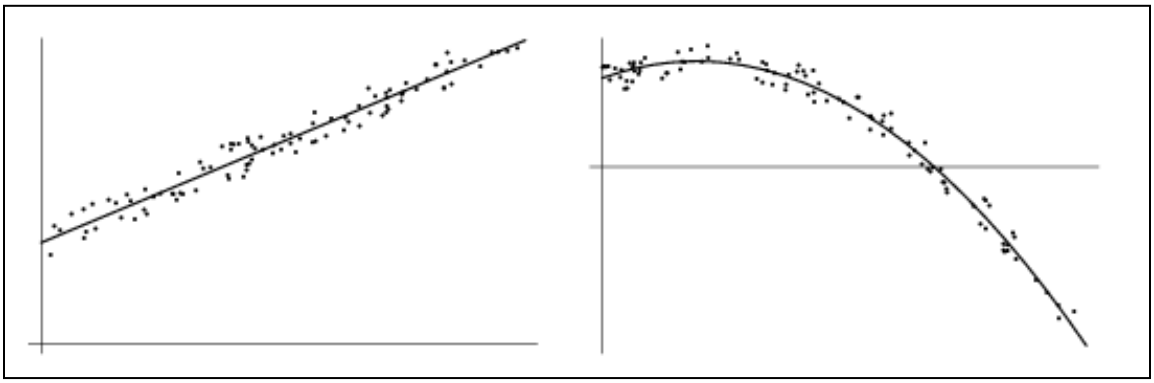
$$y = f (x_1, x_2, \dots , x_m)$$

Sunt prezente două categorii de modele

A) Modele corelaționale liniare

B) Modele corelaționale polinomiale

În figura următoare sunt ilustrate cele două tipuri de modele



A. Modele corelaţionale liniare

Exprimă legătura dintre doua variabile ce caracterizează fiecare element al eşantionului. Funcţia de regresie are două aspecte :

a) Dacă *x* caracterizează fenomenul cauză, iar *y* fenomenul efect, funcţia de regresie este :

$$y = a_0 + a_1 x$$

b) Dacă *y* caracterizează fenomenul cauză, iar *x* fenomenul efect, funcţia de regresie este :

$$x = b_0 + b_1 y$$

În primul caz, funcţia poartă numele de regresia liniară în x a lui y , iar în cel de-al doilea, regresia liniară în y a lui x.

Caracteristici :

- modelul este reprezentat printr-o linie dreaptă (dreapta de regresie –fig. 8.3) ;
- valoarea variabilei efect este funcție de un singur factor, toți ceilalți factori fiind consideraţi ca mărimi constante reprezentate prin valori medii și sunt exprimați prin coeficienţii ecuației ;
- valorile ajustate ale variabilei efect sunt, de asemenea, mărimi medii care se notează de obicei cu y_x și respectiv, x_y ;
- corelația dintre variabilele cauza și efect este directă dacă odată cu creșterea valorii variabilei cauză creste și mărimea variabilei efect și inversă în caz contrar .

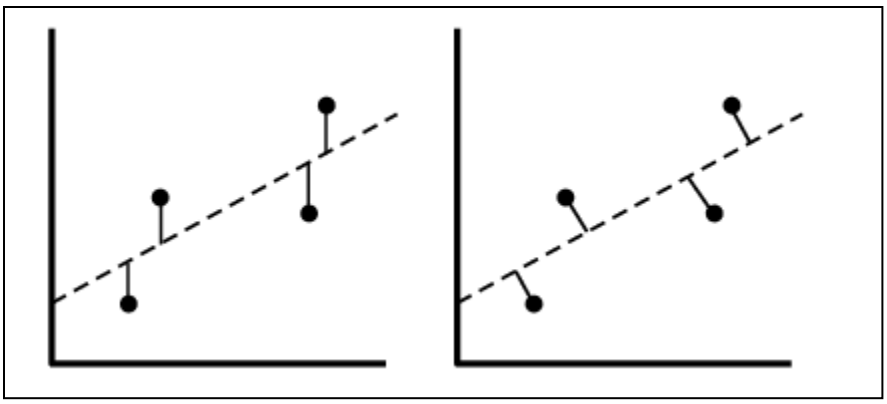
Determinarea coeficienţilor dreptei de regresie

Vom determina aceşti coeficienţi numai pentru un set de date în care un element este caracterizat de doua atribute (x și y), deci modelul (ecuaţia regresională) va fi de forma :

$$y = a_0 + a_1 x$$

Coeficienţii a_0 , a_1 se determină din condiția

- ca suma abaterilor valorilor reale ale lui y față de valorile calculate y_x sa fie minimă (vezi fig. 8.2 a).
- ca suma distanțelor de la valorile setului de măsurători la dreapta de regresie să fie minimă (vezi fig. 8.2.b)
-



(a) (b)

Fig. 8.2 Tehnici de calcul a distanțelor dintre model și setul de măsurători

Vom calcula această distanță în varianta (a).

Dacă notăm cu ***S*** suma a cărei minim se caută, avem :

$$S = \sum \left(y_x - \bar{y} \right)^2 = \min$$

sau

$$S = \sum \left(a_0 + a_1 x - \bar{y} \right)^2 = \min$$

unde $\bar{y}$ reprezintă valoare medie a valorilor y_x Pentru a determina minimul lui ***S*** calculăm derivatele parțiale ale acesteia funcţie de a_0 și a_1

$$\frac{\partial S}{\partial a_0} = 2\sum \left(a_0 + a_1 x - y \right)$$

$$\frac{\partial S}{\partial a_1} = 2\sum \left(a_0 + a_1 x - y \right) x$$

Anulăm derivatele parțiale :

$$\sum \left(a_0 + a_1 x - y \right) = 0$$

$$\sum \left(a_0 x + a_1 x^2 - yx \right) = 0$$

de unde rezultă sistemul :

$$n a_0 + a_1 \sum x = \sum y$$

$$a_0 \sum x + a_1 \sum x^2 = \sum yx$$

Rezolvând sistemul se obține :

$$a_0 = \frac{\sum y \sum x^2 - \sum x \sum yx}{n\sum x^2 - \left(\sum x\right)^2}$$

$$a_1 = \frac{n\sum xy - \sum x \sum y}{n\sum x^2 - \left(\sum x\right)^2}$$

Similar, pentru ecuaţia regresională :

$$x = b_0 + b_1 y$$

se obține :

$$nb_0 + b_1 \sum y = \sum x$$

$$b_0 \sum y + b_1 \sum y^2 = \sum xy$$

de unde :

$$b_0 = \frac{\sum x \sum y^2 - \sum y \sum yx}{n\sum y^2 - \left(\sum y\right)^2}$$

$$b_1 = \frac{n\sum xy - \sum x \sum y}{n\sum y^2 - \left(\sum y\right)^2}$$

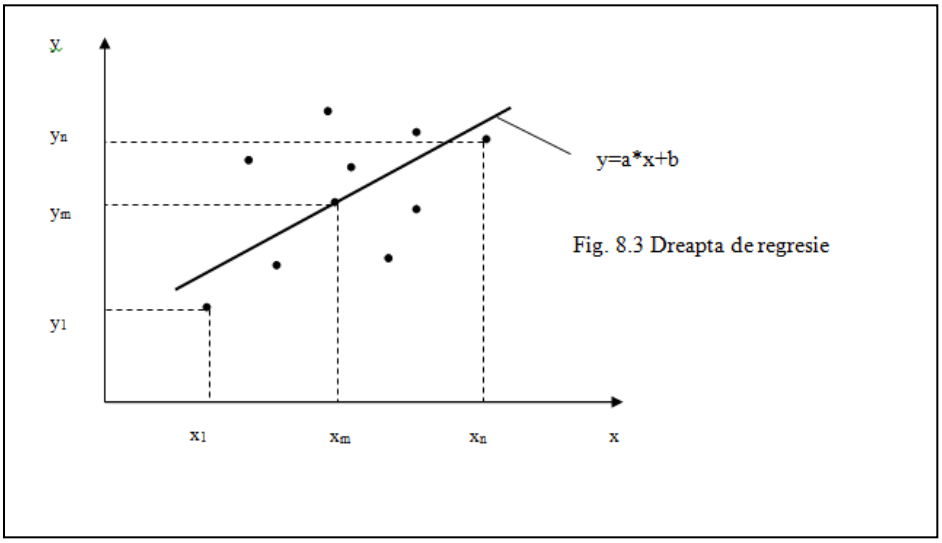


Fig. 8.3 Dreapta de regresie

Coeficientul de corelație

Definește calitatea modelului (cât de bun este acesta). Este definit de un număr care măsoară gradul de legătură (împrăștiere – dispersie) între variabile.

Se determină astfel :

Erorile standard de estimare pot fi considerate o măsură a gradului de legătură dintre două variabile deoarece :

- o valoare mare (indică o împrăștiere mare a punctelor față de dreapta de regresie) va indica o legătură slabă (asociere) intre cele două variabile ;

- o valoare mică (indică o împrăștiere mică a punctelor fată de dreapta de regresie) va indica o legătura mai puternică între cele două variabile.

Dezavantajul constă în faptul că nu pot fi comparate direct între ele, deoarece ele se măsoară în unități ale variabilei ***x*** sau ***y***, care pot fi diferite de la caz la caz. Din acest motiv, se recurge la o măsură relativă raportând eroarea standard de estimare la abaterea medie pătratică.

Raportul astfel obținut :

$$\frac{S_y}{\sigma_y} \text{ sau } \frac{S_x}{\sigma_x}$$

are următoarele avantaje :

- poate fi exprimat în procente, fiind adimensional ;

- dacă legătura dintre cele două variabile este perfectă, S_y sau S_x vor fi egale cu zero și raportul va fi egal cu zero ;

- dacă asocierea este foarte slabă, valoarea erorii standard va crește până când la limită va fi egală cu abaterea medie pătratică, caz în care raportul este egal cu 1

Deoarece raportul are o valoare 0 pentru o legătură perfectă, și 1 pentru absenta oricărei legături, s-a recurs la definirea unei măsuri a cărei valoare să varieze direct proporțional cu gradul de asociere.

Se definește *coeficientul de corelație* ca fiind :

$$r_{yx} = 1 - \frac{S_y^2}{\sigma_y^2} = 1 - \frac{\sum (y - y_c)^2}{\sum (y - \bar{y})^2}$$

$$r_{xy} = 1 - \frac{S_x^2}{\sigma_x^2} = 1 - \frac{\sum (x - x_c)^2}{\sum (x - \bar{x})^2}$$

cei doi coeficienți caracterizând gradul de asociere dintre ***y*** și ***x*** si, respectiv, ***x*** și ***y*** (corectitudinea modelelor corelaţionale $y = a_0 + a_1 x$ și respectiv $x = b_0 + b_1 y$)

Caracteristici :

- ia valori între 0 și 1 ;

- dacă corelația dintre ***x*** și ***y*** este directă, coeficientul de corelație primește semnul '+' și respectiv, semnul '-' dacă corelația dintre x și y este inversă ;

- în practică se consideră semnificative acele modele pentru care coeficientul de corelație are o valoare mai mare de 0.7.

Pentru exemplul dat anterior, gradul de asociere dintre y și x, respectiv corectitudinea modelului corelațional $y = a_0 + a_1 x$ se calculează astfel :

x	y	y_c	$y - y_c$	$(y - y_c)^2$	y - y	$(y - y)^2$
1	1	1.18	-0.18	0.324	-4	16
3	2	2.45	-0.45	0.202	-3	9
4	4	3.10	0.90	0.810	-1	1
6	4	4.36	-0.36	0.130	-1	1
8	5	5.63	-0.63	0.397	0	0
9	7	6.27	0.73	0.533	2	4
11	8	7.54	0.46	0.212	3	9
14	9	9.45	-0.45	0.202	4	16

$$\bar{y} = 5$$

$$S_y = 0.6$$

$$\sigma_y = \frac{\sum (y - \bar{y})^2}{N} = \frac{56}{8}$$

$$r_{yx} = 1 - \frac{0.36}{\frac{56}{8}} = 0.99$$

Concluzie

Între x și y exista o asociere strânsă, modelul corelaţional

$$y = (6/11) + (7/11)x$$

a) poate fi utilizat în calculul valorilor ***y*** pentru o valoare ***x*** dată ;

b) dacă ***x*** caracteriza elementele altui set de date se putea trage concluzia ca ambele aparțineau unor date cu aceeași structura.

Observații privind analiza corelaţională

Analiza corelaţională reprezintă un instrument al analizei relațiilor și legăturilor dintre elementele unui set de date. Deși tehnicile analizei corelaţionale sunt obiective, bazate pe statistică și probabilități, rezultatele pot duce la deformări grosolane a realității dacă nu se aplică corect tehnicile de analiză.

Condițiile care trebuiesc respectate sunt :

- deoarece construirea modelului matematic este legată inevitabil de o serie de simplificări (nu sunt incluse în model toți factorii care influențează fenomenul studiat) este necesară reținerea numai a factorilor cu influenta semnificativă asupra variabilei dependente ;

- se recomandă utilizarea acelor variabile care se exprimă prin unități de măsură relative, deoarece sunt mai puțin supuse deformărilor pe care le incumba unitățile de măsură ;

- numărul de elemente trebuie să fie suficient de mare pentru a se evita obținerea unor modele relaţionale nereprezentative (caracterizate de un coeficient de corelaţie mare, dar incorect).

B. Modelul corelațional multiliniar

În cazul existenţei unor legături multiple (proprietatea P măsurată prin valorile Y_i depinde de M factori măsurabili prin mărimile X_{ij}, cu j=1,2,...,M, (datele statistice disponibile pentru aceasta sunt prezentate în tabelul 8.3)

Date în setul analizat	x_1	x_2	x_3	.....	x_M	Y
1	x_{11}	x_{21}	x_{31}	.....	x_{M1}	Y_1
2	x_{12}	x_{22}	x_{32}	.....	x_{M2}	Y_2
.....	.....	.....	.....	.....	.....	.....
N	x_{1N}	x_{2N}	x_{3N}	.....	x_{MN}	Y_N

Tabelul 8.3 Datele statistice utilizabile în cadrul modelului regresional multiliniar

Dacă se analizează corelarea dintre mai multe variabile în acest caz se utilizează o ecuație regresională multidimensională de forma :

$$Y = a + b_1 x + b_2 x_2 + ... + b_M x_M = \sum_{j=1}^{M} b_j x_j$$

Subscriptul *J* (și *M*) se referă la dimensiunea modelului matematic și nu la variabile experimentale pe care le vom presupune în număr de *N*. în cadrul modelului regresional multiliniar se presupune că x_J sunt cunoscute precis, iar *Y* (estimat ca Y) sunt afectate de erori aleatoare, fiind distribuite normal în jurul suprafeței de regresie cu o variabilă constantă. Se observă că în locul dreptei de regresie (*M=1*) vom avea o suprafață de regresie (*M=2*) sau o hipersuprafață (*M>2*). în cazul general, valorile numerice x_J ale variabilelor independente (variabile predictor sau factori) F_J sunt raportate la axele de coordonate (f_J) ale spațiului factorilor, iar hipersuprafața poate fi privită ca o suprafață de răspuns ce urmează a fi construită

Pentru găsirea coeficienţilor de regresie şi a constantei a se aplică metoda celor mai mici pătrate. Condiţia de minim se reduce la anularea derivatelor parţiale:

$$\begin{cases} \dfrac{\partial S}{\partial a} = 0 \\ \dfrac{\partial S}{\partial b_j} = 0 \end{cases}$$

se obține:

$$\begin{cases} a \cdot n + b_1 \cdot \sum X_{i1} + b_2 \cdot \sum X_{i2} + ... + b_M \cdot \sum X_{iM} = \sum Y_i \\ a \cdot \sum X_{i1} + b_1 \sum X_{i1}^2 + b_2 \cdot \sum X_{i1} \cdot X_{i2} + ... + b_M \cdot \sum X_{i1} \cdot X_{iM} = \sum X_{i1} \cdot Y_i \\ a \cdot \sum X_{i2} + b_1 \sum X_{i1} \cdot X_{i2} + b_2 \cdot \sum X_{i2}^2 + ... + b_M \cdot \sum X_{i2} \cdot X_{iM} = \sum X_{i2} \cdot Y_i \\ \\ a \cdot \sum X_{iM} + b_1 \sum X_{i1} \cdot X_{iM} + b_2 \cdot \sum X_{i2} \cdot X_{iM} + ... + b_M \cdot \sum X_{iM}^2 = \sum X_{iM} \cdot Y_i \end{cases}$$

Acest sistem se poate rezolva prin metode clasice (Gauss, Jacobi, Gauss-Seidel) sau se determină coeficienţii de regresie printr-o metodă matricială. Sistemul liniar de mai sus se poate scrie

$$(\mathbf{X}^T\mathbf{X})\mathbf{A} = \mathbf{X}^T\mathbf{Y}$$

unde elementele matricelor **X** şi **Y** sunt mărimile măsurate X_{ij} pentru variabilele independente, având elementele primei coloane egale cu unitatea, respectiv Y_i pentru variabila dependentă :

$$\mathbf{X} = \begin{Vmatrix} 1 & X_{11} & X_{12} & X_{1M} \\ 1 & X_{21} & X_{22} & X_{2M} \\ & & & \\ 1 & X_{N1} & X_{N2} & X_{NM} \end{Vmatrix} \qquad \mathbf{Y} = \begin{Vmatrix} Y_1 \\ Y_2 \\ \\ Y_N \end{Vmatrix}$$

X^T reprezintă transpusa matricei X, iar A este matricea coeficienţilor de regresie. Valorile acestora din urmă se obţin efectuând următoarele operaţii matriciale :

$$\mathbf{A} = (\mathbf{X}^T\mathbf{X})^{-1} \cdot \mathbf{X}^T\mathbf{Y}$$

Se notează :

$$\mathbf{C} = (\mathbf{X}^T\mathbf{X})^{-1}$$

Elementele diagonale ale matricei **C** sunt varianţele coeficienţilor de regresie, iar elementele ne diagonale covarianţele lor. În cazul corelărilor multiliniare apare problema importanţei variabilelor în problema studiată. Situaţia în care se cunoaşte apriori importanţa anumitor variabile este destul de rară. De aceea este recomandată transformarea variabilelor astfel încât fiecare să aibă o pondere egală (procedeu numit autoscalare). În cazul în care distribuţia valorilor variabilelor este foarte abruptă (de exemplu multe valori mici şi câteva valori foarte mari) este recomandabilă corectarea lor (de fapt o încercare de grupare) prin logaritmare, extragerea rădăcinii pătrate sau utilizarea altor transformări.

Pentru modelele multiliniare se defineşte coeficientul de corelaţie totală, care este un indicator normat al intensităţii corelaţiei între variabila dependentă şi toate variabilele independente. Relaţia de definiţie este :

$$R_{Y,X_1,X_2,\ldots,X_M} = \frac{\sum_i (Y_i - \overline{Y}) \cdot (\hat{Y}_i - \overline{Y})}{\sqrt{[\sum_i (Y_i - \overline{Y})^2] \cdot [\sum_i (\hat{Y}_i - \overline{Y})^2]}}$$

Şi în cazul corelării multiple se defineşte coeficientul de determinare multiplă sau totală, care este egal cu pătratul coeficientului de corelaţie totală.

Acest parametru ne arată cât din variaţia variabilei dependente Y este explicată de variaţia simultană a celor M variabile independente:

$$d_{Y,X_1,X_2,...,X_M} = R^2_{Y,X_1,X_2,...,X_M}$$

Pentru stabilirea influenţei separate a factorilor asupra proprietăţii cercetate este necesară descompunerea coeficientului de determinaţiei totale în coeficienţi de determinaţie parţială. Pentru un factor oarecare j, coeficientul determinaţiei parţiale se defineşte:

$$d_{pj} = \frac{b_j \cdot [\sum_i (X_{ij} - \overline{X}_j) \cdot (Y_i - \overline{Y})]}{N \cdot s_Y^2}$$

Fiecare coeficient de determinaţie parţială arată ponderea factorului respectiv în variaţia proprietăţii studiate. Suma tuturor coeficienţilor parţiali trebuie să fie egală cu valoarea coeficientului total, constituind în acest fel şi un mijloc de control al calculelor. Rădăcina pătrată a coeficienţilor de determinaţie parţială poartă numele de coeficienţi de corelaţie parţială.

În relaţia anterioară pătratul mărimii s_Y reprezintă dispersia valorilor Y_i în jurul dreptei de regresie (mai corect în jurul hiperplanului de regresie) şi se defineşte conform relaţiei:

$$s_Y^2 = \frac{\sum_i (Y_i - \hat{Y}_i)}{N - K}$$

unde N reprezintă numărul de determinări, iar K numărul de coeficienţi care este egal cu M+1. Fiecare coeficient de determinare parţială arată ponderea factorului respectiv în variaţia proprietăţii studiate. Suma tuturor coeficienţilor trebuie să fie egală cu valoarea coeficientului total, constituind în acest fel şi un mijloc de verificare a calculelor.

În cazul modelelor corelaţionale, când proprietatea urmărită este influenţată de mai mulţi factori este util să se calculeze şi coeficienţii de intercorelare, luându-se în general în calcul o dependenţă liniară. Aceşti coeficienţi ne arată dacă există o legătură între variabilele independente sau dacă acestea sunt ortogonale.

$$r_{(j,k)} = \frac{\sum_i (X_{ij} - \overline{X}_j) \cdot (X_{ik} - \overline{X}_k)}{\sqrt{[\sum_i (X_{ij} - \overline{X}_j)^2] \cdot [\sum_i (X_{ik} - \overline{X}_k)^2]}}$$

Evident nu se poate exclude o dependență neliniară. Este de dorit ca aceşti coeficienţi să fie cât mai apropiaţi de valoarea zero. Dacă acest lucru nu se întâmplă este utilă găsirea altor mărimi cu ajutorul cărora să se încerce reconstruirea modelului.

Calitatea și stabilitatea ecuațiilor corelaţionale (multiliniare)

Valoarea coeficientului de corelare, r , oferă o primă indicaţie asupra calităţii
Corespondenta dintre valorile **r** și calitatea ecuației regresionale este dată în Tabelul 8.3 :

Coeficientul de corelare, **r**	Calitatea Corelării
0,90 - 1,00	Excelentă foarte bună
0,80 - 0,90	Buna
0,75 - 0,80	Satisfăcătoare
0,75	Slabă
< 0,75	Nesemnificativă

Tabelul 8.3. Criterii pentru calitatea ecuaţiei regresionale

Coeficienţii de corelare astfel calculaţi reflectă, în general, nu numai variația caracteristicilor cantitative măsurate, ci și proprietățile unităților de observare.

Acest aspect capătă o importantă deosebită atunci când încercăm să lămurim factorii cauzali ai legăturilor considerate.

Exemplu.

Modelarea regresională a fenomenului "accident rutier"

Prezentarea problematicii

Informaţiile care fac subiectul acestei analize reprezintă un eşantion (de mărime 19 elemente) rezultat din selecţia din setul de documente de tip „*Înştiinţare – Declaraţie eveniment*" care se completează în momentul producerii unui accident rutier la firma (ARDAF) unde este asigurat autoturismul implicat în accident.

Structura informaţiilor de tip „accident rutier"

Informaţiile care fac subiectul acestei analize reprezintă un eşantion (de mărime 19 elemente) rezultat din selecţia din setul de documente de tip „*Înştiinţare – Declaraţie eveniment*" care se completează în momentul producerii unui accident rutier la firma (ARDAF) unde este asigurat autoturismul implicat în accident.

Structura de date

Structura unei obiect din baza de date este prezentata în cele două figuri de mai jos

Relation: ARDAF_3 nominal

No.	Sex Nominal	Ora accident Numeric	Lumini intalnire Nominal	Viteza vehicol condus de mine Numeric	Viteza vehicol condus de celalalt Numeric	Codificare cauze accident nominal Nominal	Conditii de vizibilitate Nominal	Stare carosabil Nominal
1	M	17.0						
2	M	20.0						
3	M	11.3						
4	F	4.0						
5	F	10.3						
6	F	5.0						
7	M	19.15						
8	M	15.45						
9	M	11.2						
10	M	13.0						
11	M	17.2						
12	F	22.0						
13	M	11.4						
14	M	13.0						
15	F	12.0						
16	M	14.0						
17	M	10.3						
18	M	18.3						
19	M	7.3						

Accidentul s-a produs cu implicarea Nominal	Accident s-a datorat coliziuni Nominal	Varsta Numeric	Ziua Accident Nominal	Luna Accident Numeric	Vechimea in Conducere Numeric	SCOR AVARII Numeric
B	C	26.0	Monday	12.0	84.0	11.0
A	F	42.0	Friday	10.0	25.0	0.0
B	C	24.0	Wednesday	1.0	26.0	9.0
B	C	50.0	Saturday	11.0	168.0	15.0
B	A	34.0	Monday	12.0	19.0	2.0
A	C	26.0	Saturday	11.0	25.0	7.0
A	A	45.0	Wednesday	9.0	20.0	4.0
B	C	24.0	Tuesday	10.0	23.0	7.0
B	B	30.0	Saturday	10.0	13.0	5.0
B	F	31.0	Wednesday	12.0	68.0	3.0
B	F	38.0	Friday	11.0	62.0	6.0
A	A	22.0	Thursday	1.0	47.0	2.0
B	A	31.0	Monday	9.0	58.0	4.0
A	C	30.0	Tuesday	10.0	61.0	4.0
B	C	31.0	Sunday	11.0	17.0	3.0
B	A	45.0	Saturday	12.0	117.0	2.0
B	C	48.0	Friday	12.0	43.0	4.0
A	G	30.0	Monday	5.0	123.0	2.0
B	C	59.0	Wednesday	5.0	28.0	1.0

Se pot face următoare precizări:

Fiecare instanţă (obiect din baza de date) defineşte un accident rutier în care au fost implicate două autoturisme (datele sunt obţinute din fişa de asigurare furnizate de ARDAF) şi este caracterizat de 15 atribute:

- ***Sex*** de tip nominal cuantifică dacă cel care dă declaraţia este bărbat sau femeie *M* – este bărbat, *F* – este femeie
- ***Ora accident*** de tip numeric specifică momentul din zi ora şi minutul când s-a produs accidentul
- ***Lumini întâlnire*** specifică dacă maşinile au avut lumini de întâlnire, este de tip nominal şi pot avea valorile:
  - *A* dacă ambele maşini au avut lumini de întâlnire în funcţiune
  - *B* daca este aprinsă faza de drum aprinse
  - *C* dacă maşinile nu au avut de întâlnire aprinse
- ***Viteza vehicul accidentat*** de tip numeric specifică viteza în km/oră a autoturismului care este condus de cel care dă declaraţia ARDAF
- ***Viteza vehicul care a fost accidentat*** de tip numeric specifică viteza în km/oră a autoturismului implicat în accident diferit de cel al persoanei care dă declaraţia. Reprezintă aprecierea celui care dă declaraţia a vitezei autoturismului cu care s-a ciocnit;
- ***Codificare cauze accident*** de tip nominal specifică cauza accidentului din punct de vedere a legislaţiei rutiere. S-au avut în vedere următoarele tipuri de cauze (acestea au rezultat din analiza declaraţiilor analizate):

Cauza accidentului nominal	Codificare Cauza accidentului numeric
Nu s-a asigurat	1
Neacordare prioritate	2
Staţionare incorecta	3
Lovit la trecerea de pietoni	4
Lovit în parcare	5
Depăşire incorecta	6

- ***Condiţii de vizibilitate*** de tip nominal specifică condiţiile meteorologice:
  a) *A* dacă condiţiile meteo sunt normale
  b) *B* daca accidentul s-a produs pe ceaţă
  c) *C* daca este ninsoare

d) *D* dacă este ploaie

- ***Stare carosabil*** de tip nominal specifica starea drumului pe care a rulat autoturismul. Poate avea două valori:
  a) *A* dacă carosabilul este uscat
  b) *B* dacă carosabilul este umed, îngheţat etc.
- ***Accidentul s-a produs cu implicarea*** de tip nominal specifică numărul de autovehicule implicate în accident. Poate avea două valori:
  a) *A* în accident este implicat un singur autovehicul;
  b) *B* în accident sunt implicate două sau mai multe autovehicule;
- ***Accidentul s-a datorat coliziunii*** de tip nominal specifică cum s-a produs accidentul (tipul coliziunii):
  a) *A* din spate
  b) *B* din faţă;
  c) *C* din lateral;
  d) *D* schimbare de direcţie;
  e) *E* depăşire;
  f) *F* cauzată de traversare sau întoarcere
  g) *J* altele (inclusiv cu vehicule parcate)
- ***Vârsta*** de tip numeric specifică vârsta conducătorului auto;
- ***Ziua accident*** de tip nominal cuantifică ziua din săptămână în care s-a produs accidentul;
- ***Luna accident*** de tip numeric specifică luna în care s-a produs accidentul;
- ***Vechimea în conducere*** de tip numeric specifică care este vechimea ca şofer a celui implicat în accidentul rutier. Vechimea este dată în luni de zile;
- ***Scor avarii*** de tip numeric specifică gravitatea accidentului prin cuantificarea avariilor autoturismului implicat în accident. Cuantificarea avariilor este dată de un scor obţinut prin cuantificarea fiecărei avarii produse în urma accidentului.

în baza de date exista un număr de 19 fişe de descriere a accidentului auto tip ARDAF

In cadrul prezentului studiu s-a urmărit Determinarea relaţiilor care apar în scopul găsirii celor mai relevante cauze care conduc la producerea accidentului

Modelul corelațional a fenomenului „accident rutier”

A) Definirea modelului corelaţional a fenomenului „accident rutier”

Spre deosebire de analiza anterioară în care s-au determinat elemente abstracte care caracterizează întregul set de date, de acesta dată se vor determina relaţii care apar în cadrul eşantionului supus analizei. în acest scop se va construi un model corelaţional de forma:

Scor avarii = f(caracteristici accident)

S-a considerat că rezultatul unui accident este o sumă de avarii produse autoturismului, motiv pentru care acesta a fost selectat ca şi variabilă dependentă. Ceea ce interesează în urma construirii modelului se referă la:

- Matricea de corelaţie din contextul căreia se vor putea detecta relaţii care există în setul de date. Aceste relaţii vor putea fi extinse la definirea relaţiilor ce caracterizează fenomenul :accident rutier", credibilitatea lor fiind dată de credibilitatea modelului construit;

Pentru atingerea acestui scop vom considera ca parametrii care intervin în model sunt cei analizaţi în capitolul 3 cu semnificaţia dată în tabelul de mai jos:

Număr Parametru	**Semnificaţie**	**Codificare numerică**
1	*Sex*	*M* – este bărbat = 1 *F* – este femeie =2
2	*Ora accident*	
3	*Lumini întâlnire*	*1* dacă ambele maşini au avut lumini de întâlnire în funcţiune *2* daca este aprinsă faza de drum aprinse *3* dacă maşinile nu au avut de întâlnire aprinse
4	*Viteza vehicul accidentat*	
5	*Viteza vehicul care a fost accidentat*	
6	*Codificare cauze accident*	Nu s-a asigurat = 1 Neacordare prioritate=2 Staţionare incorecta =3 Lovit la trecerea de pietoni=4 Lovit în parcare=5 Depăşire incorecta=6
7	*Condiţii de vizibilitate*	*A* dacă condiţiile meteo sunt normale = 1 *B* daca accidentul s-a produs pe ceaţă = 2 *C* daca este ninsoare = 3 *D* dacă este ploaie = 4
8	*Stare carosabil*	*A* dacă carosabilul este uscat = 1 *B* dacă carosabilul este umed, îngheţat etc. = 2
9	*Accidentul s-a produs cu implicarea*	*A* în accident este implicat un singur autovehicul = 1 *B* în accident sunt implicate două sau mai multe autovehicule = 2

10	*Accidentul s-a datorat coliziunii*	*A* din spate = 1 *B* din faţă = 2 *C* din lateral = 3 *D* schimbare de direcţie = 4 *E* depăşire = 5 *F* cauzată de traversare sau întoarcere = 6 *J* altele (inclusiv cu vehicule parcate) = 7
11	*Vârsta*	
12	*Ziua accident*	
13	*Luna accident*	
14	*Vechimea în conducere*	*Cuantizară în luni*
15	*Scor avarii*	*VARIABILA DEPENDENTA*

Pentru construirea modelului s-a utilizat platforma DataFit care implementează o regresie multiliniară.

In urma execuţiei s-a obţinut următoarea funcţie:

Linear Regression Model

SCOR AVARII =

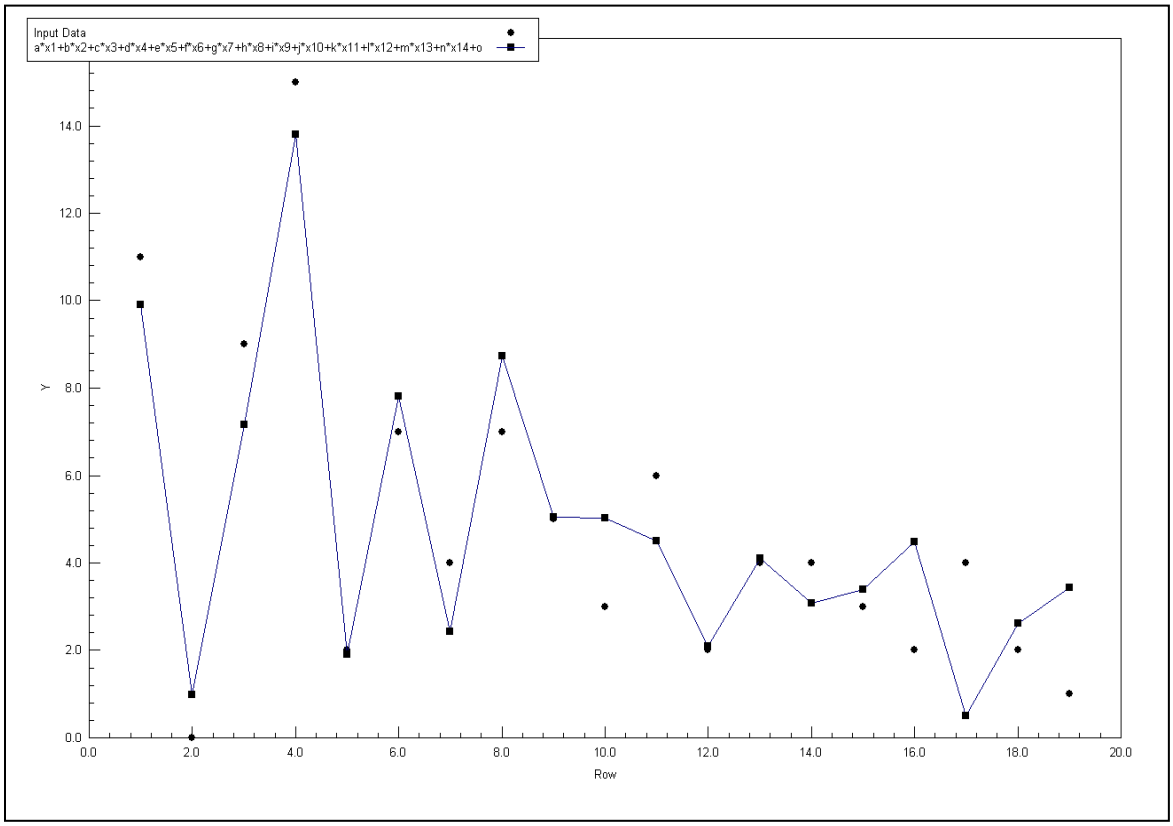
0.2221 * Sex +
-0.186 * Ora accident +
-2.0517 * Lumini de întâlnire c +
0.0619 * Viteza vehicul accidentat +
0.1478 * Viteza vehicul care a produs accidentul +
-0.7454 * Codificare cauze accident +
0.0941 * Condiţii de vizibilitate +
1.0742 * Stare carosabil +
-3.3383 * Accident de impact +
-0.4382 * Accident de coliziune +
-0.0896 * Vârsta +
-0.3133 * Ziua Accident din săptămâna +
0.1053 * Luna Accident +
0.0181 * Vechimea în Conducere +
14.6361

Pentru a determina credibilitatea modelului s-a recurs la un utilitar profesional DataFit. Acesta a propus doua modele de forma:

Rank	Model	R^2
1	a*x1+b*x2+c*x3+d*x4+e*x5+f*x6+g*x7+h*x8+i*x9+j*x10+k*x11+l*x12+m*x13+n*x14+o	0.81815
2	a*x1+b*x2+c*x3+d*x4+e*x5+f*x6+g*x7+h*x8+i*x9+j*x10+k*x11+l*x12+m*x13+n*x14	0.79

Se observă că coeficientul de corelaţie pentru primul din cele două modele este de 0.82. Deoarece acest parametru defineşte credibilitatea modelului (modelul are o credibilitate de 0.82 maxim este 1), putem concluziona că eşantionul este corect ales şi că este posibilă utilizarea metricii de corelaţie pentru analiza relaţiilor care apar în setul de date.

Acurateţea modelului ales poate rezulta şi din vizualizarea graficului funcţiei care reprezintă fenomenul studiat dată mai jos:



B) Analiza coeficienţilor de corelare

Acest tip de analiză are la baza matricea coeficienţilor de corelare. Aceasta defineşte cum şi în ce măsură un parametru influenţează un alt parametru şi cum şi în ce măsură este influenţat de alţi parametri. Ca urmare rezultă un aspect important şi anume faptul că devine posibilă obţinerea de informaţii privind modul în care factorii care apar într-un accident rutier se inter influenţează reciproc.

Matricea de corelare furnizată de DataFit pentru modelul ales este dată în continuare în două variante. O primă variantă este în valori absolute iar în a doua procentual (%) caz în care este mai relevantă contribuţia parametrilor în procesul de inter condiţionare reciprocă.

Matricea de corelare – valori absolute

Correlation Matrix								
	X1	**X2**	**X3**	**X4**	**X5**	**X6**	**X7**	**X8**
X1	1.00	-0.32	0.05	-0.03	-0.21	0.09	-0.04	-0.03
X2	-0.32	1.00	-0.16	-0.23	0.16	0.17	-0.21	0.00
X3	0.05	-0.16	1.00	0.06	0.34	-0.15	-0.22	-0.28
X4	-0.03	-0.23	0.06	1.00	0.44	0.09	0.03	-0.16
X5	-0.21	0.16	0.34	0.44	1.00	0.24	-0.04	0.18
X6	0.09	0.17	-0.15	0.09	0.24	1.00	-0.11	0.04
X7	-0.04	-0.21	-0.22	0.03	-0.04	-0.11	1.00	0.65
X8	-0.03	0.00	-0.28	-0.16	0.18	0.04	0.65	1.00
X9	-0.11	-0.42	0.22	0.45	0.54	0.19	0.12	0.12
X10	-0.25	0.26	-0.23	0.28	0.03	0.28	0.00	0.17
X11	-0.15	-0.29	-0.12	-0.09	-0.43	-0.23	-0.05	-0.31
X12	0.24	-0.35	0.12	0.14	-0.04	-0.05	0.27	0.07
X13	0.01	-0.25	0.14	0.15	0.12	0.12	-0.03	-0.04
X14	0.02	-0.09	-0.30	0.29	-0.32	0.19	0.14	0.20
Y	0.17	-0.39	-0.07	0.70	0.21	-0.20	0.20	0.17

Correlation Matrix							
	X9	**X10**	**X11**	**X12**	**X13**	**X14**	**Y**
X1	-0.11	-0.25	-0.15	0.24	0.01	0.02	0.17
X2	-0.42	0.26	-0.29	-0.35	-0.25	-0.09	-0.39
X3	0.22	-0.23	-0.12	0.12	0.14	-0.30	-0.07
X4	0.45	0.28	-0.09	0.14	0.15	0.29	0.70
X5	0.54	0.03	-0.43	-0.04	0.12	-0.32	0.21
X6	0.19	0.28	-0.23	-0.05	0.12	0.19	-0.20
X7	0.12	0.00	-0.05	0.27	-0.03	0.14	0.20
X8	0.12	0.17	-0.31	0.07	-0.04	0.20	0.17
X9	1.00	-0.18	0.17	0.14	0.29	0.06	0.30
X10	-0.18	1.00	-0.14	0.07	0.11	0.25	0.00
X11	0.17	-0.14	1.00	0.34	0.21	0.22	-0.13
X12	0.14	0.07	0.34	1.00	0.34	0.00	0.11
X13	0.29	0.11	0.21	0.34	1.00	0.11	0.13
X14	0.06	0.25	0.22	0.00	0.11	1.00	0.40
Y	0.30	0.00	-0.13	0.11	0.13	0.40	1.00

Matricea de corelare – valori procentuale

Correlation Matrix								
	X1	**X2**	**X3**	**X4**	**X5**	**X6**	**X7**	**X8**
X1	100.00%	-32.37%	5.16%	-3.05%	-21.18%	8.73%	-4.38%	-2.55%
X2	-32.37%	100.00%	-15.90%	-23.19%	15.90%	16.64%	-20.94%	0.30%
X3	5.16%	-15.90%	100.00%	5.81%	34.21%	-14.84%	-22.38%	-27.59%
X4	-3.05%	-23.19%	5.81%	100.00%	44.22%	8.67%	3.37%	-16.14%
X5	-21.18%	15.90%	34.21%	44.22%	100.00%	23.59%	-4.19%	17.82%
X6	8.73%	16.64%	-14.84%	8.67%	23.59%	100.00%	-10.74%	4.49%
X7	-4.38%	-20.94%	-22.38%	3.37%	-4.19%	-10.74%	100.00%	64.63%
X8	-2.55%	0.30%	-27.59%	-16.14%	17.82%	4.49%	64.63%	100.00%
X9	-10.83%	-42.26%	21.98%	44.57%	54.20%	19.08%	8.98%	12.07%
X10	-25.27%	25.70%	-22.80%	27.80%	3.02%	28.20%	0.00%	16.90%
X11	-14.56%	-29.19%	-8.95%	-8.90%	-42.89%	-23.03%	-4.81%	-31.16%
X12	24.43%	-35.35%	12.15%	13.57%	-3.67%	-5.30%	26.66%	7.26%
X13	0.73%	-25.13%	14.20%	15.17%	11.92%	11.78%	-3.18%	-3.92%
X14	1.65%	-8.96%	-30.47%	28.78%	-32.20%	19.34%	13.55%	20.46%
Y	16.68%	-38.95%	-7.05%	69.80%	21.47%	-20.08%	19.75%	16.73%

Correlation Matrix							
	X9	**X10**	**X11**	**X12**	**X13**	**X14**	**Y**
X1	-10.83%	-25.27%	-14.56%	24.43%	0.73%	1.65%	16.68%
X2	-42.26%	25.70%	-29.19%	-35.35%	-25.13%	-8.96%	-38.95%
X3	21.98%	-22.80%	-11.95%	12.15%	14.20%	-30.47%	-7.05%
X4	44.57%	27.80%	-8.90%	13.57%	15.17%	28.78%	69.80%
X5	54.20%	3.02%	-42.89%	-3.67%	11.92%	-32.20%	21.47%
X6	19.08%	28.20%	-23.03%	-5.30%	11.78%	19.34%	-20.08%
X7	11.98%	0.00%	-4.81%	26.66%	-3.18%	13.55%	19.75%
X8	12.07%	16.90%	-31.16%	7.26%	-3.92%	20.46%	16.73%
X9	100.00%	-17.96%	17.23%	13.95%	29.47%	6.37%	30.44%
X10	-17.96%	100.00%	-13.54%	6.93%	10.52%	24.56%	0.00%
X11	17.23%	-13.54%	100.00%	33.70%	21.12%	21.71%	-12.53%
X12	13.95%	6.93%	33.70%	100.00%	33.74%	0.22%	11.08%
X13	29.47%	10.52%	21.12%	33.74%	100.00%	11.41%	12.53%
X14	6.37%	24.56%	21.71%	0.22%	11.41%	100.00%	40.50%
Y	30.44%	0.00%	-12.53%	11.08%	12.53%	40.50%	100.00%

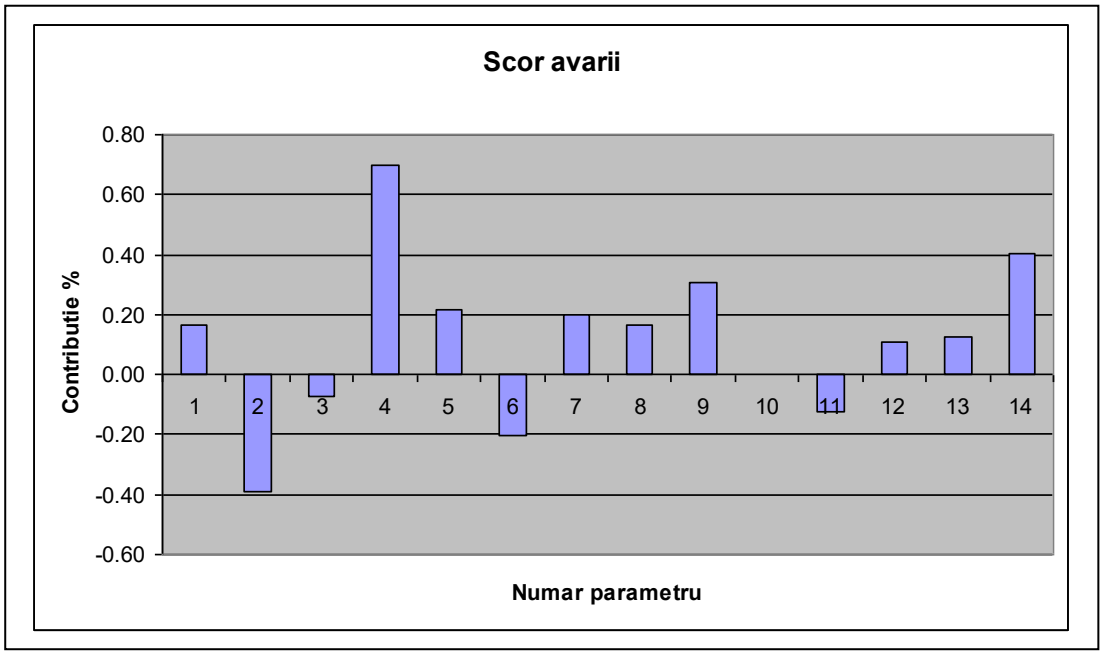
Analiza coeficienţilor de corelare

Aceştia reflectă în ultimă instanță importanta fiecărui parametru în cadrul modelului adoptat, și deci contribuţia fiecăruia din cei 14parametri luaţi în considerare la stabilirea scorului avarilor care pot fi produse în urma unui accident . Pentru eşantionul luat în considerare s-au obţinut următoarele valori :

Coeficienţii de corelare parţială

Număr	**Semnificaţie Parametru**	**Coeficient de Corelare parţială**
1	*Sex*	0.17
2	*Ora accident*	-0.39
3	*Lumini întâlnire*	-0.07
4	*Viteza vehicul accidentat*	0.70

5	*Viteza vehicul care a fost accidentat*	0.21
6	*Codificare cauze accident*	-0.20
7	*Condiţii de vizibilitate*	0.20
8	*Stare carosabil*	0.17
9	*Accidentul s-a produs cu implicarea*	0.30
10	*Accidentul s-a datorat coliziunii*	0.00
11	*Vârsta*	-0.13
12	*Ziua accident*	0.11
13	*Luna accident*	0.13
14	*Vechimea în conducere*	0.40



Concluzii

(A) O primă concluzie care rezultă se referă la **apariţia unei ierarhii** a factorilor care concură la obţinerea unui anumit scor al avariilor. Această ierarhie apare inclusiv din diagrama de mai sus. Analizând în ordine descrescătoare se poate observa că :

1. Cea mai mare contribuţie la producerea unor avarii cu scor mare îl are *viteza autovehiculului* (procent de 70%). Cu cât viteza creşte cu atât avariile sunt mai importante;

2. Pe locul doi se află *Vechimea în conducere* cu un procent de 40%. Este de remarcat faptul că o vechime mai mare în conducere conduce la producerea unor avarii mai mari în cazul producerii unui accident rutier;

3. Pe locul trei se află *ora la care s-a produs accidentul* cu un procent de 39%. Este interesantă analiza semnului – din faţa acestui parametru. Semnificaţia sa este următoarea: Avariile cresc o dată cu micşorarea orei la care se produce accidentul. Cu alte cuvinte avariile cresc la ore matinale.

4. Pe locul patru se afla parametrul nouă *Accidentul s-a produs cu implicarea*. Acesta arată dacă în accident a fost implicată o singura maşină sau două sau mai multe. Parametru arată că avariile cresc dacă a avut loc o coliziune în trafic şi nu în momentul unei parcări.

5. Pe locul cinci se află cu un procent de 20 % parametrul *Viteza vehicul care a fost accidentat.* Se observă că importanţa avariilor creşte o dată cu creşterea vitezei celui de al doilea auto vehicul implicat în accident.

(B) **Analiza coeficienţilor de intercorelare**

In cele ce urmează vom analiza fiecare parametru în parte cu observaţia că analiza se va face numai pentru contribuţii mai mari de 25% pe care o are un parametru în modificarea altui parametru. . Este de remarcat că matricea este simetrică, astfel încât studiul se va face numai pentru valorile deasupra diagonalei principale. Ca urmare vom avea:

		X1	X2	X3	X4	X5	X6	X7
Sex	X1		-32.37					
Ora accident	X2	-32.37						
Lumini întâlnire	X3					34.21		
Viteza vehicul accidentat	X4					44.22		
Viteza vehicul care a fost accidentat	X5			34.21	44.22			
Codificare cauze accident	X6							
Condiţii de vizibilitate	X7							
Stare carosabil	X8			-27.59				64.63
Accidentul s-a produs cu implicarea	X9		-42.26		44.57	54.20		
Accidentul s-a datorat coliziunii	X10	-25.27	25.70		27.80		28.20	
Vârsta	X11		-29.19			-42.89		
Ziua accident	X12	24.43	-35.35					26.66
Luna accident	X13	0.73	-25.13					
Vechimea în conducere	X14			-30.47	28.78	-32.20		

		X8	X9	X10	X11	X12	X13	X14
Sex	X1					24.43		
Ora accident	X2		-42.26	25.70	-29.19	-35.35	-25.13	
Lumini întâlnire	X3	-27.59						-30.47
Viteza vehicul accidentat	X4		44.57	27.80				28.78
Viteza vehicul care a fost accidentat	X5		54.20		-42.89			-32.20
Codificare cauze accident	X6			28.20				
Condiţii de vizibilitate	X7	64.63				26.66		
Stare carosabil	X8				-31.16			
Accidentul s-a produs cu implicarea	X9						29.47	
Accidentul s-a datorat coliziunii	X10							24.56
Vârsta	X11	-31.16				33.70		
Ziua accident	X12				33.70		33.74	
Luna accident	X13		29.47			33.74		
Vechimea în conducere	X14			24.56				

1. **Parametrul 1 - *Sex***
   - Cu cât ora este mai mică cu atât şansa ca accidentul sa fie făcut de un bărbat este mai mare (pondere 32);
   - Accidentele în care sunt implicaţi femeile cresc spre sfârşitul săptămânii (pondere 24.4);

2. **Parametrul 2 – *Ora accident***

- Cu cât ora este mai mică cu atât şansa ca accidentul să fie produs de o singură maşină creşte (pondere 42);
- Cu cât ora este mai mare cu atât şansa ca accidentul să se datoreze unei coliziuni creşte (pondere 25.7)
- Cu cât ora este mai mică cu atât şansa ca cel care produce accidentul să aibă o vârstă mai mare creşte (pondere 29);
- Accidentele care au loc la ore matinale au loc la sfârşitul săptămânii (pondere 35.35);
- Accidentele care au loc la ore matinale apar îndeosebi în lunile 8 – 12 (pondere 25.13);

3. **Parametrul 3 – *Lumini întâlnire***
   - Maşinile care au produs accidente care au lumini de întâlnire au o viteză mai mare (pondere 34.2);
   - Prezenţa luminilor de întâlnire apare îndeosebi în condiţii de carosabil uscat (pondere 27.5);
   - Cu cât vechimea în conducere este mai mare cu atât şansa ca automobilul să aibă lumini de întâlnire este mai mică (pondere 30.4);

4. **Parametrul 4 – *Viteză vehicul accidentat***
   - In declaraţie viteza vehiculului propriu este corelată cu viteza autoturismului cu care s-a ciocnit. Cu alte cuvinte există tendinţa de a ajusta viteza celuilalt faţa de cea proprie (pondere 44.2);
   - Viteza autoturismului propriu creşte dacă este vorba de o coliziune cu un alt autoturism (pondere 44.5). Cu alte cuvinte, există tendinţa de a ajusta şi viteza proprie în caz de coliziune în declaraţie;
   - Cu cat viteza este mai mare cu atât creste şansa ca vehiculul sa fie lovit fata / spate (pondere 27.8);
   - Cu cat vechimea în conducere este mai mare cu atât viteza în momentul accidentului este mai mare (pondere 28.7);

   St accidentat
5. **Parametrul 5 – *Viteza vehicul care a fost accidentat***
   - Cu cat viteza este mai mare cu atât şansa ca cel de care se ciocneşte sa fie o alta maşina este cu atât mai mare (pondere 54.2);
   - Intr-un accident cu cat vârsta este mai mare a şoferului cu atât scade viteza maşinii de care se ciocneşte – și complementara este valabila – cu scăderea vârstei şoferului se constata o creştere a vitezei maşinii de care se ciocneşte (pondere 42.8);

- Cu cat vechimea în conducere este mai mica a şoferului cu atât creste viteza maşinii de care se ciocneşte (pondere 32)

6. **Parametrul 6– *Codificare cauze accident***
   - Cu cat cauza accidentului (cuantificata de la 1= nu s-a asigurat la 6= depăşire incorecta) este mai mare cu atât şansa ca coliziunea sa fie frontala este mai mare (pondere 28.2);
7. **Parametrul 7– *Condiţii de vizibilitate***
   - In caz de accident scăderea conidiilor de vizibilitate este corelata cu şansa de a avea un carosabil impropriu (polei, noroi, umed etc..), (pondere 64.3);
   - Accidentele care au loc în condiţii de vizibilitate proste au loc la sfârşitul săptămânii (pondere 26.6);
8. **Parametrul 8– *Stare carosabil***
   - Fac accidente pe un carosabil impropriu cei cu vârsta mica (pondere 31.4);
9. **Parametrul 9– *Accidentul s-a produs cu implicarea***
   - Cu cat creste cauza accidentului (cuantificata de la 1= nu s-a asigurat la 6= depăşire incorecta) cu atât creste şansa ca sa fie implicate doua maşini în acesta (pondere 29.4);
10. **Parametrul 10– *Accidentul s-a datorat coliziunii***
    - Cu cat creste vechimea în conducere a şoferului creste şansa ca accidentul sa fie de tip coliziune (pondere 24.5);
11. **Parametrul 11– *Vârsta***
    - Cu cat creste vârsta şoferului cu atât creste şansa ca accidentul sa aibă loc la sfârşitul săptămânii (pondere 33.7);
12. **Parametrul 12– *Ziua accidentului***
    - Spre sfârşitul săptămânii accidentele cresc începând cu sfârşitul anului (pondere 33.7);

9. Tehnici de modelare Monte - Carlo

Bazele teoretice ale metodei au fost puse în anul 1949 de Metropolis şi Ulam[1], dar ideea acestor metode a apărut încă din 1777 când Buffon a formulat celebra problemă a calculului probabilităţii de intersecţie a unui ac aruncat la întâmplare, pe o suprafaţă plană pe care sunt trasate drepte paralele echidistante. Aceasta idee în 1860 ia permis lui Barbier sa calculeze numărul π prin aruncări succesive ale unui ac de lungime $\boldsymbol{l}$, pe o suprafaţă plană cu drepte paralele la echidistanta $\boldsymbol{2l}$. Fermi, Metropolis şi Ulam au folosit *metoda experimentărilor statistice*, la studiul difuziei neutronilor în materialele fisionabile. In acest scop au utilizat listele de numere întâmplătoare (rezultate in jocul de ruleta) care se publicau la Monte - Carlo. De aici a rezultat cea mai răspândită denumire a metodei. În SUA, metoda a mai fost cunoscută şi sub denumirea de "*metoda Las Vegas*". În literatura de specialitate se întâlnesc următoarele denumiri echivalente: *metoda încercărilor echivalente*; *metoda experimentărilor statistice; simularea numerică; metoda simulării indirecte; metoda numerelor aleatoare.*

Termenul de "*Metoda Monte - Carlo*" se utilizează pentru a desemna două tehnici diferite.

1. Prima tehnică constă în evaluarea integralelor definite prin utilizarea variabilelor aleatoare.
2. Al doilea sens al "*metodei Monte - Carlo*" presupune înlocuirea unui fenomen real cu un experiment statistic.

1. Nicholas Metropolis; S. Ulam, *The Monte Carlo Method*, Journal of the American Statistical Association, Vol. 44, No. 247. (Sep., 1949), pp. 335-341.

9.1 Evaluarea integralelor definite prin tehnica Monte Carlo.

Principiul metodei de calcul Monte Carlo (MC)

Principiul metodei Monte Carlo de calcul este ilustrat de calculul valorii numărului π din figura următoare și constă în următoarele

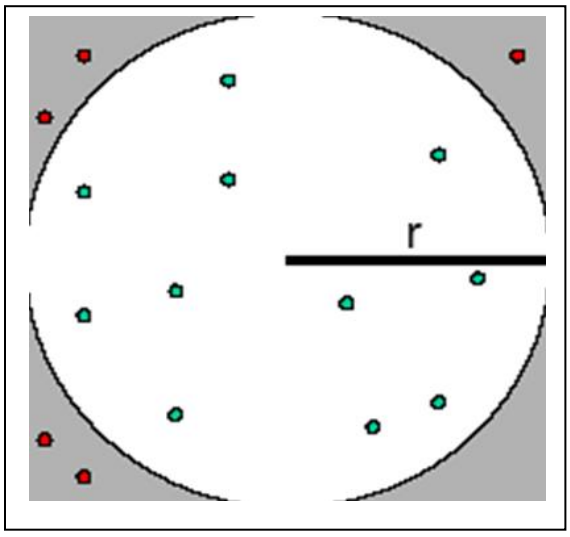
$$\text{aria patratului} = (2r)^2$$

$$\text{aria cercului} = \pi r^2$$

$$\frac{\text{aria patratului}}{\text{aria cercului}} = \frac{4r^2}{\pi r^2} = \frac{4}{\pi}$$

$$\pi = 4 \times \frac{\text{aria cercului}}{\text{aria patratului}} \text{ unde}$$

$$\frac{\text{aria cercului}}{\text{aria patratului}} = \frac{\text{numar de puncte in interiorul cercului}}{\text{numarul total de puncte}}$$



Ca urmare

- Se generează puncte uniform repartizate (x_i, y_i) în spațiul definit de pătratul de dimensiune ***2r x 2r***. Notăm cu ***N*** numărul de puncte generate. Generarea de puncte de coordonate (x_i, y_i) presupune generarea de coordonate x_i respectiv y_i în intervalul [0, 2r] urmând o lege de distribuție uniform repartizată.

- Notăm cu ***S*** numărul de puncte care cad în interiorul suprafeței delimitate de cerc. Acest contor se incrementează cu 1 dacă punctul de coordonate *(x_i, y_i)* generat îndeplinește condiția $x_i^2 + y_i^2 \le r^2$.
- După generarea unui număr de ***N*** puncte valoarea constantei π va fi dată de relația

$$\pi = 4 * \frac{S}{N}$$

Prin creșterea numărului de puncte în spațiul definit de pătrat vom obține următoarele valori estimative

N	PI
1000	3.13200000
2000	3.14200000
3000	3.10800000
4000	3.11800000
5000	3.13040000
6000	3.12266667
7000	3.15142857
8000	3.12450000
9000	3.15333333
10000	3.15600000
Valoarea exactă	3.14159265

Estimarea poate fi îmbunătățită prin efectuarea unui număr de experimente independente (independența fiind realizată prin utilizarea de diferite secvențe de numere aleatoare uniform distribuite) și calculul valorii medii. De exemplu efectuând un număr de 1000 măsurători independente s-a obținut

N = 10000 m = 1000 PI = 3.14140240

I. Calculul valorii unei integrale prin tehnica Monte Carlo.

Metoda hit-or-miss.

Obiectivul metodei este acela de a calcula

$$y = \int_a^b f(x)dx \quad \text{unde} \quad a,b \in R$$

În așa numita metodă "hit-or-miss" de integrare Monte Carlo, integrala este estimată prin desenarea unei dreptunghi care delimitează funcția $f(x)$ în intervalul [a, b]. Dreptunghiul se extinde de la a b și de la 0 la f_{max}, unde $f_{\max} > f(x)$ în intervalul dat. Se generează N puncte aleatoriu în cadrul dreptunghiului. Estimarea integralei poate fi obținută raportând numărul total de puncte N_0 care apar sub curba $f(x)$ la N.

$$I_{est} = \frac{N_0}{N} A$$

unde $A = (b-a) f_{\max}$ este aria dreptunghiului.

Fiecare din cele N puncte aleatoare se obține prin generarea a generarea a două valori numerice s_1 și s_2 uniform distribuite și calcularea a două coordonate x, respectiv y de forma

$$x = a + s_1 * (b-a)$$
$$y = s_2 * f_{\max}$$

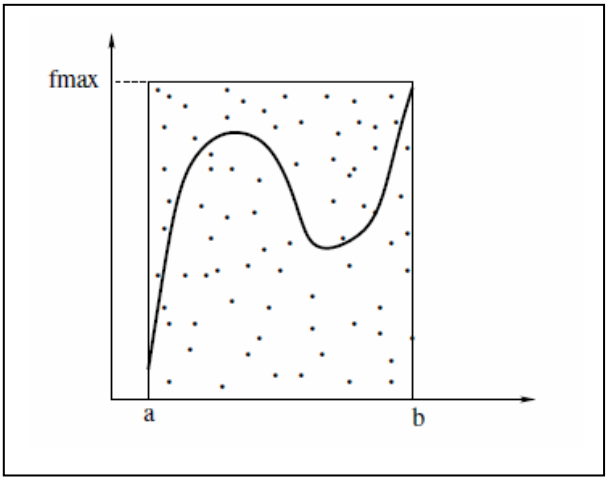
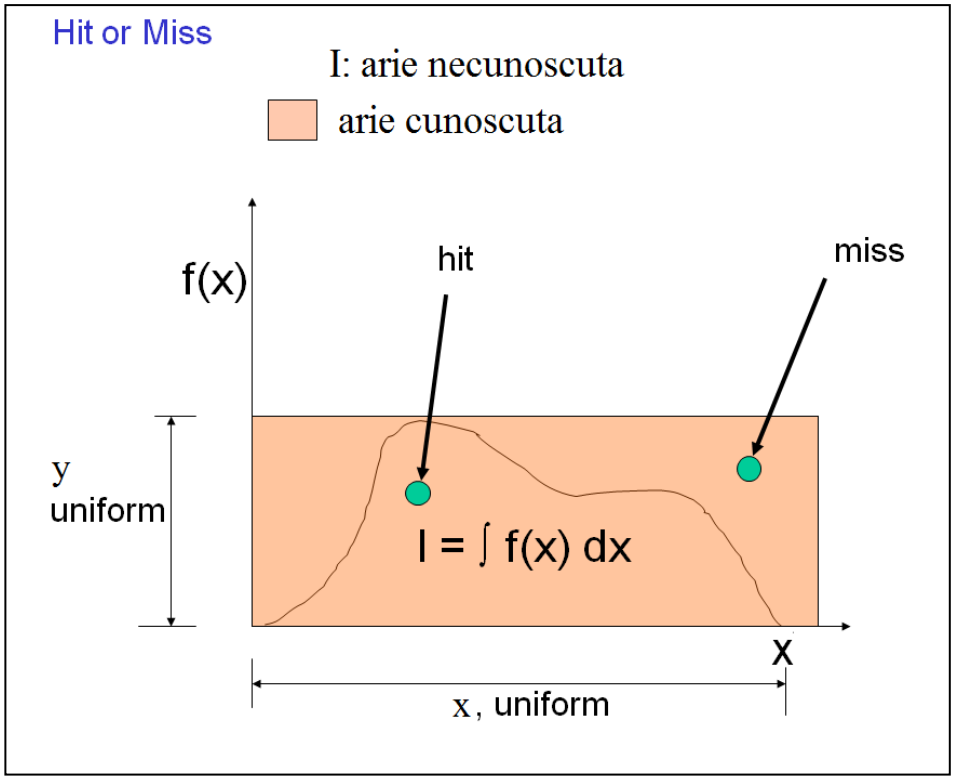


Figura 1. Hit-or-miss MC. Punctele sunt generate aleator în spațiul definit de aria dreptunghiulară care delimitează funcția $f(x)$ în intervalul [a, b] . Numărul de puncte de sub curbă este utilizat pentru calculul integralei.



Estimarea valorii integralei va crește în precizie dacă $N \to \infty$ și va converge spre un răspuns corect. Trebuie specificat că calitatea răspunsului obținut depinde de calitatea generatorului de numere aleatoare care se utilizează.

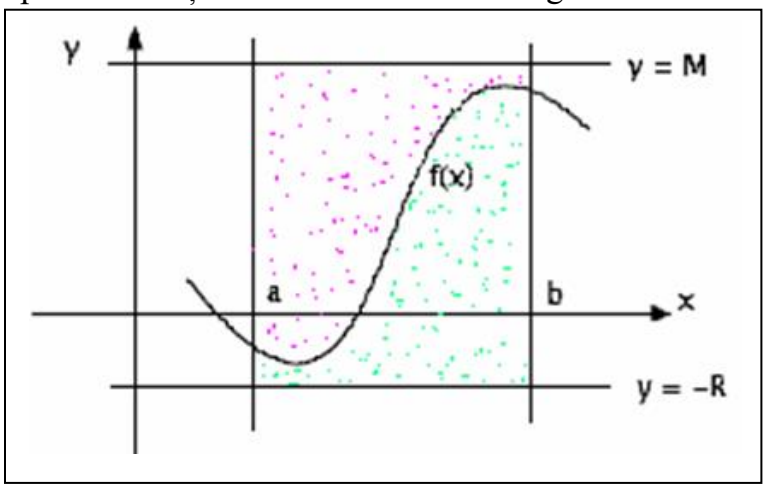
Etapele care se parcurg pentru calculul integralei prin această metodă sunt

- Se generează puncte uniform repartizate (x_i, y_i) în spațiul definit de dreptunghi de dimensiune *b-a * ymax - ymin*. Notăm cu ***N*** numărul de puncte generate. Generarea de puncte de coordonate (x_i, y_i) presupune generarea de coordonate x_i în intervalul [a, b], respectiv y_i în intervalul [ymin, ymax] urmând o lege de distribuție uniform repartizată.

- Notăm cu ***S*** numărul de puncte care cad în interiorul suprafeței delimitate de f(x). Acest contor se incrementează cu 1 dacă punctul de coordonate *(x_i, y_i)* generat îndeplinește condiția $y_i \le f(x_i)$.
- După generarea unui număr de ***N*** puncte valoarea constantei integralei va fi dată de va fi dată de relația

$$I = (y_{\max} - y_{\min}) * (b-a) * \frac{S}{N}$$

- Dacă o parte a funcției este sub axa x ca în figura următoare vom avea



$$\frac{S}{N} = \frac{\text{aria de sub curba f(x)}}{\text{aria totala}} = \frac{\int_a^b f(x)dx}{(M+R)(b-a)}$$

$$\int_a^b f(x)dx = (M+R)(b-a)\frac{S}{N}$$

Această relație va trebui corectată deoarece linia y=-R s-a utilizat ca linie de bază pentru calculul suprafeței în loc de linia y=0 ca în cazul anterior. Pentru aceasta se va scădea aria R(b-a) din valoarea obținută. Se va obține în final

$$\int_a^b f(x)dx = (M+R)(b-a)\frac{S}{N} - R(b-a)$$

Metoda ***Monte Carlo hit-or-miss***, poate fi extinsă pentru calculul unei integrale multiple. De exemplu dacă considerăm o integrală de forma

$$I = \int_{a_1}^{a_2}\int_{b_1}^{b_2}\int_{c_1}^{c2} f(x,y,z)dxdydz$$

Care definește un volum într-un spațiu cu 3 dimensiuni o valoare estimativă se va putea calcula de forma

$$\begin{aligned} I &= \int_{a_1}^{a_2}\int_{b_1}^{ab}\int_{c_1}^{c2} f(x,y,z)dxdydz \\ &= \int_{a_1}^{a_2}\left[\int_{b_1}^{b_2}\left(\int_{c_1}^{c_2} f(x,y,z)\,dx\right)dy\right]dz \\ &\approx (a_2-a_1)(b_2-b_1)(c_2-c_1)\frac{N_0}{N} \end{aligned}$$

unde (x_i, y_i, z_i) este un punct aleator în spațiul tri dimensional definit de paralelipipedul $(a_2-a_1)\times(b_2-b_1)\times(c_2-c_1)$. În total vom avea nevoie de ***3N*** numere aleatoare pentru a genera ***N*** puncte aleatoare. N_0 se obține incrementând cu 1 acest contor dacă condiția $f(x_i, y_i, z_i) < 0$ este îndeplinită

Metoda sample-mean.

O altă tehnică simplă de calcul MC este dată de "**sample-mean**". Aceasta presupune obținerea unui eșantion ***N*** de valori *x* uniform distribuite din intervalul [a, b]. Aceste valori sunt utilizate pentru obținerea unei valori estimative pentru integrală de forma

$$I_{est} = (b-a)\frac{1}{N}\sum_{i=1}^{n} f(x_i)$$

În acest mod vom aproxima integrala prin media unui număr de N valori de forma $f(x_1), f(x_2), f(x_3), ..., f(x_N)$. Și în acest caz estimarea este cu atât mai bună cu cât

eșantionul de numere aleatoare x_i este mai mare. Această estimare va converge la rezultatul corect atunci când $N \to \infty$.

Metoda MC "sample-mean", poate fi extinsă pentru calculul unei integrale multiple. De exemplu dacă considerăm o integrală de forma

$$I = \int_{a_1}^{a_2} \int_{b_1}^{b_2} \int_{c_1}^{c2} f(x,y,z) dxdydz$$

Care definește un volum într-un spațiu cu 3 dimensiuni o valoare estimativă se va putea calcula de forma

$$\begin{aligned} I &= \int_{a_1}^{a_2} \int_{b_1}^{b_2} \int_{c_1}^{c2} f(x,y,z) dxdydz \\ &= \int_{a_1}^{a_2} \left[\int_{b_1}^{b_2} \left(\int_{c_1}^{c_2} f(x,y,z)\, dx \right) dy \right] dz \\ &\approx (a_2 - a_1)(b_2 - b_1)(c_2 - c_1) \frac{1}{N} \sum_{i=1}^{N} f(x_i, y_i, z_i) \end{aligned}$$

unde (x_i, y_i, z_i) este un punct aleator în spațiul tri dimensional definit de paralelipipedul $(a_2 - a_1) \times (b_2 - b_1) \times (c_2 - c_1)$. În total vom avea nevoie de 3N numere aleatoare pentru a genera N puncte aleatoare.

Calculul volumelor.

Tehnica MC dă posibilitatea calculului unor regiuni complicate dintr-un spațiu tri dimensional. Pentru a ilustra tehnica MC considerăm volumul unei regiuni a cărei puncte satisfac condiția

$$\begin{cases} 0 \le x \le 1 \quad 0 \le y \le 1 \quad 0 \le z \le 1 \\ x^2 + \sin y \le z \\ x - z + e^y \le 1 \end{cases}$$

Prima linie definește un cub de volum 1. Cele două inegalități definesc un volum care este un subset al cubului. În acest caz se poate aplica metoda "hit-or-miss" prin generarea

de ***N*** puncte în interiorul cubului și determinarea punctelor care definesc cele două inegalități (***N₀***). În acest caz estimarea volumului cerut este dată de $\frac{N_0}{N}$. În Figura 2 se prezintă valoarea acestui volum în 20 de calcule, în care s-au utilizat valori diferite pentru ***N.***

9.2 Înlocuirea unui fenomen real cu un experiment statistic

Principiul de Simulare ***Monte Carlo (MCS)*** este ilustrat in figura 3. În contextul acestei metode intrările sunt aleatoriu generate din distribuții de probabilitate. Datele generate din simulare vor fi reprezentate de distribuții de probabilitate sau histograme

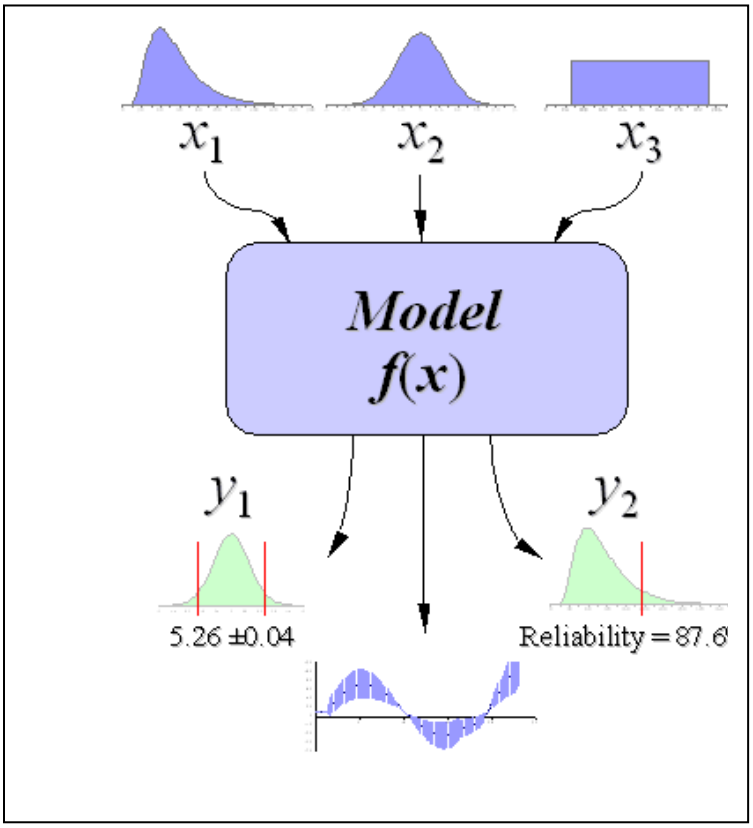


Figura 3. Principiul de Simulare Monte Carlo (MCS)

- **În cadrul acestei tehnici analiza fenomenului real se înlocuieşte cu analiza unui fenomen artificial, descris de un model parametric.** Prin rezolvarea acestuia se generează pentru variabile, valori aleatoare.

- Modelul parametric este de forma $y = f\left(x_1, x_2, x_3, ..., x_q\right)$

- În vederea obţinerii unei imagini corecte a evoluţiei fenomenului sau procesului studiat trebuie ca variabilele aleatoare să fie estimate cu abatere cât mai mică în raport cu cele ce apar în realitate şi experimentul să fie repetat de un număr convenabil de mare de ori, pentru a se pune în evidenţă principalele trăsături ale fenomenului modelat.

- Metoda asociază problemei reale un model aleator şi prin generarea unor variabile aleatoare legate funcţional de soluţie, se realizează experienţe pe model şi se furnizează informaţii asupra soluţiei problemei deterministe.
-

Pașii care se parcurg sunt

Pas 1: Se creează un model parametric, $y = f(x_1, x_2, ..., x_q)$.

Pas 2: Se generează un set de intrări, $x_{i1}, x_{i2}, ..., x_{iq}$.

Pas 3: Se evaluează modelul și se memorează valorile pentru y_i.

Pas 4: Repetă pașii 2 și 3 pentru $i = 1$ to n.

Pas 5: Se analizează rezultatele utilizând histograme, statistici, interval de încredere, etc.

Pentru a ilustra modul în care se utilizează această tehnică vom considera următoarele exemple.

Exemplul 1

Tabelul 9.1 prezintă vânzările de calculatoare PC ale unei firme de profil în ultimele 30 de săptămâni. Se cere utilizând tehnica Monte Carlo simularea vânzărilor de calculatoare pentru 10 săptămâni utilizând distribuţia vânzărilor săptămânale de PC din tabelul 9.2

Tabelul 9.1

Număr curent i	Calculatoare vândute pe săptămână x_i	Număr de Săptămâni f_i
1	0	6
2	1	12
3	2	6
4	3	3
5	4	3

Pentru a simula cererea săptămânală de calculatoare se va determina distribuţia de probabilitate a cererii săptămânale utilizând frecvenţa relativă a cererii în cele 30 săptămâni, adică $P(x_i)=\frac{f_i}{30}$.

Tabelul 10.2

Număr curent i	Calculatoare vândute pe săptămână x_i	Probabilitatea cererii $P(x_i)$
1	0	0,20
2	1	0,40
3	2	0,20
4	3	0,10
5	4	0,10

Pasul 1.

În Tabelul 9.3 sunt prezentate valorile funcţiei distribuţiei cumulative $F(x_i)$ pentru vânzările săptămânale de calculatoare PC determinate pe baza distribuţiei discrete din Tabelul 9.2. Aceasta defineşte **modelul parametric** al fenomenului studiat.

Tabelul 9.3

Calculatoare vândute pe săptămână x_i	Probabilitatea cererii $P(x_i)$	Funcţia distribuţiei cumulative $F(x_i) = P(X \le x_i)$
0	0,20	0,20
1	0,40	0,60
2	0,20	0,80
3	0,10	0,90
4	0,10	1

Media determinată pe baza datelor ***reale*** referitoare la vânzările săptămânale de PC este

valoarea medie $\mu = 0\times 0.2 + 1\times 0.4 + 2\times 0.2 + 3\times 0.1 + 4\times 0.1$

$\mu = 1.5$ calculatoare

dispersia $\sigma^2 = 0\times 0.2 + 1\times 0.4 + 2^2\times 0.2 + 3^2\times 0.1 + 4^2\times 0.1 - 1.5^2$

$\sigma^2 = 1.45$ calculatoare

abaterea standard $\sigma = 1.204$ calculatoare

Pasul 2.

Tabelul 9.4 conţine valorile numerice pentru cazul vânzărilor săptămânale de calculatoare PC

MODEL PARAMETRIC

Tabelul 9.4

Valoarea variabilei probabiliste x_i	Probabilitatea $P(X = x_i) = P(x_i)$	Funcţia distribuţiei cumulative $F(x_i)$	Intervale $[F(x_{i-1}), F(x_i))$
$x_1 = 0$	0,2	0,2	[0 0.2)
$x_2 = 1$	0,4	0,6	[0.2 0.6)
$x_3 = 2$	0,2	0,8	[0.6 0.8)
$x_4 = 3$	0,1	0,9	[0.8 0.9)
$x_5 = 4$	0,1	1,0	[0.9 1.0)

Pasul 3

Se generează un număr de 10 numere aleatoare uniform distribuite în intervalul [0, 1] care au drept corespondent cele 10 săptămâni pentru care se dorește obținerea evoluției probabile a vânzărilor. Evoluția este prezentată în Tabelul 9.5

Tabelul 9.5

Nr. aleator	Valoarea x_i a variabilei probabiliste	Număr calculatoare (bucăţi/săptămână)
0,486281	x2	1
0,928927	x5	4
0,205136	x2	1
0,852845	x4	3
0,005645	x1	0
0,651622	x3	2
0,799931	x3	2
0,333693	x2	1
0,416841	x2	1
0,011913	x1	0

Media determinată pe baza selecţiei simulate = 1,5 calculatoare pe săptămână, iar abaterea standard = 1,269 calculatoare.

Exemplul 2

Numărul de produse vândute zilnic în cadrul unui magazin este dat de o variabilă probabilistă discretă uniform repartizată în intervalul [6, 10]. Se cere simularea vânzărilor pentru 10 zile.

În Tabelul 9.6 sunt prezentate probabilităţile $P(x_i)$, $F(x_i) = P(X \le x_i)$ şi intervalele de numere aleatoare asociate fiecărei valori in intervalul [6, 10] (interval [a, b]). Acestea definesc **modelul parametric.**

Tabelul 9.6

Numărul de produse vândute zilnic x_i	Probabilitatea $P(X=x_i)=\frac{1}{5}$	Funcția distribuției cumulative $F(x_i)=P(X\le x_i)=\frac{1}{5}$	Intervale $[F(x_{i-1}),F(x_i))$
6	0.2	0.2	[0 0.2)
7	0.2	0.4	[0.2 0.4)
8	0.2	0.6	[0.4 0.6)
9	0.2	0.8	[0.6 0.8)
10	0.2	1.0	[0.8 1.0)

În Tabelul 9.7 sunt simulate vânzările din 10 zile.

Tabelul 9.7

Ziua	Număr aleator u	Numărul de produse
1	0,709084	9
2	0,149934	6
3	0,294974	7
4	0,200192	7
5	0,189083	6
6	0,900415	10
7	0,940097	10
8	0,291185	7
9	0,002452	6
10	0,469177	8

Observaţie: În cazul variabilelor cu distribuţie uniformă discretă în intervalul [a, b], se poate genera direct o anumită valoare x_i (numar produse)cu ajutorul relaţiei:

$$x_i = \textit{partea întreagă din } [a + (b-a+1)u]$$

De exemplu, dacă s-a generat u = 0,709084, (numar uniform repartizat in intervalul 0-1) atunci pentru variabila probabilistă cu distribuţie uniformă discretă în intervalul [6, 10], numărul de produse vândute într-o zi oarecare este:

$$x_i = \textit{partea întreagă din } [6 + (10-6+1)* 0{,}709084] = 9 \textit{ produse}$$

Exemplul 3 – Determinarea riscului în management prin modelare și simulare Monte Carlo

Definiții

- **Riscul** este un concept care exprimă probabilitatea unor întâmplări negative și impactul acestora (International Organization for Standardization – ISO). Conform definiției, riscul este efectul (pozitiv sau negativ) al incertitudinii asupra obiectivelor.
- Posibilitatea de pierdere, daune, sau alte circumstanțe neprielnice sau negative; o șansă sau situație care implică o astfel de posibilitate (Oxford English Dictionary).

Presupunem că trebuie să conducem un proiect care implică crearea unui produs eLearning. Pentru creearea acestui produs sunt necesare realizarea unui număr de trei taskuri (activități) scrierea conținutului, crearea interfeței grafice și integrarea de elemente multimedia. În baza unei experințe anterioare sau din aprecierea dificultății de realizare se determină durata acestor activități – cel mai bun caz, cel mai probabil caz respectiv cel mai rău scenariu de terminare pentru fiecare din cele trei activități. Acesta definește **modelul parametric** al sistemului.

Tabelul 9.8

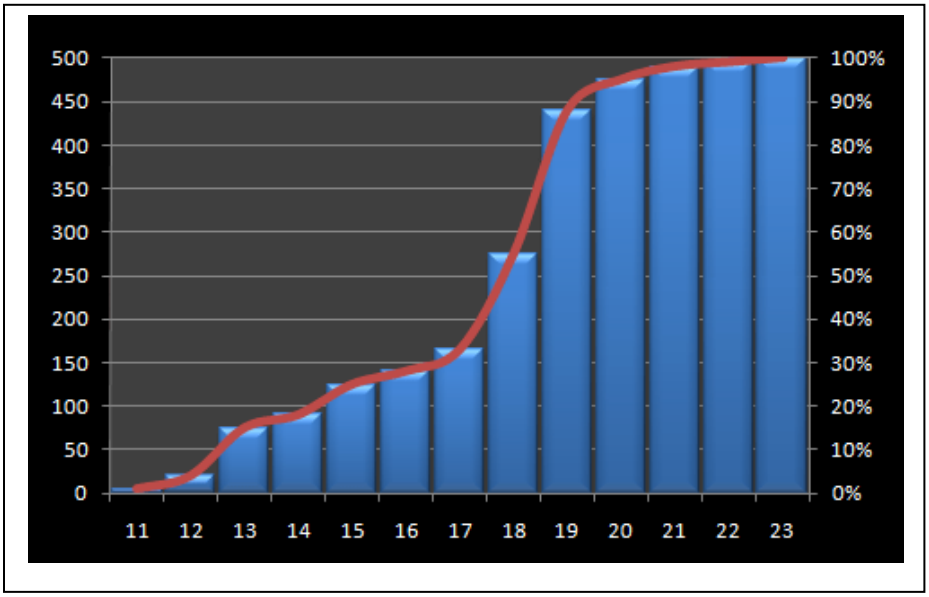
Activități	Cea mai bună estimare de terminare	Cea mai probabilă estimare de terminare	Cea mai pesimistă estimare de terminare
scrierea conținutului	4 zile	6 zile	8 zile
crearea interfeței grafice	5 zile	7 zile	9 zile
integrarea de elemente multimedia	2 zile	4 zile	6 zile
Durata realizării produsului	11 zile	17 zile	23 zile

Simularea Monte Carlo presupune generarea aleatorie de valori pentru diferirele taskuri prezente în crearea produsului cu scopul obținerii de posibile durare de derulare a acestuia. Pentru cazul concret dat vom genera variante de durate pentru cele trei taskuri implicate astfel generând valori uniform distribuite de durate de execuție în intervalul [4 zile, 8 zile] pentru taskul 1, [5 zile, 9 zile] pentru taskul 2 și respectiv [2 zile, 6 zile] pentru taskul 3. Efectuăm această generare de variante de posibile durate de execuțir a produsului de 500 ori. În tabelul 9.9 sunt prezentate rezultatele obținute pentru durata proiectului, luând în considerare suma duratelor celor 3 taskuri de realizat.

Tabelul 9.9

Durata totală a proiectului [zile]	De câte ori s-a generat aceast durată	Procentul variantei de durată care apare în cele 500 simulări
11	5	1%
12	20	4%
13	75	15%
14	90	18%
15	125	25%
16	140	28%
17	155	33%
18	275	55%
19	440	88%
20	475	95%
21	490	98%
22	495	99%
23	500	100%

Grafic, informțiile din acest tabel apar în urmîtoarea formă



Din grafic se observă că șansa de a termina proiectul în 17 zile este mai mică de 33%. În baza acestei analize proiectul se va termina în 19 – 20 zile.

Analiza Risk Monte Carlo :

Pași

1. Se identifică variabilele de risk ale proiectului
2. Se determină plaja de valori în care apar aceste variabile
3. Se identifică relațiile care apar între aceste variabile
4. Se realizează simularea ținând cont de cele două restricții anterioare (intervale de valori și legaturi între variabile)
5. Se analizează statitstic rezultatele obținute

9. Tehnici de modelare Monte - Carlo

9.2 Înlocuirea unui fenomen real cu un experiment statistic

În cadrul acestei tehnici analiza fenomenului real se înlocuieşte cu analiza unui fenomen artificial, descris de un model parametric de forma

$$y = f\left(x_1, x_2, x_3, ..., x_q\right)$$

unde:

$x_{i,i=1,q}$ definesc parametrii de intrare a modelului fiind reprezentați de un set de q variabile stohastice

y reprezintă răspunsul modelului atunci cînd la intrare sunt prezente un număr de $x_{i,i=1,q}$ variabile stohastice. Acesta are de asemenea un caracter stohastic.

9.3 Procedura pentru aplicarea metodei Monte Carlo în cazul variabilelor probabiliste discrete

CONSTRUIRE MODEL

Se referă la construirea distribuţiei de probabilitate a unei variabile stochastice sau probabiliste pe baza datelor istorice sau obţinute prin măsurare directă. Construirea distribuției de probabilitate este o procedură formată din patru etape:

1. Colectarea datelor referitoare la valorile variabilei probabiliste.
2. Determinarea probabilității de apariție a unei valori x_i, asocociată variabilei stohastice analizată
3. Gruparea datelor pe intervale şi construirea funcţiei distribuţiei cumulative asociată variabilei stohastice analizată $F(x_i)$
4. Analiza graficului histogramei frecvenţelor relative și construirea unor intervale de forma $[F(x_{i-1}), F(x_i)]$

Principiul de tehnicii de Modelare și Simulare ***Monte Carlo (MCS)*** este ilustrat in figura 3.

MODEL PARAMETRIC

Valoarea variabilei probabiliste x_i	Probabilitatea prezenței x_i $P(X = x_i) = P(x_i)$	Funcţia distribuţiei cumulative a prezenței x_i $F(x_i)$	Intervale $[F(x_{i-1}), F(x_i)]$	
Intrare			Iesire	**Construire** MODEL
Iesire			Intrare	**Utilizare** MODEL

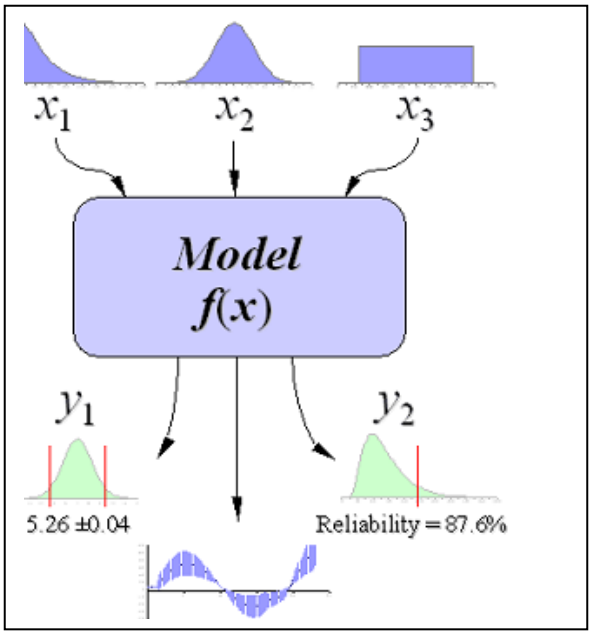


Figura 3. Principiul de Simulare Monte Carlo (MCS)

UTILIZARE MODEL

- Se utilizează generatoare de valori aleatoare în domeniul specificat de funcţia distribuţiei cumulative asociată variabilei stohastice de intrare care se analizează.

- În vederea obţinerii unei imagini corecte a evoluţiei fenomenului sau procesului studiat trebuie ca variabilele aleatoare să fie estimate cu abatere cât mai mică în raport cu cele ce apar în realitate şi experimentul să fie repetat de un număr convenabil de mare de ori, pentru a se pune în evidenţă principalele trăsături ale fenomenului modelat.

CONCLUZIE

- Metoda asociază problemei reale un model aleator şi prin generarea unor variabile aleatoare legate funcţional de soluţie, se realizează experienţe pe model şi se furnizează informaţii asupra soluţiei problemei deterministe.

Pașii care se parcurg sunt

Pas 1: Se creează un model parametric, $y = f(x_1, x_2, ..., x_q)$.

Pas 2: Se generează un set de intrări, $x_{i1}, x_{i2}, ..., x_{iq}$.

Pas 3: Se evaluează modelul și se memorează valorile pentru y_i.

Pas 4: Repetă pașii 2 și 3 pentru $i = 1$ to n.

Pas 5: Se analizează rezultatele utilizând histograme, statistici, interval de încredere, etc.

Pentru a ilustra modul în care se utilizează această tehnică vom considera următoarele exemple.

Exemplul 1

Tabelul 9.1 prezintă vânzările de calculatoare PC ale unei firme de profil în ultimele 30 de săptămâni. Se cere utilizând tehnica Monte Carlo simularea vânzărilor de calculatoare pentru 10 săptămâni utilizând distribuţia vânzărilor săptămânale de PC din tabelul 9.2

Tabelul 9.1

Număr curent i	Calculatoare vândute pe săptămână x_i	Număr de Săptămâni f_i
1	0	6
2	1	12
3	2	6
4	3	3
5	4	3

Pentru a simula cererea săptămânală de calculatoare se va determina distribuţia de probabilitate a cererii săptămânale utilizând frecvenţa relativă a cererii în cele 30 săptămâni, adică $P(x_i)=\frac{f_i}{30}$.

Tabelul 9.2

Număr curent i	Calculatoare vândute pe săptămână x_i	Număr de Săptămâni f_i	Probabilitatea cererii $P(x_i)$
1	0	6	0,20
2	1	12	0,40
3	2	6	0,20
4	3	3	0,10
5	4	3	0,10

Pasul 1.

În Tabelul 9.3 sunt prezentate valorile funcţiei distribuţiei cumulative $F(x_i)$ pentru vânzările săptămânale de calculatoare PC determinate pe baza distribuţiei discrete din Tabelul 9.2. Aceasta definește **modelul parametric** al fenomenului studiat

Tabelul 9.3

Calculatoare vândute pe săptămână x_i	Probabilitatea cererii $P(x_i)$	Funcția distribuției cumulative $F(x_i) = P(X \le x_i)$
0	0,20	0,20
1	0,40	0,60
2	0,20	0,80
3	0,10	0,90
4	0,10	1

Media determinată pe baza datelor ***reale*** referitoare la vânzările săptămânale de PC este

valoarea medie $\mu = 0\times0.2+1\times0.4+2\times0.2+3\times0.1+4\times0.1$

$\mu = 1.5$ calculatoare

dispersia $\sigma^2 = 0\times0.2+1\times0.4+2^2\times0.2+3^2\times0.1+4^2\times0.1-1.5^2$

$\sigma^2 = 1.45$ calculatoare

abaterea standard $\sigma = 1.204$ calculatoare

Pasul 2.

Tabelul 9.4 conţine valorile numerice pentru cazul vânzărilor săptămânale de calculatoare PC

MODEL PARAMETRIC

Valoarea variabilei probabiliste cerere / săptămână x_i	Număr de săptămâni f_i	Probabilitatea cererii $P(X = x_i) = P(x_i)$	Funcţia distribuţiei cumulative $F(x_i)$	Intervale $[F(x_{i-1}), F(x_i)]$
$x_1 = 0$	6	0,2	0,2	[0 0.2)
$x_2 = 1$	12	0,4	0,6	[0.2 0.6)
$x_3 = 2$	6	0,2	0,8	[0.6 0.8)
$x_4 = 3$	3	0,1	0,9	[0.8 0.9)
$x_5 = 4$	3	0,1	1,0	[0.9 1.0)

Tabelul 9.4



Pasul 3

Se generează un număr de 10 numere aleatoare uniform distribuite în intervalul [0, 1] care au drept corespondent cele 10 săptămâni pentru care se dorește obținerea evoluției probabile a vânzărilor. Evoluția este prezentată în Tabelul 9.5

Tabelul 9.5

Nr. aleator	Valoarea x_i a variabilei probabiliste	Număr calculatoare (bucăţi/săptămână)
0,486281	x2	1
0,928927	x5	4
0,205136	x2	1
0,852845	x4	3
0,005645	x1	0
0,651622	x3	2
0,799931	x3	2
0,333693	x2	1
0,416841	x2	1
0,011913	x1	0

Media determinată pe baza selecţiei simulate = 1,5 calculatoare pe săptămână, iar abaterea standard = 1,269 calculatoare.

Exemplul 2

Numărul de produse vândute zilnic în cadrul unui magazin este dat de o variabilă probabilistă discretă uniform repartizată în intervalul [6, 10]. Se cere simularea vânzărilor pentru 10 zile.

În Tabelul 9.6 sunt prezentate probabilităţile $P(x_i)$, $F(x_i) = P(X \le x_i)$ şi intervalele de numere aleatoare asociate fiecărei valori in intervalul [6, 10] (interval [a, b]). Acestea definesc **modelul parametric.**

Numărul de produse vândute zilnic x_i	Probabilitatea $P(X=x_i)=\frac{1}{5}$	Funcția distribuției cumulative $F(x_i)=P(X\le x_i)=\frac{1}{5}$	Intervale $[F(x_{i-1}),F(x_i))$
6	0.2	0.2	[0 0.2)
7	0.2	0.4	[0.2 0.4)
8	0.2	0.6	[0.4 0.6)
9	0.2	0.8	[0.6 0.8)
10	0.2	1.0	[0.8 1.0)

În Tabelul următor sunt simulate vânzările din 10 zile.

Ziua	Număr aleator u	Numărul de produse
1	0,709084	9
2	0,149934	6
3	0,294974	7
4	0,200192	7
5	0,189083	6
6	0,900415	10
7	0,940097	10
8	0,291185	7
9	0,002452	6
10	0,469177	8

Observaţie: În cazul variabilelor cu distribuţie uniformă discretă în intervalul [a, b], se poate genera direct o anumită valoare x_i (numar produse) cu ajutorul relaţiei:

$$x_i = \textit{partea întreagă din } [a + (b-a+1)u]$$

De exemplu, dacă s-a generat u = 0,709084, (numar uniform repartizat in intervalul 0-1) atunci pentru variabila probabilistă cu distribuţie uniformă discretă în intervalul [6, 10], numărul de produse vândute într-o zi oarecare este:

$$x_i = \textit{partea întreagă din } [6 + (10-6+1)* 0,709084] = 9 \textit{ produse}$$

Exemplul 3

Determinarea riscului în management prin modelare și simulare Monte Carlo

Presupunem că trebuie să conducem un proiect care implică crearea unui produs eLearning. Pentru creearea acestui produs sunt necesare realizarea unui număr de trei taskuri (activități)

- scrierea conținutului,
- crearea interfeței grafice și
- integrarea de elemente multimedia.

În baza unei experințe anterioare sau din aprecierea dificultății de realizare se determină durata acestor activități

– cel mai bun caz,

– cel mai probabil caz respectiv

– cel mai rău scenariu de terminare pentru fiecare din cele trei activități.

Modelul cu 3 parametri de intrare a activități de proiectare se construiește de următoarea manieră

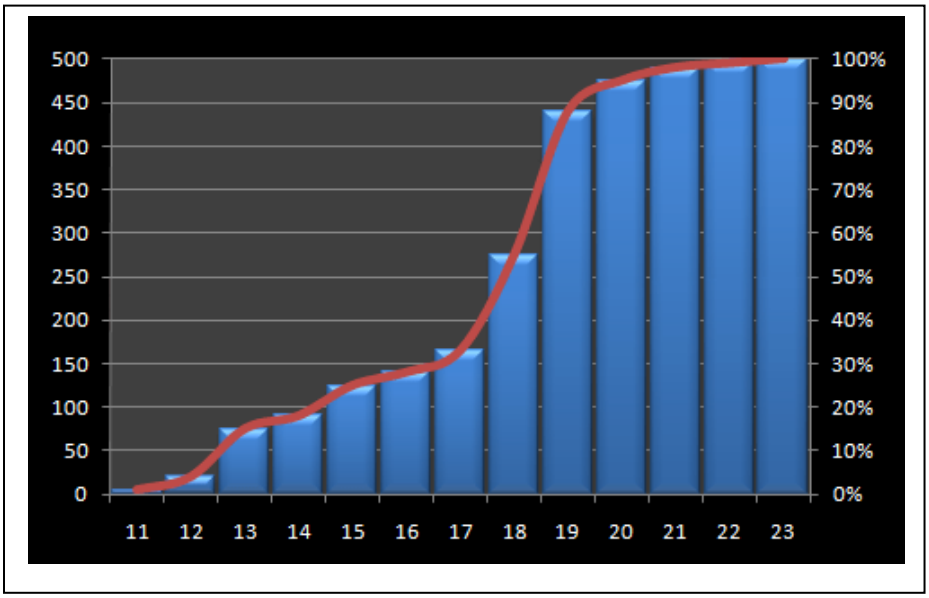
Activități $x_{i,i=1,3}$	Cea mai bună estimare de terminare	Cea mai probabilă estimare de terminare	Cea mai pesimistă estimare de terminare	Intervale $\left[F(x_{i-1}), F(x_i)\right)$
Scrierea conținutului x_1	4 zile	6 zile	8 zile	[4 zile, 8 zile]
Crearea interfeței grafice x_2	5 zile	7 zile	9 zile	[5 zile, 9 zile]
Integrarea de elemente multimedia x_3	2 zile	4 zile	6 zile	[2 zile,6 zile]
Durata realizării produsului	11 zile	17 zile	23 zile	

Simularea Monte Carlo presupune generarea aleatorie de valori pentru diferitele taskuri prezente în crearea produsului cu scopul obținerii de posibile durate de derulare a acestuia. Pentru cazul concret dat vom genera variante de durate pentru cele trei taskuri implicate astfel generând valori uniform distribuite de durate de execuție în intervalul [4 zile, 8 zile] pentru taskul 1, [5 zile, 9 zile] pentru taskul 2 și respectiv [2 zile, 6 zile] pentru taskul 3.

Efectuăm această generare de variante de posibile durate de execuție a produsului de 500 ori. În tabelul care urmează sunt prezentate rezultatele obținute pentru durata proiectului, luând în considerare suma duratelor celor 3 taskuri de realizat.

Durata totală a proiectului [zile]	De câte ori s-a generat aceast durată x_i	Procentul variantei de durată care apare în cele 500 simulări $F(x_i) = P(X \le x_i)$
11	5	1%
12	20	4%
13	75	15%
14	90	18%
15	125	25%
16	140	28%
17	155	33%
18	275	55%
19	440	88%
20	475	95%
21	490	98%
22	495	99%
23	500	100%

Grafic, informțiile din acest tabel apar în urmîtoarea formă



Din grafic se observă că șansa de a termina proiectul în 17 zile este mai mică de 33%. În baza acestei analize proiectul se va termina în 19 – 20 zile.

9.4 Procedura pentru aplicarea metodei Monte Carlo în cazul variabilelor probabiliste continue

Distribuţii continue de probabilitate

Spre deosebire de distribuţia discretă de probabilitate, nu se poate defini o distribuţie continuă de probabilitate care să determine probabilitatea pentru o anumită valoare particulară a variabilei probabiliste. Deoarece o variabilă probabilistă continuă este o variabilă care poate avea orice valoare într-un interval specificat, ea are un număr infinit de valori posibile în acel interval şi deci probabilitatea ca o variabilă probabilistă continuă să aibă o anumită valoare particulară este zero.

Pentru o variabilă probabilistă continuă se poate defini

- probabilitatea ca valoarea variabilei să fie cuprinsă într-un interval specificat.
- În acest scop, distribuţia este reprezentată printr-o curbă, iar probabilitatea se determină prin evaluarea ariei de sub curbă între limitele intervalului de pe axa *x*.
- Funcţia *f(x)* prin care se calculează această arie se numeşte ***funcţie de densitate de probabilitate*** şi trebuie să îndeplinească următoarele condiţii:

a) $f(x) \geq 0$ pentru toate valorile x

b) $\int_{-\infty}^{\infty} f(x)dx = 1$, specifică că aria de sub curbă pînă la axa valorilor x este 1

c) $P(a \leq x \leq b) = \int_{a}^{b} f(x)dx = 1$

Deci, pentru o variabilă probabilistă continuă se poate defini numai probabilitatea ca valoarea variabilei să fie cuprinsă într-un interval specificat. Această probabilitate se calculează cu o funcţie *f(x)* de densitate de probabilitate a cărui valoare reprezintă aria de sub curba *f(x)* corespunzătoare intervalului specificat. Probabilitatea $P(X \leq x)$ ca

valoarea variabilei probabiliste X să fie mai mică decât o anumită valoare particulară x se calculează cu funcţia de distribuţie cumulativă

$$F(x) = P(X \le x) = \int_{-\infty}^{x} f(v)dv$$

Aplicarea metodei Monte Carlo pentru obţinerea de selecţii simulate în cazul variabilelor probabiliste continue se poate face pe baza următoarei proceduri:

Pasul 1.

Se construiesc funcţiile *f(x)* de densitate de probabilitate şi *F(x)* de distribuţie cumulativă. În cazul distribuţiilor empirice, după organizarea şi gruparea pe intervale, valorile variabilei probabiliste continue se pot prezenta conform Tabelului următor. Graficul funcţiei F(x) al distribuţiei empirice cumulative va fi o curbă liniară pe porţiuni, obţinută prin unirea punctelor ale căror coordonate sunt limitele superioare ale intervalelor $[x_{i-1}, x_i]$ şi respectiv $[F(x_{i-1}), F(x_i)]$.

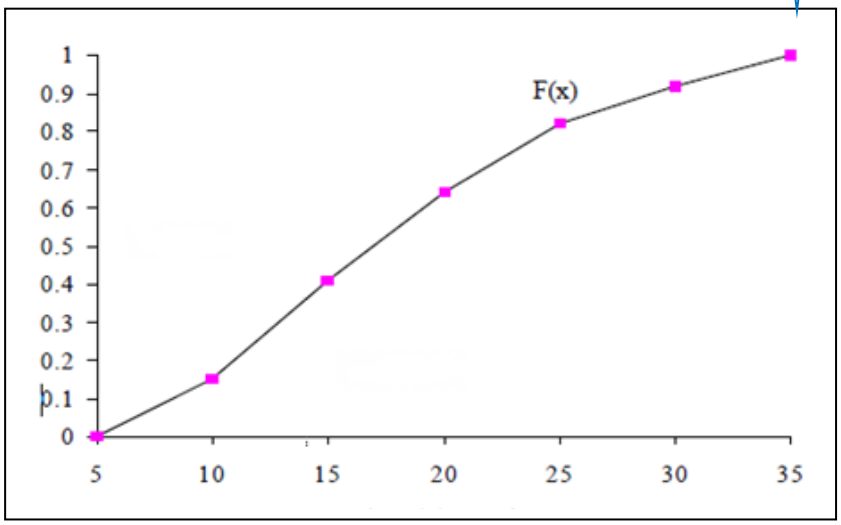
Intervale de valori ale variabilei probabiliste $[x_{i-1}, x_i)$	Frecvenţa f_i	Frecvenţa Relativă $\frac{f_1}{\sum_{k=1}^{m} f_k}$	Frecvenţa Cumulativă $F(x_1)$	Intervale $[F(x_{i-1}), F(x_i))$
$[x_0, x_1)$	f_1	$\frac{f_1}{\sum_{k=1}^{m} f_k}$	$F(x_1) = \frac{f_1}{\sum_{k=1}^{m} f_k}$	$[F(x_0), F(x_1))$
$[x_1, x_2)$	f_2	$\frac{f_2}{\sum_{k=1}^{m} f_k}$	$F(x_1) = \frac{f_1 + f_2}{\sum_{k=1}^{m} f_k}$	$[F(1), F(x_2))$
.....	.....			
$[x_{m-1}, x_m)$	f_m	$\frac{f_m}{\sum_{k=1}^{m} f_k}$	$F(x_m) = 1$	$[F(x_{m-1}), F(x_m)]$

Exemplu

Datele rezultate în urma observării timpului de servire – variabilă probabilistă, a 100 clienţi care au solicitat efectuarea unor operaţiuni la un ghişeu de bancă sunt prezentate în Tabelul următor.

Pasul 1

Intervale de valori ale variabilei probabiliste $[x_0, x_1)$	Frecvenţa f_i	Frecvenţa Relativă $\frac{f_1}{\sum_{k=1}^{m} f_k}$	Frecvența Cumulativă $F(x_1)$	Intervale $[F(x_{i-1}), F(x_i))$
[5, 10)	15	0.15	0.15	[0.00 0.15)
[10, 15)	26	0.26	0.41	[0.15 0.41)
[15, 20)	23	0.23	0.64	[0.41 0.64)
[20, 25)	18	0.18	0.82	[0.64 0.82)
[25, 30)	10	0.10	0.92	[0.82 0.92)
[30, 35)	8	0.08	1.00	[0.92 1.00]
	Total 100 clienți			



În Figura anterioară este reprezentată funcţia *F(x)* a distribuţiei cumulative pentru timpul de servire a clienţilor la un ghişeu bancar, obţinută prin unirea punctelor ale căror coordonate sunt limitele superioare ale intervalelor $[x_{i-1}, x_i]$ şi respectiv $[F(x_{i-1}), F(x_i)]$.

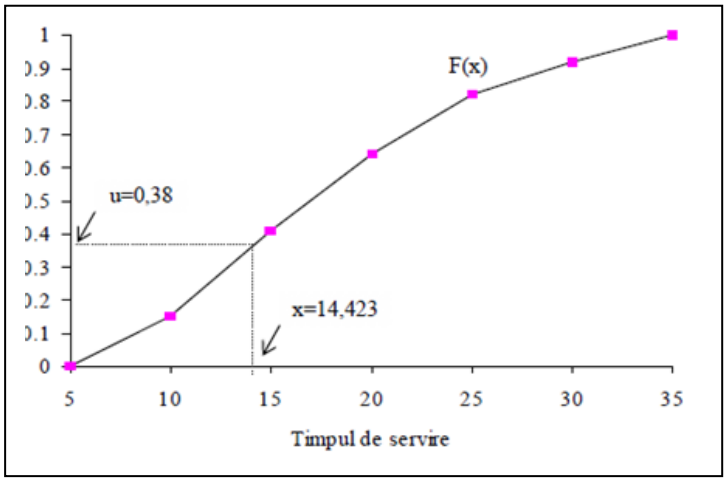
Pasul 2. Se generează un număr aleator *u* uniform repartizat în intervalul [0, 1]

Pasul 3. Se generează o valoare x a variabilei probabiliste continue prin rezolvarea ecuaţiei *F(x)* = u.

Dacă la *Pasul 2* s-a generat numărul aleator *u* = 0,38, ca şi în cazul variabilelor probabiliste discrete, se reprezintă numărul *u* pe axa verticală şi se proiectează pe orizontală până când întâlneşte curba F(x) şi, apoi, se citeşte valoarea *x* de pe axa orizontală.

Această procedură grafică poate fi înlocuită cu o procedură algebrică echivalentă de rezolvare a ecuaţiei F(x) = u cu *metoda interpolării*. Astfel, deoarece u = 0,38 aparţine intervalului de numere aleatoare [0,15 0,14) corespunzător intervalului [10 15) al timpului de servire, rezultă că

$$x = 10 + (0.38 - 0.15)\frac{15-10}{0.41-0.15} = 14.423 \text{ minute}$$



În general, dacă numărul aleator *u* aparţine intervalului de numere aleatoare $[F(x_{i-1}), F(x_i))$ asociat valorilor $[x_{i-1}, x_i)$, atunci se va genera valoarea x cu relaţia de interpolare:

$$x = x_{i-1} + \left(u - F\left(x_{i-1}\right)\right)\frac{x_i - x_{i-1}}{F\left(x_i\right) - F\left(x_{i-1}\right)}$$

Pentru *distribuţia uniformă continuă* în intervalul [a, b], ecuaţia F(x)=u este de forma

$$\frac{x-a}{b-a} = u \text{ de unde } x=a+u\left(b-a\right)$$

Concluzii

În tehnica Monte Carlo , pentru a imita sau reproduce ceea ce se întâmplă într-un sistem stochastic este necesar să se genereze în mod întâmplător valorile variabilelor probabiliste care intervin în problema decizională.

- Procesul de generare aleatoare a valorilor unei variabile probabiliste econstă în utilizarea unui generator de numere aleatoare uniform distribuite în intervalul [0, 1] şi a funcţiei distribuţiei cumulative asociată variabilei probabiliste respective.
- Numărul aleator furnizat de un generator este apoi utilizat pentru extragerea unei valori din distribuţia de probabilitate care **descrie comportamentul variabilei probabiliste**.

10. Particle Swarm Optimization

10.1 Introducere

Tehnica Optimizari roiului de particule (PSO - **P**article **S**warm **O**ptimization) este o metodă de calcul care optimizează o problemă încercând în mod iterativ să îmbunătățească o soluție candidat cu privire la o anumită măsură de calitate. Rezolvă o problemă prin faptul că are o populație de soluții candidate, numite particule pe care le mută în spațiul de căutare, conform relațiilor matematice care specifică modul de modificare a poziției și vitezei particulelor în contextul prezenței unei funcții fitness de evaluare a poziției curente (funcție fitness - Funcții matematice utilizate în optimizare pentru a evalua calitatea soluțiilor în algoritmi evoluționali sau de selecție natural).

Taxonomie

Particle Swarm Optimization se găsește la granița dintre tehnicile de modelare / simulare și domeniul Inteligenței Artificiale

Inspirație

Particle Swarm Optimization este inspirată de comportamentul social a unor animale,cum ar fi comportamentul zborului păsărilor în roi ca și comportamentul bancurilor de pești.

Strategie

Algoritmul operează cu un set de soluții candidat (parțiale). Fiecare soluție candidat este definită ca o particulă într-un spațiu multi-dimensional al tuturor soluțiilor posibile. În acest acest spațiu particula evoluează, aspect care se realizează prin atribuirea unor poziții și viteze aleatorii inițial tuturor particulelor. Algoritmul modifică poziția fiecărei particule în funcție de

- viteza sa,
- poziția globală cea mai cunoscută în spațiul problemei și
- cea mai bună poziție cunoscută unei particule.

Funcția obiectiv (fitness) este activată după fiecare actualizare a poziției. De-a lungul timpului, printr-o combinație de explorare și exploatare, particulele vor converge spre un optim sau mai multe optime.

Particle swarm optimization (PSO) - Tehnica optimizării roiului de particule. A fost propus de Kennedy, J.; Eberhart, R. (1995). "*Particle Swarm Optimization". Proceedings of IEEE International Conference on Neural Networks. IV. pp. 1942–1948. doi:10.1109/ICNN.1995.488968*.

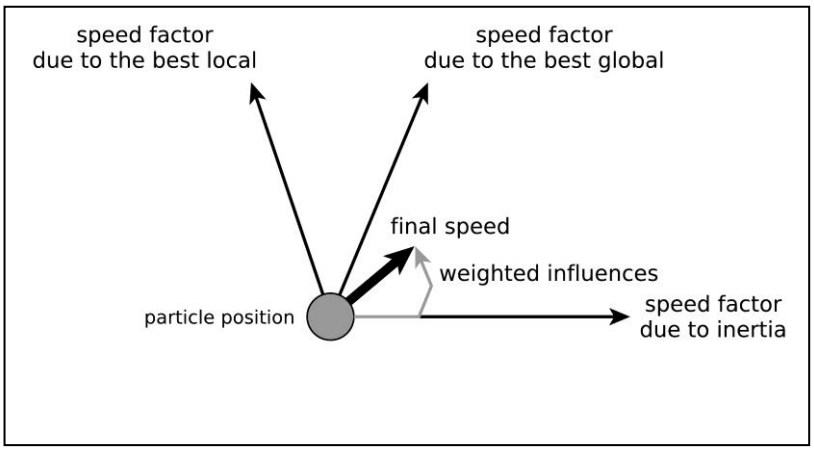
Concepte

- Particle Swarm Optimization, sau „*tehnica optimizării roiului de particule*”, , folosește un model populațional.
- Populația, *roiul*, este formată din *particule*, potențiale soluții. Roiul de particule, se spune că „zboară” în hiperspațiul de dimensiune *n*, unde *n* este dimensiunea unei soluții (nr. de parametri căutați). Acest zbor presupune găsirea unei soluții acceptabile plecând de la o populație de soluții inițială generată aleatoriu, care se îmbunătățește pe parcursul a mai multor iterații.
-

O particulă tinde să orbiteze

- în jurul celei mai bune sale poziții (***pbest***) și
- în jurul celei mai bune poziții (***gbest***) din grupul din care face parte.

- Fiecare particulă își ajustează viteza de deplasare și direcția în acord cu:
  - propria sa experiență de zbor și
  - cea a particulelor din roi.



- Algoritmul se poate termina luînd în considerare mai multe criterii, spre exemplu când o soluție satisfăcătoare a fost găsită ori s-au executat un număr predefinit de iterații.
-

Există două tipuri de PSO:

- varianta *gbest* și
- varianta *lbest*.

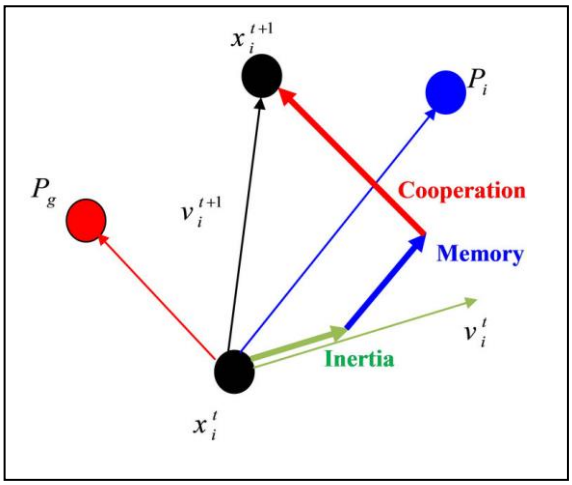
- în cadrul modelului *gbest*, o particulă schimbă informație cu tot roiul,
- pe când în cadrul modelului *lbest*, informația este schimbată doar cu particulele aflate într-o vecinătate a acesteia.

10.2 Algoritmul original

În cele ce urmează vom prezenta algoritmul original PSO, o variantă *gbest*, așa cum a fost descris de către creatorii săi (Kennedy, J.; Eberhart, R. (1995). "*Particle Swarm Optimization*". Proceedings of IEEE International Conference on Neural Networks. IV. pp. 1942–1948)

În acest model, la un moment oarecare ***t***, fiecare particula ***i***, are următoarele caracteristici:

- x_i – poziția curentă;
- v_i – viteza curentă;
- fiecare particulă are în propria memorie cea mai bună poziție descoperită de-a lungul iterațiilor, notată cu p_i, iar
- întreg roiul are în propria memorie cea mai bună poziție găsită de toate particulele sale, notată cu p_g definită ca:



Atât p_i, cât și p_g sunt actualizate la fiecare iterație a algoritmului.

Acest model de PSO, numit „global”, menține o singură cea mai bună poziție pentru tot roiul. Deoarece toate particulele din roi se îndreaptă spre această poziție, dacă ea nu ar fi actualizată destul de des, la fiecare iterație sau câteva iterații, atunci tot roiul ar converge prematur.

Algoritmul are trei mari faze, pe care le vom descrie separat: faza de inițializare, faza iterațiilor și faza de terminare.

Inițializarea

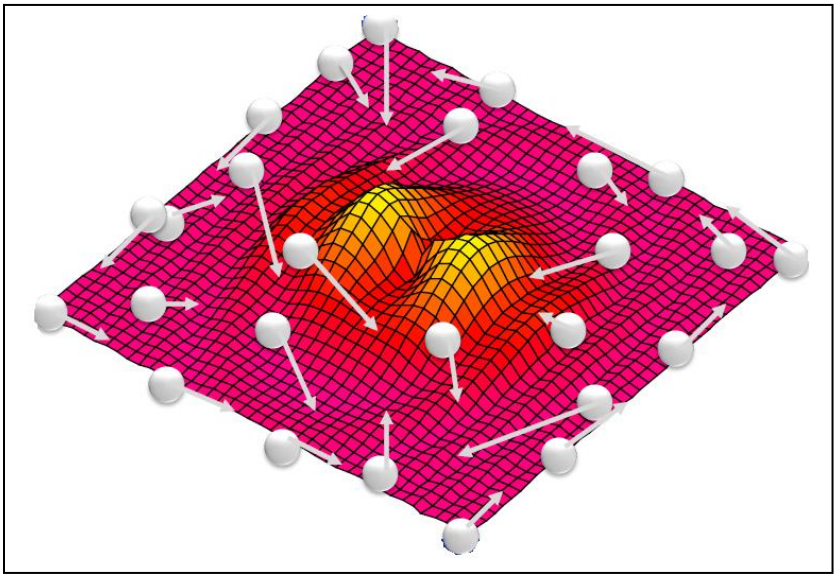
Înainte de a „zbura”, particulele au nevoie de o inițializare a componentelor vectoriale descrise mai sus.

Fiecărei componente

- x_i^t ale vectorului de poziție i se va asigna o valoare aleatoare uniform distribuită în intervalul maxim din spațiul de căutare $[-x_{max}, +x_{max}]$,
- v_i^t ale vectorului de viteză, fie i se va asigna inițial valoarea 0, fie o valoare uniform aleatoare din intervalul $[-v_{max}, +v_{max}]$,
- cele specificate mai sus se traduc prin următoarele calcule

$$x_0^i = x_{\min} + rand\left(x_{\max} - x_{\min}\right)$$
$$v_0^i = \frac{x_{\min} + rand\left(x_{\max} - x_{\min}\right)}{\Delta t}$$

Cele două componente (poziție, viteză) pot fi văzute în figura următoare.



Faza iterațiilor

În faza iterațiilor se actualizează pentru fiecare particulă în parte vectorul de viteză, v_t^i, iar pe baza acestuia și vectorul de poziție, x_t^i.

Schimbarea vitezei pentru fiecare particulă în fiecare iterație presupune luarea în considerare:

- poziției curente a particulei
- a celei mai bune poziții anterioare pe care a avut-o particula
- a celei mai bune poziții anterioare a roiului

Tendința de deplasare a particulei, influența roiului sunt ponderate aleator. Ecuația (1) arată cum se schimbă viteza în fiecare iterație iar ecuația (2) arată cum viteza contribuie la schimbarea poziției particulei.

În ecuație:

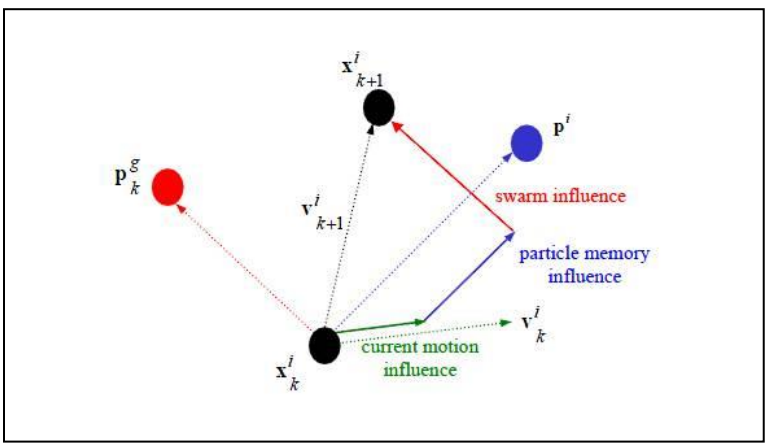
- ***w*** este factorul de inerție,
- ***c1*** este coeficientul de încredere în decizia pe care o ia particula, iar
- ***c2*** este coeficientul de încredere în comportarea roiului,
- ***rand*** este un generator de numere aleatoare uniform distribuite în (0, 1).

Cea mai bună locație anterioară a particulei este memorată în p_i iar cea mai bună poziție curentă a roiului este memorată în p_g .

Figura următoare arată cum fiecare din aceste componente se combină pentru a rezulta noua viteză și poziția care rezultă pentru o particulă la sfârșitul unei.

$$(1)\ v_{k+1}^i = w \cdot v_k^i + c1 \cdot rand(\ ) \cdot \frac{\left(p^i - x_k^i\right)}{\Delta t} + c2 \cdot rand(\ ) \cdot \frac{\left(p_k^g - x_k^i\right)}{\Delta t}$$

$$(2)\ x_{k+1}^i = x_k^i + v_{k+1}^i \cdot \Delta t$$



Pentru a căpăta proprietăți stohastice, algoritmul folosește, după cum se observă, doi vectori care au conținut uniform aleatoriu $rand \sim U(0,1)$, scalați de *coeficienții de accelerație* $c_1, c_2 \in [0,2]$.

- Coeficienții c_1, c_2 au rolul de a stabili mărimea maximă a pasului înspre
  - p_i – cea mai bună poziție personală , respectiv
  - p_g - cea mai bună poziție găsită de întregul roi.

- Coeficientul *w* are rolul de a balansa căutarea între
  - explorare globală (*w* mare) şi
  - explorare locală (*w* mic).

Ignorând viteza anterioară v_k^i , ecuația se împarte în două componente:

- ***componenta cognitivă personală***, $c1 \cdot rand \dfrac{\left(p^i - x_k^i\right)}{\Delta t}$

Această componentă ia în considerare doar experiențele personale ale particulei *i*, și influențează cât se va deplasa particula spre cea mai bună performanță a sa din trecut. Pentru actualizarea vitezei, Kennedy a folosit într-un experiment doar această componentă în ecuație, sub forma

$$v_{k+1}^i = w \cdot v_k^i + c1 \cdot rand \frac{\left(p^i - x_k^i\right)}{\Delta t},$$

omițând cea de-a doua componentă. Rezultatele obținute au fost mult inferioare soluției complete, deoarece particulele nu aveau nici o interacțiune.

- ***componenta socială de grup***, $c2 \cdot rand \dfrac{\left(p_k^g - x_k^i\right)}{\Delta t}$

Această componentă ia în considerare interacțiunile dintre particula ***i*** și roi. Influențează cât se va deplasa particula spre cea mai bună poziție găsită de roi.

În cadrul aceluiași experiment despre care am discutat mai sus, Kennedy a folosit pentru actualizarea vitezei doar componenta socială, sub forma

$$v_{k+1}^i = w \cdot v_k^i + c2 \cdot rand \frac{\left(p_k^g - x_k^i\right)}{\Delta t},$$

iar rezultatele au fost superioare primei încercări în care s-a folosit doar componenta cognitivă.

În prezent nu se știu prea multe despre cât de importante sunt cele două componente în parte, deși empiric s-a demonstrat că pe un set mai larg de probleme componenta socială ar fi mai importantă.

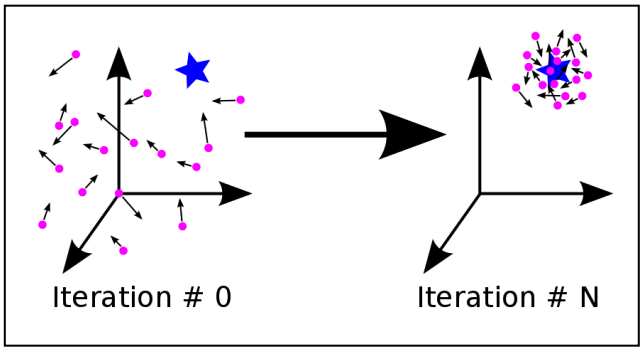
Cert este că, folosind ambele componente, rezultatele sunt satisfăcătoare în comparație cu alți algoritmi care încearcă să rezolve aceleași probleme.
Pe baza vectorului de viteză se calculează vectorul de poziție după formula:

$$x_{k+1}^{i} = x_{k}^{i} + v_{k+1}^{i} \cdot \Delta t$$

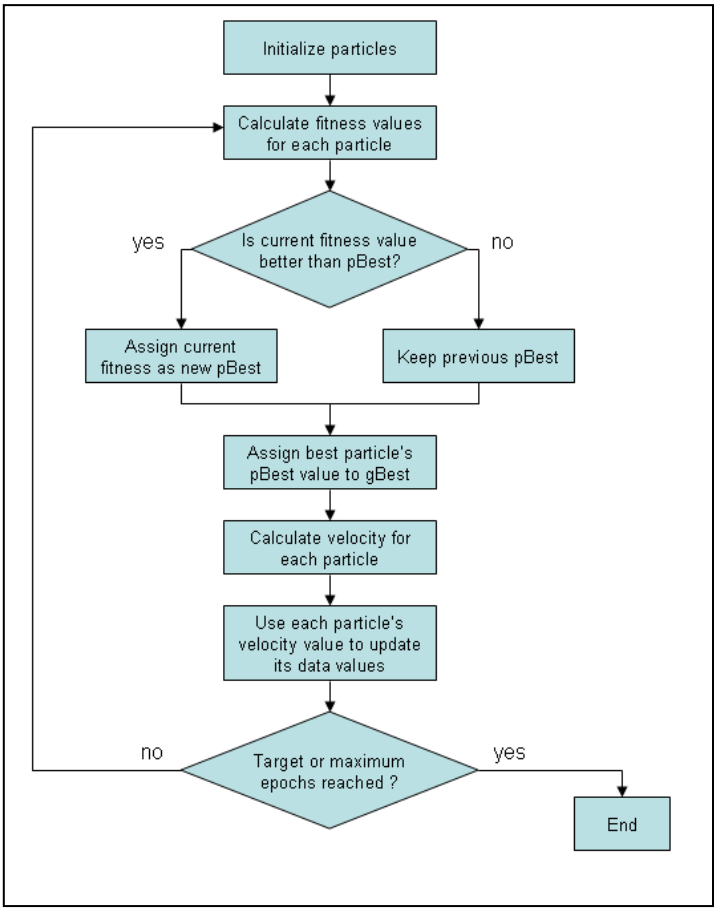
Urmează actualizarea celei mai bune poziții găsite de particula ***i*** până la momentul ***t***. După ce toate particulele au fost procesate, se poate calcula din nou cea mai bună poziție găsită de roi.

Faza de terminare

Algoritmul se rulează de un număr de ori stabilit dinainte sau până se atinge un nivel prestabilit de eroare. Desigur pot exista și alte criterii de oprire, acestea fiind date de natura problemei de rezolvat. În figura următoare se prezintă faza de iterație și ultima iterație în care s-a atins un optim.



În continuare redăm o simplă variantă de pseudo-cod, care sintetizează cele discutate mai sus.



10.3 Exemplu

Optimizarea unui portofoliu utilizând Particle Swarm Optimization

Algoritmul PSO poate fi utilizat pentru optimizarea unui portofoliu în contextul unor tranzacții bursiere. În contextul optimizării portofoliului, fiecare particulă poate defini o posibilă alocare de capital între diverse 'bunuri' din contextul portofoliului. Funcția de fitness a acestui portofoliu poate fi determinată utilizând funcții financiare care calculează riscul unei investiții. Presupunând că se utilizează pentru funcția de fitness – Sharpe ratio - (Indice de performanță a unui portofoliu. A fost descrisa de Sharpe care corelează câștigul prognozat al unui portofoliu eficient cu rata dobânzii pentru titlul cu risc zero si câștigul prognozat al pieței. Este în prezent un standard de măsură a eficienței unui portofoliu)

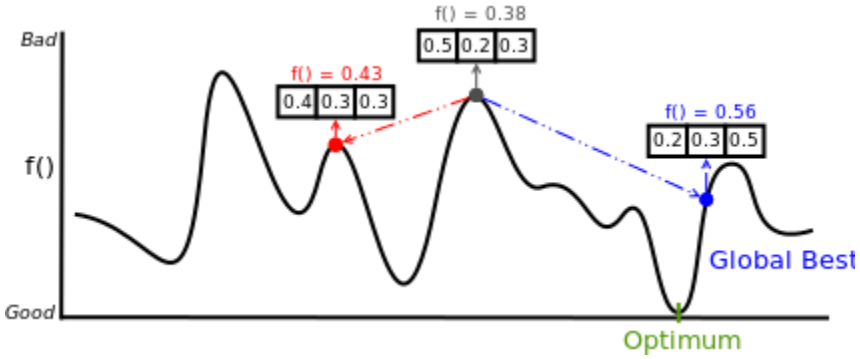
$$E\left(R_p\right) = R_f + \frac{\left[E\left(R_M\right) - R_f\right]}{\sigma_M}\sigma_P$$

Unde:

- $E(R_p)$ câștigul prognozat al portofoliului;
- R_f câștigul prognozat al titlului cu risc zero;
- $E(R_M)$ câștigul prognozat al pieței (indice);
- σ_P abaterea standard a portofoliului;
- σ_M abaterea standard a pieței.

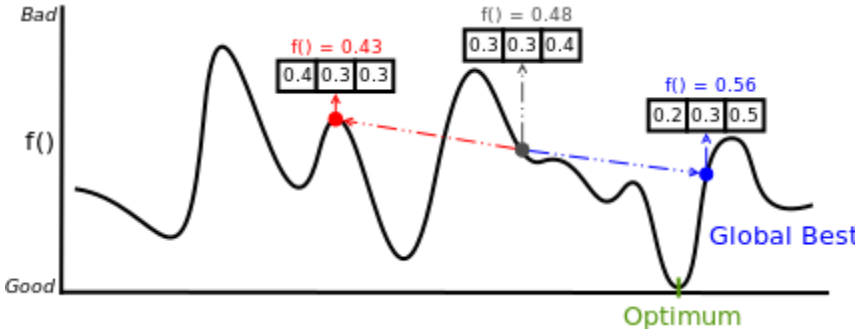
Considerăm următoare ilustrare a tehnicii PSO aplicată unui portofoliu constând din 3 bunuri

,

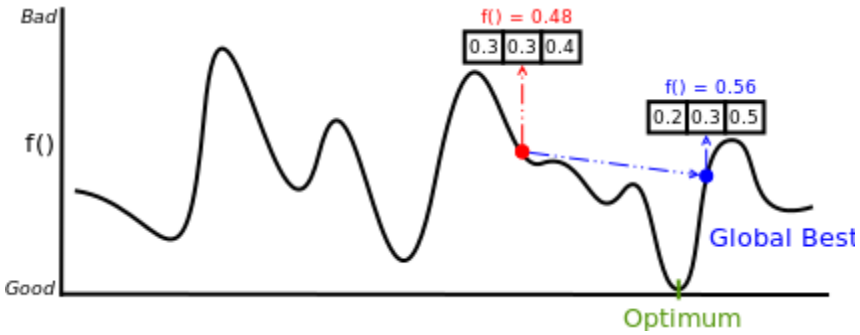


Particula gri este particula care a fost actualizată, Particula roșie este cea mai bună poziție a particulei gri (*pbest*) iar cea albastră cea mai bună poziție globală (gbest).

- Particula gri glisează în vectorul (0.5, 0.2, 0.3) care înseamnă că 50% din portofoliu este alocat pentru bunul 1, 20% pentru bunul 2 și 30% pentru bunul 3. Coeficientul Sharpe pentru această alocare de fonduri este de 0.38 care este mai mică decât cea mai bună poziție personală (particular roșie) și cea mai bună poziție global (particular albastră). Din această poziție particula gri este actualizată astfel încât aceasta se va apropria mai mult atât de valorile cele mai bune atât personale (pbest) cât ți globale (gbest). Rezultatul este mai bun decât cel din pasul anterior.



- Particula gri prezintă în acest pas valoarea (0.3, 0.3, 0.4) care are un coeficient Sharpe de 0.48. Deoarece această valoare este mai mare decât valoare pbest din pasul anterior poziția particulei va actualiza valoare pbest



Adevărata provocare în procesul de optimizare cu (PSO) este legată de asigurarea respectării faptului că constrângerile de optimizare a portofoliului sunt satisfăcute. Cele mai frecvente constrângeri sunt

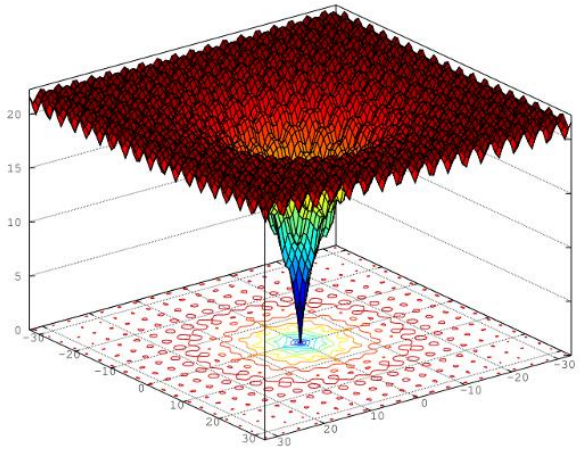
- în primul rând, legate de faptul că nu mai mult și nu mai puțin de 100% din capitalul disponibil se alocă între active (de exemplu, valoarea vectorului trebuie să fie 1,0). În al doilea rând, alocările negative de active nu sunt permise.
- Capitalul disponibil trebuie să fie alocat tuturor activelor din portofoliu. Aceasta din urmă fiind o constrângere cardinalitate. Două tehnici comune sunt utilizate pentru a se asigura că particulele satisfac constrângerile.
    - Pentru fiecare particulă care nu satisface constrângerile, se aplică un set de reguli pentru a modifica poziția particula lui astfel încât aceste restricții să fie îndeplinite.
    - Se penalizează prin intermediul funcției de fitness particulele care nu satisfac constrângeri

Anexa

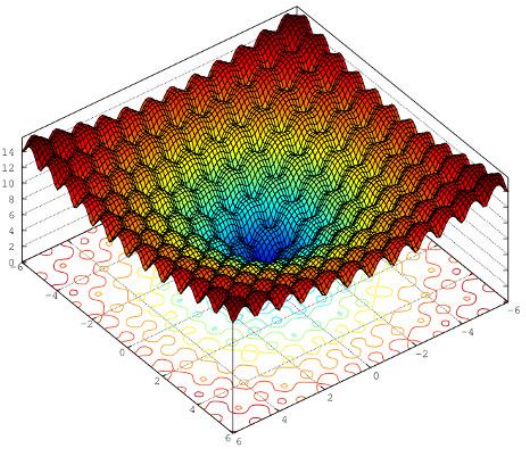
Ackley Function

$$f(x) = 20 + e - 20e^{-\frac{1}{5}\sqrt{\frac{1}{n}\sum_{i=1}^{n} x_i^2}} - e^{\frac{1}{n}\sum_{i=1}^{n}\cos(2\pi x_i)}$$

Dimensions:	n
Domain:	$-32.768 \leq x_i \leq 32.768$
Global Optimum:	$f(x) = 0.0$ at $x = (0.0, 0.0, \ldots, 0.0)$
Operator:	AckleyEvaluator
Charts:	



(a) [-32.768, 32.768]

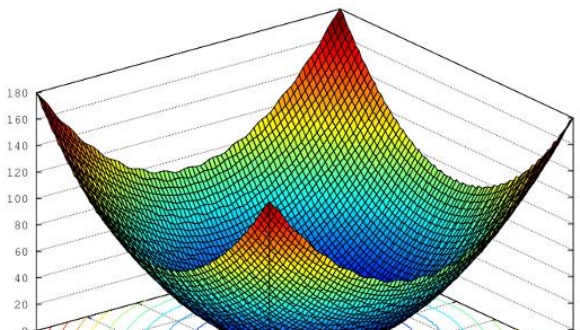


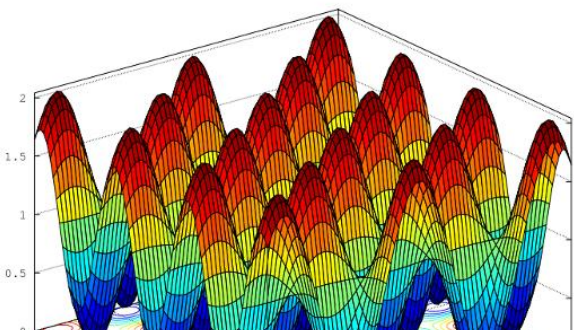
(b) [-6.0, 6.0]

Griewank Function

$$f(x) = 1 + \sum_{i=1}^{n} \frac{x_i^2}{4000} - \prod_{i=1}^{n} \cos(\frac{x_i}{\sqrt{i}})$$

Dimensions:	n
Domain:	$-600.0 \leq x_i \leq 600.0$
Global Optimum:	$f(x) = 0.0$ at $x = (0.0, 0.0, \ldots, 0.0)$
Operator:	GriewankEvaluator
Charts:	

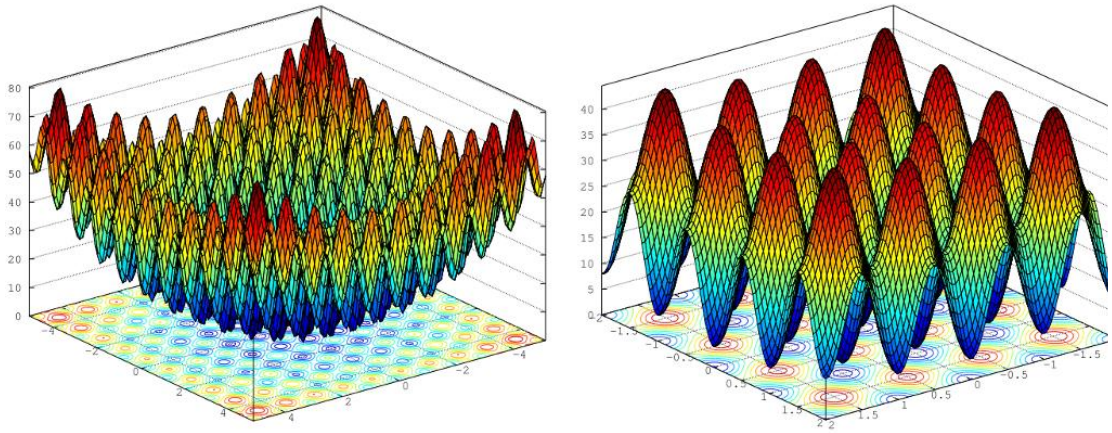




Rastrigin Function

$$f(x) = 10n + \sum_{i=1}^{n}[x_i^2 - 10\cos(2\pi x_i)]$$

Dimensions: n
Domain: $-5.12 \leq x_i \leq 5.12$
Global Optimum: $f(x) = 0.0$ at $x = (0.0, 0.0, \ldots, 0.0)$
Operator: RastriginEvaluator
Charts:



(a) [-5.12, 5.12]

(b) [-2.0, 2.0]

Rosenbrock Function

$$f(x) = \sum_{i=1}^{n-1}[100(x_i^2 - x_{i+1})^2 + (x_i - 1)^2]$$

Dimensions: n
Domain: $-2.048 \leq x_i \leq 2.048$
Global Optimum: $f(x) = 0.0$ at $x = (1.0, 1.0, \ldots, 1.0)$
Operator: RosenbrockEvaluator
Charts:

