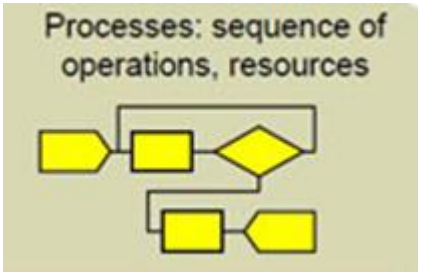
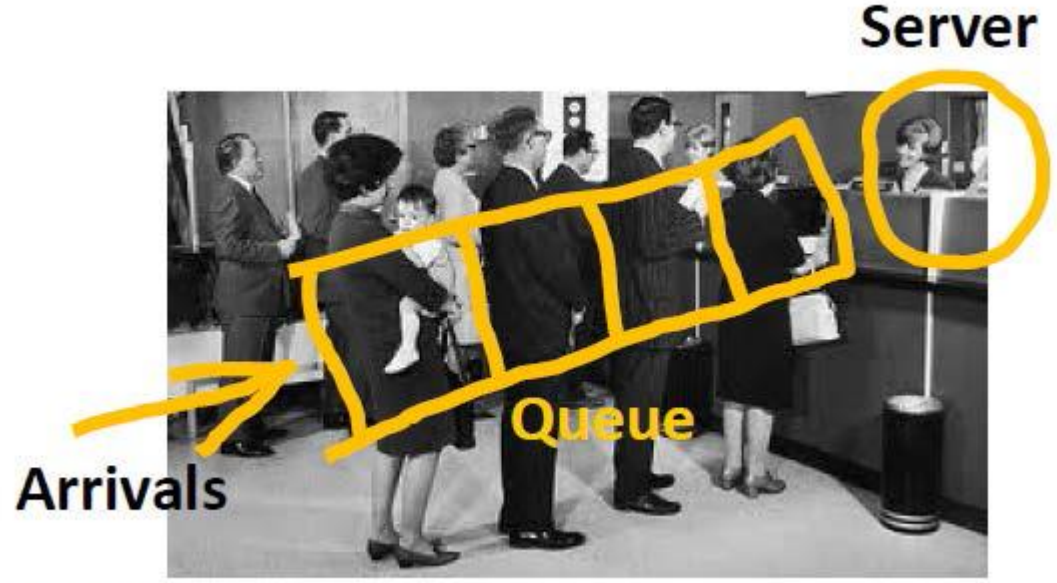
Elemente de bază în modelarea sistemelor cu şiruri de aşteptare

CONCEPTE



Sistemul Modelat





A queue in a bank

Sistemul modelat este descris de o secvență de evenimente interconectate care se desfășoară în timp la momente discrete de timp.



Arhitectura unui model cu șiruri de așteptare

Modelul se reprezintă prin două componente

a) Un graf care descrie succesiunea evenimentelor din sistemul din lumea reală.

b) Un element mobil care definește solicitarea ce declanșează un eveniment din sistemul modelat.



Arhitectura unui model cu șiruri de așteptare

În structura de tip graf

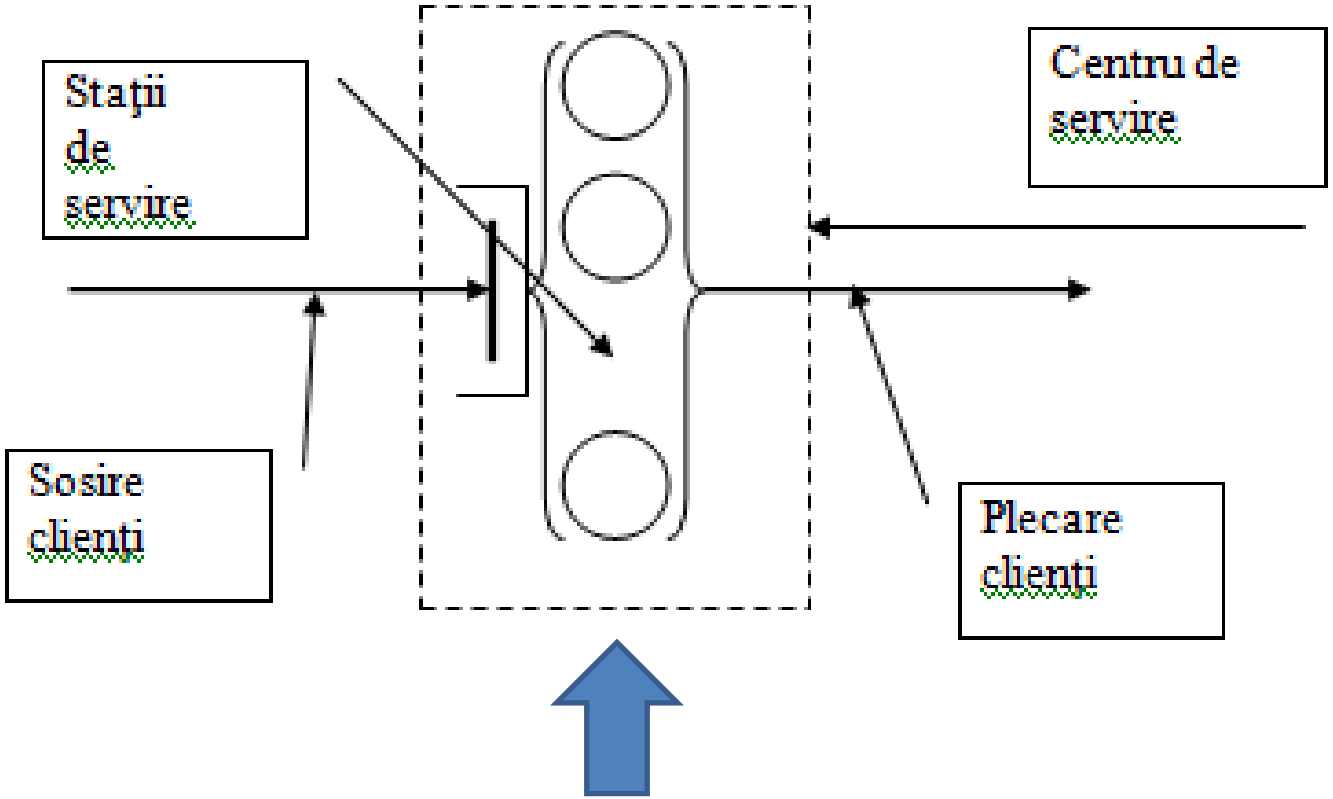
- Nodurile

  reprezintă activități.

- Arcele

  definesc succesiunea în timp a activităților. Datorită faptului că arcele prezintă un sens de conectare, graful sistemului este orientat.

Structura unui nod a grafului



Denumirea pentru nod este de centru de servire



Structura unui nod a grafului

Un centru de servire (nod din graful activităților ce definește sistemul modelat) prezintă o structură complexă formată din

- una sau mai multe stații de servire.

Acestea modelează activitatea propriu zisă din sistemul modelat

- un șir de așteptare

Acesta modelează fenomenul de așteptare a cererilor pentru declanșarea activității modelate de șirul de stația (stațiile) de servire



Structura unui nod a grafului

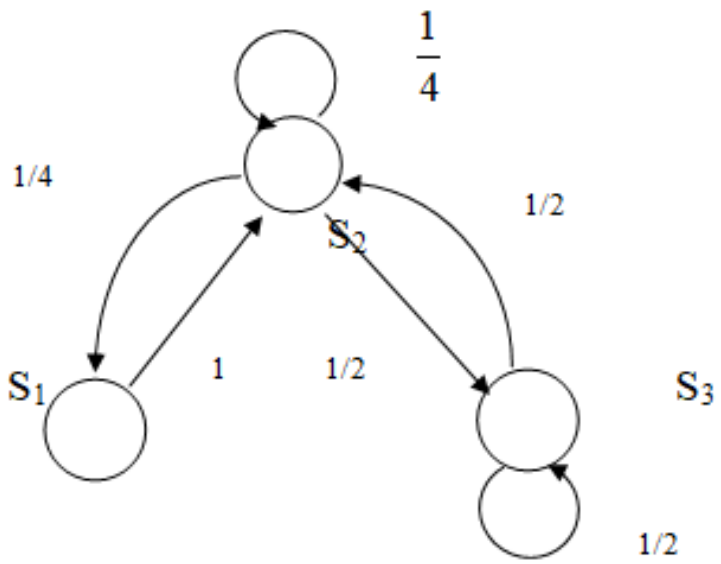
La nivelul unui centru de servire (nod din graful activităților ce definește sistemul modelat) apar un număr de patru procese

1. Un proces de sosire a clienților
2. Un proces de așteptare – clienții rămân în șirul de așteptare până în momentul în care o stație de servire devine disponibilă. Ocuparea ei este echivalentă cu declanșarea activității pe care o reprezintă nodul din graf.
3. Un proces de derulare a activității. Operația este echivalentă cu execuția în stația de servire
4. Un proces de plecare a clientului din centrul de servire. Operația este echivalentă cu terminarea activității pe care a declanșat-o clientul

Structura unui arc a grafului

Specifică numai modul de conectare a două activități în timp.

Dacă arcele au etichetă, aceasta va reprezenta procentul de solicitări care vehiculează respectivul arc.





Structura elementului mobil

Elementul mobil definește o entitate care se deplasează în graf cu rolul de a declanșa activitățile care sunt definite de noduri.

Elementul mobil, corespunde elementului mobil din sistemul modelat (mașină, pieton, mesaj, etc).

Este cunoscut sub denumirea generică de cerere (solicitare) sau client.



Atributele unui model cu șiruri de așteptare

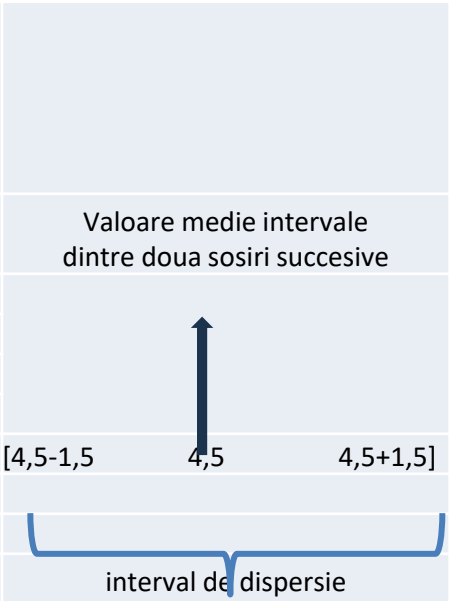
- Atributele apar atât la nivelul unei activități cât și la nivelul unui client.

- În ambele cazuri acestea, caracterizează individual o activitate sau un client. În cazul unui client, este posibil ca atributele să nu fie prezente, caz în care clientul este utilizat numai pentru declanșarea activităților descrise de arhitectura grafului.

Atributele unui model cu șiruri de așteptare

Valoare atributelor este stabilită în urma măsurătorilor efectuate pe sistemul real. În urma măsurătorilor se obține o valoare medie si un interval de dispersie.

Client (cerere)	Momentul Sosiri [ut]	Interval intre doua sosiri succesive [ut]	
1	3	3	
2	7	4	
3	11	4	
4	16	5	
5	22	6	
6	26	4	
7	31	5	
8	38	7	
9	41	3	
10	45	4	
Valoare medie		4,5	
Abatere Standard		1,50	





Mărimi caracteristice procesului de sosire/servire

Parametru - valori medii	*Notație*
Frecvența de sosire a clienților	λ
Timpul mediu de servire	s
Frecvența de servire	μ
Gradul de utilizare	ρ
Capacitatea de trecere	τ
Timpul mediu de așteptare	W
Timpul mediu de răspuns	T
Lungimea șirului de așteptare	Q
Numărul mediu de cereri din centrul de servire	N



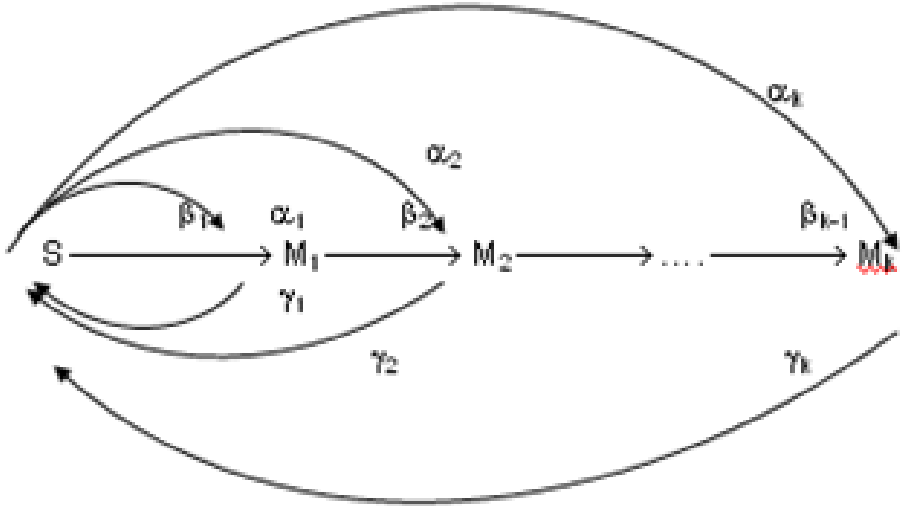
Procesul de construire a unui model

Modelare:

este operaţia de construire a modelului în cadrul căreia se face trecerea de la fenomenul real la modelul fizic sau matematic prin neglijarea unor elemente şi aspecte – uneori esenţiale ale sistemului real – în vederea obţinerii unor informaţii despre sistem.

Modelul ca reprezentare satisfăcătoare a unui sistem este rezultatul unor iteraţii în care se parcurge de fiecare dată ciclul

Procesul de construire a unui model



unde:
S- sistemul modelat;
β_k- informaţiile obţinute de la modelul k pentru construirea modelului k+1;
γ_k – rezultatele obţinute de la modelul k care se compară cu sistemul real:
α_k - informaţiile obţinute direct de la sistem, utilizate în construirea modelului M_k.
Dacă γ_k dă un răspuns satisfăcător privind calitatea reprezentării realizate de model, procesul de construire a modelului se opreşte, iar modelul M_k poate fi acceptat pentru utilizări ulterioare ca reprezentare a sistemului S.

Procesul de construire a unui model

Parametri măsurați pe sistemul real	*Simbol*	*Parametri utilizați în model*	*Parametri Rezultați din simulare*
Frecvența de sosire a clienților	λ	λ	
Timpul mediu de servire	s	s	
Frecvența de servire	μ	μ	
Gradul de utilizare	ρ		ρ
Capacitatea de trecere	τ		τ
Timpul mediu de așteptare	W		W
Timpul mediu de răspuns	T		T
Lungimea șirului de așteptare	Q	SE COMPARĂ	Q
Numărul mediu de cereri din centrul de servire	N		N

Procesul de validare a unui model

Parametri măsurați pe sistemul real	*Parametri Rezultați din simulare*	*Decizie*
Gradul de utilizare		
Valoare medie  *Dispersie*	ρ ***DA Aparține la intervalul măsurat*** [ρ-σ , ρ+σ]	*Model corect*
	ρ ***NU Aparține la intervalul măsurat*** [ρ-σ , ρ+σ]	*Model incorect*


MULTIMETHOD
MODELING
SYSTEM
DYNAMICS
AGENT BASED
MODELING
DISCRETE EVENT
MODELING

Întrebări???

MODELARE și SIMULARE

Markov Chains





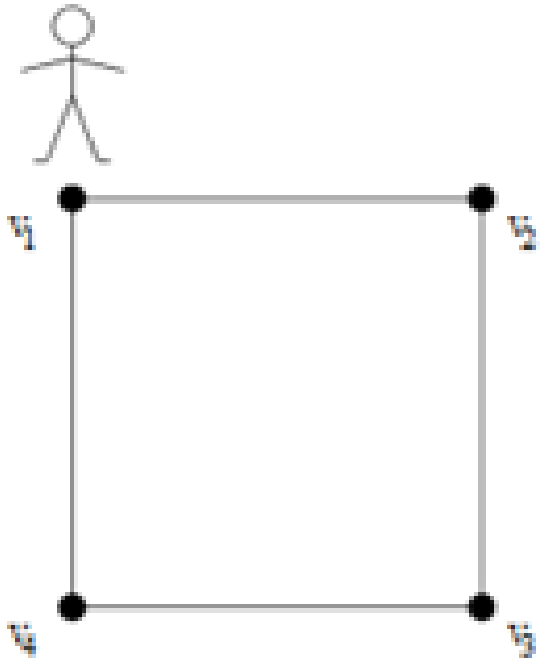
Markov Chains
Concepte

Sunt utilizate pentru descrierea unui sistem prin intermediul unui graf în care:

- nodurile reprezintă stări în care este prezent sistemul;
- arcele sunt utilizate pentru descrierea modului în care sistemul tranzitează dintr-o stare în alta;
- etichetele arcelor reprezintă şansa (probabilitatea) ca sistemul să treacă dintr-o stare în altă stare.

Markov Chains
Exemplu. Pieton aleator.

Considerăm un "*pieton aleator*" într-un oraș mic, care are numai 4 străzi și 4 colțuri de stradă v_1, v_2, v_3, v_4 aranjate ca în figura următoare:



La momentul 0 , pietonul stă în colțul de stradă v_1.
La momentul 0 aruncă o monedă în aer și după cum cade, cap sau stemă se deplasează la v_2 sau v_4.

Alegerea de deplasare la următorul colț de stradă este *în sens orar dacă este cap* și *trigonometric dacă este stemă*. Această procedură este utilizată pentru toate momentele de timp *n = 0, 1, 2, 3, ….*



Markov Chains

Exemplu. Pieton aleator.

Notăm cu X_n o variabilă care să definească colțul de stradă unde este prezent pietonul la momentul de timp *n.*

În acest context mulțimea (X_0, X_1, X_2, …..) va defini un proces aleator care ia valori din mulțimea {1, 2, 3, 4}.

Deoarece pietonul începe să se deplaseze la momentul de timp 0 fiind prezent în v_1, vom avea

$$P(X_0 = 1) = 1$$

La următorul moment de timp pietonul se va putea deplasa la v_2 sau v_4 cu probabilitatea ½ fiecare astfel că

$$P(X_0 = 2) = \frac{1}{2} \qquad P\left(X_{n+1} = v_1 \middle| X_n = v_2\right) = \frac{1}{2}$$

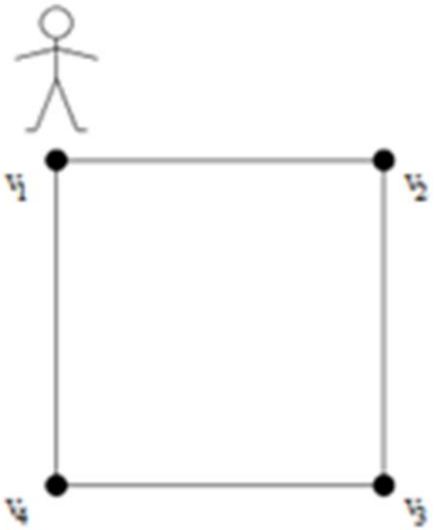
Markov Chains

Exemplu. Pieton aleator.

Să luăm în considerare un alt aspect. Presupunem că la momentul de timp *n* , pietonul este la v_2.
Putem scrie că

$$P\left(X_{n+1} = v_1 \middle| X_n = v_2\right) = \frac{1}{2}$$

$$P\left(X_{n+1} = v_3 \middle| X_n = v_2\right) = \frac{1}{2}$$



Markov Chains

Exemplu. Pieton aleator.

Datorită mecanismului de alegere a sensului de deplasare pe care pietonul l-a adoptat, se poate lua în considerare întregul istoric al deplasării în oraș de forma

$$P\left(X_{n+1}=v_1 \mid X_0=i_0, X_1=i_1, \ldots\ldots, X_{n-1}=i_{n-1}, X_n=v_2\right)=\frac{1}{2}$$

MÂINE — ISTORIC trecutul — AZI

$$P\left(X_{n+1}=v_3 \mid X_0=i_0, X_1=i_1, \ldots\ldots, X_{n-1}=i_{n-1}, X_n=v_2\right)=\frac{1}{2}$$

pentru orice alegere din $i_0, i_1, \ldots\ldots i_{n-1}$.

Cu alte cuvinte, probabilitatea ca sistemul să treacă la următoarea stare depinde doar de starea actuală și nu de modul în care a ajuns acolo.



Markov Chains
Model. Reprezentare matematică

În acest context sistemul modelat este reprezentat prin

Stările în care poate fi prezent acesta ⟺ $S = \{s_1, s_2, s_3, s_4, \ldots\ldots s_n\}$

Evoluția în timp a sistemului este descrisă de o variabilă aleatoare unde fiecare variabilă X_n poate lua o valoare dintr-o mulțime de stări la momentul de timp *n* ⟺ $X_1, X_2, X_3, \ldots\ldots$

Modul în care se efectuează tranziția , evoluția, dintr-o stare in alta ⟺

$$P\left(X_{n+1} = s_j \mid X_0 = s_0, X_1 = s_1, \ldots\ldots, X_{n-1} = s_{n-1}, X_n = s_n\right)$$
$$= P\left(X_{n+1} = s_j \mid X_n = s_i\right)$$
$$= P_{i,j}$$



Markov Chains
Model. Reprezentare matematică
Caracteristici

(1)
Relația spune că distribuția de valori pentru X_{n+1} dată de istoricul valorilor din stările trecute $X_0, X_1, X_2, \ldots\ldots, , X_n$ depinde numai de valoarea obținută în starea X_n .

Cu alte cuvinte pentru a fi posibil de **prevăzut** ce se va întâmpla "*mâine*" (timpul *n+1*) este necesar să cunoaștem ce se întâmplă "*azi*" (timpul *n*) iar "*trecutul – istoricul*" (timpul *0, 1, …., n-1*) nu ne furnizează nici o informație utilă.

Această afirmație este corectă, deoarece o aruncare a monedei în pasul *n+1* este independentă de toate cele n aruncări anterioare $X_0, X_1, X_2, \ldots\ldots, , X_n$. Acest fenomen este cunoscut sub denumirea de *lipsă de memorie* sau *proprietate Markov* iar sistemul în care apare acest fenomen este cunoscut sub denumirea de *sistem cu proprietate Markov*.



Markov Chains

Model. Reprezentare matematică

(2)

distribuția de valori pentru X_{n+1} depinde numai de valorile din starea precedentă X_n fiind aceeași pentru toate momentele de timp n , (aceasta deoarece mecanismul prin care pietonul ia decizii în fiecare moment de timp n este același).

Această proprietate este cunoscută ca omogenitate a unui proces Markov sau pe scurt *omogenitate*.



Markov Chains
Model. Construcție.

Modelul unui sistem definit printr-un lanț Markov presupune

- Definirea mulțimii de stări în care poate fi prezent sistemul $S=\{s_1, s_2, \ldots s_k\}$
- Specificarea modului în care sistemul reprezentat trece dintr-o stare în altă stare . Aceast proces evolutiv este specificat de o matrice de probabilități de tranziție de dimensiune *(k x k)* cu elemente $\{P_{i,j} : i, j = 1, \ldots,k\}$.
- Construirea elementelor matricei de tranziție. Acestea poartă numele de ***probabilități de tranziție***. Probabilitatea de tranziție P_{ij} este probabilitatea ca să fim în starea s_j "*mâine*" atunci când suntem în starea s_i "*azi*".

$$P\left(X_{n+1} = s_j \mid X_0 = s_0, X_1 = s_1, \ldots\ldots, X_{n-1} = s_{n-1}, X_n = s_n\right)$$

$$P_{i,j} = P\left(X_{n+1} = s_j \mid X_n = s_i\right)$$

$$= P_{i,j}$$

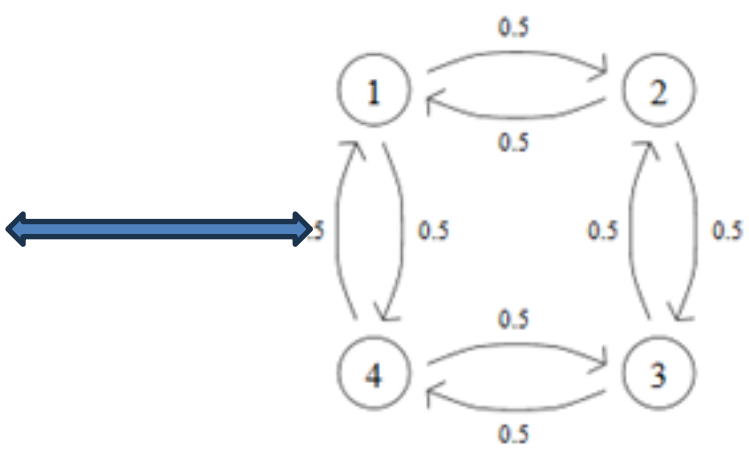
Termenul omogen se referă la faptul că indiferent de starea în care se găsește sistemul se utilizează aceeași procedură trecere dintr-o stare în alta. Atunci când se vorbește despre *lanț Markov* proprietatea de *omogen* este implicită și se omite.

Markov Chains

Model. Pieton aleator.

De exemplu pentru un "*pieton aleator*" acesta poate fi definit de un lanț Markov unde spațiul stărilor este {1, . . .,4} și matricea de tranziție

$$(3)\quad \begin{matrix} 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \end{matrix}$$



O modalitate curentă de reprezentare a unui lanț Markov este grafică prin intermediul unui **graf de tranziție**.

Un graf de tranziție (matricea probabilităților de tranziție) constă din noduri care definesc stările unui lanț Markov, iar arcele dintre noduri vor reprezenta probabilitățile de tranziție. Pentru exemplul dat definit prin matricea *(3)* vom avea următoarea reprezentare

Markov Chains

Model. Caracteristici

(1)

Fiecare matrice de tranziție satisface următoarele condiții

(1) $P_{i,j} \geq 0$

(2) $\sum_{j=1}^{k} P_{i,j} = 1$

pentru toți *i*, *j* ϵ {1,….k},

Proprietatea *(1)* specifică faptul că toate probabilitățile de tranziție sunt pozitive ia proprietatea *(2)* că suma lor este întotdeauna 1.



Markov Chains

Model. Caracteristici

(2)

O caracteristică importantă a unui lanț Markov poartă denumirea de **distribuție inițială.** Aceasta specifică starea inițială a unui lanț Markov, fiind reprezentată de un vector $\mu^{(0)}$

Deoarece $\mu^{(0)}$ reprezintă o distribuție de probabilitate vom avea

$$\mu^{(0)} = \left(\mu_1^{(0)}, \mu_2^{(0)}, ..., \mu_k^{(0)}\right)$$

$$= \left(P\left(X_0 = s_1\right), P\left(X_0 = s_2\right), ...P\left(X_0 = s_k\right)\right)$$

Avem
- *k* stări
- stare inițială *(0)*

Cunoscând distribuția inițială $\mu^{(0)}$ și matricea de tranziție ***P*** se pot calcula toate distribuțiile de probabilitate $\mu^{(1)}, \mu^{(2)}, ...$

unui lanț Markov. Această observație face ca calculul distribuției să se reducă la o simplă multiplicare de matrice. Convenim să scriem $\boldsymbol{P^n}$ pentru a specifica putere a *n* a acestei matrice

$$\mu^{(n)} = \mu^{(0)} \times P^n$$

Markov Chains

Exemplu. Pieton aleator.

$$\mu^{(0)} = \begin{pmatrix} 1 & 0 & 0 & 0 \end{pmatrix}$$

$$\mu^{(1)} = \mu^{(0)} \bullet \begin{bmatrix} 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \end{bmatrix}$$

$$\mu^{(2)} = \mu^{(1)} \bullet \begin{bmatrix} 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \end{bmatrix}$$

•

•

$$\mu^{(n)} = \mu^{(n-1)} \bullet \begin{bmatrix} 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \end{bmatrix}$$

Pentru exemplul dat al "*pieton aleator*" se observă

- cunoscând distribuția inițială $\mu^{(0)}$ și matricea de tranziție P se pot calcula toate distribuțiile

$$\mu^{(1)}, \mu^{(2)}, \ldots$$

$$\mu^{(n)} = \left(\mu_1^{(n)}, \mu_2^{(n)}, \ldots, \mu_k^{(n)}\right)$$

$$= \left(P\left(X_n = s_1\right), P\left(X_n = s_2\right), \ldots . P\left(X_n = s_k\right)\right)$$

- a unui lanț Markov. Această observație face ca calculul distribuției să se reducă la o simplă multiplicare de matrice. Convenim să scriem P^n pentru a specifica putere a *n* a acestei matrice

$$\mu^{(n)} = \mu^{(0)} \bullet P^n$$



Markov Chains

Definiție formală

Un Lanț Markov este o secvență de variabile aleatoare

$$X_1, X_2, X_3, \ldots\ldots$$

unde fiecare variabilă X_n poate lua o valoare dintr-o mulțime de stări

$$S = \{s_1, s_2, s_3, s_4, \ldots\ldots s_n\}$$

Proprietatea principală a lanțului Markov este:

$$P\left(X_{n+1} = s_j \mid X_0 = s_0, X_1 = s_1, \ldots\ldots, X_{n-1} = s_{n-1}, X_n = s_n\right)$$
$$= P\left(X_{n+1} = s_j \mid X_n = s_i\right)$$
$$= P_{i,j}$$

Cu alte cuvinte, probabilitatea ca sistemul să treacă la următoarea stare depinde doar de starea actuală și nu de modul în care a ajuns acolo.

MODEL



Markov Chains

Elemente cheie

1. *Spațiul de stări*: Este mulțimea tuturor stărilor posibile pe care le poate lua lanțul. Acestea pot fi discrete (ex: o mulțime de numere finite sau infinite) sau continue.

2. *Matricea de tranziție*: Aceasta este o matrice care descrie probabilitățile de tranziție de la o stare la alta. Fiecare element *P(i,j)* din matrice reprezintă probabilitatea de a trece din starea i în starea j într-un pas:

$$P_{i,j} = P\left(X_{n+1} = s_j \middle| X_n = s_i\right)$$

3. *Proprietatea Markov*: Menționată anterior, aceasta spune că viitorul unui proces este independent de trecut, dacă cunoaștem prezentul.



Markov Chains

Elemente cheie

a) Probabilităţi de tranziţie

Definesc şansa ca sistemul să evolueze dintr-o stare prezentă într-o altă stare. Şansa de a trece din starea *i* existentă la momentul *t* în starea *j* la momentul următor de timp *t+1* matematic apare de forma:

$$P(X_{t+1}=j/X_t=i)$$

şi este notată cu $q_{ij}(t)$.



Markov Chains

Elemente cheie

b) Matricea probabilităţilor de tranziţie

Considerăm ca sistemul se găseşte în starea *i* la momentul de timp *t* cu şansa (probabilitatea*)* $p_i(t)$, $i = 1,2,...j, ...N$.

Sistemul va evolua în momentul de timp următor *t+1* în starea *j* cu probabilitatea $p_j(t+1)$.

Pentru fiecare stare *i* există o probabilitate de tranziţie $q_{ij}(t)$ pe care sistemul o va lua ca să tranziteze din această stare în starea *j*.

Markov Chains

Reprezentare matricială

b) Matricea probabilităţilor de tranziţie

Deci putem scrie:

$$p_j(t+1) = \sum_{i=1}^{N} p_i(t)\, q_{ij}(t) \quad \text{j=1,2,...N}$$

în reprezentare matricială
unde

- $[p(t+1)]$ este o matrice N dimensională linie având elementele $p_j(t);\ j=1,2,...N$
- $[Q(t)]$ este o matrice $N \times N$ având elementele $q_{ij}(t)$, a cărei denumire este de *matricea probabilităţilor de tranziţie* la momentul t.

$$[p(t+1)] = [p(t)] \cdot [Q(t)]$$

Model Markov – Reprezentare matricială



Markov Chains

Tipuri de lanțuri Markov

în reprezentare matricială un model Markov este definit de o relație de forma

$$\left[p(t+1)\right]=\left[p(t)\right]\cdot\left[Q(t)\right]$$

Tipurile de lanţuri Markov se definesc funcţie de forma pe care o prezintă matricea probabilităţilor de tranziţie. Astfel vom avea:

- Lanţ Markov omogen: Dacă probabilitățile de tranziție nu depind de timp (matricea de tranziție este aceeași pentru toți pașii), lanțul se numește omogen. Modelul apare de forma $[p(t+1)] = [p(t)] \cdot [Q]$
- lanţ Markov nestaţionar apare dacă matricea Q diferă de la o etapă la alta. Se obţine deci în cazul în care q_{ij} este dependent de t, situaţie în care modelul este definit de ecuaţia

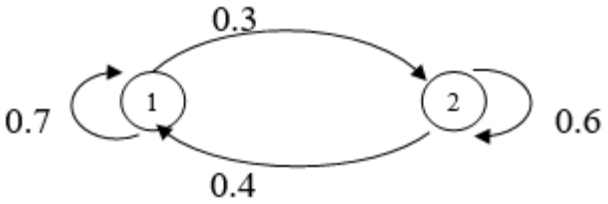
$$\left[p(t+1)\right]=\left[p(t)\right]\cdot\left[Q(t)\right]$$

Markov Chains

Tipuri de lanțuri Markov

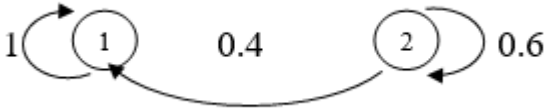
- Lanț Markov aperiodic dacă se revine la o stare după un număr oarecare de tranziţii

$$[Q] = \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{bmatrix}$$



- Lanţuri Markov absorbante: Au anumite stări absorbante, unde odată ce procesul ajunge într-o astfel de stare, nu mai poate părăsi acea stare (ex: starea finală într-un joc de șah).

$$[Q] = \begin{bmatrix} 1 & 0 \\ 0.4 & 0.6 \end{bmatrix}$$

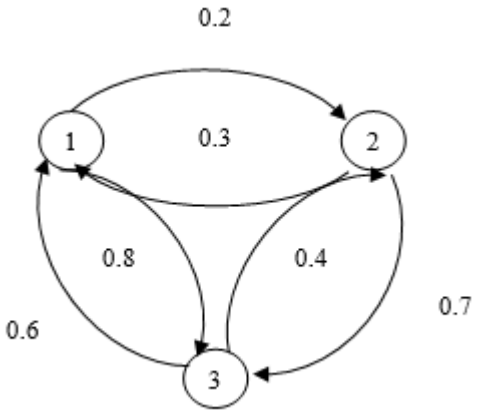


Markov Chains

Tipuri de lanțuri Markov

- Lanțuri Markov periodice : dacă se revine la o stare după aceleaşi număr de tranziţi

$$[Q] = \begin{bmatrix} 0 & 0.2 & 0.8 \\ 0.3 & 0 & 0.7 \\ 0.6 & 0.4 & 0 \end{bmatrix}$$

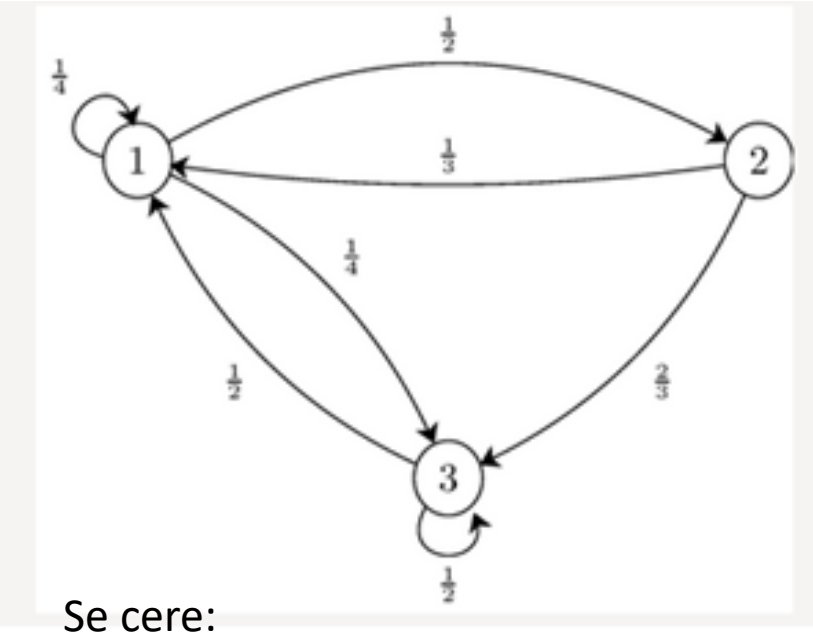


- Lanțuri Markov ergodice: Fiecare stare este accesibilă din oricare altă stare, ceea ce înseamnă că lanțul nu poate fi blocat în niciun subset de stări.

Markov Chains

(A) Exemplu

Considerăm lanțul Markov din figura următoare



$$P = \begin{bmatrix} \frac{1}{4} & \frac{1}{2} & \frac{1}{4} \\ \frac{1}{3} & 0 & \frac{2}{3} \\ \frac{1}{2} & 0 & \frac{1}{2} \end{bmatrix}.$$

Se cere:

$P(X_4 = 3 | X_3 = 2)$.

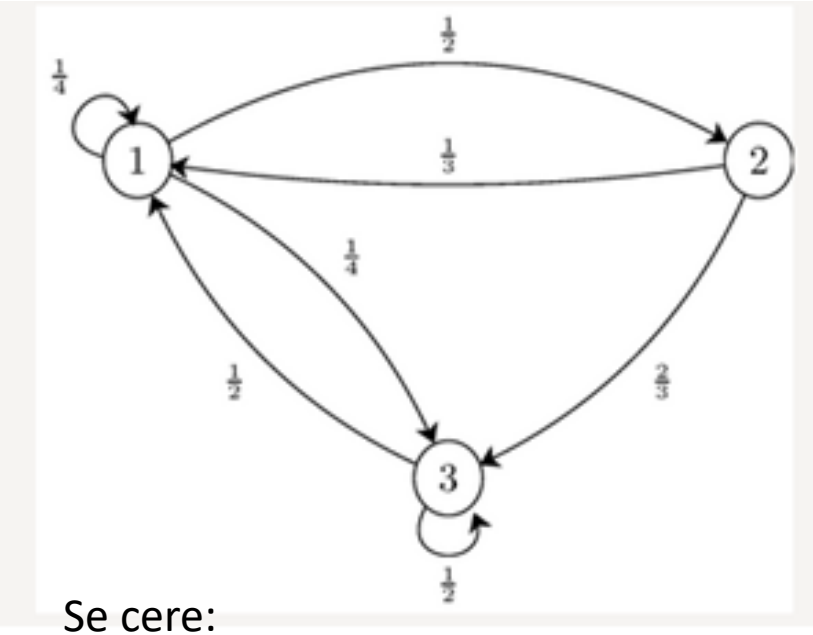
Răspuns

Prin definiție avem $P(X_4 = 3|X_3 = 2) = p_{23} = 2/3$

Markov Chains

(B) Exemplu

Considerăm lanțul Markov din figura următoare



$$P = \begin{bmatrix} \frac{1}{4} & \frac{1}{2} & \frac{1}{4} \\ \frac{1}{3} & 0 & \frac{2}{3} \\ \frac{1}{2} & 0 & \frac{1}{2} \end{bmatrix}.$$

Se cere:

$P(X_3 = 1 | X_2 = 1)$.

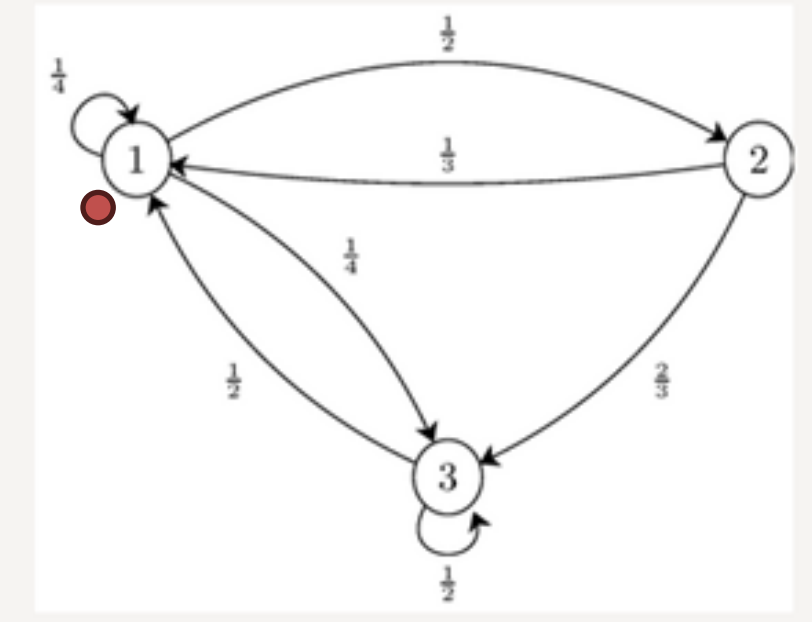
Răspuns

Prin definiție avem $P(X_3 = 1|X_2 = 1) = p_{11} = 1/4$

Markov Chains

(C) Exemplu

Considerăm lanțul Markov din figura următoare



$$P = \begin{bmatrix} \frac{1}{4} & \frac{1}{2} & \frac{1}{4} \\ \frac{1}{3} & 0 & \frac{2}{3} \\ \frac{1}{2} & 0 & \frac{1}{2} \end{bmatrix}.$$

Dacă se cunoaște că $P(X_0 = 1) = 1/3$, determinați $P(X_0 = 1, X_1 = 2)$.

Răspuns

$$P(X_0 = 1, X_1 = 2) = P(X_0 = 1) \cdot P(X_1 = 2 | X_0 = 1)$$

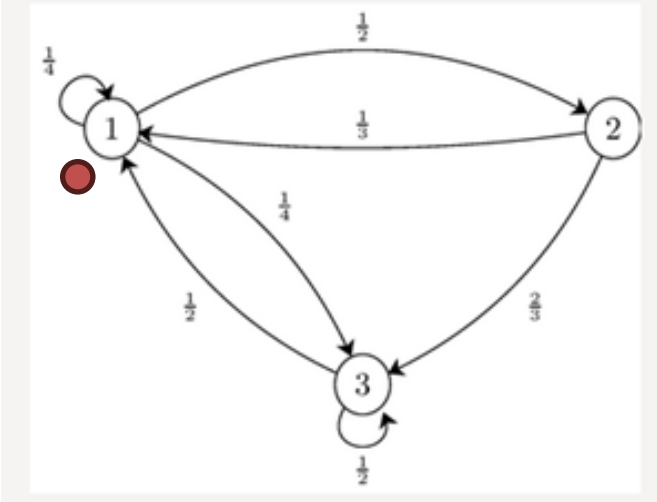
$$= 1/3 \cdot p_{12}$$

$$= 1/3 \cdot 1/2 = 1/6.$$

Markov Chains

(D) Exemplu

Considerăm lanțul Markov din figura următoare



$$\Longleftrightarrow \quad P = \begin{bmatrix} \frac{1}{4} & \frac{1}{2} & \frac{1}{4} \\ \frac{1}{3} & 0 & \frac{2}{3} \\ \frac{1}{2} & 0 & \frac{1}{2} \end{bmatrix}.$$

Dacă se cunoaște că $P(X_0 = 1) = 1/3$, determinați $P(X_0 = 1, X_1 = 2, X_3 = 3)$.

Răspuns

$P(X_0 = 1, X_1 = 2, X_3 = 3) =$

$= P(X_0 = 1) \cdot P(X_1 = 2 | X_0 = 1) \cdot P(X_2 = 3 | X_1 = 2, X_0 = 1)$

$= P(X_0 = 1) \cdot P(X_1 = 2 | X_0 = 1) \cdot P(X_2 = 3 | X_1 = 2)$

(datorită proprietății unui lanț Markov)

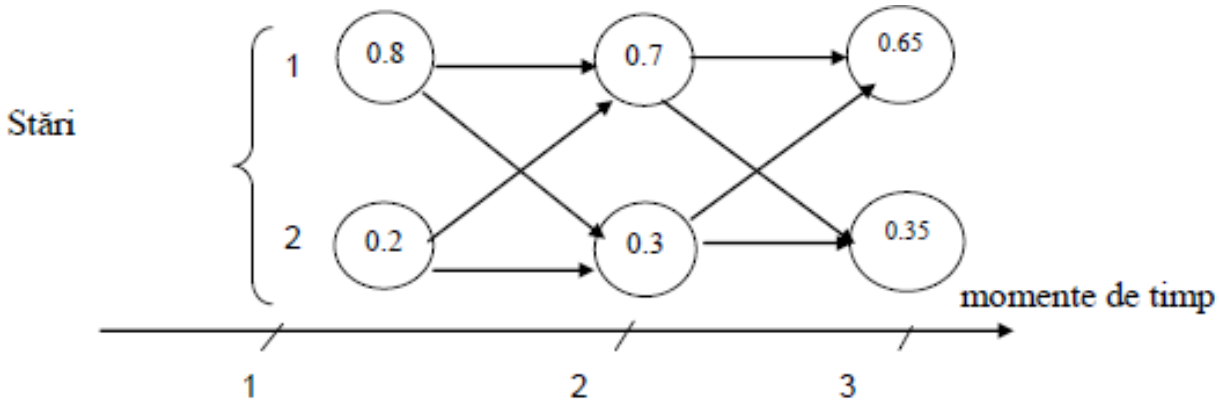
$= 1/3 \cdot p_{12} \cdot p_2 = 1/3 \cdot 1/2 \cdot 2/3 = 1/9$

Markov Chains

Aproximarea matricei probabilităţilor de tranziţie

În practică nu se dispune decât cu totul întâmplător de valorile elementelor matricei probabilităţilor de tranziţie dintr-o stare în alta. În marea majoritate a cazurilor se dispune numai de valorile probabilităţilor de stare (şansa ca sistemul să fie prezent într-o stare la un moment dat) la diferite intervale de timp.

Procedura de construire se bazează pe explorarea unei secvenţe de ecuaţii. De exemplu, presupunem că pentru un sistem care poate fi prezent în două stări cunoaştem valorile matricei [p(t)] la momentele de timp t=1, 2 şi 3.



Markov Chains

Aproximarea matricei probabilităţilor de tranziţie

Utilizând $\left[p(t+1)\right]=\left[p(t)\right][Q]$

⬇

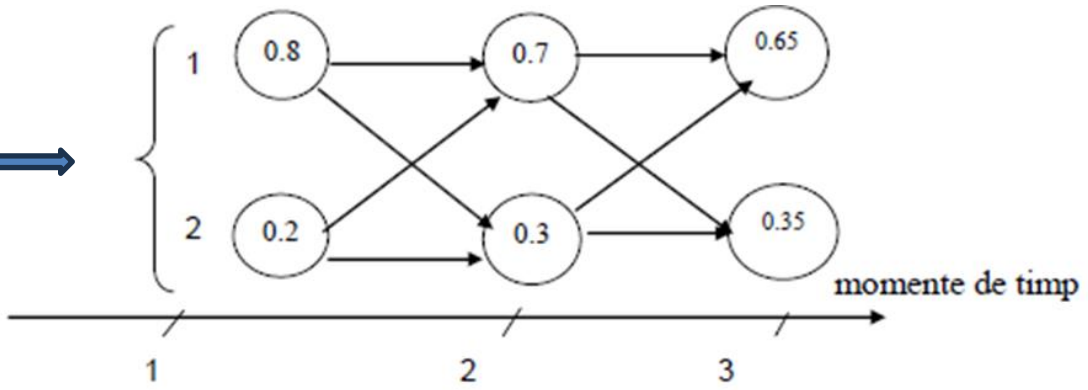
Rezultă sistemul de ecuații

⬇

$$\begin{cases} 0.7 = 0.8q_{11} + 0.2q_{21} \\ 0.3 = 0.8q_{12} + 0.2q_{22} \\ 0.65 = 0.7q_{11} + 0.3q_{21} \\ 0.35 = 0.7q_{12} + 0.3q_{21} \end{cases}$$

⬇

Stări ⟺



prin rezolvarea sistemului rezultă:

⬇

$$[Q]=\begin{bmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{bmatrix}$$

În concluzie dacă un sistem are *m* stări posibile,

- trebuie cunoscute matricele [*p(t)*] pentru *m+1* stări posibile,
- rezultă un sistem de *m* ecuaţii cu *m* necunoscute.



Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov.

In practică, în majoritatea cazurilor probabilitatea ca sistemul să se afle într-o stare sau alta nu se modifică la momente de timp succesive.

Cu alte cuvinte, comportarea sistemului este staţionară, cu excepţia momentelor de la începutul sau sfârşitul perioadei analizate (moment în care comportarea are un regim tranzitoriu).

Eliminând perioadele tranzitorii caracteristice începutului, respectiv terminării funcţionalităţii sistemului, putem considera că probabilitatea ca sistemul să fie prezent într-o stare sau alta este independentă de timp.

Notăm cu [π] distribuţia de probabilitate ca sistemul să fie prezent într-o stare staţionară :

$$\lim_{t\to\infty}\left[p(t)\right]=\left[\pi\right]$$



Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov.

Aplicând această limită ecuaţiei

$$\left[p(t+1)\right]=\left[p(t)\right]\cdot[Q]$$

Obținem

$$[\pi]=[\pi]\cdot[Q] \qquad (1)$$

Distribuţia de probabilitate [π] care satisface ecuaţia (1) poartă numele de

distribuţie staţionară de probabilitate.

Este evident că în acest caz

$$\sum_{i=1}^{N}\pi_i=1$$

Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov.

Concatenăm cele două ecuații

$$\begin{cases} [\pi] = [\pi] \cdot [Q] \\ \sum_{i=1}^{N} \pi_i = 1 \end{cases} \longrightarrow \begin{cases} [\pi] = [\pi] \cdot [Q] \\ [\pi]\ [1]^T = 1 \end{cases}$$

$$\sum_{i=1}^{N} \pi_i = 1 \longrightarrow [\pi_1, \pi_2, \ldots . \pi_N] \bullet \begin{bmatrix} 1 \\ 1 \\ 1 \\ . \\ . \\ 1 \end{bmatrix} = [\pi][1]^T = 1$$

- unde $[1]^T$ este transpusa matricei linie N dimensională cu toate elementele egale cu unitatea

Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov.

Concatenăm cele două ecuații

$$\begin{cases} [\pi] = [\pi] \cdot [Q] \\ [\pi]\ [1]^T = 1 \end{cases} \longrightarrow \begin{cases} [\pi] = [\pi] \cdot [Q] \\ [\pi]\ [\mathrm{E}] = [1] \end{cases}$$

$$[\pi]\ [1]^T = 1 \longrightarrow [\pi_1, \pi_2, \ldots . \pi_N][1]^T \bullet [1] = 1 \bullet [1] \longrightarrow [\pi]\ [\mathrm{E}] = [1]$$

- unde [E] este o matrice *NxN* dimensională cu toate elementele egale cu unitatea



Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov.

Concatenăm cele două ecuații

$$\begin{cases}[\pi]=[\pi][Q] \\ [\pi][E]=[1]\end{cases} \Rightarrow [\pi][Q]+[\pi][E]=[\pi]+[1]$$

$$\Downarrow$$

$$[\pi][Q]+[\pi][E]-[\pi]=[1]$$

$$\Downarrow$$

$$[\pi]\left([Q]+[E]-[I]\right)=[1]$$

în care [I] este o matrice N x N dimensională cu toate elementele de pe diagonala principală 1 restul fiind 0 (numită matricea unitate sau identică – este matricea care înmulţită cu orice altă matrice o lasă neschimbată).

Ca urmare vectorul distribuţiei staţionare este

Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov.

Vectorul distribuţiei staţionare

$$[\pi] = [1]\left([Q] + [E] - [I]\right)^{-1}$$

unde

$[\pi] = [\pi_1, \pi_2 ..... \pi_N]$ N --- stări

$[1] = [1, 1, ... 1]$

$$[E] = \begin{bmatrix} 1 & 1 & . & 1 \\ 1 & 1 & . & 1 \\ . & . & . & . \\ 1 & 1 & . & 1 \end{bmatrix}$$

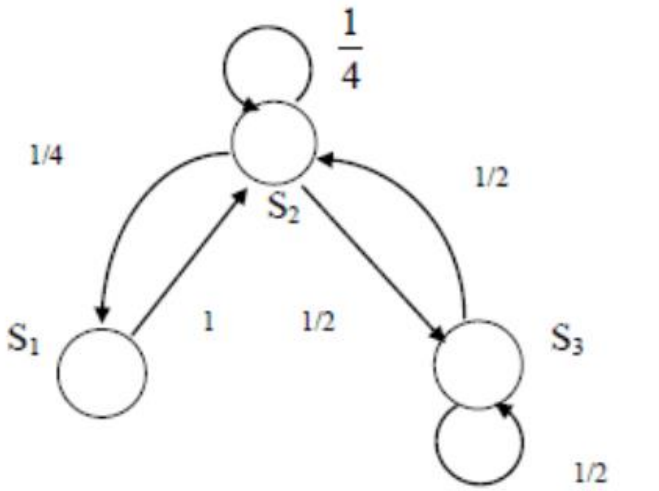
$$[I] = \begin{bmatrix} 1 & & . & \\ & 1 & . & \\ . & . & . & . \\ & & . & 1 \end{bmatrix}$$

Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov. Exemple

A. Găsiţi distribuţia staţionară de probabilitate a următorului lanţ Markov

$$[Q] = \begin{bmatrix} 0 & 1 & 0 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}$$



Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov. Exemple

Se pleaca de la relația

$$[\pi]([Q]+[E]-[I])=[1]$$

$$[Q]+[E]-[I]=\begin{bmatrix}0 & 1 & 0\\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2}\\ 0 & \frac{1}{2} & \frac{1}{2}\end{bmatrix}+\begin{bmatrix}1 & 1 & 1\\ 1 & 1 & 1\\ 1 & 1 & 1\end{bmatrix}-\begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\\ 0 & 0 & 1\end{bmatrix}$$

$$[Q]+[E]-[I]=\begin{bmatrix}0 & 2 & 1\\ \frac{5}{4} & \frac{1}{4} & \frac{3}{2}\\ 1 & \frac{3}{2} & \frac{1}{2}\end{bmatrix}$$

Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov. Exemple

$$[\pi]([Q]+[E]-[I])=[1]$$

$$\begin{bmatrix}\pi_1 & \pi_2 & \pi_3\end{bmatrix}\begin{bmatrix}0 & 2 & 1\\ \frac{5}{4} & \frac{1}{4} & \frac{3}{2}\\ 1 & \frac{3}{2} & \frac{1}{2}\end{bmatrix} = [1,\ 1,\ 1] \Rightarrow \begin{cases}\frac{5}{4}\pi_2+\pi_3=1\\ 2\pi_1+\frac{\pi_2}{4}+\frac{3}{2}\pi_3=1\\ \pi_1+\frac{3}{2}\pi_2+\frac{1}{2}\pi_3=1\end{cases}$$

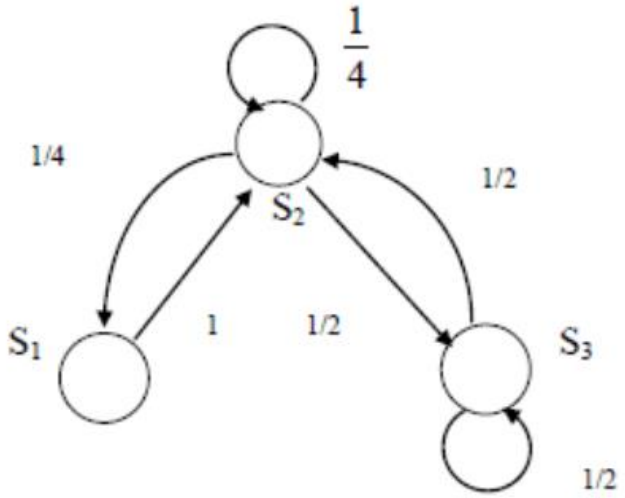
$$\pi_1=\frac{1}{9},\quad \pi_2=\frac{4}{9},\quad \pi_3=\frac{4}{9}$$

Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov. Indici de performanţă

Discuția se va face în contextul exemplului anterior

$$[\pi]=\begin{bmatrix}\frac{1}{9} & \frac{4}{9} & \frac{4}{9}\end{bmatrix} \quad [Q]=\begin{bmatrix}0 & 1 & 0\\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2}\\ 0 & \frac{1}{2} & \frac{1}{2}\end{bmatrix}$$



Timpul de tranziţie dîntr-o stare în alta este de 50 u.t. (unităţi de timp) – mărime măsurabilă pe sistemul real. Am determinat anterior următoarele valori pentru şansa ca sistemul să fie prezent în una din stările S_1, S_2 şi S_3 . Aceste sunt :

$$\pi_1=\frac{1}{9},\quad \pi_2=\frac{4}{9},\quad \pi_3=\frac{4}{9}$$



Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov. Indici de performanță

***1) π_i poate fi interpretată* ca fiind**:

procentul din timpul în care sistemul se găseşte în starea S_i.

Dacă sistemul se analizează pentru 1000 u.t. timpul în care sistemul se găseşte în S_1 este de 1000 x 1/9 u.t.

2) Gradul de utilizare

a echipamentului corespunzător stării care îl modelează.

De exemplu echipamentul asociat stătii S_2 prezintă un grad de utilizare de $\rho_2 = 4/9$



Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov. Indici de performanță

3) Valoarea medie a timpului petrecut în starea Si

se notează cu t_i şi se calculează astfel:La fiecare moment discret de timp (în cazul nostru acestea sunt cuante de 50 u.t.) sistemul are probabilitatea π_i de a rămâne în starea *i* şi ca urmare distribuţia de probabilitate a intervalelor de timp petrecute în starea S_i este:

Dacă sistemul stă în starea i o unitate de timp

$P(t_i=1) = (1- \pi_i)$ interpretată ca fiind *sistemul NU pleacă din starea i*

Dacă sistemul stă în starea *i* 2 cuante de timp

$P(t_i=2) = \pi_i (1- \pi_i)$ interpretată ca fiind sistemul stă în starea *i* o cuantă de timp și tranzitează din ea în următoarea cuantă de timp

-
-

Dacă sistemul este în starea *i n* cuante de timp $P(t_i=n) = \pi^{n-1}_i (1- \pi_i)$



Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov. Indici de performanță

Ca urmare Valoarea medie este

$$\bar{t}_i = \sum_{n=1}^{\infty} n.P\left(t_i = n\right)$$

$$\bar{t}_i = \sum_{n=1}^{\infty} n\left(1-p_i\right)p_i^{n-1} = \left(1-p_i\right)\left[1+2p_i+3p_i^2+\ldots\right]$$

$$\bar{t}_i = \frac{1-p_i}{\left(1-p_i\right)^2} \Rightarrow \bar{t}_i = \frac{1}{1-p_i}$$

Pentru exemplul dat timpul petrecut în starea 3 în cadrul unui interval de 50 u.t. Este

$$\bar{t}_3 = \frac{50}{1-\frac{4}{9}} = \frac{450}{5} = 90 \text{ u.t.}$$



Markov Chains

Distribuţia staţionară de probabilitate a unui lanţ Markov. Indici de performanță

3) valoarea medie a timpului de revenire în starea si se notează cu t_{ri} *și se calculează astfel*

$$p_i = \frac{\text{timpul mediu petrecut in Si}}{\textit{timpul mediu}\ \text{petrecut în Si}\ +\ \text{timp revenire in Si}}$$

Din definiția probabilității

$$p_i = \frac{\frac{1}{1-p_i}}{\frac{1}{1-p_i} + \bar{t}_{ri}} \Rightarrow p_i\left(\frac{1}{1-p_i} + \bar{t}_{ri}\right) = \frac{1}{1-p_i}$$

$$p_i \bar{t}_{ri} = \frac{1}{1-p_i} - \frac{p_i}{1-p_i} \Rightarrow \bar{t}_{ri} = \frac{1}{p_i}$$

Pentru exemplul dat $\bar{t}_{r3} = \frac{50u.t.}{\frac{4}{9}} = \frac{450}{4} = 112\ u.t.$

deci sistemul revine în starea 3 în medie după 112 u.t.



Markov Chains

Exemplu 1 - MODEL

Atelier Revizie tehnică periodică

Să considerăm o maşină care efectuează o revizie tehnică într-un atelier de întreţinere auto. Autoturismul. în intervalul de timp corespunzător reviziei se poate găsi în unul din punctele de lucru:

M – atelier mecanic

E – verificare instalaţie electrică

T – testare caracteristici frână

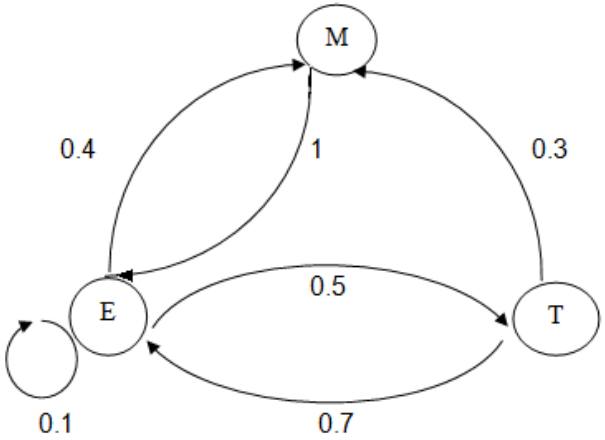
Ca urmare a acestei configuraţii de stări, variabila aleatoare X cu semnificaţie – unde este prezent autoturismul poate fi scrisă:

$X = \{M, E, T\}$

Markov Chains

Exemplu 1 - MODEL
Atelier Revizie tehnică periodică

Din măsurătorile efectuate în atelier apar modalităţile în care autoturismul tranzitează între aceste stări – deci probabilităţile de tranziţie de forma



În cazul dat putem scrie:

$$p_e(t+1) = 0.1\, p_e(t) + 0.7 p_t(t) + p_m(t)$$

$$p_t(t+1) = 0.5\, p_e(t)$$

$$p_m(t+1) = 0.3\, p_t(t) + 0.4\, p_e(t)$$

prima ecuaţie din sistemul de mai sus defineşte şansa de a trece în starea *e* şi este dată de şansa de a fi în:

- E şi a rămâne în E cu probabilitatea de 0.1 *SAU*
- T şi a trece în E cu probabilitatea de 0.7 *SAU*
- M şi a trece în E cu probabilitatea de 0.1

Markov Chains

Exemplu 1 - MODEL
Atelier Revizie tehnică periodică

Matricial avem:

$$p_e(t+1) = 0.1\, p_e(t) + 0.7 p_t(t) + p_m(t)$$

$$p_t(t+1) = 0.5\, p_e(t)$$

$$p_m(t+1) = 0.3\, p_t(t) + 0.4\, p_e(t)$$

$$[p_e(t+1), p_t(t+1), p_m(t+1)] = [p_e(t), p_t(t), p_m(t)] \bullet \begin{bmatrix} 0.1 & 0.5 & 0.4 \\ 0.7 & 0 & 0.3 \\ 1 & 0 & 0 \end{bmatrix}$$

MODEL
Atelier Revizie tehnică periodică

$[p(1)] = [1 \quad 0]$



Markov Chains

Exemplu 2 – MODEL Atelier Reparare utilaj

Un utilaj este caracterizat prin două stări:

- o stare în care nu sunt necesare intervenţii
- o stare în care sunt necesare intervenţii

În conformitate cu această caracterizare utilajul se găseşte în starea

$$p(1) = [1 \quad 0]$$

După un an de exploatare se constată că 10% din componente au nevoie de reparaţii

$$p(2) = [0.9 \quad 0.1]$$

După 2 ani de exploatare se constată că 18% din componente au nevoie de reparaţii

$$p(3) = [0.82 \quad 0.18]$$

Se cere. să se determine în ce an vor fi necesare intervenţii la 40% din componente

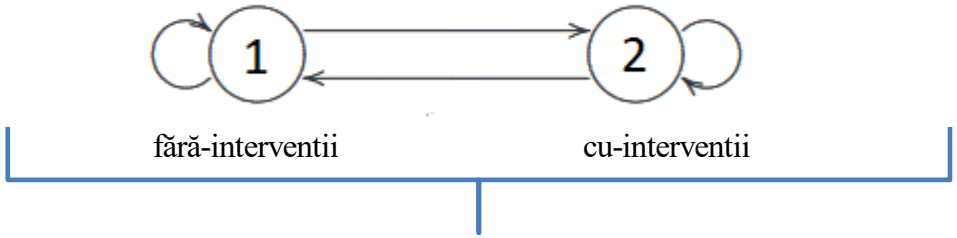
Markov Chains

Exemplu 2 – MODEL Atelier Reparare utilaj

Etape de calcul

1. se calculează matricea probabilităţilor de tranziţie

$$\begin{cases} 0.9 = q_{11} \cdot 1 + 0 \cdot q_{21} \\ 0.1 = q_{12} \cdot 1 + 0 \cdot q_{22} \\ 0.82 = 0.9 \cdot q_{11} + 0.1 \cdot q_{21} \\ 0.18 = 0.9 \cdot q_{21} + 0.1 \cdot q_{22} \end{cases} \Rightarrow [Q] = \begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}$$



MODEL Atelier Reparare utilaj

Markov Chains

Exemplu 2 – MODEL Atelier Reparare utilaj

Etape de calcul

2. Utilizând relația $\left[p(t+1)\right]=\left[p(t)\right]\cdot\left[Q(t)\right]$ vom avea

   - anul $t+1=4$ de funcționare a utilajului

$$p(4) = p(3) \bullet \begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}$$

$$\left[q_{\text{fără-interventii}} \quad q_{\text{cu-interventii}}\right]=\left[0.82 \quad 0.18\right]\bullet\begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}$$

$$\left[q_{fara-\text{int}erventii} \quad q_{cu-\text{int}erventii}\right]=\left[0.756 \quad 0.244\right]$$

Markov Chains

Exemplu 2 – MODEL Atelier Reparare utilaj

Etape de calcul

2. Utilizând relația $\left[p(t+1)\right]=\left[p(t)\right]\cdot\left[Q(t)\right]$ vom avea

- pentru succesiunea de ani *t=1,2,3,4……,8* de funcționare a utilajului

$$p(2) = p(1) \bullet [Q]$$
$$p(3) = p(2) \bullet [Q]$$
$$p(4) = p(3) \bullet [Q]$$
$$\cdot \quad \cdot \quad \cdot \quad \cdot$$
$$p(6) = p(5) \bullet [Q]$$
$$p(7) = p(6) \bullet [Q]$$
$$p(8) = p(7) \bullet [Q]$$

$$\Longrightarrow \quad p(t+1) = p(t) \bullet \begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}^{n-1}$$

n este numărul de stări

$$[0.6048 \quad 0.3952] \Longrightarrow$$

Deci la trecerea a 8 ani 39,52% din componentele sistemului vor solicita intervenţii.

$[p(1)] = [1 \quad 0]$



Markov Chains

Exemplu 3a - MODEL - Predicție vreme 1

Ne propunem să construim un model de tip vreme. Luăm în considerare două stări "zi cu ploaie" respectiv "ziua este însorită". Probabilitățile asociate condițiilor de vreme dau vremea din precedenta zi și sunt reprezentate de următoarea matrice a probabilităților de tranziție

$$Q = \begin{matrix} \text{însorit} & \text{ploaie} \\ \end{matrix} \begin{bmatrix} 0.9 & 0.1 \\ 0.5 & 0.5 \end{bmatrix} \begin{matrix} \text{însorit} \\ \text{ploaie} \end{matrix}$$

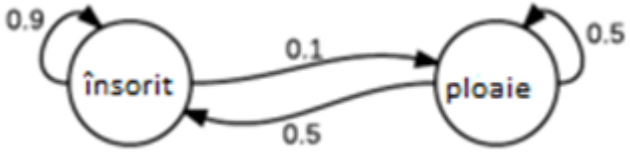
Model Predicție vreme

Matricea Q definește modelul vreme în care o zi însorita are șansa de 90% de a fi urmată de o altă zi însorită, și o zi cu ploaie are șansa de 50% de a fi urmată de o altă zi cu ploaie.

Markov Chains

Exemplu 3a - MODEL - Predicție vreme 1

Graful corespunzător prezintă aspectul



Predicția vremii

Cunoaștem că vremea în ziua 0 este însorită. Condiția inițială va fi reprezentată de un vector în care poziția corespunzătoare zilei de tip însorit este 100% intrarea corespunzătoare zilei în care plouă este 0%. Acesta apare de forma

$$p(0) = [1 \quad 0]$$

Vremea după o zi poate fi prezisă ca fiind:

$$p(1) = p(0) \bullet Q = [1 \quad 0] \bullet \begin{bmatrix} 0.9 & 0.1 \\ 0.5 & 0.5 \end{bmatrix} = [0.9 \quad 0.1]$$



Markov Chains

Exemplu 3a - MODEL - Predicție vreme 1

$$p(2) = p(1) \bullet Q = p(0) \bullet Q^2 = \begin{bmatrix} 1 & 0 \end{bmatrix} \bullet \begin{bmatrix} 0.9 & 0.1 \\ 0.5 & 0.5 \end{bmatrix}^2 = \begin{bmatrix} 0.86 & 0.14 \end{bmatrix}$$

Pentru a prezice vremea pentru ziua *n* putem proceda de următoarea manieră:

$$p(n) = p(n-1) \bullet Q$$

$$p(n) = p(0) \bullet Q^n$$

Se specifică că $p(0) = \begin{bmatrix} 1 & 0 \end{bmatrix}$ reprezintă condiția inițială



Markov Chains

Exemplu 3b - MODEL - Predicție vreme 2

Se afirmă că cel mai simplu mod de a prevedea vremea de mâine este acela de a ști cum este vremea azi. Să presupunem că această afirmație este corectă aspect care face ca modelul firesc pentru predicția vremii este de tip lanț Markov. Pentru simplificare să presupunem că luăm numai trei tipuri de vreme: Înnorat, Plouă și Soare. În acest caz avem

- spațiul stărilor este *S = { s1 = „Înorat”, s2 = „Plouă” și s3 = „Soare”}*
- Matricea de tranziție

$$A = \begin{bmatrix} a_{11} & a_{12} & .... & a_{1j} & .... & a_{1N} \\ a_{21} & a_{22} & .... & a_{2j} & ..... & a_{2N} \\ . & . & . & . & . & . \\ a_{i1} & a_{i2} & .... & a_{ij} & .... & a_{iN} \\ . & . & . & . & . & . \\ a_{N1} & a_{N2} & .... & a_{Nj} & .... & a_{NN} \end{bmatrix}$$

$$a_{ij} = P\left(q_t = j \mid q_{t-1} = i\right) \qquad 1 \le i, j \le N$$

$$\text{cu:} \quad a_{ij} > 0 \qquad \forall i, j$$

$$\sum_{j=1}^{N} a_{ij} = 1 \qquad \forall i$$



Markov Chains

Exemplu 3b - MODEL - Predicție vreme 2

Pentru cazul particular din exemplu avem

$$[A] = \begin{array}{c} \begin{matrix} \text{Înnorat} & \text{Plouă} & \text{Soare} \end{matrix} \\ \begin{bmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{bmatrix} \end{array} \begin{matrix} \text{Înorat} \\ \text{Plouă} \\ \text{Soare} \end{matrix}$$

$$a_{13} = P\left(q_t = \text{Soare} \mid q_{t-1} = \text{Înnorat}\right) = 0.3$$

$$a_{32} = P\left(q_t = \text{Plouă} \mid q_{t-1} = \text{Soare}\right) = 0.1$$

Se cere

Calculați care este probabilitatea de a avea *SSSPPSÎS* dacă astăzi este *S*.

Starea inițială este dată de $\pi = P(S) = 1$



Markov Chains

Exemplu 3b - MODEL - Predicție vreme

Rezolvare

Probabilitatea de a avea evenimentul A care sa succeadă după evenimentul B este

$$P(A,B)=P(A\mid B)P(B)$$

Modelul Markov care surprinde aceasta succesiune in care cu $q_{k,k=\overline{1,n}}$

s-a notat probabilitatea de a avea un eveniment de tip $\{\hat{I},P,S\}$ la momentele de timp 1,2,….n.

Cu

$$\begin{aligned}
&P(q_{1,}q_{2,}.....q_n)\\
&=P(q_{n,}\mid q_{1,}q_{2,}.....q_{n-1,})P(q_{1,}q_{2,}.....q_{n-1,})\\
&=P(q_n\mid q_{n-1})P(q_{1,}q_{2,}.....q_{n-1})\\
&=P(q_n\mid q_{n-1})P(q_{n-1}\mid q_{n-2})P(q_{1,}q_{2,}.....q_{n-2})\\
&=P(q_n\mid q_{n-1})P(q_{n-1}\mid q_{n-2,})\ldots\ldots P(q_2\mid q_1)P(q_1)
\end{aligned}$$



Markov Chains

Exemplu 3b - MODEL - Predicție vreme

Pentru secvența O = (SSSPPSÎS)

$$P(O|\text{model})$$

$$=P(S,S,S,P,P,S,\hat{I},S|\text{model})$$

$$=P(S)P(S|S)P(S|S)P(P|S)P(P|P)P(S|P)P(\hat{I}|S)P(S|\hat{I})$$

$$=\pi a_{33}a_{33}a_{31}a_{11}a_{13}a_{32}a_{23}$$

$$=(1)(0.8)(0.8)(0.1)(0.4)(0.3)(0.1)(0.2)=1.536\times10^{-4}$$


MULTIMETHOD
MODELING
SYSTEM
DYNAMICS
AGENT BASED
MODELING
DISCRETE EVENT
MODELING

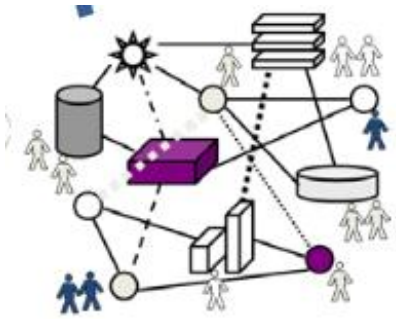
Întrebări???

Modele matematice. Modelarea și simularea dinamicii sistemelor.

CONCEPTE



Modelarea dinamicii sistemelor

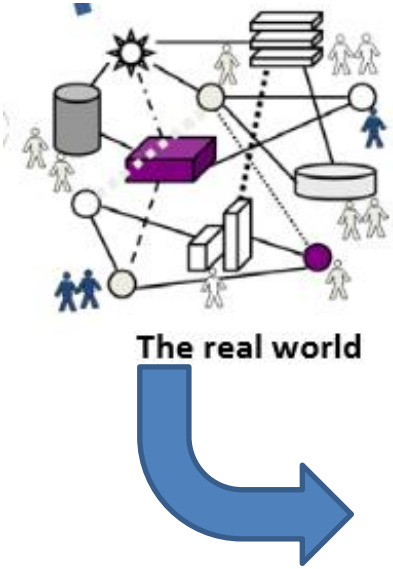


Un **model matematic** este un sistem de relații matematice / ecuații diferențiale, care descrie comportamentul (relațiile) care sunt prezente între componentele unui sistem real într-o măsură rezonabilă.

Într-un model matematic se disting:

- *Variabile independente* care sunt puse în corespondentă cu intrările sistemului real, în general manipulabile.
- Alte *variabile sunt dependente* de primele și sunt puse în legătură cu ieșirile sistemului modelat.
- *Parametrii* fac particular un model, îl pun în acord cu realitatea unui sistem fizic. Variabilele și parametrii unui model pot fi uneori în relație directă cu cantități fizice și/sau fizico-chimice din sistemul real.

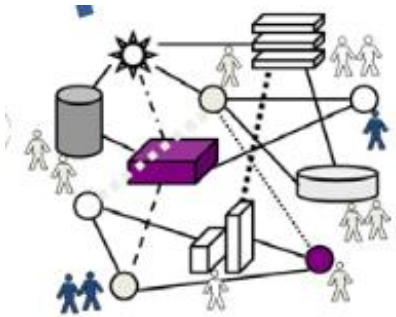
Simularea dinamicii sistemelor



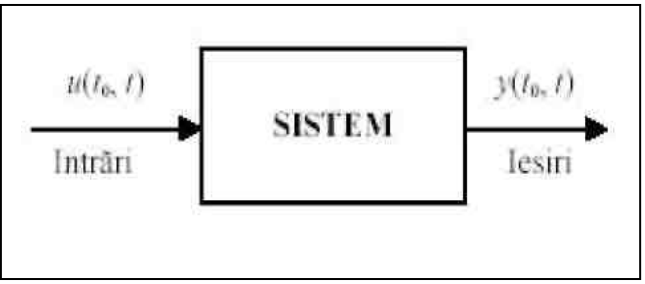
Prin **simulare** se înțelege operația de rezolvare în condiții precizate a sistemului de relații / ecuații care constituie modelul matematic al dinamicii unui sistem real sau pe cale de a deveni real.

Simularea se conduce cu referire la și prin comparare permanentă cu sistemul simulat, real sau virtual, sau cu sisteme similare. Prin urmare, este necesară o acțiune constantă de interpretare a produsului calculelor de simulare din partea celui care elaborează sau utilizează modelul cu care se face simularea.

Modelarea simularea dinamicii sistemelor



The real world

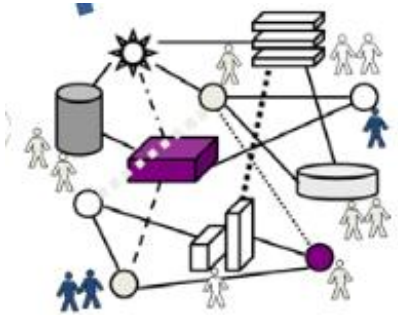


Se disting:

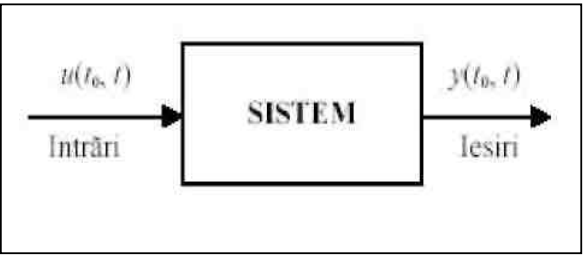
- vectorul intrărilor $u(t_0, t)$ si
- vectorul ieșirilor $y(t_0, t)$.
- momentul t_0 poate fi convențional o origine a timpului, momentul de început al aplicării intrărilor care sunt funcții de timp mai simple sau mai complicate.
- Ulterior momentului inițial t_0 se observă ieșirile. Acestea depind desigur de intrările aplicate dar și de starea sistemului la momentul inițial t_0.
- ieșirile sistemului, numite și răspunsul lui la intrări pot fi diferite dacă intrările aplicate sunt repetat aceleași dar starea sistemului este diferită de la caz la caz în momentul de început al aplicării acelor intrări.

Se poate spune că, de fapt, intrările acționează asupra stării sistemului, iar ieșirile observate sunt produse de modificările în starea sistemului.

Modelarea simularea dinamicii sistemelor



The real world



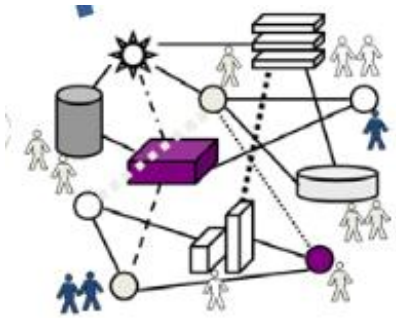
Starea sistemului este descrisă uzual de un număr de variabile de stare.

Variabilele de stare

- sunt funcții de timp și conțin informația minimală necesară la un moment ***t,*** altfel oarecare, pentru a determina comportarea sistemului în momentele următoare, cu sau fără intrări.

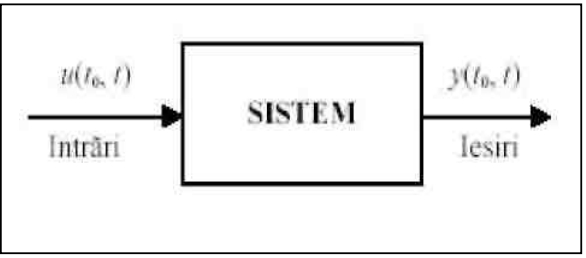
- Informația privind starea unui sistem este grupată de obicei într-un vector ***x(t),*** așa-numitul vector de stare. Vectorul ***x(t)*** nu este unic. Orice transformare liniară nedegenerată a spațiului componentelor acestui vector produce un vector de stare care conține nealterată informația necesară definirii stării sistemului.

Modelarea simularea dinamicii sistemelor



The real world

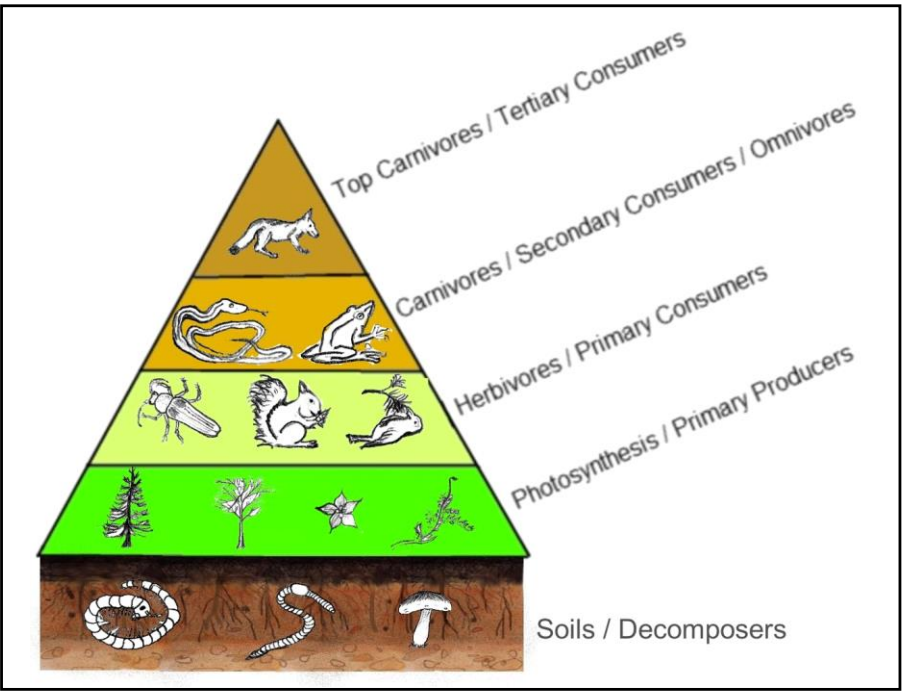
Dacă starea sistemului în momentul inițial t_0 este descrisă de vectorul $x(t_0)$ și dacă se aplică sistemului intrările $u(t_0,t)$ evoluția sistemului după t_0 este observată prin intermediul ieșirilor $y(t_0,t)$.



Relațiile care cuprind dependenta răspunsului unui sistem de starea lui curentă și de intrările aplicate și care dau șansa calculului explicit al răspunsului se constituie în modelul matematic al acelui sistem.

Modelul Lotka-Volterra

Modele de tip pradă prădător



Modelul a fost propus independent de Alfred Lotka in 1925 și Vito Volterra în 1926 având scopul de a descrie dinamica populațiilor prezente în natură și modul în care acestea interacționează atât între ele cât și mediul în care sunt prezente.

Modelul s-a orientat pe descrierea relației care apare între o populație pradă care interacționează într-un areal dat cu o populație de tip prădător. Astfel de relații de tip pradă / prădător se întâlnesc în natură la toate nivelele unui Eco sistem

Modele de tip pradă prădător sunt utilizate in toate domeniile socio-economice pentru

- a descrie relația dinamică dintre salariile reale și ocuparea forței de muncă
- Analiza fluctuațiilor și ciclurilor economice (modele - Goodwin)
- Impactul investițiilor în cercetare și dezvoltare (C & D) și produsul intern brut (PIB)
- studiul relației dintre consumul de energie și PIB.

Modelul pradă-prădător de bază

În studiul dinamicii unei singure populații se iau în considerare factori de tip

- *„creștere naturală”* și

- capacitatea de “*sustenabilitate*” a mediului în care este prezentă populația respectivă. Sustenabilitatea se referă în acest caz la factorii (cantitate de hrană, modul în care se interacționează cu mediul în care este prezentă populația).

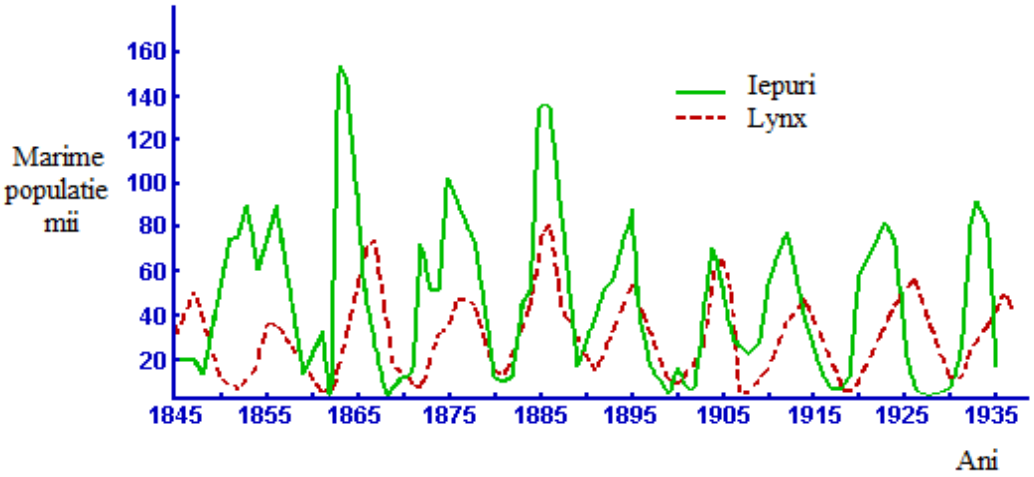
Un caz special al dinamicii unei populații se referă la modul în care exact două specii , una dintre ele de tip prădător iar cea de a doua de tip pradă interacționează. Astfel de cazuri sunt numeroase în natură, de exemplu
- Păsări și insecte,
- Lei și gazele,
- Panda și arbori eucalipți
- Lilieci și insecte.

Modelul pradă-prădător de bază
- presupuneri simplificatoare -

Specia prădător este total dependentă de o singură specie pradă, aceasta reprezentând singura sursă de hrană

- Specia pradă dispune de cantități nelimitate de hrană
- Specia pradă nu este amenințată de alte specii prădător

Deși o astfel de interacțiune poate fi considerată restrictivă ea se întâlnește în natură, exemplul clasic fiind cel al interacțiunii dintre râsul canadian și iepurele de zăpadă. Înregistrările au fost realizate pe un interval de 100 de ani de Hudson Bay Company, fiind prezentate în graficul de mai jos. Caracteristica dominantă prezentă în grafic este dată de oscilațiile în mărimea celor două populații cât și modul în care acestea se corelează între ele.



Modelul pradă-prădător de bază
- Ecuațiile Lotka-Volterra -

Modelul reprezintă o pereche de ecuații diferențiale neliniare utilizate pentru descrierea dinamicii sistemelor biologice în care are loc interacțiunea a două specii de tip prădător respective pradă

$$\frac{dx}{dt} = \alpha x - \beta xy$$

$$\frac{dy}{dt} = \delta xy - \gamma y$$

Unde

x este numărul de animale pradă (de exemplu iepuri)

y este numărul de animale prădător (de exemplu vulpi)

$\frac{dx}{dt}$ si $\frac{dy}{dt}$ reprezintă ratele (frecvențele) de creștere a celor două populații

unde

- ***α*** (frecvența de creștere populației de tip pradă),
- ***β*** (frecvența cu care prădătorii distrug prada),
- ***γ*** (frecvența de deces a prădătorilor) și
- ***δ*** (frecvența cu care prădătorii cresc consumând prada),



Modelul pradă-prădător extins
- Ecuațiile Lotka-Volterra -

Modelul Lotka-Volterra funcționează în contextul unui set de presupuneri , nu neapărat prezente în natură, relative la mediul înconjurător și la modul de evoluție a populațiilor pradă prădător

1. Populația pradă găsește hrană tot timpul în cantități suficiente

2. Necesarul de hrană a populației prădător depinde în totalitate de mărimea populației pradă

3. Frecvența de modificare a populației este proporțională cu mărimea sa

4. În timpul procesului de interacțiune mediul înconjurător nu se schimbă în favoarea unei specii iar adaptarea genetică este nulă

5. Prădătorii au un apetit limitat

6. Presupunem un teritoriu restrâns ca biotop, ceea ce limitează în mod evident populația de tip pradă

Modelul pradă-prădător extins
- Ecuațiile Lotka-Volterra -

Pradă

Ecuația pentru specia pradă este de forma $\frac{dx}{dt} = \alpha x - \beta xy$

Se presupune că

- Prada are hrană nelimitată și se reproduce exponențial, reproducerea exponențială este reprezentată în ecuație de termenul αx .
- În absența prădătorilor populația x va crește exponențial cu mărimea sa, creștere care este dată de $\frac{dx}{dt} = \alpha x$
- Coeficientul a fost numit de Volterra coeficient de auto creștere. În această formă relația definește legea de creștere a lui Malthus a populației, soluția ecuației fiind $x(t) = x_0 e^{\alpha t}$
- Frecvența cu care această populație este diminuată de către prădători este proporțională cu frecvența cu care aceste două specii se întâlnesc, fiind reprezentată de βxy .

Deci ecuația exprimă modul de modificare a populației pradă care este dată de propria creștere minus cantitatea cu care este diminuată de specia prădător.

Modelul pradă-prădător extins
- Ecuațiile Lotka-Volterra -

Prădător

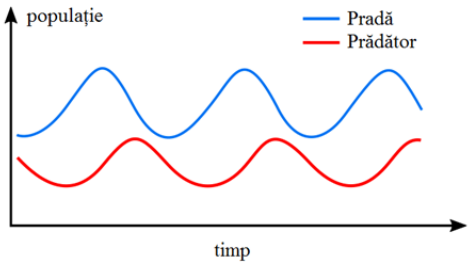
Ecuația pentru specia prădător este dată de $\frac{dy}{dt} = \delta xy - \gamma y$

- În ecuație δxy reprezintă modul în care crește populația prădător. Constanta este utilizată pentru definirea frecvenței cu care această populație consumă elemente din specia pradă. În absența prăzii, populația *y* se va diminua progresiv cu mărimea sa până la extincție, diminuarea este dată în acest caz de

$$\frac{dy}{dt} = -\gamma y,\ y > 0$$

- În ecuație γy reprezintă frecvența cu care se diminuează (scade) populația prădător datorită deceselor sau migrației.

Deci ecuația exprimă modul de variație a mărimii populației de prădător funcție numai de frecvența cu care consumă elemente din populația pradă, minus frecvența intrinsecă de deces.



Modelul pradă-prădător extins
- Ecuațiile Lotka-Volterra -

Dinamica sistemului

În sistemul modelat , prădătorii prosperă atâta timp cât au hrană în cantități mari și vor intra în declin atunci când aceasta se diminuează cantitativ. Populația prădător va crește din nou atunci când populația pradă va crește din nou. Aceasta dinamică continuă în contextul unor cicluri succesive de creștere și declin.

- Echilibrul populației

Apare atunci când din punct de vedere cantitativ populația nu se schimbă. Din punct de vedere matematic echilibrul apare atunci când ambele derivate sunt egale cu 0

$$x(\alpha - \beta y) = 0$$

$$-y(\gamma - \delta x) = 0$$

Rezolvând sistemul se obțin două soluții $\{y = 0, x = 0\}$ si $\left\{y = \frac{\alpha}{\beta}, x = \frac{\gamma}{\delta}\right\}$

Deci avem un număr de două puncte de echilibru

- Primul corespunde cazului extincției celor două specii. Dacă ambele specii sunt 0 , vor fi astfel un timp infinit.
- Cea de a doua soluție reprezintă puncte fixe în care cele două populații se pot susține reciproc (co-existență) de asemenea un timp nedefinit. Nivelul populației în care acest echilibru este atins depinde de valorile parametrilor



Modelul pradă-prădător extins
- Ecuațiile Lotka-Volterra -

Modelul Lotka-Volterra este nerealistic deoarece ia în considerare numai interacțiunea dintre două populații în care mărimea acestora dictează dinamica acestora. De exemplu atunci când populația pradă crește, este încurajată creșterea populației prădător, iar când aceasta scade, asistăm la un declin a populației prădător. Depinzând de natura sistemului modelat astfel de situații conduc la cicluri haotice care se desfășoară într-o plajă de valori aproximativ constantă fără să existe perspectiva atingerii unei stări de echilibru între cele două populații.

*Aceste aspecte au condus la definirea unui **model pradă / prădător extins** în care sunt prinse*

- *condiții externe ca de exemplu competiția în interiorul populației între indivizi de aceeași natură,*
- *influența factorului uman respectiv influența mediului exterior.*

Modelul pradă-prădător extins
- Ecuațiile Lotka-Volterra -

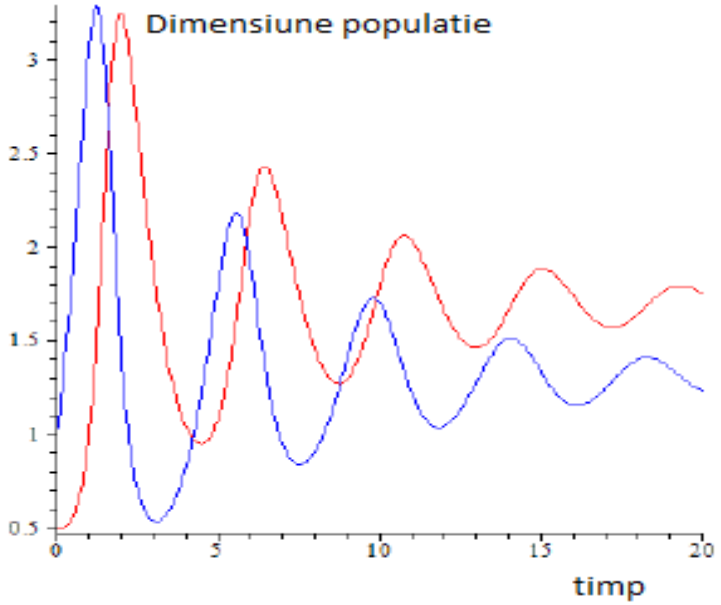
Modelul în aceste circumstanțe prezintă aspectul

$$\frac{dx}{dt} = \alpha x - \lambda x^2 - \beta xy$$

$$\frac{dy}{dt} = \delta xy - ky^2 - \gamma y$$

$$\alpha,\ \beta,\ \gamma,\ \delta,\ \lambda,\ k$$

În contextul modelului $\lambda,\ k$ contorizează mediul care afectează dinamica populației. În acest caz variația prăzii și a prădătorului nu mai este periodică după cum se poate vedea din figura de mai jos



Metode numerice de rezolvare a ecuațiilor diferențiale

Pentru o ecuație diferențială de tipul

$$y' = f(x,y), \qquad y(x_0)=y_0$$

există două tipuri distincte de metode numerice cu ajutorul cărora obținem aproximația numerică a soluției ecuației precedente. Pentru o discretizare a lui *x de* tipul:

$$x_0,$$
$$x_1 = x_0 + h,$$
$$x_2 = x_1 + h = x_0 + 2h,$$
$$x_3 = x_2 + h = x_1 + 2h = x_0 + 3h,$$
$$etc.,$$

ambele tipuri de metode numerice determină valorile lui ***y*** pentru precedentele valori ale lui ***x***, anume:

$$y(x_1) = y_1,$$
$$y(x_2) = y_2,$$
$$y(x_3) = y_3,$$
$$etc.,$$

Metode numerice de rezolvare a ecuațiilor diferențiale

Cele două tipuri distincte de metode numerice cu ajutorul cărora obținem aproximația numerică a soluției ecuației

diferă calitativ prin tipul polinomului care interpolează funcția y.

Astfel, cunoscută fiind valoarea funcției ***y*** de la punctul inițial x_0 până la un punct oarecare x_n și fiind necesară aflarea funcției în punctul x_{n+1}, ecuația

$$y' = f(x,y), \qquad y(x_0)=y_0$$

se rescrie de obicei sub forma

$$y_{n+1} = y_n + h \bullet F(x)$$

$$y_{n+1} \approx y_n + h\left(\beta_n \bullet f_n + \beta_{n-1} \bullet f_{n-1} + \beta_{n-2} \bullet f_{n-2} \ldots\ldots\right)$$

unde h reprezinta pasul de interpolare $x_{n+1} = x_n + h$

determinarea lui y_{n+1} depinzând acum de construirea unui polinom de interpolare ***F(x),*** ce coincide cu *f* atât în x_n, cât și într-un număr de puncte anterioare lui x_n, anume x_{n-1}, x_n-2, etc., unde β_n, β_n-1, β_n-2, etc., sunt coeficienți numerici a căror valoare depinde de ordinul polinomului de interpolare



Metode numerice de rezolvare a ecuațiilor diferențiale multi-pas sau metode cu memorie.

Dacă polinomul de interpolare folosit în calcul integralei este determinat folosind informații cu privire la soluția ecuației în puncte precedente lui x_n metoda este denumita în mod curent ***metode multi-pas*** **sau** ***metode cu memorie***.

Particularitatea acestor metode numerice este aceea că polinomul de interpolare *F* este determinat folosind *și* punctul x_{n+1}, nu doar punctul x_n și cele precedente, valoarea aproximativă a lui y_{n+1} fiind

$$y_{n+1} \approx y_n + h\left(\beta_{n+1} \bullet f_{n+1} + \beta_n \bullet f_n + \beta_{n-1} \bullet f_{n-1} + \beta_{n-2} \bullet f_{n-2} \ldots\ldots\right)$$

Aceste metode sunt așadar implicite, valoarea numerice a lui y_{n+1} fiind obținută după rezolvarea unei ecuații al cărei grad de neliniaritate depinde de dependența funcțională a lui *f* de *y*.

Metode numerice de rezolvare a ecuațiilor diferențiale unipas.

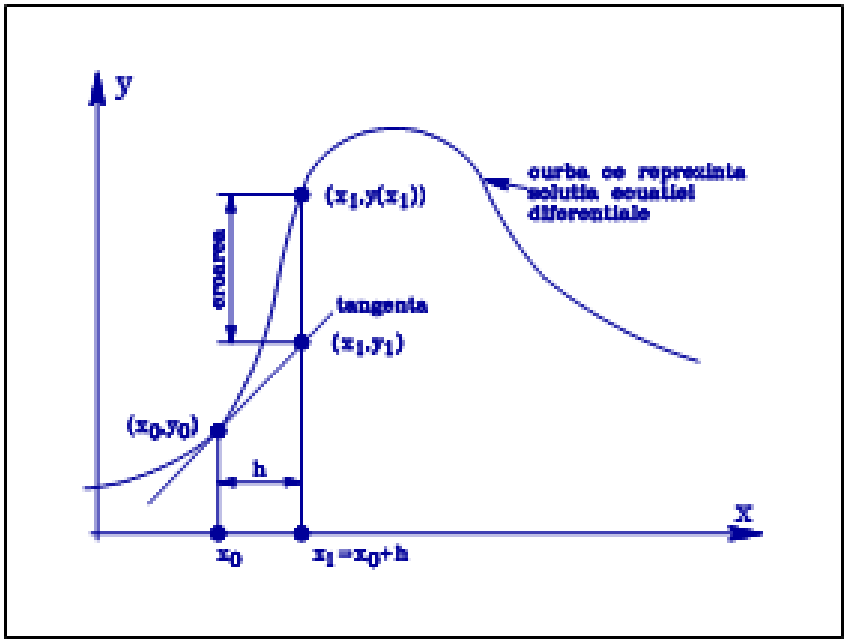
Particularitatea acestor metode numerice este aceea că polinomul de interpolare *F* este determinat fără a folosi puncte anterioare lui x_n.
Valoarea aproximativă a lui y_{n+1} este dată de

$$y_{n+1} \approx y_n + h \bullet f\left(x_n + \frac{h}{2}, y_n + \frac{h}{2} \bullet f\left(x_n, y_n\right)\right)$$

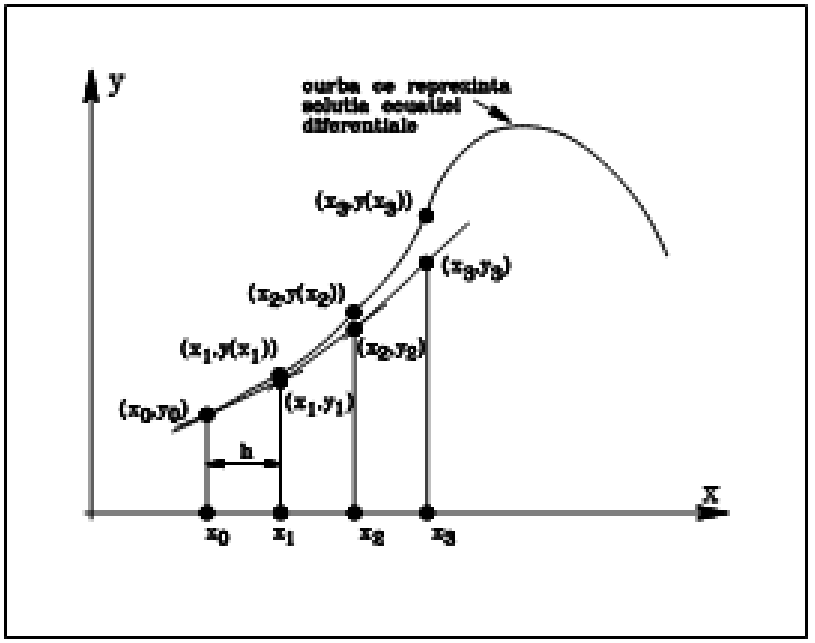
După cum se observă schema de calcul este una explicită, partea dreaptă a ecuației precedente fiind calculată exclusiv pe baza valorii funcției *y* în punctul x_n.

Metode numerice de rezolvare a ecuațiilor diferențiale unipas.
- Metoda Euler -

Soluția ecuației diferențiale este aproximată de o linie polinomială formată din tangentele la soluția locală a ecuației



În metoda Euler se aproximează soluția exactă cu o linie poligonală.



Aproximarea soluției ecuației diferențiale

Metode numerice de rezolvare a ecuațiilor diferențiale multipas.
- Metoda dezvoltării în serie Taylor -

Soluția ecuației diferențiale ia in considerare dezvoltarea in serie Taylor funcției ***y(x)*** în jurul unui punct ***x = a*** de forma:

$$y(x) = y(a) + y'(a)\frac{(x-a)}{1!} + y''(a)\frac{(x-a)^2}{2!} + \ldots\ldots$$

Pentru a apropia expresia de mai sus de problema curenta, daca se considera cazul în care ***a = x_n și x = x_n+h***, se obține :

$$y(x_n + h) \cong y(x_n) + y'(x_n)\,h$$

$$\Updownarrow$$

$$y(x_n + h) \cong y(x_n) + f(x_n, y(x_n))\,h$$

Oprind trei termeni se obține următoarea formula:

$$y_{n+1} = y_n + y_n'\,h + y_n''\,h^2$$

Metode numerice de rezolvare a ecuațiilor diferențiale multipass.
- Metoda Runge-Kutta -

Soluția ecuației diferențiale ia in considerare dezvoltarea in serie Taylor funcției ***y(x)*** in jurul unui punct $a = x_n$ pentru care se opresc primii patru termeni din dezvoltarea în serie Taylor

$$y_{n+1} = y_n + \frac{1}{6}\left(k_1 + 2k_2 + 2k_3 + k_4 \right),$$

$$k_1 = h\, f\left(x_n, y_n \right),$$

$$k_2 = h\ f\left(x_n + \frac{1}{2}h,\ y_n + \frac{1}{2}k_1 \right),$$

$$k_3 = h\ f\left(x_n + \frac{1}{2}h,\ y_n + \frac{1}{2}k_2 \right),$$

care este forma standard de scriere a unei metode Runge-Kutta.


MULTIMETHOD
MODELING
SYSTEM
DYNAMICS
AGENT BASED
MODELING
DISCRETE EVENT
MODELING

Întrebări???

MODELARE și SIMULARE

Modelarea bazată pe agenţi





Modelarea bazată pe agenţi
Concepte

Un model matematic descrie comportarea unui sistem din lumea reală prin ecuații diferențiale în marea majoritate a cazurilor în care coeficienții sunt valori constante reprezentând interacțiunea dintre sistem și mediul înconjurător și respectiv interacțiunea dintre componentele sistemului

Un model comportamental este un model matematic în care coeficienții ecuațiilor diferențiale care descriu sistemul din lumea reală sunt mărimi variabile care se modifică în timp.



Modelarea bazată pe agenţi

Modelul comportamental Kermack-McKendrick

Este un model comportamental utilizat pentru a înțelege modul în care evoluează o epidemie în contextul unei populații date.

Populația este văzută ca fiind format din

- persoane susceptibile de a fi infectate (notate cu ***S*** - Susceptible)
- persoane care au fost infectate de virusul patogen (notate cu ***I*** – Infected)
- persoane care sau vindecat sau care sunt imune (notate cu ***R*** – Recovered)

Din aceste considerente, modelele matematice care încearcă să analizeze modul de evoluție a unei epidemii sunt cunoscte sub denumirea de modele comportamentale de tip ***SIR*** (**S**usceptible, **I**nfected. **R**ecovered/removed/immune)



Modelarea bazată pe agenţi

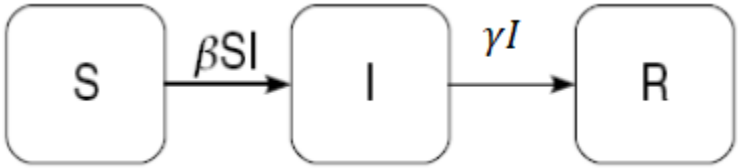
Modelul comportamental Kermack-McKendrick

Modelul este construit plecând de la următoarele presupuneri

- mărimea populației este fixă
- nu există nașteri
- decesul apare din cauza epidemiei sau din cauze natural
- perioada de incubație a agentului infecțios este instantanee, iar durata de îmbolnăvire este aceeași pentru orice persoană
- se consideră că populația este omogenă – nu se ține cont de vârstă, structură socială și localizare în spațiul geografic în care se manifestă boala.

Modelarea bazată pe agenţi

Modelul comportamental Kermack-McKendrick



Graful Modelului Kermack-McKendrick

În graf nodurile reprezintă stări de tip (**S**usceptible, **I**nfected. **R**ecovered /removed / immune iar arcele tranziții între acestea.

$$S + I + R = 1$$

$$\frac{dS}{dt} = -\beta SI$$

$$\frac{dI}{dt} = \beta SI - \gamma I$$

$$\frac{dR}{dt} = \gamma I$$

- ***t*** este timpul
- ***S(t)*** – procentul de persoane care pot fi infectate
- ***I(t)*** procentul de persoane infectate
- ***R(t)*** procentul de persoane care s-au recuperat sau au dezvoltat imunitate la infecție
- ***R(0)=0*** La momentul ***t=0*** procentul persoanelor recuperate sau care au dezvoltat imunitate este 0
- ***β* este frecvența (rata) de infecției**
- ***γ* este frecvența (rata) de recuperare (însănătoșire)**



Modelarea bazată pe agenţi

Modelul comportamental Kermack-McKendrick

O valoare importantă care determină dinamica celor trei parametrii din sistemul de ecuație poartă denumire de **prag epidemiologic** (mărime care este considerată cel mai important factor în epidemiologie) și este definită de

$$R_0 = \frac{\beta S}{\gamma}$$

Când

- $R_0 < 1$ fiecare persoană care contractează boala va infecta mai puțin de o persoană înainte de a deceda sau se va însănătoși .

  În acest caz $\frac{dI}{dt} < 0$ și epidemia se va stinge

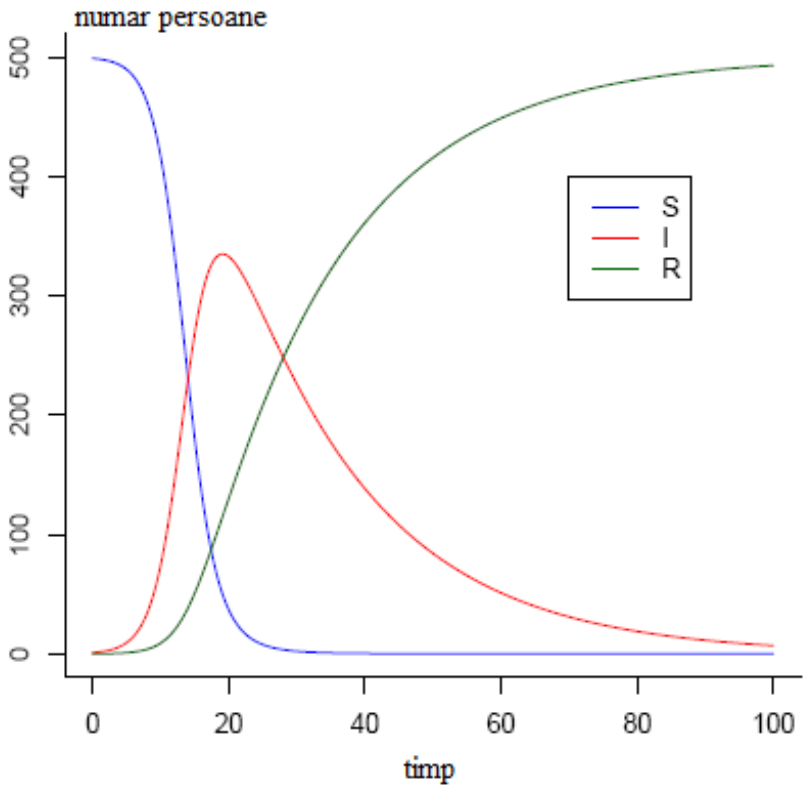
- $R_0 > 1$ fiecare persoană care a contractat boala va infecta mai mult de o persoană astfel că epidemia se va răspândi.

  În acest caz $\frac{dI}{dt} > 0$ și epidemia se va răspândi

Modelarea bazată pe agenţi

Modelul comportamental Kermack-McKendrick

Un exemplu al dinamicii celor trei parametri *S, I, R* este prezentat în figura de mai jos.





Modelul comportamental Kermack-McKendrick
- Studiu –

Modul în care ratele de vaccinare afectează răspândirea bolii într-o comunitate

Pentru a lua în considerare vaccinarea se procedează la schimbarea condițiilor inițiale.

- Adăugarea stării suplimentare de vaccinare pentru un individ menține aceeași dimensiune și densitate a populației, dar reduce proporția de indivizi care sunt susceptibili la boală.

- S-a luat în considerare și efectul eficacității vaccinului. În model, procentul de indivizi vaccinați înmulțit cu eficacitatea vaccinului oferă procentul din populație care începe să fie imunizată. Astfel, se poate presupune că indivizii imunizați din categoria vaccinați nu interacționează niciodată cu restul populațiilor SIR. În consecință, condiția se va defini de forma:

$$S + I + R = 1$$

$$\Downarrow$$

$$S(0) + I(0) + (\text{Procentul de persoane vaccinate}) \bullet (\text{Eficacitatea vaccinului}) = 1$$

Modelul comportamental Kermack-McKendrick
- Studiu –

Modul în care ratele de vaccinare afectează răspândirea bolii într-o comunitate

i0: % infected at beginning 0.01

percent vaccinated 0.9

vaccine effectiveness 1

contact number 18

infectious period (in days) 8

time (in days) 50

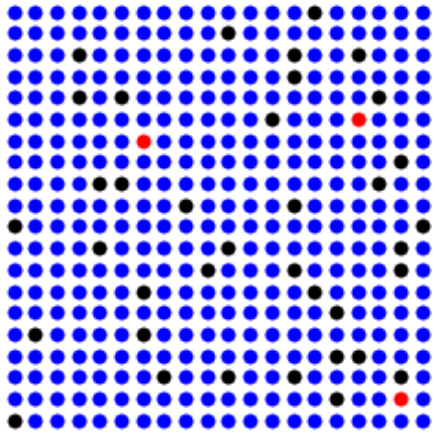
CA measles

CA whooping cough

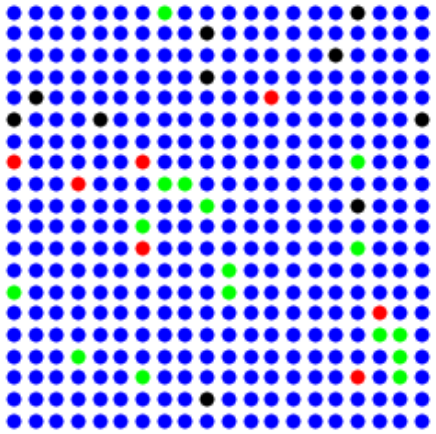
NYC Hong Kong flu

reset

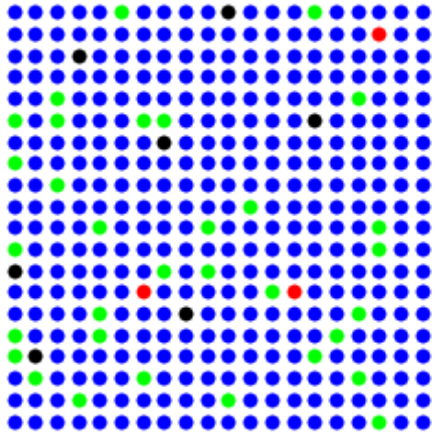
key:
Susceptible *S*
Infected *I*
Immunized
Recovered *R*



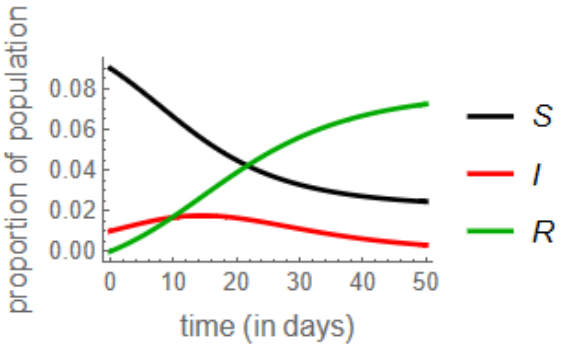
at t = 0



at t = 25. days



at t = 50 days



minimum proportion of vaccinated individuals needed: 0.934444

epidemic



Modelarea bazată pe agenţi

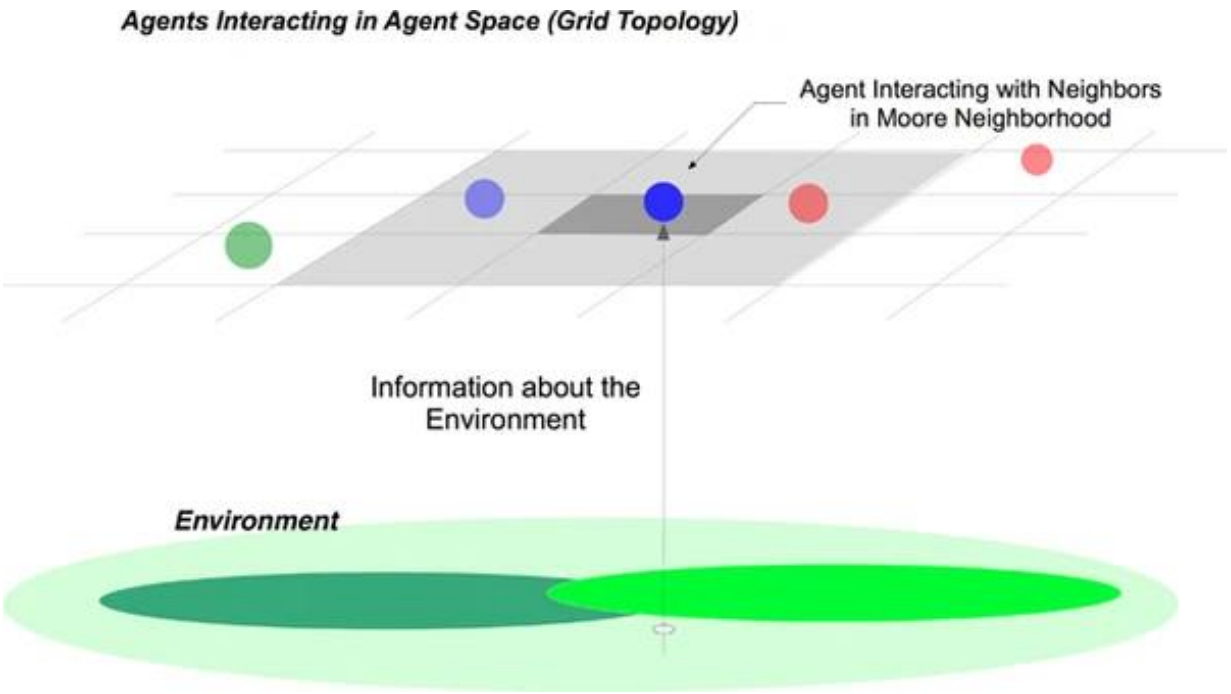
Modele comportamentale – Deficiențe

(1) Deoarece funcționarea modelelor comportamentale este greu de surprins datorită modificării în timp a coeficienților ecuațiilor care definesc sistemul, s-a încercat o altă abordare de descriere în care, acești coeficienți sunt înlocuiți de relațiile care apar între între componentele sistemului, și între componentele sistemului și mediul înconjurător

(2) Mare deficiență a modelelor comportamentale (descrise prin ecuații diferențiale) rezidă din faptul că descriu numai parțial complexitatea sistemului din lumea reală. Această deficiență se datorează absenței reprezentări mediului geografic în care este prezent sistemul modelat. Atașarea reprezentări mediului geografic (spațial) a condus la dezvoltarea unei noi tehnici de modelare cunoscută sub denumirea de Agent-Based Modelling (ABM).

Modelarea bazată pe agenţi
Concepte

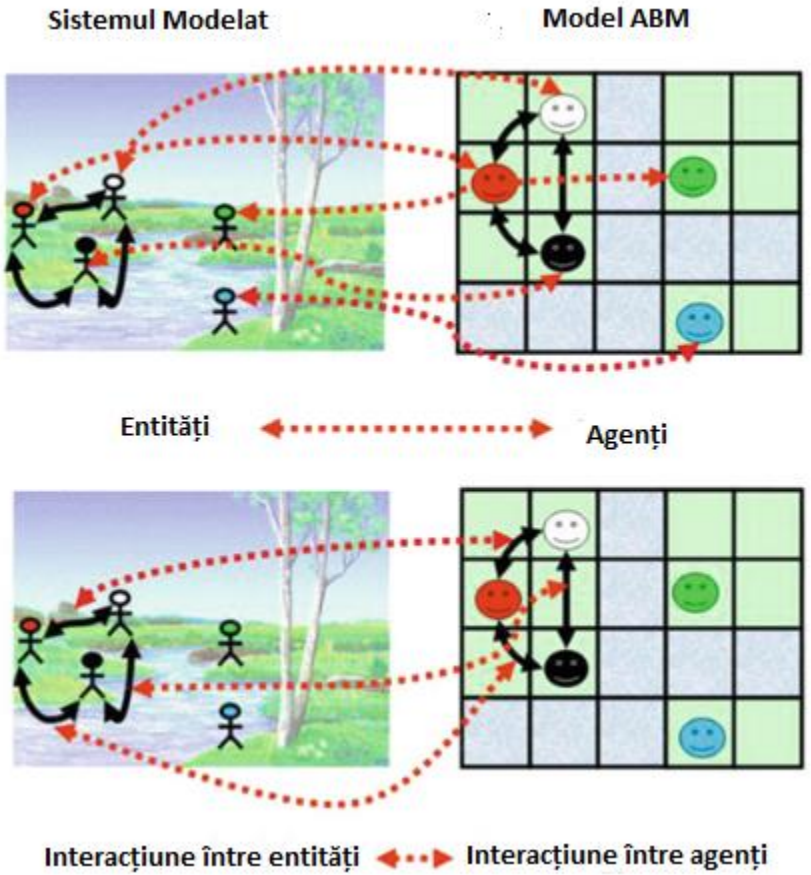
Agent-Based Modelling (ABM). Modelarea bazată pe agenți este utilizată atunci când se reprezintă un sistem prin intermediul relațiilor care apar între entitățile care definesc comportarea acestuia. Sistemul din punctul de vedere conceptual, apare de forma (Epstein and Axtell, 1996).



Modelarea bazată pe agenţi
Concepte

Definiție

Un Agent este o entitate care funcționează continuu si autonom intr-un mediu in care au loc alte acțiuni si in care sunt prezenți si alți agenți





Modelarea bazată pe agenţi
Concepte

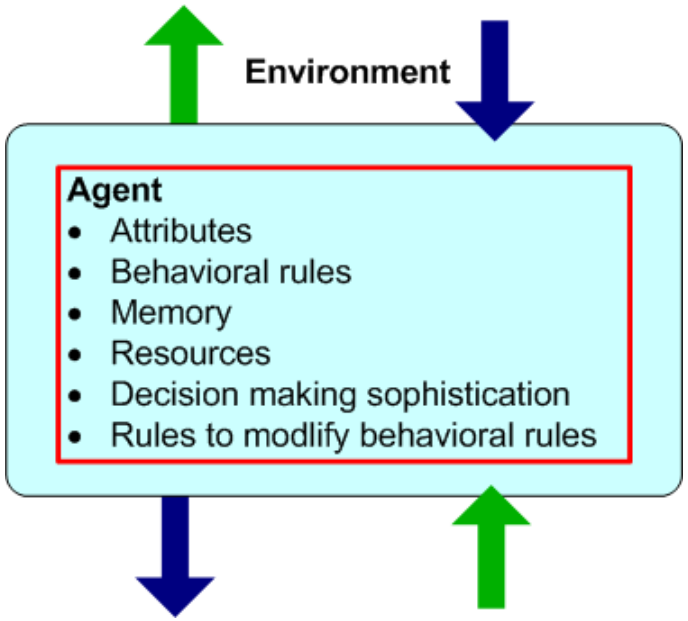
Poziţionarea**,** în acest context, înseamnă că agentul primeşte informații de la mediul în care este prezent și că poate executa acţiuni care schimbă acest mediu într-un anumit fel.

Autonomia este înțeleasă ca absenţa intervenţiei umane sau a altor agenţi, deci un agent îşi poate controla complet propriile acţiuni şi starea sa internă. Uneori autonomia este înţeleasă. într-un sens mai strict, ca şi capacitatea pe care o are agentul de a învăţa din propria sa experienţă.

Flexibilitatea presupune , în esenţă, că agentul percepe mediul şi răspunde la timp la schimbările ce apar în el, fiind capabil să exercite un comportament orientat către un anumit scop şi să iniţieze acţiuni care îl apropie de aceste scopuri, şi social, deci agentul este capabil să interacţioneze cu alţi agenţi. Structura tipică a unui agent este prezentată în figura următoare

Modelarea bazată pe agenţi

Arhitecturi de Agenţi Inteligenţi



Un agent tipic utilizat în ABM are un număr de trei componente:
Atribute care descriu și particularizează agentul (nume, resurse de care dispune etc.)

Reguli de interacțiune cu alți agenți.

Agentul acționează într-un context (spațiu real sau virtual), aspect care impune definirea regulilor după care se desfășoară această interacțiune.



Modelarea bazată pe agenţi

Modelul abstract al unui agent inteligent

Din punct de vedere formal un agent inteligent care acționează într-un mediu dat este definit de

1. Mediul ***S*** în care acționează agentul este definit prin intermediul stărilor pe care acesta le prezintă. Din punct de vedere formal acesta este definit de o mulțime de stări de forma

$$S = \{s_1, s_2 \ldots\ldots\ldots\}$$

La orice moment mediul este prezent în una din aceste stări.

2. Agentul poate realiza un set de acțiuni Din punct de vedere formal acțiunile ***A*** pe care un agent le poate realiza apar de forma

$$A = \{a_1, a_2 \ldots\ldots\ldots\}$$

Un agent standard poate fi considerat ca fiind o funcție care mapează secvenţe de stări ale mediului la acţiuni. Formal un astfel de agent apare de forma

$$actiune : S^* \Rightarrow A$$



Modelarea bazată pe agenţi

Modelul abstract al unui agent inteligent

Istoricul interacţiunii agentului cu mediul în care este prezent este reprezentat de o secvenţă de stări ale mediului – acelea pe care agentul le-a întâlnit până în momentul respectiv. Un istoric ***h*** este o secvenţă

$$h : s_0 \xrightarrow{a_0} s_1 \xrightarrow{a_1} \ldots\ldots \xrightarrow{a_{u-1}} s_u \xrightarrow{a_u} \ldots$$

unde

s_0 este starea iniţială a mediului (starea în care se află mediul în momentul în care agentul îşi începe execuţia),

a_u fiind ce-a de-a *u*-a acţiune efectuată de agent,

s_u fiind cea de-a *u*-a stare a mediului (starea rezultată în urma execuţiei acţiunii a_{u-1} în starea s_{u-1}).

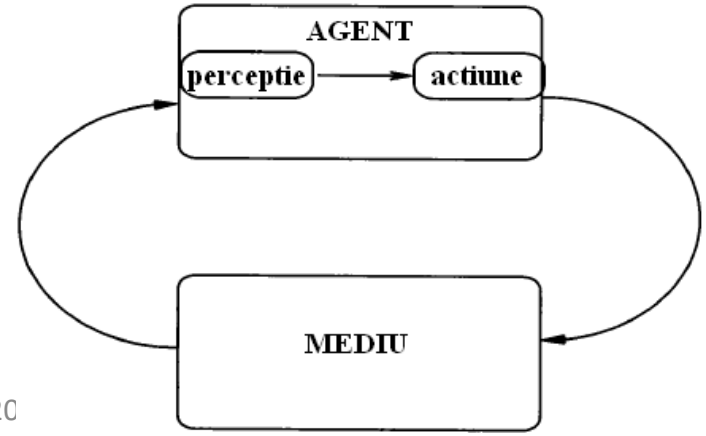
Modelarea bazată pe agenţi

Modelul abstract al unui agent inteligent

modelul *abstract* al unui agent presupune prezenîa a două componente:

- arhitectura agentului şi proiectarea unei funcţii de decizie a agentului.

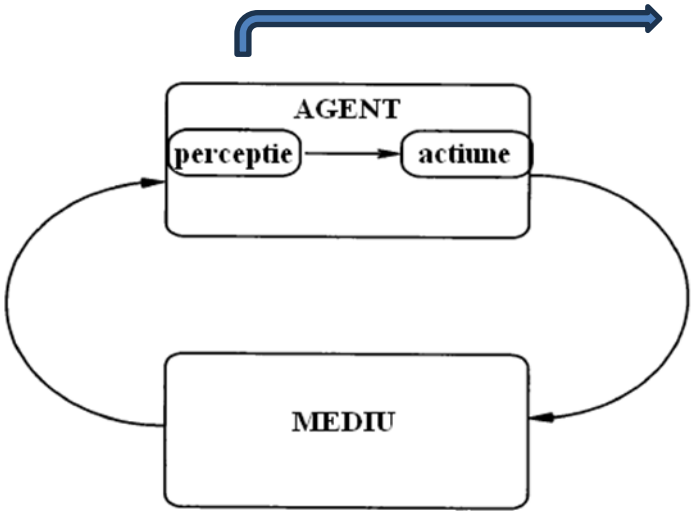
- *Arhitectura* agentului se referă la datele şi structurile de control ce vor fi prezente în descrierea agentului – structurile de date, operaţiile care vor trebui aplicate acestor structuri, precum şi controlul fluxului între structurile de date.
- *Funcţia de decizie* specifică modul în care acționează agentul, aspect care presupune prezența a două subsisteme: subsistemul *percepţie* şi subsistemul *acţiune*



Structura comportamentală a unui Agent

Modelarea bazată pe agenţi

Modelul abstract al unui agent inteligent



Funcţia percepţie:

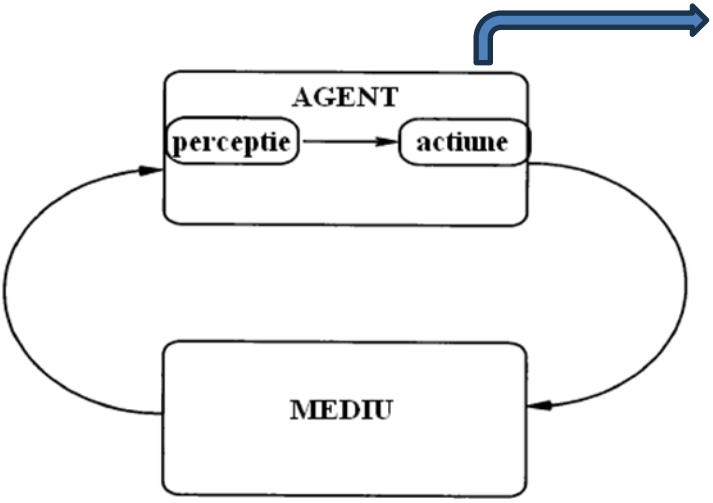
- se referă la abilitatea agentului de a-şi observa (percepe) mediul;
- rezultatul (output-ul) funcţiei *percepţie* este un *semnal* (percepţie) – o secvenţă perceptuală primită la intrare; Perceptual semnificând rezultatul interpretării semnalelor obţinute din observarea mediului
- dacă P este o mulţime nevidă de percepţii despre mediu , atunci funcţia *percepţie* va fi:

$$perceptie : S^* \rightarrow P$$

funcţie ce asignează stărilor mediului la percepţii.

Modelarea bazată pe agenţi

Modelul abstract al unui agent inteligent



Funcţia acţiune :

- se referă la procesul de aplicare al deciziilor;

dacă *P* este o mulţime nevidă de percepţii despre mediu, funcţia *acţiune* va fi:

$$actiune : P^* \rightarrow A$$

- funcţie ce asignează secvenţelor de percepţii (semnale) la acţiuni.



Modelarea bazată pe agenţi

Arhitecturi de Agenţi Inteligenţi

Comportamentul unui agent standard poate fi

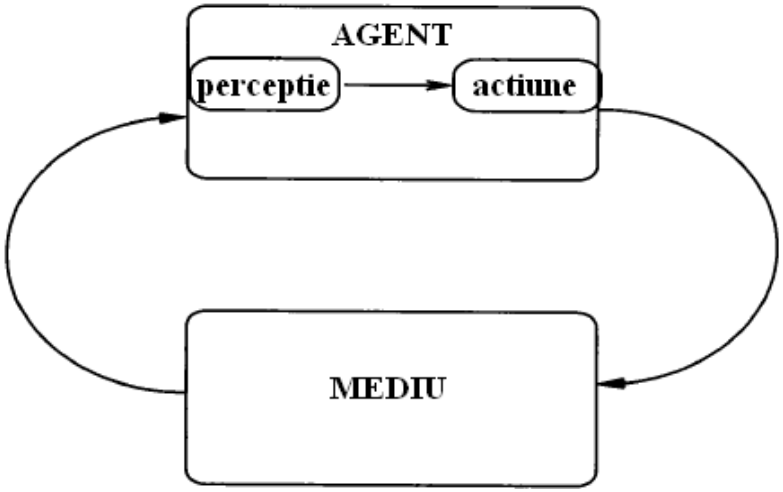
determinist dacă acesta dintr-o stare a mediului în care este prezent poate trece în altă stare existentă a mediului întotdeauna aceeași , indiferent de momentul de timp. Se consideră în acest caz că *mediul este determinist* iar comportamentul agentului poate fi prezis cu acuratețe.

nedeterminist, dacă dintr-o stare în care este prezent poate trece în una din stările de mediu prezente într-o submulțime care rezultă în urma executării acțiunii întreprinse de agent Se consideră în acest caz că *mediul este nedeterminist* iar comportamentul agentului este probabilistic

Modelarea bazată pe agenţi

Arhitecturi de Agenţi Inteligenţi

Structura comportamentală a unui agent



Funcţia percepţie: se referă la abilitatea agentului de a observa mediul.
Funcţia acţiune: se referă la procesul de aplicare al deciziilor



Modelarea bazată pe agenţi

Arhitecturi de Agenţi Inteligenţi

I. Agenţi total reactivi

Sunt agenţi care decid ce acţiune să aleagă la un moment dat, fără a ţine cont de *istoric*-ul lor. Luarea unei decizii se bazează doar pe prezent, nu are nici o legătură cu acţiunile trecute ale agentului. Un astfel de agent se numeşte ***agent total reactiv***, datorită faptului că reacţionează *direct* la mediu

Comportamentul unui agent total reactiv

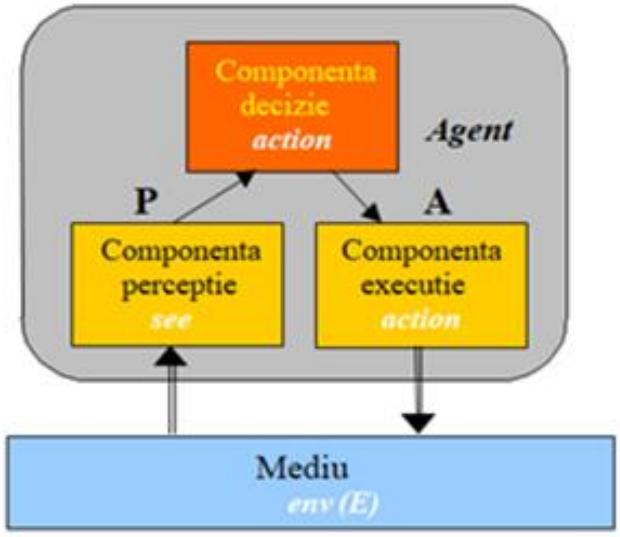
Formal, comportamentul unui agent total reactiv poate fi reprezentat sub forma unei funcţii : ***acţiune : S→ A***.

Modelarea bazată pe agenţi

Arhitecturi de Agenţi Inteligenţi

I. Agenţi total reactivi

Formal, comportamentul unui agent total reactiv poate fi reprezentat sub forma unei funcţii : ***acţiune : S→ A***.



$S = \{s_1, \ldots s_n \ldots\}$
$P = \{p_1, \ldots p_n \ldots\}$
$A = \{a_1, \ldots a_n \ldots\}$

Stările mediului
Mulțimea percepțiilor de care dispune agentul
Mulțimea acțiunilor care pot fi intreprinse

Agent reactiv

$$\begin{cases} see: \quad S \to P \\ action: \quad P \to A \\ env: \quad S \times A \to S \\ env: (S \times A \to P(S)) \end{cases} \quad env(E)$$

Modelarea bazată pe agenţi
Arhitecturi de Agenţi Inteligenţi

I. Agenţi total reactivi

Formal, comportamentul unui agent total reactiv în prezența unor agenți total reactivi poate fi reprezentat dr asemenea sub forma unei funcţii :

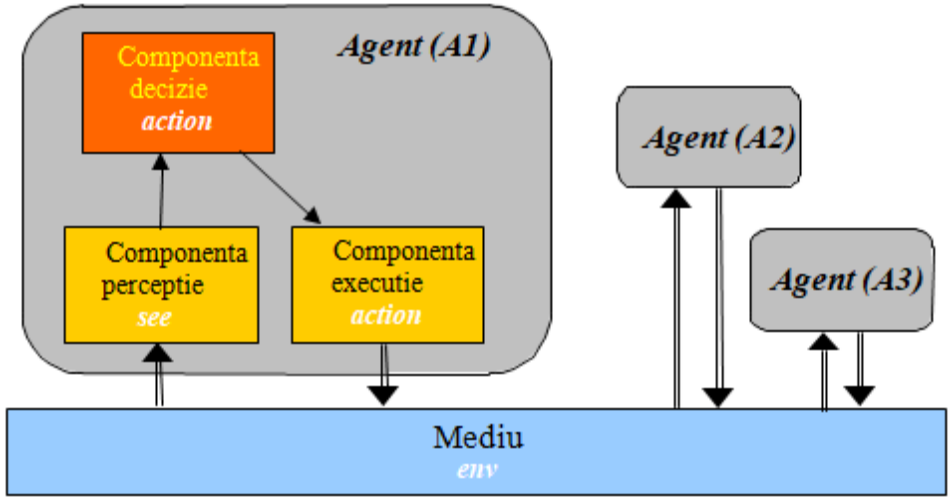
acţiune : S→ A.

Cooperarea între agenți se face prin intermediul mediului în care sunt prezenți

$\mathbf{A_1},\ldots,\mathbf{A_i},..$

$\mathbf{P_1},\ldots,\mathbf{P_i},..$

(de obicei identice)



Mai multi agenti reactivi

$$\begin{cases} see: & S \to P_i \\ action: & P_i \to A_i \\ env: & S \times A_1 \ldots . A_n \to P(S) \end{cases}$$

$$env(E)$$



Modelarea bazată pe agenţi

Arhitecturi de Agenţi Inteligenţi

I. Agenţi total reactivi - Exemplu

Un exemplu de agent total reactiv este un termostat ce dispune de un senzor pentru a detecta temperatura camerei. Mediul termostatului poate fi în una din următoarele două stări: e_1 = prea frig sau e_2 = temperatură corectă. Acţiunile disponibile fiind doar două, corespunzătoare celor două stări ale mediului:

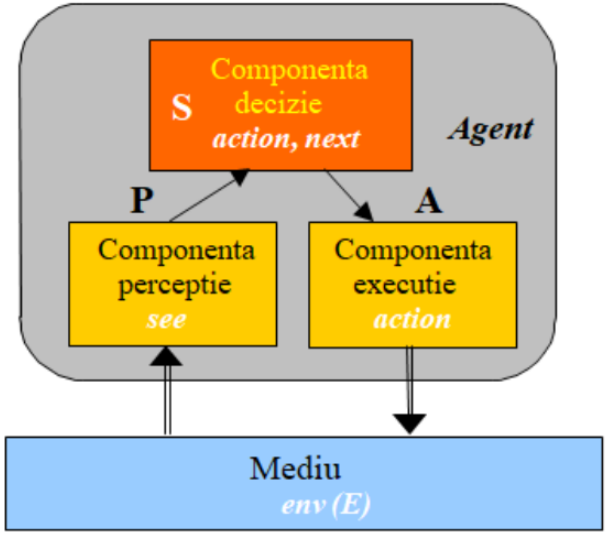
$$agent(e) = \begin{cases} căldura Pornită \\ căldura Oprită \end{cases}$$

Agentul poate la orice moment să reacţioneze imediat, decizia despre acţiunea pe care o va efectua fiind *independentă* de acţiunile sale anterioare.

Modelarea bazată pe agenţi

Arhitecturi de Agenţi Inteligenţi

II. Agenţi cu stări (cognitivi).



$$S = \{s_1, \ldots . s_n \ldots\}$$
$$P = \{p_1, \ldots . p_n \ldots\}$$
$$A = \{a_1, \ldots . a_n \ldots\}$$

Agent cognitiv

$$\begin{cases} see: & S \to P \\ next: & S \times P \to S \\ action: & S \to A \\ env: & S \times A \to P(S) \end{cases}$$

Comportamentul unui agent bazat pe stări (cognitiv)

- agentul porneşte cu o stare internă iniţială $\boldsymbol{i_0}$ şi observă starea mediului ***s***;
- generează percepţia ***percepţie(s)***;
- starea internă a agentului va fi actualizată conform funcţiei *next*, devenind ***next*($\boldsymbol{i_0}$, *percepţie*(*s*))**;
- acţiunea selectată de agent, corespunzătoare stării sale interne va fi ***action(next*($\boldsymbol{i_0}$, *percepţie*(*s*)))**;
- acţiunea va fi executată, după care agentul reia ciclul.

Modelarea bazată pe agenţi

Arhitecturi de Agenţi Inteligenţi

II. Agenţi cu stări (cognitivi).

Formal, comportamentul unui agent cognitiv în prezența unor agenți cognitivi cu care interactioneaza poate fi reprezentat dr asemenea sub forma unei funcţii :

acţiune : S→ A.

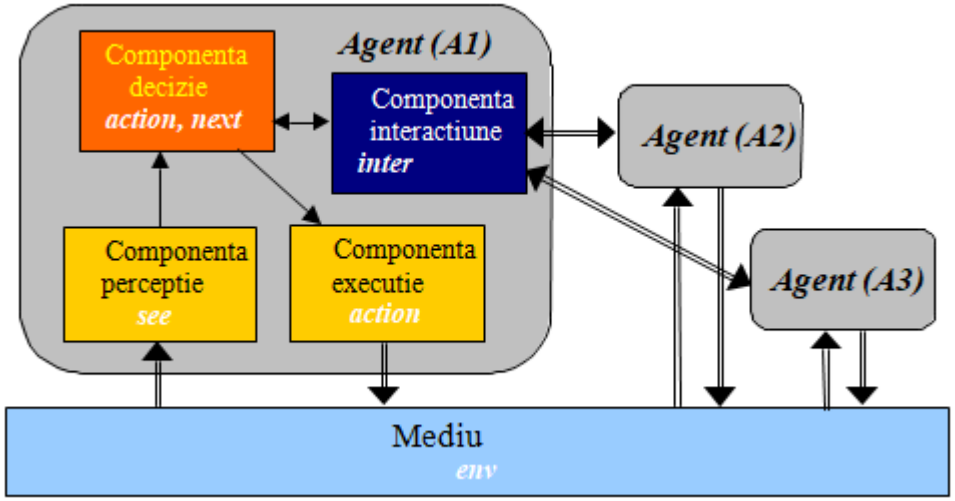
Cooperarea între agenți se face prin intermediul unei componente ***interactiune*** care stabilește secventa de actiuni propuse de agenti cognitivi

$S = \{s_1, ...s_n ...\}$ {stari}

$P = \{p_1, ...p_n ...\}$ {perceptii}

$A = \{a_1, ...a_n ...\}$ {actiuni luate de agentul prezent}

$I = \{i_1, ...i_n ...\}$ {actiuni propuse de agenti cu care agentul prezent interactioneaza}



$S = \{s_1, ...s_n ...\}$

$P = \{p_1, ...p_n ...\}$

$A = \{a_1, ...a_n ...\}$

$I = \{i_1, ...i_n ...\}$

Mai multi agenti cognitivi

$$\begin{cases} see_i : & S \to P_i \\ next_i : & S_i \times P \to S_i \\ interactiune_i : & S_i \to I \\ action_i : & S_i \times I \to A_i \\ env : & S \times A_1 \times .....A_n \to P(S) \end{cases}$$



Modelarea bazată pe agenţi

Concepte

Definiție

Modelarea bazată pe agenți - agent-based model (ABM) – Reprezintă o tehnică de modelare în care sistemul este reprezentat printr-o colecție de agenți care interacționează între ei pe de o parte și cu mediul în care este prezent sistemul modelat pe de altă parte.

Scopul acestei tehnici este acela de a reprezenta un sistem prin intermediul relațiilor care apar între entitățile care definesc comportarea acestuia. Din acest punct de vedere ABM este o tehnică care se poate aplica pentru descrierea și modelarea structurilor sociale, economice și nu în ultimul rând a evenimentelor de orice natură în care relațiile care se stabilesc între componentele sistemului sunt cele care determină comportarea acestuia (manifestări sportive, dezastre naturale etc.)



Modelarea bazată pe agenţi

Cum se construiește un model de tip ABM

- Care este scopul modelului și ce se dorește a fi obținut printr-o modelare bazată pe agenți
- Ce relații se vor modela prin intermediul agenților
- Stabilirea structurii unui agent:
  - Ce atribute statice are agentul?
  - Ce atribute dinamice are agentul? Dintre aceste atribute dinamice care se actualizează de agent și care de modelul în ansamblu?
  - Care sunt atributele prin intermediul cărora agentul interacționează cu mediul în care acționează?
- Comportarea agentului
  - Ce acțiuni poate întreprinde agentul?
  - Cum se reprezintă comportarea agentului? Prin reguli de tip If-then? Printr-o comportare probabilistică? Prin modele regresionale sau rețele neuronale?
- Interacțiunea dintre agenți:
  - Cum interacționează un agent cu un alt agent?
  - Cum interacționează agentul cu mediul în care acționează?
  - Cât de generale sau particulare sunt interacțiunile agentului?
- Rezultate obținute prin simulare de tip ABM



Modelarea bazată pe agenţi

Aspecte care trebuie obligatoriu rezolvate în modelarea bazată pe agenți

1. **Rezolvarea conflictelor**: Problema apare atunci când doi sau mai mulți agenți urmează să execute o activitate la același moment de timp. Stabilirea unui mecanism de rezolvare a acestor situații este obligatorie. Mecanismul va trebui să țină cont de implicațiile pe care generează execuția unei activități cerute de un agent în fața alteia solicitate de un alt agent la același moment de timp.

2. **Interacțiunea cu mediul**: Problema apare atunci când mediul este descris prin mai multe layere, caz în care trebuie stabilită o strategie de mișcare a agentului în cadrul acestui spațiu complex.



Modelarea bazată pe agenţi

Aspecte care trebuie obligatoriu rezolvate în modelarea bazată pe agenți

3. **Strategii de interacțiune**: Strategiile pot avea un caracter dinamic. În cazul în care se definesc noi reguli sau se modifică acestea în timpul interacțiunii agenților este necesară separarea clară a procesul de activare a regulilor de mecanismul de creare de noi reguli.

4. **Învățare**: Se referă la posibilitatea ca un agent să învețe și să își modificecomportamentul funcție de experiența obținută din interacțiunea cu mediu și din interacțiunea cu alți agenți



Modelarea bazată pe agenţi

Exemple - Jocul vieţii (game of life)

- Jocul Life este un automat celular inventat de matematicianul John Conway în 1970. Conway a fost interesat de o problemă prezentată în 1940 de matematicianul John von Neumann, care a încercat să găsească un dispozitiv ipotetic care putea să se reproducă.

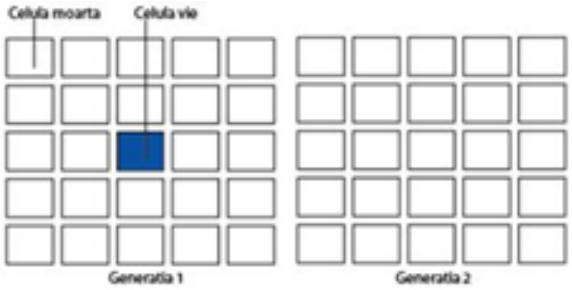
- Jocul Life nu este chiar un joc el neavând jucători şi nu există pierdere sau câştig aceasta însemnând că el depinde doar de stare sa iniţială și de regulile de evoluție.

- Game of Life se desfăşoară pe o suprafaţă pătrată împărţită în celule, asemănător cu o tablă de şah, suprafaţa pătrată se presupune a fi infinită în toate direcţiile. Fiecare celulă poate să fie moartă sau vie, adică goală sau ocupată de o entitate, şi este înconjurată de alte opt celule care îi pot influenţa starea sa , adică poate să se nască o nouă entitate sau să moară dacă ea există. Starea fiecărei celule se schimbă simultan datorită regulilor jocului.

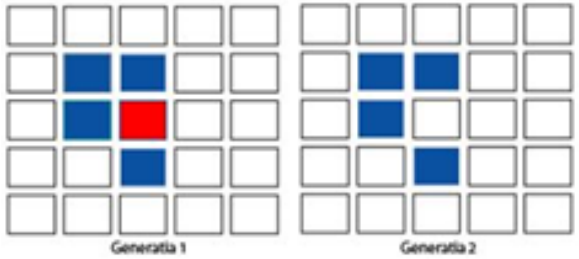
Modelarea bazată pe agenţi

Exemple - Jocul vieţii (game of life)

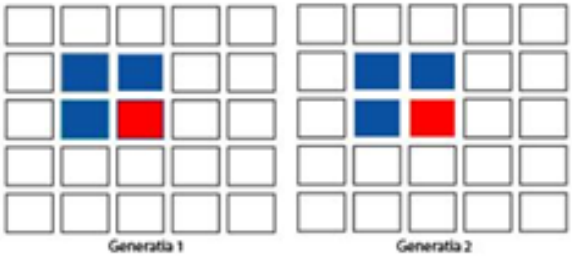
Regulile jocului



1. Dacă o celulă este vie, dar nu are nici un vecin viu, sau doar un singur vecin viu atunci ea va muri de singurătate în generaţia următoare



2. Dacă o celulă este vie, dar are cel puțin patru vecini vii, atunci ea va muri sufocată în generaţia următoare.

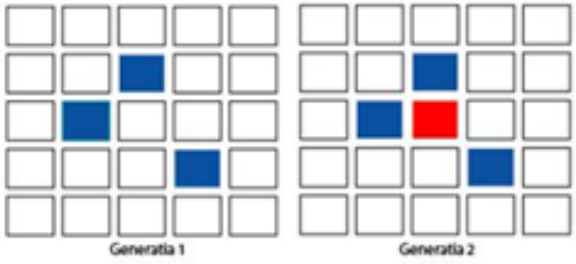


3. Dacă o celulă este în viaţă şi are doi sau trei vecini atunci ea va trăi, neschimbată, şi în generaţia următoare

Modelarea bazată pe agenţi

Exemple - Jocul vieţii (game of life)

Regulile jocului



4. Orice celulă moartă va învia în generaţia următoare dacă are exact trei vecini vii în generaţia curentă.

5. Jocul se opreşte într-o stare care se repetă la infinit sau în care toți agenții (entităţiile) mor.



Modelarea bazată pe agenţi

Exemple - Jocul vieţii (game of life)

Observații

1. regulile din Life sunt simple și utilizează numai informații locale. Prin local vom înțelege că starea unui agent este bazată numai pe starea agenților din imediata vecinătate

2. evoluția în Life este dictată de configurația inițială (agenți cu stări *On* sau *Off* generate aleator) de la care se pleacă. Ideea este că avem un sistem simplu compus din reguli simple, care începe într-o stare aleatoare și că evoluția sa care depinde de o stare inițială reflectă posibilitatea de a genera lumi virtual infinite.

3. Conway a descoperit anumite forme de viaţă pe care el le numea „*R-pentomino*” care nu puteau să se stabilizeze.

4. Se pleacă de la o matrice, în care fiecare celulă este 0 iar unde există o entitate se notează cu 1, se parcurge matricea şi unde se întâlneşte 1 i se verifică cei opt vecini şi se aplică regula.

Modelarea bazată pe agenţi

Exemple - Jocul vieţii (game of life)

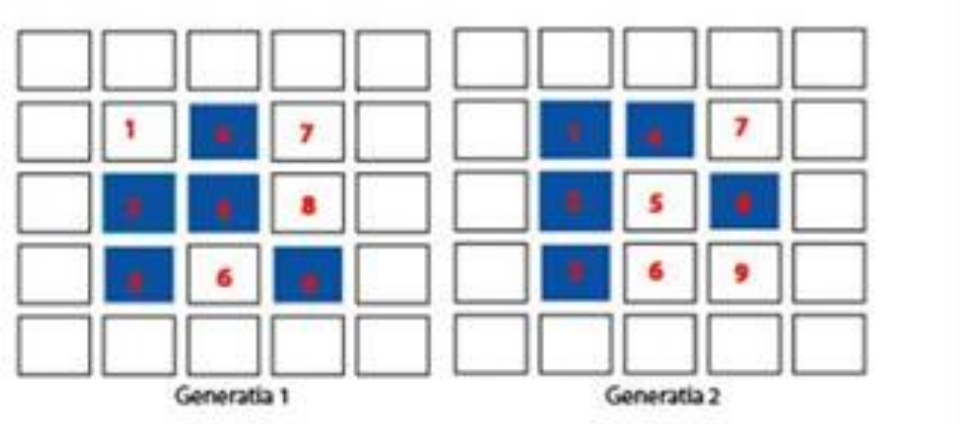
Regulile jocului

Exemplu

- ✓ Din cauza existenţei a exact trei vecini în viaţă în jurul celulelor 1 şi 8 , având ca vecini vii celulele 2,4 şi 5 respectiv 4,5 şi 9 în jurul lui 8, se aplică regula patru iar celule moarte 1 şi 8 învie.

- ✓ Celulele 2,3 şi 4 rămân neschimbate datorită reguli 2, având fiecare celulă doi sau trei vecini în viaţă pe 3,4 şi 5 respectiv 2 şi 5.

- ✓ Entităţile 5 şi 9 mor din cauza regulilor 1 şi 2 , celula 9 moare de singurătate, având un singur vecin viu iar celula 5 moare pentru este sufocată de celulele 2,3,4 şi 9.





Modelarea bazată pe agenţi

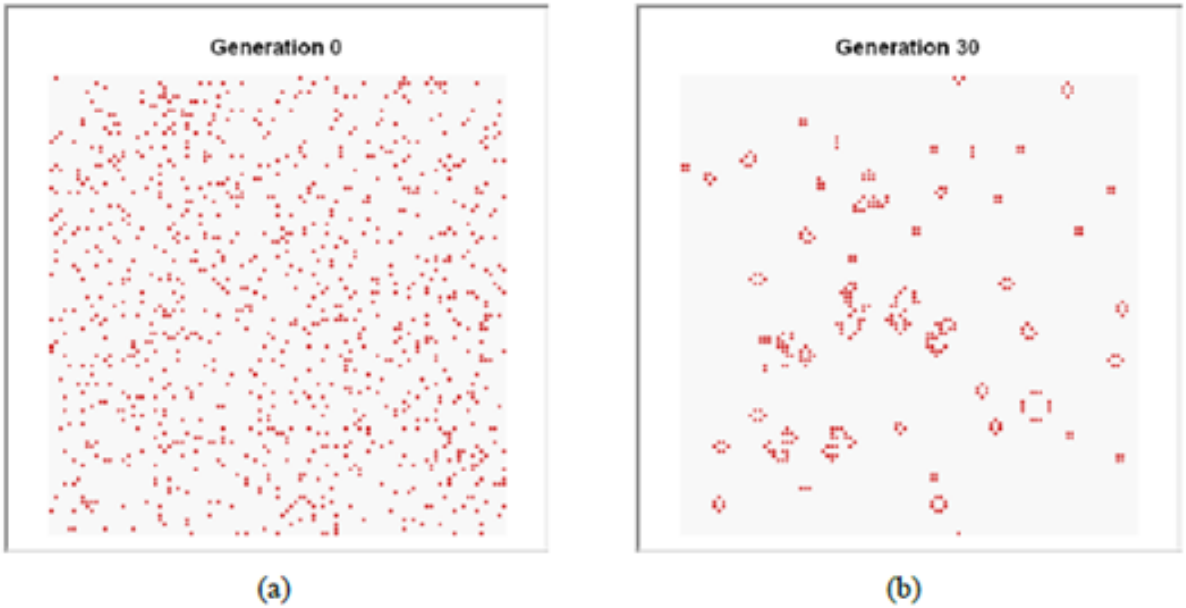
Exemple - Jocul vieţii (game of life)

Dacă interpretăm *Life* ca un **Model – ABM** vom putea considera că:

- fiecare celulă este un agent. Agentul utilizat este de tip reactiv.
- regulile jocului definesc comportarea agentului.
- starea celulei (*On* sau *Off*) reprezintă cele două stări în care este prezentă o celulă.
- starea tuturor agenților luați împreună la un moment dat de timp din durata simulării definește starea modelului (sistemului).
- mediul în care acționează *Life* este definit de grila (matricea) în care agenții acționează.
- Funcția mediul este minimă fiind utilizată numai pentru determinarea vecinilor unui agent (în număr de 8).

Modelarea bazată pe agenţi

Exemple - Jocul vieţii (game of life)



Simulare Life

(a) distribuția inițială a agenților în mediul în care sunt prezenți. Toți agenții sunt în starea On

(b) distribuția agenților după 30 cicluri de evoluție.



Modelarea bazată pe agenţi

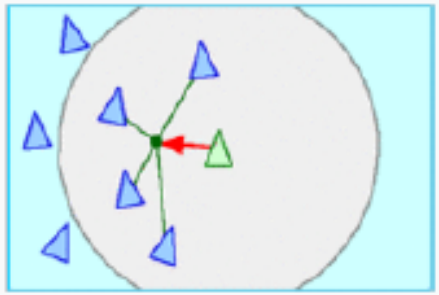
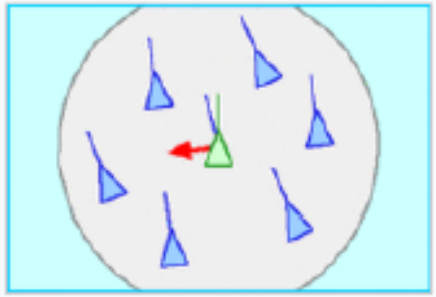
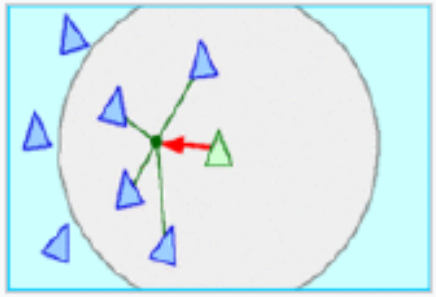
Exemple - Modelarea comportării stolurilor de păsări

- Modelul a fost propus Craig Reynolds în 1986 cu scopul modelării și simulării comportamentului zborului stolurilor de păsări.

- Modelul în care sunt încorporate reguli simple de comportament dă posibilitatea explicării comportamentului emergent (*Teoria evoluției emergente = teorie idealistă și metafizică cu privire la procesul dezvoltării, potrivit căreia apariția noilor calități este absolut spontană și imprevizibilă*) al mulțimilor de păsări în cazul dat. O pasăre este denumită "boid,, Termenul de "**boid**" corespunde la abrevierea "**bird-oid object**", care corespunde la păsări ca și obiect

Modelarea bazată pe agenţi

Exemple - Modelarea comportării stolurilor de păsări

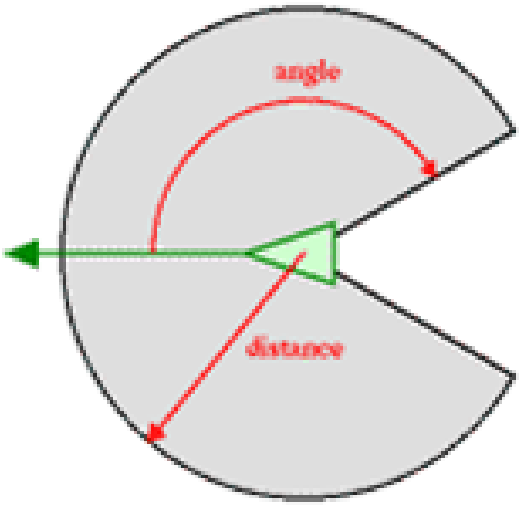
Regulă		
coeziune		Fiecare tinde să se deplaseze spre mijlocul roiului din care face parte
separare		Evitarea coliziunilor cu vecinii
aliniere		Potrivirea vitezei cu aceea a vecinilor

Modelarea bazată pe agenţi

Exemple - Modelarea comportării stolurilor de păsări

Precizări

- Accesul este limitat la un moment dat numai la un număr mic de elemente din imediata vecinătate.
- Vecinătatea este caracterizată de o *distanţă* (măsurată din centrul boid-ului) şi de un unghi , (măsurat de la boid în direcţia de zbor). Elementele boid prezente în afara acestei vecinătăţi sunt ignorate.



Vecinătatea poate fi considerată un model al percepţiei limitate a unui element boid, dar de asemenea ca fiind zona în care comportamentul unui boid este influenţat de comportamentul elementelor vecine.

Modelarea bazată pe agenţi

Exemple - Modelarea comportării stolurilor de păsări

Precizări

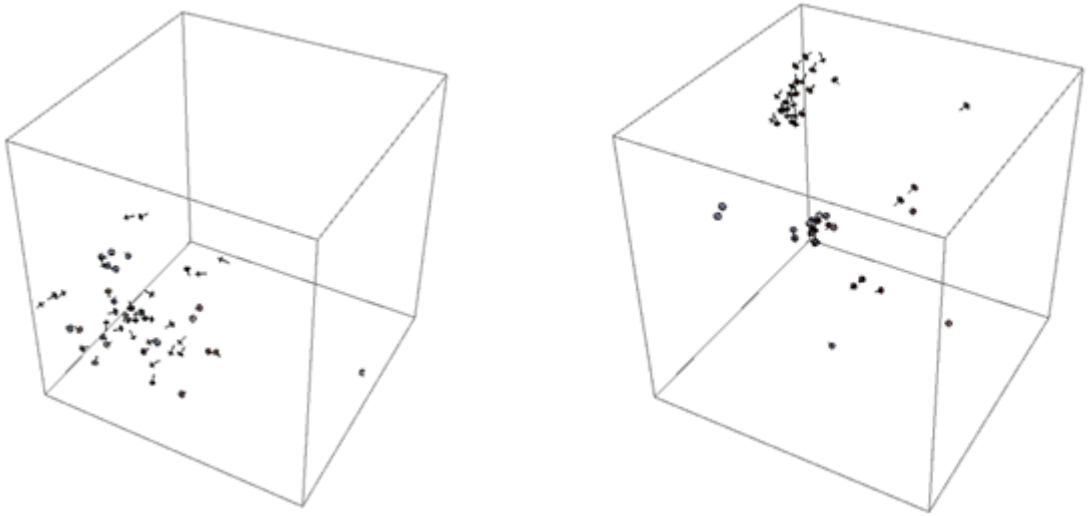
1) Considerăm că fiecare boid este un agent.
2) Agentul utilizat este de tip reactiv
3) Cele 3 reguli plus modul de definire a vecinătății definesc comportarea agentului mediul în care acționează
4) Spațiul este definit de o matrice (de dimensiune 2D sau 3D – dacă se modelează deplasarea în trei dimensiuni) în care agenții acționează. Inițial, se generează un număr aleatoriu de elemente de tip boid care se vor amplasa în celulele matricei. În urma acestei generări se va defini poziția inițială de plecare. Aceasta se va actualiza în fiecare pas conform regulilor specificate. În urma actualizării se vor modifica pozițiile elementelor boid din matricea care definește mediul. În contextul acestui mediu se pot defini obstacole (prin blocarea unor elemente din matricea care reprezintă mediul) care să fie evitate de multimea de elemente boid.

Modelarea bazată pe agenţi

Exemple - Modelarea comportării stolurilor de păsări

Precizări

- starea tuturor agenților luați împreună la un moment dat de timp din durata simulării definește starea modelului (sistemului).



(a) (b)

Simulare *Boid*

(a) distribuția inițială aleatoare a agenților în mediul în care sunt prezenți.

(b) distribuția agenților după 500 cicluri de evoluție



Modelarea bazată pe agenţi

Exemple - Modelarea dinamici unei epidemii

Considerăm un model comportamental de tip SEIR (**S**usceptible **E**xposed **I**nfectious **R**ecovered). Inițial problema ridicată de un model SEIR (dinamica unei epidemii) a fost rezolvată utilizând ecuații diferențiale. Aceste tratează problema în caz general fără să țină cont de:

- spațiul în care apare epidemia, de modul în care acesta influențează răspândirea acesteia (comunicarea între persoane este dependentă de amplasarea acestora într-un spațiu dat)
- de particularitățile individuale ale unei persoane din spațiul respectiv.

Acesta este motivul pentru care în prezent sunt utilizate modele cu agenți inteligenți cu stări (cognitivi)



Modelarea bazată pe agenţi

Exemple - Modelarea dinamici unei epidemii

Caracteristici Epidemie

- Considerăm o populație de 10,000 persoane care domiciliază într-o arie de 10 x 10 km. Aceste persoane apar în zonă uniform.
- O persoană își cunoaște vecinii pe o zonă de 1 km față de punctul în care locuiește. Nu cunoaște persoanele care sunt în afara acestei.
- Inițial 10 persoane sunt infectate aleatoriu. Restul persoanele sunt susceptibile de a fi infectate, ne existând persoane imune la agentul epidemic.
- Dacă o persoană infectată ia contact cu o altă persoană susceptibilă de a fi infectată probabilitatea de transmisie a bolii este de 0,1 %.



Modelarea bazată pe agenţi Exemple - Modelarea dinamici unei epidemii

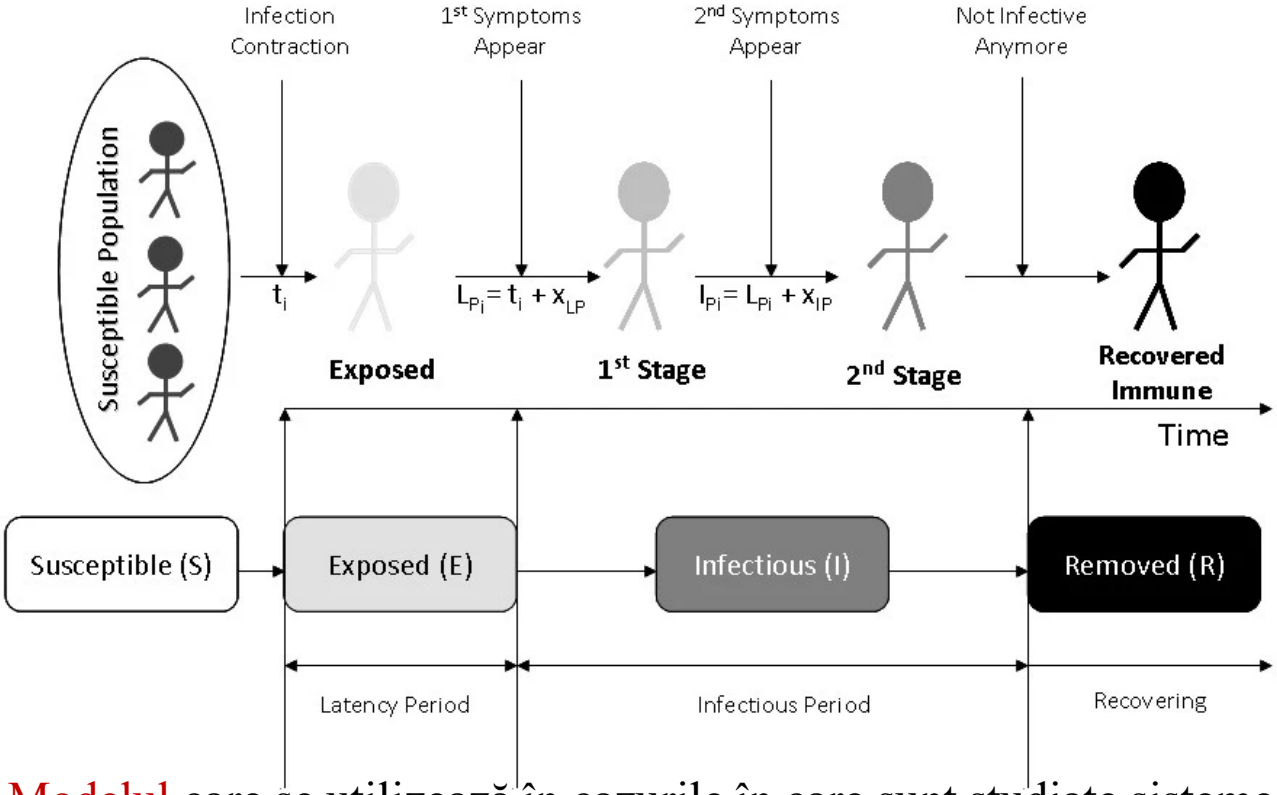
Caracteristici Epidemie

- Dacă o persoană a fost infectată, boala este într-o *fază latentă* cu o durată de 3 până la 6 zile. În această perioadă (pe care o vom numi *exposed*) nu infecta alte persoane cu care intră în contact.
- Durata bolii după faza latentă fază pe care o vom numi *fază de infecție*) este uniform distribuită între 7 și 15 zile
- În timpul fazei de infecție o persoană poate contacta maxim până la 5 persoane pe zi.
- Când o persoană se recuperează devine imună. Imunitatea este câștigată o perioadă limitată de timp, care se întinde pe o perioadă de 30 până la 70 de zile.

Modelarea bazată pe agenți

Exemple - Modelarea dinamici unei epidemii

Diferite stări ale modelului de infecție SEIR

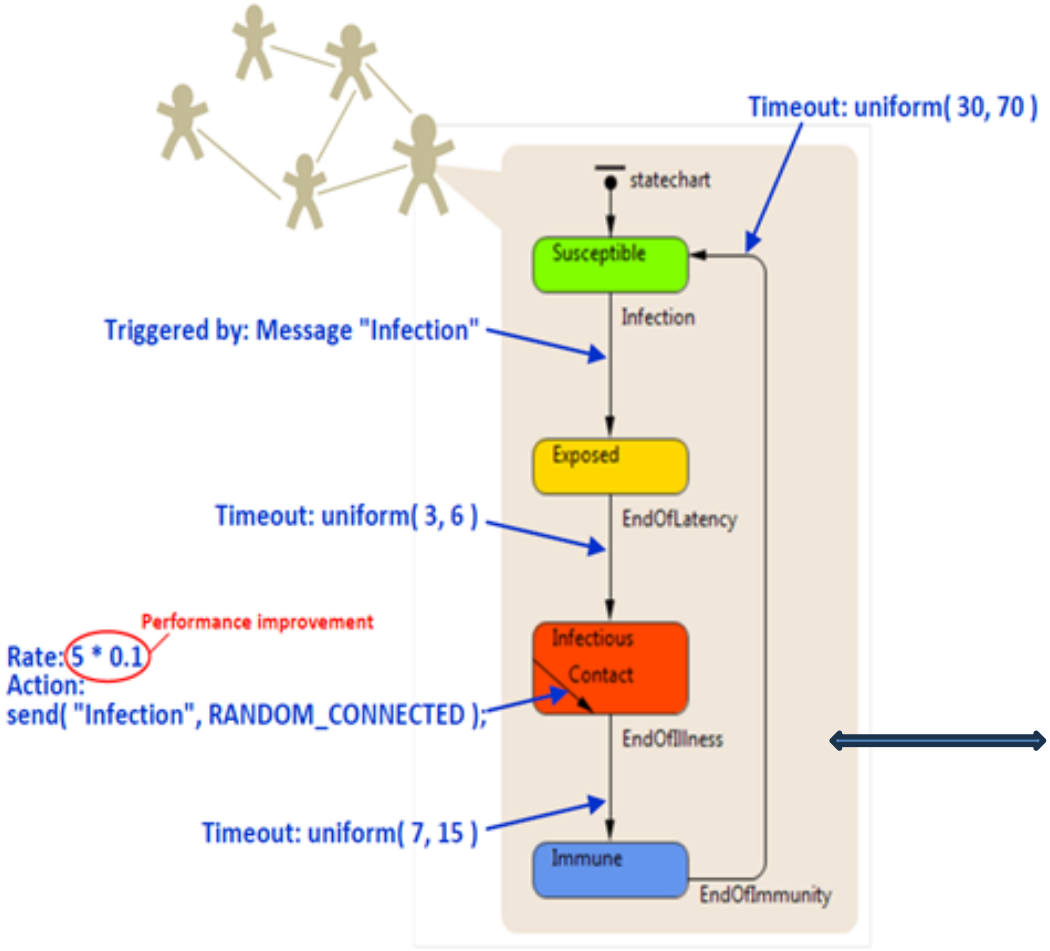


L_{Pi}: perioadă de latență,
I_{Pi}: perioadă infecțioasă,
t_i: prima zi în care un individ e pentru prima dată,
x_{LP}: numărul de zile în care o p devine infecțioasă și
x_{IP}: numărul de zile în care un individ este expus la virus. recuperați din boală.

Modelul care se utilizează în cazurile în care sunt studiate sisteme în care apar relații și schimburi de informații între componentele sistemului pe de o parte și între acestea și mediul înconjurător este cel de tip *agent cu stări (cognitiv).*

Modelarea bazată pe agenţi

Exemple - Modelarea dinamici unei epidemii



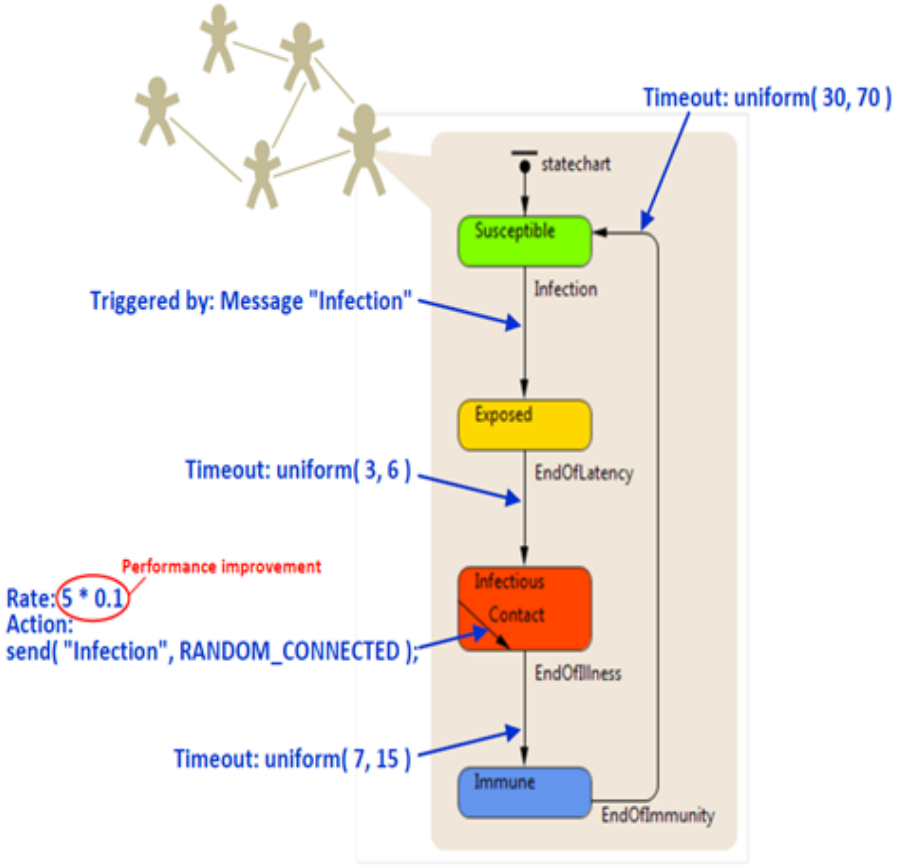
Comportamentul agentului

Dacă interpretăm *SIER* ca un model de tip *agent cu stări* , vom putea considera că fiecare persoană este un agent. Comportamentul agentului este descris de o diagramă de stare.

Cele 4 stări prezente în diagramă corespund celor patru faze de evoluție a bolii.

Modelarea bazată pe agenţi

Modelarea dinamici unei epidemii

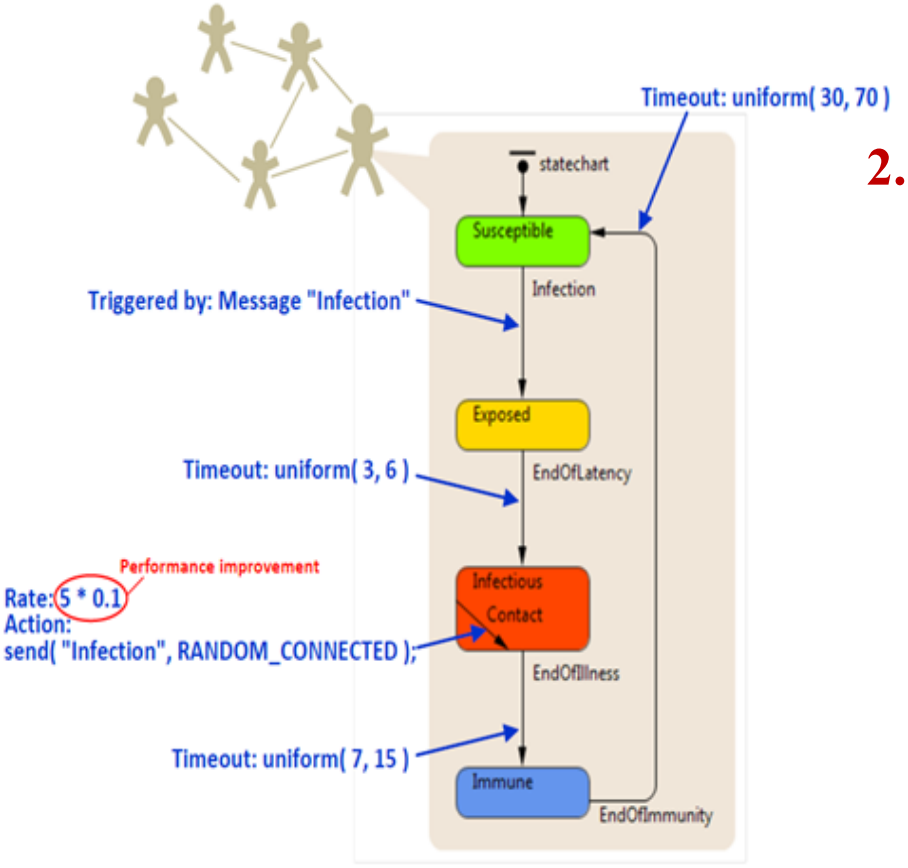


Faze de evoluție a bolii

1. Inițial persoana este în starea **Susceptibil** , stare în care rămâne până când este infectată. Infectarea poate avea loc numai în timpul contactului cu o altă persoană (de tip vecin) . Acest contact, este modelat prin intermediul unui mesaj care este trimis de la un agent la altul.

Modelarea bazată pe agenţi

Modelarea dinamici unei epidemii

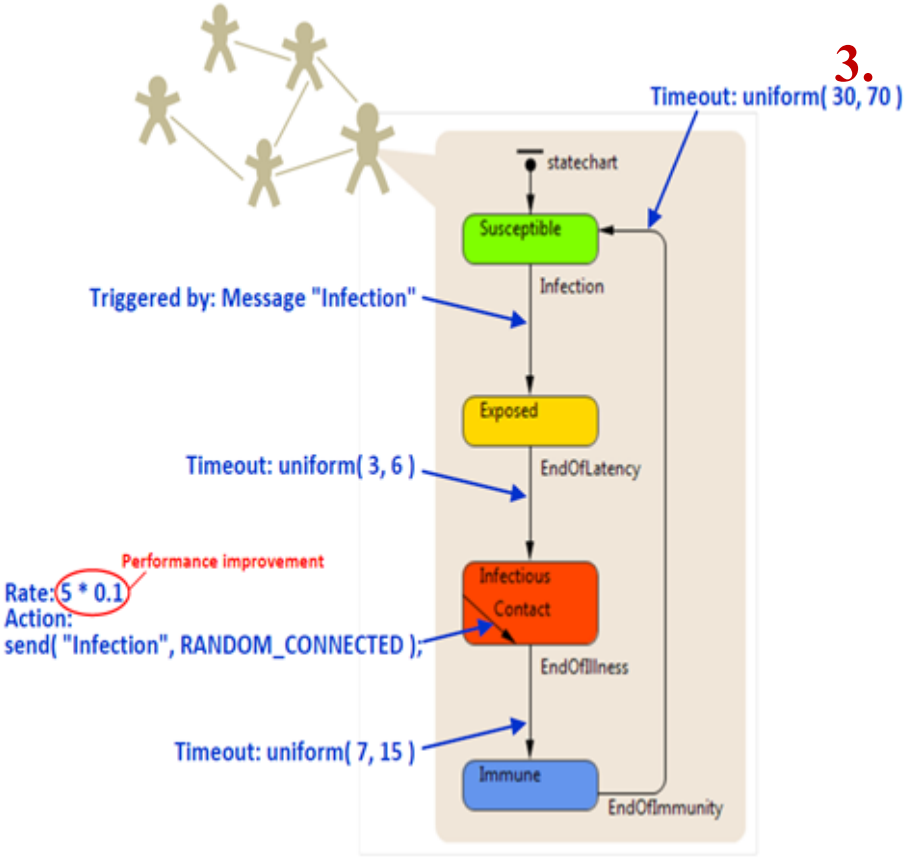


Faze de evoluție a bolii

2. Tranziția din starea **Susceptibil** în starea **Expus** se face în momentul primirii mesajului prin intermediul căruia se modelează transmiterea virusului.

Modelarea bazată pe agenţi

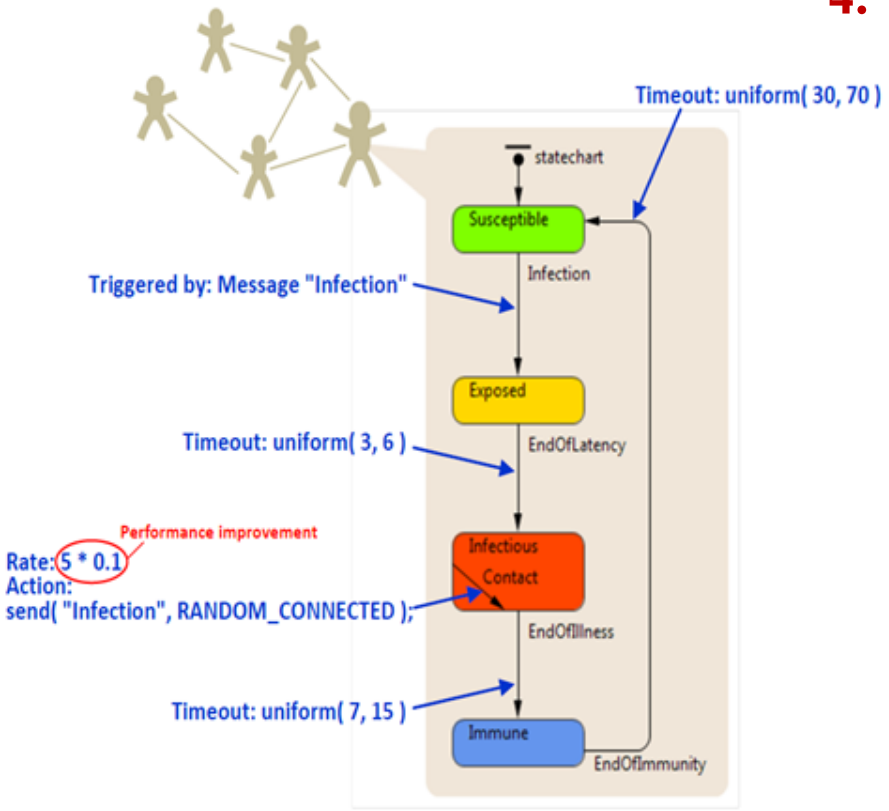
Modelarea dinamici unei epidemii



3. "**Infecție**" . O dată ce o persoană este infectată se trece la calcularea duratei de incubație a maladiei. Acest aspect presupune calcularea valorii pentru **EndOfLatency**, mărime care specifică momentul în care boala devine activă și terminarea perioadei de incubație. Agentul trece în starea **Expus** fază care este de [3, 6] zile. Valoarea, se obține generând o valoare uniform distribuită în intervalul specificat.

Modelarea bazată pe agenţi

Modelarea dinamici unei epidemii



4. Atunci când persoana este în faza **Infecție** poate lua periodic contact cu alte persoane din aria vecină definită. Acest aspect este modelat printr-o tranziție internă a fazei **Infecție** care este activată ciclic cu o frecvență specifică fiecărui agent (persoană) în parte. În momentul când se activează acest tranziție (o numim **Contact**) se trimite un mesaj de tip **Infecție** spre un alt agent. Mesajul conține si o informație de tip șansă de a infecta agentul care primește mesajul. Pentru cazul dat această șansă este de 0,1 %



Modelarea bazată pe agenţi

Modelarea dinamici unei epidemii

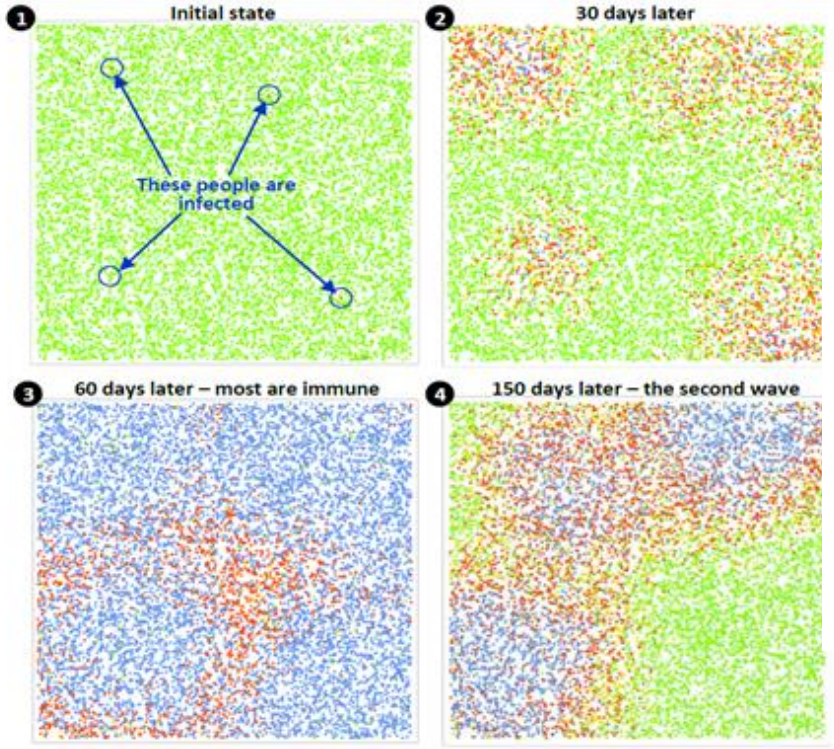
Definirea mediului (ariei în care se desfășoară epidemia)

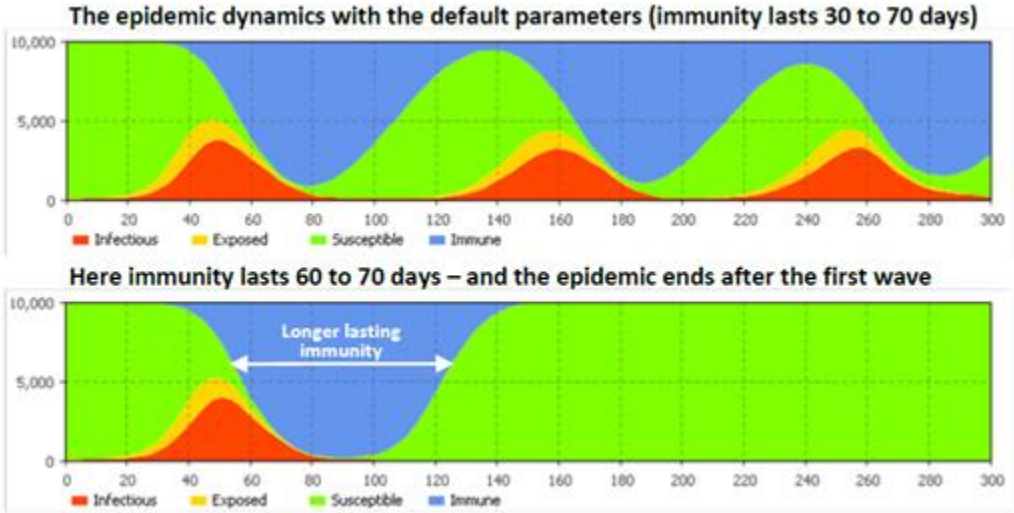
- Spațiul în care se desfășoară epidemia (10 km x 10 km) se poate defini ca o matrice de dimensiune de 1000 x 1000 considerând că un element al matricei va defini un spațiu de 100 metri x 100 metri.
- Se populează spațiul cu un număr de 10,000 de persoane.
- Se infectează aleatoriu 10 persoane prin trimiterea de mesaje de tip **Infecție la începutul simulării.**
- Se lansează operația de simulare pentru o perioadă dată.

Modelarea bazată pe agenţi

Modelarea dinamici unei epidemii

O dinamică a modului în care evoluează epidemia este dată în figura de mai jos





Animation and output of the agent based epidemic model


MULTIMETHOD
MODELING
SYSTEM
DYNAMICS
AGENT BASED
MODELING
DISCRETE EVENT
MODELING

Întrebări???

MODELARE și SIMULARE

Modele corelaționale –
Modele Cauză / Efect





Modele corelaționale

Concepte

În multe situații, sistemul care definește un fenomen din lumea reală (de exemplu fenomene meteo, tehnice – caracteristici funcționale ale unor aparate electronice, medicale, sociale – promovarea unui produs, fenomene de tip imigraționiste etc.) este reprezentat de un set de entități a căror mod de interacțiune între ele și cu lumea înconjurătoare nu este posibil de a fi definit prin ecuații intrare / ieșire, relații între elementele care alcătiesc sistemul și de asemenea nu este posibil să avem o desfășurare clară a succesiunii activităților care au loc sau a stărilor în care acesta este prezent

În aceste cazuri singura posibilitate care rămâne, este aceea ca sistemul asociat fenomenului să fie descris de un set de date (obținute prin măsurători directe care descriu comportarea acestuia la un moment dat), care în foarte multe cazuri are un caracter strict numeric.

Tehnica utilizată în astfel de cazuri poartă denumirea de *Analiză corelațională*. *Modelele care apar prin aplicarea acestei tehnici sunt cunoscute sub denumirea de modele corelaționale (regresionale) sau modele de tip cauză / efect*

Modele corelaționale

Exemplu

Considerăm un set de date de volum ***n***.

✓Acestea vor caracterizează sistemul respectiv și vor corespunde unei situații particulare în care se găsește sistemul în cauză. Practic s-a surprins un instantaneu din funcționarea sistemului.

✓Fiecare element (instanță) din setul de date poate fi caracterizat de un ansamblu de atribute. Aceste atribute sunt: memoria principala, memorie cache, etc. În cele ce urmează convenim să denumim setul de atribute ca reprezentând variabile

	Cycle time (ns)	Main memory (Kb)		Cach e	Channels		Performanc e
	MYCT	MMI	MMA	CACH	CHMIN	CHMAX	PRP
1	125	256	6000	256	16	128	198
2	29	8000	3200	32	8	32	269
...							
208	480	512	8000	32	0	0	67
209	480	1000	4000	0	0	0	45

MMIN: minimum main memory în kilobytes (integer)
MMAX: maximum main memory în kilobytes (integer)
CACH: cache memory în kilobytes (integer)
CHMIN: minimum channels în units (integer)
CHMAX: maximum channels în units (integer)
PRP: published relative performance (integer)



Modele corelaționale

Concepte

Analiza unui set de date cu această structură care să conducă la obținerea unui model, se poate efectua din următoarele puncte de vedere:

1. ***din punctul de vedere a unei singure variabile* a cărei valoare este influențată de restul variabilelor din setul de date. D**e exemplu, aceasta poate fi un atribut de forma: memoria principala ce caracterizează un sistem de calcul a cărei mărime este condiționată de restul atributelor din setul de măsurători.

2. ***fie din punctul de vedere al ansamblului de atribute*** ce caracterizează un sistem, caz în care modelul surprinde relațiile care apar între variabilele ce caracterizează sistemul în ansamblu. De exemplu relații de intercondiționare între memoria principala, memorie cache, etc.,



Modele corelaționale

Concepte

Analiza corelaţionala permite obținerea unor modele analitice ce definesc sistemul care a generat setul de date.

Pentru setul de date prezent modelul care poate fi obţinut este de forma:

$$PRP=-55.9+0.0489MYCT+0.0153\ MMIN+0.0056\ MMAX +$$
$$+0.6410\ CACH-0.2700\ CHMIN+1.480\ CHMAX$$

Pentru construirea modelului se parcurg două etape de analiză :

(A) ***Analiza regresională***, care se ocupă cu descrierea și *cercetarea legăturilor (dependenţei)* care există intre variabilele ce caracterizează elementele setului analizat. Rezultatul este un model matematic al fenomenului în cauză,

(B) ***Calculul coeficientului de corelaţie***, care se ocupă cu *determinarea_ gradului de dependenţă* care există intre variabilele. Acest coeficient va specifica acuratețea modelului construit

Modele corelaționale

Concepte

Dacă notăm

$x_1, x_2, \ldots x_m, y$ *setul de variabile ce caracterizează un element al eșantionului în care*

- $\{ x_i \}_{i=1}^{n}$ *caracterizează fenomenul cauză,*
- y *fenomenul efect,*

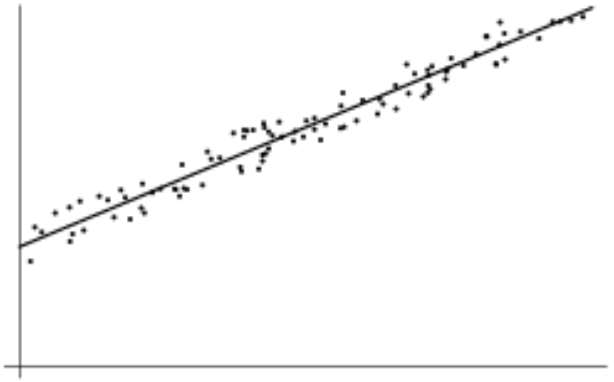
modelul dependenţei dintre cauză şi efect, este de forma :

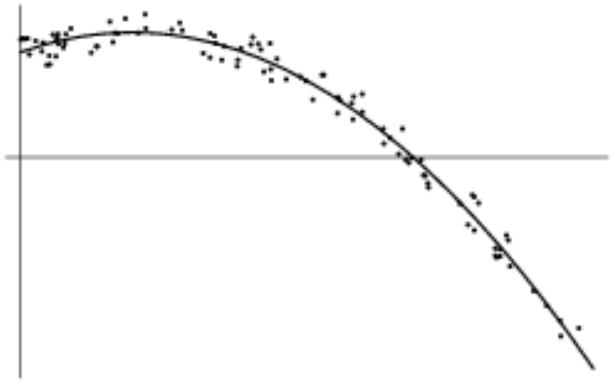
$$y = f (x_1, x_2, \ldots , x_m)$$

Sunt prezente două categorii de modele

A) Modele corelaționale liniare

B) Modele corelaționale polinomiale







Modele corelaționale

Modele corelaționale liniare

Modul în care se construiește modelul de tip cauze / efect se va exemplifica petru situația în care sistemul a furnizat un eșantion de msurători de dimensiune ***n*** fiecare măsurătoare având un număr de două valori de de forma $(x_i, y_i)_{i=1,n}$

a) Modelul (în care ***x*** este cauza iar ***y*** efectul) care descrie sistemul avut în vedere este de forma

$$y = a_0 + a_1 x$$

b) Modelul (în care ***y*** este cauza iar ***x*** efectul) care descrie sistemul avut în vedere este de forma

$$x = b_0 + b_1 y$$

În primul caz, modelul poartă numele de regresia liniară în ***x*** a lui ***y*** , iar în cel de-al doilea, regresia liniară în ***y*** a lui ***x***.



Modele corelaționale

Modele corelaționale liniare

Caracteristici :

- modelul $y = f(x_1, x_2, \ldots, x_m)$ este reprezentat printr-o linie dreaptă (dreapta de regresie) ;

- corelația (legătura) dintre variabilele cauza și efect este directă dacă odată cu creșterea valorii variabilei cauză creste și mărimea variabilei efect și inversă în caz contrar .

Modele corelaționale

Modele corelaționale liniare

Determinarea coeficienţilor dreptei de regresie

Vom determina aceşti coeficienţi numai pentru un set de date în care un element este caracterizat de doua atribute (***x*** și ***y***), deci modelul (ecuaţia regresională) va fi de forma :

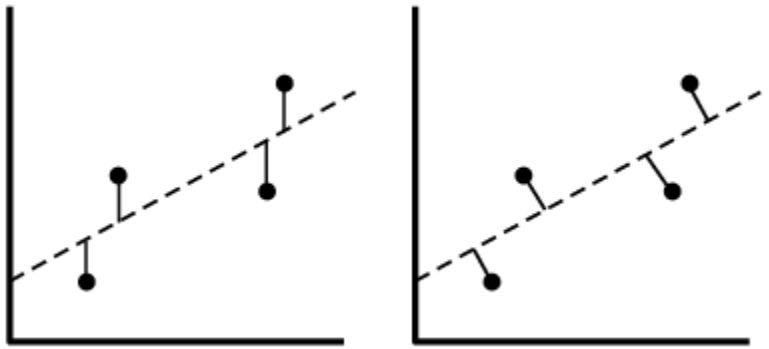
$$y = a_0 + a_1 x$$

Coeficienţii a_0 , a_1 se determină din condiția

a) ca suma abaterilor valorilor reale ale lui ***y*** față de valorile calculate y_x sa fie minimă .

b) ca suma distanțelor de la valorile setului de măsurători la dreapta de regresie să fie minimă

(a)



(b)



Modele corelaționale

Modele corelaționale liniare

Vom calcula această distanță în varianta (a).

Dacă notăm cu ***S*** suma a cărei minim se caută, avem

$$S = \sum \left(y_x - \bar{y} \right)^2 = \min$$

sau

$$S = \sum \left(a_0 + a_1 x - \bar{y} \right)^2 = \min$$

$\hat{y}$

Unde $\bar{y}$ reprezintă valoare medie a valorilor y_x Pentru a determina minimul lui ***S*** calculăm derivatele parțiale ale acesteia funcţie de a_0 și a_1

$$\frac{\partial S}{\partial a_0} = 2\sum \left(a_0 + a_1 x - y \right)$$

$$\frac{\partial S}{\partial a_1} = 2\sum \left(a_0 + a_1 x - y \right) x$$



Modele corelaționale

Modele corelaționale liniare

Anulăm derivatele parțiale :

$$\begin{cases} \sum \left(a_0 + a_1 x - y \right) = 0 \\ \sum \left(a_0 x + a_1 x^2 - yx \right) = 0 \end{cases}$$

de unde rezultă sistemul

$$\begin{cases} n a_0 + a_1 \sum x = \sum y \\ a_0 \sum x + a_1 \sum x^2 = \sum yx \end{cases}$$

Modele corelaționale

Modele corelaționale liniare

Model

$y = a_0 + a_1 x$

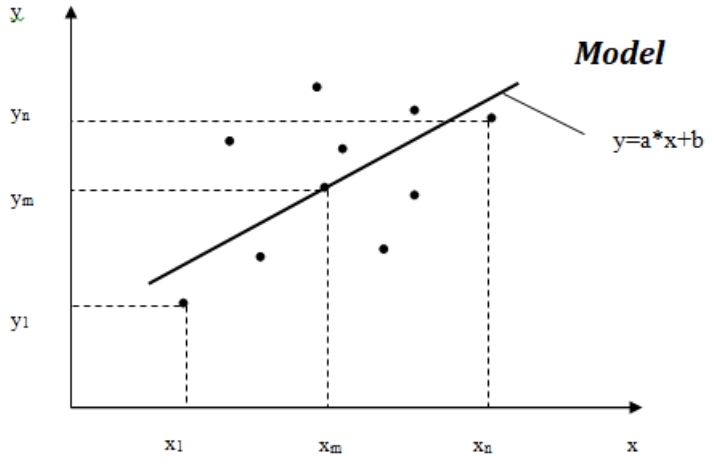
$$a_0 = \frac{\sum y \sum x^2 - \sum x \sum yx}{n\sum x^2 - \left(\sum x\right)^2}$$

$$a_1 = \frac{n\sum xy - \sum x \sum y}{n\sum x^2 - \left(\sum x\right)^2}$$

$x = b_0 + b_{1y}$

$$b_0 = \frac{\sum x \sum y^2 - \sum y \sum yx}{n\sum y^2 - \left(\sum y\right)^2}$$

$$b_1 = \frac{n\sum xy - \sum x \sum y}{n\sum y^2 - \left(\sum y\right)^2}$$





Modele corelaționale

Modele corelaționale liniare

Coeficientul de corelație

Definește calitatea modelului *(cât de bun este acesta). Este definit de un număr care măsoară gradul de legătură (împrăștiere – dispersie) între variabile.*

Se determină astfel :

Erorile standard de estimare pot fi considerate o măsură a gradului de legătură dintre două variabile deoarece :

- **o valoare mare** (indică o împrăștiere mare a punctelor fată de dreapta de regresie) va indica o legătură slabă (asociere) intre cele două variabile ;

- **o valoare mică** (indică o împrăștiere mică a punctelor fată de dreapta de regresie) va indica o legătura mai puternică între cele două variabile.

Dezavantajul constă în faptul că nu pot fi comparate direct între ele, deoarece ele se măsoară în unități ale variabilei ***x*** sau ***y***, care pot fi diferite de la caz la caz. Din acest motiv, se recurge la o măsură relativă raportând eroarea standard de estimare la abaterea medie pătratică.



Modele corelaționale

Modele corelaționale liniare

Raportul astfel obținut $\frac{S_y}{\sigma_y}$ sau $\frac{S_x}{\sigma_x}$

are următoarele avantaje :

- poate fi exprimat în procente, fiind adimensional ;
- dacă legătura dintre cele două variabile este perfectă, S_y sau S_x vor fi egale cu zero și raportul va fi egal cu zero ;
- dacă asocierea este foarte slabă, valoarea erorii standard va crește până când la limită va fi egală cu abaterea medie pătratică, caz în care raportul este egal cu 1

Deoarece raportul are o valoare 0 pentru o legătură perfectă, și 1 pentru absenta oricărei legături, s-a recurs la definirea unei măsuri a cărei valoare să varieze direct proporțional cu gradul de asociere.

Modele corelaționale

Modele corelaționale liniare

Se definește *coeficientul de corelație* ca fiind :

$$r_{yx} = 1 - \frac{S_y^2}{\sigma_y^2} = 1 - \frac{\sum (y - y_c)^2}{\sum (y - \bar{y})^2}$$

$$r_{xy} = 1 - \frac{S_x^2}{\sigma_x^2} = 1 - \frac{\sum (x - x_c)^2}{\sum (x - \bar{x})^2}$$

cei doi coeficienți caracterizează gradul de asociere dintre ***y*** și ***x*** si, respectiv, ***x*** și ***y*** (corectitudinea modelelor corelaţionale $y = a_0 + a_1 x$ și respectiv $x = b_0 + b_1 y$)

Caracteristici :

- ia valori între 0 și 1 ;
- dacă corelația dintre ***x*** și ***y*** este directă, coeficientul de corelație primește semnul '+' și respectiv, semnul '-' dacă corelația dintre x și y este inversă ;
- în practică se consideră semnificative acele modele pentru care coeficientul de corelație are o valoare mai mare de 0.7.



Modele corelaționale

Modele corelaționale liniare - Exemplu

Ne propunem să construim un model pentru un sistem definit de un set de ***n=8*** măsurători de forma $(x_i, y_i)_{i=1,n.}$ Modelul va fi de forma $y = a_0 + a_1 x$

x	y	y_c	$y - y_c$	$(y - y_c)^2$	$y - \bar{y}$	$(y - \bar{y})^2$
1	1	1.18	-0.18	0.324	-4	16
3	2	2.45	-0.45	0.202	-3	9
4	4	3.10	0.90	0.810	-1	1
6	4	4.36	-0.36	0.130	-1	1
8	5	5.63	-0.63	0.397	0	0
9	7	6.27	0.73	0.533	2	4
11	8	7.54	0.46	0.212	3	9
14	9	9.45	-0.45	0.202	4	16

$$\bar{y} = 5$$

$$S_y = 0.6$$

$$\sigma_y = \frac{\sum (y - \bar{y})^2}{N} = \frac{56}{8}$$

$$r_{yx} = 1 - \frac{0.36}{\frac{56}{8}} = 0.99$$

modelul corelaţional este $y = (6/11) + (7/11)x$ având precizia de 0.99



Modele corelaționale

Modele corelaționale

Observații privind analiza corelaţională

Analiza corelaţională reprezintă o tehnică de modelare care ia în considerare măsurători numerice care descriu comportarea globală a sistemului analizat. Tehnica de construiește un model care descrie sistemul luat în considerare indirect prin luarea în considerare a cauzelor care conduc la un efect al funcționării sistemului în cauză

Condițiile care trebuiesc respectate sunt :

- necesară reținerea numai a factorilor cu influenta semnificativă asupra variabilei dependente ;
- se recomandă utilizarea acelor variabile care se exprimă prin unități de măsură relative, deoarece sunt mai puțin supuse deformărilor pe care le incumba unitățile de măsură ;
- numărul de elemente trebuie să fie suficient de mare pentru a se evita obținerea unor modele relaţionale nereprezentative (caracterizate de un coeficient de corelaţie mare, dar incorect).

Modele corelaționale

Modele corelaționale - multiliniare

În cazul în care sistemul este descris de un set ***N*** măsurători unde fiecare măsurătoare este formată din ***M+1*** valori numerice modelul care descrie comportarea sistemului prin luarea în considerare cauzelor ***M*** care conduc la un efect ***y*** este de forma

Cauze | Efect

Date în setul analizat	x_1	x_2	x_3	.....	x_M	Y
1	x_{11}	x_{21}	x_{31}	.....	x_{M1}	Y_1
2	x_{12}	x_{22}	x_{32}	.....	x_{M2}	Y_2
.....	.....	.....	.....	.....	.....	.....
N	x_{1N}	x_{2N}	x_{3N}	.....	x_{MN}	Y_N

MODEL

$$Y = a + b_1 x + b_2 x_2 + \ldots\ldots\ldots\ldots + b_M x_M = \sum_{j=1}^{M} b_j x_j$$

Modele corelaționale

Modele corelaționale - multiliniare

- Pentru modelele multiliniare precizia se defineşte ca fiind coeficientul de corelaţie total. Acesta, definește efectul total al tuturor cauzelor care conduc la obținerea unui cauze Relaţia de definiţie este

$$R_{Y,X_1,X_2,\ldots,X_M} = \frac{\sum_i (Y_i - \overline{Y}) \cdot (\hat{Y}_i - \overline{Y})}{\sqrt{[\sum_i (Y_i - \overline{Y})^2] \cdot [\sum_i (\hat{Y}_i - \overline{Y})^2]}}$$

Unde

$\overline{Y}$ valoarea medie a mărimilor măsurate Y_i

$\hat{Y}_i$ valoarea medie a mărimilor calculate Y_i

- Pentru modelele multiliniare se poat calcula inclusiv importanța unei cauze particulare în producerea efectului total. Legătura dintr cauză și efect poartă denumirea de **indice de corelare parțială**

- Pentru modelele multiliniare se poate calcula cît de puternică este legătura dintre două cauze în contextul modelului construit Legătura dintre două cauze poartă denumirea de **indice de intercorelare**


MULTIMETHOD
MODELING
SYSTEM
DYNAMICS
AGENT BASED
MODELING
DISCRETE EVENT
MODELING

Întrebări???

MODELARE și SIMULARE

Tehnici de Modelare Monte Carlo





Tehnici de Modelare Monte Carlo

Concepte

Bazele teoretice ale metodei au fost puse în anul 1949 de Metropolis şi Ulam[1], dar ideea acestor metode a apărut încă din 1777 când Buffon a formulat celebra problemă a calculului probabilităţii de intersecţie a unui ac aruncat la întâmplare, pe o suprafaţă plană pe care sunt trasate drepte paralele echidistante. Aceasta idee în 1860 ia permis lui Barbier sa calculeze numărul π prin aruncări succesive ale unui ac de lungime l, pe o suprafaţă plană cu drepte paralele la echidistanta $2l$

1. Nicholas Metropolis; S. Ulam, The Monte Carlo Method, Journal of the American Statistical Association, Vol. 44, No. 247. (Sep., 1949), pp. 335-341.



Tehnici de Modelare Monte Carlo

Concepte

Fermi, Metropolis şi Ulam au folosit *metoda experimentărilor statistice*, la studiul difuziei neutronilor în materialele fisionabile. In acest scop au utilizat listele de numere întâmplătoare (rezultate in jocul de ruleta) care se publicau la Monte - Carlo. De aici a rezultat cea mai răspândită denumire a metodei. În SUA, metoda a mai fost cunoscută şi sub denumirea de "*metoda Las Vegas*". În literatura de specialitate se întâlnesc următoarele denumiri echivalente: *metoda încercărilor echivalente; metoda experimentărilor statistice; simularea numerică; metoda simulării indirecte; metoda numerelor aleatoare.*

1. Nicholas Metropolis; S. Ulam, The Monte Carlo Method, Journal of the American Statistical Association, Vol. 44, No. 247. (Sep., 1949), pp. 335-341.



Tehnici de Modelare Monte Carlo

Concepte

Metoda Monte Carlo este o metodă de rezolvare numerică a problemelor matematice, bazată pe modelarea variabilelor aleatoare

Termenul de "Metoda Monte - Carlo" se utilizează pentru a desemna două tehnici diferite.

1. Prima tehnică constă în evaluarea integralelor definite prin utilizarea variabilelor aleatoare.

2. Al doilea sens al "metodei Monte - Carlo" presupune înlocuirea unui fenomen real cu un experiment statistic.

Evaluarea integralelor definite prin tehnica Monte Carlo.

Principiul metodei Monte Carlo (MC) de calcul este ilustrat de calculul valorii numărului ***π*** din figura următoare și constă în următoarele

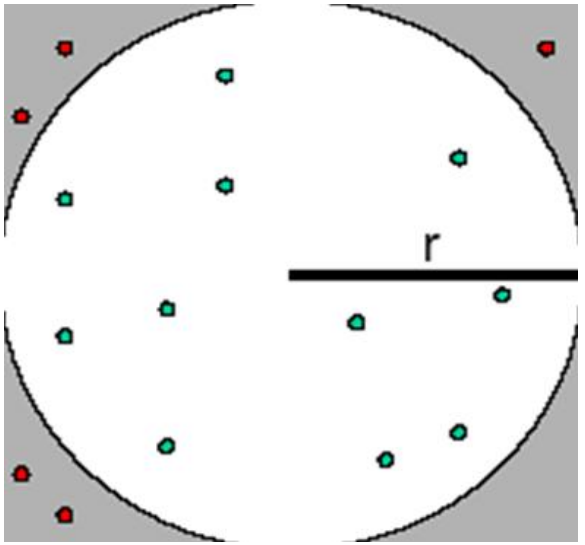
$$\text{aria patratului} = (2r)^2$$

$$\text{aria cercului} = \pi r^2$$

$$\frac{\text{aria patratului}}{\text{aria cercului}} = \frac{4r^2}{\pi r^2} = \frac{4}{\pi}$$

$$\pi = 4 \times \frac{\text{aria cercului}}{\text{aria patratului}} \text{ unde}$$

$$\frac{\text{aria cercului}}{\text{aria patratului}} = \frac{\text{numar de puncte in interiorul cercului}}{\text{numarul total de puncte}}$$





Evaluarea integralelor definite prin tehnica Monte Carlo.

Principiul metodei Monte Carlo (MC)

- Se generează puncte uniform repartizate (x_i, y_i) în spațiul definit de pătratul de dimensiune ***2r x 2r***. Notăm cu ***N*** numărul de puncte generate. Generarea de puncte de coordonate (x_i, y_i) presupune generarea de coordonate x_i respectiv y_i în intervalul [0, 2r] urmând o lege de distribuție uniform repartizată.

- Notăm cu S numărul de puncte care cad în interiorul suprafeței delimitate de cerc. Acest contor se incrementează cu 1 dacă punctul de coordonate (xi, yi) generat îndeplinește condiția.

$$x_i^2 + y_i^2 \leq r^2$$

- După generarea unui număr de N puncte valoarea constantei π va fi dată de relația

$$\pi = 4 * \frac{S}{N}$$

Evaluarea integralelor definite prin tehnica Monte Carlo.

Principiul metodei Monte Carlo (MC)

Prin creșterea numărului de puncte în spațiul definit de pătrat vom obține următoarele valori estimative

N	PI
1000	3.13200000
2000	3.14200000
3000	3.10800000
4000	3.11800000
5000	3.13040000
6000	3.12266667
7000	3.15142857
8000	3.12450000
9000	3.15333333
10000	3.15600000
Valoarea exactă	3.14159265

Estimarea poate fi ui număr de experimente independente (independența fiind realizată prin utilizarea de diferite secvențe de numere aleatoare uniform distribuite) și calculul valorii medii. De exemplu efectuând un număr de 1000 măsurători independente s-a obținut

N = 10000 m = 1000 PI = 3.14140240



Evaluarea integralelor definite prin tehnica Monte Carlo.

Metoda hit-or-miss (sau Rejection).

Obiectivul este acela de a calcula

$$y = \int_a^b f(x)dx \quad \text{unde} \quad a, b \in R$$

În așa numita metodă "***hit-or-miss***" de integrare Monte Carlo, integrala este estimată prin desenarea unei dreptunghi care delimitează funcția *f(x)*

în intervalul [a, b]. Dreptunghiul se extinde de la ***a*** la ***b*** și de la ***0*** la ***fmax***, unde

$$f_{\max} > f(x)$$

în intervalul dat.



Evaluarea integralelor definite prin tehnica Monte Carlo.

Metoda hit-or-miss (sau Rejection).

Se generează *N* puncte aleatoriu în cadrul dreptunghiului. Estimarea integralei poate fi obținută raportând numărul total de puncte N_0 care apar sub curba *f(x)* la N.

Unde este aria dreptunghiului

Fiecare din cele *N* puncte aleatoare se obține prin generarea a generarea a două valori numerice s_1 și s_2 uniform distribuite și calcularea a două coordonate *x*, respectiv *y* de forma

$$I_{est} = \frac{N_0}{N} A$$

$$x = a + s_1 * (b - a)$$

$$y = s_2 * f_{\max}$$

Evaluarea integralelor definite prin tehnica Monte Carlo.

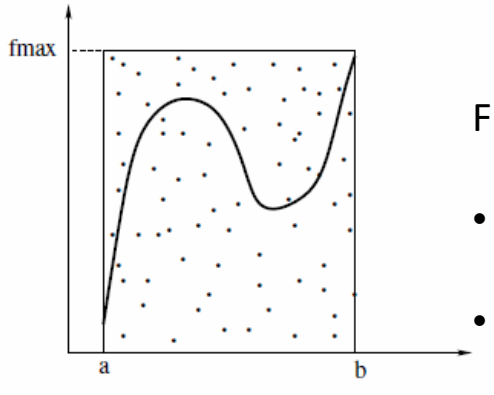
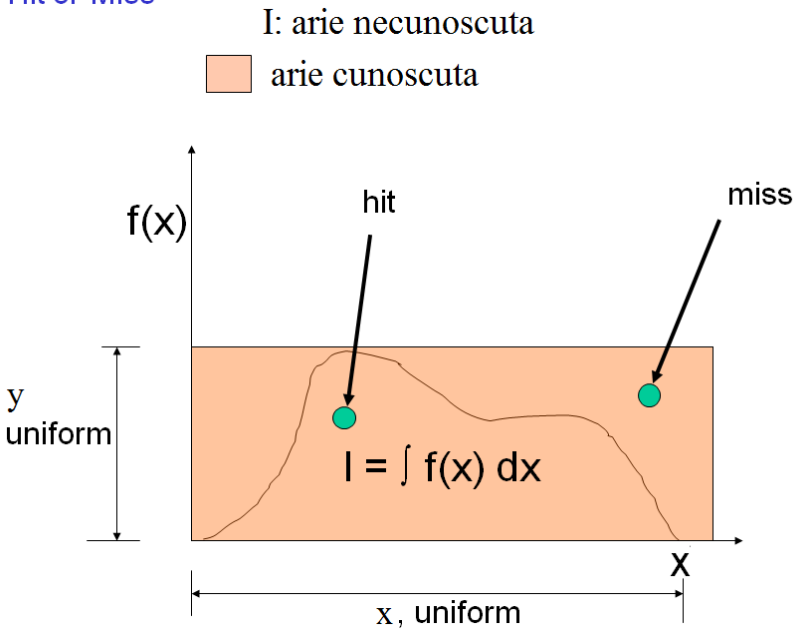


Figura 1. **Metoda hit-or-miss (sau Rejection).**

- Punctele sunt generate aleator în spațiul definit de aria dreptunghiulară care delimitează funcția în intervalul [a, b]
- Numărul de puncte de sub curbă este utilizat pentru calculul integralei.

Hit or Miss





Evaluarea integralelor definite prin tehnica Monte Carlo.

Etapele care se parcurg pentru calculul integralei prin această metodă **hit-or-miss** sunt

1) Se generează puncte uniform repartizate (x_i, y_i) în spațiul definit de dreptunghi de dimensiune *b-a * ymax - ymin*. Notăm cu ***N*** numărul de puncte generate. Generarea de puncte de coordonate (x_i, y_i) presupune generarea de coordonate x_i în intervalul [a, b], respectiv y_i în intervalul [ymin, ymax] urmând o lege de distribuție uniform repartizată.

2) Notăm cu ***S*** numărul de puncte care cad în interiorul suprafeței delimitate de f(x). Acest contor se incrementează cu 1 dacă punctul de coordonate (x_i, y_i) generat îndeplinește condiția

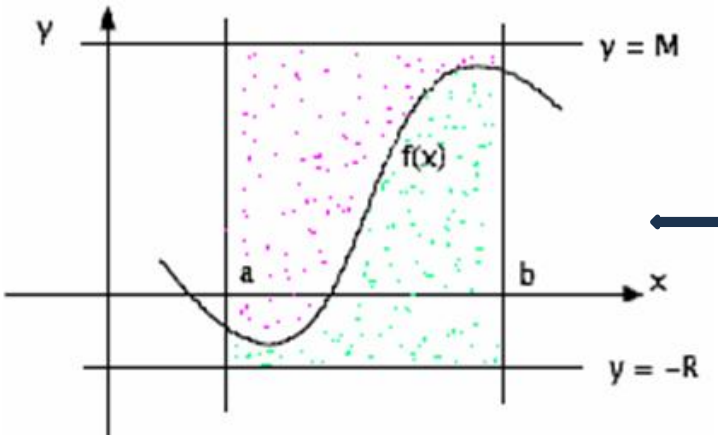
$$y_i \leq f(x_i)$$

3) După generarea unui număr de N puncte valoarea constantei integralei va fi dată de va fi dată de relația

$$I = (y_{\max} - y_{\min}) \cdot (b - a) \cdot \frac{S}{N}$$

Evaluarea integralelor definite prin tehnica Monte Carlo.

Metoda hit-or-miss



$$\frac{S}{N} = \frac{\text{aria de sub curba f(x)}}{\text{aria totala}} = \frac{\int_a^b f(x)dx}{(M+R)(b-a)}$$

$$\int_a^b f(x)dx = (M+R)(b-a)\frac{S}{N}$$

Această relație va trebui corectată deoarece linia ***y=-R*** s-a utilizat ca linie de bază pentru calculul suprafeței în loc de linia ***y=0*** ca în cazul anterior. Pentru aceasta se va scădea aria ***R(b-a)*** din valoarea obținută. Se va obține în final

$$\int_a^b f(x)dx = (M+R)(b-a)\frac{S}{N} - R(b-a)$$



Evaluarea integralelor definite prin tehnica Monte Carlo.

Metoda ***Monte Carlo hit-or-miss***, poate fi extinsă pentru calculul unei integrale multiple. De exemplu dacă considerăm o integrală de forma

$$I = \int_{a_1}^{a_2} \int_{b_1}^{b_2} \int_{c_1}^{c2} f(x,y,z)dxdydz$$

Care definește un volum într-un spațiu cu 3 dimensiuni. O valoare estimativă se va putea calcula de forma

Unde

$$I = \int_{a_1}^{a_2} \int_{b_1}^{ab} \int_{c_1}^{c2} f(x,y,z)dxdydz$$

$$= \int_{a_1}^{a_2} \left[\int_{b_1}^{b_2} \left(\int_{c_1}^{c_2} f(x,y,z)\,dx \right) dy \right] dz$$

$$\approx (a_2 - a_1)(b_2 - b_1)(c_2 - c_1)\frac{N_0}{N}$$

(x_i, y_i, z_i) este un punct aleator în spațiul tri dimensional definit de paralelipipedul

$$(a_2 - a_1) \times (b_2 - b_1) \times (c_2 - c_1)$$

În total vom avea nevoie de ***3N*** numere aleatoare pentru a genera ***N*** puncte aleatoare. ***N_0*** se obține incrementând cu 1 acest contor dacă condiția este îndeplinită

$$f(x_i, y_i, z_i) < 0$$

Evaluarea integralelor definite prin tehnica Monte Carlo.

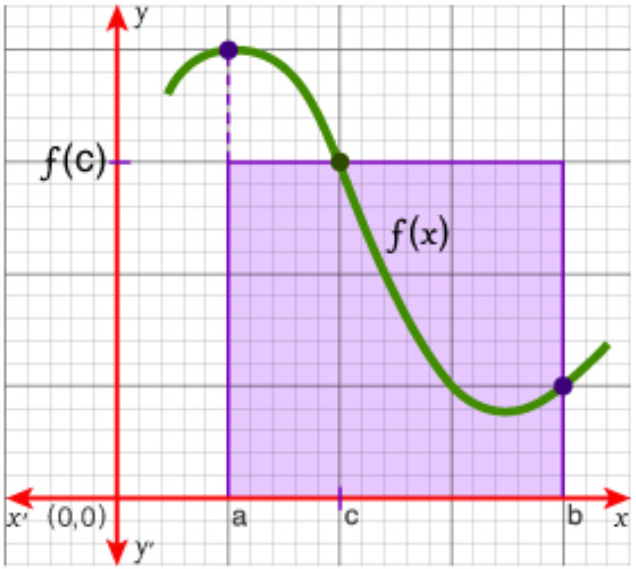
Metoda sample-mean.

Teorema valorii medii pentru integrale

Dacă o functie ***f(x)*** este continuă pe un interval închis ***[a.b]*** există un punct ***c*** pe ***[a,b]*** astfel încât

$$f_{avg} = f(c) = \frac{1}{b-a}\int_a^b f(x)dx$$

$$\int_a^b f(x)dx = f(c)(b-a)$$



In grafic partea dreptunghiulară umbrită este valoarea medie a funcției ***f(x)***



Evaluarea integralelor definite prin tehnica Monte Carlo.

Metoda sample-mean.

1) Aceasta presupune obținerea unui eșantion ***N*** de valori ***x*** uniform distribuite din intervalul [a, b].
2) Aceste valori sunt utilizate pentru obținerea unei valori **est**imative pentru integrală de forma

$$I_{est} = (b-a)\underbrace{\frac{1}{N}\sum_{i=1}^{N} f(x_i)}_{f(c)}$$

Și în acest caz estimarea este cu atât mai bună cu cât eșantionul de numere aleatoare x_i este mai mare. Această estimare va converge la rezultatul corect atunci când

$$N \to \infty$$

Evaluarea integralelor definite prin tehnica Monte Carlo.

Exemplu

Se cere determinarea punctului 'c' care satisface teorema valorii medii pentru integrala functiei

$f(x) = 12x - 8$ pe intervalul [2,6]

$$\int_a^b f(x)dx = f(c)(b-a)$$

Avem

$$\Rightarrow \int_2^6 (12x-8)dx = (12c-8)(6-2)$$

$$\Rightarrow 12\int_2^6 xdx - 8\int_2^6 dx = 48c - 32$$

$$\Rightarrow 12\left[\frac{6^2}{2} - \frac{2^2}{2}\right] - 8[6-2] = 48c - 32$$

$$\Rightarrow 6\times 32 - 8\times 4 = 48c - 32$$

$$\Rightarrow 48c = 192$$

$$\Rightarrow c = 4 \in [2,6]$$

In consecinta solutia este c=4.

Evaluarea integralelor definite prin tehnica Monte Carlo.

Metoda MC "***sample-mean***", poate fi extinsă pentru calculul unei integrale multiple. De exemplu dacă considerăm o integrală de forma

$$I = \int_{a_1}^{a_2} \int_{b_1}^{b_2} \int_{c_1}^{c2} f(x, y, z) dxdydz$$

Care definește un volum într-un spațiu cu 3 dimensiuni o valoare estimativă se va putea calcula de forma

$$I = \int_{a_1}^{a_2} \int_{b_1}^{b_2} \int_{c_1}^{c2} f(x, y, z) dxdydz$$

$$= \int_{a_1}^{a_2} \left[\int_{b_1}^{b_2} \left(\int_{c_1}^{c_2} f(x, y, z)\, dx \right) dy \right] dz$$

$$\approx (a_2 - a_1)(b_2 - b_1)(c_2 - c_1) \frac{1}{N} \sum_{i=1}^{N} f(x_i, y_i, z_i)$$

Unde (x_i, y_i, z_i) este un punct aleator în spațiul tri dimensional definit de paralelipipedul

$$(a_2 - a_1) \times (b_2 - b_1) \times (c_2 - c_1)$$

În total vom avea nevoie de *3N* numere aleatoare pentru a genera N puncte aleatoare

Evaluarea integralelor definite prin tehnica Monte Carlo.

Calculul volumelor.

Tehnica MC dă posibilitatea calculului unor regiuni complicate dintr-un spațiu tri dimensional. Pentru a ilustra tehnica MC considerăm volumul unei regiuni a cărei puncte satisfac condiția

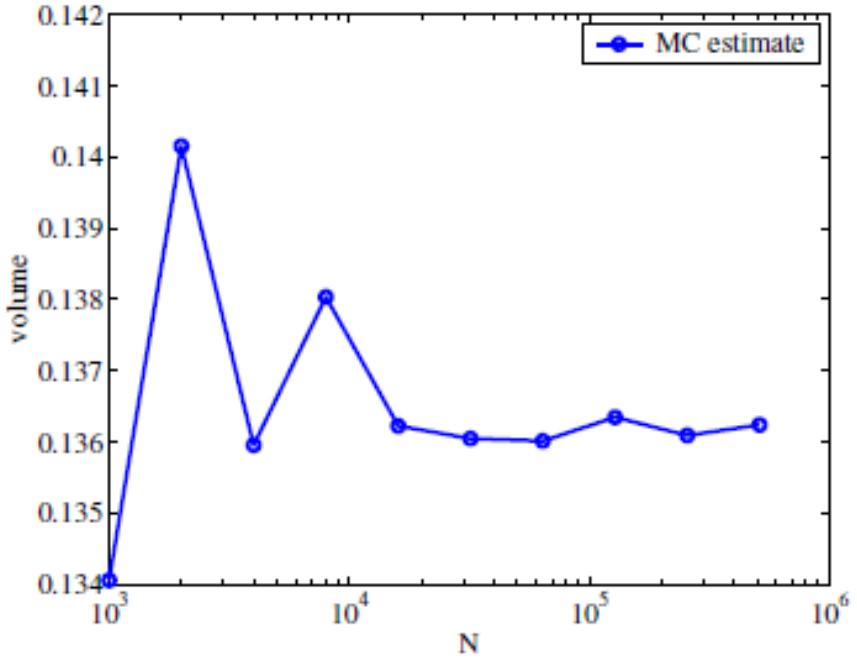
$$\begin{cases} 0 \le x \le 1 \;\; 0 \le y \le 1 \;\; 0 \le z \le 1 \\ x^2 + \sin y \le z \\ x - z + e^y \le 1 \end{cases}$$

Prima linie definește un cub de volum 1. Cele două inegalități definesc un volum care este un subset al cubului. În acest caz se poate aplica metoda "**hit-or-miss**" prin generarea de N puncte în interiorul cubului și determinarea punctelor care definesc cele două inegalități (N_0). În acest caz estimarea volumului cerut este dată de

$$\frac{N_0}{N}$$

Evaluarea integralelor definite prin tehnica Monte Carlo.

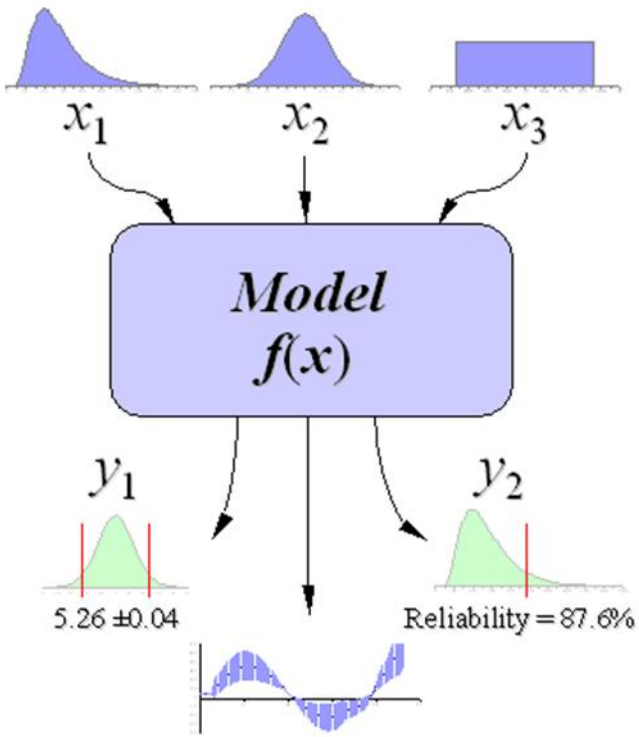
În figură se prezintă valoarea acestui volum în 20 de calcule, în care s-au utilizat valori diferite pentru ***N.***



Înlocuirea unui fenomen real cu un experiment statistic

În cadrul acestei tehnici analiza fenomenului real se înlocuieşte cu analiza unui fenomen artificial, descris de un model parametric de forma

$$y = f\left(x_1, x_2, x_3, ..., x_q\right)$$



În contextul acestei metode

1. intrările sunt aleatoriu generate din distribuții de probabilitate rezultate din analiza sistemului real.
2. Datele generate din simulare vor fi reprezentate de distribuții de probabilitate sau histograme

➢ Metoda asociază problemei reale un model aleator şi prin generarea unor variabile aleatoare legate funcţional de soluţie, se realizează experienţe pe model şi se furnizează informaţii asupra soluţiei problemei deterministe.



Înlocuirea unui fenomen real cu un experiment statistic

Pașii care se parcurg

Pas 1: Se creează un model parametric, $y = f(x_1, x_2, ..., x_q)$.

Pas 2: Se generează un set de intrări, $x_{i1}, x_{i2}, ..., x_{iq}$.

Pas 3: Se evaluează modelul și se memorează valorile pentru y_i.

Pas 4: Repetă pașii 2 și 3 pentru $i = 1$ to n.

Pas 5: Se analizează rezultatele utilizând histograme, statistici, interval de încredere, etc.

Pentru a ilustra modul în care se utilizează această tehnică vom considera următoarele exemple.

- Exemplu 1 -

În tabelul următor sunt prezente vânzările de calculatoare PC ale unei firme de profil în ultimele 30 de săptămâni.

Număr curent i	Calculatoare vândute pe săptămână x_i	Număr de Săptămâni f_i
1	0	6
2	1	12
3	2	6
4	3	3
5	4	3

Număr curent i	Calculatoare vândute pe săptămână x_i	Probabilitatea cererii $P(x_i)$
1	0	0.20
2	1	0.40
3	2	0.20
4	3	0.10
5	4	0.10

Pentru a simula cererea săptămânală de calculatoare se va determina distribuţia de probabilitate a cererii săptămânale utilizând frecvenţa relativă a cererii în cele 30 săptămâni, adică

$$P(x_i) = \frac{f_i}{30}$$

- Exemplu 1 - Pasul 1.

Calculatoare vândute pe săptămână	Probabilitatea cererii $P(x_i)$	Funcția Distribuției cumulative $F(x_i) = P(X \leq x_i)$
0	0.20	0.20
1	0.40	0.60
2	0.20	00.80
3	0.20	0.90
4	0.20	1

În Tabel sunt prezentate valorile funcţiei distribuţiei cumulative *F(x)* pentru vânzările săptămânale e calculatoare PC determinate pe badza distribuţiei discrete.

Aceasta definește **modelul parametric** al fenomenului studiat.

valoarea medie $\mu = 0 \times 0.2 + 1 \times 0.4 + 2 \times 0.2 + 3 \times 0.1 + 4 \times 0.1$

$\mu = 1.5$ calculatoare

dispersia $\sigma^2 = 0 \times 0.2 + 1 \times 0.4 + 2^2 \times 0.2 + 3^2 \times 0.1 + 4^2 \times 0.1 - 1.5^2$

$\sigma^2 = 1.45$ calculatoare

abaterea standard $\sigma = 1.204$ calculatoare

- Exemplu 1 - Pasul 2.

Tabelul conţine valorile numerice pentru cazul vânzărilor săptămânale de calculatoare

MODEL PARAMETRIC

Valoarea variabilei probabiliste x_i	Probabilitatea $P(X=x_i)=P(x_i)$	Funcţia distribuţiei cumulative $F(x_i)$	Intervale $[F(x_{i-1}), F(x_i))$
$x_1 = 0$	0,2	0,2	[0 0.2)
$x_2 = 1$	0,4	0,6	[0.2 0.6)
$x_3 = 2$	0,2	0,8	[0.6 0.8)
$x_4 = 3$	0,1	0,9	[0.8 0.9)
$x_5 = 4$	0,1	1,0	[0.9 1.0)

- Exemplu 1 - Pasul 3.

Se generează un număr de 10 numere aleatoare uniform distribuite în intervalul [0, 1] care au drept corespondent cele 10 săptămâni pentru care se dorește obținerea evoluției probabile a vânzărilor. Evoluția este prezentată în tabelul următor

Nr. aleator	Valoarea x_i a variabilei probabiliste	Număr calculatoare (bucăţi/săptămână)
0,486281	x2	1
0,928927	x5	4
0,205136	x2	1
0,852845	x4	3
0,005645	x1	0
0,651622	x3	2
0,799931	x3	2
0,333693	x2	1
0,416841	x2	1
0,011913	x1	0

Media determinată pe baza selecţiei simulate = 1,5 calculatoare pe săptămână, iar abaterea standard = 1,269 calculatoare.

- Exemplu 2 - Pasul 1.

Numărul de produse vândute zilnic în cadrul unui magazin este dat de o variabilă probabilistă discretă uniform repartizată în intervalul [6, 10]. Se cere simularea vânzărilor pentru 10 zile. În Tabel sunt prezentate probabilităţile $P(x_i)$ $F(x_i) = P(X \leq x_i)$ şi intervalele de numere aleatoare asociate fiecărei valori in intervalul [6, 10] (interval [a, b]).

Acestea definesc **modelul parametric.**

Numărul de produse vândute zilnic x_i	Probabilitatea $P(X = x_i) = \frac{1}{5}$	Funcția distribuției cumulative $F(x_i) = P(X \leq x_i) = \frac{1}{5}$	Intervale $[F(x_{i-1}), F(x_i))$
6	0.2	0.2	[0 0.2)
7	0.2	0.4	[0.2 0.4)
8	0.2	0.6	[0.4 0.6)
9	0.2	0.8	[0.6 0.8)
10	0.2	1.0	[0.8 1.0)

- Exemplu 2 - Pasul 2.

În Tabel sunt simulate vânzările din 10 zile.

Ziua	Număr aleatoru	Numărul de produse
1	0,709084	9
2	0,149934	6
3	0,294974	7
4	0,200192	7
5	0,189083	6
6	0,900415	10
7	0,940097	10
8	0,291185	7
9	0,002452	6
10	0,469177	8

Observaţie:

În cazul variabilelor cu distribuţie uniformă discretă în intervalul [a, b], se poate genera direct o anumită valoare x_i (numar produse)cu ajutorul relaţiei:

x_i = *partea întreagă din [a + (b-a+1)u]*

De exemplu, dacă s-a generat u = 0,709084, (numar uniform repartizat in intervalul 0-1) atunci pentru variabila probabilistă cu distribuţie uniformă discretă în intervalul [6, 10], numărul de produse vândute într-o zi oarecare este:

x_i = *partea întreagă din [6 + (10-6+1)* 0,709084] = 9* produse



- Exemplu 3 – Determinarea riscului în management prin modelare și simulare Monte Carlo

Definiții

- **Riscul** este un concept care exprimă probabilitatea unor întâmplări negative și impactul acestora (International Organization for Standardization – ISO). Conform definiției, riscul este efectul (pozitiv sau negativ) al incertitudinii asupra obiectivelor

- Posibilitatea de pierdere, daune, sau alte circumstanțe neprielnice sau negative;
  Riscul este o șansă sau situație care implică o astfel de posibilitate
  (Oxford English Dictionary).

Presupunem că trebuie să conducem un proiect care implică crearea unui produs eLearning. Pentru creearea acestui produs sunt necesare realizarea unui număr de trei taskuri (activități) scrierea conținutului, crearea interfeței grafice și integrarea de elemente multimedia.

- Exemplu 3 –

Determinarea riscului în management prin modelare și simulare Monte Carlo

Presupunem că trebuie să conducem un proiect care implică crearea unui produs eLearning. Pentru creearea acestui produs sunt necesare realizarea unui număr de trei taskuri (activități) scrierea conținutului, crearea interfeței grafice și integrarea de elemente multimedia

În baza unei experințe anterioare sau din aprecierea dificultății de realizare se determină durata acestor activități – cel mai bun caz, cel mai probabil caz respectiv cel mai rău scenariu de terminare pentru fiecare din cele trei activități.

Activități	Cea mai bună estimare de terminare	Cea mai probabilă estimare de terminare	Cea mai pesimistă estimare de terminare
scrierea conținutului	4 zile	6 zile	8 zile
crearea interfeței grafice	5 zile	7 zile	9 zile
integrarea de elemente multimedia	2 zile	4 zile	6 zile
Durata realizării produsului	11 zile	17 zile	23 zile

MODEL PARAMETRIC

- Exemplu 3 –
Determinarea riscului în management prin modelare și simulare Monte Carlo

Simularea Monte Carlo presupune generarea aleatorie de valori pentru diferirele taskuri prezente în crearea produsului cu scopul obținerii de posibile durate de derulare a acestuia.

Durata totală a proiectului [zile]	De câte ori s-a generat această durată	Procentul variantei de durată care apare în cele 500 simulări
11	5	1%
12	20	4%
13	75	15%
14	90	18%
15	125	25%
16	140	28%
17	155	33%
18	275	55%
19	440	88%
20	475	95%
21	490	98%
22	495	99%
23	500	100%

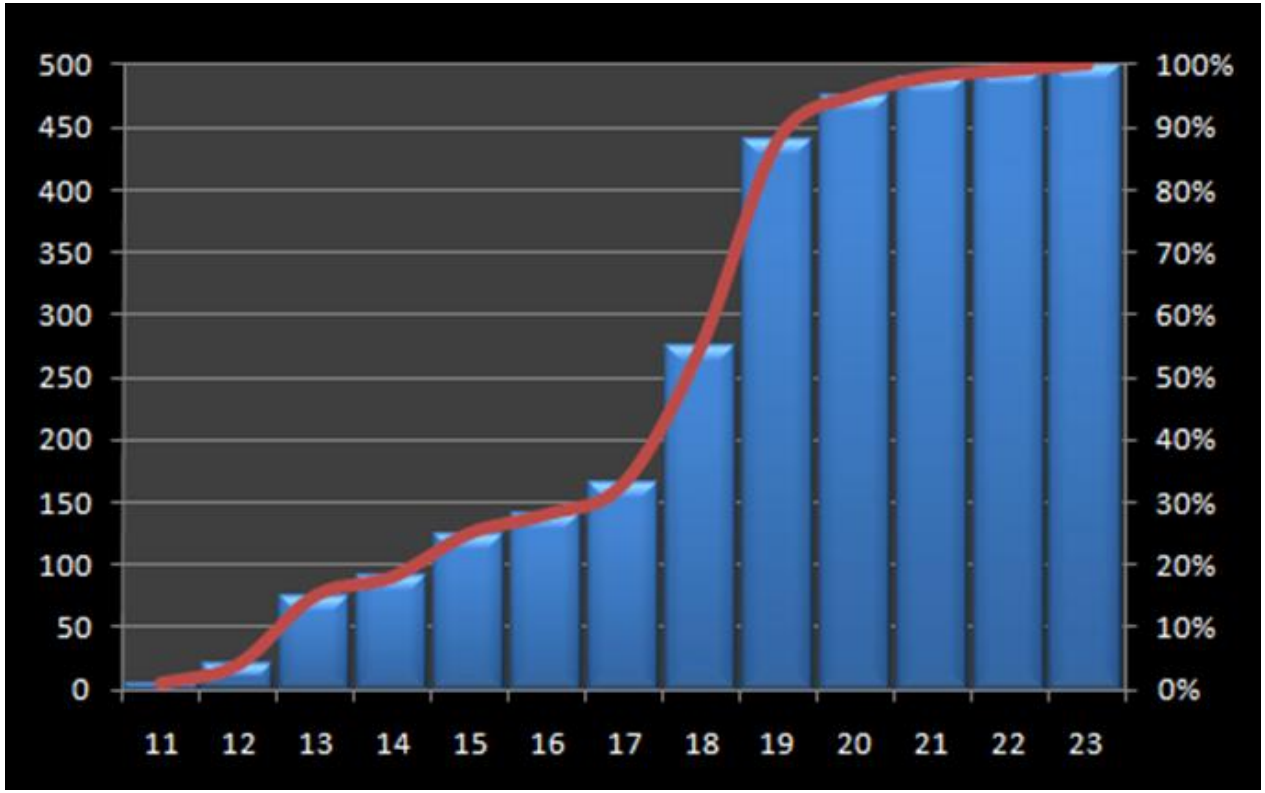
Pentru cazul concret dat vom genera variante de durate pentru cele trei taskuri implicate generând valori uniform distribuite de durate de execuție în intervalul

- [4 zile, 8 zile] pentru taskul 1,
- [5 zile, 9 zile] pentru taskul 2
- [2 zile, 6 zile] pentru taskul 3.

Efectuăm această generare de variante de posibile durate de execuție a produsului de 500 ori. În tabel sunt prezentate rezultatele obținute pentru durata proiectului, luând în considerare suma duratelor celor 3 taskuri de realizat.

- Exemplu 3 –
Determinarea riscului în management prin modelare și simulare Monte Carlo

Grafic, informțiile din acest tabel apar în următoarea formă



Din grafic se observă că șansa de a termina proiectul în 17 zile este mai mică de 33%. În baza acestei analize proiectul se va termina în 19 – 20 zile.



Determinarea riscului în management prin modelare și simulare Monte Carlo
Analiza Risk Monte Carlo

Pași

1. Se identifică variabilele de risk ale proiectului
2. Se determină plaja de valori în care apar aceste variabile
3. Se identifică relațiile care apar între aceste variabile
4. Se realizează simularea ținând cont de cele două restricții anterioare (intervale de valori și legaturi între variabile)
5. Se analizează statistic rezultatele obținute


MULTIMETHOD
MODELING
SYSTEM
DYNAMICS
AGENT BASED
MODELING
DISCRETE EVENT
MODELING

Întrebări???


MULTIMETHOD
MODELING
SYSTEM
DYNAMICS
AGENT BASED
MODELING
DISCRETE EVENT
MODELING


MULTIMETHOD
MODELING
SYSTEM
DYNAMICS
AGENT BASED
MODELING
DISCRETE EVENT
MODELING