1. Linear Regression

1

Identificați în formularea de mai jos rolul fiecărui termen, bazându-vă pe Ecuația (1):

$$\text{Preț Prezis} = 50.000 + 150 \times (\text{Suprafață}) - 10.000 \times (\text{Vechime})$$

1. Care este valoarea bias-ului (w_0)?
2. Câte caracteristici (d) are modelul?
3. Care este ponderea asociată cu caracteristica "Suprafață"?
4. Dacă toate caracteristicile ar fi zero, care ar fi prețul prezis?

Rezolvare 1:

1. Bias-ul (w_0) este **50.000**.
2. Modelul are **două** caracteristici ($d = 2$): Suprafața și Vechimea.
3. Ponderea (w_1) asociată cu Suprafața este **150**.
4. Prețul prezis ar fi egal cu bias-ul, adică **50.000**.

2.

Folosind modelul de la Exercițiul 1:

$$\hat{y} = 50.000 + 150 \cdot x_{\text{suprafață}} - 10.000 \cdot x_{\text{vechime}}$$

Calculați prețul prezis ($\hat{y}$) pentru o casă cu următoarele caracteristici:

- Suprafață ($x_{\text{suprafață}}$) = 120 mp
- Vechime (x_{vechime}) = 5 ani

Rezolvare 2:

Se substituie valorile în ecuație:

$$\hat{y} = 50.000 + 150 \times 120 - 10.000 \times 5$$

1. $150 \times 120 = 18.000$
2. $10.000 \times 5 = 50.000$

$$\hat{y} = 50.000 + 18.000 - 50.000$$

$$\hat{y} = 18.000$$

Prețul prezis este **18.000** (Unitatea de măsură nu este specificată în surse, dar logic ar fi USD/EUR/unități monetare).

(3)

real output
input

Assume we have a dataset $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), (x^{(3)}, y^{(3)})\} = \{(1,2), (2,4), (3,5)\}$ of points in the 2D plane, and we want to estimate the following linear regression model:

$$\hat{y} = w_1 x + w_0.$$

Compute w_0, w_1 and $\hat{y}^{(1)}$, $\hat{y}^{(2)}$, $\hat{y}^{(3)}$.

Formule:

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_d^{(1)} \\ 1 & x_1^{(2)} & \dots & x_d^{(2)} \\ \vdots & & & \\ 1 & x_1^{(m)} & \dots & x_d^{(m)} \end{bmatrix} = \begin{bmatrix} x^{(1)T} \\ x^{(2)T} \\ \vdots \\ x^{(m)T} \end{bmatrix} \in \mathbb{R}^{m \times (d+1)}$$

1's dummy

$$Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix} \in \mathbb{R}^{m \times 1}$$

$$w^* = (X^T X)^{-1} X^T Y \in \mathbb{R}^{(d+1) \times 1}$$

$$\hat{Y} = \begin{bmatrix} \hat{y}^{(1)} \\ \hat{y}^{(2)} \\ \vdots \\ \hat{y}^{(m)} \end{bmatrix} \in \mathbb{R}^{m \times 1}$$

$$\hat{Y} = X w \in \mathbb{R}^{m \times 1}$$

Rezolvare

$m = 3$ (nr. de exemple)

$d = 1$ (nr. de features)

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \in \mathbb{R}^{3 \times 2} \qquad Y = \begin{bmatrix} 2 \\ 4 \\ 5 \end{bmatrix} \in \mathbb{R}^{3 \times 1}$$

$$X^T \cdot X = \underbrace{\begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix}}_{\in \mathbb{R}^{2 \times 3}} \underbrace{\begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}}_{\in \mathbb{R}^{3 \times 2}} = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix} \longrightarrow \in \mathbb{R}^{2 \times 2}$$

$$(X^T X)^{-1} = A^{-1} = \frac{1}{\det A} A^*$$

$\det A = 3 \cdot 14 - 6 \cdot 6 = 42 - 36 = 6 > 0$

$$A^T = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}$$

$a_{11} = (-1)^{1+1} |14| = 14$ $\quad$ $a_{21} = (-1)^{2+1} |6| = -6$

$a_{12} = (-1)^{1+2} |6| = -6$ $\quad$ $a_{22} = (-1)^{2+2} |3| = 3$

$$A^* = \begin{pmatrix} 14 & -6 \\ -6 & 3 \end{pmatrix}$$

$$\Rightarrow (X^T X)^{-1} = \frac{1}{6} \begin{pmatrix} 14 & -6 \\ -6 & 3 \end{pmatrix}$$

$$w^* = (X^T \cdot X)^{-1} X^T y =$$

$$= \frac{1}{6} \begin{pmatrix} 14 & -6 \\ -6 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 2 \\ 4 \\ 5 \end{pmatrix} =$$

$$= \frac{1}{6} \begin{pmatrix} 8 & 2 & -4 \\ -3 & 0 & 3 \end{pmatrix} \begin{pmatrix} 2 \\ 4 \\ 5 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 4 \\ 9 \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ \frac{3}{2} \end{pmatrix} \in \mathbb{R}^{2 \times 1}$$

$\frac{2}{3} \rightarrow w_0$, $\frac{3}{2} \rightarrow w_1$

$$\hat{y} = X w^* = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} \frac{2}{3} \\ \frac{3}{2} \end{pmatrix} = \begin{pmatrix} \frac{13}{6} \\ \frac{22}{6} \\ \frac{31}{6} \end{pmatrix} \in \mathbb{R}^{3 \times 1}$$

$\frac{13}{6} \rightarrow \hat{y}^{(1)}$, $\frac{22}{6} \rightarrow \hat{y}^{(2)}$, $\frac{31}{6} \rightarrow \hat{y}^{(3)}$

4.

Time left 2:59:43

Assume we have a dataset $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \ldots, (x^{(n)}, y^{(n)})\}$ of points in the 2D plane, and we want to estimate the following linear regression model:

$\hat{y} = w_1 x + w_0$.

Compute w_0, w_1 in terms of $x^{(1)}, y^{(1)}, x^{(2)}, y^{(2)}, \ldots, x^{(n)}, y^{(n)}$. Numerical application: $(1, 1), (2, -1), (3, 2)$.

la fel ca sus

5. Enunț

$x^{(1)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ $x^{(2)} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$ $x^{(3)} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$y^{(1)} = 1$ $y^{(2)} = 2$ $y^{(3)} = 3$

Cerință: $w_0, w_1, w_2, \hat{y}, \mathcal{L}(w)$

Rezolvare:

$n = 3$ exemple $d = 2$ features

$$X = \begin{pmatrix} 1 & 1 & 0 \\ 1 & -1 & 1 \\ 1 & 0 & 1 \end{pmatrix} \qquad Y = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

$$X^T \cdot X = \begin{pmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 1 & -1 & 1 \\ 1 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 3 & 0 & 2 \\ 0 & 2 & -1 \\ 2 & -1 & 2 \end{pmatrix}$$

$\det A = 12 - 8 - 3 = 1$

$$A^T = \begin{pmatrix} 3 & 0 & 2 \\ 0 & 2 & -1 \\ 2 & -1 & 2 \end{pmatrix} \qquad A^* = \begin{pmatrix} 3 & -2 & -4 \\ -2 & 2 & 3 \\ -4 & 3 & 6 \end{pmatrix}$$

$a_{11} = (-1)^2 \begin{vmatrix} 2 & -1 \\ -1 & 2 \end{vmatrix} = 4 - 1 = 3$ etc

$A^{-1} = A^*$

$$w^* = A^{-1} \begin{pmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \\ 0 & 1 & 1 \end{pmatrix} \quad \begin{matrix} X^T \\ \end{matrix} \qquad \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \quad Y = \begin{pmatrix} 0 \\ 1 \\ 3 \end{pmatrix} \begin{matrix} w_0 \\ w_1 \\ w_2 \end{matrix}$$

$\hat{y} = 0 + 1 \cdot x_1 + 3 x_2$

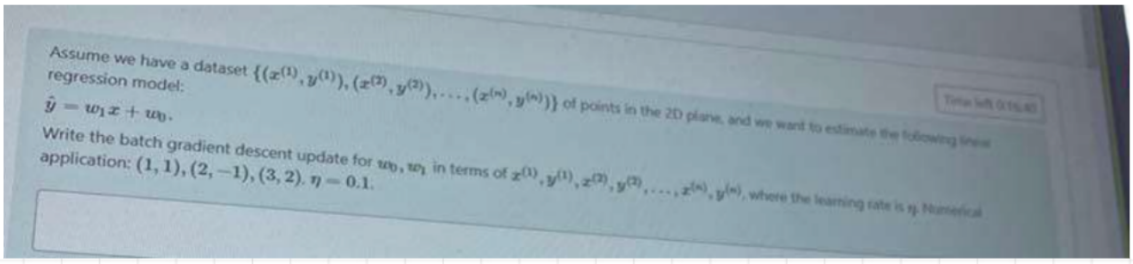
$$\hat{y} = X w^* = \begin{pmatrix} 1 & 1 & 0 \\ 1 & -1 & 1 \\ 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \\ 3 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \qquad \hat{y} = y$$

$\Rightarrow$ nu ar trb să existe loss

$$\mathcal{L}(w) = \frac{1}{2m}(\underbrace{Xw - y}_{\downarrow})^T (Xw - y) = \frac{1}{2m}(\hat{y} - y)^T (\hat{y} - y) =$$

$$= \frac{1}{2m} \cdot (0 \quad 0 \quad 0) \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} = \frac{1}{6} \cdot 0 = 0 \quad \checkmark$$

11. Gradient descent



Assume we have a dataset $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \ldots, (x^{(n)}, y^{(n)})\}$ of points in the 2D plane, and we want to estimate the following linear regression model:

$\hat{y} = w_1 x + w_0$.

Write the batch gradient descent update for w_0, w_1 in terms of $x^{(1)}, y^{(1)}, x^{(2)}, y^{(2)}, \ldots, x^{(n)}, y^{(n)}$, where the learning rate is η. Numerical application: $(1,1), (2,-1), (3,2)$. $\eta = 0.1$.

$$\nabla_w \mathcal{L}(w) = \frac{1}{n} X^T (Xw - y)$$

$n = 3 \quad d = 1$

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \qquad y = \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}$$

$$X^T = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix}$$

$$w \leftarrow w - \eta \nabla_w \mathcal{L}(w)$$

$$\begin{pmatrix} w_0 \\ w_1 \end{pmatrix} \leftarrow \begin{pmatrix} w_0 \\ w_1 \end{pmatrix} - \frac{0,1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \left[\begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \end{pmatrix} - \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix} \right]$$

$$\leftarrow \begin{pmatrix} w_0 \\ w_1 \end{pmatrix} - \frac{0,1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} w_0 + w_1 - 1 \\ w_0 + 2w_1 + 1 \\ w_0 + 3w_1 - 2 \end{pmatrix}$$

$$\leftarrow \begin{pmatrix} w_0 \\ w_1 \end{pmatrix} - \frac{0,1}{3} \begin{pmatrix} 3w_0 + 6w_1 - 2 \\ 6w_0 + 14w_1 - 5 \end{pmatrix}$$

$$w_0 \leftarrow 0,9 w_0 - 0,2 w_1 + \frac{0,2}{3}$$

$$w_1 \leftarrow w_1 - 0,2 w_0 - \frac{1,4}{3} w_1 + \frac{0,5}{3}$$

2. Enunț

$x^{(1)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ $x^{(2)} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$ $x^{(3)} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ $n = 3$, $d = 2$

$y^{(1)} = 1$ $y^{(2)} = 2$ $y^{(3)} = 3$

$w^0 = \begin{pmatrix} 1 \\ -1 \\ 3 \end{pmatrix}$, $\eta = 0,1$ (valoare aleatorie)

$X = \begin{pmatrix} 1 & 1 & 0 \\ 1 & -1 & 1 \\ 1 & 0 & 1 \end{pmatrix}$ $Y = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$

$w^1 \leftarrow w^0 - \eta \nabla_w \mathcal{L}(w^0)$

$\nabla_w \mathcal{L}(w^0) = \frac{1}{n} X^T (Xw - Y) =$

$= \frac{1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \\ 0 & 1 & 1 \end{pmatrix} \left[\begin{pmatrix} 1 & 1 & 0 \\ 1 & -1 & 1 \\ 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 3 \end{pmatrix} - \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \right] =$

$= \frac{1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \\ 0 & 1 & 1 \end{pmatrix} \left[\begin{pmatrix} 0 \\ 4 \\ 3 \end{pmatrix} - \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \right] = \frac{1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ 2 \\ 0 \end{pmatrix} =$

$= \frac{1}{3} \begin{pmatrix} 1 \\ -3 \\ 2 \end{pmatrix}$

$$w_1 \leftarrow \begin{pmatrix} 1 \\ -1 \\ 3 \end{pmatrix} - \frac{0,1}{3} \begin{pmatrix} 1 \\ -3 \\ 2 \end{pmatrix} = \begin{pmatrix} 29/30 \\ -9/30 \\ 58/30 \end{pmatrix}$$

III. Polynomial regression

Exercițiul 1: Expansiunea Polinomială a Caracteristicilor

Presupunem că avem un set de date cu două caracteristici, a și b, și dorim să aplicăm Regresia Polinomială de **gradul** $M = 2$.

1. Enumerați toate noile caracteristici care trebuie incluse în vectorul transformat $\phi(\mathbf{x})$, inclusiv termenul de bias ($x_0 = 1$).
2. Dacă un model de regresie liniară simplă cu a și b folosea 3 parametri ($\mathbf{w} \in \mathbb{R}^3$), câți parametri va folosi modelul de Regresie Polinomială de grad 2?

Rezolvare 1:

Pasul 1: Listarea caracteristicilor pentru gradul $M = 2$

Regula impune includerea tuturor puterilor și combinațiilor până la gradul 2.

- **Grad 0 (Bias):** 1
- **Grad 1:** a, b

- **Grad 2 (Puteri):** a^2, b^2
- **Grad 2 (Combinații):** ab

Vectorul de caracteristici transformat (pentru $\mathbf{x} = [a, b]$) este:

$$\phi(\mathbf{x}) = [1 \; a \; b \; a^2 \; b^2 \; ab]$$

Pasul 2: Determinarea numărului de parametri

Numărul de parametri M este egal cu numărul de componente din vectorul $\phi(\mathbf{x})$. Modelul de Regresie Polinomială de grad 2 va folosi **6 parametri** (ponderi w_i), corespunzători fiecărei componente din vectorul $\phi(\mathbf{x})$.

Exercițiul 2: Evaluarea Overfitting-ului

Aveți un set de date de antrenare cu $n = 100$ exemple. V-ați antrenat trei modele de regresie polinomială:

Model	Grad Polinomial (M)	RMSE pe Date de Antrenare	RMSE pe Date de Testare
A	1	4.5	4.4
B	10	1.1	1.3
C	99	0.05	15.0

1. Care model suferă cel mai mult de **underfitting** (Bias ridicat)? Explicați de ce.
2. Care model suferă cel mai mult de **overfitting** (Varianță ridicată)? Explicați de ce.
3. Care model oferă cea mai bună **generalizare**?

Rezolvare 2:

1. **Underfitting (Model A):** Modelul A are cel mai mare RMSE pe ambele seturi (4.5 și 4.4). Acest lucru indică faptul că modelul (o simplă linie dreaptă) nu a fost suficient de complex pentru a se potrivi măcar datelor de antrenare, sugerând un **Bias ridicat**.
2. **Overfitting (Model C):** Modelul C ($M = 99$) se potrivește aproape perfect datelor de antrenare (RMSE=0.05), trecând practic prin fiecare punct. Cu toate acestea, performanța pe setul de testare este dezastruoasă (RMSE=15.0). Această diferență uriașă indică faptul că modelul a învățat zgomotul din datele de antrenare și are o **Varianță ridicată**, fiind cel mai supra-antrenat.
3. **Cea mai bună Generalizare (Model B):** Modelul B are o eroare de testare scăzută (1.3) și o diferență mică între eroarea de antrenare și cea de testare. Acest model reprezintă cel mai bun echilibru în **bias/variance trade-off** pentru datele furnizate.

3. Dorim să estimăm un model de regresie polinomială de **gradul 3** pe baza unui set de date $(x^{(i)}, y^{(i)})_{i=1}^{n}$. Scrieți ecuația modelului $\hat{y}$. Definiți matricea de caracteristici (feature matrix) $\mathbf{X}$ (incluzând termeni de bias) pe care ar trebui să o utilizați pentru a rezolva această problemă ca o regresie liniară standard.

pe o singură variabilă x

$$\hat{y} = w_0 + w_1 x + w_2 x^2 + w_3 x^3$$

$$\phi(x^{(i)}) = \begin{pmatrix} 1 \\ x^{(i)} \\ x^{(i)2} \\ x^{(i)3} \end{pmatrix}$$

pt m ese

$$X = \begin{pmatrix} 1 & x^{(1)} & (x^{(1)})^2 & (x^{(1)})^3 \\ \cdots & - & - & - \\ 1 & x^{(m)} & (x^{(m)})^2 & (x^{(m)})^3 \end{pmatrix}$$

4. Presupuneți că avem un set de date $\{(x^{(i)}, y^{(i)})\}$ și dorim să estimăm un model de **regresie polinomială de gradul 2**: $\hat{y} = w_2 x^2 + w_1 x + w_0$.

a) Explicați cum poate fi tratat acest model ca un model de regresie liniară multiplă prin transformarea datelor de intrare.

b) Scrieți forma matricială a datelor de intrare $\mathbf{X}$ (matricea de design) și a vectorului de parametri $\mathbf{w}$ pentru un set de n puncte.

$$w = \begin{pmatrix} w_0 \\ w_1 \\ w_2 \end{pmatrix} \qquad X = \begin{pmatrix} 1 & x^{(1)} & (x^{(1)})^2 \\ \cdot & \cdot & \cdot \\ 1 & x^{(m)} & (x^{(m)})^2 \end{pmatrix}$$

IV. Regularized linear models

Exercițiul 1: Identificarea Obiectivului de Optimizare

Completați spațiile libere în cele două obiective de optimizare de mai jos și identificați tipul de regularizare asociat fiecărui caz.

1. **Obiectivul I:** Minimizarea $(\text{MSE ermenu}) + \frac{1}{2}\lambda \sum_j w_j^2$.
2. **Obiectivul II:** Minimizarea $(\text{MSE ermenu}) + \frac{1}{2}\lambda \sum_j |w_j|$.

Rezolvare 1:

1. **Obiectivul I** folosește norma ℓ_2 (suma pătratelor). Acesta corespunde **Ridge Regression**.
2. **Obiectivul II** folosește norma ℓ_1 (suma valorilor absolute). Acesta corespunde **Lasso Regression**.

Exercițiul 2: Efectul Hiperparametrului λ

Ce se întâmplă cu modelul de Regresie Ridge în următoarele cazuri extreme, în funcție de hiperparametrul λ?

1. λ este setat la 0 ($\lambda = 0$).
2. λ este setat la o valoare foarte mare ($\lambda \to \infty$).

Rezolvare 2:

1. Dacă $\lambda = 0$, termenul de regularizare devine zero. **Ridge Regression se reduce la regresia liniară simplă** (ne-regularizată).
2. Dacă λ este foarte mare, penalizarea domină. Modelul va încerca să minimizeze costul de a avea ponderi mari. Toate ponderile ajung **foarte aproape de zero**, iar rezultatul este o linie plată care aproximează media datelor.

Exercițiul 3: Avantajele Selecției de Caracteristici

De ce este considerată **Lasso Regression** superioară (sau cel puțin preferabilă) Regresiei Ridge în scenariile în care se suspectează că majoritatea caracteristicilor de intrare sunt irelevante?

Rezolvare 3:

Lasso Regression este preferabilă în acest caz, deoarece utilizează regularizarea ℓ_1 care are proprietatea de a **seta automat la zero** ponderile caracteristicilor considerate irelevante. Acest proces este numit **selecția automată a caracteristicilor (*feature selection*)**. Prin eliminarea caracteristicilor inutile, Lasso produce un **model rar (*sparse model*)** care este mai simplu de interpretat de către oameni și mai puțin probabil să se supra-antreneze. Ridge Regression, pe de altă parte, doar micșorează ponderile, fără a le anula.

4.

Rândul 4

1. Assume we have a dataset $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \ldots, (x^{(n)}, y^{(n)})\}$ of points in the 2D plane, and we want to estimate the following elastic net regression model with hyperparameters λ and r:

$$\hat{y} = w_1 x + w_0.$$

Write the batch gradient descent update for w_0, w_1 in terms of $x^{(1)}, y^{(1)}, x^{(2)}, y^{(2)}, \ldots, x^{(n)}, y^{(n)}, \lambda, r$, where the learning rate is η. Numerical application: $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), (x^{(3)}, y^{(3)})\} = \{(1,1), (2,-1), (3,2)\}$, $\eta = 0.1$, $\lambda = 1$, $r = 0.5$.

[illegible] that contains seven

$$Y = \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix} \qquad X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \qquad n = 3, \quad d = 1$$

$$\mathcal{L}(w) = \frac{1}{2n} (Xw - y)^T (Xw - y) + r\lambda \|w\|_1 + \frac{1-r}{2} \lambda \|w\|_2^2$$

$$\|w\|_1 = \sum_{j=0}^{d} |w_j|$$

$$\|w\|_2 = \left(\sum_{j=0}^{d} |w_j|^2 \right)^{\frac{1}{2}}$$

$$\text{batch}: \quad w \leftarrow w - \eta \nabla_w \mathcal{L}(w), \qquad \nabla_w \mathcal{L} = \frac{\partial \mathcal{L}}{\partial w}$$

$$\nabla_w \mathcal{L}(w) = \frac{1}{n} (X^T X w - X^T y) + r\lambda \, \text{sgn}(w) + (1-r)\lambda w$$

$$\frac{\partial \|w\|_1}{\partial w} = \text{sgn}(w)$$

$$\frac{\partial \|w\|_2^2}{\partial w} = 2w$$

$$X^T X = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

$$X^T y = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \\ 5 \end{pmatrix}$$

$$\nabla_w \mathcal{L}(w) = \frac{1}{3} \begin{pmatrix} 3w_0 + 6w_1 & -2 \\ 6w_0 + 14w_1 & -5 \end{pmatrix} + \overset{=0,5}{0,5} \cdot 1 \cdot \begin{pmatrix} \operatorname{sgn}(w_0) \\ \operatorname{sgn}(w_1) \end{pmatrix} + \overset{=0,5}{(1-0,5)} \cdot 1 \begin{pmatrix} w_0 \\ w_1 \end{pmatrix}$$

$$= \begin{pmatrix} w_0 + 2w_1 - \frac{2}{3} + 0,5 \operatorname{sgn}(w_0) + 0,5\, w_0 \\ 2w_0 + \frac{14}{3} w_1 - \frac{5}{3} + 0,5 \operatorname{sgn}(w_1) + 0,5\, w_1 \end{pmatrix}$$

$$w^{(1)} \leftarrow w^{(0)} - 0,1 \begin{pmatrix} w_0 + 2w_1 - \frac{2}{3} + 0,5 \operatorname{sgn}(w_0) + 0,5\, w_0 \\ 2w_0 + \frac{14}{3} w_1 - \frac{5}{3} + 0,5 \operatorname{sgn}(w_1) + 0,5\, w_1 \end{pmatrix}$$

(V) Logistic regression