2.1. From linear models to deep neural networks

1.

Exercițiul F.3: Parametrizarea Softmax Regression

Considerăm un model de Regresie Softmax pentru o problemă cu $d = 5$ caracteristici de intrare și $q = 4$ clase de ieșire.

1. Specificați dimensiunea matricei de ponderi $\mathbf{W}$ și a vectorului de bias $\mathbf{b}$.
2. Calculați costul total al parametrilor (greutăți și bias-uri) pentru acest strat complet conectat.
3. Calculați costul parametrilor dacă numărul de caracteristici ar crește la $d = 1000$, menținând $q = 4$.

Rezolvare F.3:

1. **Dimensiuni:** Conform surselor, Matricea de design $\mathbf{X}$ are dimensiunea $n \times d$, iar ponderile $\mathbf{W}$ au dimensiunea $d \times q$. Bias-ul $\mathbf{b}$ are dimensiunea $1 \times q$.
   - $\mathbf{W} \in \mathbb{R}^{d \times q}$: $\mathbf{W} \in \mathbb{R}^{5 \times 4}$.
   - $\mathbf{b} \in \mathbb{R}^{1 \times q}$: $\mathbf{b} \in \mathbb{R}^{1 \times 4}$.
2. **Costul Total (d=5, q=4):**
   - Număr de greutăți (Weight parameters): $d \times q = 5 \times 4 = 20$.
   - Număr de bias-uri (Bias parameters): $q = 4$.
   - Total parametri: $20 + 4 = \mathbf{24}$.
3. **Costul Total (d=1000, q=4):**
   - Număr de greutăți: $d \times q = 1000 \times 4 = 4000$.
   - Număr de bias-uri: $q = 4$.
   - Total parametri: $4000 + 4 = \mathbf{4004}$.

   - *Implicație:* Acest exercițiu ilustrează cum costul parametrizării $O(dq)$ crește liniar cu dimensionalitatea intrării, dar menține costul gestionabil dacă d este mare, dar q este mic.

2.

Exercițiul F.4: Structura Softmax și Scorul Liniar (Logits)

Considerăm un caz simplu de clasificare binară cu Softmax (clase $q = 2$). Modelul folosește două caracteristici x_1, x_2 și bias-uri.

1. Scrieți ecuația scalară (extinsă) pentru scorul clasei 1 (o_1) și scorul clasei 2 (o_2), folosind notația w_{ij} și b_j din sursă.
2. Explicați cum ar trebui reprezentată eticheta țintă y pentru o instanță care aparține Clasei 2, folosind codificarea *one-hot*.

Rezolvare F.4:

1. **Ecuațiile Scorului (Logits):** Avem $d = 2$ intrări (x_1, x_2) și $q = 2$ ieșiri (o_1, o_2). Ponderile vor fi notate W_{ij} și bias-urile b_j:
   - Scorul Clasei 1:

$$O_1 = x_1 W_{11} + x_2 W_{12} + b_1$$

   - Scorul Clasei 2:

$$O_2 = x_1 W_{21} + x_2 W_{22} + b_2$$

2. **Codificarea One-Hot:** Pentru $q = 2$ clase, vectorul *one-hot* are 2 componente. Dacă instanța aparține Clasei 2, componenta corespunzătoare acestei clase este setată la 1, iar restul la 0.

$$y = [0\ 1]$$

2.2. Multilayer perceptrons

Exercițiul M.1: Calculul Ieșirii (Forward Pass) și Costul Parametrilor pentru MLP

Definiți un MLP pentru regresie, având $d = 3$ intrări, un singur strat ascuns cu $h = 2$ unități, folosind funcția de activare $\text{ReLU}(x) = \max(x, 0)$, și $q = 1$ ieșire.

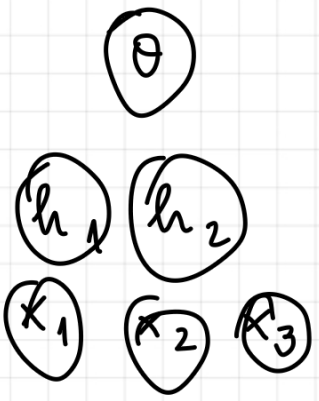

Pentru input-ul $X = \begin{bmatrix} 1 & 0 & 1 \\ -1 & 1 & 0 \end{bmatrix}$ (deci $n = 2$ exemple).

Folosim următoarele setări de parametri (similar cu):

$$W^{(1)} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{bmatrix} \in \mathbb{R}^{3\times 2}, \quad b^{(1)} = [1 \quad 0] \in \mathbb{R}^{1\times 2}$$

$$W^{(2)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \in \mathbb{R}^{2\times 1}, \quad b^{(2)} = [1] \in \mathbb{R}^{1\times 1}$$

1. Calculați ieșirea $\mathbf{O}$ a rețelei (procesul *forward pass*).
2. Specificați numărul total de parametri (greutăți și bias-uri) ai rețelei.

Rezolvare M.1:

Formule Necesare:

$$H = \text{ReLU}(XW^{(1)} + b^{(1)})$$

$$O = HW^{(2)} + b^{(2)}$$

$$\text{ReLU}(x) = \max(x, 0)$$

1. Calculul Ieșirii O:

Pasul 1.1: Calculul scorurilor liniare pentru Stratul Ascuns $XW^{(1)}$:

$$XW^{(1)} = \begin{bmatrix} 1 & 0 & 1 \\ -1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{bmatrix} = \begin{bmatrix} (1\cdot 1 + 0\cdot 0 + 1\cdot 1) & (1\cdot 0 + 0\cdot 1 + 1\cdot(-1)) \\ (-1\cdot 1 + 1\cdot 0 + 0\cdot 1) & (-1\cdot 0 + 1\cdot 1 + 0\cdot(-1)) \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix}$$

Pasul 1.2: Adăugarea Bias-ului $b^{(1)}$:

$$XW^{(1)} + b^{(1)} = \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 3 & -1 \\ 0 & 1 \end{bmatrix}$$

Notă: Bias-ul $b^{(1)} = [1\ 0]$ este extins (broadcasted) la dimensiunea 2×2 pentru a fi adunat.

Pasul 1.3: Aplicarea Funcției de Activare ReLU:

$$H = \text{ReLU}\left(\begin{bmatrix} 3 & -1 \\ 0 & 1 \end{bmatrix}\right) = \begin{bmatrix} \max(3,0) & \max(-1,0) \\ \max(0,0) & \max(1,0) \end{bmatrix} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \in \mathbb{R}^{2\times 2}$$

Pasul 1.4: Calculul ieșirii O:

$$O = HW^{(2)} + b^{(2)} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3\cdot 1 + 0\cdot 0 \\ 0\cdot 1 + 1\cdot 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$O = \begin{bmatrix} 3 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 1 \end{bmatrix} \in \mathbb{R}^{2\times 1}$$

Ieșirea finală a rețelei este $\mathbf{O} = \begin{bmatrix} 4 \\ 1 \end{bmatrix}$.

2. Numărul Total de Parametri:

- Ponderi $W^{(1)}$: $d \times h = 3 \times 2 = 6$.
- Bias-uri $b^{(1)}$: $h = 2$.
- Ponderi $W^{(2)}$: $h \times q = 2 \times 1 = 2$.
- Bias-uri $b^{(2)}$: $q = 1$.
- Total parametri: $6 + 2 + 2 + 1 = \mathbf{11}$.

Exercițiul M.2: Rolul Neliniarității

Considerați un MLP cu două straturi, dar în care funcția de activare σ este omisă (adică $\sigma(x) = x$, transformarea identitate).

1. Explicați de ce acest model nu este mai puternic din punct de vedere expresiv decât o Regresie Liniară simplă.
2. De ce funcțiile Sigmoid și tanh (dar nu și ReLU) au fost înlocuite în straturile ascunse ale MLP-urilor moderne?

Rezolvare M.2:

1. **Lipsa Puterii Expresive:** Fără o funcție de activare neliniară, MLP-ul este o compoziție de transformări afine (liniare plus bias). O compunere de funcții afine este întotdeauna **o singură funcție afină echivalentă**. Prin urmare, chiar dacă antrenăm o rețea cu mai multe straturi, aceasta poate reprezenta doar o dreaptă (sau un hiperplan) în spațiul de intrare, la fel ca un model liniar cu un singur strat, adică **nu se obține nimic în plus**.
2. **Înlocuirea Sigmoid și tanh:** Sigmoid și tanh au fost înlocuite în straturile ascunse de către ReLU, deoarece:
   - Sufereau de problema bine documentată a **gradientului evanescent (*vanishing gradient*)**. Derivatele lor se apropie de zero când inputul este mare sau mic.
   - ReLU are derivate bine comportate (0 sau 1), ceea ce facilitează optimizarea și ameliorează problema *vanishing gradient*.

2.3. Model selection

2.4. Weight decay

Exercițiul R.1: Penalizarea Weight Decay (Regularizarea ℓ_2)

Considerăm un strat MLP cu matricea de ponderi $W = [2 \quad 1 \; 0 \quad -2]$. Presupunem că hiperparametrul de regularizare este $\lambda = 0.5$.

Calculați valoarea numerică a termenului de penalizare ℓ_2 care ar fi adăugat la funcția de pierdere: $\frac{\lambda}{2}||W||_F^2$.

Rezolvare R.1:

Pasul 1: Calculul Normei Frobenius la Pătrat ($||W||_F^2$) Norma Frobenius la pătrat este suma pătratelor tuturor elementelor matricei:

$$||W||_F^2 = 2^2 + 1^2 + 0^2 + (-2)^2 = 4 + 1 + 0 + 4 = 9$$

Pasul 2: Calculul Termenului de Penalizare

$$\text{Penalizare } = \frac{\lambda}{2}||W||_F^2 = \frac{0.5}{2} \times 9 = 0.25 \times 9 = \mathbf{2.25}$$

2.5. Dropout

1.

Exercițiul D.6: Dropout vs. Test Time

Explicați de ce *Dropout* este folosit **numai** în timpul antrenării și este dezactivat în timpul testării (*at test time*). Ce ar fi necesar dacă *Dropout* ar fi aplicat în timpul testării?

Rezolvare D.6:

1. **Dezactivarea în Timpul Testării:** *Dropout* este dezactivat în timpul testării deoarece antrenarea cu *dropout* poate fi văzută ca antrenarea unui ansamblu (ensemble) de rețele mai mici. La testare, dorim să folosim capacitatea deplină a modelului antrenat (incluzând toți neuronii și ponderile învățate) pentru a obține o predicție cât mai stabilă și mai precisă.
2. **Necesitatea Normalizării Suplimentare (Dacă ar fi aplicat la Test):** Dacă *dropout* ar fi aplicat în timpul testării, ieșirea rețelei ar varia aleatoriu. În plus, dacă nu am aplica normalizarea ($\frac{h}{1-p}$) în timpul antrenării (caz neconvențional), atunci ar trebui să facem o normalizare la momentul testării prin **scalarea ponderilor** cu $1-p$ pentru a menține valoarea așteptată constantă. Totuși, în practica standard, normalizarea se face pe activări în timpul antrenării, iar *dropout* este pur și simplu dezactivat la testare.

2.

Exercițiul D.5: Aplicarea și Normalizarea Dropout

Presupunem că antrenăm un MLP cu un strat ascuns, iar probabilitatea de *dropout* este setată la $p = 0.25$. Ieșirea activării unui neuron ascuns este $h = 4$.

1. Care este probabilitatea ca acest neuron să fie **reținut** (să nu fie dezactivat)?
2. Dacă neuronul este reținut, care este valoarea activării normalizate h' care va fi transmisă stratului următor?
3. Dacă am avea 100 de neuroni într-un strat ascuns și aplicăm *dropout* cu $p = 0.25$, câți neuroni am aștepta să fie dezactivați?

Rezolvare D.5:

1. **Probabilitatea de reținere:** Probabilitatea de dezactivare este $p = 0.25$. Probabilitatea de reținere (să fie activ) este $1 - p = 1 - 0.25 = \mathbf{0.75}$.
2. **Valoarea activării normalizate h':** Dacă neuronul este reținut (cu probabilitatea $1-p$), valoarea activării este $\frac{h}{1-p}$.

$$h' = \frac{4}{1-0.25} = \frac{4}{0.75} = \frac{4}{3/4} = 4 \times \frac{4}{3} \approx \mathbf{5.33}$$

3. **Numărul așteptat de neuroni dezactivați:** Numărul așteptat este $N \times p$.
   Număr de neuroni dezactivați $= 100 \times 0.25 = \mathbf{25}$ de neuroni.

3

1. Training:
   - A layer with 5 neurons has activations $[0.8, 0.5, 0.6, 0.4, 0.7]$.
   - Dropout rate $p = 0.4$ (60% retention).
   - After dropout, the retained neurons might be $[0.8, 0, 0.6, 0, 0.7]$ (randomly set to zero).
   - Remaining activations are scaled: $[0.8/(1-0.4), 0, 0.6/(1-0.4), 0, 0.7/(1-0.4)] = [1.33, 0, 1.0, 0, 1.17]$.

2. Inference:
   - Dropout is not applied.
   - Instead, weights are scaled down by $(1-p) = 0.6$, ensuring the expected value of outputs matches training.

2.6. FP, BP, CG

1. A simple example

Our goal: find $\frac{dJ}{da}$, $\frac{dJ}{db}$, $\frac{dJ}{dc}$

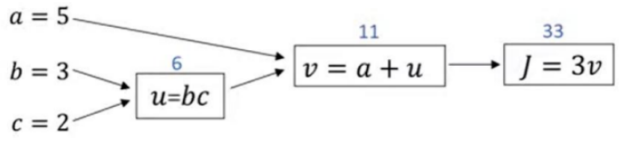

$\frac{dJ}{dv} = 3$ $\quad \frac{du}{db} = c = 2$

$\frac{dv}{du} = 1$ $\quad \frac{dv}{da} = 1$ $\quad \frac{du}{dc} = b = 3$

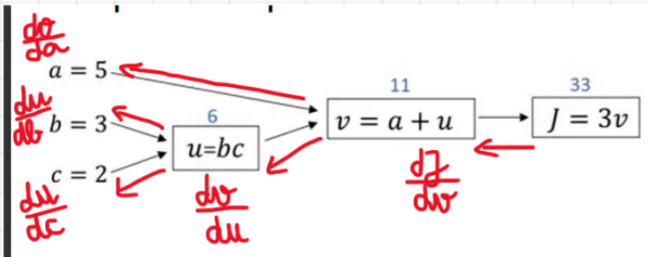

Now we use **chain rule** from high school: $F'(x) = f'(g(x)) \cdot g'(x)$ where *F(x) = f(g(x))*

or

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$$ → we will use this form !

A simple example

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$$

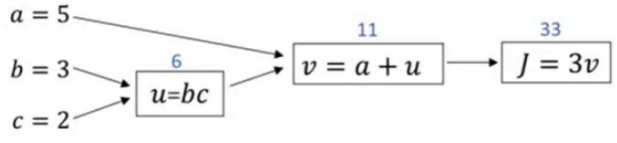

$\frac{dJ}{da} = \frac{dJ}{dv} \cdot \frac{dv}{da} = 3 \cdot 1 = 3$

$\frac{dJ}{db} = \frac{dJ}{dv} \cdot \frac{dv}{du} \cdot \frac{du}{db} = 3 \cdot 1 \cdot 2 = 6$

$\frac{dJ}{dc} = \frac{dJ}{dv} \cdot \frac{dv}{du} \cdot \frac{du}{dc} = 3 \cdot 1 \cdot 3 = 9$

2.7. Numerical stability and initialization

Exercițiul R.2: Inițializarea Xavier/Glorot (Stabilitate Numerică)

Un MLP folosește Inițializarea Xavier (Glorot) pentru a seta varianța ponderilor unui strat ascuns. Acest strat primește $n_{\text{in}} = 200$ intrări și trimite $n_{\text{out}} = 100$ ieșiri. Ponderile sunt extrase dintr-o distribuție Gaussiană cu media zero și varianța σ^2.

Calculați varianța optimă σ^2 (Conform formulei Xavier/Glorot).

Formule necesare (Conform conversației anterioare):

$$\sigma^2 = \frac{2}{n_{\text{in}} + n_{\text{out}}}$$

Rezolvare R.2:

$$\sigma^2 = \frac{2}{200 + 100} = \frac{2}{300} = \frac{1}{150} \approx \mathbf{0.00667}$$

2.8. Deep learning computation

1.

Exercițiul C.1: Calculul Ieșirii (Forward Pass) pentru un Strat MLP

Definiți un strat MLP pentru clasificare (similar unui singur neuron Logit/Softmax), având $d = 2$ intrări și $q = 2$ ieșiri. Presupunem că funcția de activare σ aplicată este transformarea identitate $\sigma(x) = x$ (sau scorurile liniare, Logits).

Pentru input-ul $X = [3 \quad 1]$ (un singur exemplu, $n = 1$), folosiți următorii parametri:

$$W = [2 \quad -1 \; 1 \quad 0] \in \mathbb{R}^{2\times 2}, \quad b = [0.5 \quad 1.0] \in \mathbb{R}^{1\times 2}$$

Calculați ieșirea $\mathbf{O}$ a acestui strat: $\mathbf{O} = XW + b$.

Rezolvare C.1:

Pasul 1: Calculul Scorul Liniar XW

$$\mathbf{XW} = [3 \quad 1] \, [2 \quad -1 \; 1 \quad 0] = [(3 \cdot 2 + 1 \cdot 1) \quad (3 \cdot (-1) + 1 \cdot 0)]$$

$$\mathbf{XW} = [7 \quad -3]$$

Pasul 2: Adăugarea Bias-ului b

$$\mathbf{O} = \mathbf{XW} + \mathbf{b} = [7 \quad -3] + [0.5 \quad 1.0]$$

$$\mathbf{O} = [7.5 \quad -2.0] \in \mathbb{R}^{1\times 2}$$

Ieșirea finală a stratului (logits) este $\mathbf{O} = [7.5 \quad -2.0]$.

2.

Exercițiul C.2: Parametrizarea unui Bloc Complex

Considerăm un "Bloc de Calcul" (*Computational Block*) format din două straturi complet conectate (Fully Connected - FC), similar unei structuri de tip *block* din ResNet.

- **Stratul FC1:** Primește $d = 10$ intrări și are $h_1 = 5$ unități ascunse.
- **Stratul FC2:** Primește ieșirea din FC1 ($h_1 = 5$ intrări) și are $q = 4$ ieșiri.

1. Specificați dimensiunea matricei de ponderi W pentru fiecare strat (FC1 și FC2).
2. Calculați costul total al parametrilor (greutăți și bias-uri) pentru întregul Bloc de Calcul.

Rezolvare C.2:

1. **Dimensiunea Matricelor de Ponderi:**
   - $W^{(1)}$ (FC1): Dimensiunea este (intrări $\times$ ieșiri) $\mathbf{10 \times 5}$.
   - $W^{(2)}$ (FC2): Dimensiunea este (intrări $\times$ ieșiri) $\mathbf{5 \times 4}$.
2. **Costul Total al Parametrilor:** Costul total este suma ponderilor (W) și a bias-urilor (b) pentru ambele straturi.
   - **FC1:** Ponderi ($10 \times 5 = 50$) + Bias-uri ($h_1 = 5$) 55 parametri.
   - **FC2:** Ponderi ($5 \times 4 = 20$) + Bias-uri ($q = 4$) 24 parametri.
   - **Total parametri în Bloc:** $55 + 24 = 79$ parametri.

Ex cu toate

1.

Exercițiul MLP.1: Calculul Ieșirii și Costul Parametrilor

Definiți un MLP pentru regresie, având **2 intrări** ($d = 2$), un singur **strat ascuns cu 3 unități** ($h = 3$) și **1 ieșire** ($q = 1$).

Funcția de activare pentru stratul ascuns este **ReLU** ($\sigma(x) = \max(x, 0)$).

Pentru matricea de intrare X și următorii parametri de ponderi și bias-uri, calculați **ieșirea O a rețelei** și specificați **numărul total de parametri (greutăți și bias-uri)** pentru rețea.

$m \times d \rightarrow d \times h \rightarrow h \times q$

$$\text{Intrare: } X = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} \in \mathbb{R}^{2\times 2}$$

$$\mathbf{W}^{(1)} = \begin{bmatrix} 1 & 0 & 1 \\ -1 & 2 & 0 \end{bmatrix} \in \mathbb{R}^{2\times 3}, \quad \mathbf{b}^{(1)} = [0 \quad 1 \quad 0] \in \mathbb{R}^{1\times 3}$$

$$\mathbf{W}^{(2)} = \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix} \in \mathbb{R}^{3\times 1}, \quad \mathbf{b}^{(2)} = [0] \in \mathbb{R}^{1\times 1}$$

Formule necesare (Conform surselor):

- Stratul Ascuns: $H = \sigma(XW^{(1)} + b^{(1)})$
- Stratul de ieșire: $O = HW^{(2)} + b^{(2)}$

Rezolvare MLP.1:

1. Calculul Total al Parametrilor:

Calculăm costul parametrilor pentru fiecare strat:

- **Stratul 1 (Intrare $d = 2$, Ascuns $h = 3$):**
  - Ponderi $W^{(1)}$: $d \times h = 2 \times 3 = 6$
  - Bias-uri $b^{(1)}$: $h = 3$
- **Stratul 2 (Ascuns $h = 3$, Ieșire $q = 1$):**
  - Ponderi $W^{(2)}$: $h \times q = 3 \times 1 = 3$
  - Bias-uri $b^{(2)}$: $q = 1$

$$\text{Total parametri} = 6 + 3 + 3 + 1 = \mathbf{13}$$

2. Calculul Ieșirii O (Forward Pass):

Pasul 2.1: Calculul scorurilor liniare pentru Stratul Ascuns ($XW^{(1)}$):

$$\mathbf{XW}^{(1)} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ -1 & 2 & 0 \end{bmatrix}$$

$$\mathbf{XW}^{(1)} = \begin{bmatrix} (2\cdot 1 + 1\cdot(-1)) & (2\cdot 0 + 1\cdot 2) & (2\cdot 1 + 1\cdot 0) \\ (0\cdot 1 + 3\cdot(-1)) & (0\cdot 0 + 3\cdot 2) & (0\cdot 1 + 3\cdot 0) \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 \\ -3 & 6 & 0 \end{bmatrix}$$

Pasul 2.2: Adăugarea Bias-ului $\mathbf{b}^{(1)}$:

$$\mathbf{XW}^{(1)} + \mathbf{b}^{(1)} = \begin{bmatrix} 1 & 2 & 2 \\ -3 & 6 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$\mathbf{XW}^{(1)} + \mathbf{b}^{(1)} = \begin{bmatrix} 1 & 3 & 2 \\ -3 & 7 & 0 \end{bmatrix}$$

Pasul 2.3: Aplicarea Funcției de Activare ReLU ($\sigma(x) = \max(x, 0)$):

$$H = \text{ReLU}\left(\begin{bmatrix} 1 & 3 & 2 \\ -3 & 7 & 0 \end{bmatrix}\right)$$

$$H = \begin{bmatrix} \max(1,0) & \max(3,0) & \max(2,0) \\ \max(-3,0) & \max(7,0) & \max(0,0) \end{bmatrix} = \begin{bmatrix} 1 & 3 & 2 \\ 0 & 7 & 0 \end{bmatrix} \in \mathbb{R}^{2\times 3}$$

Pasul 2.4: Calculul ieșirii finale O:

$$\mathbf{O} = H\mathbf{W}^{(2)} + \mathbf{b}^{(2)} = \begin{bmatrix} 1 & 3 & 2 \\ 0 & 7 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\mathbf{O} = \begin{bmatrix} (1\cdot 2 + 3\cdot 1 + 2\cdot(-1)) \\ (0\cdot 2 + 7\cdot 1 + 0\cdot(-1)) \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 2+3-2 \\ 0+7+0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\mathbf{O} = \begin{bmatrix} 3 \\ 7 \end{bmatrix} \in \mathbb{R}^{2\times 1}$$

Ieșirea rețelei pentru cele două exemple este $\mathbf{O} = \begin{bmatrix} 3 \\ 7 \end{bmatrix}$.

Exercise 2

2. Define an MLP for regression, having 3 inputs, one hidden layer of 2 units, with the ReLU activation function, and 1 output. For the input $\boldsymbol{X} = \begin{bmatrix} 1 & 0 & 1 \\ 1 & -1 & 0 \end{bmatrix}$, if the weight matrices and bias vectors of the layers are generated randomly having values from the set $\{-1, 0, 1\}$ (you can generate them yourself, not all zeros), compute the output $\boldsymbol{O}$ of the network. Specify the total number of real parameters (weights and biases) for the network.

Solution:

we have the following formulas:

$$\begin{aligned} \boldsymbol{H} &= \sigma(\boldsymbol{X}\boldsymbol{W}^{(1)} + \boldsymbol{b}^{(1)}), \\ \boldsymbol{O} &= \boldsymbol{H}\boldsymbol{W}^{(2)} + \boldsymbol{b}^{(2)}, \end{aligned}$$

where $\boldsymbol{X} \in \mathbb{R}^{n \times d}$, $\boldsymbol{W}^{(1)} \in \mathbb{R}^{d \times h}$, $\boldsymbol{b}^{(1)} \in \mathbb{R}^{1 \times h}$, $\boldsymbol{H} \in \mathbb{R}^{n \times h}$, $\boldsymbol{W}^{(2)} \in \mathbb{R}^{h \times q}$, $\boldsymbol{b}^{(2)} \in \mathbb{R}^{1 \times q}$, $\boldsymbol{O} \in \mathbb{R}^{n \times q}$, and

$$\sigma(x) = \text{ReLU}(x) = \max(x, 0).$$

$n = 2$, $d = 3$, $h = 2$, $q = 1$

total parameters $= \underbrace{3 \times 2}_{W^{(1)}} + \underbrace{1 \times 2}_{b^{(1)}} + \underbrace{2 \times 1}_{W^{(2)}} + \underbrace{1 \times 1}_{b^{(2)}}$

$$W^{(1)} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix} \in \mathbb{R}^{3 \times 2} \qquad b^{(1)} = \begin{pmatrix} 1 & 0 \end{pmatrix} \in \mathbb{R}^{1 \times 2}$$

$$W^{(2)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \in \mathbb{R}^{2 \times 1} \qquad b^{(2)} = (1) \in \mathbb{R}^{(1)}$$

$$X W^{(1)} + b^{(1)} = \begin{pmatrix} 1 & 0 & 1 \\ 1 & -1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix} + \begin{pmatrix} 1 & 0 \end{pmatrix} =$$

$$= \begin{pmatrix} 2 & -1 \\ 1 & -1 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 3 & -1 \\ 2 & -1 \end{pmatrix}$$

→ Broadcasting

$$H = \begin{pmatrix} \text{relu}(3) & \text{relu}(-1) \\ \text{relu}(2) & \text{relu}(-1) \end{pmatrix} = \begin{pmatrix} 3 & 0 \\ 2 & 0 \end{pmatrix} \in \mathbb{R}^{2 \times 2}$$

$$O = H\,W^{(2)} + b^{(2)} = \begin{pmatrix} 3 & 0 \\ 2 & 0 \end{pmatrix}\begin{pmatrix} 1 \\ 0 \end{pmatrix} + (1) =$$

$$= \begin{pmatrix} 3 \\ 2 \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 3 \end{pmatrix} \in^{2\times 1}$$

Problemă curs SIO BIA

$$x^{(1)} = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix} \quad x^{(2)} = \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} \quad x^{(3)} = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$$

$$y^{(1)} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad y^{(2)} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \quad y^{(3)} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$$

$\bar{y}(x) = \text{ReLu}(x) = \max(0, x)$

$n = 3$ (3 exemple), $d = 3$ (3 linii X), $q = 2$ (2 features) $\geq$ linii Y

Presupunem $h = 2$

$$W^{(1)}_{\in \mathbb{R}^{d\times h}} = \begin{pmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{pmatrix} \in \mathbb{R}^{3\times 2} \qquad b^{(1)}_{\in \mathbb{R}^{1\times h}} = \begin{pmatrix} 0 & 1 \end{pmatrix} \in \mathbb{R}^{1\times 2}$$

$$W^{(2)}_{\in \mathbb{R}^{h\times q}} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix} \in \mathbb{R}^{2\times 2} \qquad b^{(2)}_{\in \mathbb{R}^{1\times q}} = \begin{pmatrix} -1 & 1 \end{pmatrix} \in \mathbb{R}^{1\times 2}$$

$$X = \begin{pmatrix} 0 & 1 & -1 \\ 1 & -1 & 0 \\ -1 & 0 & 1 \end{pmatrix} \in \mathbb{R}^{3\times 3}$$

$\rightarrow x^{(1)T}$

nr parametrii = $3\times2 + 1\times2 + 2\times2 + 1\times2 = 14$

$$A = X W^{(1)} + b^{(1)} = \begin{pmatrix} 0 & 1 & -1 \\ 1 & -1 & 0 \\ -1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{pmatrix} + \begin{pmatrix} 0 & 1 \end{pmatrix} =$$

$$= \begin{pmatrix} -1 & 2 \\ 2 & -1 \\ 1 & -1 \end{pmatrix} + \begin{pmatrix} 0 & 1 \\ 0 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} -1 & 3 \\ 2 & 0 \\ -1 & 0 \end{pmatrix}$$

$$H = \text{ReLu}(A) = \begin{pmatrix} 0 & 3 \\ 2 & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{3\times2}$$

$$O = H W^{(2)} + b^{(2)} = \begin{pmatrix} 0 & 3 \\ 2 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix} + \begin{pmatrix} -1 & 1 \end{pmatrix} =$$

$$= \begin{pmatrix} -3 & 0 \\ 0 & 2 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} -1 & 1 \\ -1 & 1 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} -4 & 1 \\ -1 & 3 \\ -1 & 1 \end{pmatrix} \in \mathbb{R}^{3\times2}$$

$$\mathcal{L}(w) = \frac{1}{m} \sum_{i=1}^{m} \frac{1}{2} (\hat{y}^{(i)} - y)^2$$

$$= \frac{1}{2m} \text{Tr} \left[(O-Y)^T (O-Y) \right]$$

$Y^{(1)^T}$

$$O - Y = \begin{pmatrix} -4 & 1 \\ -1 & 3 \\ -1 & 1 \end{pmatrix} - \begin{pmatrix} 0 & 1 \\ 1 & 2 \\ 2 & 3 \end{pmatrix} = \begin{pmatrix} -4 & 0 \\ -2 & 1 \\ -3 & -2 \end{pmatrix}$$

$$\mathcal{L}\left(W^{(1)}, b^{(1)}, W^{(2)}, b^{(2)}\right) = \frac{1}{6} \operatorname{Tr}\left(\begin{pmatrix} -4 & -2 & -3 \\ 0 & 1 & -2 \end{pmatrix} \begin{pmatrix} -4 & 0 \\ -2 & 1 \\ -3 & -2 \end{pmatrix} \right) =$$

$$= \frac{1}{6} \operatorname{Tr}\begin{pmatrix} 29 & 4 \\ 4 & 5 \end{pmatrix} = \frac{34}{6} = \frac{17}{3}$$

$$L = \frac{1}{2m} \operatorname{Tr}\left((O-Y)^T (O-Y) \right)$$

$$S = \frac{\lambda}{2} \left(\|W^{(1)}\|_F^2 + \|W^{(2)}\|_F^2 \right)$$

$$J = L + S$$

$$\frac{\partial J}{\partial W^{(2)}} = \frac{\partial (L+S)}{\partial W^{(2)}} = \underbrace{\frac{\partial L}{\partial W^{(2)}}}_{\text{I}} + \underbrace{\frac{\partial S}{\partial W^{(2)}}}_{\text{II}}$$

I.
$$\frac{\partial L}{\partial W^{(2)}} = \frac{\partial L}{\partial \theta} \cdot \frac{\partial \theta}{\partial W^{(2)}} = \frac{\partial L}{\partial \theta} \frac{\partial (W^{(2)} h)}{\partial W^{(2)}} = \cancel{\frac{\partial L}{\partial \theta} h^T}$$

$$h^T \cdot \frac{\partial L}{\partial \theta}$$

$2 \times 3 \quad 3 \times 2$

- $$\frac{\partial L}{\partial \theta} = \frac{\partial}{\partial \theta} \left(\frac{1}{2m} \operatorname{Tr}\left((O-Y)^T (O-Y) \right) \right) = \frac{1}{m} (O-Y)$$

$$\Rightarrow \frac{\partial L}{\partial W^{(2)}} = \frac{1}{m} h^T (O-Y)$$

II.
$$\frac{\partial S}{\partial W^{(2)}} = \lambda W^{(2)}$$

$$\Rightarrow \frac{\partial J}{\partial W^{(2)}} = \frac{1}{m} H^T (O-Y) + \lambda W^{(2)} \in \mathbb{R}^{h \times q}$$

$$\frac{\partial J}{\partial w^{(1)}} = \frac{\partial (L+s)}{\partial w^{(1)}} = \underbrace{\frac{\partial L}{\partial w^{(1)}}}_{\text{I}} + \frac{\partial s}{\partial w^{(1)}}$$

I $$\frac{\partial L}{\partial w^{(1)}} = \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial w^{(1)}} = \frac{\partial L}{\partial z} \frac{\partial (w^{(1)} x)}{\partial w^{(1)}} = x^T \underbrace{\frac{\partial L}{\partial z}}_{d \times m \quad m \times h} \in \mathbb{R}^{d \times h}$$

- $$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial h} \cdot \frac{\partial h}{\partial z} = \frac{\partial L}{\partial h} \cdot \frac{\partial \phi(z)}{\partial z} = \frac{\partial L}{\partial h} \odot \tau'(z)$$

$$\frac{\partial L}{\partial h} = \frac{\partial L}{\partial \theta} \cdot \frac{\partial \theta}{\partial h} = \frac{\partial L}{\partial \theta} \cdot \frac{\partial (w^{(2)} h)}{\partial h} = \underbrace{\frac{\partial L}{\partial \theta}}_{m \times q} \underbrace{w^{(2)T}}_{q \times h} \in \mathbb{R}^{m \times h}$$

$$= \frac{1}{m} (\theta - y) \, w^{(2)T}$$

II $$\frac{\partial s}{\partial w^{(1)}} = \lambda w^{(1)}$$

$$\frac{\partial J}{\partial w^{(1)}} = x^T \cdot \left(\frac{1}{m} (\theta - y) w^{(2)T} \right) \odot \tau'(z) + \lambda w^{(1)}$$

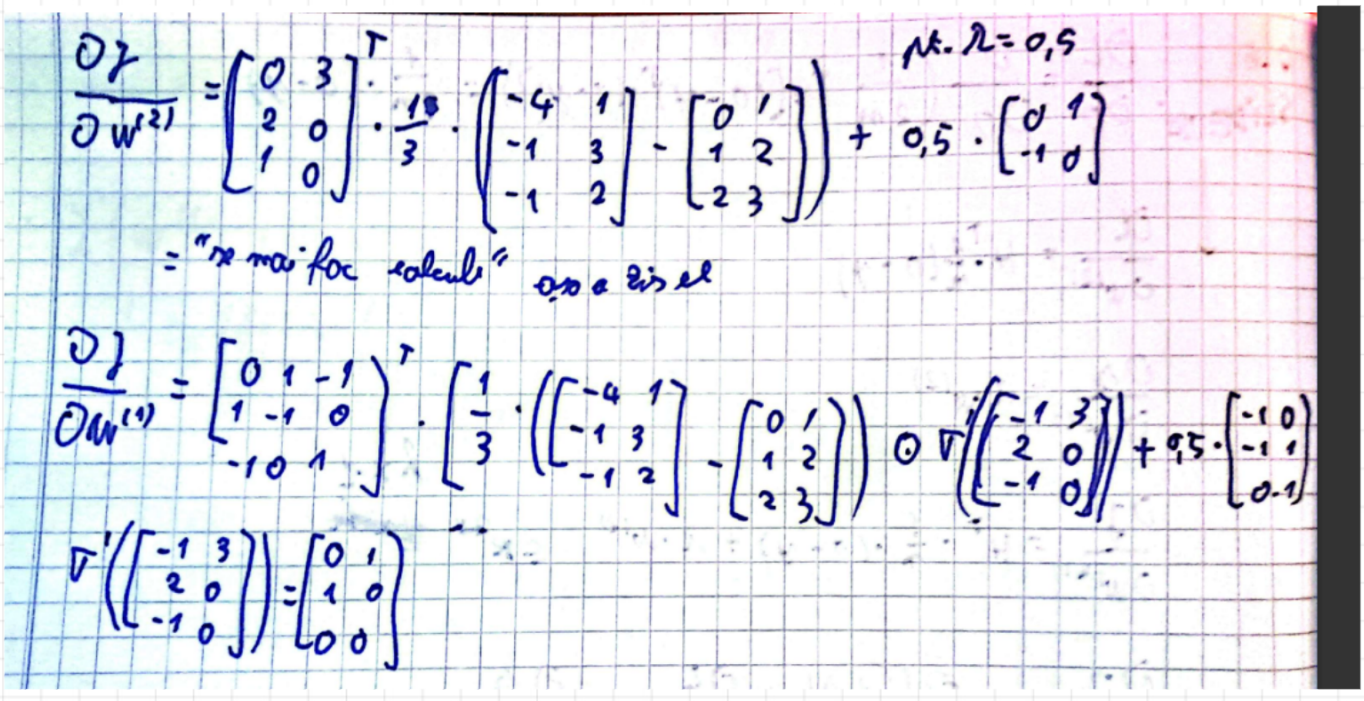

5. Consider a dataset [illegible] average linkage to perform hierarchical clustering of the points [illegible]

6. Draw the diagram of an MLP for regression, having 2 inputs, two hidden layers of 2 and 3 units, respectively, and 3 outputs. The activation function for both hidden layers is ReLU. For the input $\boldsymbol{X} = \begin{bmatrix} 1 & 0 \\ 1 & -1 \end{bmatrix}$, if the weight matrices and bias vectors of the layers are generated randomly having values from the set $\{-1, 0, 1\}$ (you can generate them yourself, not all zeros), compute the output $\boldsymbol{O}$ of the network. Specify the total number of real parameters (weights and biases) for the network.

- diagram

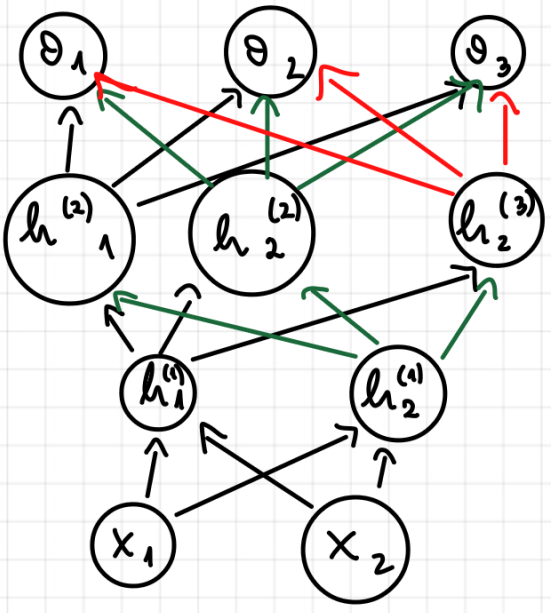

$n = 2$ (nr linii x) , $d = 2$ (nr col x) , $h^{(1)} = 2$, $h^{(2)} = 3$, $q = 3$

$$X = \begin{pmatrix} 1 & 0 \\ 1 & -1 \end{pmatrix}$$

$O = ?$, nr. param = ?

nr param $= d \cdot h^{(1)} + 1 \times h^{(1)} + h^{(1)} \cdot h^{(2)} + 1 \cdot h^{(2)} + h^{(2)} q + 1 \cdot q =$

$= 2 \cdot 2 + 1 \cdot 2 + 2 \cdot 3 + 1 \cdot 3 + 3 \cdot 3 + 1 \cdot 3 = 4 + 2 + 6 + 3 + 9 + 3 =$

$= 27$

Formule:

$H_1 = \nabla \left(X W^{(1)} + b^{(1)} \right)$

$H_2 = \nabla \left(H_1 W^{(2)} + b^{(2)} \right)$

$O = H_2 W^{(3)} + b^{(3)}$

$W^{(1)} \in \mathbb{R}^{d \cdot h^{(1)} = 2 \times 2} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$

$b^{(1)} \in \mathbb{R}^{1 \times h^{(1)} = 1 \cdot 2} = \begin{pmatrix} 1 & 0 \end{pmatrix}$

$$W^{(2)}_{\in \mathbb{R}^{h^{(1)} \times h^{(2)}} = 2\times 3} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix} \qquad b^{(2)}_{\in \mathbb{R}^{1 \times h^{(2)}} = 1\cdot 3} = \begin{pmatrix} -1 & 0 & 0 \end{pmatrix}$$

$$W^{(3)}_{\in \mathbb{R}^{h^{(2)} \cdot 2} = 3\cdot 3} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \qquad b^{(3)}_{\in \mathbb{R}^{1 \cdot 2} = 1\cdot 3} = \begin{pmatrix} 1 & 0 & 0 \end{pmatrix}$$

$$\nabla(x) = \text{ReLu}(x) = \max(x, 0)$$

$$H_1 = \nabla\Big(\overbrace{X\, W^{(1)}}^{A} + b^{(1)}\Big)$$

$$A = \begin{pmatrix} 1 & 0 \\ 1 & -1 \end{pmatrix}\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & -1 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 1 & 0 \end{pmatrix} =$$

$$= \begin{pmatrix} 2 & 0 \\ 2 & -1 \end{pmatrix}$$

$$\Rightarrow H_1 = \begin{pmatrix} 2 & 0 \\ 2 & 0 \end{pmatrix}$$

$$H_2 = \nabla\Big(\overbrace{H_1\, W^{(2)}}^{B} + b^{(2)}\Big)$$

$$B = \begin{pmatrix} 2 & 0 \\ 2 & 0 \end{pmatrix}\begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix} + \begin{pmatrix} -1 & 0 & 0 \end{pmatrix} =$$

$$= \begin{pmatrix} 2 & 0 & 0 \\ 2 & 0 & 0 \end{pmatrix} + \begin{pmatrix} -1 & 0 & 0 \\ -1 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

$$\Rightarrow H_2 = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

$$O = H_2\, W^{(3)} + b^{(3)} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} + (1\ 0\ 0)$$

$$= \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 0 & 0 \\ 2 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{2\times 3}$$

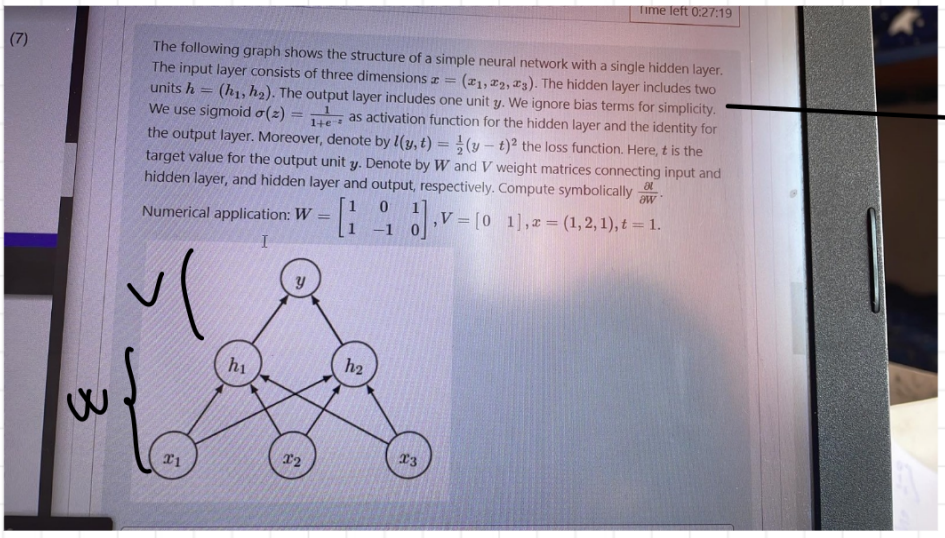

→ fără $b^{(i)}$

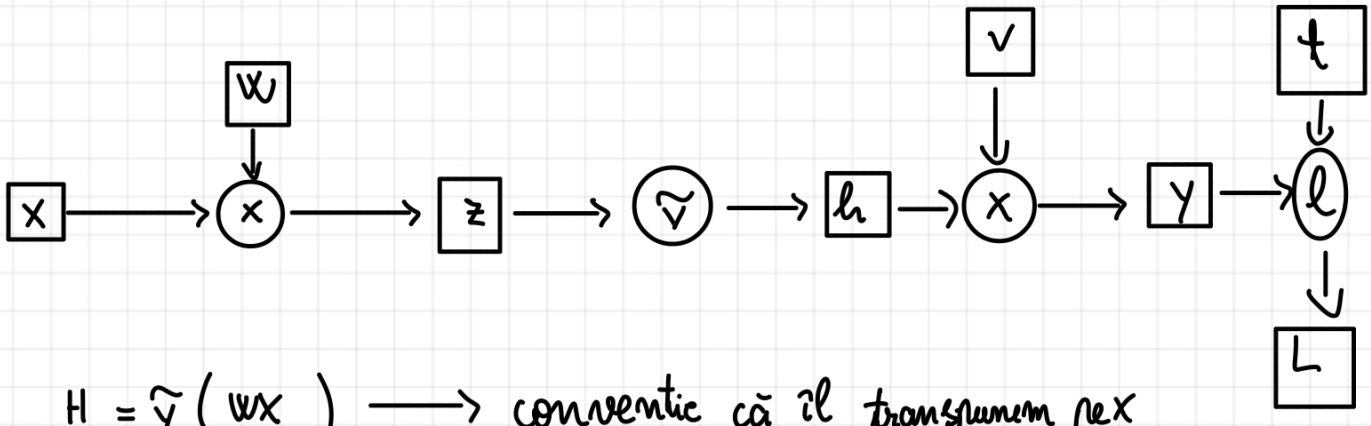

$H = \sigma(Wx)$ ⟶ convenție că îl transpunem pe x

$O = VH$

$$\ell(y,t) = \frac{1}{2}(y-t)^2 = \frac{1}{2}(V\sigma(Wx) - t)^2$$

$$\frac{\partial \ell}{\partial W} = \frac{1}{2} \cdot \frac{\partial L}{\partial W}\left(V^2\sigma^2(Wx) - 2V\sigma(Wx)\cdot t + t^2\right) =$$

$$= \frac{1}{2}\cdot 2\left(V\sigma^2(Wx) - \sigma(Wx)t\right) =$$

$$= (V\sigma(Wx) - t)\cdot\sigma(Wx)$$

$$Wx^T = \begin{pmatrix} 1 & 0 & 1 \\ 1 & -1 & 0 \end{pmatrix}\begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$$

$$H = \begin{pmatrix} \frac{1}{1+e^{-2}} \\ \frac{1}{1+e^{1}} \end{pmatrix}$$

$$O = U \cdot H = \begin{pmatrix} 0 & 1 \end{pmatrix} \begin{pmatrix} \frac{1}{1+e^{-2}} \\ \frac{1}{1+e^{1}} \end{pmatrix} = \left(\frac{1}{1+e} \right) = (0,269)$$

$$\frac{\partial e}{\partial w} = \left(V^T \cdot \left((0,269) - 1 \right) \odot \nabla'(z) \right) \cdot X^T =$$

$$= \left[\begin{pmatrix} 0 \\ 1 \end{pmatrix} \cdot (-0,731) \odot \nabla'(z) \right] \cdot X^T \cdot$$

$$\nabla'(z) = \frac{e^{-z}}{(1+e^{-z})^2} = \begin{pmatrix} 0,105 \\ 0,197 \end{pmatrix}$$

$$\begin{pmatrix} 0 \\ -0,731 \end{pmatrix} \odot \begin{pmatrix} 0,105 \\ 0,197 \end{pmatrix} \cdot \begin{pmatrix} 1 & 2 & 1 \end{pmatrix} =$$

$$= \begin{pmatrix} 0 & 0 & 0 \\ -0,144 & -0,288 & -0,144 \end{pmatrix}$$

---

trebuie refăcut

10. Define an MLP for regression, having 3 inputs, one hidden layer of 2 units, with the sigmoid $\sigma(z) = \frac{1}{1+e^{-z}}$ activation function, and 1 output. We ignore bias terms for simplicity. Moreover, the loss function is the squared error loss, and is denoted as L. Compute symbolically $\frac{\partial L}{\partial \boldsymbol{W}^{(1)}}$. Note that the first intermediate variable is $\boldsymbol{z} = \boldsymbol{X}\boldsymbol{W}^{(1)}$ and not $\boldsymbol{z} = \boldsymbol{W}^{(1)}\boldsymbol{x}$, which means that you will have to deduce the equations in this new setting. Numerical application: $\boldsymbol{W}^{(1)} = \begin{bmatrix} 1 & 1 \\ 0 & -1 \\ 1 & 0 \end{bmatrix}, \boldsymbol{W}^{(2)} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \boldsymbol{X} = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 0 \end{bmatrix}, \boldsymbol{y} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$.

↑ target

$n = 2 \quad d = 3 \quad h = 2 \quad q = 1$

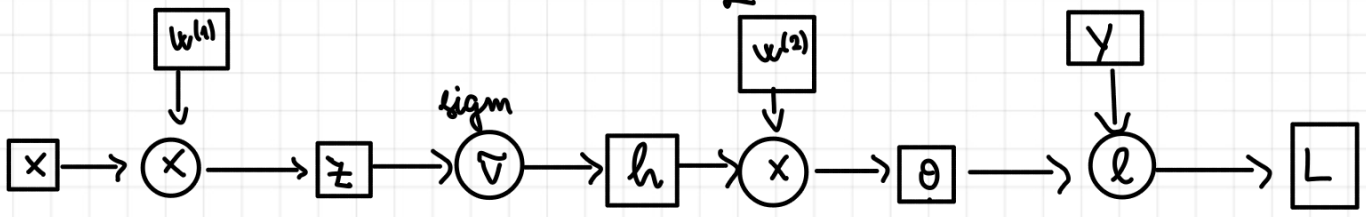

$Z = X W^{(1)} \in \mathbb{R}^{2\times 2}$

$h = \sigma(Z) \in \mathbb{R}^{2\times 2}$

$\Theta = h\, w^{(2)} \in \mathbb{R}^{2\times 1}$

$2\times 2 \quad 2\times 1$

$$\ell(\Theta, Y) = \frac{1}{2m} \mathrm{Tr}\left((\Theta - Y)^T (\Theta - Y)\right)$$

$d\times m \quad m\times h$

$$\frac{\partial L}{\partial W^{(1)}} = \frac{\partial L}{\partial Z} \cdot \frac{\partial Z}{\partial W^{(1)}} = \frac{\partial L}{\partial Z} \cdot \frac{\partial (X W^{(1)})}{\partial W^{(1)}} = X^T \frac{\partial L}{\partial Z}$$

$$\frac{\partial L}{\partial Z} = \frac{\partial L}{\partial h} \cdot \frac{\partial h}{\partial Z} = \frac{\partial L}{\partial h} \frac{\partial \sigma(Z)}{\partial Z} = \frac{\partial L}{\partial h} \odot \sigma'(Z)$$

$$\frac{\partial L}{\partial h} = \frac{\partial L}{\partial \Theta} \cdot \frac{\partial \Theta}{\partial h} = \frac{\partial L}{\partial \Theta} \cdot \frac{\partial (h \cdot w^{(2)})}{\partial h} = \frac{\partial L}{\partial \Theta} w^{(2)T}$$

$$\frac{\partial L}{\partial \Theta} = \frac{\partial}{\partial \Theta}\left(\frac{1}{2m} \mathrm{Tr}\left[(\Theta - Y)^T (\Theta - Y)\right]\right) = \frac{1}{2m} \cdot 2 (\Theta - Y) = \frac{1}{m}(\Theta - Y)$$

$$\frac{\partial L}{\partial W^{(1)}} = X^T \left[\left(\frac{1}{m} (\Theta - Y) \cdot w^{(2)T} \right) \odot \sigma'(\underbrace{XW^{(1)}}_{Z}) \right]$$

$$Z = X W^{(1)} = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & -1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ 0 & -1 \end{pmatrix}$$

$$h = \begin{pmatrix} \frac{1}{1+e^{-2}} & \frac{1}{1+e^{1}} \\ \frac{1}{1+e^{0}} & \frac{1}{1+e^{1}} \end{pmatrix} = \begin{pmatrix} 0,88 & 0,27 \\ 0,5 & 0,27 \end{pmatrix}$$

$$\theta = h\, w^{(2)} = \begin{pmatrix} 0,88 & 0,27 \\ 0,5 & 0,27 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0,27 \\ 0,27 \end{pmatrix}$$

$$\theta - y = \begin{pmatrix} 0,27 \\ 0,27 \end{pmatrix} - \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} -0,73 \\ 1,27 \end{pmatrix}$$

$$(\theta - y)\, w^{2T} = \begin{pmatrix} -0,73 \\ 1,27 \end{pmatrix} \begin{pmatrix} 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & -0,73 \\ 0 & 1,27 \end{pmatrix}$$

$$\frac{\partial L}{\partial w^{(1)}} = \frac{1}{2} \begin{pmatrix} 1 & 0 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \left[\begin{pmatrix} 0 & -0,73 \\ 0 & 1,27 \end{pmatrix} \odot \begin{pmatrix} 0,1 & 0,2 \\ 0,25 & 0,2 \end{pmatrix} \right] =$$

$$= \frac{1}{2} \begin{pmatrix} 1 & 0 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & -0,146 \\ 0 & 0,254 \end{pmatrix} =$$

$$= \frac{1}{2} \begin{pmatrix} 0 & -0,146 \\ 0 & 0,038 \\ 0 & -0,146 \end{pmatrix} = \begin{pmatrix} 0 & 0,073 \\ 0 & 0,019 \\ 0 & 0,073 \end{pmatrix}$$