

SĂPTĂMÂNA 6

Date de intrare, analiza rezultatelor, validare

Modelare și Simulare · Anul III, Calculatoare și Tehnologia Informației

Ș.l. dr. ing. Cătălin Iapă

Unde am rămas

- ✓ Un motor DES de ~40 de linii reproduce formulele M/M/1, M/M/c și Erlang C (S5)
- ✓ SimPy: procese, resurse, cozi – intersecția, linia de producție, urgențele
- ✓ Parcarea lui Holban: datele din curs dădeau o ocupare de ~4 locuri din 70 – **datele** erau problema, nu modelul
- ✓ Întrebarea de final: simulatorul a dat **W = 10,56** în loc de 10. Eroare sau zgomot statistic?

La finalul acestei săptămâni veți putea…

1. să transformați **date brute** într-o distribuție de intrare: histogramă, estimare, grafic Q-Q, teste de potrivire
2. să modelați **sosiri dependente de timp** (proces Poisson neomogen) și să le generați prin subțiere
3. să identificați **perioada de încălzire** (metoda Welch) și să raportați rezultate cu **intervale de încredere**
4. să alegeți numărul de **replicări**, să folosiți **medii pe loturi** și să comparați variante cu **numere aleatoare comune**
5. să distingeți **verificarea** de **validare** și să aplicați tehnici concrete pentru fiecare
6. să faceți **analize de sensibilitate**, experimente factoriale și să asigurați **reproductibilitatea**

Simularea ca lanț: cât de tare este cea mai slabă verigă?

1 Date de intrare

Distribuțiile sosirilor, ale timpilor de servire, ale defectărilor. **Ora 1**.

2 Modelul

Logica sistemului, implementată corect în cod. Verificare – **ora 3**.

3 Rezultatele

Estimări statistice, cu erorile lor. Analiza ieșirilor – **ora 2**.

4 Decizia

Are sens să acționăm pe baza modelului? Validare și încredere – **ora 3**.

Garbage in, garbage out: un simulator perfect alimentat cu distribuții greșite dă răspunsuri greșite, dar foarte precise. O singură rulare interpretată ca adevăr absolut este la fel de periculoasă ca un model greșit.

Ora 1

Modelarea datelor de intrare

1. Pașii: de la date brute la o distribuție
2. Un exemplu istoric: măsurătorile lui Cavendish
3. Potrivirea distribuțiilor: MLE, Q-Q, Kolmogorov–Smirnov, χ^2
4. Sosiri care depind de oră: procesul Poisson neomogen

De la date brute la o distribuție de intrare

Procesul clasic (Law; Banks et al.; Holban cap. 4):

1 — Colectare

loguri, senzori, cronometrări; **ce** măsurăm, **cât** timp, în ce condiții

2 — Explorare

histogramă, medie, mediană, Cs^2, valori suspecte, tendințe în timp

3 — Familia

alegem candidați: din fizica procesului și din forma histogramei

4 — Parametrii

estimare prin **verosimilitate maximă** (MLE) sau prin momente

5 — Potrivire

grafic Q-Q, teste **KS** și **χ^2**, AIC; dacă nu merge, înapoi la pasul 3

Alternativa fără familie teoretică: **distribuția empirică** – eșantionăm direct din date (reeșantionare). Simplă și fidelă datelor, dar nu produce niciodată valori în afara celor observate.

De unde vin datele de intrare

- **Loguri** de sistem: timpi de răspuns, momente de sosire a cererilor, cozi de mesaje – de obicei abundente
- **Măsurători directe**: cronometrarea ghișeelor, senzori în trafic, fișe de lucru din producție
- **Date istorice** agregate: numărul de clienți pe oră, pe zi – utile pentru rate, nu pentru distribuții
- **Estimări ale experților**: când sistemul nu există încă (proiectare) sau datele sunt inaccesibile
- **Literatura** și standardele: distribuții tipice pentru defectări, apeluri, trafic de rețea

L **Regula lui Law**

Colectați date despre **mărimile de intrare** (sosiri, serviri), nu doar despre ieșiri. Ieșirile se păstrează separat, pentru **validare**.

Capcane la colectarea datelor

1 Unități și rotunjiri

Timpi notați la minut întreg: multe zerouri false și o distribuție „în trepte”.

2 Perioade amestecate

Date de la ora de vârf și de noapte puse la un loc: o distribuție falsă, cu variabilitate exagerată.

3 Date cenzurate

Clienții care au renunțat nu au timp de servire; ignorarea lor subestimează cererea.

4 Măsurăm ce e ușor

Timpul de la ghișeu, nu cel de la intrarea în bancă; sosirile la coadă, nu cele respinse.

5 Efectul observatorului

Angajații cronometrați lucrează altfel (efectul Hawthorne).

6 Valori aberante

Erori de transcriere, senzori defecți – sau evenimente rare, dar reale. Se verifică, nu se șterg automat.

Un exemplu istoric (Holban, cap. 4)

Densitatea Pământului: Cavendish, 1798

1. 29 de măsurători cu balanța de torsiune
2. Histogramă, medie, mediană, abatere standard
3. Graficul Q-Q și valorile suspecte
4. Erori în materialele de curs: o lecție de verificare

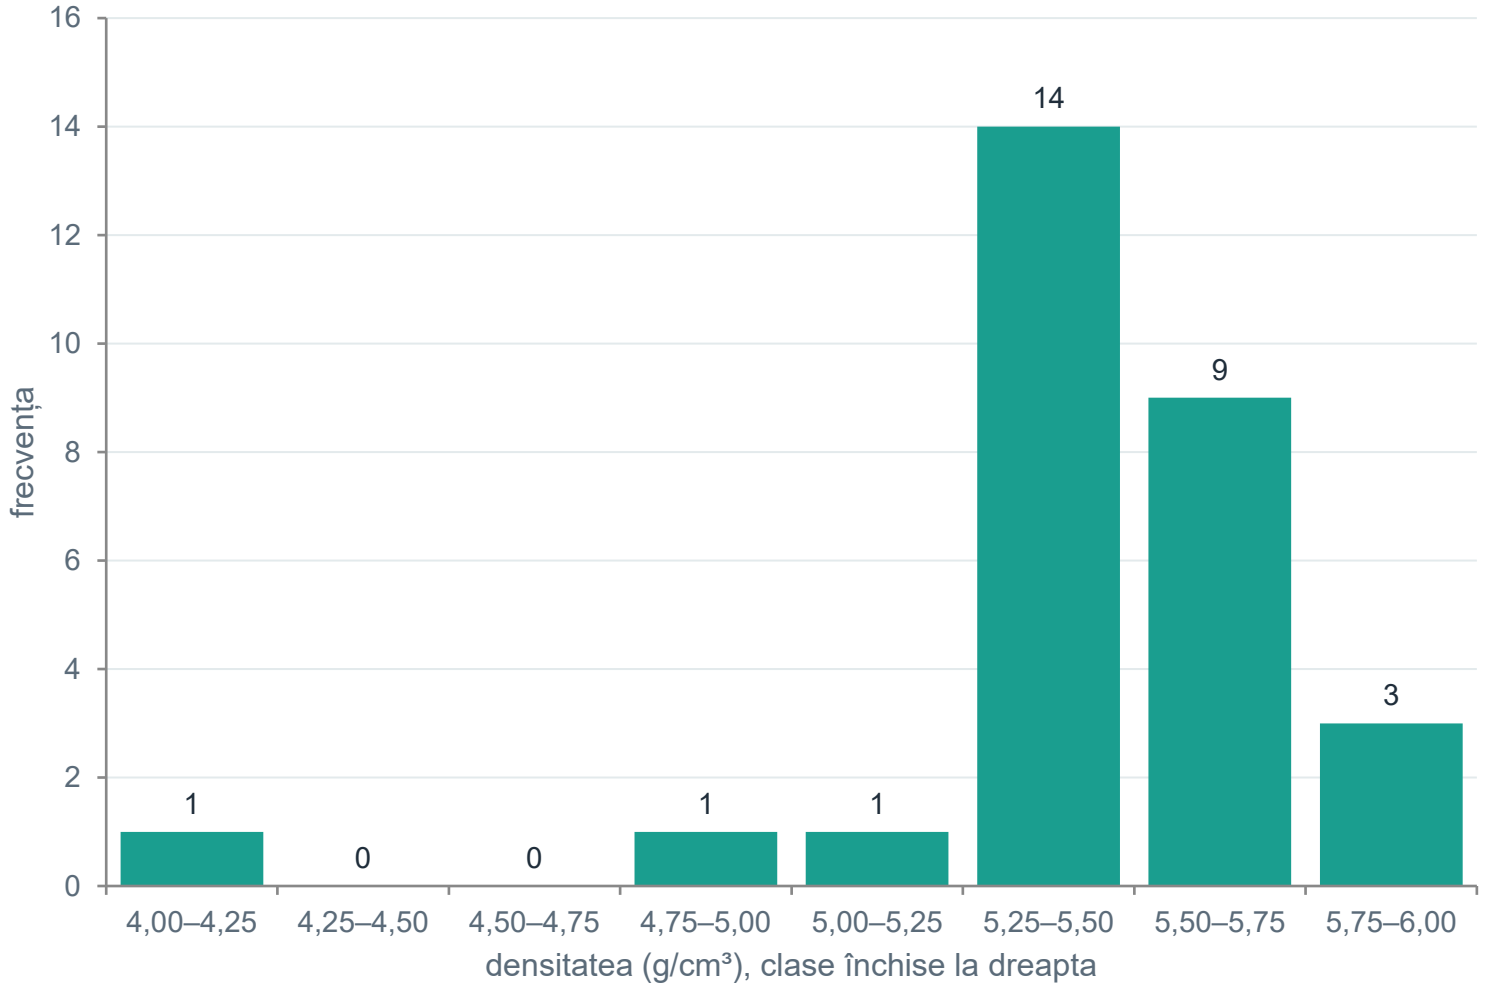
Datele: 29 de măsurători (g/cm³)

- 4,07 · 4,88 · 5,10 · 5,26 · 5,27 · 5,29 · 5,29 · 5,30 · 5,34 · 5,34
- 5,36 · 5,39 · 5,42 · 5,44 · 5,46 · 5,47 · 5,50 · 5,53 · 5,55 · 5,57
- 5,58 · 5,61 · 5,62 · 5,63 · 5,65 · 5,75 · 5,79 · 5,85 · 5,86
- Aceeași mărime, măsurată de 29 de ori, dă **29 de valori diferite**: erori de măsurare, curenți de aer, temperatură
- Densitatea este deci tratată ca o **variabilă aleatoare** X; valorile sunt un **eșantion** $x_1, \ldots, x_{29}$

Valoarea de azi

Densitatea medie a Pământului este ≈ **5,51 g/cm³**. Apa are 1 g/cm³, granitul ≈ 2,7 g/cm³ – deci interiorul Pământului este mult mai dens decât scoarța.

Histograma: clase de lățime 0,25



- **23 din 29** de valori între 5,25 și 5,75
- Două valori izolate la stânga: **4,07** și **4,88**
- Frecvența relativă = frecvența / n; aria totală a histogramei normalizate = 1
- Lățimea clasei schimbă forma: încercați 0,1 și 0,5

Statistici descriptive

Statistica	Toate (n = 29)	Fără 4,07 și 4,88	Robustă?
Media $\bar{x}$	5,420	5,490	nu
Mediana	5,46	5,47	**da**
Abaterea standard s (n − 1)	0,339	0,193	nu
Abaterea standard cu 1/n	0,333	–	nu
P(X ≤ 5,5) empirică	17/29 = 0,586	–	–

- Două valori din 29 mută media cu 0,07 și **aproape dublează** abaterea standard; mediana se mișcă doar cu 0,01
- Media fără valorile suspecte, **5,49**, este foarte aproape de valoarea acceptată, 5,51

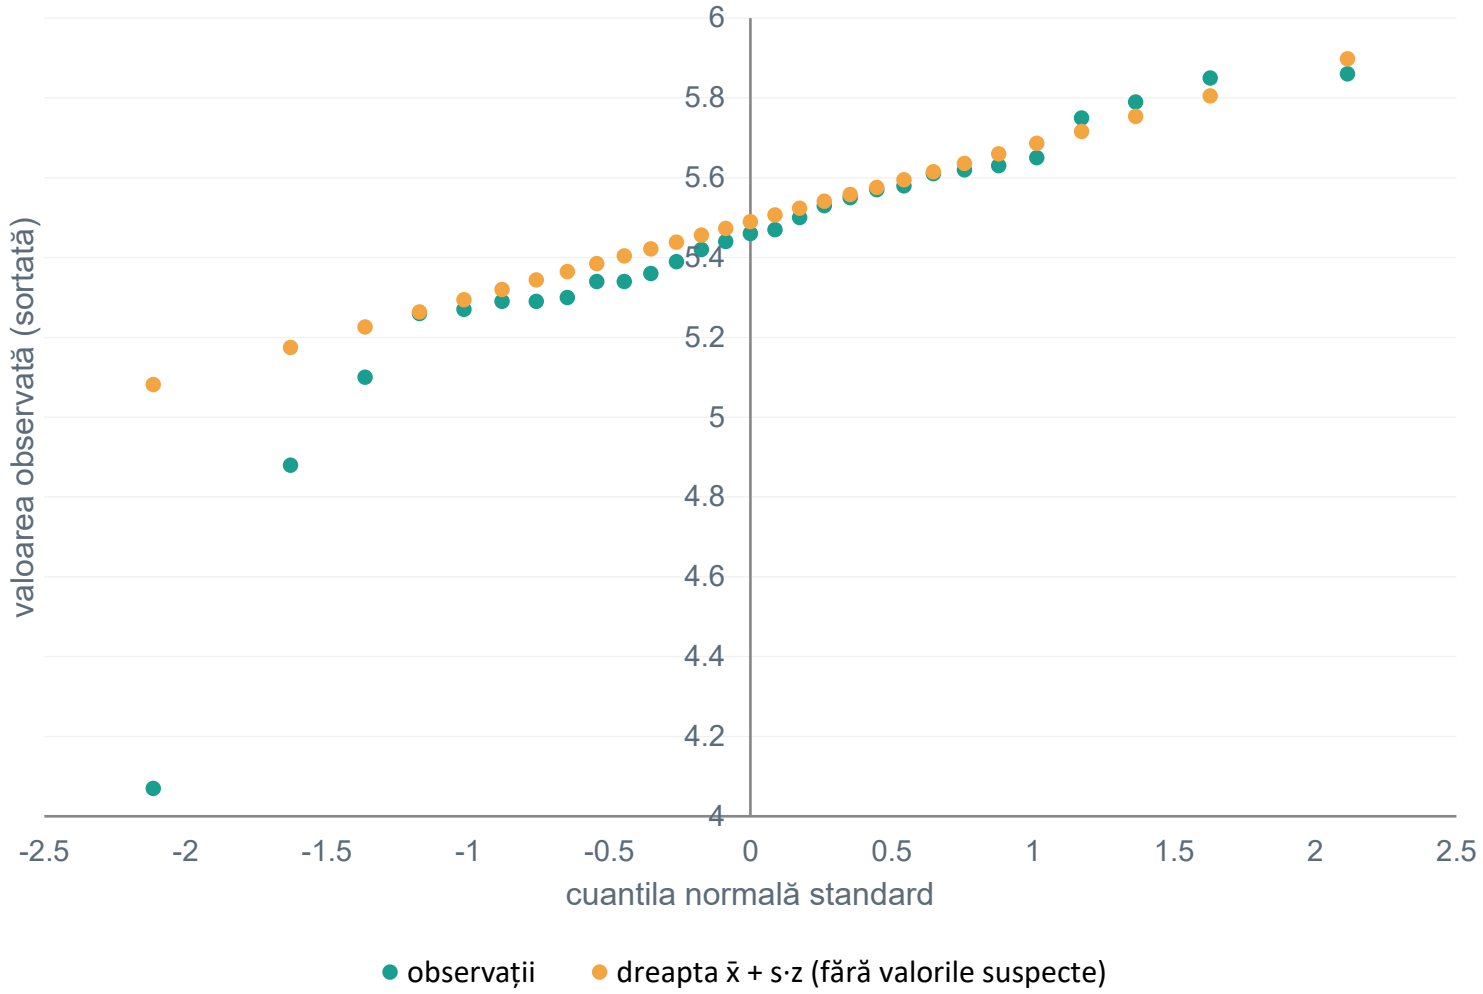
Media și dispersia de selecție

$$\bar{x} = (1/n)\cdot\Sigma\, x_i \qquad s^2 = (1/(n-1))\cdot\Sigma\,(x_i - \bar{x})^2$$

n − 1	pentru că x̄ este calculat din aceleași date, abaterile sunt sistematic puțin mai mici; împărțirea la n − 1 face estimatorul **nedeplasat**
exemplul Holban	valorile 35, 47, 48, 50, 51, 53, 54, 70, 75: x̄ = **53,67**, $\Sigma(x_i - \bar{x})^2$ = 1 168, s = **12,08** (cu n − 1) sau 11,39 (cu 1/n)
eroare	în curs media apare ca 67 (corect: 53,67), iar formula e scrisă cu 1/n, deși 12,08 este calculat cu n − 1

Pentru n mare diferența dintre n și n − 1 este neglijabilă. Contează la eșantioane mici – exact cazul replicărilor din ora 2, unde avem adesea 5–30 de valori.

Graficul Q-Q față de distribuția normală



- Punctul i: cuantila teoretică de ordin (i − 0,5)/n vs a i-a valoare sortată
- Puncte pe o dreaptă = distribuția **se potrivește**
- Mijlocul datelor: aproape liniar → **normală** plauzibilă
- Cele două puncte din stânga se abat clar: **valori suspecte**

Valorile 4,07 și 4,88: ce facem cu ele?

Investigăm

- erori de transcriere? (vezi slide-ul următor)
- o măsurătoare făcută înainte de o modificare a aparatului?
- o cauză fizică reală, care trebuie modelată?
- criterii formale: distanța față de mediană în abateri robuste

Decidem și documentăm

- fără ele: $\bar{x} = 5{,}490$, $s = 0{,}193$
- interval de încredere 95%: [5,41; 5,57]
- intervalul conține valoarea modernă, **5,51**
- raportăm **ambele** variante și motivul excluderii

Regula: o valoare aberantă se elimină doar cu un motiv documentat. În simulare, valorile extreme reale (o defectare rară, un client foarte lent) sunt adesea exact cele care produc cozile lungi.

Erori găsite în materialele vechi: verificați calculele!

Unde	Ce apare în curs	Valoarea corectă
Lista nesortată vs sortată	5,88 în lista inițială, 4,88 în lista sortată	una dintre ele e greșită; cu 4,88: $\bar{x}$ = 5,42
Probabilitatea cumulată	P(densitate < 5,5) = 0,677	17/29 = **0,586** (clase închise la dreapta)
Aria clasei 5,75–6	0,02586	3/29 = **0,1034**
Exemplul cu 9 valori	media = 67	**53,67**
Exemplul cu 4 eșantioane	Σ pătrate = 128,34; eroarea standard 3,77	128,75; **3,28** – detalii în ora 2

- Asemenea greșeli apar în orice material scris de mână sau transcris; un script de 10 linii le găsește imediat
- Aceeași disciplină se aplică datelor de intrare: **recalculați** din datele brute, nu copiați rezumate

Verificare

? Eliminăm cele două valori suspecte din datele lui Cavendish. Care statistică se schimbă **cel mai puțin**?

A media

B mediana

C abaterea standard

D amplitudinea (max − min)

Potrivirea distribuțiilor

Timpii de răspuns ai unui serviciu web

1. 500 de timpi de servire dintr-un log
2. Familii candidate: exponențială, gamma, lognormală
3. Estimare MLE, grafice Q-Q, teste KS și χ^2, AIC
4. Cât costă o distribuție greșită?

Explorarea datelor: 500 de timpi de servire (ms)

Statistica	Valoarea	Ce ne spune
Media	95,9	ordinul de mărime: ~0,1 s pe cerere
Mediana	56,8	mult sub medie: distribuție **asimetrică la dreapta**
Abaterea standard	141,1	mai mare decât media
$Cs^2 = s^2/\bar{x}^2$	**2,17**	pentru exponențială ar fi 1; aici e **dublu**
p95 / maxim	271 / 1 745	coadă lungă: câteva cereri de peste 1 s

- Primele valori din log: 34,4; 21,1; 175,4; 19,6; 10,2; 116,8; 140,7; 23,5 …
- $Cs^2 > 1$ exclude practic exponențiala și Erlang; candidați naturali: **lognormala**, gamma cu formă < 1, Weibull, hiperexponențiala

Familii candidate și de unde vin

1 Exponențială

Fără memorie; timpi între evenimente independente rare. $Cs^2 = 1$.

2 Gamma / Erlang

Suma a k faze exponențiale; $Cs^2 = 1/k$. Gamma generalizează la k real.

3 Lognormală

Produsul multor factori independenți; coadă lungă. Tipică pentru timpi de răspuns și dimensiuni de fișiere.

4 Weibull

Durate de viață: rata de defectare crește sau scade în timp.

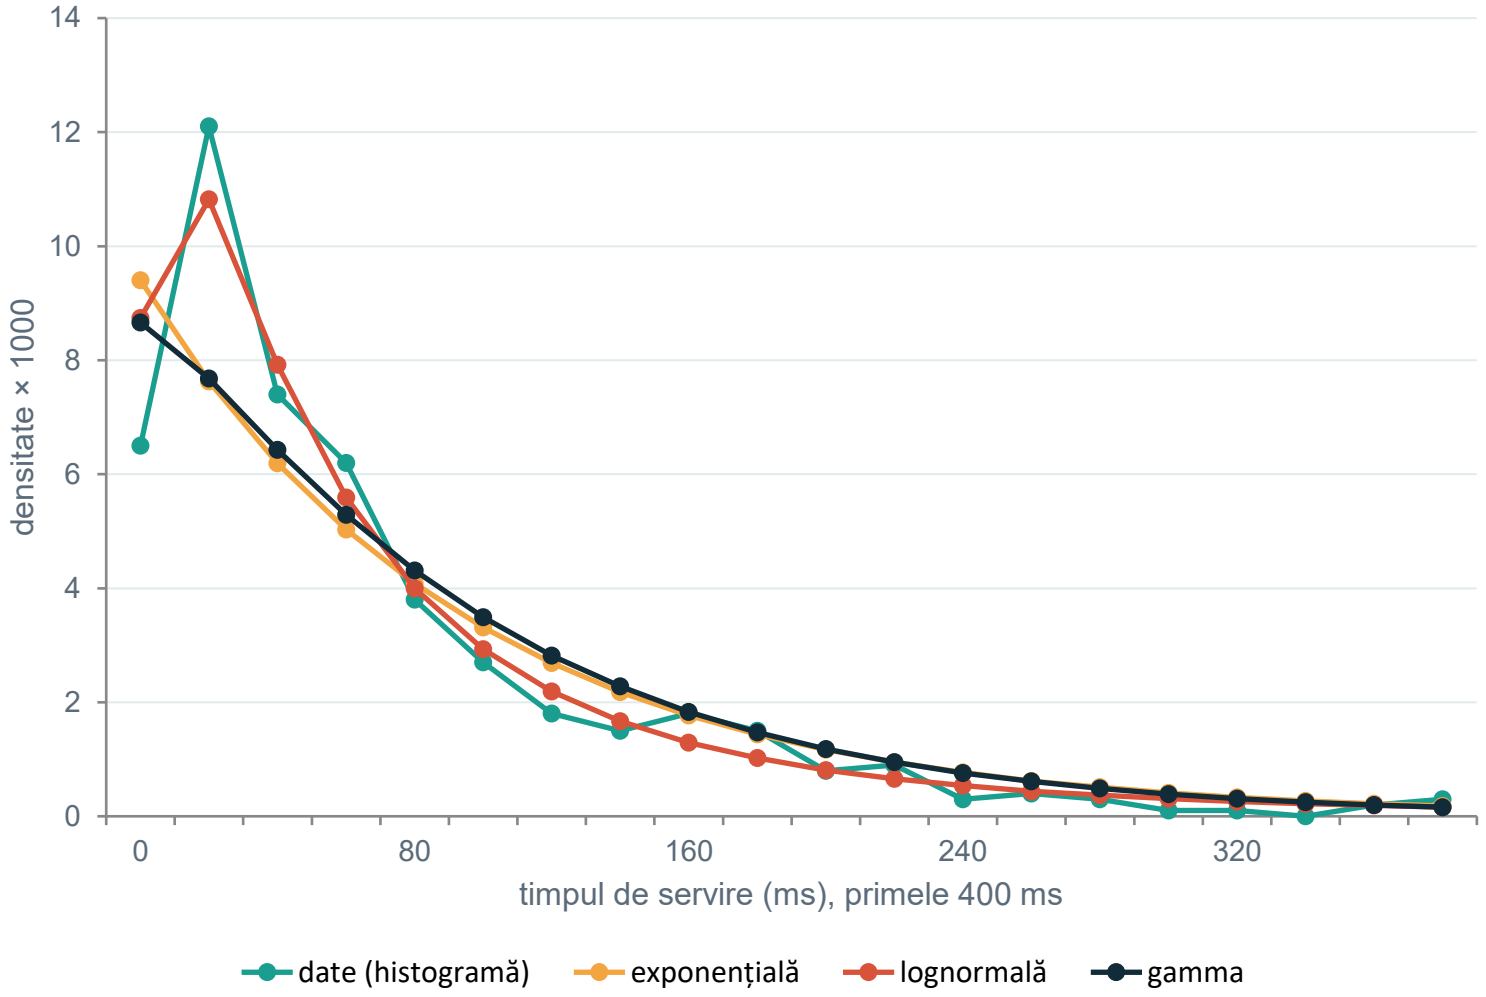
5 Normală

Suma multor efecte mici; simetrică. Poate da valori negative – atenție la timpi!

6 Triunghiulară / PERT

Fără date: minim, valoare probabilă, maxim – estimate de experți.

Histograma vs trei distribuții ajustate



- Datele au un **maxim** în jur de 50 ms
- Exponențiala are maximul în 0: prea multe cereri foarte scurte
- Gamma cu formă ≈ 1,1 seamănă aproape cu exponențiala
- **Lognormala** urmărește forma datelor

Estimarea parametrilor: verosimilitatea maximă (MLE)

$$\hat{\theta} = \arg\max \ln L(\theta) = \arg\max \sum \ln f(x_i; \theta)$$

ideea	alegem parametrii care fac datele observate **cele mai probabile**
Exp	$\hat{\lambda} = 1/\bar{x} = 0{,}01043$ pe ms (media 95,9 ms)
LogN	$\hat{\mu}$ și $\hat{\sigma}$ = media și abaterea standard ale lui $\ln x_i$: $\hat{\mu} = 4{,}044$, $\hat{\sigma} = 0{,}999$
Gamma	fără formulă închisă; numeric: formă $\hat{\alpha} = 1{,}10$, scală 87,2 ms

MLE are proprietăți bune pentru eșantioane mari (consistență, eficiență) și este metoda implicită în scipy.stats (metoda fit).

Metoda momentelor vs verosimilitatea maximă (gamma)

Metoda momentelor

- egalăm media și dispersia teoretice cu cele din date
- formă a = $\bar{x}^2/s^2$, scală = $s^2/\bar{x}$
- aici: a = **0,462**, scală = 207,6 ms
- simplă, dar sensibilă la valorile mari

vs

Verosimilitate maximă

- maximizăm Σ ln f(x_i; a, scală)
- folosește **toată** forma distribuției
- aici: a = **1,10**, scală = 87,2 ms
- metoda implicită în software

Diagnostic util: când două metode rezonabile dau parametri **foarte diferiți** (formă 0,46 vs 1,10), familia probabil nu se potrivește datelor. Pentru date cu adevărat gamma, cele două estimări ar fi apropiate.

Potrivirea în Python: scipy.stats

```
import numpy as np
from scipy import stats

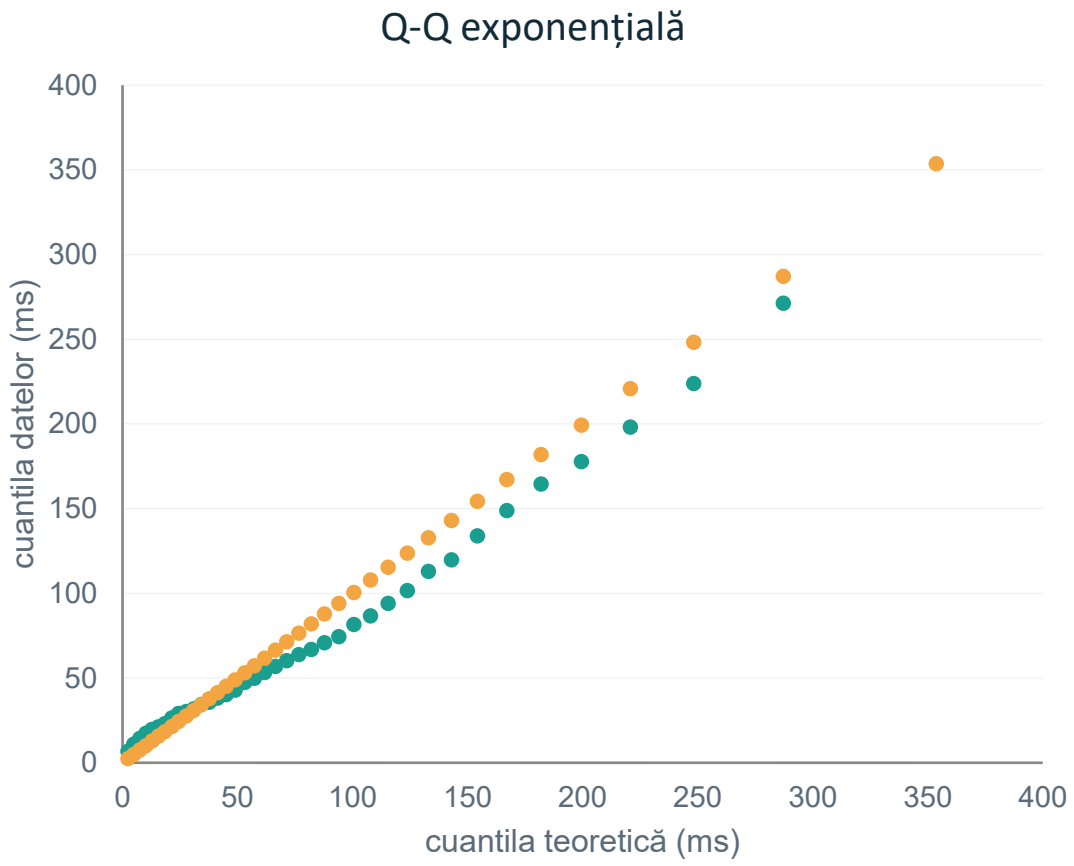
x = np.loadtxt("api_times.txt")          # 500 de valori, ms

cand = {"exp":   stats.expon(*stats.expon.fit(x, floc=0)),
        "logn":  stats.lognorm(*stats.lognorm.fit(x, floc=0)),
        "gamma": stats.gamma(*stats.gamma.fit(x, floc=0))}

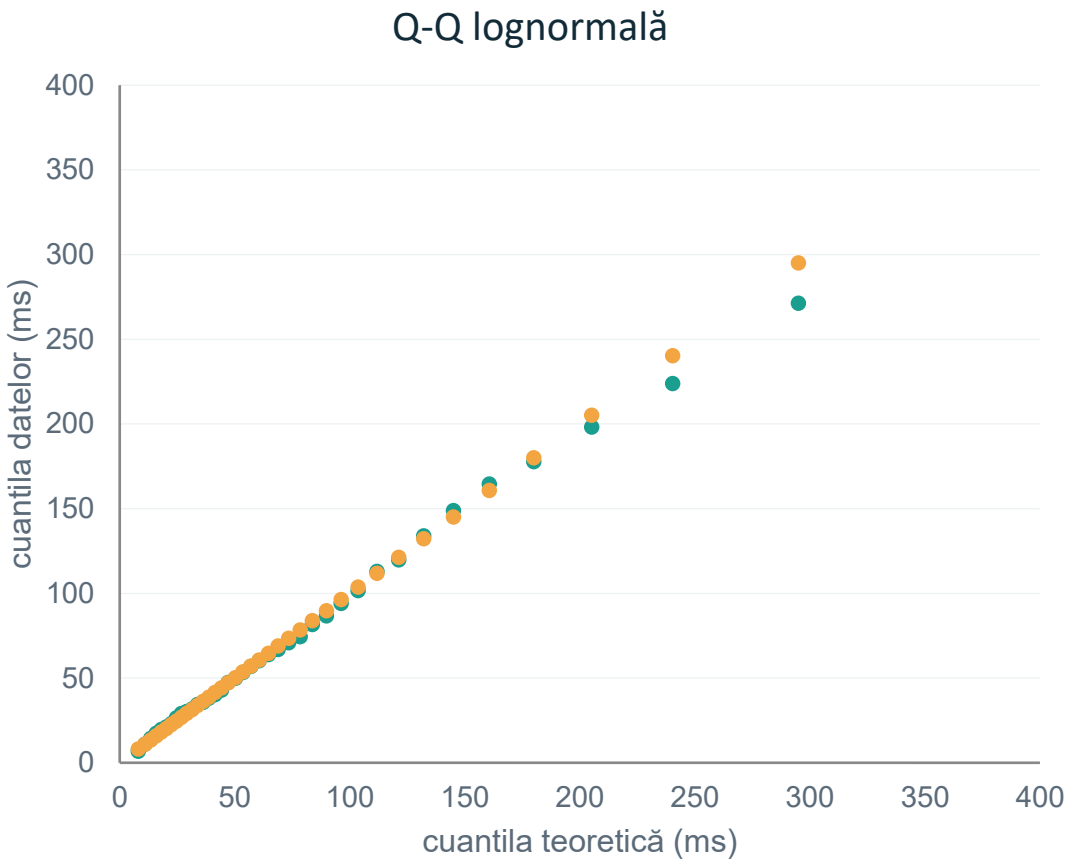
for name, d in cand.items():
    ks = stats.kstest(x, d.cdf)
    aic = 2 * (len(d.args) - 1) - 2 * d.logpdf(x).sum()
    print(name, round(ks.statistic, 3),
          round(ks.pvalue, 4), round(aic, 1))
```

- fit = estimare **MLE**
- floc=0: fixăm originea în 0 (timpi pozitivi)
- kstest: statistica D și p-valoarea
- AIC: penalizează parametrii în plus

Grafice Q-Q: exponențială vs lognormală



punctele se curbează: **forma** e greșită



punctele stau pe diagonală: **potrivire bună**

Testul Kolmogorov–Smirnov

$$D = \max |F_n(x) - F(x)|$$

Distanța maximă dintre **funcția de repartiție empirică** F_n (o scară cu trepte de 1/n) și funcția de repartiție teoretică F. Ipoteza nulă H_0: datele provin din F.

Law, 2015; Banks et al., 2010

- Respingem H_0 dacă D depășește valoarea critică; pentru n mare și $\alpha = 5\%$: aproximativ **1,36/√n** (aici 0,061)
- Folosește toate valorile, fără clase; sensibil mai ales la **mijlocul** distribuției
- Atenție: dacă parametrii sunt estimați din aceleași date, p-valoarea standard este **prea optimistă** (corecția Lilliefors sau bootstrap)

Testul χ^2 de potrivire

$$\chi^2 = \Sigma\,(O_i - E_i)^2 / E_i, \quad \text{grade de libertate} = k - 1 - p$$

O_i, E_i	frecvențele observate și cele așteptate în clasa i, sub distribuția ajustată
k, p	numărul de clase și numărul de parametri estimați din date
clasele	recomandat **echiprobabile** (E_i egale) și $E_i \geq 5$; aici k = 10 clase cu câte 50 de valori așteptate

Dezavantaj: rezultatul depinde de alegerea claselor. Avantaj: funcționează și pentru distribuții discrete (de exemplu numărul de sosiri pe interval – îl folosim la sfârșitul orei).

Rezultatele: cine câștigă?

Distribuția	KS: D	KS: p	χ^2	gl	χ^2: p	AIC
Exponențială	0,086	0,0012	48,0	8	< 0,001	5 565
Gamma	0,097	0,0002	46,6	7	< 0,001	5 564
Lognormală	**0,026**	**0,87**	**3,5**	7	**0,84**	**5 466**

- Exponențiala și gamma sunt **respinse** de ambele teste ($p < 0,01$); lognormala nu este respinsă ($p \approx 0,87$ și 0,84)
- AIC mai mic = mai bine: lognormala câștigă cu ~100 de unități – o diferență uriașă (peste 10 este deja decisivă)

Cum citim p-valoarea (și ce nu înseamnă)

- p mică (sub 0,05): datele sunt **improbabile** dacă H_0 ar fi adevărată → respingem distribuția
- p mare **nu dovedește** că distribuția este corectă: doar că datele nu o contrazic
- Cu **puține date** (n = 20) aproape orice distribuție trece testele; cu **foarte multe** ($n = 10^6$) aproape oricare este respinsă
- Testele răspund la „se potrivește exact?”; în simulare ne interesează „este **suficient de bună** pentru decizie?”
- Ordinea recomandată: **grafice** (histogramă, Q-Q) → teste → comparație cu AIC → **impactul** asupra rezultatelor

P **Pragmatic**

Dacă două distribuții dau aceleași rezultate ale simulării, alegerea dintre ele nu contează. Dacă dau rezultate diferite, **acolo** merită investit în date.

Verificare

? Testul KS pentru lognormală dă **p = 0,87**. Ce putem concluziona?

A datele sunt sigur lognormale

B datele nu contrazic lognormala; o putem folosi, cu verificarea impactului

C lognormala este respinsă la nivelul de 5%

D trebuie să folosim distribuția empirică

Cât costă distribuția greșită? Serverul la ρ = 0,8

383 ms

așteptarea medie în coadă dacă presupunem **exponențiala** ($Cs^2 = 1$)

607 ms

așteptarea cu variabilitatea **reală** a datelor ($Cs^2 = 2{,}17$)

−37%

eroarea modelului exponențial: subestimăm așteptarea cu peste o treime

- Aceeași medie a servirii, aceeași rată de sosire – doar **forma** distribuției diferă
- Verificare prin simulare (200 000 de cereri): 380 ms cu exponențiala vs 568 ms cu reeșantionare din date

Legătura cu S4: formula Pollaczek–Khinchine

$$Wq = \rho \cdot (1 + Cs^2) / (2 \cdot (1 - \rho)) \cdot s$$

s, Cs²	media și coeficientul de variație la pătrat ale servirii (din date: 95,9 ms și 2,17)
ρ = 0,8	factorul $(1 + Cs^2)/2$ este 1 pentru exponențială și **1,58** pentru datele noastre
concluzia	pentru media așteptării contează doar **primele două momente**; pentru percentile contează toată forma

Dacă sosirile nu sunt Poisson, apare și variabilitatea sosirilor, C_a^2 (aproximația Kingman): $Wq \approx \rho/(1 - \rho) \cdot (C_a^2 + Cs^2)/2 \cdot s$. Ambele variabilități trebuie măsurate din date.

Distribuție teoretică sau empirică?

Distribuție teoretică

- netezește zgomotul din date
- poate genera valori **dincolo** de cele observate
- câțiva parametri: ușor de modificat în scenarii („+10% la medie”)
- riscul: familia greșită

Distribuție empirică

- reeșantionare: rng.choice(date)
- reproduce exact forma, inclusiv vârfuri ciudate
- nu generează **niciodată** valori mai mari decât maximul observat
- riscul: puține date, cozile subestimate

Compromisul: distribuția empirică **interpolată** (liniar între valorile sortate), eventual cu o coadă teoretică (de ex. exponențială) peste un prag înalt. Cu 500 de valori, empirica este de obicei o alegere rezonabilă.

Fără date: distribuții din opinia experților

- Sistemul nu există încă (o fabrică nouă, un serviciu nelansat) sau datele sunt inaccesibile
- **Uniformă (a, b)**: știm doar limitele – maximă incertitudine între ele
- **Triunghiulară (a, m, b)**: minim, valoarea cea mai probabilă, maxim – ușor de cerut unui expert
- **PERT (beta)**: aceleași trei valori, formă mai netedă; media ≈ (a + 4m + b)/6
- Experții subestimează sistematic **variabilitatea** și cozile: cereți și „cel mai rău caz din ultimul an”

Obligatoriu

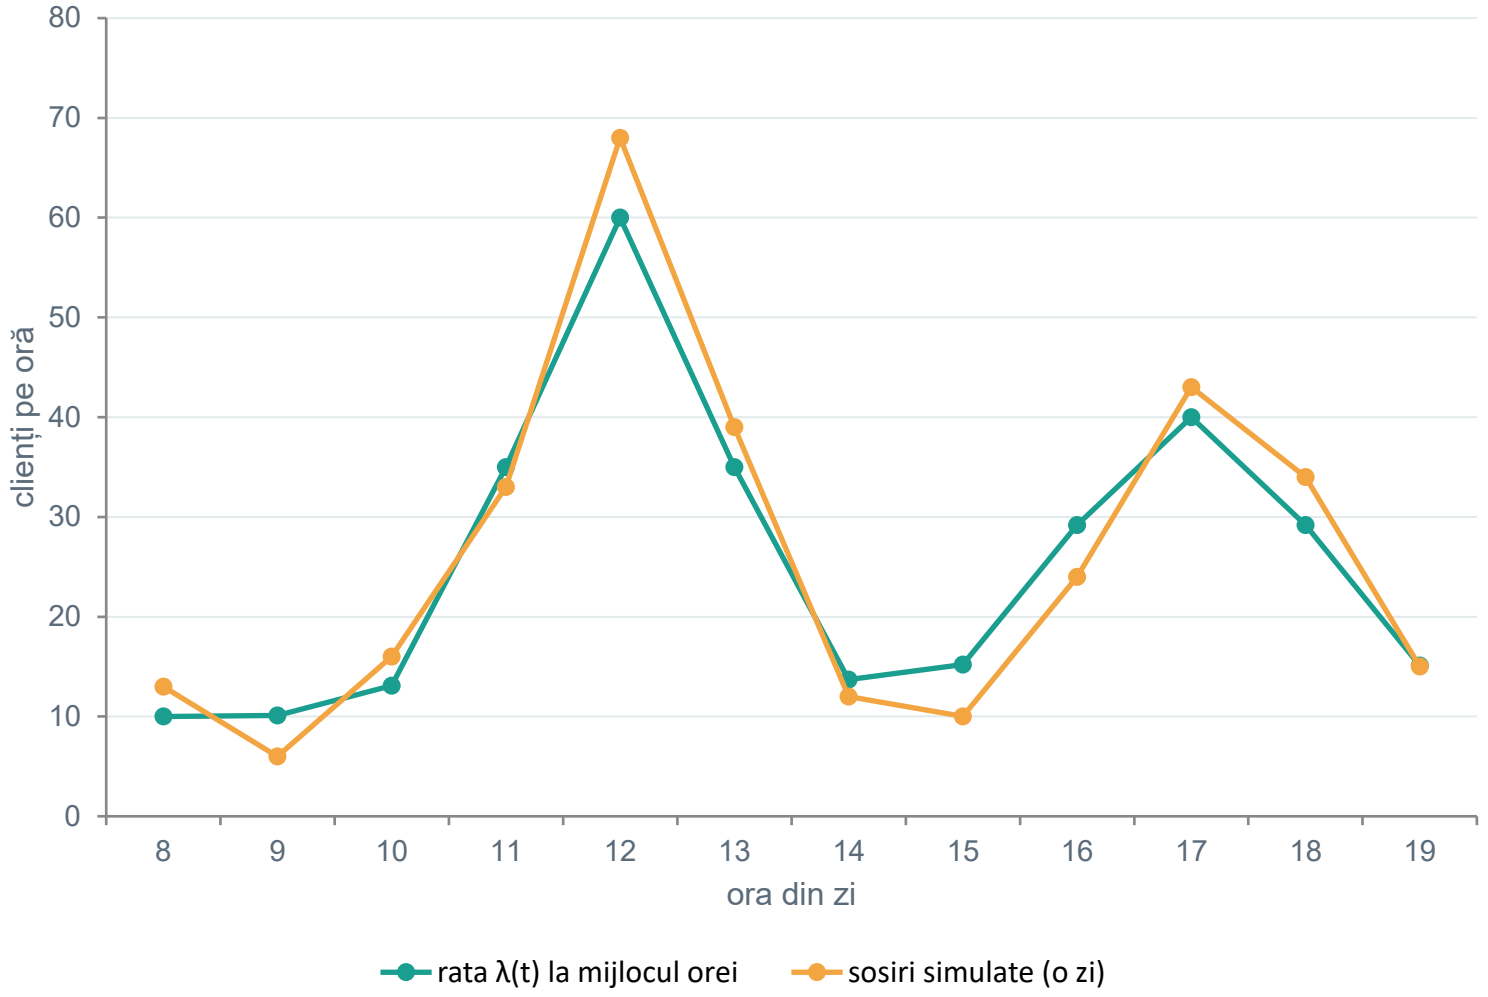
Când intrările vin din opinii, **analiza de sensibilitate** (ora 3) nu este opțională: aflăm dacă decizia se schimbă când modificăm presupunerile.

Sosiri dependente de timp

Rata sosirilor se schimbă pe parcursul zilei

1. Procesul Poisson neomogen (NHPP)
2. Generarea prin subțiere (Lewis–Shedler)
3. Test: sunt sosirile Poisson pe toată ziua? Dar într-o oră?
4. Legătura cu „intervalele orare” din laborator

O zi la ghișeu: rata λ(t) și sosirile simulate pe ore



- Vârf la **prânz** (~60/oră) și unul **după program** (~40/oră)
- Dimineața: doar ~10 clienți pe oră
- O zi: **313** de sosiri (în medie 305)
- O rată medie constantă ar ascunde complet vârfurile

Procesul Poisson neomogen (NHPP)

Rata λ(t) variază în timp

Numărul de sosiri într-un interval [a, b] are distribuția Poisson cu media $\Lambda(a, b) = \int_a^b \lambda(t)\, dt$, iar numerele de sosiri din intervale disjuncte sunt **independente**.

Law, 2015; Lewis & Shedler, 1979

- Local, pe intervale scurte, se comportă ca un proces Poisson obișnuit
- Timpii dintre sosiri **nu** mai sunt exponențiali cu aceeași rată: nu putem genera cu Exp(λ) fix
- Estimare simplă: rata pe fiecare interval de 15–60 de minute, mediată pe mai multe zile (funcție în trepte)
- Exemplu: la prânz Λ(12:00, 13:00) ≈ 57 de clienți; dimineața, între 8 și 9, doar ≈ 10 – aceeași zi, rate de 6 ori diferite

Generarea prin subțiere (thinning)

```
def nhpp(rate, lam_max, T, rng):
    """Sosiri pe [0, T] cu rata rate(t) <= lam_max."""
    t, out = 0.0, []
    while True:
        t += rng.exponential(1 / lam_max)   # candidat
        if t > T:
            return out
        if rng.random() < rate(t) / lam_max:
            out.append(t)                   # acceptat

# rata la prânz: 60/h; lam_max = 62/h
sosiri = nhpp(rate, 62.0, 12.0, rng)
```

- Generăm un proces Poisson **omogen** cu rata maximă
- Păstrăm fiecare candidat cu probabilitatea **λ(t)/λmax**
- Aici se acceptă 42% din candidați
- Corect pentru orice λ(t) mărginită (Lewis–Shedler)

Sunt sosirile Poisson? Sosiri pe intervale de 10 minute, 30 de zile

Setul de intervale	Media	Dispersia	Dispersie / medie	Test χ^2 Poisson
Toată ziua (8–20)	4,23	10,27	**2,43**	$\chi^2 = 2\,096$, $p < 0{,}001$
Doar 12:00–13:00	9,70	8,23	**0,85**	$\chi^2 = 7{,}6$, $p = 0{,}67$

- Pentru Poisson, **dispersia = media** (indicele de dispersie = 1). Pe toată ziua raportul este 2,4: amestecul de ore liniștite și ore de vârf **nu** este un singur proces Poisson
- În interiorul unei ore raportul este aproape de 1 și testul nu respinge: modelăm ziua pe **intervale orare**, fiecare cu rata ei – exact ideea din laborator

Alte structuri în datele de intrare

- **Sezonalitate**: ora din zi, ziua din săptămână, sărbători – rata depinde de calendar
- **Corelații**: timpi de servire consecutivi corelați (același operator obosit, cereri similare în rafală)
- **Rafale**: traficul de rețea alternează perioade calme și agitate (proces Poisson modulat Markov, MMPP)
- **Dependențe între variabile**: comenzi mari au și timp de procesare mare – nu le generăm independent
- **Simulare ghidată de urme** (trace-driven): folosim chiar secvența reală de sosiri – ideal pentru validare

V **Verificare rapidă**

Graficul valorilor în **ordinea timpului** și corelația dintre valori consecutive: două minute de lucru care evită un model complet greșit.

Media și dispersia „din mers”: algoritmul Welford

```
class Running:
    """Media și dispersia fără a păstra datele."""
    def __init__(self):
        self.n, self.mean, self.m2 = 0, 0.0, 0.0

    def add(self, x):
        self.n += 1
        d = x - self.mean
        self.mean += d / self.n
        self.m2 += d * (x - self.mean)

    def var(self):              # s², cu n − 1
        return self.m2 / (self.n - 1)
```

- Folosit în loguri uriașe și **în interiorul** simulatorului
- Memorie O(1): nu păstrăm milioane de valori
- Formula „naivă” $\Sigma x^2 - n\cdot\bar{x}^2$ pierde precizie (anulare catastrofală)
- Exercițiul 4 din foaia Cambridge

Rezumatul orei 1

- ✓ Pași: colectare → explorare → familie → parametri (**MLE**) → potrivire (**Q-Q**, KS, χ^2, AIC)
- ✓ Cavendish: mediana e robustă, valorile suspecte se investighează; **recalculați** orice rezumat
- ✓ API: $Cs^2 = 2{,}2$ → lognormala câștigă; exponențiala subestimează așteptarea cu **~37%**
- ✓ p mare nu dovedește potrivirea; contează **impactul** asupra deciziei
- ✓ Sosiri variabile: **NHPP**, generat prin subțiere; Poisson pe intervale scurte, nu pe toată ziua

Ora 2

Analiza rezultatelor

1. Rezultatul unei simulări este o variabilă aleatoare
2. Regimul tranzitoriu și perioada de încălzire (Welch)
3. Replicări, intervale de încredere, medii pe loturi
4. Compararea variantelor: numere aleatoare comune, reducerea dispersiei

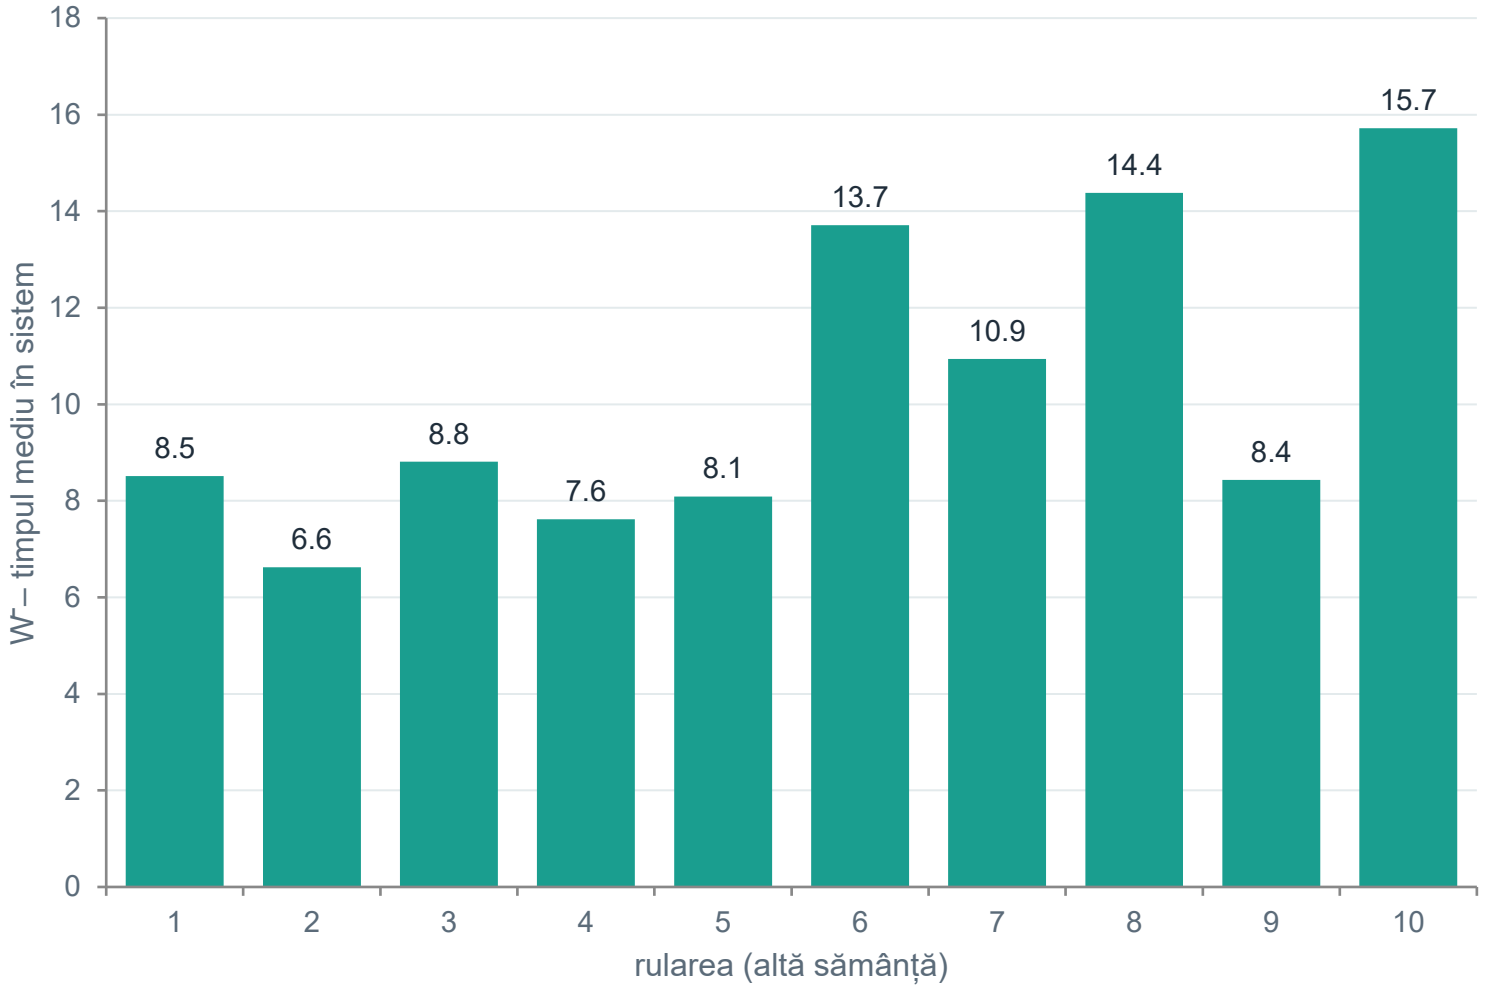
O rulare = o singură observație

- Simulatorul folosește numere aleatoare, deci ieșirea (W, L, p95) este o **variabilă aleatoare**
- Altă sămânță a generatorului → alt rezultat; o singură rulare este **un eșantion de mărime 1**
- Media lui W pe 5 000 de clienți **nu** este o medie a 5 000 de observații independente: clienții consecutivi așteaptă aproape la fel
- Pe lângă zgomot, există și **deplasare**: pornim cu sistemul gol, deci primii clienți așteaptă mai puțin
- Întrebarea corectă nu este „cât este W?”, ci „în ce interval se află W, cu ce încredere?”

Law (2015)

Una dintre cele mai frecvente greșeli în studiile de simulare: o singură rulare, de lungime arbitrară, tratată ca răspunsul „adevărat”.

Zece rulări ale aceluiași model (M/M/1, ρ = 0,9, 5 000 de clienți)



- Teoria: **W = 10**
- Rulările dau între **6,6** și **15,7**
- Același model, același cod – doar sămânța diferă
- Valoarea 10,56 din S5 este perfect compatibilă cu W = 10

Două tipuri de simulări

Terminale (cu final natural)

- au un eveniment de oprire: închiderea băncii, sfârșitul turei, lansarea unui produs
- starea inițială face parte din problemă (banca se deschide goală)
- metoda naturală: **replicări** independente ale întregii perioade
- exemple: o zi la bancă, o campanie de vânzări, un meci

Staționare (fără final)

- ne interesează comportamentul **pe termen lung**
- starea inițială este **artificială** și introduce o deplasare
- avem nevoie de **încălzire** și de rulări lungi
- exemple: un server 24/7, o linie de producție continuă, o rețea

Primul lucru de decis într-un studiu: **ce tip de simulare** avem? De el depind starea inițială, lungimea rulării și metoda de analiză. Formulele din S4 (M/M/1, Erlang C) descriu regimul **staționar**.

Trei probleme ale ieșirilor unei simulări

1 Deplasarea inițială

Pornim dintr-o stare nereprezentativă (sistem gol); primele observații trag media în jos. Soluție: **perioada de încălzire**.

2 Variabilitatea

Rezultatul depinde de numerele aleatoare. Soluție: **replicări** și intervale de încredere; tehnici de reducere a dispersiei.

3 Autocorelația

Observațiile consecutive nu sunt independente; formulele obișnuite subestimează eroarea. Soluție: replicări sau **medii pe loturi**.

A patra problemă, **modelul greșit**, nu se rezolvă statistic: nicio cantitate de replicări nu corectează o distribuție de intrare greșită. Despre ea vorbim în ora 3.

Regimul tranzitoriu

Perioada de încălzire (warm-up)

1. De ce primii clienți „mint”
2. Metoda grafică a lui Welch
3. Cât de lungă trebuie să fie încălzirea?

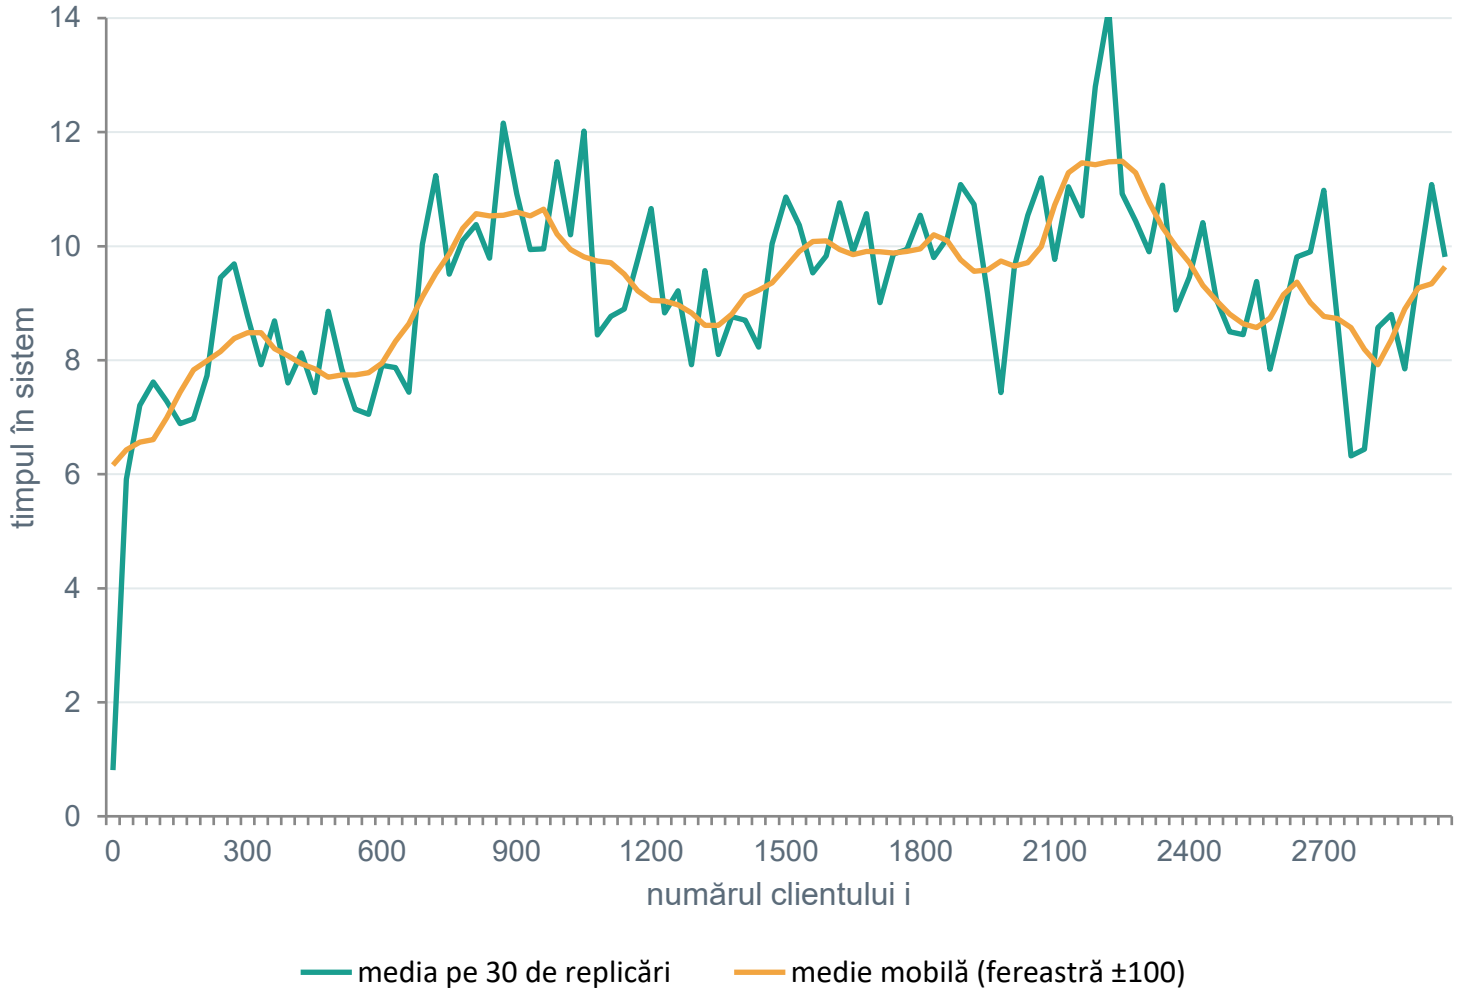
Problema stării inițiale

- Pornim M/M/1 la ρ = 0,9 cu **coada goală**; în regim staționar coada are în medie **9** clienți
- Media timpului în sistem pentru primii 100 de clienți: **6,14** (în loc de 10)
- Cu cât ρ este mai mare, cu atât sistemul „uită” mai încet starea inițială
- Timpul de relaxare al M/M/1 este aproximativ $\mathbf{1/(\mu\cdot(1-\sqrt{\rho})^2)}$: ≈ 380 de unități de timp la ρ = 0,9, dar doar ≈ 12 la ρ = 0,5
- Trei soluții: eliminăm începutul (**încălzire**), pornim dintr-o stare **realistă**, sau facem rulări **foarte lungi**

Atenție

Încălzirea se aplică doar simulărilor **staționare**. La o bancă ce se deschide la 9:00, dimineața liniștită este parte a realității, nu o deplasare.

Metoda Welch: media pe 30 de replicări a lui W_i (clientul i)



- Linia subțire: foarte zgomotoasă, chiar mediată pe 30 de replicări
- Media mobilă urcă de la ~6 și se stabilizează în jur de 10
- Alegem încălzirea: **1 000** de clienți (cu o marjă de siguranță)
- Se elimină la **fiecare** replicare

Metoda Welch pas cu pas

Welch (1983), descrisă în Law (2015):

1 — Replicări

R rulări pilot (5–30), fiecare cu m observații: Y_{1j}, …, Y_{mj}

2 — Mediere

pentru fiecare i: $\bar{Y}_i$ = media lui Y_{ij} peste cele R replicări

3 — Netezire

medie mobilă cu fereastra w: elimină zgomotul rămas

4 — Grafic

desenăm curba netezită și căutăm punctul l de după care se **stabilizează**

5 — Eliminare

ignorăm primele l observații din **fiecare** rulare de producție

Metoda este **vizuală** și subiectivă: preferați o încălzire prea lungă decât prea scurtă. Există și metode automate (MSER-5): alegem l care minimizează eroarea standard a mediei datelor rămase.

Verificare

? Pentru care studiu este **necesară** eliminarea unei perioade de încălzire?

A numărul de clienți serviți de o bancă între 9:00 și 17:00

B timpul mediu de răspuns pe termen lung al unui server care rulează 24/7

C durata de construcție a unei clădiri, de la început până la final

D numărul de mașini care trec printr-o intersecție în timpul unui meci

Estimarea cu precizie cunoscută

Replicări și intervale de încredere

1. Metoda replicărilor independente
2. Intervalul de încredere cu distribuția t
3. Câte replicări sunt necesare?
4. Ce înseamnă „95%”: experimentul de acoperire

Metoda replicărilor independente

R rulări, R semințe, R valori independente

Rulăm modelul de R ori, cu **fluxuri de numere aleatoare independente**. Din fiecare rulare j reținem o singură valoare Y_j (de exemplu media W după încălzire). Valorile Y_1, Y_2, … (câte una pe replicare) sunt **independente și identic distribuite**.

- Autocorelația din interiorul unei rulări nu mai contează: fiecare rulare dă **un singur** număr
- Pentru media rulării, teorema limită centrală face ca Y_j să fie aproximativ normale
- Costul: încălzirea se plătește la fiecare replicare
- Semințele: fluxuri distincte, nu 1, 2, 3 cu un generator slab (S2)

Intervalul de încredere pentru medie

$$\bar{Y} \pm t(1 - \alpha/2;\, R - 1) \cdot s / \sqrt{R}$$

$\bar{Y}, s$	media și abaterea standard (cu R − 1) ale celor R valori
$s/\sqrt{R}$	**eroarea standard** a mediei: scade doar cu rădăcina numărului de replicări
t	cuantila distribuției Student cu R − 1 grade de libertate: 2,776 (R = 5), 2,262 (R = 10), 2,045 (R = 30); pentru R mare → 1,96

Interpretare: dacă am repeta tot experimentul de multe ori, **95%** dintre intervalele construite astfel ar conține media adevărată. Nu înseamnă că media are 95% probabilitate să fie în **acest** interval.

Răspunsul la întrebarea din S5: 30 de replicări

Mărimea	Valoarea	Comentariu
Replicări (câte 20 000 de clienți după încălzire)	30	semințe 300…329
Media $\bar{Y}$	**9,799**	teoria: 10
Abaterea standard s	1,087	între replicări
t(0,975; 29)	2,045	față de 1,96 pentru z
Semilățimea t·s/√R	0,406	≈ 4,1% din medie
Interval de încredere 95%	**[9,39; 10,21]**	**conține 10**

- Valoarea 10,56 dintr-o singură rulare **nu** indică o eroare de program: este zgomot statistic normal la ρ = 0,9
- Raportăm: „W = 9,80 ± 0,41 (IÎ 95%, 30 de replicări, încălzire 1 000 de clienți)”

Replicări și interval de încredere în Python

```
import numpy as np
from scipy import stats

def replicare(seed, n=21_000, warm=1_000):
    rng = np.random.default_rng(seed)
    W = simuleaza_mm1(rng, n, rho=0.9)    # timpii Wi
    return W[warm:].mean()                # o singură valoare

Y = np.array([replicare(300 + j) for j in range(30)])
R, m, s = len(Y), Y.mean(), Y.std(ddof=1)
h = stats.t.ppf(0.975, R - 1) * s / np.sqrt(R)
print(f"W = {m:.2f} ± {h:.2f}")   # W = 9.80 ± 0.41
```

- O replicare întoarce **un singur** număr
- ddof=1: abaterea cu n − 1
- stats.t.ppf: cuantila Student
- Eliminăm încălzirea în **fiecare** replicare

Demo: o singură rulare vs 30 de replicări



- Chiar cu 21 000 de clienți, o rulare poate da **7,9** sau **12,0**
- Media celor 30: **9,80**
- Intervalul: ±0,41 – de ~5 ori mai îngust decât împrăștierea unei rulări
- Demo-ul din notebook: rulați cu alte semințe

z sau t? Exemplul Cambridge (17 repetiții)

Datele

- 4,1 · 3,6 · 3,1 · 4,5 · 3,8 · 2,9
- 3,4 · 3,3 · 2,8 · 4,5 · 4,9 · 5,3
- 1,9 · 3,7 · 3,2 · 4,1 · 5,1
- $\bar{x}$ = **3,776**, s^2 = 0,8144, s = 0,902

Intervalul de 95%

- cu z = 1,96: ±0,429 (prea îngust)
- cu t(0,975; 16) = 2,12: ±**0,464**
- IÎ: [3,31; 4,24]
- diferența z – t crește când n scade

Cu **n < 30** folosim t; pentru n = 5, t = 2,776 – un interval cu **42%** mai larg decât cu z. Presupunerea: valorile sunt aproximativ normale (mediile rulărilor de obicei sunt).

Exemplul lui Holban cu 4 eșantioane, corectat

Pasul	În curs	Corect
Mediile celor 4 eșantioane	53, 45, 59, 46	53, 45, 59, 46
Media mediilor	50,75	50,75
$\Sigma (\bar{x}_i - \bar{x})^2$	128,3375	**128,75**
Abaterea standard a mediilor	6,54	6,55
Eroarea standard s/√n	3,77 (s/√3)	**3,28** (s/√4)
Interval 95%	50,75 ± 3,77 = [46,98; 53,52]	50,75 ± 3,182·3,28 = **[40,3; 61,2]**

- Cu doar 4 valori, t(0,975; 3) = 3,182 – nu 1 sau 2; în plus 50,75 + 3,77 = 54,52, nu 53,52
- Eșantioanele proveneau dintr-o uniformă pe (0, 100), deci media adevărată este **50** – conținută în intervalul corect

Câte replicări sunt necesare?

$$R \geq \left(t \cdot s / h \right)^2$$

h	semilățimea dorită a intervalului (precizia absolută), de exemplu ±0,25
s	abaterea standard estimată din câteva replicări **pilot** (aici 1,087 din 30)
exemplu	$(2{,}045 \cdot 1{,}087 / 0{,}25)^2 \approx 79 \rightarrow$ **80 de replicări** pentru ±0,25; pentru ±0,1 ar trebui ~450–500

Precizie **relativă**: $h = \gamma \cdot \bar{Y}$ (de exemplu $\gamma = 2\%$). Regula de bază rămâne: de 2 ori mai precis costă de **4** ori mai mult calcul.

Procedura secvențială: adăugăm replicări până ajungem la precizie

- Pornim cu $R_0 = 10$ replicări și calculăm semilățimea $t \cdot s/\sqrt{R}$
- Cât timp semilățimea > h: adăugăm încă o replicare (sau un lot de 5–10) și recalculăm
- Oprire automată când intervalul este suficient de îngust – bună pentru experimente pe cluster
- Atenție: s estimat din puține replicări poate fi mic din întâmplare → cerem un **minim** de replicări
- Pentru mai multe mărimi de ieșire (W, L, p95), precizia se cere pentru **fiecare**; o mărime rară (p99) cere mult mai mult

P **Pe mașini multe**

Replicările sunt independente: se rulează **perfect în paralel** (un proces pe nucleu, câte un flux de numere aleatoare pentru fiecare).

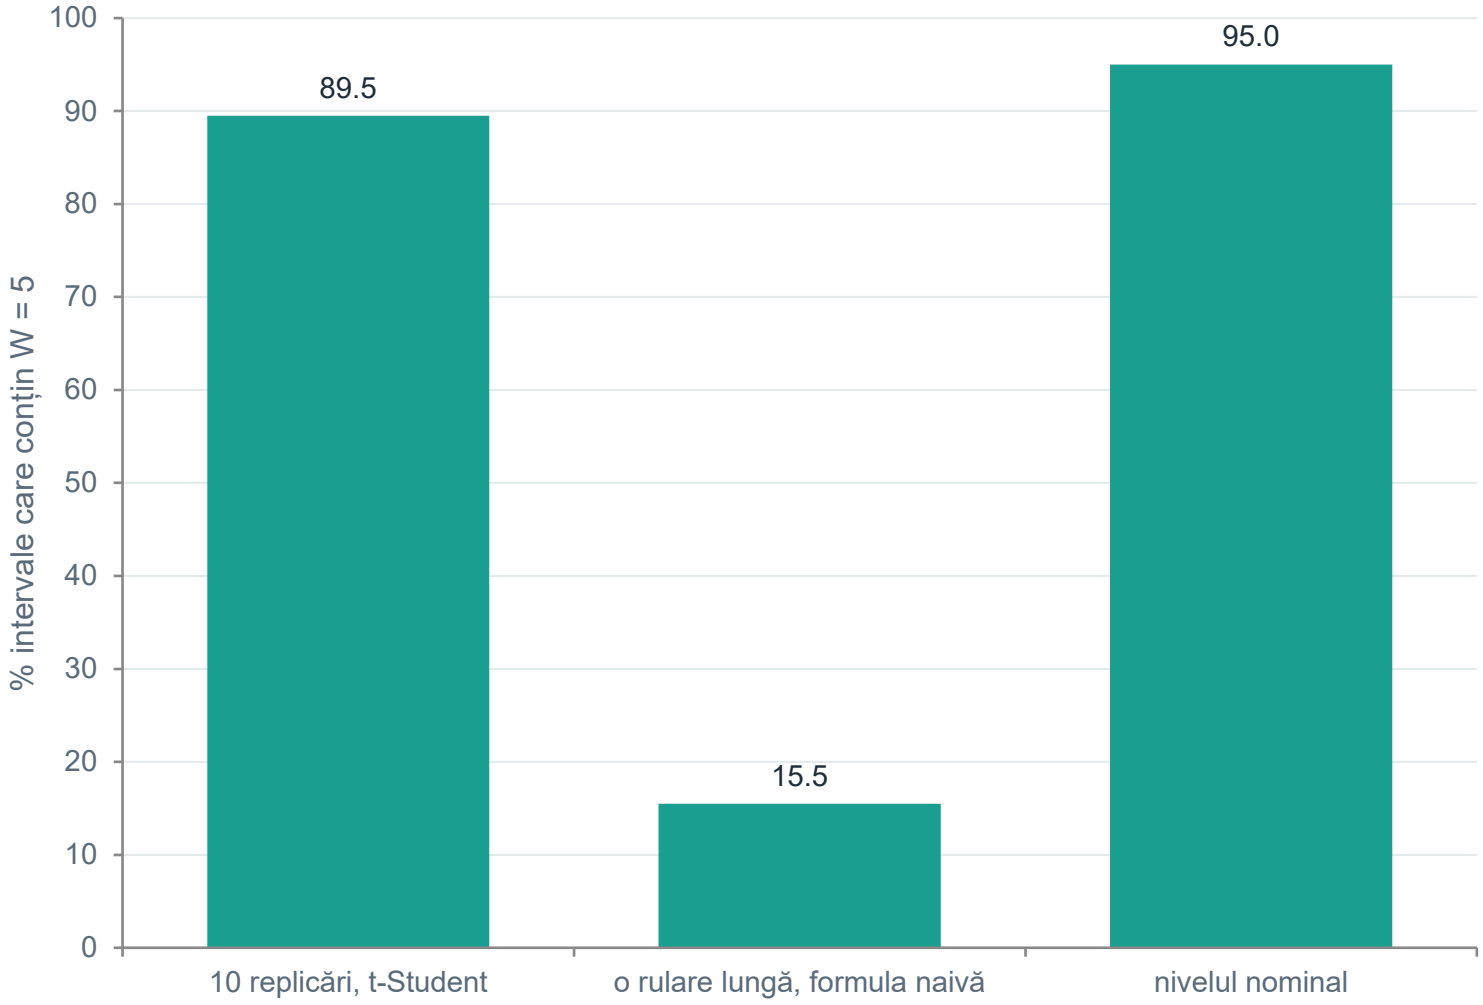
Nu doar medii: proporții și percentile

- Proporția clienților care așteaptă peste 10 minute: în fiecare replicare calculăm $\hat{p}_j$, apoi intervalul t pe cele R valori
- Percentila 95 a așteptării: o estimăm în fiecare replicare ($p95_j$) și aplicăm aceeași formulă
- Pentru mărimi rare (p99, probabilitatea unei cozi peste 50) avem nevoie de rulări **mult** mai lungi: puține observații în coadă
- Evenimente foarte rare (o defectare la 10 ani): tehnici speciale – **importance sampling**, splitting
- Aceeași regulă pentru orice mărime: un număr pe replicare, apoi statistica pe replicări

% **Exemplu**

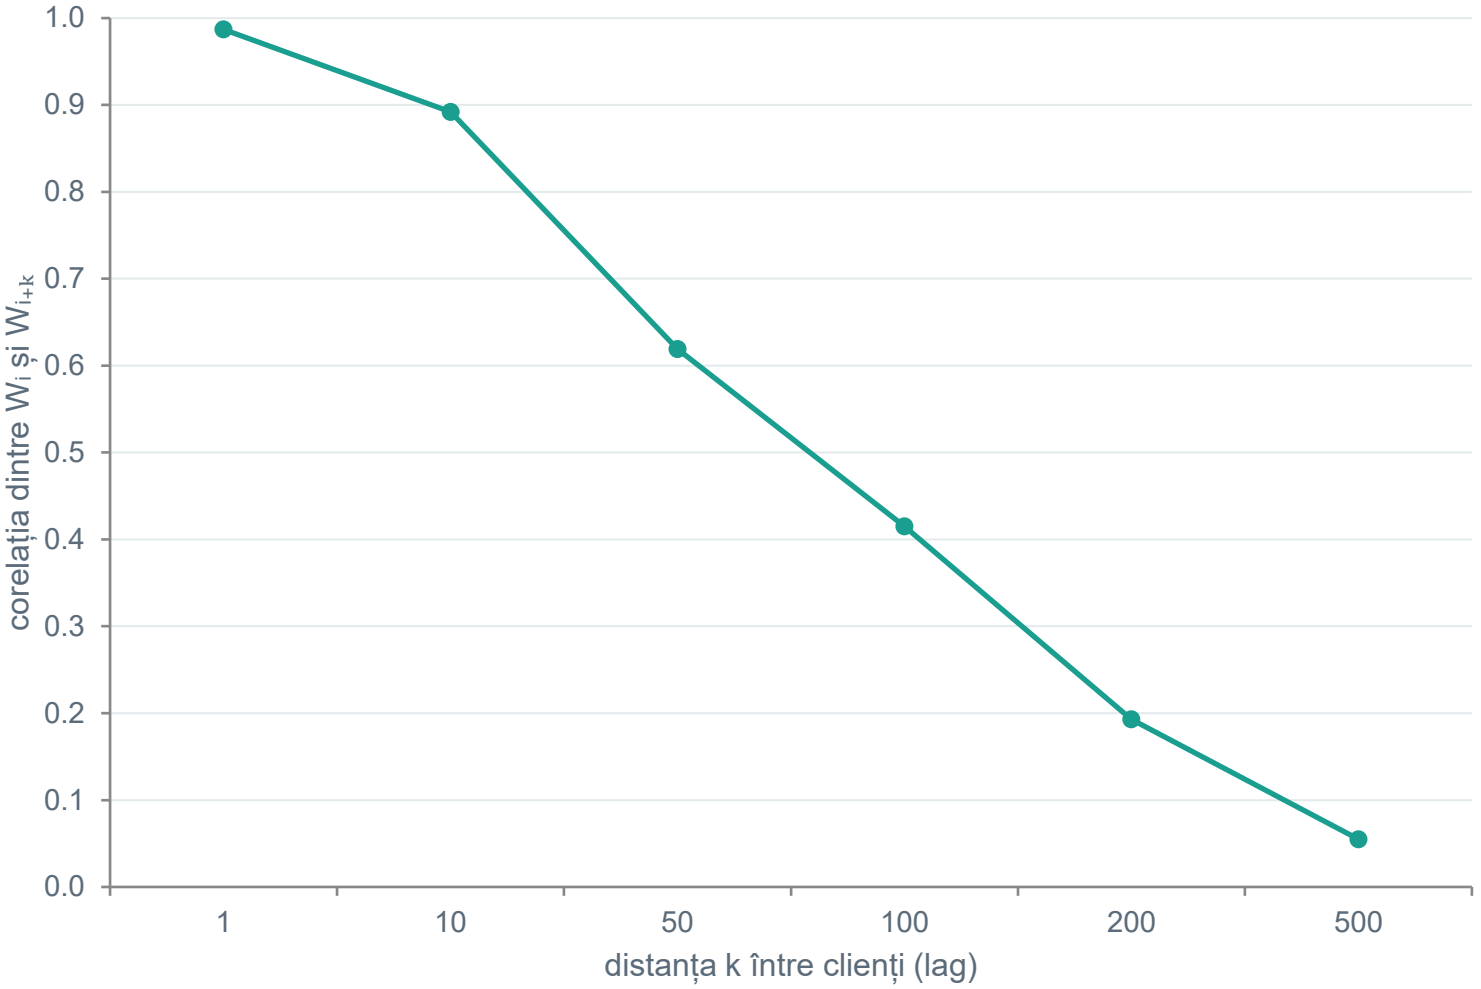
Dacă din 1 000 de clienți 3 așteaptă peste 30 de minute, estimarea 0,3% are o eroare standard relativă de ~58%. Pentru 10% ne trebuie de ~33 de ori mai mulți clienți.

Ce înseamnă „95%”? Acoperirea în 200 de experimente



- Replicări: **89,5%** din intervale conțin 5 (aproape de 95%)
- Formula naivă pe 20 000 de clienți ai unei rulări: doar **15,5%**
- Intervalul naiv e de ~10 ori prea îngust (0,14 vs 1,33)
- Greșeala din exercițiul 6 de la Cambridge

De ce greșește formula naivă: autocorelația



- Clienți vecini: corelație **0,987**
- La distanța 100: încă **0,41**
- Abia după ~500 de clienți: 0,06
- 20 000 de clienți corelați conțin informația a doar câteva sute de valori independente

Medii pe loturi (batch means)

O singură rulare lungă, împărțită în k loturi

După încălzire, împărțim rularea în **k loturi** consecutive de mărime egală (de obicei 10–30). Dacă loturile sunt suficient de lungi, **mediile loturilor** sunt aproape independente și le tratăm ca pe niște replicări.

- Exemplu: 400 000 de clienți, 20 de loturi de 20 000: W = **10,16 ± 0,59**, interval [9,58; 10,75]
- Corelația dintre loturi vecine: -0,20 – suficient de mică
- Intervalul naiv pe aceleași date: ±0,032 – de ~18 ori prea îngust
- Avantaj: încălzirea se plătește **o singură dată**

Replicări sau medii pe loturi?

Replicări independente

- simple, robuste, ușor de paralelizat
- singura metodă pentru simulări **terminale**
- încălzirea se repetă la fiecare rulare
- recomandarea implicită

Medii pe loturi

- o singură rulare: încălzirea o singură dată
- utilă când încălzirea este foarte lungă
- riscul: loturi prea scurte → corelație → interval prea îngust
- verificăm corelația dintre loturi

Alte metode pentru regimul staționar: **metoda regenerativă** (ciclurile dintre momentele în care sistemul se golește sunt independente) și metodele spectrale. În practică, replicările acoperă majoritatea cazurilor.

Verificare

? Un student simulează 20 000 de clienți într-o singură rulare și raportează intervalul **$\bar{W} \pm 1{,}96 \cdot s/\sqrt{20\,000}$**, unde s este abaterea standard a celor 20 000 de valori W_i. Ce problemă are?

A niciuna, n este foarte mare

B W_i sunt corelate, deci intervalul este mult prea îngust

C trebuia folosit t în loc de 1,96

D intervalul este prea larg, pentru că include încălzirea

Compararea variantelor

Care variantă este mai bună?

1. Intervalul pentru diferență: t pereche
2. Numere aleatoare comune (CRN)
3. Variabile antitetice și variabile de control
4. Cum raportăm rezultatele

Exemplul: merită un server cu 10% mai rapid?

- Varianta A: M/M/1 cu $\lambda = 0{,}8$, $\mu = 1$ → teoretic **W = 5**
- Varianta B: același flux de clienți, server mai rapid, $\mu = 1{,}1$ → teoretic **W = 3,33**
- Diferența teoretică: **1,667** – vrem un interval de încredere pentru ea
- Pentru fiecare replicare j calculăm $D_j = W(A, j) - W(B, j)$, apoi intervalul t pentru media lui D (**t pereche**)
- Dacă intervalul nu conține 0, diferența este semnificativă statistic

D **Formula**

$\bar{D} \pm t(0{,}975;\ R - 1) \cdot s(D) / \sqrt{R}$, unde s(D) este abaterea standard a diferențelor. Cu cât **s(D)** e mai mic, cu atât comparația e mai precisă.

Numere aleatoare comune (common random numbers)

Aceleași numere aleatoare pentru ambele variante

În replicarea j, variantele A și B folosesc **aceleași** sosiri și aceleași cereri de servire. Diferențele observate provin din variante, nu din noroc: Var(A − B) = Var(A) + Var(B) − **2·Cov(A, B)**.

- O zi aglomerată este aglomerată pentru **ambele** variante → corelație pozitivă → dispersie mai mică a diferenței
- Implementare: fluxuri separate pentru fiecare **scop** (sosiri, serviri), cu aceeași sămânță în A și B
- Aici: servirea în B = aceeași valoare exponențială împărțită la 1,1
- Legătura cu S5: evenimentele exogene pot fi generate o dată și refolosite

Rezultatul: 20 de replicări, independent vs CRN

Metoda	D = W(A) − W(B)	Semilățimea 95%	Conține 1,667?
Fluxuri independente	1,727	±0,275	da
Numere aleatoare comune	**1,659**	**±0,131**	da
Raportul dispersiilor diferenței	**4,4**		

- Cu CRN, intervalul este de ~2,1 ori mai îngust **fără niciun calcul în plus**
- Pentru aceeași precizie, cu fluxuri independente ar fi trebuit de ~4,4 ori mai multe replicări (~88 în loc de 20)

CRN în cod: un generator pentru fiecare scop

```
import numpy as np

def run(mu, seed, n=10_000):
    arr = np.random.default_rng([seed, 1])   # sosiri
    svc = np.random.default_rng([seed, 2])   # serviri
    A = arr.exponential(1 / 0.8, n)
    S = svc.exponential(1.0, n) / mu   # aceeași „muncă”
    return mean_time_in_system(A, S)

D = [run(1.0, j) - run(1.1, j) for j in range(20)]
# aceeași sămânță j în A și B -> CRN
```

- Fluxuri **separate** pentru sosiri și serviri
- Același j în ambele variante
- Servirea în B: aceeași valoare, scalată
- Sincronizarea se strică dacă o variantă consumă mai multe numere dintr-un flux comun

Variabile antitetice

$$\hat{Y} = (Y(U) + Y(1 - U)) / 2$$

ideea	dacă U dă o zi „norocoasă”, 1 − U dă o zi „ghinionistă”: perechea are **corelație negativă**, iar media ei variază mai puțin
exemplul	suma așteptărilor primilor 10 clienți ai unei cozi (Cambridge): sosiri din U, serviri din V, apoi 1 − U și 1 − V
rezultat	dispersia per pereche: 64,7 → 44,4: câștig de **1,46×** la același număr de rulări

Funcționează când ieșirea este **monotonă** în numerele aleatoare (mai multă muncă → mai multă așteptare). Poate chiar strica lucrurile dacă ieșirea nu e monotonă.

Variabile de control

$$Z = X + c \cdot (Y - E[Y]), \quad c^* = -Cov(X, Y) / Var(Y)$$

X	mărimea de interes: suma așteptărilor primilor 20 de clienți
Y	o mărime corelată cu **media cunoscută**: suma timpilor de servire, E[Y] = 20
rezultat	corelația X–Y = 0,66, c* = -4,47; media rămâne 34,2, dispersia scade de **1,78×**

Intuiția: dacă într-o rulare serviciile au fost mai lungi decât în medie, și așteptările au ieșit probabil mari – corectăm în jos. Câștigul maxim este $1/(1 - \rho^2_{xy})$.

Reducerea dispersiei: rezumat

Tehnica	Ideea	Câștig în exemplele noastre
Numere aleatoare comune	aceleași numere în variantele comparate	**4,4×** (diferența W)
Variabile antitetice	perechi U și 1 − U, corelate negativ	1,46×
Variabile de control	corecție cu o mărime de medie cunoscută	1,78×
Mai multe replicări	forța brută	2× costă 2× timp

- Un câștig de 4× în dispersie valorează cât **de 4 ori** mai multe replicări
- CRN este cea mai folosită în practică: aproape gratuită și foarte eficientă la comparații; celelalte cer mai multă grijă

Mai multe variante: cum alegem cea mai bună?

- Cu k variante avem k(k − 1)/2 comparații; la 95% fiecare, **unele** vor ieși „semnificative” din întâmplare
- **Corecția Bonferroni**: pentru m intervale simultane folosim nivelul 1 − α/m pentru fiecare
- **Selecția celei mai bune** (ranking and selection): câte replicări pentru a alege, cu probabilitatea 95%, o variantă la cel mult δ de cea optimă
- **OCBA**: alocăm replicările suplimentare variantelor apropiate de cea mai bună, nu celor clar slabe
- Pentru spații mari de variante: optimizare prin simulare (algoritmi genetici, căutare bayesiană)

S **Practic**

O diferență **semnificativă statistic** nu este neapărat **importantă practic**: 0,1 secunde câștigate nu justifică un server nou.

Verificare

? Comparăm două politici de planificare cu **numere aleatoare comune**. De ce scade dispersia diferenței?

A pentru că fiecare variantă are dispersie mai mică

B pentru că rezultatele celor două variante devin corelate pozitiv

C pentru că se elimină perioada de încălzire

D pentru că se folosesc mai multe replicări

Greșeli frecvente în analiza ieșirilor

1 O singură rulare

Rezultatul raportat fără interval; nu știm dacă 10,56 diferă de 10.

2 Fără încălzire

Media subestimată sistematic într-un sistem staționar, mai ales la încărcări mari.

3 Formula naivă

s/√n pe observații corelate: interval de 10–20 de ori prea îngust.

4 Semințe refolosite

Aceeași sămânță în „replicări” diferite: nu sunt independente, intervalul e fals.

5 z în loc de t

Cu 5 replicări, 1,96 în loc de 2,776: încredere reală mult sub 95%.

6 Rulări prea scurte

Nu apar evenimentele rare care produc cozile lungi (defectări, vârfuri).

Cum raportăm rezultatele unei simulări

- Estimarea cu **interval de încredere**, nivelul și metoda (replicări / loturi): „W = 9,80 ± 0,41 min (IÎ 95%)”
- Numărul și lungimea rulărilor, perioada de **încălzire** și cum a fost aleasă
- Pe lângă medie: **percentile** (p90, p95), maxime, proporții (clienți care așteaptă peste 10 min)
- Generatorul, **semințele**, versiunile bibliotecilor – pentru reproductibilitate (ora 3)
- Presupunerile despre intrări și sursa datelor; ce **nu** modelează modelul

G **Grafice**

Box-plot-uri ale replicărilor pentru fiecare variantă și intervale de încredere ca bare de eroare – mai clare decât tabelele cu multe zecimale.

Rezumatul orei 2

- ✓ O rulare = **o observație**; la ρ = 0,9 rulările de 5 000 de clienți dau între 6,6 și 15,7
- ✓ Staționar: **încălzire** (Welch); terminal: replicări ale întregii perioade
- ✓ Replicări + t: W = **9,80 ± 0,41** conține 10; $R \geq (t \cdot s/h)^2$
- ✓ Autocorelația face formula naivă **greșită** (acoperire 15%); soluții: replicări sau loturi
- ✓ Comparații: diferențe pereche + **CRN** (dispersie de 4,4 ori mai mică); antitetice, variabile de control

Ora 3

Verificare, validare, încredere

1. Verificare vs validare: două întrebări diferite
2. Studiu de caz: validarea modelului unui ghișeu cu date istorice
3. Analiza sensibilității și experimente factoriale
4. Incertitudine, reproductibilitate, modele moderne

Verificare vs validare

Verificare

- „Am construit **corect** modelul?”
- programul implementează fidel modelul conceptual
- erori de cod, de logică, de statistici
- se face comparând cu **specificația** și cu rezultate cunoscute

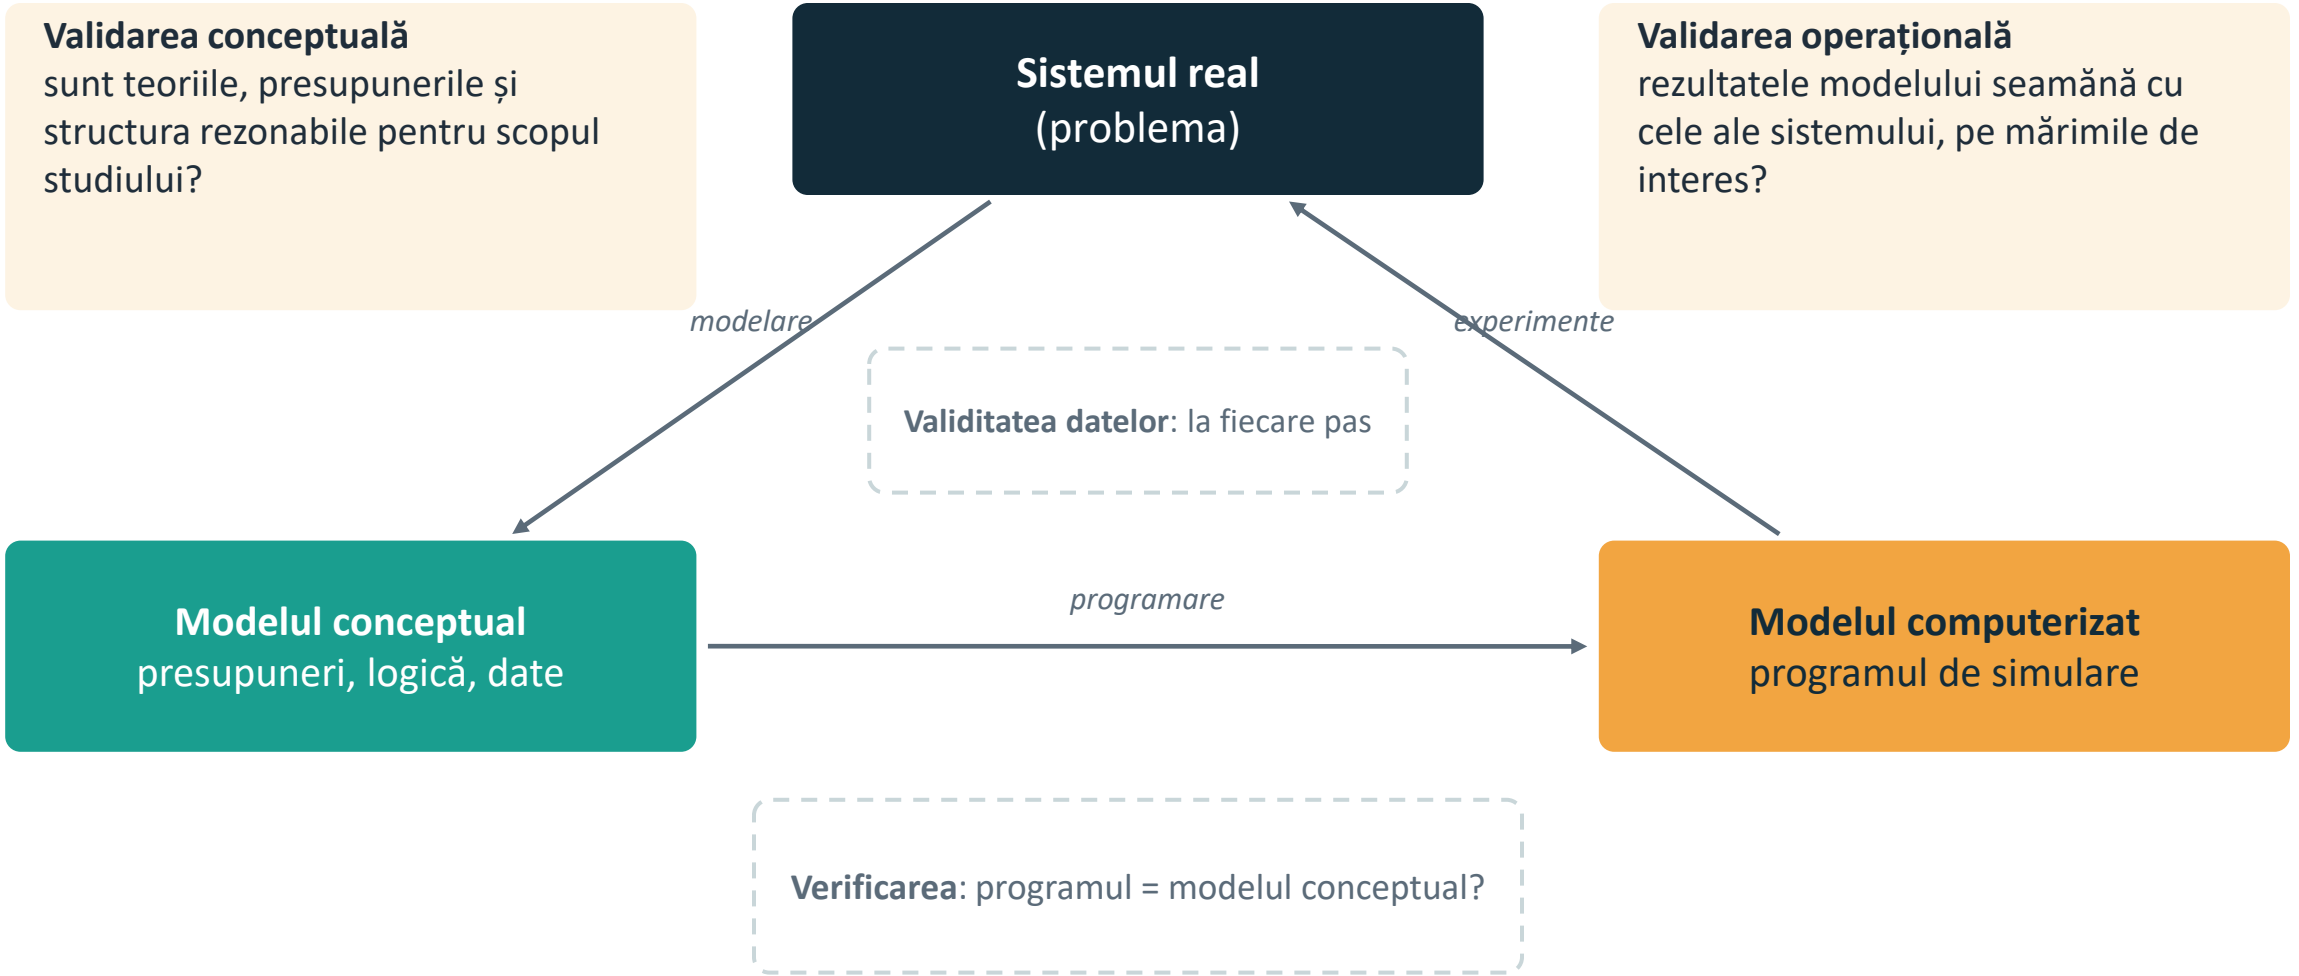
vs

Validare

- „Am construit modelul **corect**?”
- modelul reprezintă suficient de bine **sistemul real**, pentru scopul studiului
- presupuneri greșite, date greșite, simplificări exagerate
- se face comparând cu **realitatea** (date, experți)

Formularea lui Boehm (pentru software) și Balci (pentru simulare). Validarea este **relativă la scop**: un model bun pentru media așteptării poate fi prost pentru percentila 99. Niciun model nu este „valid” în absolut.

Ciclul modelării și unde intervine fiecare verificare (Sargent)



Modelul ca șir de aproximări (Holban)

- Construim un șir de modele $\mathbf{M_1, M_2, \ldots, M_k}$, fiecare mai detaliat, până când comportamentul lui M_k este suficient de apropiat de al sistemului
- La fiecare pas comparăm aceleași mărimi (de exemplu gradul de ocupare ρ) cu cele **măsurate**
- Regula din curs: modelul este acceptat dacă ρ simulat ∈ **[ρ − σ, ρ + σ]**, cu ρ și σ măsurate
- Idee bună: pornim simplu și adăugăm detalii doar unde contează (principiul parcimoniei)
- Limită importantă: **ce** comparăm – vom vedea că ρ singur nu ajunge

M

Modele simple mai întâi

Un model M/M/c calculat în 5 minute dă ordinul de mărime. Dacă simulatorul detaliat dă altceva, **unul** dintre ele este greșit – ambele sunt verificate.

Tehnici de verificare

1 Urma (trace)

Rulăm pas cu pas și comparăm cu un calcul de mână – exact exercițiul din S5.

2 Rezultate cunoscute

Cazuri speciale cu formulă: M/M/1, M/M/c, Erlang B/C, Little. Diferența trebuie să fie în intervalul de încredere.

3 Cazuri extreme

$\lambda \to 0$: nicio coadă; c foarte mare: nicio așteptare; $\rho \geq 1$: coada crește fără limită.

4 Conservare

Sosiri = plecări + clienți în sistem; timp ocupat ≤ timp total × c; nicio valoare negativă.

5 Două implementări

Motorul nostru vs SimPy: același model, cod diferit, aceleași rezultate statistice.

6 Animație și teste

Vizualizarea pune în evidență comportamente absurde; teste automate pentru fiecare componentă.

Verificarea motorului din S5: ce am făcut deja

Test	Simulare	Teorie	Concluzie
M/M/1, ρ = 0,5: L	0,99	1	OK
M/M/1, ρ = 0,8: L	4,05	4	OK
M/M/1, ρ = 0,9: L (o rulare)	9,50	9	? → replicări
M/M/c, c = 10, ρ = 0,9: Wq	0,676	0,669 (Erlang C)	OK
SimPy vs motorul nostru, ρ = 0,8: W	5,05 / 5,06	5	OK

- Singura abatere „vizibilă” era la ρ = 0,9 – iar ora 2 a arătat că este zgomot: cu 30 de replicări, IÎ 95% conține valoarea teoretică
- Regula: diferențele dintre simulare și teorie se judecă **statistic**, niciodată „din ochi”

Verificarea automată: teste pentru simulator

```
import pytest

def test_mm1_formula():
    Y = [run_mm1(rho=0.5, seed=s) for s in range(20)]
    m, h = ci95(Y)                        # media ± semilățimea
    assert abs(m - 2.0) <= h              # W teoretic = 2

def test_little():
    r = run_mm1(rho=0.8, seed=1)
    assert r.L == pytest.approx(r.lam * r.W, rel=0.01)

def test_conservare():
    r = run_mm1(rho=0.8, seed=2)
    assert r.sosiri == r.plecari + r.in_sistem

def test_extrem():
    r = run_mm1(rho=0.01, seed=3)
    assert r.Wq < 0.05                    # aproape nicio coadă
```

- Rulate automat la **fiecare** modificare a codului
- Formula: comparație **statistică** (IÎ), nu egalitate
- Little și conservarea: exacte în orice rulare
- Cazuri extreme: răspuns evident

Tehnici de validare

1 Validitate aparentă

Experții în sistem examinează logica și rezultatele: „așa se comportă ghișeul la prânz?”

2 Date istorice

Rulăm modelul în condițiile unei perioade trecute și comparăm ieșirile cu cele **măsurate**.

3 Testul Turing

Experții primesc rapoarte reale și simulate amestecate. Le pot deosebi?

4 Alte modele

Comparație cu modele analitice sau cu alte simulatoare validate anterior.

5 Validare predictivă

Modelul prezice o schimbare (un ghișeu în plus); comparăm cu ce se întâmplă după implementare.

6 Evenimente

Apar în model aceleași evenimente ca în realitate: blocaje, vârfuri, cozi la aceleași ore?

Studiu de caz

Validarea modelului unui ghișeu

1. 20 de zile de date măsurate: ρ și timpul de așteptare
2. Modelul A: servire exponențială (presupunere comodă)
3. Modelul B: servire lognormală (ajustată pe date)
4. Regula lui Holban vs un test pe mărimea de interes

Datele și cele două modele

- Ghișeu cu un funcționar, program de **8 ore**; sosiri Poisson, λ = **0,8 clienți/min**
- Servire reală: media **1 min**, dar variabilă – lognormală cu **$Cs^2 \approx 2$** (unii clienți au operațiuni complexe)
- Măsurat pe **20 de zile**: ocuparea funcționarului ρ și așteptarea medie în coadă Wq, pe zi
- **Modelul A**: servire Exp(1) – aceeași medie, $Cs^2 = 1$
- **Modelul B**: servire lognormală, media 1 și $Cs^2 = 2$, estimate din cronometrări (ora 1)
- Fiecare model rulat 20 de zile (replicări), cu sosiri și parametri identici

Pasul 1: validarea după gradul de ocupare (regula Holban)

Sursa	ρ mediu	Interval [ρ − σ, ρ + σ]	Acceptat?
Sistemul real (20 de zile)	0,803	[0,746; 0,860]	–
Modelul A (exponențial)	0,796		**da**
Modelul B (lognormal)	0,817		**da**

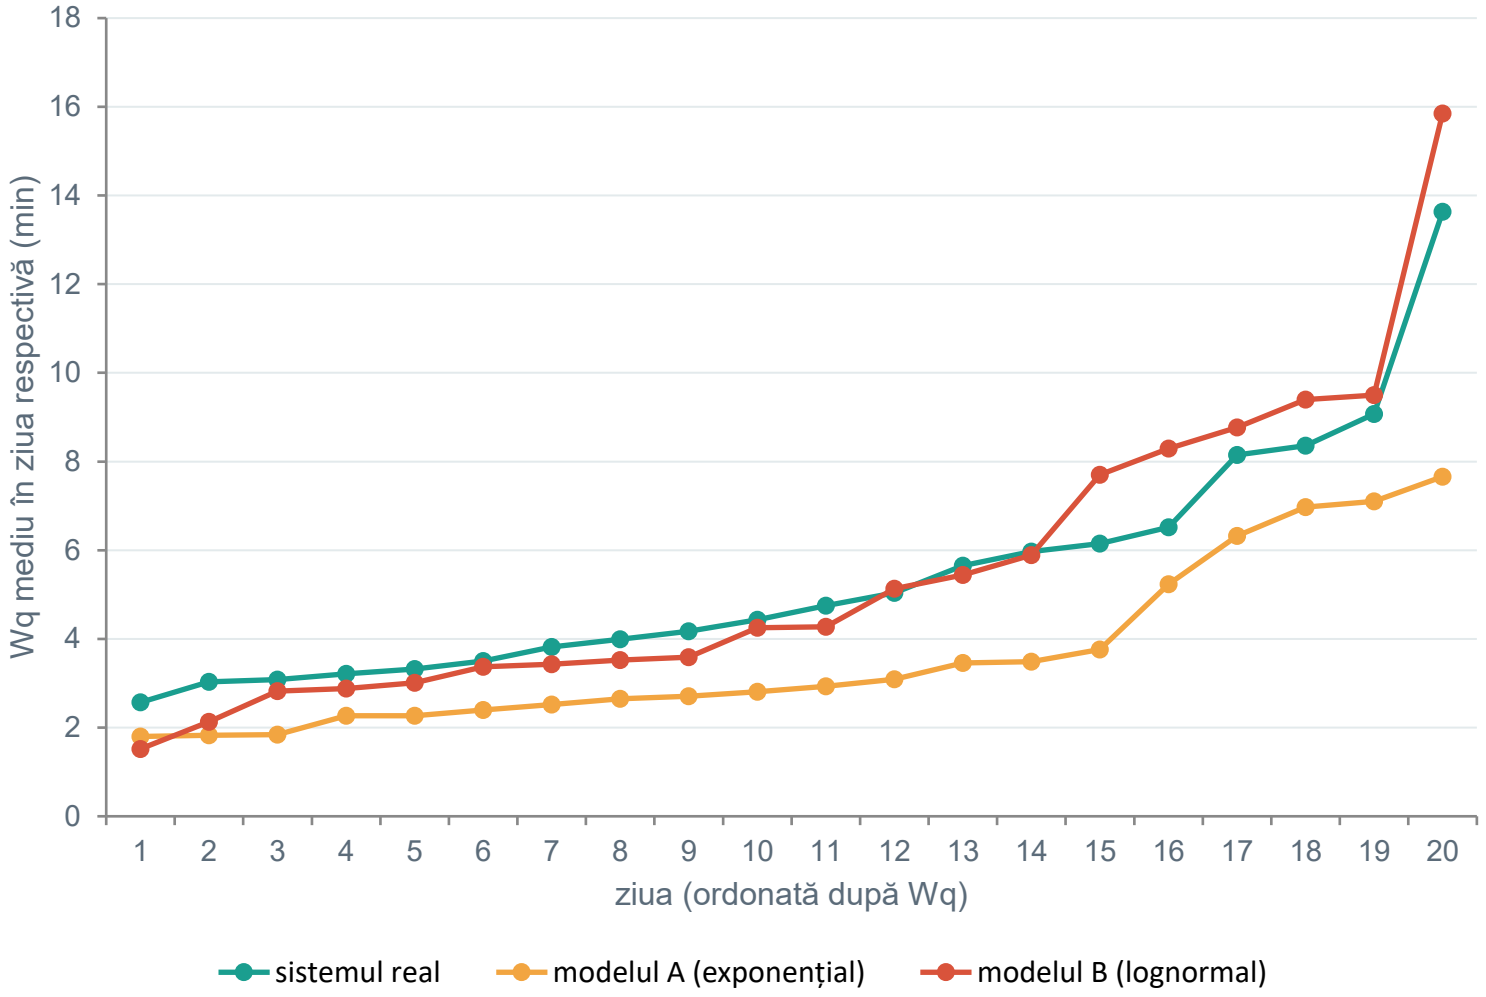
- Ambele modele trec testul: ocuparea simulată cade în intervalul măsurat
- Nu este o coincidență: ρ = λ·s depinde doar de **media** servirii, nu de variabilitatea ei – deci ρ nu poate distinge cele două modele

Pasul 2: validarea după mărimea de interes – așteptarea Wq

Sursa	Wq mediu (min)	IÎ 95% (20 de zile)	Test t Welch vs real
Sistemul real	**5,42**	±1,27	–
Modelul A (exponențial)	**3,65**	±0,89	p = 0,023 → **respins**
Modelul B (lognormal)	**5,54**	±1,62	p = 0,91 → nu e respins

- Modelul A **subestimează** așteptarea cu aproximativ o treime – aceeași eroare ca în formula P-K din ora 1
- Dacă decizia depinde de așteptare (câți funcționari angajăm?), modelul A ar duce la o decizie greșită, deși „a trecut validarea”

Cele 20 de zile, ordonate crescător: așteptarea medie pe zi



- Curba modelului A este **sub** cea reală aproape peste tot
- Modelul B se suprapune cu realitatea
- Variabilitatea între zile este mare: de la 2 la 14 minute
- Comparăm **distribuții**, nu doar medii

Testul t Welch pentru două eșantioane

$$t = (\bar{X} - \bar{Y}) / \sqrt{(s^2_x/n_x + s^2_y/n_y)}$$

X, Y	valorile zilnice reale și cele simulate (aici câte 20)
Welch	nu presupune dispersii egale; gradele de libertate se calculează din date (formula Welch–Satterthwaite)
Python	scipy.stats.ttest_ind(x, y, equal_var=False) – întoarce t și p-valoarea

Aceleași avertismente ca la testele de potrivire: cu 20 de zile, un test care **nu respinge** nu dovedește validitatea. Mai informativ: **intervalul de încredere pentru diferență**, comparat cu diferența care ar schimba decizia.

Lecțiile studiului de caz

- Validați pe **mărimile de ieșire** care contează pentru decizie (Wq, p95), nu pe cele ușor de măsurat (ρ)
- Un grad de ocupare corect este o condiție **necesară, nu suficientă**: el verifică doar media servirii
- Regula [ρ − σ, ρ + σ] este prea largă: σ măsoară variația între zile, nu precizia mediei (ar trebui σ/√n)
- Eroarea modelului A vine din **datele de intrare** (ora 1), nu din cod – verificarea nu ar fi găsit-o niciodată
- Păstrați date de validare **separate** de cele folosite la construirea modelului

R **Reformulare**

Criteriul lui Holban devine: intervalul de încredere pentru diferența dintre model și realitate, pe **mărimea de interes**, este mai mic decât toleranța acceptată pentru decizie.

Verificare

? Un model reproduce corect gradul de ocupare al serverelor, dar subestimează timpul de așteptare. Care este cauza cea mai probabilă?

A rata sosirilor este greșită

B variabilitatea timpilor de servire (sau a sosirilor) este subestimată

C numărul de servere este greșit

D sămânța generatorului este nepotrivită

Calibrare vs validare: analogia cu învățarea automată

Calibrare (antrenare)

- ajustăm parametrii nemăsurabili ca modelul să reproducă datele
- ex.: timpul mediu de „pauză” al funcționarului
- folosim un set de date: zilele 1–20
- riscul: **supraajustare** – modelul reproduce zgomotul

Validare (test)

- comparăm cu date **nefolosite** la calibrare
- ex.: zilele 21–40, sau altă sucursală
- arată dacă modelul **generalizează**
- un model calibrat pe toate datele nu mai poate fi validat pe ele

Exact ca **train / test split** în ML: cu destui parametri liberi, orice model reproduce datele istorice. Un model cu 30 de parametri calibrați pe 20 de zile „se potrivește perfect” și nu prezice nimic.

Un plan de validare în cinci pași

Adaptat după Sargent (2013) și Law (2015):

1 — Scopul

ce decizie sprijină modelul, ce **mărimi** de ieșire și ce **toleranță** acceptăm

2 — Datele

date de intrare pentru construcție și date de ieșire **separate** pentru validare

3 — Experții

validitate aparentă: logica, animația, rezultate pe scenarii cunoscute

4 — Statistica

IÎ pentru diferența model – realitate pe mărimile de interes, pe mai multe perioade

5 — Documentare

presupuneri, domeniu de valabilitate, sensibilitate, versiuni și semințe

Pasul 1 este cel mai des sărit și cel mai important: fără o toleranță fixată **înainte**, orice diferență poate fi declarată „acceptabilă” după ce vedem rezultatele.

Experimente cu modelul

Analiza sensibilității și experimente factoriale

1. Care intrări contează? Diagrama tornado
2. Experimentul factorial 2^3
3. Efecte principale și interacțiuni

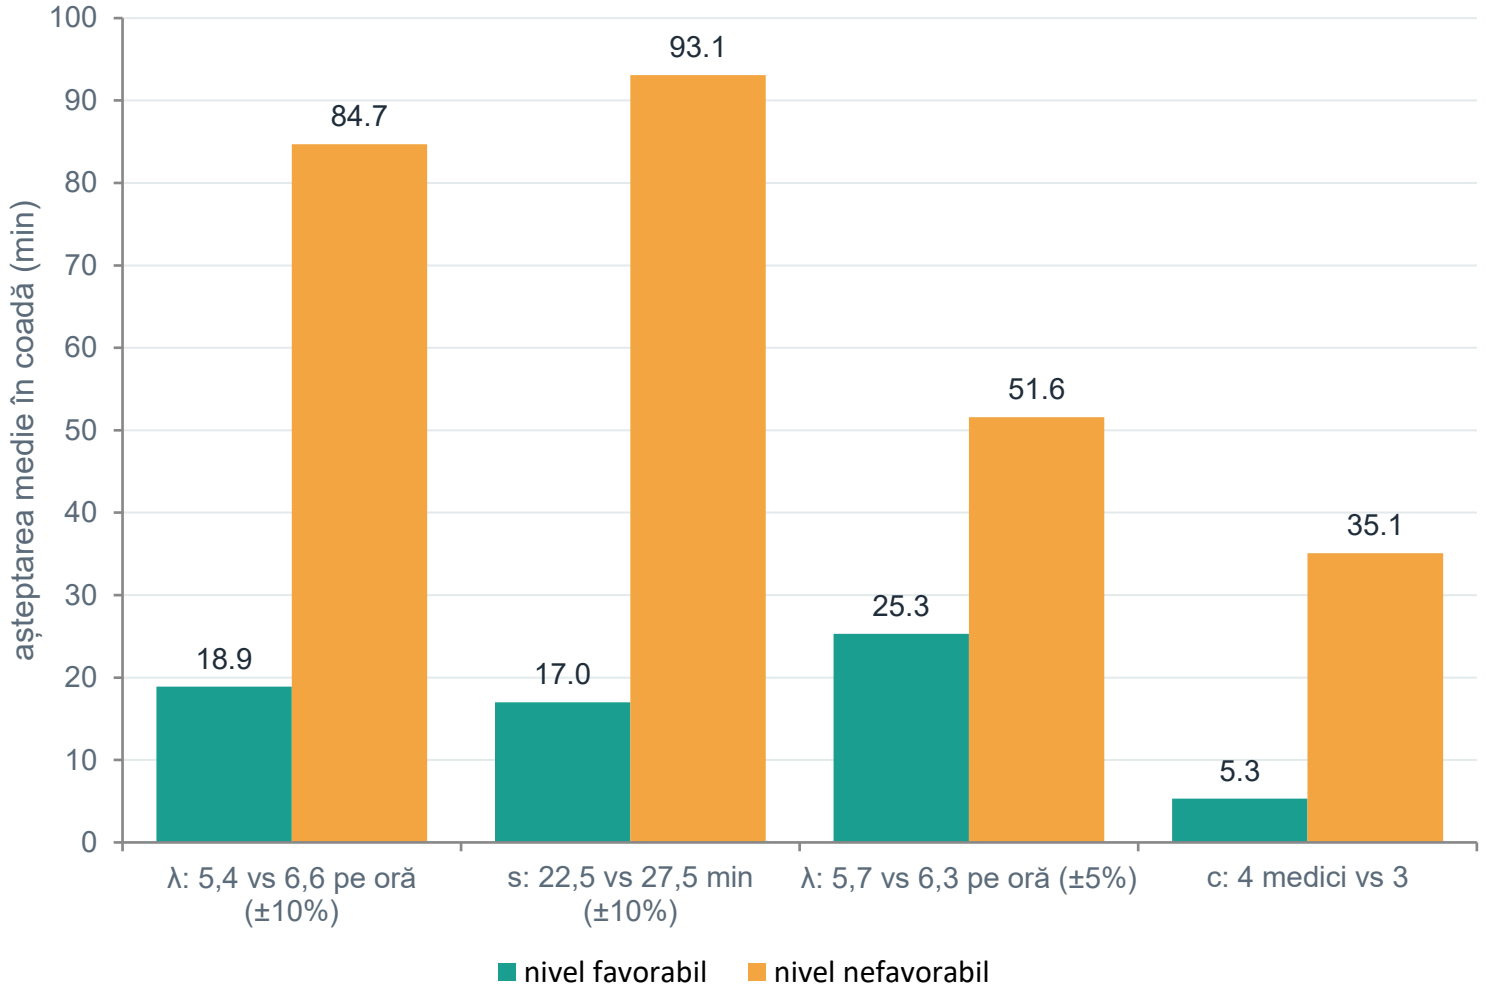
De ce analiza sensibilității?

- Intrările sunt **estimate**, cu erori: cât de mult se schimbă rezultatul dacă ele sunt puțin greșite?
- Arată unde merită investit în **date mai bune**: parametrii la care rezultatul e sensibil
- Arată **robustețea** deciziei: dacă decizia rămâne aceeași pe tot intervalul plauzibil, putem avea încredere
- Metoda simplă (OAT): variem **câte un parametru**, ceilalți rămân la valoarea de bază
- Modelul: urgențele din S5 – λ = **6 pacienți/oră**, consultația **25 min**, **c = 3** medici; așteptarea medie (Erlang C) **35,1 min**

Atenție

OAT nu vede **interacțiunile**: efectul unui factor poate depinde de nivelul altuia. Pentru ele folosim experimente factoriale.

Diagrama tornado: așteptarea medie (bază 35,1 min)



- ±10% la λ sau s: așteptarea variază între **17** și **93** min
- Efect **asimetric**: +10% costă mult mai mult decât câștigă −10%
- Un al patrulea medic: 35 → **5 min**
- Cu 2 medici sistemul e instabil (a = 2,5 > 2)

Ce ne spune tornada

- Ocuparea de bază: ρ = λ·s/c = 6 · (25/60) / 3 = **0,83** – aproape de saturație
- Lângă ρ = 1 așteptarea crește ca **1/(1 − ρ)**: mici erori în intrări devin erori mari în ieșire
- Aceleași ±10% la o coadă M/M/1 cu ρ = 0,5 schimbă așteptarea cu doar −18% / +22%, nu de 2–3 ori
- Concluzie pentru colectarea datelor: **λ** și **s** trebuie estimate precis (sute de observații, pe ore)
- Concluzie pentru decizie: al patrulea medic face sistemul **robust** – așteptarea rămâne mică pe tot intervalul plauzibil

R **Decizie robustă**

Cu 4 medici, chiar la λ = 6,6 **și** s = 27,5 min, așteptarea rămâne sub 15 minute. Cu 3 medici, o singură eroare de +10% o duce la 85–93 de minute, iar ambele împreună fac sistemul **instabil**.

Experimente factoriale 2^k

k factori, fiecare la 2 niveluri: 2^k combinații

Variem **simultan** toți factorii între un nivel „jos” (−1) și unul „sus” (+1) și rulăm toate combinațiile. Obținem **efectele principale** și **interacțiunile** cu un număr mic de rulări.

Law, 2015; Montgomery, Design and Analysis of Experiments

- Exemplul nostru: 3 factori – **c** ∈ {2, 3}, **s** ∈ {0,8; 1,0}, **λ** ∈ {1,2; 1,5} → 8 combinații
- Fiecare combinație: 5 replicări cu motorul din S5 (clasa MMc)
- Mărimea de ieșire: W, timpul mediu în sistem
- Pentru k mare: **fracțiuni** de experimente factoriale (2^{k-p}) sau hipercub latin

Cele 8 combinații: simulare vs Erlang C

Combinația	W simulat	± (IÎ 95%)	W teoretic
c=2, s=0,8, λ=1,2	1,049	0,034	1,040
c=2, s=0,8, λ=1,5	1,246	0,027	1,250
c=2, s=1,0, λ=1,2	1,555	0,040	1,562
c=2, s=1,0, λ=1,5	2,292	0,045	2,286
c=3, s=0,8, λ=1,2	0,826	0,005	0,832
c=3, s=0,8, λ=1,5	0,866	0,008	0,863
c=3, s=1,0, λ=1,2	1,079	0,017	1,078
c=3, s=1,0, λ=1,5	1,163	0,024	1,158

- Toate cele 8 valori simulate sunt în intervalul de încredere față de formulă: o **verificare** suplimentară a motorului

Efectele principale și interacțiunile

$$efectul\ lui\ A = \bar{W}(A\ sus) - \bar{W}(A\ jos) = \Sigma\, x^{A}_{i} \cdot W_i \,/\, 4$$

x^{A}_{i}	nivelul factorului A în combinația i: −1 sau +1
interacțiune a AB	aceeași formulă cu produsul $x^{A}_{i} \cdot x^{B}_{i}$: cât se schimbă efectul lui A când B trece de la jos la sus (jumătate din diferență)
rezultate	c: **-0,55**, s: **+0,53**, λ: +0,27, c×s: -0,25, c×λ: -0,20, s×λ: +0,15

Interpretare: trecerea de la 2 la 3 servere scade W în medie cu 0,55; mărirea servirii de la 0,8 la 1,0 crește W cu 0,53.

Efectele în cinci linii de NumPy

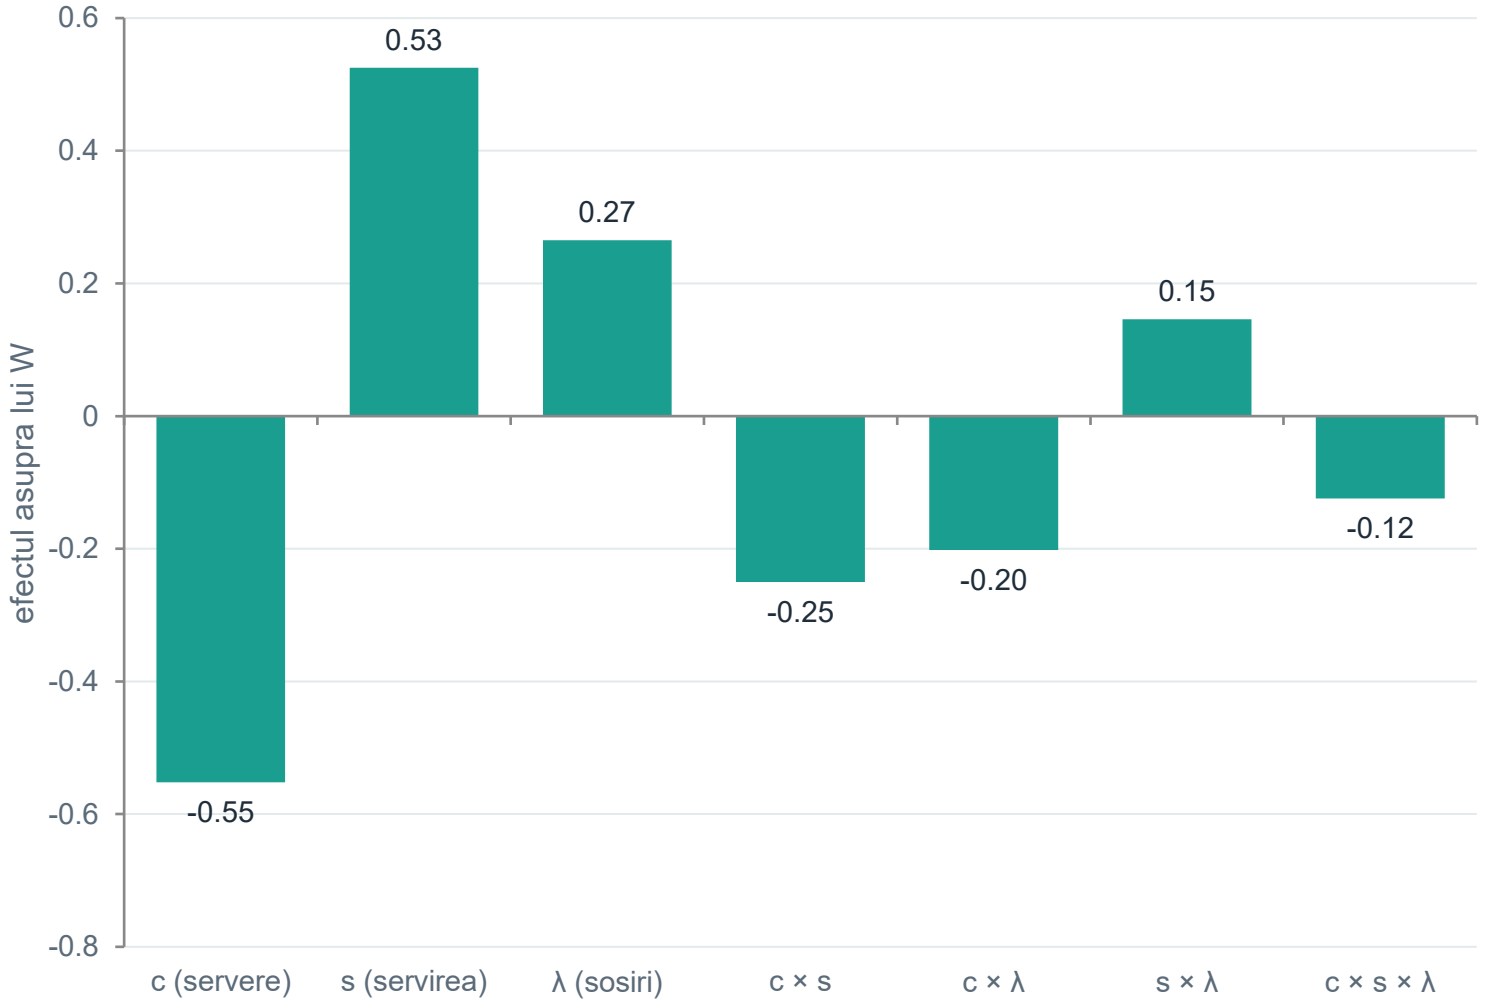
```
import numpy as np, itertools

# nivelurile codificate -1 / +1, în ordinea combinațiilor
X = np.array(list(itertools.product([-1, 1], repeat=3)))
W = np.array([1.049, 1.246, 1.555, 2.292,
              0.826, 0.866, 1.079, 1.163])   # din tabel

for name, cols in [("c", [0]), ("s", [1]), ("lam", [2]),
                   ("c*s", [0, 1]), ("c*lam", [0, 2])]:
    x = X[:, cols].prod(axis=1)
    print(name, round(x @ W / 4, 3))
```

- itertools.product: toate cele 8 combinații
- Interacțiunea: produsul coloanelor
- x @ W / 4: diferența mediilor
- Același cod pentru orice 2^k (împărțim la 2^{k-1})

Efectele estimate asupra lui W



- **c** și **s** domină, cu semne opuse
- Interacțiunea **c × s** este mare: −0,25
- Un server în plus ajută **mai mult** când servirea e lentă
- OAT nu ar fi văzut interacțiunea

Verificare

? Într-un experiment 2^2, W este: 10 (A jos, B jos), 6 (A sus, B jos), 12 (A jos, B sus), 4 (A sus, B sus). Care este **efectul principal al lui A**?

A −2

B −6

C +6

D −12

Încredere

Incertitudine și reproductibilitate

1. Incertitudinea parametrilor: câtă încredere avem în λ?
2. Aleator vs epistemic
3. Reproductibilitate: semințe, versiuni, notebook-uri
4. Validarea modelelor moderne

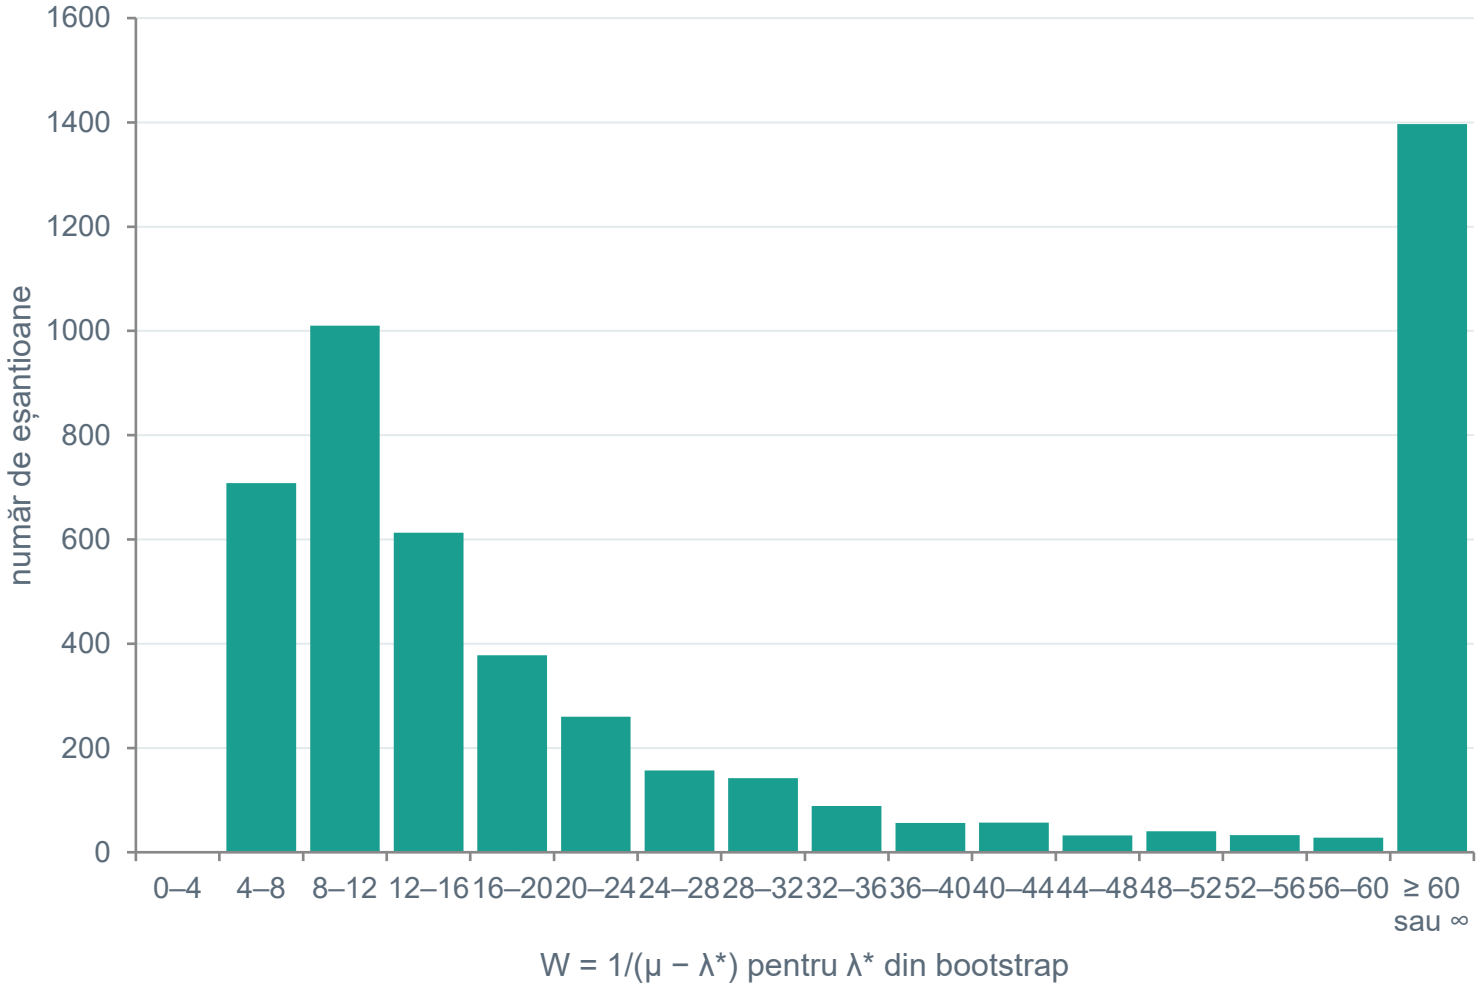
Incertitudinea parametrilor: un exemplu periculos

- Estimăm λ din **200** de sosiri observate: λ̂ = **0,942** (μ = 1, deci ρ̂ = 0,94)
- Formula M/M/1 cu λ̂: W = 1/(μ − λ̂) = **17,3**
- Dar λ̂ are și el un interval (bootstrap 95%): **[0,82; 1,09]** – include valori peste 1!
- Propagăm incertitudinea: în **20,6%** din eșantioanele bootstrap sistemul este **instabil** (ρ ≥ 1)
- Printre cele stabile: W între 6,1 (p5) și 106,7 (p95) – nu „17,3”

U **Lecția**

Oricâte replicări am face, intervalul pentru W rămâne îngust **în jurul unei valori greșite** dacă ignorăm incertitudinea lui λ.

Distribuția lui W când λ este incert (5 000 de eșantioane bootstrap)



- Masa principală: W între 4 și 20
- Coadă foarte lungă spre dreapta
- Ultima bară: 1 397 de cazuri cu W ≥ 60 sau sistem instabil
- Decizia corectă: **mai multe date** despre λ sau capacitate suplimentară

Două tipuri de incertitudine

Aleatorie (variabilitate)

- aleatorismul intrinsec al sistemului: sosiri, serviri
- modelat prin distribuții și numere aleatoare
- se **cuantifică** prin replicări (ora 2)
- nu poate fi redusă prin mai multe date

Epistemică (lipsă de cunoaștere)

- nu știm exact parametrii sau structura modelului
- λ estimat din 200 de valori; familia distribuției
- se propagă prin **bootstrap** sau abordări bayesiene
- se **reduce** prin mai multe date

Un raport complet le separă: „W = 9,8 ± 0,4 din variabilitatea simulării, dar între 6 și 100 dacă ținem cont de incertitudinea lui λ”. Replicările nu pot compensa lipsa de date.

Reproductibilitate: altcineva obține aceleași cifre?

- **Semințe** explicite și salvate pentru fiecare rulare; niciodată sămânța implicită „din ceas” în rezultatele raportate
- Fluxuri independente pentru replicări paralele: **SeedSequence.spawn** (NumPy) – nu semințele 1, 2, 3
- Versiunile bibliotecilor fixate (requirements.txt, environment.yml); rezultatele pot varia între versiuni
- **Notebook-uri** executabile și un depozit git: codul exact care a produs fiecare figură
- **Containere** (Docker) pentru medii complete; configurația experimentelor salvată lângă rezultate

C **În acest curs**

Toate cifrele din slide-uri sunt produse de scripturi cu semințe fixe; notebook-ul săptămânii le reproduce. Așa am găsit și erorile din materialele vechi.

Semințe pentru replicări paralele (NumPy)

```
import numpy as np

root = np.random.SeedSequence(20261006)  # în raport
children = root.spawn(30)   # 30 de fluxuri independente
rngs = [np.random.default_rng(s) for s in children]

# replicarea j folosește doar rngs[j], pe orice nucleu
Y = [replicare(rngs[j]) for j in range(30)]

# CRN: aceeași copie j pentru variantele A și B
# scopuri diferite: children[j].spawn(2) -> sosiri, serviri
```

- O singură sămânță **rădăcină**, raportată
- spawn: fluxuri garantat independente
- Funcționează și pe cluster
- Se combină cu CRN

Validarea modelelor moderne: probleme deschise

1 Modele bazate pe agenți

Comportamentul apare din interacțiuni; validăm **tipare** (distribuții, structuri spațiale), nu doar medii – pattern-oriented modelling.

2 Gemeni digitali

Modelul rulează continuu lângă sistemul real: validarea devine **permanentă**, cu recalibrare automată din date.

3 Surogate ML

Rețele neuronale antrenate pe rulări de simulare: rapide, dar valide doar în domeniul datelor de antrenare.

4 Agenți cu LLM

Simulări sociale cu agenți conduși de modele de limbaj: plauzibile, dar greu de validat și reproductibile doar parțial.

Încrederea este o chestiune de grad

- „Toate modelele sunt greșite, dar unele sunt utile” (G. Box): întrebarea este **utile pentru ce**
- Credibilitatea se construiește: verificare + validare + date documentate + experți implicați de la început
- Documentați **presupunerile** și domeniul de valabilitate: ce întrebări **nu** poate primi modelul
- Validarea costă: nivelul de efort trebuie să fie proporțional cu **miza** deciziei
- Un model bun este revizuit când apar date noi – validarea nu se face o singură dată

S **Sargent**

Un model este valid pentru un **scop**, pe un **domeniu** de condiții, cu o **precizie** acceptabilă. Toate trei trebuie spuse explicit.

Rezumatul săptămânii

- ✓ Intrări: explorare, **MLE**, Q-Q, KS/χ^2; forma distribuției contează (−37% la așteptare); NHPP pentru rate variabile
- ✓ Ieșiri: încălzire (Welch), **replicări** și IÎ cu t, $R \geq (t \cdot s/h)^2$, loturi; CRN pentru comparații
- ✓ Verificare = programul e corect; **validare** = modelul e potrivit scopului, pe mărimea de interes
- ✓ Ghișeul: ρ corect nu garantează Wq corect; validăm pe ce contează pentru decizie
- ✓ Sensibilitate (tornado), 2^k, incertitudinea parametrilor, **reproductibilitate**

Săptămâna viitoare

Sisteme dinamice continue

- Ecuații diferențiale: metodele Euler și Runge–Kutta 4
- Pasul de timp, stabilitate, eroare
- Modele clasice: Lotka–Volterra (prădător–pradă), SIR (epidemii)

Bila din S5 se mișca fără forțe. Ce facem când forțele acționează tot timpul și nu mai există „următorul eveniment”?

Bibliografie pentru săptămâna 6

- Ș. Holban – Tehnici de modelare și simulare, cap. 4: analiza datelor, estimare, validarea modelelor (materiale de curs)
- R. J. Gibbens – Computer Systems Modelling, Cambridge – analiza ieșirilor, reducerea dispersiei (foaia de exerciții 1)
- A. M. Law – Simulation Modeling and Analysis, ed. 5, McGraw-Hill, 2015 – cap. 5, 6, 9–12
- J. Banks, J. S. Carson, B. L. Nelson, D. M. Nicol – Discrete-Event System Simulation, ed. 5, Pearson, 2010
- R. G. Sargent – Verification and validation of simulation models, Journal of Simulation, 7(1), 2013
- O. Balci – Verification, validation and testing, în J. Banks (ed.), Handbook of Simulation, Wiley, 1998
- P. D. Welch – The statistical analysis of simulation results, în S. Lavenberg (ed.), Computer Performance Modeling Handbook, 1983
- P. A. W. Lewis, G. S. Shedler – Simulation of nonhomogeneous Poisson processes by thinning, Naval Research Logistics Quarterly, 1979
- S. M. Stigler – Do robust estimators deal with real data?, Annals of Statistics, 5(6), 1977 (datele lui Cavendish)
- Prezentare realizata cu ajutorul Claude Fable 5.1 și Claude Opus 5.5