MODELARE ȘI SIMULARE

Săptămâna 6. Date de intrare, analiza rezultatelor, validare

Suport de curs · Anul III, Calculatoare și Tehnologia Informației

Ș.l. dr. ing. Cătălin Iapă

Obiective

1. să transformați date brute într-o distribuție de intrare: histogramă, estimare prin verosimilitate maximă, grafic Q-Q, teste Kolmogorov–Smirnov și χ^2, criteriul AIC;
2. să modelați sosiri dependente de timp printr-un proces Poisson neomogen și să le generați prin subțiere;
3. să identificați perioada de încălzire cu metoda Welch și să raportați rezultate cu intervale de încredere bazate pe replicări independente;
4. să calculați numărul necesar de replicări, să folosiți medii pe loturi și să comparați variante cu numere aleatoare comune;
5. să distingeți verificarea de validare și să aplicați tehnici concrete pentru fiecare, inclusiv validarea statistică pe date istorice;
6. să faceți analize de sensibilitate și experimente factoriale 2^k și să asigurați reproductibilitatea rezultatelor.

Cuvinte cheie: *date de intrare, histogramă, mediană, abatere standard, grafic Q-Q, verosimilitate maximă, metoda momentelor, testul Kolmogorov–Smirnov, testul χ^2, AIC, distribuția lognormală, distribuție empirică, proces Poisson neomogen, subțiere, regim tranzitoriu, încălzire, metoda Welch, replicări independente, interval de încredere, distribuția t, medii pe loturi, autocorelație, numere aleatoare comune, variabile antitetice, variabile de control, verificare, validare, calibrare, analiza sensibilității, experiment factorial, incertitudine, reproductibilitate*

1. Modelarea datelor de intrare

1.1. De la date brute la o distribuție

Un studiu de simulare este un lanț: date de intrare, model, rezultate, decizie. Săptămânile trecute ne-am concentrat pe model; acum ne ocupăm de celelalte verigi, care sunt de obicei mai slabe. Expresia **garbage in, garbage out** rezumă prima problemă: un simulator perfect, alimentat cu distribuții greșite, dă răspunsuri greșite, dar foarte precise. A doua problemă este că rezultatul unei simulări stohastice este o variabilă aleatoare și trebuie tratat statistic.

Procesul clasic de modelare a datelor de intrare are cinci pași: **colectarea** datelor (loguri, cronometrări, senzori), **explorarea** lor (histogramă, medie, mediană, coeficient de variație, valori suspecte, tendințe în timp), alegerea unor **familii** candidate de distribuții (din mecanismul fizic și din forma histogramei), **estimarea parametrilor** (de obicei prin verosimilitate maximă) și **verificarea potrivirii** (grafice Q-Q, teste statistice, criterii informaționale). Dacă potrivirea este slabă, ne întoarcem la pasul al treilea. Datele despre ieșirile sistemului (de exemplu timpii de așteptare măsurați) nu se folosesc la construirea modelului, ci se păstrează separat, pentru validare.

La colectare apar capcane frecvente: rotunjiri (timpi notați la minut întreg), amestecarea unor perioade diferite (ora de vârf cu noaptea), date **cenzurate** (clienții care au renunțat nu au timp de servire), măsurarea

a ceea ce este ușor în loc de ceea ce contează, efectul observatorului și valorile aberante, care pot fi erori de transcriere sau evenimente rare, dar reale. Valorile aberante se investighează, nu se șterg automat.

1.2. Un exemplu istoric: Cavendish (Holban, cap. 4)

În 1798, Henry Cavendish a măsurat densitatea Pământului cu o balanță de torsiune și a obținut 29 de valori, între 4,07 și 5,86 g/cm³ (Figura 1). Media este **5,42**, mediana **5,46**, iar abaterea standard (cu n − 1) este **0,339**. Graficul Q-Q față de distribuția normală arată că 27 de valori urmează bine o dreaptă, în timp ce două valori, 4,07 și 4,88, se abat clar. Fără ele, media devine 5,49, abaterea standard 0,193, iar intervalul de încredere de 95% pentru medie, [5,41; 5,57], conține valoarea modernă de aproximativ 5,51 g/cm³. Mediana se schimbă doar cu o sutime: este o statistică **robustă**.

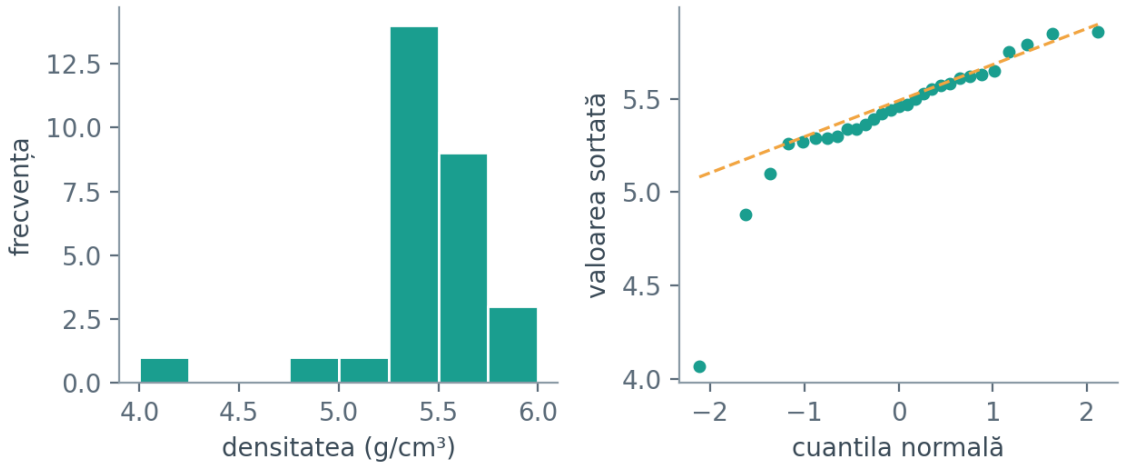


Figura 1. Datele lui Cavendish: histograma cu clase de 0,25 și graficul Q-Q față de distribuția normală

Dispersia de selecție se calculează cu împărțire la n − 1, pentru că media este estimată din aceleași date, iar abaterile față de ea sunt sistematic puțin mai mici decât cele față de media adevărată; împărțirea la n − 1 face estimatorul nedeplasat. Diferența contează la eșantioane mici, de exemplu la un număr mic de replicări.

Tabelul 1. Erori găsite în capitolul 4 al cursului Holban, verificate prin recalculare

Unde	În curs	Corect
Lista inițială vs lista sortată	5,88 vs 4,88	una dintre ele este greșită; cu 4,88, media este 5,42
P(densitate < 5,5)	0,677	17/29 = 0,586 (clase închise la dreapta)
Aria clasei 5,75–6	0,02586	3/29 = 0,1034
Exemplul cu 9 valori (35 … 75)	media 67; formula cu 1/n	media 53,67; 12,08 corespunde formulei cu n − 1
Exemplul cu 4 eșantioane	Σ pătrate 128,34; eroarea standard 3,77	128,75; 3,28 (secțiunea 2.3)

Asemenea greșeli apar în orice material transcris manual; un script scurt le găsește imediat. Aceeași disciplină se aplică datelor de intrare ale unei simulări: rezumatele numerice se recalculează din datele brute, nu se copiază.

1.3. Potrivirea distribuțiilor: timpii de servire ai unui API

Avem 500 de timpi de servire ai unui serviciu web, extrași dintr-un log. Media este 95,9 ms, mediana doar 56,8 ms, abaterea standard 141,1 ms, iar coeficientul de variație la pătrat **$C_s^2 = 2{,}17$**, dublu față de distribuția exponențială ($C_s^2 = 1$). Distribuția este asimetrică, cu o coadă lungă (p95 = 271 ms, maximul 1 745 ms). Familiile candidate se aleg și după mecanismul care produce datele: exponențiala pentru evenimente rare și independente, gamma și Erlang pentru sume de faze, **lognormala** pentru produse de mulți factori (tipică pentru timpi de răspuns), Weibull pentru durate de viață, triunghiulara și PERT când avem doar estimări ale experților.

Parametrii se estimează prin **verosimilitate maximă** (MLE): alegem valorile care maximizează $\Sigma \ln f(x_i; \theta)$. Pentru exponențială rezultă $\hat{\lambda} = 1/\bar{x}$; pentru lognormală, $\hat{\mu}$ și $\hat{\sigma}$ sunt media și abaterea standard ale logaritmilor (4,044 și 0,999); pentru gamma, estimarea este numerică (formă 1,10, scală 87,2 ms). **Metoda momentelor** pentru gamma dă o formă de 0,462, foarte diferită; o asemenea discrepanță între două metode rezonabile semnalează că familia nu se potrivește datelor (Figura 2).

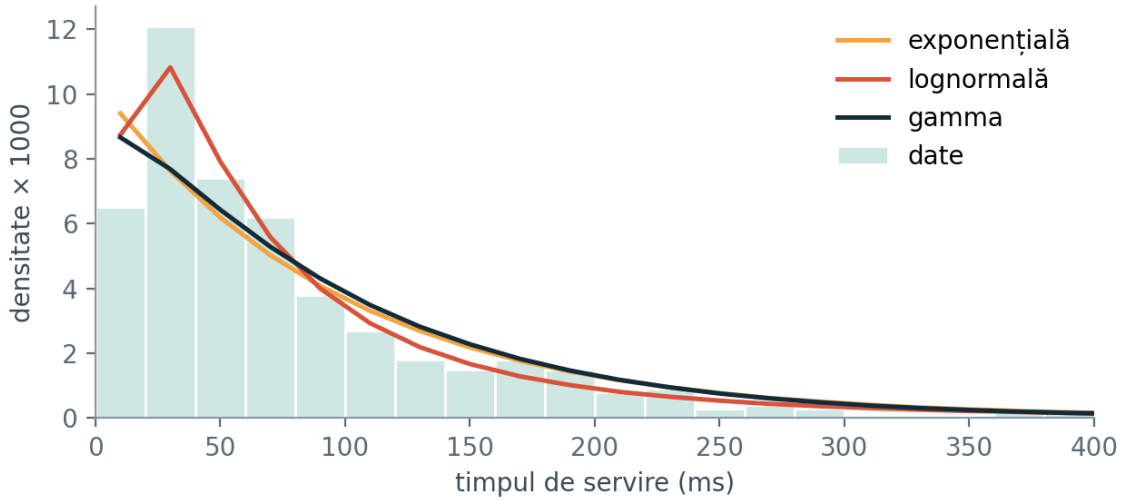


Figura 2. Histograma timpilor de servire și densitățile ajustate prin verosimilitate maximă

```
from scipy import stats
cand = {"exp":   stats.expon(*stats.expon.fit(x, floc=0)),
        "logn":  stats.lognorm(*stats.lognorm.fit(x, floc=0)),
        "gamma": stats.gamma(*stats.gamma.fit(x, floc=0))}
for name, d in cand.items():
    ks = stats.kstest(x, d.cdf)
    aic = 2 * (len(d.args) - 1) - 2 * d.logpdf(x).sum()
    print(name, ks.statistic, ks.pvalue, aic)
```

Graficul **Q-Q** compară cuantilele datelor cu cele ale distribuției ajustate; punctele trebuie să stea pe diagonală. Pentru exponențială punctele se curbează sistematic, iar pentru lognormală urmează diagonala pe tot domeniul (Figura 3). Testul **Kolmogorov–Smirnov** folosește distanța maximă D dintre funcția de repartiție empirică și cea teoretică; pentru n mare și $\alpha = 5\%$, valoarea critică este aproximativ $1{,}36/\sqrt{n}$ (0,061 pentru n = 500). Când parametrii sunt estimați din aceleași date, p-valoarea standard este prea optimistă. Testul **χ^2** compară frecvențele observate și așteptate pe clase (de preferință echiprobabile, cu cel puțin 5 valori așteptate), cu $k - 1 - p$ grade de libertate, unde p este numărul de parametri estimați. **AIC** $= 2k - 2 \ln L$ penalizează parametrii suplimentari; o diferență de peste 10 este considerată decisivă.

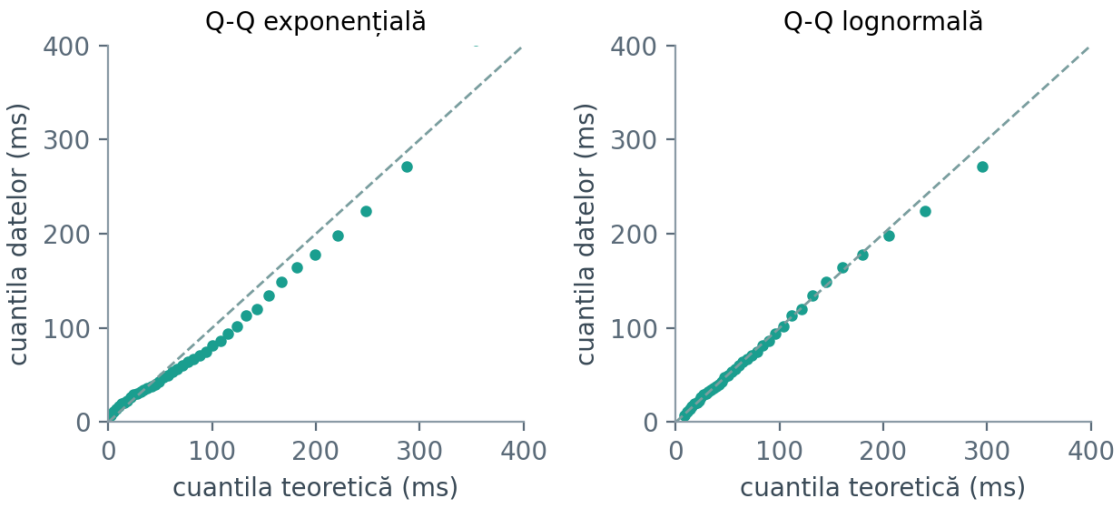


Figura 3. Graficele Q-Q ale timpilor de servire față de exponențială (stânga) și lognormală (dreapta)

Tabelul 2. Rezultatele testelor de potrivire pentru cele trei familii

Distribuția	KS: D	KS: p	χ^2 (gl)	χ^2: p	AIC
exponențială	0,086	0,0012	48,0 (8)	< 0,001	5 565
gamma	0,097	0,0002	46,6 (7)	< 0,001	5 564
lognormală	0,026	0,87	3,5 (7)	0,84	5 466

O p-valoare mică înseamnă că datele ar fi improbabile dacă distribuția ar fi corectă, deci o respingem. O p-valoare mare **nu dovedește** că distribuția este corectă. Cu puține date aproape orice distribuție trece testele, iar cu foarte multe aproape oricare este respinsă. De aceea graficele și, mai ales, impactul asupra rezultatelor simulării sunt la fel de importante ca testele.

Cât costă o distribuție greșită? Pentru un server cu sosiri Poisson la $\rho = 0{,}8$, formula Pollaczek–Khinchine, $W_q = \rho(1 + C_s^2)/(2(1 - \rho))\cdot s$, dă 383 ms dacă presupunem servire exponențială și **607 ms** cu variabilitatea reală a datelor: modelul exponențial subestimează așteptarea cu aproximativ 37%. Simularea confirmă ordinul de mărime (380 ms vs 568 ms cu reeșantionare din date). Pentru media așteptării contează primele două momente ale servirii; pentru percentile contează toată forma distribuției.

Alternativa la familiile teoretice este **distribuția empirică**: eșantionăm direct din date (reeșantionare). Ea reproduce exact forma datelor, dar nu poate genera valori mai mari decât maximul observat, deci subestimează evenimentele rare. Un compromis frecvent este empirica interpolată, completată cu o coadă teoretică. Când nu avem deloc date, folosim distribuții uniforme, triunghiulare sau PERT pe baza estimărilor experților (minim, valoare probabilă, maxim), iar analiza de sensibilitate devine obligatorie.

1.4. Sosiri dependente de timp

Rata sosirilor variază adesea pe parcursul zilei. Modelul standard este **procesul Poisson neomogen** (NHPP): numărul de sosiri în [a, b] are distribuția Poisson cu media $\Lambda(a, b) = \int \lambda(t)\, dt$, iar intervalele disjuncte sunt independente. În exemplul nostru, rata este de aproximativ 10 clienți pe oră dimineața, 60 la prânz și 40 după program (Figura 4); o zi simulată are 313 de sosiri. Generarea se face prin **subțiere** (Lewis–Shedler): generăm un proces Poisson omogen cu rata maximă λ_{max} și păstrăm fiecare candidat cu probabilitatea $\lambda(t)/\lambda_{max}$ (aici se acceptă 42% din candidați).

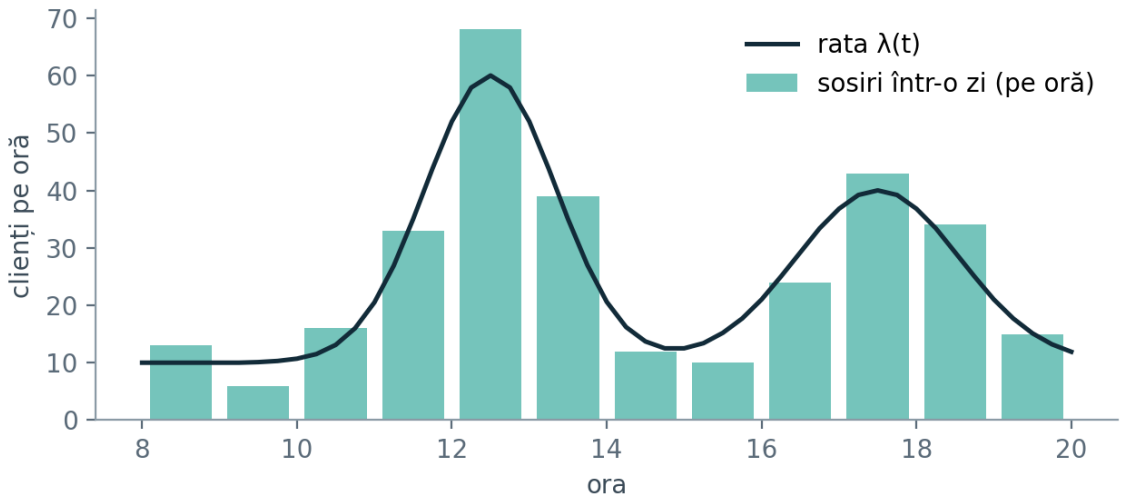


Figura 4. Rata λ(t) și sosirile pe ore dintr-o zi generată prin subțiere

```
def nhpp(rate, lam_max, T, rng):
    t, out = 0.0, []
    while True:
        t += rng.exponential(1 / lam_max)      # candidat
        if t > T:
            return out
        if rng.random() < rate(t) / lam_max:
            out.append(t)                      # acceptat
```

Pentru un proces Poisson, dispersia numărului de sosiri pe interval este egală cu media. Pe intervale de 10 minute din 30 de zile, raportul dispersie/medie este 2,43 pe toată ziua, iar testul χ^2 respinge categoric ipoteza Poisson omogen; în interiorul orei de prânz raportul este 0,85, iar testul nu respinge ($p = 0,67$). Concluzia practică: modelăm ziua pe intervale orare, fiecare cu rata ei. Alte structuri de verificat în date sunt sezonalitatea, corelațiile dintre valori consecutive, rafalele (procese Poisson modulate Markov) și dependențele între variabile; simularea ghidată de urme (trace-driven) folosește direct secvența reală de evenimente.

Pentru volume mari de date, media și dispersia se calculează „din mers” cu **algoritmul Welford**: la fiecare valoare nouă, $d = x - \text{medie}$, $\text{medie} \mathrel{+}= d/n$, $M2 \mathrel{+}= d \cdot (x - \text{medie})$, iar $s^2 = M2/(n-1)$. Formula aparent mai simplă $\Sigma x^2 - n\bar{x}^2$ poate pierde toată precizia în virgulă mobilă (anulare catastrofală).

De reținut

Pași: colectare, explorare, familie, parametri (MLE), potrivire (Q-Q, KS, χ^2, AIC). Mediana este robustă; valorile suspecte se investighează. Pentru API: $Cs^2 = 2,2$, lognormala câștigă, iar exponențiala subestimează așteptarea cu ~37%. O p-valoare mare nu dovedește potrivirea. Sosirile variabile se modelează ca NHPP, generat prin subțiere; Poisson pe intervale scurte, nu pe toată ziua.

2. Analiza rezultatelor

2.1. Rezultatul unei simulări este o variabilă aleatoare

Un simulator stohastic este un experiment statistic: altă sămânță dă alt rezultat, deci o rulare este o singură observație. Pentru o coadă M/M/1 la ρ = 0,9, zece rulări a câte 5 000 de clienți dau timpi medii în sistem între 6,6 și 15,7, față de valoarea teoretică 10. Ieșirile unei simulări au trei probleme statistice: **deplasarea inițială** (pornim dintr-o stare nereprezentativă), **variabilitatea** și **autocorelația** (observațiile consecutive nu sunt independente). O a patra problemă, modelul greșit, nu se rezolvă statistic.

Distingem simulările **terminale**, cu un final natural (o zi la bancă, o tură), în care starea inițială face parte din problemă, de simulările **staționare**, care studiază comportamentul pe termen lung (un server care rulează permanent), în care starea inițială este artificială. Formulele din S4 descriu regimul staționar.

2.2. Perioada de încălzire (metoda Welch)

Pornind M/M/1 la ρ = 0,9 cu sistemul gol, primii 100 de clienți petrec în medie doar 6,14 unități de timp în sistem, față de 10 în regim staționar. Timpul de relaxare al cozii M/M/1 este aproximativ $1/(\mu(1-\sqrt{\rho})^2)$: circa 380 de unități de timp la ρ = 0,9, dar doar 12 la ρ = 0,5. Metoda **Welch** mediază observația i peste R replicări pilot, netezește curba cu o medie mobilă și alege vizual punctul după care curba se stabilizează (Figura 5). Aici alegem 1 000 de clienți, eliminați apoi din fiecare replicare. Este preferabilă o încălzire prea lungă decât una prea scurtă; există și metode automate, de exemplu MSER-5.

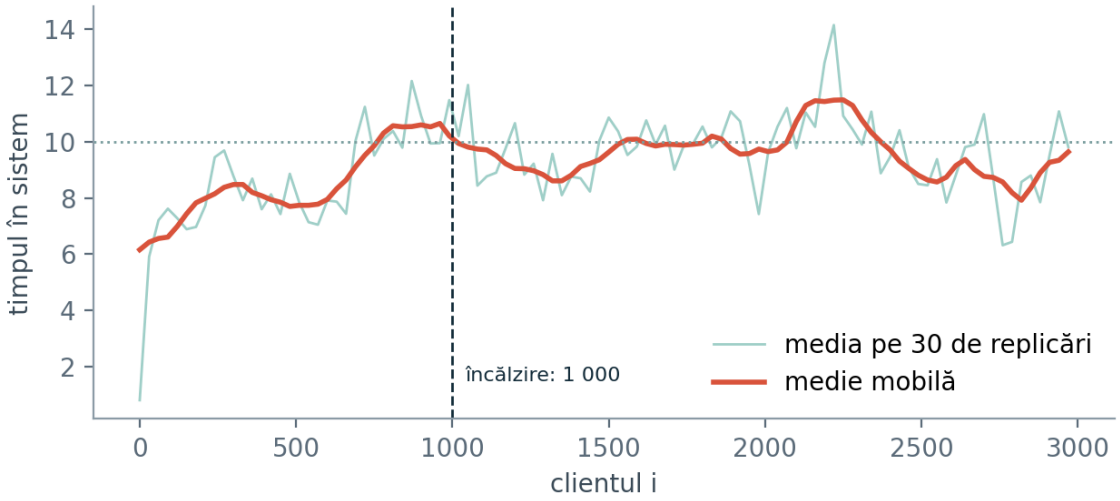


Figura 5. Metoda Welch: media pe 30 de replicări a timpului în sistem al clientului i și media mobilă

2.3. Replicări independente și intervale de încredere

Metoda replicărilor independente rulează modelul de R ori, cu fluxuri de numere aleatoare independente, și reține din fiecare rulare o singură valoare Y_j (de exemplu media după încălzire). Valorile Y_1, Y_2, … sunt independente și identic distribuite, iar intervalul de încredere pentru medie este $\bar{Y} \pm t(1-\alpha/2;\, R-1)\cdot s/\sqrt{R}$. Interpretarea: 95% dintre intervalele construite astfel conțin valoarea adevărată. Eroarea standard scade doar cu √R, deci o precizie de două ori mai bună costă de patru ori mai multe replicări.

Răspunsul la întrebarea din S5: cu 30 de replicări a câte 20 000 de clienți după încălzire, $\bar{Y}$ = 9,799, s = 1,087, t(0,975; 29) = 2,045, iar intervalul de 95% este **[9,39; 10,21]**, care conține valoarea teoretică 10 (Figura 6). Valoarea 10,56 dintr-o singură rulare era zgomot statistic. Raportăm: „W = 9,80 ± 0,41 (IÎ 95%, 30 de replicări, încălzire 1 000 de clienți)”.

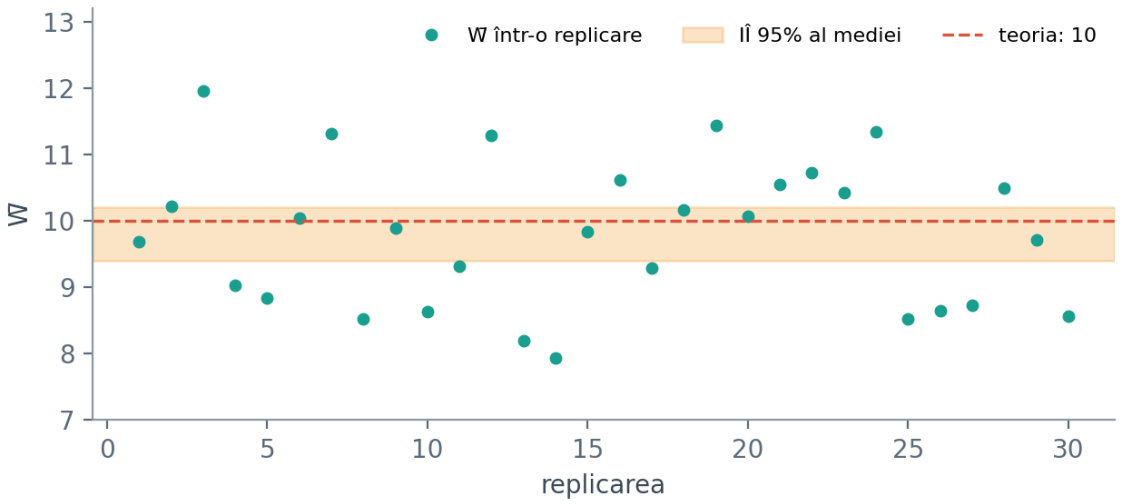


Figura 6. 30 de replicări independente, intervalul de încredere de 95% al mediei și valoarea teoretică

```
Y = np.array([replicare(300 + j) for j in range(30)])
R, m, s = len(Y), Y.mean(), Y.std(ddof=1)
h = stats.t.ppf(0.975, R - 1) * s / np.sqrt(R)
print(f"W = {m:.2f} ± {h:.2f}")
```

Pentru eșantioane mici folosim distribuția Student. Exemplul Cambridge cu 17 repetiții ($\bar{x}$ = 3,776, s = 0,902) dă semilățimea 0,429 cu z = 1,96, dar 0,464 cu t(0,975; 16) = 2,12. Exemplul lui Holban cu patru eșantioane (mediile 53, 45, 59, 46) se corectează astfel: $\Sigma(\bar{x}_i - \bar{x})^2 = 128{,}75$, s = 6,55, eroarea standard $s/\sqrt{4} = 3{,}28$, iar cu t(0,975; 3) = 3,182 intervalul este [40,3; 61,2], care conține media adevărată 50 a distribuției uniforme pe (0, 100).

Numărul de replicări necesar pentru o semilățime h este $\mathbf{R \geq (t \cdot s/h)^2}$, cu s estimat din replicări pilot. Pentru h = 0,25 obținem aproximativ 80 de replicări, iar pentru h = 0,1 aproximativ 450–500. În practică se folosește adesea o procedură secvențială: se adaugă replicări până când semilățimea scade sub h, cu un număr minim impus. Pentru proporții și percentile se aplică aceeași regulă (o valoare pe replicare), dar mărimile rare cer rulări mult mai lungi sau tehnici speciale (importance sampling).

2.4. Autocorelația și mediile pe loturi

Formula naivă s/√n aplicată clienților unei singure rulări presupune observații independente, ceea ce este fals: corelația dintre timpii a doi clienți consecutivi este 0,987, iar la distanța de 100 de clienți încă 0,41. Într-un experiment cu 200 de repetări la ρ = 0,8, intervalele din 10 replicări au conținut valoarea adevărată în 89,5% din cazuri, iar intervalele naive doar în **15,5%**, fiind de aproximativ 10 ori prea înguste.

Metoda **mediilor pe loturi** împarte o singură rulare lungă, după încălzire, în k loturi consecutive și tratează mediile loturilor ca pe replicări. Cu 400 000 de clienți în 20 de loturi obținem W = 10,16 ± 0,59, iar corelația dintre loturi vecine este -0,20; intervalul naiv pe aceleași date ar fi fost ±0,032. Replicările sunt recomandarea implicită (simple, paralelizabile, singura opțiune pentru simulări terminale); mediile pe loturi economisesc încălzirea. Există și metoda regenerativă și metode spectrale.

2.5. Compararea variantelor și reducerea dispersiei

Pentru a compara două variante calculăm, în fiecare replicare, diferența D_j și construim intervalul t pentru media diferențelor (t pereche). Exemplu: M/M/1 cu λ = 0,8 și μ = 1 (W = 5) vs μ = 1,1 (W = 3,33); diferența teoretică este 1,667. Cu **numere aleatoare comune** (CRN), ambele variante folosesc aceleași sosiri și aceleași

cereri de servire, deci rezultatele lor sunt corelate pozitiv și Var(A − B) = Var(A) + Var(B) − 2·Cov(A, B) scade. Cu 20 de replicări, semilățimea intervalului pentru diferență scade de la ±0,275 la **±0,131**, iar raportul dispersiilor este 4,4 (Figura 7). Implementarea cere câte un generator pentru fiecare scop (sosiri, serviri), cu aceeași sămânță în ambele variante.

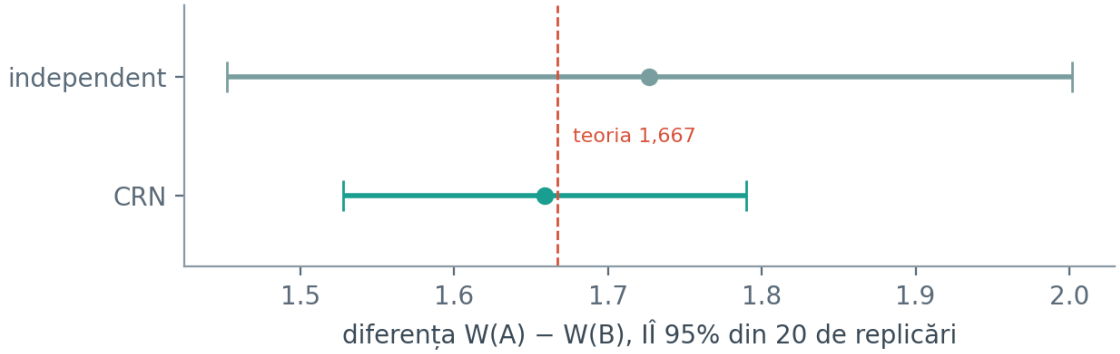


Figura 7. Intervalele de 95% pentru diferența W(A) − W(B): fluxuri independente vs numere aleatoare comune

Variabilele antitetice rulează modelul cu U și cu 1 − U și mediază perechea; pentru suma așteptărilor primilor 10 clienți (exemplul Cambridge), câștigul în dispersie este de 1,46 ori. **Variabilele de control** corectează rezultatul cu o mărime de medie cunoscută: Z = X + c(Y − E[Y]), cu c = *−Cov(X, Y)/Var(Y); cu Y = suma timpilor de servire, corelația este 0,66 și dispersia scade de 1,78 ori. Când comparăm multe variante, folosim corecția Bonferroni sau proceduri de selecție a celei mai bune variante; o diferență semnificativă statistic nu este neapărat importantă practic.*

De reținut

O rulare = o observație. Staționar: încălzire (Welch); terminal: replicări ale întregii perioade. Replicări + t: W = 9,80 ± 0,41 conține 10; R ≥ (t·s/h)². Autocorelația face formula naivă greșită (acoperire 15%); soluții: replicări sau medii pe loturi. Comparații: diferențe pereche și numere aleatoare comune; variabile antitetice și de control. Raportăm intervalul, metoda, încălzirea, semințele.

3. Verificare, validare, încredere

3.1. Verificare și validare

Verificarea răspunde la întrebarea „am construit corect modelul?”: programul implementează fidel modelul conceptual. **Validarea** răspunde la întrebarea „am construit modelul corect?”: modelul reprezintă suficient de bine sistemul real, pentru scopul studiului. În ciclul lui Sargent, validarea conceptuală leagă sistemul de modelul conceptual, verificarea leagă modelul conceptual de program, iar validarea operațională compară rezultatele programului cu sistemul; validitatea datelor se verifică la fiecare pas. Validitatea este întotdeauna relativă la scop.

Tehnicile de verificare includ urma pas cu pas, comparația cu rezultate cunoscute (M/M/1, Erlang C, legea lui Little), cazurile extreme, legile de conservare, două implementări independente (motorul nostru și SimPy) și testele automate. Diferențele dintre simulare și teorie se judecă statistic, cu intervale de încredere. Tehnicile de validare includ validitatea aparentă (experții), comparația cu date istorice, testul Turing, comparația cu alte modele, validarea predictivă și validarea evenimentelor.

3.2. Studiu de caz: validarea modelului unui ghișeu

Profesorul Holban descrie modelarea ca pe un șir de modele $M_1, \ldots, M_k$, rafinate până când comportamentul se apropie de al sistemului, cu criteriul ca gradul de ocupare simulat să cadă în $[\rho - \sigma, \rho + \sigma]$. Considerăm un ghișeu cu un funcționar, 8 ore pe zi, sosiri Poisson cu $\lambda = 0{,}8$/min și servire reală lognormală cu media 1 min și $Cs^2 \approx 2$, măsurat pe 20 de zile. Modelul A presupune servire exponențială, iar modelul B folosește lognormala ajustată. Ocuparea reală este 0,803 ± 0,057; modelele dau 0,796 și 0,817, deci ambele trec criteriul.

Pe mărimea de interes, așteptarea medie în coadă, situația se schimbă: realitatea dă 5,42 min, modelul A 3,65 min (testul t Welch respinge, $p = 0{,}023$), iar modelul B 5,54 min ($p = 0{,}91$) (Figura 8). Gradul de ocupare depinde doar de media servirii, deci nu poate distinge modelele. Lecțiile: validăm pe mărimile care contează pentru decizie; ρ corect este o condiție necesară, nu suficientă; intervalul $[\rho - \sigma, \rho + \sigma]$ descrie variația zilelor, nu incertitudinea mediei; eroarea modelului A vine din datele de intrare, deci nicio verificare a codului nu ar fi găsit-o.

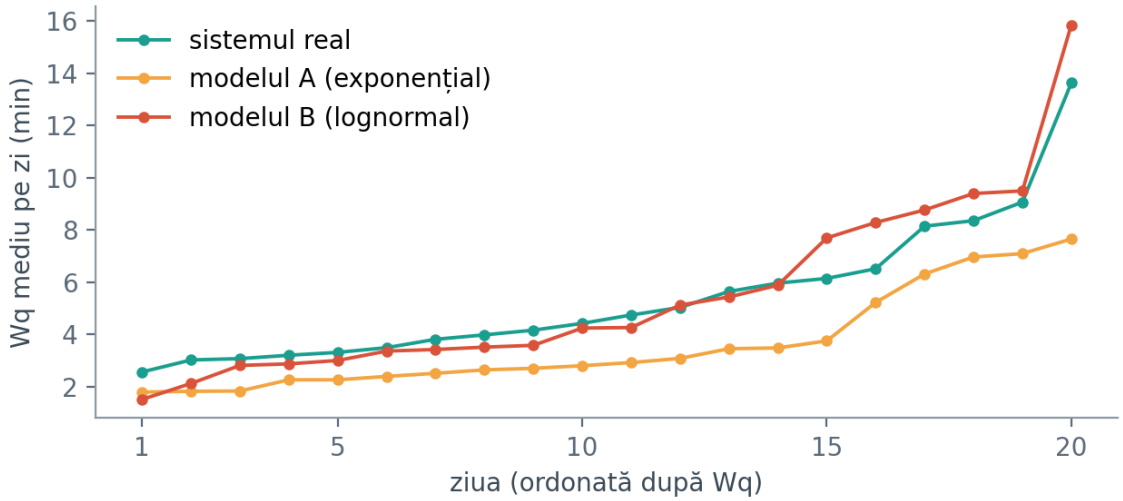


Figura 8. Așteptarea medie pe zi, ordonată crescător: sistemul real și cele două modele

Calibrarea ajustează parametrii nemăsurabili astfel încât modelul să reproducă datele; validarea trebuie făcută pe date nefolosite la calibrare, exact ca separarea datelor de antrenare și de test în învățarea automată. Un plan de validare are cinci pași: scopul, mărimile de ieșire și toleranța (fixate înainte de a vedea rezultatele), date separate, implicarea experților, comparații statistice pe mărimile de interes și documentarea presupunerilor și a domeniului de valabilitate.

3.3. Analiza sensibilității și experimente factoriale

Analiza sensibilității arată cât se schimbă rezultatul când intrările sunt puțin greșite. Pentru unitatea de urgențe din S5 ($\lambda = 6$ pacienți/oră, consultația 25 min, 3 medici, ocupare 0,83), așteptarea medie dată de Erlang C este 35,1 min. O variație de ±10% a ratei sosirilor o schimbă între 18,9 și 84,7 min, iar una a duratei consultației între 17,0 și 93,1 min; un al patrulea medic o reduce la 5,3 min (Figura 9). Aproape de saturație, erorile mici ale intrărilor sunt amplificate, deci λ și s trebuie estimate precis; cu patru medici decizia este robustă.

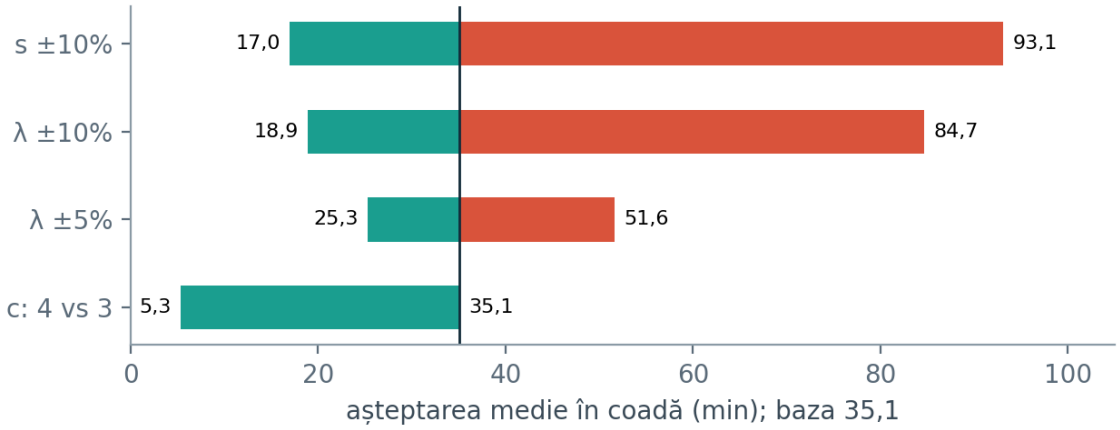


Figura 9. Diagrama tornado pentru așteptarea medie la unitatea de urgențe (Erlang C)

Metoda „un factor o dată” nu vede interacțiunile. Un **experiment factorial 2^k** variază simultan toți factorii între două niveluri. Cu $c \in \{2, 3\}$, $s \in \{0{,}8; 1{,}0\}$ și $\lambda \in \{1{,}2; 1{,}5\}$, cu câte 5 replicări pentru fiecare dintre cele 8 combinații, toate valorile simulate sunt compatibile cu Erlang C. Efectul principal al unui factor este diferența dintre media la nivelul sus și media la nivelul jos: c: -0,55, s: +0,53, λ: +0,27; interacțiunea c × s este -0,25, adică un server în plus ajută mai mult când servirea este lentă.

3.4. Incertitudine și reproductibilitate

Intervalele de încredere din replicări acoperă doar variabilitatea simulării, nu și incertitudinea parametrilor. Dacă λ este estimat din 200 de sosiri ($\hat{\lambda} = 0{,}942$, $\mu = 1$), formula dă $W = 17{,}3$, dar intervalul bootstrap pentru λ este [0,82; 1,09]. Propagând incertitudinea, în 20,6% din eșantioane sistemul este instabil, iar printre celelalte W variază între 6,1 (p5) și 106,7 (p95) (Figura 10). Distingem incertitudinea **aleatorie** (variabilitatea sistemului, cuantificată prin replicări) de cea **epistemică** (lipsa de cunoaștere, redusă doar cu date suplimentare).

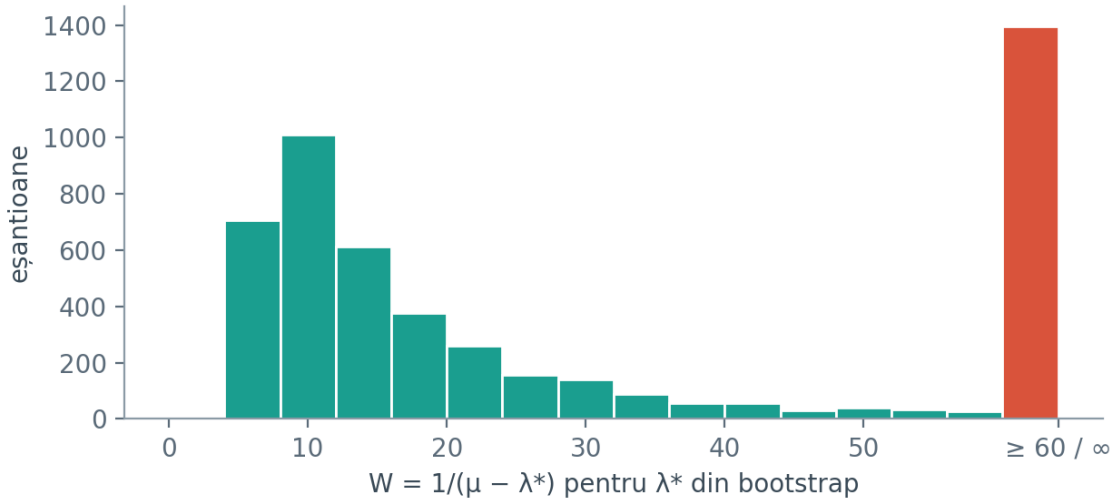


Figura 10. Distribuția lui W când λ este estimat din 200 de observații (5 000 de eșantioane bootstrap)

Reproductibilitatea cere semințe explicite și salvate, fluxuri independente pentru replicări paralele (NumPy SeedSequence.spawn), versiuni fixate ale bibliotecilor, notebook-uri executabile într-un depozit git și, pentru medii complete, containere. Validarea modelelor moderne rămâne o problemă deschisă: modelele bazate pe agenți se validează pe tipare, gemenii digitali cer validare continuă, surogatele învățate automat sunt valide doar în domeniul datelor de antrenare, iar simulările cu agenți conduși de modele de limbaj sunt greu

de validat și de reprodus. Un model este valid pentru un scop, pe un domeniu de condiții, cu o precizie acceptabilă.

De reținut

Verificare = programul este corect; validare = modelul este potrivit scopului. Ghișeul: ρ corect nu garantează Wq corect; validăm pe mărimea de interes, pe date nefolosite la calibrare. Sensibilitatea (tornado) arată ce intrări trebuie estimate precis; experimentele 2^k dau efecte și interacțiuni. Incertitudinea parametrilor poate domina zgomotul simulării. Reproductibilitate: semințe, versiuni, notebook-uri.

Glosar RO – EN

Română	English
date de intrare	input data
verosimilitate maximă	maximum likelihood estimation (MLE)
metoda momentelor	method of moments
grafic Q-Q	Q-Q plot
test de potrivire	goodness-of-fit test
funcție de repartiție empirică	empirical distribution function
distribuție empirică	empirical distribution
date cenzurate	censored data
valoare aberantă	outlier
proces Poisson neomogen	non-homogeneous Poisson process (NHPP)
subțiere	thinning
simulare terminală / staționară	terminating / steady-state simulation
perioadă de încălzire	warm-up period
deplasare inițială	initialisation bias
replicări independente	independent replications
interval de încredere	confidence interval
eroare standard	standard error
medii pe loturi	batch means
autocorelație	autocorrelation
acoperire	coverage
numere aleatoare comune	common random numbers (CRN)

Română	English
variabile antitetice	antithetic variates
variabile de control	control variates
reducerea dispersiei	variance reduction
verificare / validare	verification / validation
validitate aparentă	face validity
calibrare	calibration
analiza sensibilității	sensitivity analysis
experiment factorial	factorial design
efect principal / interacțiune	main effect / interaction
incertitudine aleatorie / epistemică	aleatory / epistemic uncertainty
reproductibilitate	reproducibility

Întrebări de autoevaluare

1. Din datele lui Cavendish eliminăm două valori suspecte. Care statistică se schimbă cel mai puțin?

a) media

b) mediana

c) abaterea standard

d) amplitudinea (max − min)

2. De ce se împarte la n − 1 în formula dispersiei de selecție?

a) pentru că prima valoare nu se folosește

b) pentru că așa se obține abaterea standard

c) pentru că media este estimată din aceleași date, iar împărțirea la n − 1 face estimatorul nedeplasat

d) pentru că datele sunt corelate

3. Într-un grafic Q-Q, punctele stau aproape de o dreaptă pe tot domeniul. Ce înseamnă?

a) distribuția teoretică descrie bine forma datelor

b) datele sunt independente

c) media datelor este zero

d) datele sunt sigur normale

4. Testul Kolmogorov–Smirnov pentru o distribuție dă p = 0,87. Ce concluzie este corectă?

a) distribuția este sigur corectă

b) distribuția este respinsă la nivelul de 5%

c) trebuie folosită distribuția empirică

d) datele nu contrazic distribuția; o putem folosi, verificând impactul asupra rezultatelor

5. Timpii de servire ai unui API au media 96 ms și $Cs^2 = 2{,}2$. Care distribuție este practic exclusă?

a) lognormala

b) exponențiala

c) hiperexponențiala

d) distribuția empirică

6. Care este estimatorul de verosimilitate maximă al ratei λ a distribuției exponențiale, din valorile $x_1, \ldots, x_n$?

a) $\bar{x}$

b) s^2

c) $1/\bar{x}$

d) mediana

7. În metoda subțierii pentru un proces Poisson neomogen, cu ce probabilitate păstrăm un candidat generat la momentul t?

a) λ(t)/λmax

b) λmax/λ(t)

c) 1/2

d) e^(−λ(t))

8. Numărul de sosiri pe intervale de 10 minute are, pe toată ziua, dispersia de 2,4 ori mai mare decât media. Ce indică?

a) sosirile sunt un proces Poisson omogen

b) datele sunt greșite

c) sosirile sunt deterministe

d) rata variază pe parcursul zilei; nu avem un singur proces Poisson omogen

9. Pentru care studiu este necesară eliminarea unei perioade de încălzire?

a) clienții serviți de o bancă între 9:00 și 17:00

b) timpul de răspuns pe termen lung al unui server care rulează permanent

c) durata unui proiect de construcție

d) traficul dintr-o intersecție în timpul unui meci

10. Un student raportează intervalul $\bar{W} \pm 1{,}96 \cdot s/\sqrt{20\,000}$ calculat din cei 20 000 de clienți ai unei singure rulări. Ce problemă are?

a) niciuna, n este mare

b) trebuia folosit t în loc de 1,96

c) timpii clienților consecutivi sunt corelați, deci intervalul este mult prea îngust

d) intervalul este prea larg

11. Avem doar 5 replicări. Ce cuantilă folosim pentru un interval de încredere de 95%?

a) $t(0{,}975;\ 4) = 2{,}776$

b) $z = 1{,}96$

c) $t(0{,}975;\ 5) = 2{,}571$

d) $z = 1{,}645$

12. De ce reduc numerele aleatoare comune dispersia diferenței dintre două variante?

a) fiecare variantă are dispersie mai mică

b) se elimină încălzirea

c) se folosesc mai multe replicări

d) rezultatele celor două variante devin corelate pozitiv, iar $\mathrm{Var}(A - B) = \mathrm{Var}(A) + \mathrm{Var}(B) - 2\mathrm{Cov}(A, B)$ scade

13. Care afirmație descrie corect validarea unui model de simulare?

a) verificăm că programul nu are erori de compilare

b) verificăm că modelul reprezintă suficient de bine sistemul real pentru scopul studiului

c) verificăm că rezultatele sunt reproductibile

d) verificăm că programul implementează fidel modelul conceptual

14. Un model reproduce corect gradul de ocupare al serverelor, dar subestimează timpul de așteptare. Care este cauza cea mai probabilă?

a) rata sosirilor este greșită

b) numărul de servere este greșit

c) variabilitatea timpilor de servire sau a sosirilor este subestimată

d) sămânța generatorului este nepotrivită

15. La o unitate de urgențe cu ocupare 0,83, o eroare de +10% la rata sosirilor mărește așteptarea medie de peste 2 ori. De ce?

a) aproape de saturație, așteptarea crește ca $1/(1 - \rho)$, deci erorile mici ale intrărilor sunt amplificate

b) pentru că simularea are prea puține replicări

c) pentru că rata sosirilor nu este Poisson

d) pentru că medicii lucrează mai încet

16. Cinci replicări independente dau timpii medii 4, 6, 5, 7 și 8 minute. Care este estimarea mediei (în minute)?

(Răspuns numeric)

17. Din replicări pilot estimăm $s = 2$. Folosind $t \approx 2$, câte replicări sunt necesare pentru o semilățime a intervalului de 0,5? ($R = (t \cdot s/h)^2$)

(Răspuns numeric)

18. Într-un experiment 2^2, W este: 8 (A jos, B jos), 5 (A sus, B jos), 10 (A jos, B sus), 3 (A sus, B sus). Care este efectul principal al lui A?

(Răspuns numeric)

19. Un server cu sosiri Poisson are $\rho = 0{,}5$, timpul mediu de servire $s = 2$ min și $Cs^2 = 3$. Care este așteptarea medie în coadă Wq, în minute (Pollaczek–Khinchine)?

(Răspuns numeric)

20. Nouă replicări au abaterea standard $s = 6$. Care este eroarea standard a mediei, $s/\sqrt{n}$?

(Răspuns numeric)

Răspunsuri

1. b) – Mediana depinde doar de valoarea din mijloc, deci este robustă la valori aberante (5,46 → 5,47).

2. c) – Abaterile față de media de selecție sunt sistematic puțin mai mici decât cele față de media adevărată; n − 1 corectează această deplasare.

3. a) – Graficul Q-Q compară cuantilele datelor cu cele teoretice; o dreaptă înseamnă o formă potrivită. Nu demonstrează însă că distribuția este exact cea corectă.

4. d) – O p-valoare mare înseamnă doar că nu avem motive să respingem distribuția; nu demonstrează că este corectă.

5. b) – Exponențiala are întotdeauna $Cs^2 = 1$ (iar Erlang are $Cs^2 < 1$); datele au variabilitate dublă.

6. c) – Maximizând $\Sigma \ln(\lambda e^{(-\lambda x_i)}) = n \ln \lambda - \lambda \Sigma x_i$ obținem $\hat{\lambda} = n/\Sigma x_i = 1/\bar{x}$.

7. a) – Generăm un proces omogen cu rata λmax și păstrăm fiecare candidat cu probabilitatea $\lambda(t)/\lambda max$ (Lewis–Shedler).

8. d) – Pentru Poisson dispersia este egală cu media. Amestecul de ore liniștite și de vârf mărește dispersia; modelăm ziua pe intervale, fiecare cu rata ei.

9. b) – Doar simulările staționare au o stare inițială artificială care introduce deplasare; celelalte sunt terminale.

10. c) – Formula presupune observații independente; din cauza autocorelației intervalul real este de aproximativ 10 ori mai larg. Corect: replicări sau medii pe loturi.

11. a) – Cu R replicări folosim distribuția Student cu $R - 1 = 4$ grade de libertate; 1,96 ar da un interval cu 42% prea îngust.

12. d) – Dispersia fiecărei variante rămâne aceeași; covarianța pozitivă reduce dispersia diferenței.

13. b) – Validarea: „am construit modelul corect?”. Varianta D descrie verificarea: „am construit corect modelul?”.

14. c) – Ocuparea depinde doar de λ și de media servirii; variabilitatea nu o afectează, dar crește puternic așteptarea (Pollaczek–Khinchine).

15. a) – Lângă $\rho = 1$ numitorul $1 - \rho$ este mic; de aceea λ și s trebuie estimate foarte precis, iar un medic în plus face decizia robustă.

16. 6 – $\bar{Y} = (4 + 6 + 5 + 7 + 8)/5 = 30/5 = 6$.

17. 64 – $R = (2 \cdot 2 / 0{,}5)^2 = 8^2 = 64$.

18. -5 – Media la A sus: (5 + 3)/2 = 4; media la A jos: (8 + 10)/2 = 9; efectul = 4 − 9 = −5.

19. 4 – $W_q = \rho(1 + C_s^2)/(2(1 - \rho)) \cdot s = 0{,}5 \cdot 4 / 1 \cdot 2 = 4$ minute.

20. 2 – $s/\sqrt{n} = 6/\sqrt{9} = 6/3 = 2$.

Bibliografie

- Ș. Holban – Tehnici de modelare și simulare, cap. 4: analiza datelor, estimare, validarea modelelor (materiale de curs).
- R. J. Gibbens – Computer Systems Modelling, University of Cambridge – analiza ieșirilor și reducerea dispersiei; foaia de exerciții 1.
- A. M. Law – Simulation Modeling and Analysis, ed. 5, McGraw-Hill, 2015.
- J. Banks, J. S. Carson, B. L. Nelson, D. M. Nicol – Discrete-Event System Simulation, ed. 5, Pearson, 2010.
- R. G. Sargent – Verification and validation of simulation models, Journal of Simulation, 7(1), 2013.
- O. Balci – Verification, validation and testing, în J. Banks (ed.), Handbook of Simulation, Wiley, 1998.
- P. D. Welch – The statistical analysis of simulation results, în S. Lavenberg (ed.), Computer Performance Modeling Handbook, Academic Press, 1983.
- P. A. W. Lewis, G. S. Shedler – Simulation of nonhomogeneous Poisson processes by thinning, Naval Research Logistics Quarterly, 26(3), 1979.
- S. M. Stigler – Do robust estimators deal with real data?, Annals of Statistics, 5(6), 1977.
- D. C. Montgomery – Design and Analysis of Experiments, Wiley.
- Material realizat cu ajutorul Claude Fable 5.1 și Claude Opus 5.5.