MODELARE ȘI SIMULARE

Săptămâna 9. Modelarea bazată pe agenți și sisteme complexe

Suport de curs · Anul III, Calculatoare și Tehnologia Informației

Ș.l. dr. ing. Cătălin Iapă

Obiective

1. să definiți un agent prin percepție, stare, comportament și acțiune și să distingeți agenții reactivi, cu stare și care învață;
2. să alegeți mediul (grilă, spațiu continuu, rețea), tipul de interacțiune și schema de actualizare (sincronă, asincronă) a unui model;
3. să implementați modelele clasice Boids, Schelling, Deneubourg, chemotaxia și El Farol și să interpretați fenomenele emergente;
4. să comparați un model epidemic cu agenți cu modelul cu ecuații și să explicați rolul spațiului, al rețelelor de lume mică și al huburilor;
5. să descrieți un model cu protocolul ODD, să stabiliți numărul de replicări, să calibrați parametrii prin ABC și să validați pe tipare;
6. să evaluați critic simulările cu agenți generativi bazați pe modele de limbaj, în special problema validării.

Cuvinte cheie: *agent, autonomie, percepție, stare internă, agent reactiv, agent cu stare, agent care învață, sistem multi-agent, model bazat pe agenți, mediu, topologia interacțiunilor, stigmergie, actualizare sincronă, actualizare asincronă, abordare lagrangiană, abordare euleriană, model SEIRS, El Farol, raționalitate limitată, Boids, parametru de ordine, segregarea Schelling, prag de toleranță, modelul Deneubourg, chemotaxie, lume mică, rețea fără scară, hub, vaccinare țintită, protocolul ODD, replicări, analiză de sensibilitate, ABC, modelare orientată pe tipare, docking, Mesa, NetLogo, agenți generativi*

1. De la ecuații la agenți

1.1. Limitele modelelor cu populație omogenă

În săptămâna a șaptea am modelat epidemii cu ecuațiile Kermack–McKendrick. Profesorul Holban (cap. 7) enumeră presupunerile lor: populația este fixă și **omogenă** (nu contează vârsta, structura socială sau localizarea), incubația este instantanee, durata bolii este aceeași pentru toți, iar contactele sunt complet aleatoare. Când coeficienții variază în timp vorbim de un **model comportamental**; când variațiile vin din deciziile și relațiile indivizilor, este mai natural să modelăm direct indivizii. Marea deficiență a modelelor cu ecuații, spune Holban, este absența mediului geografic – adăugarea lui și a relațiilor dintre entități a dus la **modelarea bazată pe agenți** (ABM): sistemul este o colecție de agenți care interacționează între ei și cu mediul, iar comportamentul global **emerge** din aceste interacțiuni.

1.2. Agentul: percepție, stare, comportament, acțiune

Un **agent** este o entitate care funcționează continuu și autonom într-un mediu în care au loc alte acțiuni și în care există alți agenți. Holban folosește trei concepte: **poziționarea** (primește informații din mediu și îl modifică prin acțiuni), **autonomia** (își controlează acțiunile și starea internă) și **flexibilitatea** (reacționează la timp, urmărește scopuri, interacționează). Formal, dacă S este mulțimea stărilor mediului și A mulțimea acțiunilor, un agent standard este o funcție acțiune : S → *A, care asociază istoricului* $s_0, a_0, s_1, a_1, \ldots$ *o acțiune;*

funcția se separă în percepție : S → P și acțiune : P → A. Cernazean (L8) desenează agentul ca o buclă: percepție, comportament, eventual memorie, acțiune asupra mediului.

Un **agent reactiv** (reflex simplu) decide doar după percepția curentă: acțiune : S → A, sau, în notația lui Cernazean, PERCEPȚIE → ACȚIUNE. Un **agent cu stare** (cognitiv) are o memorie internă I, actualizată de funcția următor : I × P → I, iar decizia depinde de această stare: PERCEPȚIE × STARE → ACȚIUNE × STARE. Agentul cu stare poate învăța. Clasificarea lui Russell și Norvig adaugă agenții orientați pe scop, pe utilitate și agenții care învață. Regula practică în simulare: folosim agentul cel mai simplu care reproduce fenomenul, pentru că bogăția comportamentului vine din interacțiuni.

Exemplul termostatului arată cât contează o singură variabilă de stare (Figura 1). Într-o cameră care se răcește spre 5 °C, cu un senzor care are zgomot de 0,1 °C, un termostat reactiv („pornește dacă T < 20 °C") comută de **764** de ori pe zi. Un termostat cu stare, care își amintește dacă încălzirea e pornită și folosește pragurile 19,5 °C pentru pornire și 20,5 °C pentru oprire (histerezis), comută doar de **47** de ori, cu aceeași fracțiune de funcționare (52%).

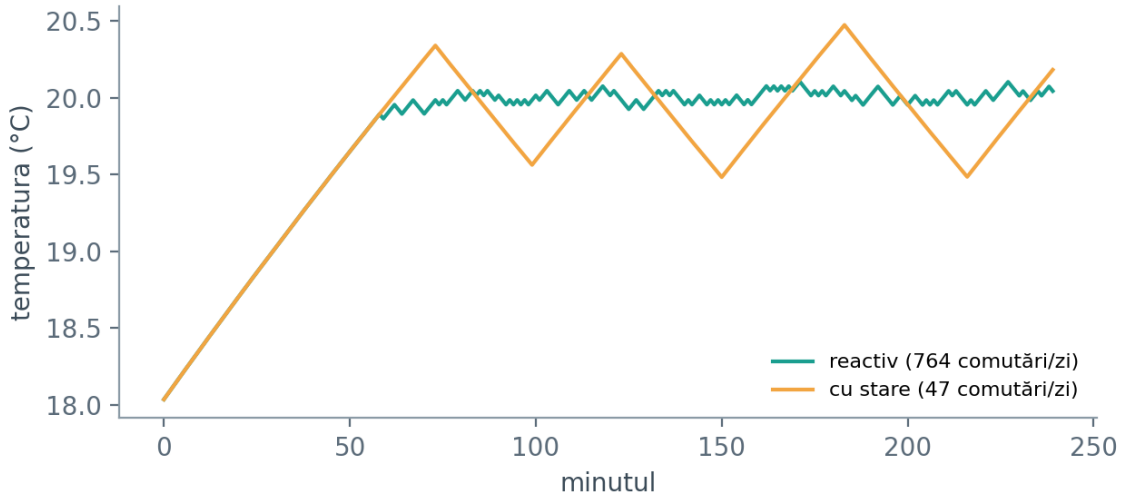


Figura 1. Termostat reactiv vs termostat cu stare: temperatura în primele 4 ore și numărul de comutări pe zi

1.3. Sisteme multi-agent: mediu, interacțiuni, actualizare

Un **sistem multi-agent** conține mai mulți agenți, identici sau diferiți, care interacționează direct sau prin mediu; nu orice sistem multi-agent este un model de simulare (Cernazean: există sisteme multi-agent pentru optimizare, securitate sau jocuri). **Mediul** poate lipsi (oricine întâlnește pe oricine – echivalentul ecuațiilor), poate fi o grilă, un spațiu continuu, o rețea sau o hartă reală. Interacțiunile pot fi **directe** (mesaje: contactul de infectare din modelul Holban), **prin mediu** (stigmergie: furnicile reacționează la cadavrele mutate de altele) sau **globale** (prețul unei piețe). Percepția este limitată de rază, unghi de vedere și obstacole; graurii, de exemplu, urmăresc aproximativ 6–7 vecini, indiferent de distanță (Ballerini et al., 2008).

Implementarea poate fi **lagrangiană** (o listă de agenți cu poziții exacte; găsirea vecinilor costă $O(N^2)$ naiv, mai puțin cu arbori k-d) sau **euleriană** (o grilă în care fiecare celulă are lista agenților din ea; interacțiuni locale și paralelizabile, dar cu pierderea preciziei spațiale). Agenții se pot actualiza **sincron** (toți percep aceeași stare, ca la automatele celulare; trebuie rezolvate conflictele) sau **asincron** (pe rând, în ordine amestecată la fiecare pas). Alegerea contează: pe un inel cu opinii alternante, regula majorității aplicată sincron produce o oscilație perpetuă (oscilează), iar aplicată asincron ajunge la punct fix după 1 rundă – oscilația era un artefact. Timpul poate avansa în pași ficși sau prin evenimente discrete programate de agenți (legătura cu S5).

1.4. Exemplul Holban: o epidemie SEIRS cu 10 000 de agenți

Modelul din cursul profesorului Holban: 10 000 de persoane distribuite uniform pe 10 × 10 km; fiecare cunoaște doar oamenii aflați la cel mult 1 km; inițial 10 persoane infectate; un infectat contactează cel mult 5 vecini pe zi, iar un contact transmite boala cu probabilitatea 0,1; latența (Expus) durează uniform 3–6 zile, boala (Infecțios) 7–15 zile, imunitatea 30–70 de zile, după care persoana redevine susceptibilă. Comportamentul fiecărei persoane este o diagramă de stări S → E → I → R → S, iar contactele sunt mesaje între agenți. Numărul de reproducere de bază rezultă direct: $R_0 = 5 \times 0{,}1 \times 11 = 5{,}5$.

```
inf = np.flatnonzero(st == I)
src = np.repeat(inf, 5)                      # 5 contacte pe zi
k = (rng.random(len(src)) * grad[src]).astype(int)
tgt = vecini[start[src] + k]                 # vecini aleatori pe 1 km
noi = tgt[(st[tgt] == S) & (rng.random(len(tgt)) < 0.1)]
timer -= 1   # apoi tranzițiile E->I, I->R, R->S și noii expuși
```

Simularea vectorizată a unui an durează sub o secundă. Pe hartă (Figura 2) se vede un **front epidemic** care traversează orașul – ceva imposibil într-un model fără spațiu. Comparația cu varianta fără spațiu (contacte alese din toată populația) și cu ecuațiile SEIRS cu aceleași medii (Figura 3, Tabelul 1) arată trei efecte: duratele uniforme, mai regulate decât cele exponențiale presupuse de ecuații, produc vârfuri mai ascuțite (5 224 față de 3 608); spațiul coboară vârful (3 229), pentru că vecinii unui bolnav sunt deja infectați sau imuni; iar modelele cu agenți produc **valuri** repetate, cu perioade aproape de stingere (doar 1 infecțios fără spațiu), în timp ce ecuațiile se liniștesc într-un echilibru de ~1 364 infecțioși.

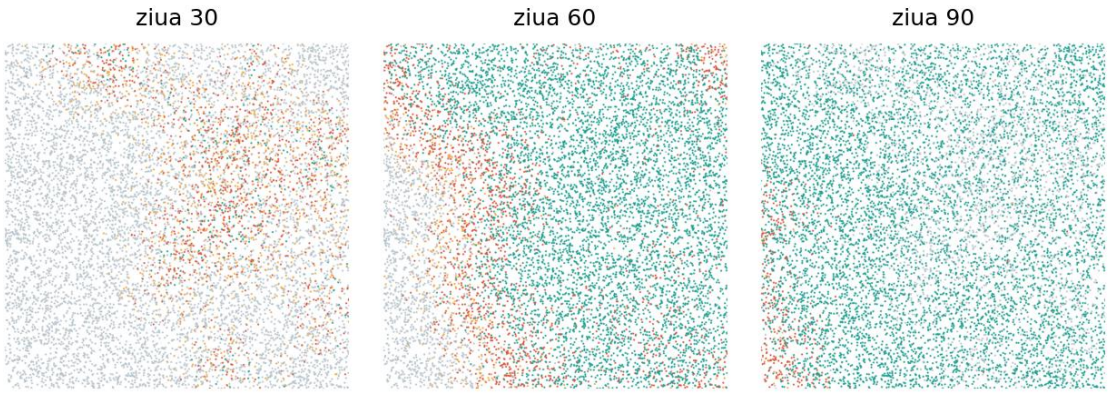


Figura 2. Modelul Holban în spațiu: infecțioși (roșu), expuși (galben), recuperați (verde), susceptibili (gri) la zilele 30, 60 și 90

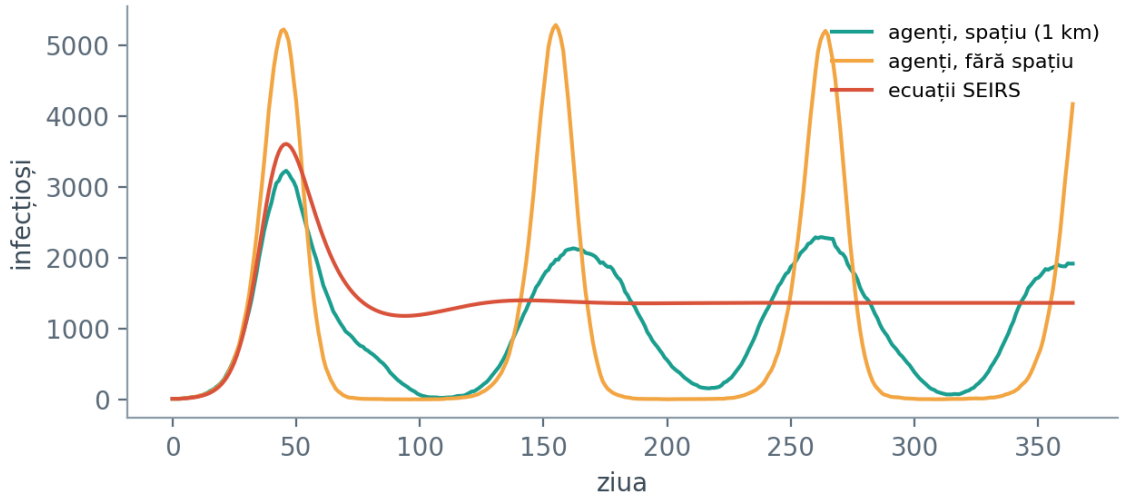


Figura 3. Infecțioși în timp pentru trei modele cu aceiași parametri medii: agenți în spațiu, agenți fără spațiu și ecuațiile SEIRS

Tabelul 1. Ce schimbă spațiul și indivizii în modelul Holban

Mărimea	Ecuații	Agenți, fără spațiu	Agenți, în spațiu
Primul vârf (infecțioși)	3 608	5 224	3 229
Ziua primului vârf	46	45	46
Minimul dintre valuri	≈ 1 364	1	23
Pe termen lung	echilibru endemic	valuri, aproape de stingere	valuri locale, focare

Textul original conține două neconcordanțe, utile ca exercițiu de verificare. Probabilitatea de transmisie apare o dată ca 0,1 și o dată ca „0,1%”; cu 0,1%, $R_0 \approx 0{,}055$ și epidemia nu ar porni. Apoi, suprafața de 10 × 10 km este descrisă ca o matrice 1 000 × 1 000 cu celule de 100 × 100 m; corect ar fi 100 × 100 de celule (sau celule de 10 m). Lecția: înainte de a rula un model, calculăm pe hârtie o mărime cheie, cum este R_0.

1.5. Agenți care învață: barul El Farol

În problema lui Brian Arthur (1994), 100 de oameni decid săptămânal, fără să comunice, dacă merg la un bar care este plăcut doar dacă vin cel mult 60. Fiecare agent are câțiva predictori ai prezenței („ca săptămâna trecută”, „media ultimelor 4 săptămâni”, „opusul săptămânii trecute”) și îl folosește pe cel care a greșit cel mai puțin; încrederea în predictori se actualizează din experiență. Cu predictori diferiți, prezența se auto-organizează în jurul capacității (medie 57,6, abatere 14,7); cu predictori identici, toți iau aceeași decizie și barul este alternativ plin și gol (Figura 4). Lecțiile: raționalitate limitată, o „ecologie” de predictori în care succesul unei strategii o face să eșueze când devine populară și importanța diversității – exact ce nu poate surprinde un model cu un agent reprezentativ.

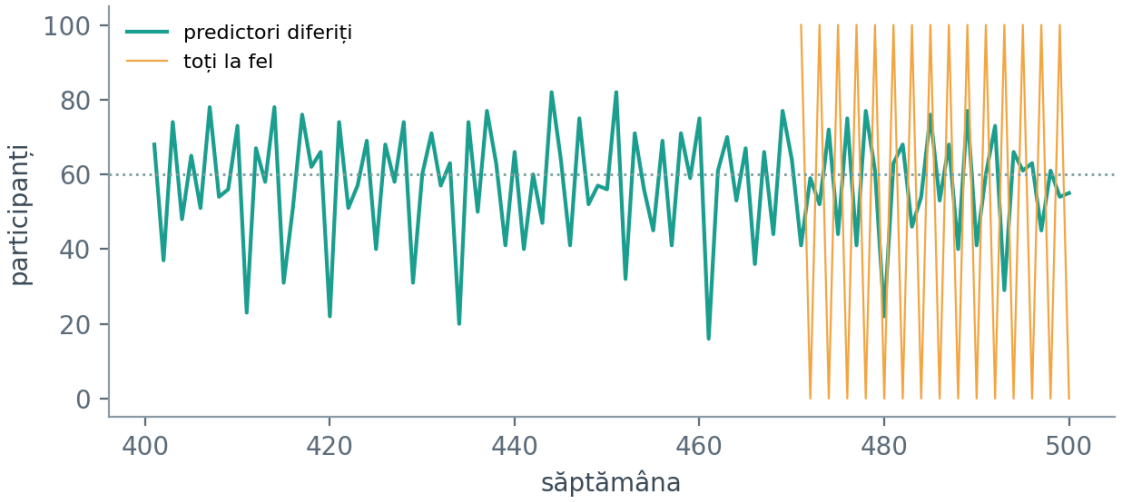


Figura 4. Prezența la barul El Farol: agenți cu predictori diferiți (auto-organizare în jurul capacității 60) și agenți cu același predictor (oscilație 100–0)

Un model bazat pe agenți merită construit când interacțiunile sunt discrete și structurate (spațiu, rețea), când indivizii sunt eterogeni, când agenții învață sau se adaptează, când ne interesează fenomene emergente sau evenimente rare și când informația există la nivel individual (Bonabeau, 2002). Dacă populația este mare, omogenă și bine amestecată, iar ne interesează doar mediile, ecuațiile rămân mai rapide și mai transparente.

De reținut

Agent = percepție + (stare) + comportament + acțiune; reactiv: S → A; cu stare: P × I → A × I. Mediu: fără spațiu, grilă, spațiu continuu, rețea, hartă. Interacțiuni: directe, prin mediu (stigmergie), globale. Actualizarea sincronă poate crea artefacte; asincron cu ordine amestecată. Holban SEIRS: $R_0 = 5 \times 0{,}1 \times 11 = 5{,}5$; spațiul coboară vârful și produce valuri. El Farol: diversitatea strategiilor produce auto-organizare.

2. Modele clasice

2.1. Boids (Reynolds, 1987)

Fiecare boid vede vecinii dintr-o rază dată și își ajustează viteza după trei reguli: **separare** (evită vecinii prea apropiați), **aliniere** (își potrivește viteza cu media vecinilor) și **coeziune** (se îndreaptă spre centrul vecinilor). Holban îl clasifică drept agent reactiv. În implementarea noastră (150 de boizi, spațiu periodic 100 × 100, raze 2,5 și 10, ponderi 0,15 / 0,05 / 0,005, viteză constantă), parametrul de ordine ϕ = |viteza medie| crește de la 0,08 la 0,99, iar boizii formează câteva stoluri compacte (Figura 5). Fără aliniere, ϕ rămâne 0,07: grupuri fără direcție comună. Vectorizarea pasului cu matrice N × N este de ~16 de ori mai rapidă decât buclele Python pentru N = 300. Boids a fost folosit în filme (Batman Returns, 1992), a inspirat modelul Vicsek (1995) din fizică și controlul roiurilor de drone.

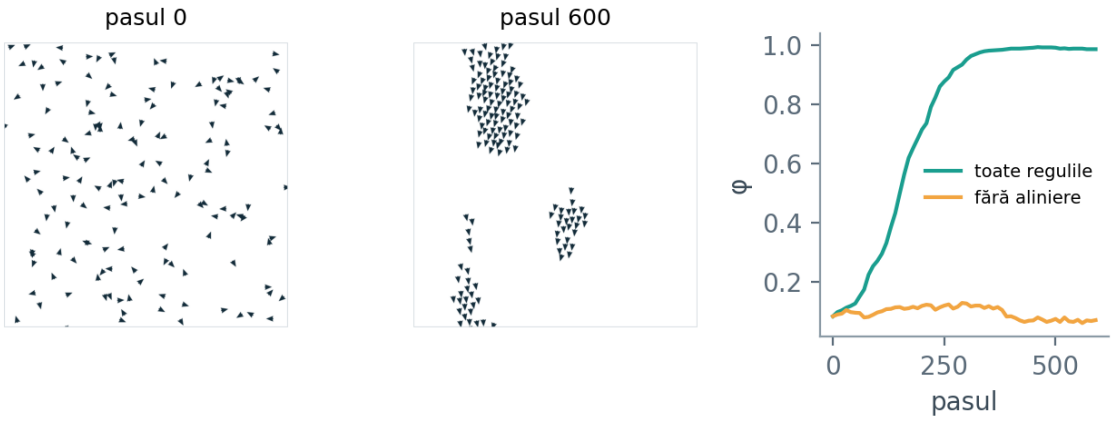


Figura 5. Boids: starea inițială, starea după 600 de pași și parametrul de ordine ϕ, cu și fără regula de aliniere

2.2. Segregarea Schelling (1971) – demo-ul săptămânii

Pe o grilă 50 × 50, 90% ocupată de agenți din două grupuri egale, fiecare agent este mulțumit dacă cel puțin o fracțiune t dintre vecinii ocupați sunt din grupul lui; altfel se mută într-o casă goală aleasă la întâmplare (actualizare asincronă, în ordine aleatoare). Cu t = 0,3 – un agent acceptă liniștit să fie în minoritate – fracțiunea medie de vecini din același grup crește de la 50% la **74%** în 11 runde (Figura 6). Cu t = 0,5 ajunge la 88%, cu t = 0,75 la 99%, iar peste aproximativ 0,8 nu mai există echilibru: 85% dintre agenți rămân nemulțumiți și se mută la nesfârșit. Lecția lui Schelling (Micromotives and Macrobehavior, 1978): din tiparul global nu putem deduce intențiile indivizilor – segregarea puternică poate apărea din preferințe slabe. Modelul nu dovedește însă că segregarea reală are această cauză.

```
class Locuitor(mesa.Agent):
    def __init__(self, model, grup):
        super().__init__(model)
        self.grup = grup
    def step(self):
        vec = self.model.grid.get_neighbors(self.pos, moore=True)
        la_fel = sum(v.grup == self.grup for v in vec)
        if vec and la_fel / len(vec) < self.model.prag:
            self.model.grid.move_to_empty(self)
# Model: mesa.space.SingleGrid(50, 50, torus=True); step: self.agents.shuffle_do("step")
```

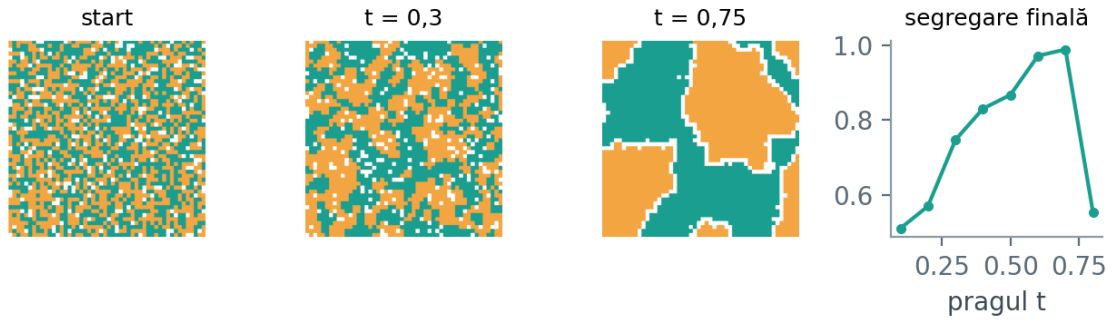


Figura 6. Schelling: amestecul inițial, starea finală pentru t = 0,3 și t = 0,75 și segregarea finală în funcție de prag

2.3. Furnicile lui Deneubourg și chemotaxia (Cernazean L8)

Furnicile Messor sanctus adună cadavrele coloniei în câteva grămezi (Jost et al., 2007). În modelul lui Deneubourg (1991), furnicile fac pași aleatori pe o grilă și au o memorie a ultimilor n pași; dacă f este fracțiunea de cadavre întâlnite recent, o furnică neîncărcată ridică un cadavru cu probabilitatea $P_p = (k_1/(k_1 + f))^2$, iar una încărcată îl lasă cu $P_d = (f/(f + k_2))^2$. (În slide-urile originale f apare ca suma memoriei; ca parametrii

$k_1 = 0{,}1$ și $k_2 = 0{,}3$ să fie comparabili, f trebuie să fie o fracțiune.) Cu 40 de furnici și 640 de cadavre pe o grilă 80 × 80, după 400 000 de pași rămân 7 grămezi, cea mai mare cu 122 de cadavre (Figura 7). Cernazean arată că și furnicile „proaste”, fără memorie, formează grămezi: mecanismul de bază sunt fluctuațiile statistice, iar inteligența doar accelerează procesul; timpul scade proporțional cu numărul de furnici, deci nu este un efect colectiv. Interacțiunea prin mediu se numește **stigmergie** (Grassé, 1959).

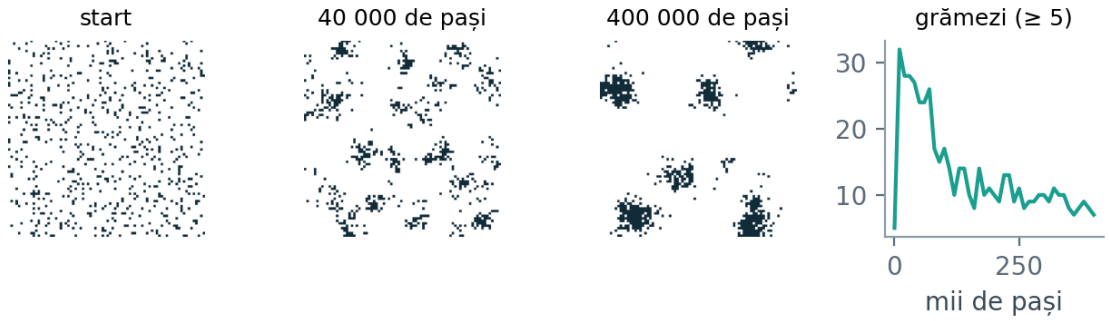


Figura 7. Modelul Deneubourg: cadavrele la început, după 40 000 și 400 000 de pași și numărul de grămezi cu cel puțin 5 cadavre

Bacteria E. coli alternează alergarea în linie dreaptă cu rostogolirea într-o direcție aleatoare. Nu poate măsura gradientul, dar își amintește concentrația de nutrient de acum o clipă: dacă aceasta a crescut, se rostogolește rar ($p\uparrow = 0{,}1$), altfel des ($p\downarrow = 0{,}5$). Cu această memorie de un singur număr, 300 de bacterii care pornesc la distanța 40 de sursă ajung la o distanță medie de 7,3, iar 74% se află în raza 10; fără memorie se împrăștie (distanța 55,3, 2% în raza 10) – Figura 8.

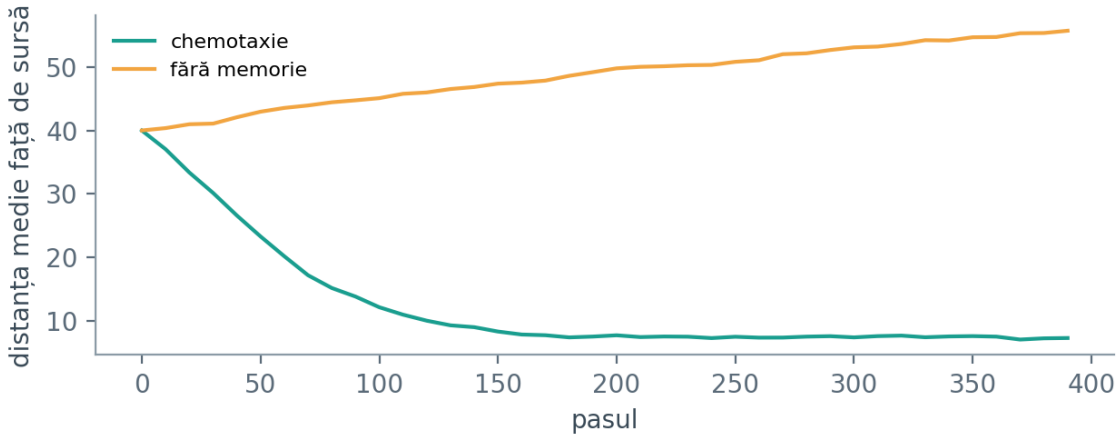


Figura 8. Chemotaxia: distanța medie până la sursa de hrană, cu și fără memoria concentrației

2.4. Epidemii pe rețele: lume mică și huburi

Un model SIR cu agenți poate folosi o rețea de contacte. Rețelele reale au două proprietăți. **Lumea mică** (Watts și Strogatz, 1998): câteva legături aleatoare adăugate unei rețele regulate scurtează dramatic drumurile, păstrând grupurile locale – pentru 1 000 de noduri cu câte 10 vecini, recablarea a 1% dintre legături reduce drumul mediu la 17% din valoarea inițială (50,5 pași), iar clusterizarea rămâne 97%. **Rețelele fără scară** (Barabási și Albert, 1999): atașamentul preferențial produce câteva huburi foarte conectate – cu grad mediu 6, gradul maxim este 273, față de 16 într-o rețea aleatoare, iar 1% dintre noduri au 11% din legături (Figura 9).

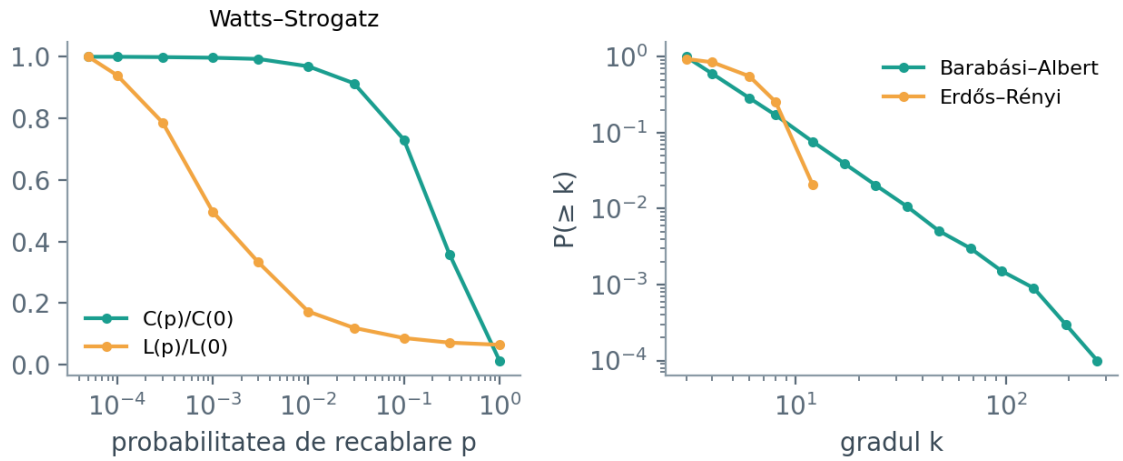


Figura 9. Stânga: clusterizarea și drumul mediu în rețeaua Watts–Strogatz în funcție de probabilitatea de recablare. Dreapta: distribuția gradelor (P(grad ≥ k)) pentru Barabási–Albert și Erdős–Rényi

Tabelul 2. SIR pe rețele cu 10 000 de noduri și grad mediu 6 (transmisie 0,06 pe legătură și zi, vindecare 0,2 pe zi)

Rețeaua	Infectați în total	Vârful
Aleatoare (Erdős–Rényi)	55,5%	7,0%
Fără scară (Barabási–Albert)	55,3%	14,3%
BA, 10% vaccinați la întâmplare	43,5%	10,4%
BA, 10% vaccinați: huburile	0,3%	0,1%

Pe rețeaua fără scară, huburile se infectează devreme, iar vârful este de două ori mai înalt. Aceleași 1 000 de doze reduc epidemia doar cu un sfert dacă sunt date la întâmplare, dar o opresc aproape complet dacă sunt date huburilor (Tabelul 2). Cum nu știm cine sunt huburile, putem vaccina câte un prieten al unor oameni aleși la întâmplare (Cohen et al., 2003): datorită paradoxului prieteniei (Feld, 1991), prietenii sunt în medie mai conectați.

De reținut

Boids: separare, aliniere, coeziune; ϕ măsoară ordinea; alinierea creează direcția comună. Schelling: pragul 30% produce ~74% vecini similari; peste ~0,8 nu există echilibru. Deneubourg: $Pp = (k_1/(k_1+f))^2$, $Pd = (f/(f+k_2))^2$; grămezi din fluctuații; stigmergie. Chemotaxie: o valoare memorată. Rețele: lume mică (drumuri scurte + grupuri), fără scară (huburi); vaccinarea huburilor oprește epidemia.

3. Ingineria unui ABM și frontiera

3.1. Etapele unui model și protocolul ODD

Holban propune o listă de întrebări înaintea codului: scopul (ce sistem, ce întrebări, de ce agenți), agenții (ce entități, ce date), structura (atribute statice și dinamice, mobilitate), comportamentul (decizii, reguli dacă–atunci, probabilități, regresii, rețele neuronale), interacțiunile și rezultatele (experimente, validare). Orice model trebuie să decidă explicit cum rezolvă **conflictele**, cum se mișcă agenții într-un mediu cu mai multe

straturi, cum separă regulile de mecanismul care le schimbă și dacă agenții învață (North și Macal, 2011). Epstein (2008) amintește că predicția nu este singurul scop: modelele explică mecanisme, compară scenarii, ghidează colectarea de date și ajută la predare.

Protocolul **ODD** (Overview, Design concepts, Details; Grimm et al., 2006, actualizat în 2010 și 2020) standardizează descrierea modelelor, astfel încât oricine să le poată reimplementa (Tabelul 3). Conceptele de proiectare sunt o listă de verificare: emergență, adaptare, obiective, învățare, predicție, percepție, interacțiune, stocasticitate, colective și observare.

Tabelul 3. Elementele protocolului ODD și exemplul Schelling

Element	Întrebarea	Schelling
Scop și tipare	Ce explică modelul? După ce tipare îl judecăm?	segregare din preferințe slabe; fracțiunea de vecini similari
Entități, variabile, scări	Ce agenți, ce mediu, ce unități?	locuitori (grup 1/2); grilă 50 × 50 toroidală; pas = rundă
Procese și ordonare	Ce se întâmplă la fiecare pas și în ce ordine?	în ordine aleatoare: verifică vecinii, mută-te dacă e cazul
Concepte de proiectare	Ce emerge? Ce percep agenții? Unde e aleatorul?	cartiere; 8 vecini; ordinea și casa nouă
Inițializare	Starea la t = 0?	90% ocupare, grupuri egale, aleator (seed)
Date de intrare	Ce date externe?	niciuna
Submodele	Detaliile proceselor	mulțumit dacă similari / ocupați ≥ t

3.2. Replicări, sensibilitate, calibrare și validare

Un ABM este stocastic, deci raportăm medii pe replicări, cu intervale de încredere, seed-uri controlate și numere aleatoare comune la compararea scenariilor (S6). În 60 de rulări ale modelului Holban cu 2 500 de agenți, vârful epidemiei are media 1 164 și abaterea 66 (între 950 și 1 283). Numărul de replicări pentru o semi-lățime h a intervalului de 95% este $n \approx (1{,}96 \cdot s / h)^2$; pentru h = 20 rezultă ~42 de replicări. Analiza de sensibilitate (unul câte unul, baleiere, planuri 2^k, Latin Hypercube, indici Sobol) arată ce parametri contează; atenție la tranzițiile bruște, ca la pragul Schelling. În Mesa, DataCollector și batch_run automatizează colectarea datelor și baleierea parametrilor, inclusiv în paralel.

Pentru un ABM nu putem scrie verosimilitatea datelor, dar putem simula. **ABC** (Approximate Bayesian Computation) prin respingere: eșantionăm parametri din distribuția a priori, simulăm, păstrăm cei mai apropiați 10% de date. Pentru modelul Holban, „datele observate” au fost generate cu p = 0,1; din 400 de simulări cu p uniform pe [0,02; 0,2], cele 41 acceptate dau media a posteriori 0,102 și intervalul credibil de 90% [0,091; 0,116], care conține valoarea adevărată (Figura 10). Validarea depășește validarea „de față”: **modelarea orientată pe tipare** (Grimm et al., 2005) cere reproducerea simultană a mai multor tipare observate, **docking**-ul compară implementări independente, iar testul cel mai puternic rămân datele nefolosite la calibrare.

```
prior = rng.uniform(0.02, 0.2, 400)
dist = np.array([rmse(saptamanal(model_holban(p=p, seed=5000 + k)), obs)
                 for k, p in enumerate(prior)])
```

```
acceptat = prior[dist <= np.quantile(dist, 0.10)]     # cele mai bune 10%
print(acceptat.mean(), np.quantile(acceptat, [0.05, 0.95]))
```

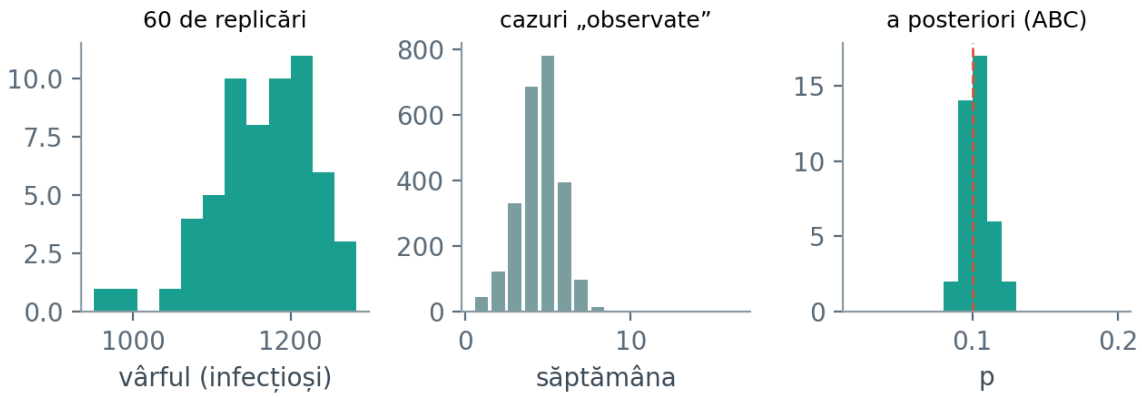


Figura 10. Stânga: vârful epidemiei în 60 de replicări. Mijloc: cazurile săptămânale „observate”. Dreapta: distribuția a posteriori a probabilității de transmisie obținută prin ABC (linia: valoarea adevărată 0,1)

3.3. Unelte și scară

Tabelul 4. Unelte pentru modelarea bazată pe agenți

Unealta	Caracteristici	Potrivită pentru
NetLogo 7	limbaj propriu; bibliotecă mare de modele; septembrie 2025	predare, prototipuri
Mesa 3	Python, NumPy, pandas; vizualizare în browser (3.5, martie 2026)	cercetare, analiză
AnyLogic	comercial; agenți + evenimente discrete + dinamica sistemelor	industrie, logistică
Repast4Py, MASON	Python cu MPI; Java performant	modele mari, paralele
GAMA, MATSim	hărți GIS; transport la scara unei țări	orașe, trafic
AgentTorch	GPU, diferențiabil, agenți bazați pe LLM	milioane de agenți

Performanța urmează ideile din S8: căutarea vecinilor cu grile sau arbori k-d, agenți reprezentați ca tabele vectorizate în loc de obiecte, replicări rulate în paralel. Modelele la scară mare includ MATSim pentru transport, CovidSim și Covasim pentru pandemii și AgentTorch, care a simulat 8,4 milioane de agenți pentru New York (COVID-19 și piața muncii) folosind „arhetipuri”: agenții cu aceleași caracteristici partajează un singur apel la modelul de limbaj.

3.4. Agenți generativi cu modele de limbaj

În „Generative agents” (Park et al., UIST 2023), 25 de agenți dintr-un oraș virtual au o descriere în limbaj natural, un flux de memorie, reflecție și planificare, iar un model de limbaj generează acțiunile și conversațiile. Pornind de la ideea dată unui singur agent de a organiza o petrecere de Ziua Îndrăgostiților, după două zile de joc 13 din 25 de agenți (52%) știau de ea, iar 5 dintre cei 12 invitați au venit la ora potrivită; densitatea rețelei de cunoștințe a crescut de la 0,17 la 0,74. În 2024, același grup a creat agenți pe baza

interviurilor cu 1 052 de persoane reale; agenții reproduc răspunsurile la General Social Survey cu 85% din consecvența cu care oamenii își reproduc propriile răspunsuri după două săptămâni.

Analiza critică a lui Larooij și Törnberg (Artificial Intelligence Review, 2026), pe 35 de studii, concluzionează că modelele de limbaj pot **agrava** problema validării: sunt cutii negre, reproduc stereotipuri, sunt costisitoare și stocastice, iar multe studii se bazează pe validare „de față” și pe o singură rulare. O validare serioasă compară cu date empirice, folosește multe replicări, face ablații (ce aduce agentul generativ față de reguli simple), verifică reproducerea modelelor clasice și raportează prompturile și versiunea modelului într-o descriere de tip ODD. Pentru orice ABM folosit în decizii reale, comunicăm incertitudinea, publicăm codul și protejăm datele individuale.

De reținut

Etape: scop, agenți, comportament, mediu și interacțiuni, experimente, validare. ODD: scop și tipare; entități; procese; concepte; inițializare; date; submodele. Replicări: $n \approx (1{,}96 \cdot s/h)^2$. ABC prin respingere: a priori, simulare, păstrăm cei mai apropiați 10%. Validare: tipare multiple, docking, date noi. Unelte: NetLogo, Mesa, AnyLogic, MATSim, AgentTorch. Agenți generativi: promițători, dar validarea rămâne problema centrală.

Glosar RO – EN

Română	English
agent	agent
model bazat pe agenți	agent-based model (ABM)
sistem multi-agent	multi-agent system
percepție	perception
stare internă	internal state
agent reactiv	reactive (simple reflex) agent
agent cu stare	stateful agent
comportament emergent	emergent behaviour
auto-organizare	self-organisation
mediu	environment
topologia interacțiunilor	interaction topology
stigmergie	stigmergy
actualizare sincronă / asincronă	synchronous / asynchronous update
rațională limitată	bounded rationality
parametru de ordine	order parameter
stol	flock

Română	English
prag de toleranță	tolerance threshold
segregare	segregation
chemotaxie	chemotaxis
alergare și rostogolire	run and tumble
lume mică	small world
rețea fără scară	scale-free network
atașament preferențial	preferential attachment
hub	hub
protocolul ODD	ODD protocol
replicare	replication
analiză de sensibilitate	sensitivity analysis
calcul bayesian aproximativ	approximate Bayesian computation (ABC)
modelare orientată pe tipare	pattern-oriented modelling
agent generativ	generative agent

Întrebări de autoevaluare

1. Ce caracterizează un agent **reactiv** (reflex simplu)?

a) are o memorie a tuturor acțiunilor trecute

b) decide doar pe baza percepției curente

c) învață din experiență

d) urmărește un plan pe termen lung

2. Un termostat cu histerezis pornește încălzirea sub 19,5 °C și o oprește peste 20,5 °C. De ce este un agent **cu stare**?

a) pentru că măsoară temperatura

b) pentru că are două praguri fixe

c) pentru că decizia depinde și de faptul că încălzirea este deja pornită sau oprită

d) pentru că folosește un senzor cu zgomot

3. Care este un exemplu de interacțiune prin **stigmergie**?

a) furnicile reacționează la cadavrele mutate anterior de alte furnici

b) o persoană infectată trimite un mesaj unui vecin

c) toți comercianții văd același preț

d) doi agenți negociază direct un contract

4. Pe un inel cu opinii alternante 0/1, regula majorității aplicată **sincron** produce o oscilație perpetuă, iar aplicată asincron se stabilizează. Ce concluzie este corectă?

a) actualizarea asincronă este greșită

b) opiniile reale oscilează la nesfârșit

c) regula majorității este instabilă

d) oscilația este un artefact al schemei de actualizare

5. Care este scopul principal al protocolului **ODD**?

a) accelerarea simulărilor

b) descrierea completă și standardizată a unui model, astfel încât să poată fi reimplementat

c) calibrarea automată a parametrilor

d) înlocuirea validării

6. În modelul Holban, de ce are varianta **spațială** (vecini pe 1 km) un prim vârf mai mic decât varianta fără spațiu?

a) pentru că probabilitatea de transmisie este mai mică

b) pentru că sunt mai puțini agenți

c) pentru că vecinii unui bolnav sunt adesea deja infectați sau imuni, deci contactele se „risipesc”

d) pentru că boala durează mai puțin

7. În problema barului El Farol, ce se întâmplă dacă **toți** agenții folosesc același predictor?

a) barul este alternativ plin și gol

b) prezența se stabilizează la exact 60

c) nimeni nu mai merge la bar

d) prezența devine aleatoare în jurul valorii 60

8. Care regulă din modelul **Boids** este responsabilă pentru faptul că stolul zboară într-o direcție comună?

a) separarea

b) alinierea

c) coeziunea

d) zgomotul

9. În modelul Schelling cu pragul de toleranță **30%** (grilă 50 × 50, 90% ocupată), aproximativ ce fracțiune de vecini din același grup are un agent la final?

a) 30%

b) 50%

c) 75%

d) 100%

10. Ce concluzie metodologică susține modelul lui Schelling?

a) segregarea reală este cauzată exclusiv de preferințe individuale

b) preferințele puternice sunt necesare pentru segregare

c) modelele cu agenți pot prezice exact compoziția cartierelor

d) din tiparul global nu putem deduce intensitatea preferințelor individuale

11. În modelul Deneubourg, $Pd = (f/(f + k_2))^2$. Când lasă o furnică încărcată cadavrul cu probabilitate mare?

a) când a întâlnit multe cadavre recent (f mare)

b) când a întâlnit puține cadavre recent (f mic)

c) întotdeauna după 20 de pași

d) când întâlnește o altă furnică

12. Cum găsește o bacterie E. coli sursa de hrană în modelul „alergare și rostogolire”?

a) măsoară gradientul la capetele celulei

b) se rostogolește mai rar când concentrația crește față de momentul anterior

c) urmează alte bacterii

d) cunoaște harta concentrației

13. Ce caracterizează o rețea de tip **lume mică** (Watts–Strogatz)?

a) puține noduri și puține legături

b) toate nodurile au același grad și drumuri lungi

c) drumuri medii scurte și clusterizare locală mare

d) câteva huburi cu mii de legături

14. Pe o rețea de contacte fără scară, avem doze pentru 10% din populație. Ce strategie reduce cel mai mult epidemia?

a) vaccinarea la întâmplare

b) vaccinarea celor cu cele mai puține contacte

c) nu contează strategia, doar procentul

d) vaccinarea celor mai conectate persoane (huburile)

15. Care este principala critică adusă de Larooij și Törnberg simulărilor cu **agenți generativi** (LLM)?

a) validarea este adesea doar „de față”, din puține rulări, iar modelele de limbaj sunt cutii negre cu prejudecăți

b) agenții nu pot vorbi între ei

c) simulările sunt prea rapide

d) nu se pot simula mai mult de 25 de agenți

16. În modelul Holban, un infectat are 5 contacte pe zi, transmisie 0,1 pe contact, iar boala durează în medie 11 zile. Cât este R_0?

(Răspuns numeric)

17. Dacă probabilitatea de transmisie din modelul Holban ar fi 0,1% (0,001), cu 5 contacte pe zi și 11 zile de boală, cât ar fi R_0? (3 zecimale)

(Răspuns numeric)

18. Modelul Schelling cu prag t = 0,3. Un agent are 7 vecini ocupați. Câți dintre ei trebuie să fie din grupul lui, **minimum**, ca să fie mulțumit?

(Răspuns numeric)

19. În modelul Deneubourg, $k_1 = 0,1$. O furnică neîncărcată găsește un cadavru, iar fracțiunea de cadavre din memoria ei este f = 0,1. Cu ce probabilitate îl ridică, $Pp = (k_1/(k_1 + f))^2$?

(Răspuns numeric)

20. Rulările pilot ale unui ABM dau o abatere standard s = 50 pentru mărimea de interes. Câte replicări trebuie, aproximativ, pentru o semi-lățime h = 10 a intervalului de încredere de 95%, cu $n = (1,96 \cdot s/h)^2$? (rotunjiți în sus)

(Răspuns numeric)

Răspunsuri

1. b) – Agentul reactiv implementează acțiune : S → A (Cernazean: PERCEPȚIE → ACȚIUNE); nu are stare internă.

2. c) – Între 19,5 și 20,5 °C, acțiunea depinde de starea memorată (pornit/oprit): PERCEPȚIE × STARE → ACȚIUNE × STARE.

3. a) – Stigmergia (Grassé, 1959) înseamnă coordonare prin urmele lăsate în mediu, fără comunicare directă.

4. d) – Schema de actualizare este o alegere de modelare; oamenii nu își schimbă opinia exact simultan, deci oscilația sincronă nu descrie fenomenul.

5. b) – ODD (Overview, Design concepts, Details) este un format de descriere care face modelele transparente și reproductibile.

6. c) – Parametrii sunt identici; diferența vine din structura contactelor: în spațiu, contactele se repetă local, iar saturarea locală încetinește epidemia.

7. a) – Toți primesc aceeași predicție și iau aceeași decizie, care își anulează premisa: 100 de participanți, apoi 0, și așa mai departe.

8. b) – Fără aliniere, parametrul de ordine rămâne mic (~0,07 în simularea noastră): boizii se grupează, dar nu au o direcție comună.

9. c) – Mutările succesive creează cartiere: fracțiunea medie crește de la ~50% la ~74%, deși fiecare agent ar accepta 30%.

10. d) – Preferințe slabe pot produce segregare puternică; modelul infirmă o explicație intuitivă, dar nu dovedește că acesta este mecanismul real.

11. a) – Pd crește cu f: furnica lasă cadavrul în zonele aglomerate, ceea ce face grămezile mari să crească.

12. b) – Bacteria compară concentrația actuală cu cea memorată; dacă a crescut, continuă mai mult în aceeași direcție ($p\uparrow < p\downarrow$).

13. c) – Câteva legături aleatoare într-o rețea regulată scurtează drumurile (de ex. la ~17% cu 1% recablare), păstrând grupurile locale.

14. d) – Huburile concentrează o mare parte din legături; în simularea noastră, vaccinarea lor reduce infectările de la ~55% la ~0,3%, față de ~44% la vaccinarea aleatoare.

15. a) – Analiza a 35 de studii arată că modelele de limbaj pot agrava problema validării ABM; sunt necesare comparații cu date empirice și multe replicări.

16. 5,5 – R_0 = contacte pe zi × probabilitatea de transmisie × durata = 5 × 0,1 × 11 = 5,5.

17. 0,055 – R_0 = 5 × 0,001 × 11 = 0,055 < 1: epidemia nu ar porni – de aceea valoarea „0,1%" din text este o neconcordanță.

18. 3 – Trebuie ca la_fel / 7 ≥ 0,3, adică la_fel ≥ 2,1, deci minimum 3 vecini (2/7 ≈ 0,29 nu ajunge).

19. 0,25 – $Pp = (0,1 / 0,2)^2 = 0,5^2 = 0,25$.

20. 97 – $n = (1,96 \cdot 50 / 10)^2 = 9,8^2 = 96,04$, deci 97 de replicări.

Bibliografie

- Ș. Holban – Tehnici de modelare și simulare, cap. 7: modelarea bazată pe agenți (materiale de curs).
- Prof. Cernazean – Modelling and Simulation, Lecture 8: Agent based models (materiale de curs).
- T. C. Schelling – Dynamic models of segregation, Journal of Mathematical Sociology, 1, 1971; Micromotives and Macrobehavior, Norton, 1978.
- C. W. Reynolds – Flocks, herds and schools: a distributed behavioral model, Computer Graphics (SIGGRAPH 1987), 21(4).
- J.-L. Deneubourg et al. – The dynamics of collective sorting: robot-like ants and ant-like robots, Simulation of Adaptive Behavior, MIT Press, 1991.
- W. B. Arthur – Inductive reasoning and bounded rationality, American Economic Review, 84(2), 1994.
- D. J. Watts, S. H. Strogatz – Collective dynamics of "small-world" networks, Nature, 393, 1998; A.-L. Barabási, R. Albert – Emergence of scaling in random networks, Science, 286, 1999.
- E. Bonabeau – Agent-based modeling: methods and techniques for simulating human systems, PNAS, 99, 2002; J. M. Epstein – Why model?, JASSS, 11(4), 2008.
- V. Grimm et al. – The ODD protocol for describing agent-based and other simulation models: a second update, JASSS, 23(2), 2020.
- S. F. Railsback, V. Grimm – Agent-Based and Individual-Based Modeling: A Practical Introduction, ed. 2, Princeton University Press, 2019.
- J. S. Park et al. – Generative agents: interactive simulacra of human behavior, UIST 2023; Generative agent simulations of 1,000 people, arXiv:2411.10109, 2024.
- M. Larooij, P. Törnberg – Validation is the central challenge for generative social simulation: a critical review of LLMs in agent-based modeling, Artificial Intelligence Review, 59, 2026.
- Mesa – documentația Mesa 3 (mesa.readthedocs.io); NetLogo 7 (ccl.northwestern.edu/netlogo).
- Material realizat cu ajutorul Claude Fable 5.1 și Claude Opus 5.5.